ARQUITETURA DE SISTEMAS OPERACIONAIS

4ª edição

Francis Berenger Machado
Luiz Paulo Maia

Incluindo exercícios com o simulador SOsim
e estudos de caso do MS Windows e Unix

LTC

www.baixebr.org

Arquitetura de Sistemas Operacionais

CÓPIA NÃO AUTORIZADA É CRIME
ABDR
ASSOCIAÇÃO BRASILEIRA DE DIREITOS REPROGRÁFICOS
RESPEITE O DIREITO AUTORAL

Arquitetura de Sistemas Operacionais

4.ª Edição

Francis Berenger Machado

(berenger@pobox.com)
Mestre em Administração de Empresas na PUC-Rio,
graduado em Engenharia Eletrônica pelo
Centro Federal de Educação Tecnológica do Rio de Janeiro (CEFET-RJ) e em
Informática pela PUC-Rio.
Atualmente trabalha na Atos Origin, além de lecionar no
Departamento de Informática da PUC-Rio.
Autor do livro *Fidelização de Clientes no Setor de Serviços*

Luiz Paulo Maia

(lpmaia@training.com.br)
Mestre em Informática pela UFRJ/NCE,
graduado em Informática pela PUC-Rio e pós-graduado
em Marketing pela mesma instituição.
Atualmente trabalha na Atos Origin, onde atua nas áreas de redes LAN e WAN,
além de lecionar na FGV, no IBMEC e na Unicarioca.
Co-autor do livro *Programação e Lógica com Turbo Pascal.*

LTC
EDITORA

No interesse de difusão da cultura e do conhecimento, os autores e os editores envidaram o máximo esforço para localizar os detentores dos direitos autorais de qualquer material utilizado, dispondo-se a possíveis acertos posteriores caso, inadvertidamente, a identificação de algum deles tenha sido omitida.

CIP-BRASIL. CATALOGAÇÃO-NA-FONTE
SINDICATO NACIONAL DOS EDITORES DE LIVROS, RJ.

M131a
4.ed.

Machado, Francis B. (Francis Berenger)
Arquitetura de sistemas operacionais / Francis Berenger Machado, Luiz Paulo Maia. - 4.ed. - Rio de Janeiro : LTC, 2007.
il. ;

www.baixebr.org

Contém exercícios
ISBN 978-85-216-1548-4

1. Sistemas operacionais (Computação). I. Maia, Luiz Paulo. II. Título.

07-0180. CDD: 005.43
CDU: 004.451

1.ª edição: 1992 — Reimpressões: 1993 (três), 1994, 1995 e 1996
2.ª edição: 1997 — Reimpressões: 1997, 1998, 1999 (duas) e 2000
3.ª edição: 2002 — Reimpressão: 2004 (duas)
4.ª edição: 2007

Editoração Eletrônica: ALSAN – Serviço de Editoração

Direitos exclusivos para a língua portuguesa
Copyright © 2007 by Francis Berenger Machado e Luiz Paulo Maia
LTC — Livros Técnicos e Científicos Editora S.A.
Travessa do Ouvidor, 11
Rio de Janeiro, RJ – CEP 20040-040
Tel.: 21-3970-9480
Fax: 21-2221-3202
ltc@ltceditora.com.br
www.ltceditora.com.br

Reservados todos os direitos. É proibida a duplicação ou reprodução deste volume, no todo ou em parte, sob quaisquer formas ou por quaisquer meios (eletrônico, mecânico, gravação, fotocópia, distribuição na Web ou outros), sem permissão expressa da Editora.

Este livro publica nomes comerciais e marcas registradas de produtos pertencentes a diversas companhias. O editor utiliza essas marcas somente para fins editoriais e em benefício dos proprietários das marcas, sem nenhuma intenção de infringir os seus direitos.

Prefácio

Este livro aborda a arquitetura e o funcionamento dos sistemas operacionais multiprogramáveis de forma atual, abrangente e didática. Seu conteúdo é direcionado a estudantes e a profissionais de informática de todas as áreas. Como pré-requisitos básicos para sua leitura, é necessário apenas algum conhecimento de organização de computadores e estrutura de dados. O livro pode ser utilizado integralmente, em disciplinas universitárias de graduação, ou parcialmente, em cursos de extensão.

O estudo de sistemas operacionais ganha importância à medida que diversos profissionais da área de computação necessitam desse conhecimento para exercer suas atividades, como é o caso de administradores de sistemas, programadores de aplicações concorrentes e gerentes de segurança. Outro fator importante é o relacionamento dos sistemas operacionais nas redes de comunicação de dados, o que faz seu estudo necessário para os administradores de rede.

O texto não foi baseado em nenhuma arquitetura específica, mas são utilizados, como exemplos, sistemas operacionais já consagrados. Ao final do livro são apresentados estudos de casos, onde é possível encontrar uma descrição da arquitetura dos sistemas operacionais MS Windows e Unix. Além desses dois estudos de casos estará disponível no web site do livro (**http://www.pobox.com/~aso**) o estudo de caso sobre o sistema operacional OpenVMS.

Alguns termos originais do inglês foram conservados sem tradução, de modo a não prejudicar a legibilidade do texto e mantê-lo padronizado com a literatura internacional. Sempre que for necessário o uso de programas será utilizada a linguagem de programação Pascal, por sua clareza e fluência no meio acadêmico. Por vezes, quando a estrutura da linguagem não permitir certas construções, uma sintaxe não-convencional será utilizada, a fim de facilitar a legibilidade e a compreensão dos exemplos.

Estrutura do Livro

O livro está dividido em quatro partes:

- a Parte I oferece uma visão geral de um sistema operacional, definindo conceitos que freqüentemente são referenciados no decorrer do livro;
- a Parte II apresenta os conceitos de processos e threads, além dos mecanismos de comunicação e sincronização utilizados;
- a Parte III descreve os principais subsistemas de gerência de recursos que compõem um sistema operacional, como processador, memória e dispositivos de entrada e saída;
- a Parte IV apresenta estudos de casos dos sistemas MS Windows e Unix, e nela o objetivo principal é mostrar de forma prática as técnicas e os conceitos apresentados, aumentando assim a compreensão do texto.

Nesta Edição

Nesta nova edição, além de uma detalhada revisão técnica da edição anterior, alguns capítulos foram reorganizados e ampliados. Foram incluídos, em alguns capítulos, exercícios práticos com o uso do simulador de sistemas operacionais SOsim.

A seguir são apresentadas as principais alterações desta quarta edição:

- No Capítulo 2 – Conceitos de Hardware e Software –, "Interpretador de Comandos e Linguagem de Controle" e "Ativação/Desativação do Sistema" foram transferidos para o Capítulo 4. Foram inseridas, ainda, no Capítulo 2 informações sobre memória cache de níveis 1 e 2 no item "Memória Cache";
- O Capítulo 3 – Concorrência – teve sua parte inicial reorganizada, sendo o item "Proteção do Sistema" eliminado e seu conteúdo transferido para o Capítulo 4;
- O Capítulo 4 – Estrutura do Sistema Operacional – sofreu grande alteração na sua parte inicial. Os itens que tratavam dos assuntos núcleo do sistema, modos de acesso, rotinas do sistema operacional, systems calls e chamadas a rotinas do sistema foram reescritos e tiveram seus conteúdos fortemente seqüenciados;
- O Capítulo 5 – Processo – foi reorganizado, enfatizando no início o conceito de concorrência de programas e processos. Alguns exemplos com uso de comandos de sistemas reais foram inseridos para exemplificar alguns assuntos, e um novo item foi inserido apresentando as diferentes formas de criação do processo. Ao final do capítulo, foram adicionados exercícios práticos com o uso do simulador SOsim;
- O Capítulo 6 – Thread – foi reorganizado e teve adicionado o item "Programação Multithread";
- Os Capítulos 8 – Gerência do Processador – e 10 – Gerência de Memória Virtual – sofreram pequenas atualizações e tiveram adicionados exercícios práticos com o uso do simulador SOsim;
- O Capítulo 14 – Microsoft Windows – foi atualizado, apresentando nesta nova edição o estudo de casos do sistema MS Windows;
- Os Capítulos 1, 7, 9, 11 12, 13 e 15 sofreram pequenas atualizações.

Internet

No web site **http://www.pobox.com/~aso** estarão disponíveis diversas informações adicionais sobre o livro. Nosso objetivo é colaborar com professores e alunos para tornar o ensino e o aprendizado da disciplina de sistemas operacionais mais fáceis e agradáveis. O web site do livro oferece:

- Plano de aulas para professores que queiram utilizar o livro como referência para seus cursos;
- Slides em MS PowerPoint para apoio de aulas;
- Soluções dos exercícios propostos;
- Estudo de caso do sistema operacional OpenVMS;
- Links interessantes;
- Errata;
- Novidades sobre o livro e assuntos ligados ao tema.

Simulador SOsim

Alguns capítulos do livro apresentam laboratórios que fazem uso do simulador SOsim, como os que tratam de processos, gerência do processador e gerência de memória virtual. O simulador foi desenvolvido pelo Prof. Luiz Paulo Maia como parte de sua tese de mestrado no Núcleo de Computação Eletrônica da Universidade Federal do Rio de Janeiro, defendida em 2001 e orientada pelo Prof. Ageu Pacheco. O objetivo do trabalho foi desenvolver uma ferramenta gratuita que permitisse facilitar e melhorar as aulas de sistemas operacionais para alunos e professores.

O SOsim permite que o professor apresente os conceitos e mecanismos de um sistema operacional multitarefa de forma simples e animada. O simulador permite visualizar os conceitos de multiprogramação, processo e suas mudanças de estado, gerência do processador e gerência de memória virtual. A partir das opções de configuração, é possível selecionar diferentes políticas e alterar o funcionamento do simulador. Mais informações sobre o simulador podem ser obtidas no site **http://www.training.com.br/sosim**.

Agradecimentos

Aos alunos, que sempre nos proporcionam um aprendizado contínuo e motivação para publicar mais uma edição revisada deste projeto.

Aos professores e professoras que colaboraram com críticas e sugestões, especialmente o Prof. Jorge Rogoski e a Profa. Cassiana Fagundes da Silva.

À Editora LTC, mais uma vez, pelo apoio dado à realização desta obra.

Comentários e Sugestões

Apesar dos melhores esforços dos autores, do editor e dos revisores, é inevitável que surjam erros no texto. Assim, são bem-vindas as comunicações de usuários sobre correções ou sugestões referentes ao conteúdo ou ao nível pedagógico que auxiliem o aprimoramento de edições futuras. Encorajamos os comentários dos leitores que podem ser encaminhados à LTC – Livros Técnicos e Científicos Editora S.A. no endereço: Travessa do Ouvidor, 11 – Rio de Janeiro, RJ – CEP 20040-040 ou ao endereço eletrônico ltc@ltceditora.com.br, bem como ao site dos autores no endereço www.pobox.com/~aso.

Sumário

PARTE I CONCEITOS BÁSICOS

1 VISÃO GERAL, 3

1.1 Introdução, 3
1.2 Funções Básicas, 3
1.3 Máquina de Camadas, 5
1.4 Histórico, 6
1.4.1 Década de 1940, 7
1.4.2 Década de 1950, 8
1.4.3 Década de 1960, 10
1.4.4 Década de 1970, 11
1.4.5 Década de 1980, 12
1.4.6 Década de 1990, 13
1.4.7 Década de 2000, 14
1.5 Tipos de Sistemas Operacionais, 15
1.5.1 Sistemas Monoprogramáveis/Monotarefa, 15
1.5.2 Sistemas Multiprogramáveis/Multitarefa, 16
1.5.3 Sistemas com Múltiplos Processadores, 19
1.6 Exercícios, 22

2 CONCEITOS DE HARDWARE E SOFTWARE, 24

2.1 Introdução, 24
2.2 Hardware, 24
2.2.1 Processador, 24
2.2.2 Memória Principal, 26
2.2.3 Memória Cache, 27
2.2.4 Memória Secundária, 28
2.2.5 Dispositivos de Entrada e Saída, 28
2.2.6 Barramento, 29
2.2.7 Pipelining, 31
2.2.8 Arquiteturas RISC e CISC, 32
2.2.9 Análise de Desempenho, 33
2.3 Software, 34
2.3.1 Tradutor, 35
2.3.2 Interpretador, 36
2.3.3 Linker, 36
2.3.4 Loader, 37
2.3.5 Depurador, 37
2.4 Exercícios, 38

3 CONCORRÊNCIA, 39

3.1 Introdução, 39
3.2 Sistemas Monoprogramáveis × Multiprogramáveis, 39
3.3 Interrupções e Exceções, 41
3.4 Operações de Entrada/Saída, 43
3.5 Buffering, 46
3.6 Spooling, 47
3.7 Reentrância, 48
3.8 Exercícios, 49

4 ESTRUTURA DO SISTEMA OPERACIONAL, 50

4.1 Introdução, 50
4.2 Funções do Núcleo, 50
4.3 Modo de Acesso, 52
4.4 Rotinas do Sistema Operacional e System Calls, 53
4.5 Chamada a Rotinas do Sistema Operacional, 54
4.6 Linguagem de Comandos, 56
4.7 Ativação/Desativação do Sistema, 57
4.8 Arquiteturas do Núcleo, 58
4.8.1 Arquitetura Monolítica, 58
4.8.2 Arquitetura de Camadas, 59
4.8.3 Máquina Virtual, 60
4.8.4 Arquitetura Microkernel, 61
4.9 Exercícios, 62

PARTE II PROCESSOS E THREADS

5 PROCESSO, 65

5.1 Introdução, 65
5.2 Estrutura do Processo, 65
5.2.1 Contexto de Hardware, 68
5.2.2 Contexto de Software, 69
5.2.3 Espaço de Endereçamento, 70
5.2.4 Bloco de Controle do Processo, 70
5.3 Estados do Processo, 72
5.4 Mudanças de Estado do Processo, 73
5.5 Criação e Eliminação de Processos, 75
5.6 Processos CPU-bound e I/O-bound, 76
5.7 Processos Foreground e Background, 76
5.8 Formas de Criação de Processos, 77
5.9 Processos Independentes, Subprocessos e Threads, 79
5.10 Processos do Sistema Operacional, 81
5.11 Sinais, 82
5.12 Exercícios, 84
5.13 Laboratório com o Simulador SOsim 84

6 THREAD, 88

6.1 Introdução, 88
6.2 Ambiente Monothread, 89
6.3 Ambiente Multithread, 90
6.4 Programação Multithread, 94
6.5 Arquitetura e Implementação, 96
6.5.1 Threads em Modo Usuário, 96

6.5.2 Threads em Modo Kernel, 97
6.5.3 Threads em Modo Híbrido, 98
6.5.4 Scheduler Activations, 99
6.6 Exercícios, 100

7 SINCRONIZAÇÃO E COMUNICAÇÃO ENTRE PROCESSOS, 101

7.1 Introdução, 101
7.2 Aplicações Concorrentes, 101
7.3 Especificação de Concorrência em Programas, 102
7.4 Problemas de Compartilhamento de Recursos, 104
7.5 Exclusão Mútua, 105
7.5.1 Soluções de Hardware, 107
7.5.2 Soluções de Software, 109
7.6 Sincronização Condicional, 115
7.7 Semáforos, 116
7.7.1 Exclusão Mútua Utilizando Semáforos, 116
7.7.2 Sincronização Condicional Utilizando Semáforos, 118
7.7.3 Problema dos Filósofos, 120
7.7.4 Problema do Barbeiro, 121
7.8 Monitores, 122
7.8.1 Exclusão Mútua Utilizando Monitores, 123
7.8.2 Sincronização Condicional Utilizando Monitores, 124
7.9 Troca de Mensagens, 126
7.10 Deadlock, 129
7.10.1 Prevenção de Deadlock, 130
7.10.2 Detecção do Deadlock, 131
7.10.3 Correção do Deadlock, 132
7.11 Exercícios, 132

PARTE III GERÊNCIA DE RECURSOS

8 GERÊNCIA DO PROCESSADOR, 137

8.1 Introdução, 137
8.2 Funções Básicas, 138
8.3 Critérios de Escalonamento, 138
8.4 Escalonamentos Não-Preemptivos e Preemptivos, 139
8.5 Escalonamento First-In-First-Out (FIFO), 140
8.6 Escalonamento Shortest-Job-First (SJF), 141
8.7 Escalonamento Cooperativo, 143
8.8 Escalonamento Circular, 143
8.9 Escalonamento por Prioridades, 145
8.10 Escalonamento Circular com Prioridades, 147
8.11 Escalonamento por Múltiplas Filas, 148
8.12 Escalonamento por Múltiplas Filas com Realimentação, 149
8.13 Política de Escalonamento em Sistemas de Tempo Compartilhado, 151
8.14 Política de Escalonamento em Sistemas de Tempo Real, 153
8.15 Exercícios, 153
8.16 Laboratório com o Simulador SOsim, 156

9 GERÊNCIA DE MEMÓRIA, 159

9.1 Introdução, 159
9.2 Funções Básicas, 159
9.3 Alocação Contígua Simples, 160

9.4 Técnica de Overlay, 161
9.5 Alocação Particionada, 162
9.5.1 Alocação Particionada Estática, 162
9.5.2 Alocação Particionada Dinâmica, 165
9.5.3 Estratégias de Alocação de Partição, 168
9.6 Swapping, 170
9.7 Exercícios, 172

10 GERÊNCIA DE MEMÓRIA VIRTUAL, 174

10.1 Introdução, 174
10.2 Espaço de Endereçamento Virtual, 175
10.3 Mapeamento, 176
10.4 Memória Virtual por Paginação, 179
10.4.1 Políticas de Busca de Páginas, 181
10.4.2 Políticas de Alocação de Páginas, 182
10.4.3 Políticas de Substituição de Páginas, 183
10.4.4 Working Set, 184
10.4.5 Algoritmos de Substituição de Páginas, 187
10.4.6 Tamanho de Página, 192
10.4.7 Paginação em Múltiplos Níveis, 193
10.4.8 Translation Lookaside Buffer, 194
10.4.9 Proteção de Memória, 197
10.4.10 Compartilhamento de Memória, 198
10.5 Memória Virtual por Segmentação, 198
10.6 Memória Virtual por Segmentação com Paginação, 202
10.7 Swapping em Memória Virtual, 202
10.8 Thrashing, 205
10.9 Exercícios, 205
10.10 Laboratório com o Simulador SOsim, 212

11 SISTEMA DE ARQUIVOS, 215

11.1 Introdução, 215
11.2 Arquivos, 215
11.2.1 Organização de Arquivos, 216
11.2.2 Métodos de Acesso, 217
11.2.3 Operações de Entrada/Saída, 218
11.2.4 Atributos, 218
11.3 Diretórios, 219
11.4 Gerência de Espaço Livre em Disco, 222
11.5 Gerência de Alocação de Espaço em Disco, 223
11.5.1 Alocação Contígua, 223
11.5.2 Alocação Encadeada, 225
11.5.3 Alocação Indexada, 226
11.6 Proteção de Acesso, 227
11.6.1 Senha de Acesso, 227
11.6.2 Grupos de Usuário, 227
11.6.3 Lista de Controle de Acesso, 228
11.7 Implementação de Caches, 229
11.8 Exercícios, 229

12 GERÊNCIA DE DISPOSITIVOS, 230

12.1 Introdução, 230
12.2 Subsistema de Entrada e Saída, 230

12.3 Device Driver, 233
12.4 Controlador de Entrada e Saída, 235
12.5 Dispositivos de Entrada e Saída, 237
12.6 Discos Magnéticos, 238
12.6.1 Desempenho, Redundância e Proteção de Dados, 239
12.7 Exercícios, 242

13 SISTEMAS COM MÚLTIPLOS PROCESSADORES, 243

13.1 Introdução, 243
13.2 Vantagens e Desvantagens, 244
13.3 Tipos de Sistemas Computacionais, 246
13.4 Sistemas Fortemente e Fracamente Acoplados, 247
13.5 Sistemas com Multiprocessadores Simétricos, 249
13.5.1 Evolução dos Sistemas Simétricos, 249
13.5.2 Arquitetura dos Sistemas Simétricos, 249
13.6 Sistemas NUMA, 253
13.7 Clusters, 257
13.8 Sistemas Operacionais de Rede, 259
13.9 Sistemas Distribuídos, 261
13.9.1 Transparência, 262
13.9.2 Tolerância a Falhas, 263
13.9.3 Imagem Única do Sistema, 263
13.10 Exercícios, 263

PARTE IV ESTUDOS DE CASOS

14 MICROSOFT WINDOWS, 267

14.1 Histórico, 267
14.2 Características, 269
14.3 Estrutura do Sistema, 269
14.4 Processos e Threads, 271
14.5 Gerência do Processador, 273
14.6 Gerência de Memória, 276
14.7 Sistema de Arquivos, 280
14.8 Gerência de Entrada e Saída, 282

15 UNIX, 285

15.1 Histórico, 285
15.2 Características, 287
15.3 Estrutura do Sistema, 288
15.4 Processos e Threads, 289
15.5 Gerência do Processador, 293
15.6 Gerência de Memória, 294
15.7 Sistema de Arquivos, 296
15.8 Gerência de Entrada/Saída, 299

BIBLIOGRAFIA, 302

ÍNDICE, 306

PARTE I

CONCEITOS BÁSICOS

"Não basta ensinar ao homem uma especialidade, porque se tornará assim uma máquina utilizável, mas não uma personalidade. É necessário que adquira um sentimento, um senso prático daquilo que vale a pena ser empreendido, daquilo que é belo, do que é moralmente correto. A não ser assim, ele se assemelhará, com seus conhecimentos profissionais, mais a um cão ensinado do que a uma criatura harmoniosamente desenvolvida. Deve aprender a compreender as motivações dos homens, suas quimeras e suas angústias, para determinar com exatidão seu lugar preciso em relação a seus próximos e à comunidade."

ALBERT EINSTEIN (1879-1955)
Físico alemão

"Se plantarmos para um ano, devemos plantar cereais.
Se plantarmos para uma década, devemos plantar árvores.
Se plantarmos para toda a vida, devemos treinar e educar o homem."

KWANTSU (séc. III a.C.)

"Educai as crianças e não será preciso punir os homens."

ABRAHAM LINCOLN (1809-1865)
Presidente americano

"Ninguém nasce feito, ninguém nasce marcado para ser isso ou aquilo. Pelo contrário, nos tornamos isso ou aquilo. Somos programados, mas para aprender. A nossa inteligência se inventa e se promove no exercício social de nosso corpo consciente. Se constrói. Não é um dado que, em nós, seja um a priori *da nossa história individual e social."*

PAULO FREIRE (1921-1997)
Educador brasileiro

1

VISÃO GERAL

1.1 Introdução

Um *sistema operacional*, por mais complexo que possa parecer, é apenas um conjunto de rotinas executado pelo processador, de forma semelhante aos programas dos usuários. Sua principal função é controlar o funcionamento de um computador, gerenciando a utilização e o compartilhamento dos seus diversos recursos, como processadores, memórias e dispositivos de entrada e saída.

Sem o sistema operacional, um usuário para interagir com o computador deveria conhecer profundamente diversos detalhes sobre hardware do equipamento, o que tornaria seu trabalho lento e com grandes possibilidades de erros. O sistema operacional tem como objetivo funcionar como uma interface entre o usuário e o computador, tornando sua utilização mais simples, rápida e segura.

A grande diferença entre um sistema operacional e aplicações convencionais é a maneira como suas rotinas são executadas em função do tempo. Um sistema operacional não é executado de forma linear como na maioria das aplicações, com início, meio e fim. Suas rotinas são executadas concorrentemente em função de eventos assíncronos, ou seja, eventos que podem ocorrer a qualquer momento.

O nome sistema operacional, apesar de ser o mais empregado atualmente, não é o único para designar esse conjunto de rotinas. Denominações como monitor, executivo, supervisor ou controlador possuem, normalmente, o mesmo significado.

Neste capítulo serão apresentadas as funções básicas de um sistema operacional, o conceito de máquina de camadas, um histórico da evolução dos sistemas operacionais e seus diferentes tipos e classificações.

1.2 Funções Básicas

Um sistema operacional possui inúmeras funções, mas antes de começar o estudo dos conceitos e dos seus principais componentes é importante saber primeiramente quais

são suas funções básicas. Nesta introdução, as funções de um sistema operacional são resumidas em duas, descritas a seguir:

- Facilidade de acesso aos recursos do sistema

Um computador ou sistema computacional possui diversos dispositivos, como monitores de vídeo, impressoras, unidades de CD/DVD, discos e fitas magnéticas. Quando utilizamos um desses dispositivos, não nos preocupamos com a maneira como é realizada esta comunicação e os inúmeros detalhes envolvidos nas operações de leitura e gravação.

Para a maioria dos usuários, uma operação como a leitura de um arquivo em disco pode parecer simples. Na realidade, existe um conjunto de rotinas específicas, controladas pelo sistema operacional, responsável pelo acionamento do mecanismo de leitura e gravação da unidade de disco, posicionamento na trilha e setor corretos, transferência dos dados para a memória e, finalmente, informar ao programa a conclusão da operação. Cabe, então, ao sistema operacional servir de interface entre os usuários e os recursos disponíveis no sistema computacional, tornando esta comunicação transparente, além de permitir um trabalho mais eficiente e com menores chances de erros. Este conceito de ambiente simulado, criado pelo sistema operacional, é denominado máquina virtual e está presente na maioria dos sistemas modernos (Fig. 1.1).

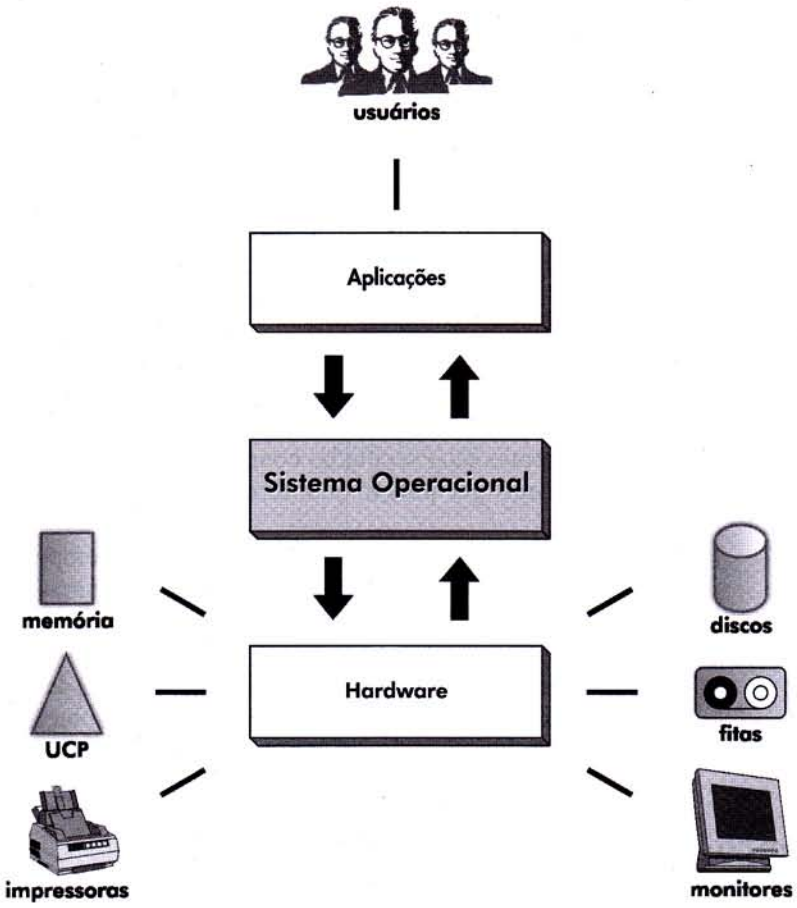

Fig. 1.1 Visão do sistema operacional.

É comum pensar-se que compiladores, linkers, bibliotecas, depuradores e outras ferramentas fazem parte do sistema operacional, mas, na realidade, estes recursos são apenas utilitários, destinados a facilitar a interação do usuário com o computador.

- Compartilhamento de recursos de forma organizada e protegida

Em sistemas onde diversos usuários compartilham recursos do sistema computacional, é necessário controlar o uso concorrente desses recursos. Se imaginarmos uma impressora sendo compartilhada, deverá existir algum tipo de controle para que a impressão de um usuário não interfira nas dos demais. Novamente é o sistema operacional que tem a responsabilidade de permitir o acesso concorrente a esse e a outros recursos de forma organizada e protegida.

O compartilhamento de recursos permite, também, a diminuição de custos, na medida em que mais de um usuário pode utilizar as mesmas facilidades concorrentemente, como discos, impressoras, linhas de comunicação etc.

Não é apenas em sistemas multiusuário que o sistema operacional é importante. Se pensarmos que um computador pessoal nos permite executar diversas tarefas ao mesmo tempo, como imprimir um documento, copiar um arquivo pela Internet ou processar uma planilha, o sistema operacional deve ser capaz de controlar a execução concorrente de todas essas atividades.

1.3 Máquina de Camadas

Um sistema computacional visto somente sob a ótica do *hardware*, ou seja, como um conjunto de circuitos eletrônicos, placas, cabos e fontes de alimentação, tem pouca utilidade. É através do *software* que serviços são oferecidos aos usuários, como armazenamento de dados em discos, impressão de relatórios, geração de gráficos, acesso à Internet, entre outras funções.

Uma operação efetuada pelo software pode ser implementada em hardware, enquanto uma instrução executada pelo hardware pode ser simulada via software. Esta decisão fica a cargo do projetista do sistema computacional em função de aspectos como custo, confiabilidade e desempenho. Tanto o hardware quanto o software são logicamente equivalentes, interagindo de uma forma única para o usuário (Tanenbaum, 1992).

Nos primeiros computadores, a programação era realizada em linguagem de máquina, em painéis através de fios, exigindo, conseqüentemente, um grande conhecimento da arquitetura do hardware. Isso era uma grande dificuldade para os programadores da época (Fig. 1.2a). O surgimento do sistema operacional minimizou esse problema, tornando a interação entre usuário e computador mais simples, confiável e eficiente. A partir desse momento, não existia mais a necessidade de o programador se envolver com a complexidade do hardware para poder trabalhar; ou seja, a parte física do computador tornou-se transparente para o usuário (Fig. 1.2b).

O computador pode ser compreendido como uma *máquina de camadas* ou *máquina de níveis*, onde inicialmente existem dois níveis: hardware (nível 0) e sistema operacional (nível 1). Desta forma, a aplicação do usuário interage diretamente com o sistema operacional, ou seja, como se o hardware não existisse. Esta visão modular e abstrata é chamada de *máquina virtual*.

Na realidade, um computador não possui apenas dois níveis, e sim tantos níveis quantos forem necessários para adequar o usuário às suas diversas aplicações. Quando o usuá-

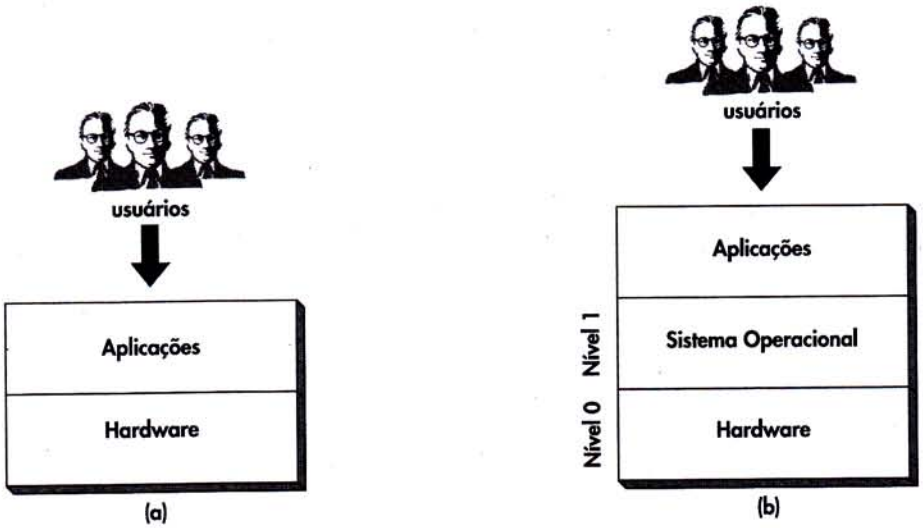

Fig. 1.2 Visão do computador pelo usuário.

rio está trabalhando em um desses níveis não necessita saber da existência das outras camadas, acima ou abaixo de sua máquina virtual.

Atualmente, a maioria dos computadores possui a estrutura básica apresentada na Fig. 1.3, podendo conter um número maior ou menor de camadas. A linguagem utilizada em cada um desses níveis é diferente, variando da mais elementar (baixo nível) à mais sofisticada (alto nível).

1.4 Histórico

A evolução dos sistemas operacionais está, em grande parte, relacionada ao desenvolvimento dos computadores. Neste histórico dividimos essa evolução em décadas, nas

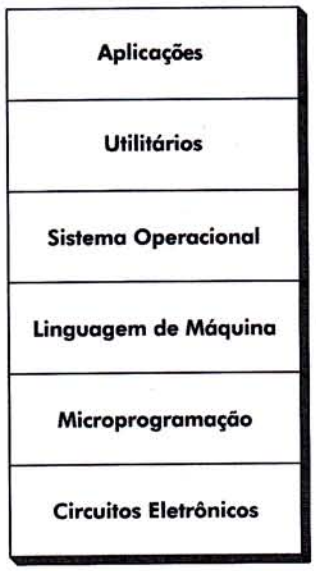

Fig. 1.3 Máquinas de camadas.

www.baixebr.org

quais destacamos em cada uma suas principais características de hardware, software, interação com o sistema e aspectos de conectividade.

Antes da década de 1940, inúmeros esforços foram feitos para criar uma máquina que pudesse realizar cálculos de forma mais rápida e precisa. Em 1642, o matemático francês Blaise Pascal inventou uma máquina de somar para auxiliar seu pai no processo de arrecadação de impostos. Em 1673, o matemático e filósofo alemão Gottfried Leibniz foi além e criou uma máquina capaz de somar e multiplicar, utilizando o conceito de acumulador. Mais tarde, em 1820, o francês Charles Colmar inventaria finalmente uma máquina capaz de executar as quatro operações.

Em 1822 o matemático inglês Charles Babbage criou uma máquina para cálculos de equações polinomiais. Mais tarde, em 1833, Babbage evoluiria esta idéia para uma máquina capaz de executar qualquer tipo de operação, conhecida como Máquina Analítica (*Analytical Engine*). Seu invento é o que mais se aproxima de um computador atual, possuindo os conceitos de unidade central de processamento, memória, unidade de controle e dispositivos de entrada/saída. Enquanto Babbage se preocupava com as características mecânicas do seu invento (hardware), sua discípula Augusta Ada Byron era responsável pela seqüência de instruções executadas pela máquina (software). Pelo trabalho realizado na época, Ada Byron é considerada a primeira programadora da história. Devido às limitações técnicas da época, a Máquina Analítica nunca funcionou de forma adequada, mesmo assim Babbage é considerado o "pai do computador".

Em 1854, o também matemático inglês George Boole criaria a lógica booleana, base para o modelo de computação digital utilizado até hoje. O conceito de lógica binária seria utilizado no desenvolvimento de dispositivos como relés e válvulas, implementados nos primeiros computadores da década de 1940.

No final do século XIX, Herman Hollerith criou um mecanismo utilizando cartões perfurados para acelerar o processamento do censo de 1890 nos EUA. Hollerith fundaria em 1896 a Tabulating Machine Company, que se tornaria a International Business Machine (IBM) em 1924. A utilização de cartões perfurados na computação perduraria por grande parte do século XX, e o nome Hollerith tornar-se-ia sinônimo de cartão perfurado.

Na década de 1930 surgem as primeiras tentativas reais de criar-se uma calculadora eletrônica. Na Alemanha, Konrad Zuse desenvolveu o Z-1, baseado em relés e que utilizava lógica binária. Nos EUA, John Vincent Atanasoff e Clifford Berry desenvolveram uma máquina para o cálculo de equações lineares. Para muitos, o ABC (Atanasoff-Berry Computer) é considerado o primeiro computador eletrônico da história.

Em 1937, o matemático inglês Alan Turing desenvolveu a idéia de Máquina Universal ou Máquina de Turing, capaz de executar qualquer seqüência de instruções (algoritmo). Apesar de ser um modelo teórico, a Máquina Universal criou a idéia de "processamento de símbolos", base da ciência da computação moderna.

1.4.1 Década de 1940

A Segunda Guerra Mundial desencadeou o desenvolvimento de máquinas que pudessem acelerar os procedimentos manuais realizados para fins militares. Neste período surgiram os primeiros computadores eletromecânicos (calculadoras), formados por milhares de válvulas, que ocupavam áreas enormes, sendo de funcionamento lento e duvidoso.

Em 1943, na Inglaterra, Alan Turing estava envolvido no desenvolvimento de uma máquina chamada Colossus para decifrar o código das mensagens alemãs, conhecido como Enigma. Este computador foi desenvolvido e utilizado na quebra de diversos códigos nazistas, como o do "Dia D", e significou uma grande vantagem para os aliados na Segunda Guerra.

Nos EUA, em 1944, foi construído o primeiro computador eletromecânico, batizado de Mark I. Desenvolvido pelo professor Howard Aiken, da Universidade de Harvard, e com apoio da IBM, foi utilizado para cálculos matemáticos pela Marinha. O Mark I utilizava os mesmos princípios da Máquina Analítica, criada por Babbage cem anos antes.

O ENIAC (Electronic Numerical Integrator And Calculator) é considerado o primeiro computador digital e eletrônico. Desenvolvido pelos engenheiros J. Presper Eckert e John W. Mauchly na Universidade da Pensilvânia, foi criado para a realização de cálculos balísticos e, posteriormente, utilizado no projeto da bomba de hidrogênio, ficando em operação no período de 1946 a 1955. Sua estrutura possuía 17 mil válvulas, 10 mil capacitores, 70 mil resistores e pesava 30 toneladas. Quando em operação, consumia cerca de 140 quilowatts e era capaz de realizar 5 mil adições por segundo.

Para trabalhar com o ENIAC era necessário conhecer profundamente o funcionamento do hardware, pois a programação era feita em painéis, através de 6 mil conectores, utilizando linguagem de máquina. Esta tarefa poderia facilmente levar alguns dias. Corretamente programado, um cálculo que levasse vinte e quatro horas manualmente era resolvido em menos de trinta segundos. A diferença entre a velocidade de processamento e o tempo necessário para codificar um programa passou a ser um grande problema a ser resolvido.

O professor John von Neumann, consultor no projeto do ENIAC, imaginou uma máquina de propósito geral na qual tanto instruções quanto dados fossem armazenados em uma mesma memória, tornando o processo de programação muito mais rápido e flexível. Este conceito, aparentemente simples, conhecido como "programa armazenado", é a base da arquitetura de computação atual, batizada de "Arquitetura von Neumann". Finalmente, as mesmas idéias de Babbage (Máquina Analítica) e Turing (Máquina Universal) puderam ser colocadas em prática em um mesmo sistema computacional.

O primeiro computador a implementar o conceito de "programa armazenado" foi o EDSAC (Electronic Delay Storage Automatic Calculator), desenvolvido pelo professor Maurice Wilkes, na Universidade de Cambridge, na Inglaterra, em 1949. Outros computadores foram construídos nessa mesma época com base no mesmo princípio, como o EDVAC (Electronic Discrete Variable Automatic Computer) na Universidade da Pensilvânia, IAS (Institute for Advanced Studies) em Princeton pelo próprio von Neumann, Manchester Mark I, ORDVAC e ELLIAC na Universidade de Illinois, JOHNIAC pela Rand Corp., MANIAC em Los Alamos e WEIZAC em Israel. A maioria destas máquinas foi utilizada apenas em universidades e órgãos militares para cálculos matemáticos.

Nessa fase, os computadores não possuíam ainda dispositivos com função de interface com os usuários, como teclados e monitores, e o conceito de sistema operacional surgiria apenas na década seguinte.

1.4.2 Década de 1950

O uso do transistor e da memória magnética contribuiu para o enorme avanço dos computadores da época. O transistor permitiu o aumento da velocidade e da confiabilidade

no processamento, e as memórias magnéticas permitiram o acesso mais rápido aos dados, maior capacidade de armazenamento e computadores menores. Apesar de o seu invento datar do final da década de 1940, os primeiros computadores transistorizados foram lançados comercialmente apenas no final da década de 1950.

Com o desenvolvimento da indústria de computadores, muitas empresas foram criadas ou investiram no setor, como Raytheon, RCA, Burroughs e IBM, o que levou à criação dos primeiros computadores para utilização em aplicações comerciais.

Em 1946, Eckert e Mauchly deixaram a Universidade da Pensilvânia para formar a primeira empresa de computadores, a Eckert-Mauchly Computer Corp. (EMCC), com a intenção de construir o UNIVAC (Universal Automatic Computer). Devido a problemas financeiros, a EMCC foi adquirida pela Remington Rand Corp., possibilitando a conclusão do projeto a tempo de ser utilizado no censo dos EUA em 1951. O UNIVAC I foi o primeiro computador bem-sucedido fabricado para fins comerciais.

Em 1951, o Massachusetts Institute of Technology (MIT) colocou em operação o que é considerado o primeiro computador voltado para o processamento em tempo real, o Whirlwind I. Entre diversas inovações, o Whirlwind introduziu a tecnologia de memória magnética.

Os programas ou jobs passaram a ser perfurados em cartões, que, submetidos a uma leitora, eram gravados em uma fita de entrada (Fig. 1.4a). A fita, então, era lida pelo computador, que executava um programa de cada vez, gravando o resultado do processamento em uma fita de saída (Fig. 1.4b). Ao término de todos os programas, a fita de saída era lida e impressa (Fig. 1.4c). A esse tipo de processamento, em que um conjunto de programas era submetido ao computador, deu-se o nome de *processamento batch*.

Pode não parecer um avanço, mas anteriormente os programas eram submetidos pelo operador, um a um, fazendo com que o processador ficasse ocioso entre a execução de um job e outro. Com o processamento batch, um conjunto de programas era submetido de uma só vez, o que diminuía o tempo de espera entre a execução dos programas, permitindo, assim, melhor aproveitamento do processador.

O primeiro sistema operacional, chamado monitor por sua simplicidade, foi desenvolvido em 1953 pelos usuários do computador IBM 701 do Centro de Pesquisas da General Motors, justamente para tentar automatizar as tarefas manuais até então utilizadas. Posteriormente, este sistema seria reescrito para um computador IBM 704 pelo grupo de usuários da IBM (Weizer, 1981).

Com o surgimento das primeiras linguagens de programação de alto nível, como FORTRAN, ALGOL e COBOL, os programas deixaram de ter relação direta com o hardware dos computadores, o que facilitou e agilizou enormemente o desenvolvimento e a manutenção de programas.

Da mesma maneira que as linguagens de programação, os sistemas operacionais evoluíram no sentido de facilitar o trabalho de codificação, submissão, execução e depuração de programas. Para isso, os sistemas operacionais incorporaram seu próprio conjunto de rotinas para operações de entrada/saída (Input/Output Control System — IOCS). O IOCS eliminou a necessidade de os programadores desenvolverem suas próprias rotinas de leitura/gravação específicas para cada dispositivo. Essa facilidade de comunicação criou o conceito de *independência de dispositivos*, introduzido pelos sistemas operacionais SOS (SHARE Operating System), FMS (FORTRAN Monitor System) e IBSYS, todos para máquinas IBM.

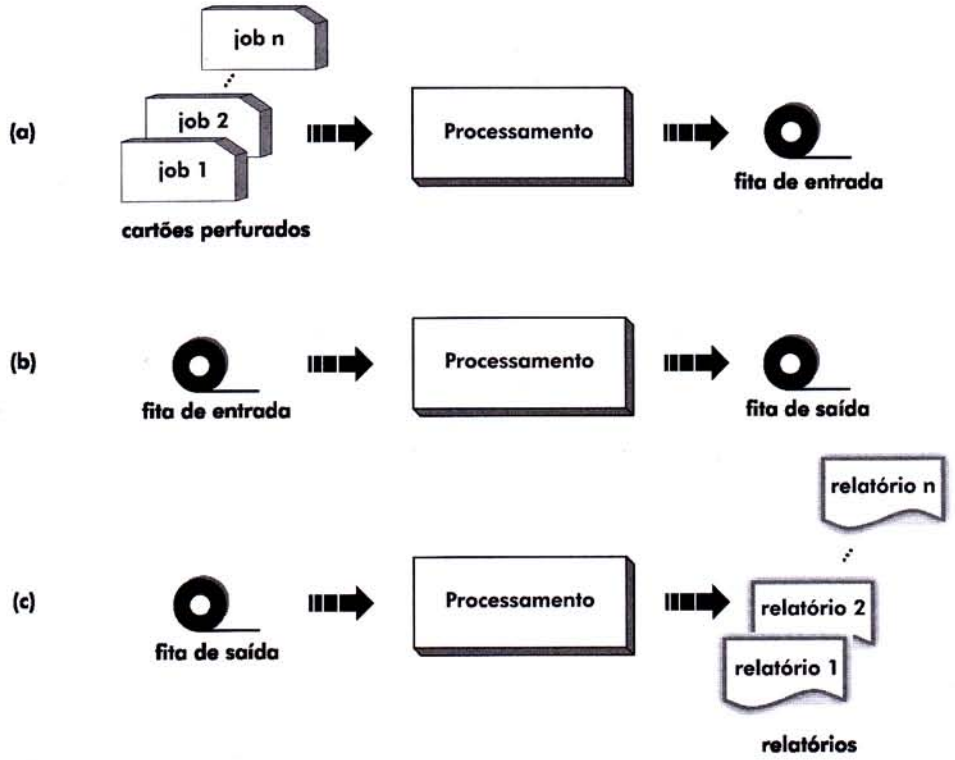

Fig. 1.4 Processamento batch.

No final da década de 1950, a Universidade de Manchester, na Inglaterra, desenvolveu o sistema operacional Atlas, que introduziu a idéia de memória hierarquizada, base do conceito de *memória virtual*, presente hoje na maioria dos sistemas operacionais atuais. O Atlas implementava o esquema de paginação por demanda para transferir informações da memória secundária para a principal.

1.4.3 Década de 1960

A partir do surgimento dos circuitos integrados, foi possível viabilizar e difundir o uso de sistemas computacionais nas empresas, devido à redução de seus custos de aquisição. Além disso, houve grande aumento do poder de processamento e diminuição no tamanho dos equipamentos. A década de 1960 foi palco de inúmeras inovações na área de sistemas operacionais, tendo sido implementadas várias técnicas presentes até hoje, como multiprogramação, multiprocessamento, time-sharing e memória virtual.

Uma das características mais importantes surgidas nesta época foi a introdução do conceito de *multiprogramação*. Antes deste conceito, sempre que um programa realizava uma operação de entrada/saída o processador ficava ocioso, aguardando o término da operação. A multiprogramação permitiu que vários programas compartilhassem a memória ao mesmo tempo e, enquanto um programa esperava por uma operação de leitura/gravação, o processador executava um outro programa.

Com a substituição das fitas por discos no processo de submissão dos programas, o processamento batch, juntamente com a multiprogramação, tornou os sistemas mais rápidos e eficientes, pois permitia a carga mais rápida dos programas na memória e a alteração na ordem de execução das tarefas, até então puramente seqüencial.

Em 1963, a Burroughs lança o computador B-5000 com o sistema operacional Master Control Program (MCP), que oferecia multiprogramação, memória virtual com segmentação e multiprocessamento assimétrico, além de ser o primeiro sistema a ser desenvolvido em uma linguagem de alto nível. No mesmo ano, a Control Data Corporation anuncia o lançamento do primeiro supercomputador, o CDC 6600, projetado por Seymour Cray.

A IBM lança em 1964 o System/360, que causaria uma revolução na indústria de informática, pois introduzia um conceito de máquinas de portes diferentes, porém com uma mesma arquitetura, permitindo a total compatibilidade entre os diferentes modelos. Desta forma, uma empresa poderia adquirir um modelo mais simples e barato e, conforme suas necessidades, migrar para modelos com mais recursos, sem comprometer suas aplicações já existentes. Para essa série, foi desenvolvido o sistema operacional OS/360.

Os sistemas batch implementando multiprogramação, como o OS/360, foram um grande avanço para os programadores, porém o trabalho de desenvolvimento e depuração das aplicações ainda era lento e tedioso. Caso o programador cometesse apenas um erro de digitação, o tempo de resposta do sistema poderia levar horas. A evolução foi oferecer aos usuários tempos de respostas menores e uma interface que permitisse interagir rapidamente com o sistema. Para tal, cada programa poderia utilizar o processador por pequenos intervalos de tempo. A esse sistema de divisão de tempo chamou-se *tempo compartilhado* (*time-sharing*). Para que a interface entre o computador e usuários fosse possível, foram introduzidos novos dispositivos de entrada/saída, como o terminal de vídeo e o teclado, possibilitando a interação do usuário com a aplicação no decorrer da sua execução (*sistema on-line*).

Um dos primeiros sistemas operacionais de tempo compartilhado foi o CTSS (Compatible Time-Sharing System). Desenvolvido pelo MIT em 1962 para um computador IBM 7094, suportava no máximo 32 usuários interativos, e através de comandos em um terminal permitia compilar e executar seus programas. O CTSS foi a base para outros sistemas operacionais de tempo compartilhado, como o MULTICS (Corbató, 1962).

Em 1965, o MIT, a Bell Labs e a General Electric estavam envolvidos no projeto do sistema operacional MULTICS (Multiplexed Information and Computing Service) para um computador GE 645. Este sistema deveria oferecer vários serviços de forma contínua e confiável, similar aos serviços de luz e telefonia. O MULTICS implementava memória virtual com segmentação e paginação, multiprogramação e deveria suportar múltiplos processadores e usuários. A maior parte do sistema seria desenvolvida em PL/I, uma linguagem de alto nível, para torná-lo portável, ou seja, independente da plataforma de hardware (Corbató, 1965). Apesar de o MULTICS não ter alcançado seus objetivos, suas idéias influenciariam inúmeros sistemas posteriormente.

A Digital Equipment Corp. (DEC) lançou o PDP-8 em 1965, também revolucionário, pois representava a primeira linha de computadores de pequeno porte e baixo custo, comparativamente aos mainframes até então comercializados, criando o mercado de minicomputadores. Em 1969, Ken Thompson, que trabalhara no projeto do MULTICS, utilizou um PDP-7 para fazer sua própria versão de um sistema operacional que viria a ser conhecido como Unix.

1.4.4 Década de 1970

A integração em larga escala (Large Scale Integration — LSI) e a integração em muito larga escala (Very Large Scale Integration — VLSI) levaram adiante o projeto de

miniaturização e barateamento dos equipamentos. Seguindo esta tendência, a Digital lança uma nova linha de minicomputadores, o PDP-11 em 1970 e, posteriormente, o sistema VAX/VMS (Virtual Memory System) de 32 bits.

Em 1971, a Intel Corp. produz seu primeiro microprocessador, o Intel 4004 e, três anos depois, o Intel 8080, utilizado no primeiro microcomputador, o Altair. Posteriormente, a Zilog lançaria um processador concorrente ao da Intel, o Z80. Com a evolução dos microprocessadores, os microcomputadores ganham rapidamente o mercado por serem muito mais baratos que qualquer um dos computadores até então comercializados. Em 1976, Steve Jobs e Steve Wozniak produzem o Apple II de 8 bits, tornando-se um sucesso imediato. Neste mesmo ano, as empresas Apple e a Microsoft são fundadas. O sistema operacional dominante nos primeiros microcomputadores foi o CP/M (Control Program Monitor) da Digital Research.

Para acelerar o processamento foram desenvolvidas arquiteturas com diversos processadores, exigindo dos sistemas operacionais novos mecanismos de controle e sincronismo. O *multiprocessamento* possibilitou a execução de mais de um programa simultaneamente ou até de um mesmo programa por mais de um processador. Além de equipamentos com múltiplos processadores, foram introduzidos processadores vetoriais e técnicas de paralelismo em diferentes níveis, tornando os computadores ainda mais poderosos. Em 1976, o Cray-1 é lançado contendo 200.000 circuitos integrados e realizando 100 milhões de operações de ponto flutuante por segundo (100 MFLOPS).

As redes distribuídas (Wide Area Network — WANs) difundiram-se, permitindo o acesso a outros sistemas de computação, independentemente da distância geográfica. Nesse contexto são desenvolvidos inúmeros protocolos de rede, alguns proprietários, como o DECnet da Digital e o SNA (System Network Architecture) da IBM, e outros de domínio público, como o NCP (predecessor do TCP/IP) e o X.25. Surgem as primeiras redes locais (Local Area Network — LANs) interligando computadores restritos a pequenas áreas. Os sistemas operacionais passam a estar intimamente relacionados aos softwares de rede.

Duas importantes linguagens de programação são desenvolvidas nesta década. Em 1971, o professor Niklaus Wirth desenvolve a linguagem Pascal, voltada para o ensino de técnicas de programação. Em 1975, Dennis Ritchie desenvolve a linguagem C e, juntamente com Ken Thompson, porta o sistema Unix para um PDP-11, concebido inicialmente em assembly.

1.4.5 Década de 1980

Em 1981, a IBM entra no mercado de microcomputadores com o IBM PC (Personal Computer), criando a filosofia dos computadores pessoais. O primeiro PC utilizava o processador Intel 8088 de 16 bits e o sistema operacional DOS (Disk Operating System) da Microsoft, muito semelhante ao CP/M.

Na área dos minis e superminicomputadores ganharam impulso os sistemas *multiusuário*, com destaque para os sistemas compatíveis com o Unix. A Universidade de Berkeley, na Califórnia, desenvolveu sua própria versão do sistema Unix (Berkeley Software Distribution – BSD) e introduziu inúmeros melhoramentos, merecendo destaque o protocolo de rede TCP/IP (Transmission Control Protocol/Internet Protocol).

Surgem as estações de trabalho (workstations) que, apesar de serem sistemas monousuário, permitem que sejam executadas diversas tarefas concorrentemente (multitarefa). Em 1982, é fundada a Sun Microsystems, que passaria a atuar fortemen-

te neste setor, lançando as primeiras estações RISC com o sistema operacional SunOS e, posteriormente, Sun Solaris.

Com a evolução dos microprocessadores, principamente da família Intel, surgem os primeiros sistemas operacionais comerciais que oferecem interface gráfica, como o Microsoft Windows e o OS/2. O software de rede passa a estar fortemente relacionado ao sistema operacional, e surgem os *sistemas operacionais de rede*, com destaque para o Novell Netware e o Microsoft LAN Manager.

Entre os anos de 1982 e 1986, foi desenvolvido no Núcleo de Computação Eletrônica da Universidade Federal do Rio de Janeiro (NCE/UFRJ) o sistema operacional PLURIX para o computador PEGASUS, também construído no NCE. Na década seguinte, o PLURIX seria transportado para a linha de processadores Intel, dando origem ao TROPIX, um sistema operacional multiusuário e multitarefa, de filosofia Unix, disponível gratuitamente na Internet (TROPIX, 2002).

1.4.6 Década de 1990

Grandes avanços em termos de hardware, software e telecomunicações foram obtidos nesta década. Essas mudanças foram conseqüência da evolução das aplicações, que necessitavam cada vez mais de capacidade de processamento e armazenamento de dados, como em sistemas especialistas, sistemas multimídia, banco de dados distribuídos, inteligência artificial e redes neurais.

A evolução da microeletrônica permitiu o desenvolvimento de processadores e memórias cada vez mais velozes e baratos, além de dispositivos de E/S menores, mais rápidos e com maior capacidade de armazenamento. Os componentes baseados em tecnologia VLSI evoluem rapidamente para o ULSI (Ultra Large Scale Integration).

Com o surgimento e a evolução da Internet, o protocolo TCP/IP passou a ser um padrão de mercado, obrigando os fabricantes de sistemas operacionais a oferecer suporte a este protocolo. Devido ao crescimento acelerado da Internet, problemas de gerência, segurança e desempenho tornaram-se fatores importantes relacionados ao sistema operacional e à rede.

A arquitetura cliente/servidor, aplicada basicamente a redes locais, passa a ser utilizada em redes distribuídas como a Internet, permitindo que qualquer pessoa tenha acesso a todo tipo de informação, independentemente de onde esteja armazenada. A partir deste modelo de computação foram criados diversos sistemas dedicados a oferecer serviços, como servidores web, de correio, de arquivos e servidores de banco de dados.

A década de 1990 foi definitiva para a consolidação dos sistemas operacionais baseados em interfaces gráficas. Os conceitos e implementações só vistos em sistemas considerados de grande porte foram introduzidos na maioria dos sistemas para desktop, como na família Windows da Microsoft e no Unix. Em 1991, o finlandês Linus Torvalds começou o desenvolvimento do Linux, que evolui a partir da colaboração de vários programadores que ajudaram no desenvolvimento do kernel, utilitários e vários aplicativos. Atualmente, o Linux é utilizado tanto para fins acadêmicos como comerciais. Em 1993, a Microsoft lança o Windows NT para competir no mercado de servidores corporativos e ao mesmo tempo substituir as versões anteriores do MS-DOS e MS-Windows utilizadas nos computadores pessoais. Durante esta década, o MS-Windows NT e o Unix (HP-UX, IBM-AIX e Sun Solaris) consolidam-se como sistemas para ambientes corporativos.

Outro fato importante nesta década foi o amadurecimento e a popularização do software aberto. Com a evolução da Internet, inúmeros produtos foram desenvolvidos e disponibilizados para uso gratuito, como sistemas operacionais (Linux), banco de dados (MySQL), servidores web (Apache), servidores de correio (Sendmail), dentre outros.

1.4.7 Década de 2000

Os computadores da próxima geração devem ser muito mais eficientes que os atuais para atender a demanda cada vez maior de processamento. Para isso, está ocorrendo uma mudança radical na filosofia de projeto de computadores. Arquiteturas paralelas, baseadas em organizações de multiprocessadores não convencionais, já se encontram em desenvolvimento em diversas universidades e centros de pesquisa do mundo.

A forma de interação com os computadores sofrerá, talvez, uma das modificações mais visíveis. Os sistemas operacionais tornam-se cada vez mais intuitivos e simples de serem utilizados. Novas interfaces usuário-máquina serão oferecidas pelos sistemas operacionais, como linguagens naturais, sons e imagens, fazendo essa comunicação mais inteligente, simples e eficiente. A evolução do hardware encadeará modificações profundas nas disciplinas de programação para fazer melhor uso das arquiteturas paralelas.

Os sistemas operacionais passam a ser proativos, ou seja, enquanto no passado o usuário necessitava intervir periodicamente para realizar certas tarefas preventivas e corretivas, os novos sistemas incorporaram mecanismos automáticos de detecção e recuperação de erros. A disponibilidade passa a ser de grande importância para as corporações, e para atender a essa demanda os sistemas em cluster são utilizados em diferentes níveis. Nestes sistemas, computadores são agrupados de forma a oferecer serviços como se fossem um único sistema centralizado. Além de melhorar a disponibilidade, sistemas em cluster permitem aumentar o desempenho e a escalabilidade das aplicações.

O conceito de *processamento distribuído* será explorado nos sistemas operacionais, de forma que suas funções estejam espalhadas por vários processadores através de redes locais e distribuídas. Isso só será possível devido à redução dos custos de comunicação e ao aumento na taxa de transmissão de dados. Com a evolução e consolidação das redes sem fio (wireless), os sistemas operacionais já estão presentes em diversos dispositivos, como em telefones celulares, handhelds e palmtops.

Nesta década, a Microsoft evolui com a linha Windows no sentido de unificar as suas diferentes versões e incluir novos recursos tanto para servidores quanto para computadores pessoais. Os sistemas Windows 2000 e Windows XP, lançados no início da década, evoluíram para o Windows 2003 e o Windows Vista, respectivamente. O Linux evolui para tornar-se o padrão de sistema operacional de baixo custo, com inúmeras formas de distribuições disponíveis no mercado. A comunidade de software livre passa a utilizar o Linux como a base para o desenvolvimento de novas aplicações gratuitas ou de baixo custo.

Os sistemas operacionais desta década caminham para tirar proveito das novas arquiteturas de processadores de 64 bits, especialmente do aumento do espaço de endereçamento, o que permitirá melhorar o desempenho de aplicações que manipulam grandes volumes de dados. Os sistemas Microsoft Windows, o Linux e diversas outras versões do Unix já oferecem suporte aos processadores de 64 bits.

1.5 Tipos de Sistemas Operacionais

Os tipos de sistemas operacionais e sua evolução estão relacionados diretamente com a evolução do hardware e das aplicações por ele suportadas. Muitos termos inicialmente introduzidos para definir conceitos e técnicas foram substituídos por outros, na tentativa de refletir uma nova maneira de interação ou processamento. Isto fica muito claro quando tratamos da unidade de execução do processador. Inicialmente, os termos programa ou job eram os mais utilizados, depois surgiu o conceito de processo e subprocesso e, posteriormente, o conceito de thread.

A seguir, abordaremos os diversos tipos de sistemas operacionais, suas características, vantagens e desvantagens (Fig. 1.5).

Fig. 1.5 Tipos de sistemas operacionais.

1.5.1 Sistemas Monoprogramáveis/Monotarefa

Os primeiros sistemas operacionais eram tipicamente voltados para a execução de um único programa. Qualquer outra aplicação, para ser executada, deveria aguardar o término do programa corrente. Os *sistemas monoprogramáveis*, como vieram a ser conhecidos, se caracterizam por permitir que o processador, a memória e os periféricos permaneçam exclusivamente dedicados à execução de um único programa.

Os sistemas monoprogramáveis estão tipicamente relacionados ao surgimento dos primeiros computadores na década de 1960. Posteriormente, com a introdução dos computadores pessoais e estações de trabalho na década de 1970, este tipo de sistema voltou a ser utilizado para atender máquinas que, na época, eram utilizadas por apenas um usuário. Os *sistemas monotarefa*, como também são chamados, se caracterizam por permitir que todos os recursos do sistema fiquem exclusivamente dedicados a uma única tarefa.

Neste tipo de sistema, enquanto um programa aguarda por um evento, como a digitação de um dado, o processador permanece ocioso, sem realizar qualquer tipo de processamento. A memória é subutilizada caso o programa não a preencha totalmente, e os periféricos, como discos e impressoras, estão dedicados a um único usuário, nem sempre utilizados de forma integral (Fig. 1.6).

Comparados a outros sistemas, os sistemas monoprogramáveis ou monotarefa são de simples implementação, não existindo muita preocupação com problemas decor-

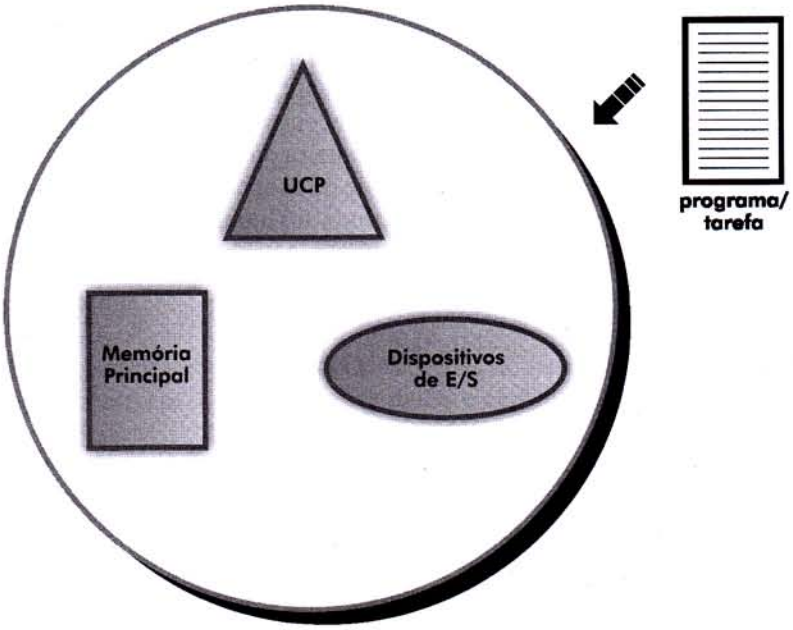

Fig. 1.6 Sistemas monoprogramáveis/monotarefa.

rentes do compartilhamento de recursos, como memória, processador e dispositivos de E/S.

1.5.2 Sistemas Multiprogramáveis/Multitarefa

Os *sistemas multiprogramáveis* ou *multitarefa* são uma evolução dos sistemas monoprogramáveis. Neste tipo de sistema, os recursos computacionais são compartilhados entre os diversos usuários e aplicações. Enquanto em sistemas monoprogramáveis existe apenas um programa utilizando os recursos disponíveis, nos multiprogramáveis várias aplicações compartilham esses mesmos recursos.

Neste tipo de sistema, por exemplo, enquanto um programa espera por uma operação de leitura ou gravação em disco, outros programas podem estar sendo processados neste mesmo intervalo de tempo. Nesse caso, podemos observar o compartilhamento da memória e do processador. O sistema operacional se preocupa em gerenciar o acesso concorrente aos seus diversos recursos, como memória, processador e periféricos, de forma ordenada e protegida, entre os diversos programas (Fig. 1.7).

A principal vantagem dos sistemas multiprogramáveis é a redução de custos em função da possibilidade do compartilhamento dos diversos recursos entre as diferentes aplicações. Além disso, sistemas multiprogramáveis possibilitam na média a redução total do tempo de execução das aplicações. Os sistemas multiprogramáveis, apesar de mais eficientes que os monoprogramáveis, são de implementação muito mais complexa.

A partir do número de usuários que interagem com o sistema operacional, podemos classificar os sistemas multiprogramáveis como monousuário ou multiusuário. *Sistemas multiprogramáveis monousuário* são encontrados em computadores pessoais e estações de trabalho, onde há apenas um único usuário interagindo com o sistema. Neste caso existe a possibilidade da execução de diversas tarefas ao mesmo tempo, como a

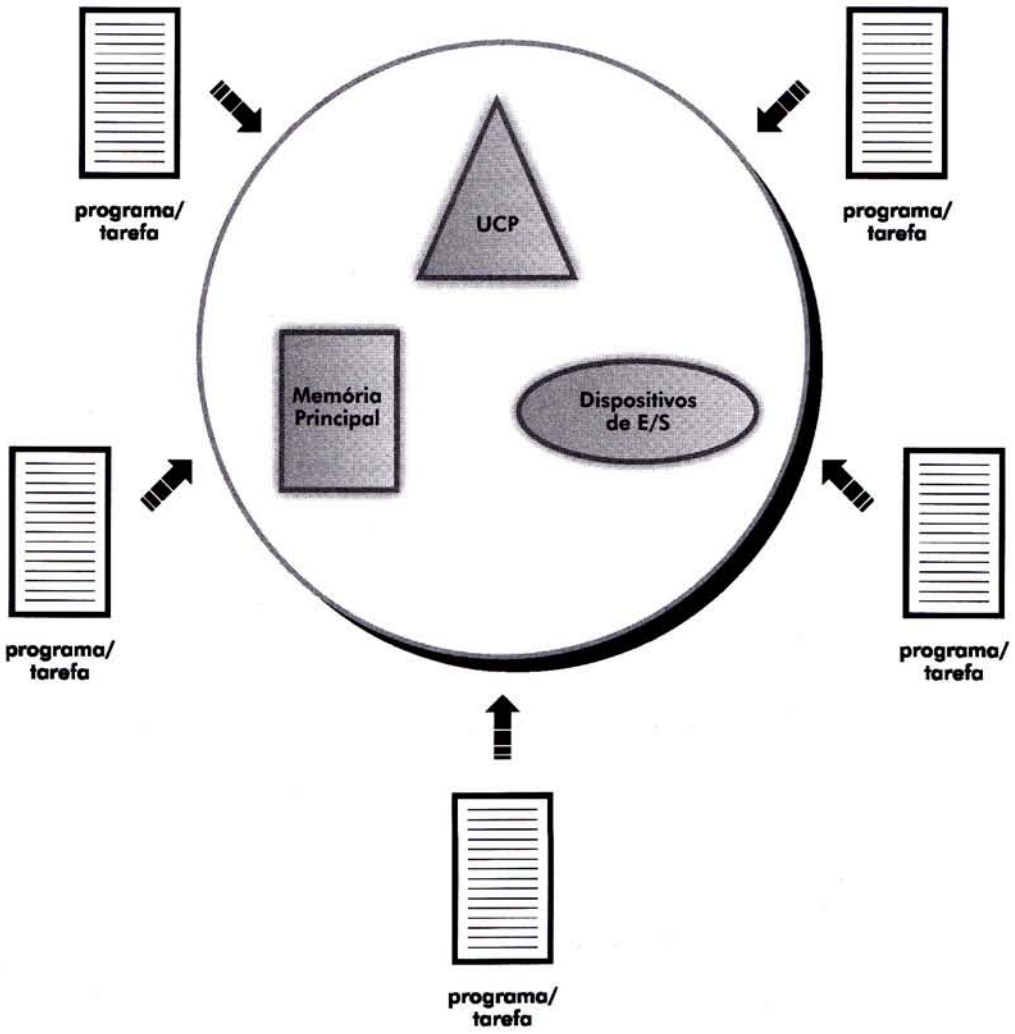

Fig. 1.7 Sistemas multiprogramáveis/multitarefa.

edição de um texto, uma impressão e o acesso à Internet. *Sistemas multiprogramáveis multiusuário* são ambientes interativos que possibilitam a diversos usuários conectarem-se ao sistema simultaneamente. A Tabela 1.1 relaciona os tipos de sistemas em função do número de usuários.

Tabela 1.1 Sistemas × usuários

	Um usuário	Dois ou mais usuários
Monoprogramação/Monotarefa	Monousuário	N/A
Multiprogramação/Multitarefa	Monousuário	Multiusuário

Os sistemas multiprogramáveis ou multitarefa podem ser classificados pela forma com que suas aplicações são gerenciadas, podendo ser divididos em sistemas batch, de tempo compartilhado ou de tempo real. Um sistema operacional pode suportar um ou mais desses tipos de processamento, dependendo de sua implementação (Fig. 1.8).

Fig. 1.8 Tipos de sistemas multiprogramáveis/multitarefa.

1.5.2.1 Sistemas batch

Os *sistemas batch* foram os primeiros tipos de sistemas operacionais multiprogramáveis a serem implementados na década de 1960. Os programas, também chamados de *jobs*, eram submetidos para execução através de cartões perfurados e armazenados em disco ou fita, onde aguardavam para ser processados. Posteriormente, em função da disponibilidade de espaço na memória principal, os jobs eram executados, produzindo uma saída em disco ou fita.

O *processamento batch* tem a característica de não exigir a interação do usuário com a aplicação. Todas as entradas e saídas de dados da aplicação são implementadas por algum tipo de memória secundária, geralmente arquivos em disco. Alguns exemplos de aplicações originalmente processadas em batch são programas envolvendo cálculos numéricos, compilações, ordenações, backups e todos aqueles onde não é necessária a interação com o usuário.

Esses sistemas, quando bem projetados, podem ser bastante eficientes, devido à melhor utilização do processador, entretanto podem oferecer tempos de resposta longos. Atualmente, os sistemas operacionais implementam ou simulam o processamento batch, não existindo sistemas exclusivamente dedicados a este tipo de processamento.

1.5.2.2 Sistemas de tempo compartilhado

Os *sistemas de tempo compartilhado* (*time-sharing*) permitem que diversos programas sejam executados a partir da divisão do tempo do processador em pequenos intervalos, denominados *fatia de tempo* (*time-slice*). Caso a fatia de tempo não seja suficiente para a conclusão do programa, ele é interrompido pelo sistema operacional e substituído por um outro, enquanto fica aguardando por uma nova fatia de tempo. O sistema cria para cada usuário um ambiente de trabalho próprio, dando a impressão de que todo o sistema está dedicado exclusivamente a ele.

Geralmente, sistemas de tempo compartilhado permitem a interação dos usuários com o sistema através de terminais que incluem vídeo, teclado e mouse. Esses sistemas possuem uma linguagem de controle que permite ao usuário comunicar-se diretamente com o sistema operacional através de comandos. Desta forma é possível verificar arquivos armazenados em disco ou cancelar a execução de um programa. O sistema, normalmente, responde em poucos segundos à maioria desses comandos. Devido a esse tipo de interação, os sistemas de tempo compartilhado também ficaram conhecidos como *sistemas on-line*.

www.baixebr.org

A maioria das aplicações comerciais atualmente é processada em sistemas de tempo compartilhado, pois elas oferecem tempos de respostas razoáveis a seus usuários e custos mais baixos, em função da utilização compartilhada dos diversos recursos do sistema.

1.5.2.3 Sistemas de tempo real

Os *sistemas de tempo real* (*real-time*) são implementados de forma semelhante aos sistemas de tempo compartilhado. O que caracteriza a diferença entre os dois tipos de sistemas é o tempo exigido no processamento das aplicações. Enquanto em sistemas de tempo compartilhado o tempo de processamento pode variar sem comprometer as aplicações em execução, nos sistemas de tempo real os tempos de processamento devem estar dentro de limites rígidos, que devem ser obedecidos, caso contrário poderão ocorrer problemas irreparáveis.

Nos sistemas de tempo real não existe a idéia de fatia de tempo, implementada nos sistemas de tempo compartilhado. Um programa utiliza o processador o tempo que for necessário ou até que apareça outro mais prioritário. A importância ou prioridade de execução de um programa é definida pela própria aplicação e não pelo sistema operacional.

Esses sistemas, normalmente, estão presentes em aplicações de controle de processos, como no monitoramento de refinarias de petróleo, controle de tráfego aéreo, de usinas termoelétricas e nucleares, ou em qualquer aplicação onde o tempo de processamento é fator fundamental.

1.5.3 Sistemas com Múltiplos Processadores

Os *sistemas com múltiplos processadores* caracterizam-se por possuir duas ou mais UCPs interligadas e trabalhando em conjunto. A vantagem deste tipo de sistema é permitir que vários programas sejam executados ao mesmo tempo ou que um mesmo programa seja subdividido em partes para serem executadas simultaneamente em mais de um processador.

Com múltiplos processadores foi possível a criação de sistemas computacionais voltados, principalmente, para processamento científico, aplicado, por exemplo, no desenvolvimento aeroespacial, prospecção de petróleo, simulações, processamento de imagens e CAD. A princípio qualquer aplicação que faça uso intensivo da UCP será beneficiada pelo acréscimo de processadores ao sistema. A evolução desses sistemas deve-se, em grande parte, ao elevado custo de desenvolvimento de processadores de alto desempenho.

Os conceitos aplicados ao projeto de sistemas com múltiplos processadores incorporam os mesmos princípios básicos e benefícios apresentados na multiprogramação, além de outras características e vantagens específicas como escalabilidade, disponibilidade e balanceamento de carga.

Escalabilidade é a capacidade de ampliar o poder computacional do sistema apenas adicionando novos processadores. Em ambientes com um único processador, caso haja problemas de desempenho, seria necessário substituir todo o sistema por uma outra configuração com maior poder de processamento. Com a possibilidade de múltiplos processadores, basta acrescentar novos processadores à configuração.

Disponibilidade é a capacidade de manter o sistema em operação mesmo em casos de falhas. Neste caso, se um dos processadores falhar, os demais podem assumir suas

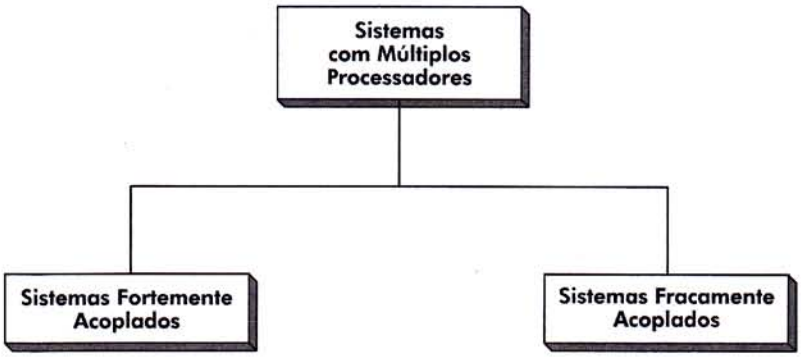

Fig. 1.9 Tipos de sistemas com múltiplos processadores.

funções de maneira transparente aos usuários e suas aplicações, embora com menor capacidade de computação.

Balanceamento de carga é a possibilidade de distribuir o processamento entre os diversos processadores da configuração a partir da carga de trabalho de cada processador, melhorando, assim, o desempenho do sistema como um todo.

Um fator-chave no desenvolvimento de sistemas operacionais com múltiplos processadores é a forma de comunicação entre as UCPs e o grau de compartilhamento da memória e dos dispositivos de entrada e saída. Em função desses fatores, podemos classificar os sistemas com múltiplos processadores em fortemente acoplados ou fracamente acoplados (Fig. 1.9).

A grande diferença entre os dois tipos de sistemas é que em sistemas fortemente acoplados existe apenas uma memória principal sendo compartilhada por todos os processadores, enquanto nos fracamente acoplados cada sistema tem sua própria memória individual. Além disso, a taxa de transferência entre processadores e memória em sistemas fortemente acoplados é muito maior que nos fracamente acoplados.

1.5.3.1 Sistemas fortemente acoplados

Nos *sistemas fortemente acoplados* (tightly coupled) existem vários processadores compartilhando uma única memória física (shared memory) e dispositivos de entrada/saída sendo gerenciados por apenas um sistema operacional (Fig. 1.10). Em função destas características, os sistemas fortemente acoplados também são conhecidos como *multiprocessadores*.

Os sistemas fortemente acoplados podem ser divididos em SMP (Symmetric Multiprocessors) e NUMA (Non-Uniform Memory Access). Os *sistemas SMP* caracterizam-se pelo tempo uniforme de acesso à memória principal pelos diversos processadores. Os *sistemas NUMA* apresentam diversos conjuntos reunindo processadores e memória principal, sendo que cada conjunto é conectado aos outros através de uma rede de interconexão. O tempo de acesso à memória pelos processadores varia em função da sua localização física.

Nos *sistemas SMP* e *NUMA* todos os processadores têm as mesmas funções. Inicialmente, os sistemas com múltiplos processadores estavam limitados aos sistemas de grande porte, restritos ao ambiente universitário e às grandes corporações. Com a evolução dos computadores pessoais e das estações de trabalho, os sistemas multitarefa

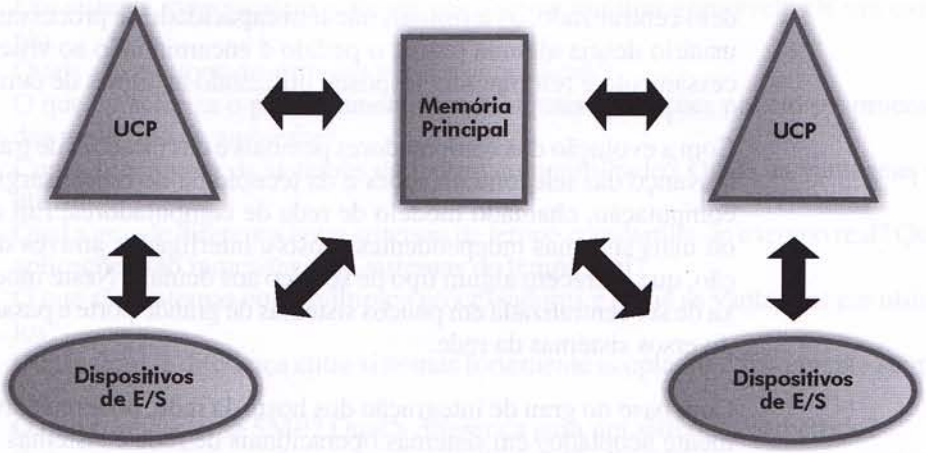

Fig. 1.10 Sistemas fortemente acoplados.

evoluíram para permitir a existência de vários processadores no modelo simétrico. Atualmente, a grande maioria dos sistemas operacionais, como o Unix e o Microsoft Windows, implementa esta funcionalidade.

1.5.3.2 Sistemas fracamente acoplados

Os *sistemas fracamente acoplados* (loosely coupled) caracterizam-se por possuir dois ou mais sistemas computacionais conectados através de linhas de comunicação. Cada sistema funciona de forma independente, possuindo seu próprio sistema operacional e gerenciando seus próprios recursos, como UCP, memória e dispositivos de entrada/saída (Fig. 1.11). Em função destas características, os sistemas fracamente acoplados também são conhecidos como *multicomputadores*. Neste modelo, cada sistema computacional também pode ser formado por um ou mais processadores.

Até meados da década de 1980, as aplicações eram tipicamente centralizadas em sistemas de grande porte, com um ou mais processadores. Neste tipo de configuração, os usuários utilizam terminais não inteligentes conectados a linhas seriais dedicadas ou linhas telefônicas públicas para a comunicação interativa com esses sistemas. No mo-

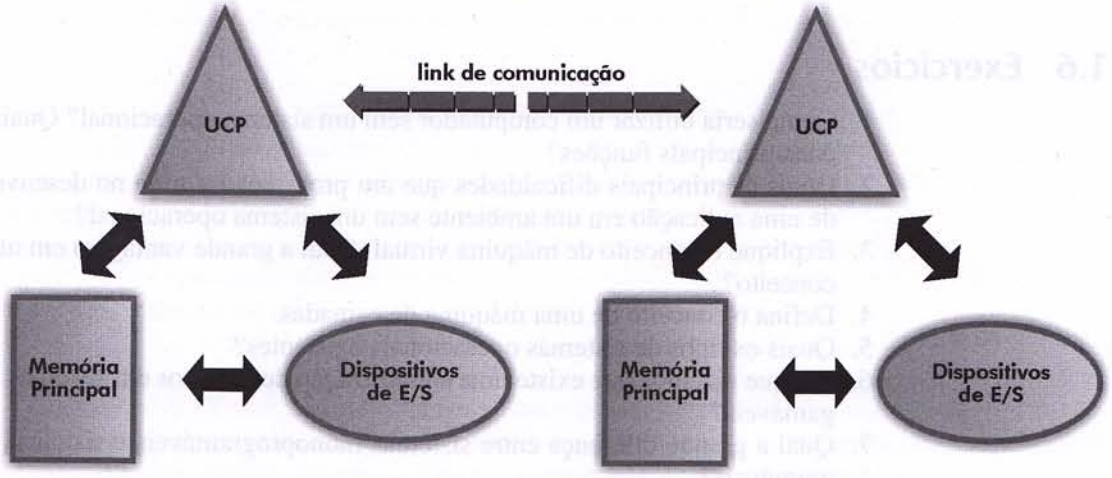

Fig. 1.11 Sistemas fracamente acoplados.

delo centralizado, os terminais não têm capacidade de processamento. Sempre que um usuário deseja alguma tarefa, o pedido é encaminhado ao sistema, que realiza o processamento e retorna uma resposta, utilizando as linhas de comunicação.

Com a evolução dos computadores pessoais e das estações de trabalho, juntamente com o avanço das telecomunicações e da tecnologia de redes, surgiu um novo modelo de computação, chamado modelo de rede de computadores. Em uma rede existem dois ou mais sistemas independentes (hosts), interligados através de linhas de comunicação, que oferecem algum tipo de serviço aos demais. Neste modelo, a informação deixa de ser centralizada em poucos sistemas de grande porte e passa a ser distribuída pelos diversos sistemas da rede.

Com base no grau de integração dos hosts da rede, podemos dividir os sistemas fracamente acoplados em sistemas operacionais de rede e sistemas distribuídos. A grande diferença entre os dois modelos é a capacidade do sistema operacional em criar uma imagem única dos serviços disponibilizados pela rede.

Os *sistemas operacionais de rede* (SOR) permitem que um host compartilhe seus recursos, como uma impressora ou diretório, com os demais hosts da rede. Um exemplo deste tipo de sistema são as redes locais, onde uma estação pode oferecer serviços de arquivos e impressão para as demais estações da rede, dentre outros serviços.

Enquanto nos SORs os usuários têm o conhecimento dos hosts e seus serviços, nos *sistemas distribuídos* o sistema operacional esconde os detalhes dos hosts individuais e passa a tratá-los como um conjunto único, como se fosse um sistema fortemente acoplado. Os sistemas distribuídos permitem, por exemplo, que uma aplicação seja dividida em partes e que cada parte seja executada por hosts diferentes da rede de computadores. Para o usuário e suas aplicações é como se não existisse a rede de computadores, mas sim um único sistema centralizado.

Outro exemplo de sistema distribuído são os *clusters*. Em um cluster existem dois ou mais servidores ligados, normalmente, por algum tipo de conexão de alto desempenho. O usuário não conhece os nomes dos membros do cluster e não sabe quantos são. Quando ele precisa de algum serviço, basta solicitar ao cluster para obtê-lo. Atualmente, sistemas em cluster são utilizados para serviços de banco de dados e Web, garantindo alta disponibilidade, escalabilidade e balanceamento de carga à solução.

1.6 Exercícios

1. Como seria utilizar um computador sem um sistema operacional? Quais são suas duas principais funções?
2. Quais as principais dificuldades que um programador teria no desenvolvimento de uma aplicação em um ambiente sem um sistema operacional?
3. Explique o conceito de máquina virtual. Qual a grande vantagem em utilizar este conceito?
4. Defina o conceito de uma máquina de camadas.
5. Quais os tipos de sistemas operacionais existentes?
6. Por que dizemos que existe uma subutilização de recursos em sistemas monoprogamáveis?
7. Qual a grande diferença entre sistemas monoprogramáveis e sistemas multiprogramáveis?
8. Quais as vantagens dos sistemas multiprogramáveis?

9. Um sistema monousuário pode ser um sistema multiprogramável? Dê um exemplo.
10. Quais são os tipos de sistemas multiprogramáveis?
11. O que caracteriza o processamento batch? Quais aplicações podem ser processadas neste tipo de ambiente?
12. Como funcionam os sistemas de tempo compartilhado? Quais as vantagens em utilizá-los?
13. Qual a grande diferença entre sistemas de tempo compartilhado e tempo real? Quais aplicações são indicadas para sistemas de tempo real?
14. O que são sistemas com múltiplos processadores e quais as vantagens em utilizá-los?
15. Qual a grande diferença entre sistemas fortemente acoplados e fracamente acoplados?
16. O que é um sistema SMP? Qual a diferença para um sistema assimétrico?
17. O que é um sistema fracamente acoplado? Qual a diferença entre sistemas operacionais de rede e sistemas operacionais distribuídos?
18. Quais os benefícios de um sistema com múltiplos processadores em um computador pessoal?
19. Qual seria o tipo de sistema operacional recomendável para uso como servidor de aplicações em um ambiente corporativo?
20. Qual seria o tipo de sistema operacional recomendável para executar uma aplicação que manipula grande volume de dados e necessita de um baixo tempo de processamento?

2

CONCEITOS DE HARDWARE E SOFTWARE

2.1 Introdução

Neste capítulo serão apresentados conceitos básicos de hardware e software relativos à arquitetura de computadores e necessários para a compreensão dos demais capítulos. Os assuntos não serão abordados com profundidade, porém podem ser consultadas referências como (Patterson e Hennesy, 1998), (Stallings, 1999) e (Tanenbaum, 1992) para mais informações.

2.2 Hardware

Um *sistema computacional* é um conjunto de circuitos eletrônicos interligados, formado por processadores, memórias, registradores, barramentos, monitores de vídeo, impressoras, mouse, discos magnéticos, além de outros dispositivos físicos (*hardware*). Todos esses dispositivos manipulam dados na forma digital, o que proporciona uma maneira confiável de representação e transmissão de dados.

Todos os componentes de um sistema computacional são agrupados em três subsistemas básicos, chamados *unidades funcionais*: processador ou unidade central de processamento, memória principal e dispositivos de entrada/saída (Fig. 2.1). Estes subsistemas estão presentes em qualquer tipo de computador digital, independente da arquitetura ou fabricante. Neste item serão descritos os conceitos básicos dos principais componentes desses subsistemas.

2.2.1 PROCESSADOR

O *processador*, também denominado *unidade central de processamento* (UCP), gerencia todo o sistema computacional controlando as operações realizadas por cada unidade funcional. A principal função do processador é controlar e executar instruções presentes na memória principal, através de operações básicas como somar, subtrair, comparar e movimentar dados.

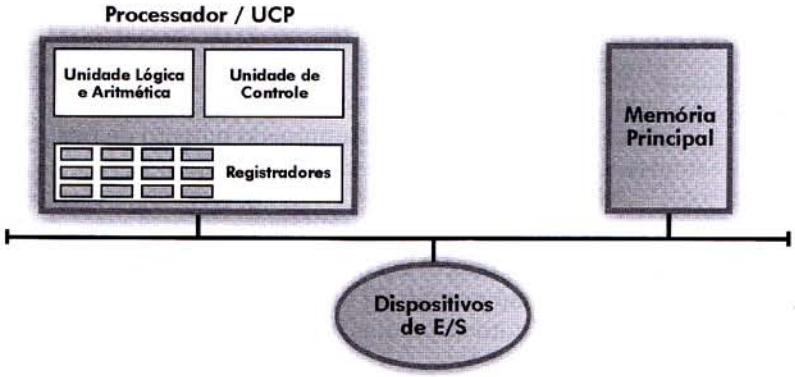

Fig. 2.1 Sistema computacional.

Cada processador é composto por unidade de controle, unidade lógica e aritmética, e registradores. A *unidade de controle* (UC) é responsável por gerenciar as atividades de todos os componentes do computador, como a gravação de dados em discos ou a busca de instruções na memória. A *unidade lógica e aritmética* (ULA), como o nome indica, é responsável pela realização de operações lógicas (testes e comparações) e aritméticas (somas e subtrações).

A sincronização de todas as funções do processador é realizada através de um *sinal de clock*. Este sinal é um pulso gerado ciclicamente que altera variáveis de estado do processador. O sinal de clock é gerado a partir de um cristal de quartzo que, devidamente polarizado, oscila em uma determinada freqüência estável e bem determinada.

Os *registradores* são dispositivos com a função principal de armazenar dados temporariamente. O conjunto de registradores funciona como uma memória de alta velocidade interna do processador, porém com uma capacidade de armazenamento reduzida e custo maior que o da memória principal. O número de registradores e sua capacidade de armazenamento variam em função da arquitetura de cada processador.

Alguns registradores podem ser manipulados diretamente por instruções (registradores de uso geral), enquanto outros são responsáveis por armazenar informações de controle do processador e do sistema operacional (registradores de uso específico). Entre os registradores de uso específico, merecem destaque:

- o *contador de instruções* (CI) ou program counter (PC) contém o endereço da próxima instrução que o processador deve buscar e executar. Toda vez que o processador busca uma nova instrução, este registrador é atualizado com o endereço de memória da instrução seguinte a ser executada;

- o *apontador da pilha* (AP) ou stack pointer (SP) contém o endereço de memória do topo da pilha, que é a estrutura de dados onde o sistema mantém informações sobre programas que estão sendo executados e tiveram que ser interrompidos;

- o *registrador de status* ou program status word (PSW) é responsável por armazenar informações sobre a execução de instruções, como a ocorrência de overflow. A maioria das instruções, quando executadas, altera o registrador de status conforme o resultado.

2.2.2 Memória Principal

A *memória principal*, *primária* ou *real* é o local onde são armazenados instruções e dados. A memória é composta por unidades de acesso chamadas células, sendo cada célula composta por um determinado número de bits. O bit é a unidade básica de memória, podendo assumir o valor lógico 0 ou 1.

Atualmente, a grande maioria dos computadores utiliza o byte (8 bits) como tamanho de célula, porém encontramos computadores de gerações passadas com células de 16, 32 e até mesmo 60 bits. Podemos concluir, então, que a memória é formada por um conjunto de células, onde cada célula possui um determinado número de bits (Fig. 2.2).

O acesso ao conteúdo de uma célula é realizado através da especificação de um número chamado *endereço*. O endereço é uma referência única que podemos fazer a uma célula de memória. Quando um programa deseja ler ou escrever um dado em uma célula, deve primeiro especificar qual o endereço de memória desejado, para depois realizar a operação.

A especificação do endereço é realizada através de um registrador denominado *registrador de endereço de memória* (memory address register — MAR). Através do conteúdo deste registrador, a unidade de controle sabe qual a célula de memória que será acessada. Outro registrador usado em operações com a memória é o *registrador de dados da memória* (memory buffer register — MBR). Este registrador é utilizado para guardar o conteúdo de uma ou mais células de memória, após uma operação de leitura, ou para guardar o dado que será transferido para a memória em uma operação de gravação. Este ciclo de leitura e gravação é apresentado na Tabela 2.1.

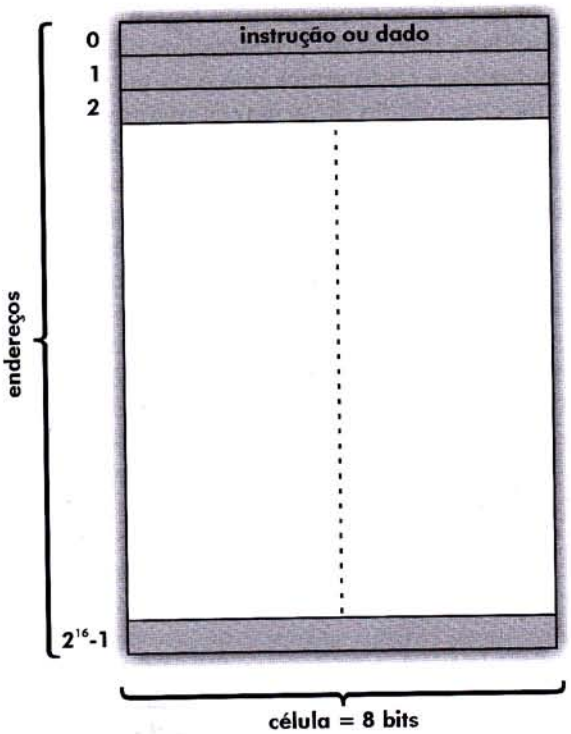

Fig. 2.2 Memória principal com 64 Kbytes.

Tabela 2.1 Ciclo de leitura e gravação

Operação de leitura	Operação de gravação
1. A UCP armazena no MAR o endereço da célula a ser lida. 2. A UCP gera um sinal de controle para a memória principal, indicando que uma operação de leitura deve ser realizada. 3. O conteúdo da(s) célula(s), identificada(s) pelo endereço contido no MAR, é transferido para o MBR. 4. O conteúdo do MBR é transferido para um registrador da UCP	1. A UCP armazena no MAR o endereço da célula que será gravada. 2. A UCP armazena no MBR a informação que deverá ser gravada. 3. A UCP gera um sinal de controle para a memória principal, indicando que uma operação de gravação deve ser realizada. 4. A informação contida no MBR é transferida para a célula de memória endereçada pelo MAR.

O número de células endereçadas na memória principal é limitado pelo tamanho do MAR. No caso de o registrador possuir n bits, a memória poderá no máximo endereçar 2^n células, isto é, do endereço 0 ao endereço $(2^n - 1)$.

A memória principal pode ser classificada em função de sua volatilidade, que é a capacidade de a memória preservar o seu conteúdo mesmo sem uma fonte de alimentação ativa. Memórias do tipo RAM (Random Access Memory) são voláteis, enquanto as memórias ROM (Read-Only Memory) e EPROM (Erasable Programmable ROM) são do tipo não voláteis.

2.2.3 Memória Cache

A *memória cache* é uma memória volátil de alta velocidade, porém com pequena capacidade de armazenamento. O tempo de acesso a um dado nela contido é muito menor que se o mesmo estivesse na memória principal. O propósito do uso da memória cache é minimizar a disparidade existente entre a velocidade com que o processador executa instruções e a velocidade com que dados são lidos e gravados na memória principal. Apesar de ser uma memória de acesso rápido, a capacidade de armazenamento das memórias cache é limitada em função do seu alto custo. A Tabela 2.2 mostra a relação entre memórias cache e principal em alguns equipamentos.

Tabela 2.2 Relação entre memórias cache e principal

	HP 9000/855S	IBM 3090/600S	VAX 9000/440
Tamanho máximo memória principal	25 Mb	512 Mb	512 Mb
Tamanho máximo memória cache	256 Kb	128 Kb por UCP	128 Kb por UCP

A memória cache armazena uma pequena parte do conteúdo da memória principal. Toda vez que o processador faz referência a um dado armazenado na memória, é verificado, primeiramente, se o mesmo encontra-se na memória cache. Caso o processador encontre o dado (cache hit), não há necessidade do acesso à memória principal, diminuindo assim o tempo de acesso.

Se a informação desejada não estiver presente na cache, o acesso à memória principal é obrigatório (cache miss). Neste caso, o processador, a partir do dado referenciado, transfere um bloco de dados da memória principal para a cache. Apesar de existir neste meca-

nismo um tempo adicional para a transferência de dados entre as diferentes memórias, este tempo é compensado pela melhora do desempenho, justificado pelo alto percentual de referências a endereços que são resolvidos na cache. Isto ocorre devido ao *princípio da localidade* existente em códigos que são estruturados de forma modular.

A *localidade* é a tendência de o processador, ao longo da execução de um programa, referenciar instruções e dados na memória principal localizados em endereços próximos. Esta tendência é justificada pela alta incidência de estruturas de repetição, chamadas a sub-rotinas e acesso a estruturas de dados como vetores e tabelas. O princípio da localidade garante, então, que após a transferência de um novo bloco da memória principal para a cache haverá uma alta probabilidade de cache hits em futuras referências, otimizando, assim, o tempo de acesso ao dado.

A maioria dos processadores apresenta uma arquitetura de memória cache com múltiplos níveis. O funcionamento desta arquitetura tem como base o princípio de que quanto menor é a capacidade de armazenamento da memória cache, mais rápido é o acesso ao dado; contudo, a probabilidade da ocorrência de cache hits é menor.

A hierarquização da cache em múltiplos níveis é uma solução para aumentar o desempenho no funcionamento das memórias caches. O nível de cache mais alto é chamado de L1 (*Level 1*), com baixa capacidade de armazenamento e com altíssima velocidade de acesso. O segundo nível, L2 (*Level 2*), possui maior capacidade de armazenamento, porém com velocidade de acesso inferior a L1. Quando a UCP necessita acessar um dado na memória principal, primeiramente é verificado se o dado encontra-se na cache L1. Caso o dado seja encontrado, obtém-se um excelente desempenho no acesso à informação, porém, caso o dado não seja encontrado, a busca prossegue para a L2.

Um processador pode ser projetado com diversos níveis de cache, conforme especificação do fabricante. Como exemplos, o processador da Motorola Power PC G4 possui cache de nível 2, enquanto o processador Intel Xeon MP possui cache de nível 3.

2.2.4 Memória Secundária

A *memória secundária* é um meio permanente, isto é, não volátil de armazenamento de programas e dados. Enquanto a memória principal precisa estar sempre energizada para manter suas informações, a memória secundária não precisa de alimentação.

O acesso à memória secundária é lento, se comparado com o acesso à memória principal, porém seu custo é baixo e sua capacidade de armazenamento é bem superior. Enquanto a unidade de acesso à memória secundária é da ordem de milissegundos, o acesso à memória principal é de nanossegundos. Podemos citar, como exemplos de memórias secundárias, a fita magnética, o disco magnético e o disco óptico.

A Fig. 2.3 mostra a relação entre os diversos tipos de dispositivos de armazenamento apresentados, comparando custo, velocidade e capacidade de armazenamento.

2.2.5 Dispositivos de Entrada e Saída

Os *dispositivos de entrada e saída (E/S)* são utilizados para permitir a comunicação entre o sistema computacional e o mundo externo, e podem ser divididos em duas categorias: os que são utilizados como memória secundária e os que servem para a interface usuário-máquina.

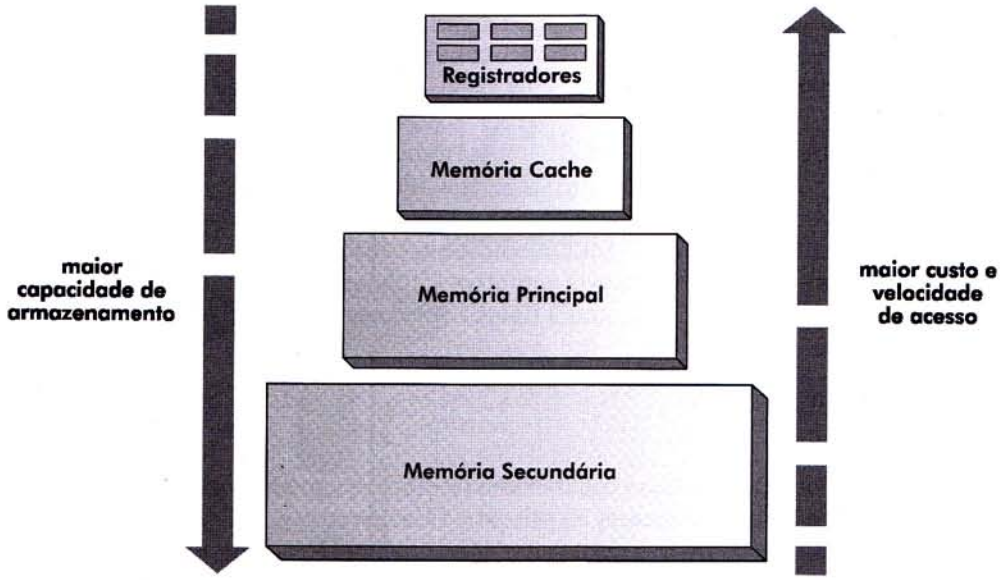

Fig. 2.3 Relação entre dispositivos de armazenamento.

Os dispositivos utilizados como memória secundária (discos e fitas magnéticas) caracterizam-se por ter capacidade de armazenamento bastante superior ao da memória principal. Seu custo é relativamente baixo, porém o tempo de acesso à memória secundária é bem superior ao da memória principal.

Outros dispositivos têm como finalidade a comunicação usuário-máquina, como teclados, monitores de vídeo, impressoras e plotters. A implementação de interfaces mais amigáveis permite, cada vez mais, que usuários pouco especializados utilizem computadores de maneira intuitiva. Scanner, caneta ótica, mouse, dispositivos sensíveis a voz humana e tato são alguns exemplos desses tipos de dispositivos.

2.2.6 Barramento

O *barramento* ou *bus* é um meio de comunicação compartilhado que permite a comunicação entre as unidades funcionais de um sistema computacional. Através de condutores, informações como dados, endereços e sinais de controle trafegam entre processadores, memórias e dispositivos de E/S.

Em geral, um barramento possui linhas de controle e linhas de dados. Através das linhas de controle trafegam informações de sinalização como, por exemplo, o tipo de operação que está sendo realizada. Pelas linhas de dados, informações como instruções, operandos e endereços são transferidos entre unidades funcionais.

Os barramentos são classificados em três tipos: *barramentos processador-memória*, *barramentos de E/S* e *barramentos de backplane*. Os barramentos processador-memória são de curta extensão e alta velocidade para que seja otimizada a transferência de informação entre processadores e memórias. Diferentemente, os barramentos de E/S possuem maior extensão, são mais lentos e permitem a conexão de diferentes dispositivos.

A Fig. 2.4 ilustra a arquitetura de um sistema computacional utilizando barramentos processador-memória e de E/S. É importante notar na ilustração que na conexão dos barramentos existe um adaptador (bus adapter) que permite compatibilizar as diferentes velocidades dos barramentos.

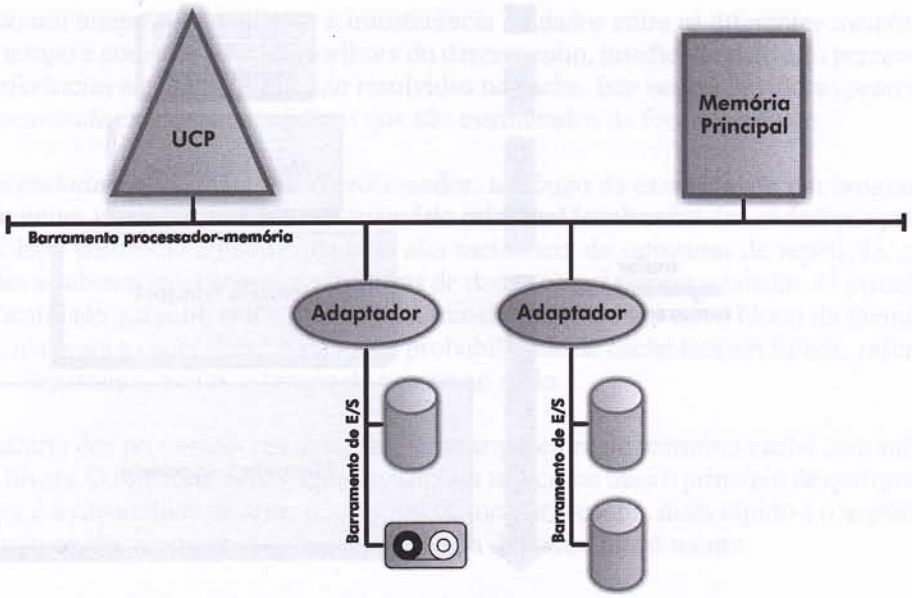

Fig. 2.4 Barramentos processador-memória e de E/S.

Alguns sistemas de alto desempenho utilizam uma arquitetura com um terceiro barramento, conhecido como barramento de backplane (Fig. 2.5). Nesta organização, o barramento de E/S não se conecta diretamente ao barramento processador-memória,

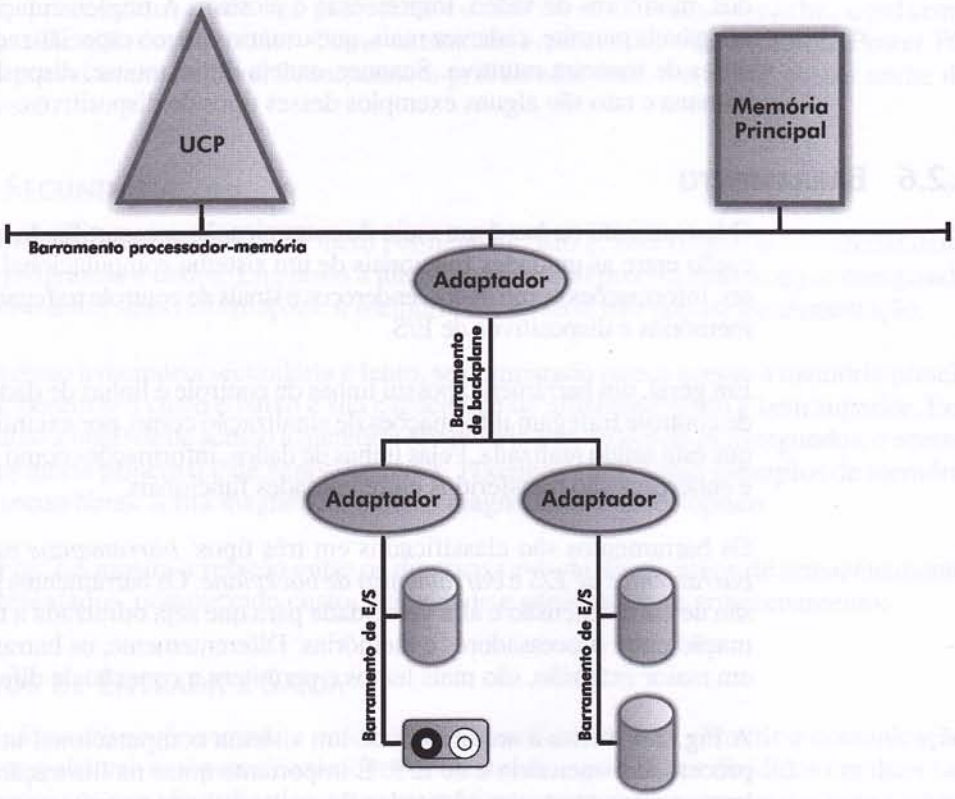

Fig. 2.5 Barramento de backplane.

tendo o barramento de backplane a função de integrar os dois barramentos. A principal vantagem desta arquitetura é reduzir o número de adaptadores existentes no barramento processador-memória e, desta forma, otimizar seu desempenho.

Os barramentos processador-memória são freqüentemente utilizados em arquiteturas proprietárias. Como exemplo, a Intel introduziu o barramento PCI (Peripheral Component Interconnect) junto com o seu processador Pentium. Os barramentos de E/S em geral seguem padrões preestabelecidos, pois, desta forma, os dispositivos de E/S podem ser conectados a sistemas computacionais de diferentes plataformas e fabricantes. O padrão SCSI (Small Computer System Interface) é um dos mais utilizados.

2.2.7 Pipelining

Pipelining é uma técnica que permite ao processador executar múltiplas instruções paralelamente em estágios diferentes. O conceito de processamento pipeline se assemelha muito a uma linha de montagem, onde uma tarefa é dividida em uma seqüência de subtarefas, executadas dentro da linha de produção.

Da mesma forma que em uma linha de montagem, a execução de uma instrução pode ser dividida em subtarefas, como as fases de busca da instrução e dos operandos, execução e armazenamento dos resultados. O processador, através de suas várias unidades funcionais pipeline, funciona de forma a permitir que, enquanto uma instrução se encontra na fase de execução, uma outra instrução possa estar na fase de busca simultaneamente. A Fig. 2.6 ilustra um processador com quatro unidades funcionais pipeline, permitindo que quatro instruções sejam executadas em paralelo, porém em estágios diferentes.

O pipelining pode ser empregado em sistemas com um ou mais processadores, em diversos níveis, e tem sido a técnica de paralelismo mais utilizada para aumentar o desempenho dos sistemas computacionais.

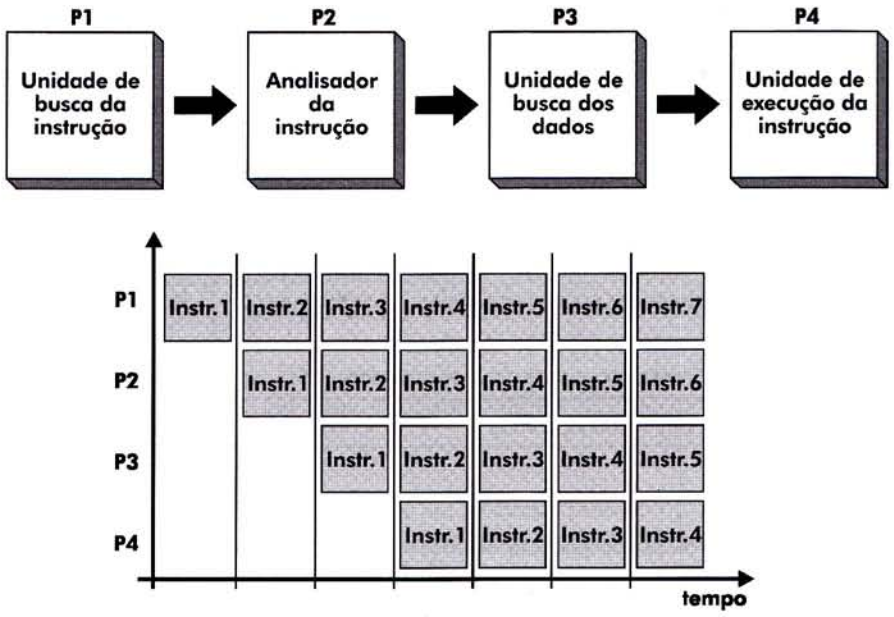

Fig. 2.6 Arquitetura pipeline com quatro estágios.

2.2.8 Arquiteturas RISC e CISC

A *linguagem de máquina* de um computador é a linguagem de programação que é realmente entendida pelo processador. Cada processador possui um conjunto definido de instruções de máquina, definido por seu fabricante. As instruções de máquina fazem referências a detalhes, como registradores, modos de endereçamento e tipos de dados, que caracterizam um processador e suas funcionalidades.

Um programa em linguagem de máquina pode ser diretamente executado pelo processador, não requerendo qualquer tipo de tradução ou relocação. Quando escrito em linguagem de máquina de um determinado processador, um programa não pode ser executado em outra máquina de arquitetura diferente, visto que o conjunto de instruções de um processador é característica específica de cada arquitetura.

Um processador com arquitetura *RISC* (Reduced Instruction Set Computer) se caracteriza por possuir poucas instruções de máquina, em geral bastante simples, que são executadas diretamente pelo hardware. Na sua maioria, estas instruções não acessam a memória principal, trabalhando principalmente com registradores que, neste tipo de processador, se apresentam em grande número. Estas características, além de permitirem que as instruções sejam executadas rapidamente, facilitam a implementação do pipelining. Como exemplos de processadores RISC podemos citar o SPARC (Sun), RS-6000 (IBM), PA-RISC (HP), Alpha AXP (Compaq) e Rx000 (MIPS).

Os processadores com arquitetura *CISC* (Complex Instruction Set Computers) já possuem instruções complexas que são interpretadas por microprogramas. O número de registradores é pequeno, e qualquer instrução pode referenciar a memória principal. Neste tipo de arquitetura, a implementação do pipelining é mais difícil. São exemplos de processadores CISC o VAX (DEC), Pentium (Intel) e 68xxx (Motorola). A Tabela 2.3 compara características presentes nas arquiteturas RISC e CISC.

Tabela 2.3 Arquitetura RISC × Arquitetura CISC

Arquitetura RISC	Arquitetura CISC
Poucas instruções	Muitas instruções
Instruções executadas pelo hardware	Instruções executadas por microcódigo
Instruções com formato fixo	Instruções com diversos formatos
Instruções utilizam poucos ciclos de máquina	Instruções utilizam múltiplos ciclos
Instruções com poucos modos de endereçamento	Instruções com diversos modos de endereçamento
Arquitetura com muitos registradores	Arquitetura com poucos registradores
Arquitetura pipelining	Pouco uso da técnica de pipelining

Nos processadores RISC, um programa em linguagem de máquina é executado diretamente pelo hardware, porém isto não ocorre nos processadores CISC. Podemos observar, na Fig. 2.7, que entre os níveis da linguagem de máquina e de circuitos eletrônicos existe um nível intermediário que é o de *microprogramação*.

Fig. 2.7 Máquina de níveis.

Os microprogramas definem a linguagem de máquina de um computador CISC. Apesar de cada computador possuir níveis de microprogramação diferentes, existem muitas semelhanças nessa camada se compararmos os diferentes equipamentos. Um computador possui, aproximadamente, 25 microinstruções básicas, que são interpretadas pelos circuitos eletrônicos.

Na realidade, o código executável de um processador CISC é interpretado por microprogramas durante sua execução, gerando *microinstruções*, que, finalmente, são executadas pelo hardware. Para cada instrução em linguagem de máquina existe um microprograma associado.

Os processadores chamados microprogramáveis são aqueles que permitem que novas instruções de máquina possam ser criadas através da criação de microprogramas. Alguns equipamentos, como os microprocessadores, não dispõem desse recurso, já que os microprogramas vêm gravados em memória do tipo ROM.

2.2.9 Análise de Desempenho

Para avaliar o desempenho de processadores, diversas variáveis devem ser consideradas, entre as quais o intervalo de tempo entre os pulsos de um sinal de clock, conhecido como *ciclo de clock*. A *freqüência do clock* é o inverso do ciclo de clock e indica o número de pulsos elétricos gerados em um segundo. A medida da freqüência é dada em hertz (Hz) ou seus múltiplos, como quilohertz (kHz) ou megahertz (MHz).

O desempenho de um processador pode ser avaliado pela comparação dos tempos que processadores distintos levam para executar um mesmo programa. Este tempo é denominado *tempo de UCP*, que leva em consideração apenas o tempo para executar instruções pelo processador, não incluindo a espera em operações de E/S. O tempo de UCP para um determinado programa é dado por:

$$\text{tempo de UCP} = \text{número de ciclos de clock} \times \text{ciclo de clock para execução do programa}$$

Considerando que a freqüência de clock é o inverso do ciclo, podemos ter para o cálculo do tempo de UCP a seguinte fórmula:

$$\text{tempo de UCP} = \frac{\text{número de ciclos de clock para execução do programa}}{\text{freqüência de clock}}$$

É possível perceber, observando as fórmulas anteriores, que o desempenho do processador pode ser otimizado reduzindo o tempo do ciclo de clock ou o número de ciclos de clock utilizados na execução do programa.

A técnica conhecida como *benchmark* permite a análise de desempenho comparativa entre sistemas computacionais. Neste método, um conjunto de programas é executado em cada sistema avaliado e o tempo de execução comparado. A escolha dos programas deve ser criteriosa, para refletir os diferentes tipos de aplicação.

Uma das técnicas de benchmark entre processadores é a SPEC (System Performance Evaluation Cooperative) criada em 1988. SPECint, SPECfp, SPEC95, SPEChpc96 são testes que foram introduzidos ao longo do tempo para tentar mensurar o desempenho dos sistemas computacionais o mais próximo possível das condições reais de uso. Aspectos como operações de E/S e componentes do sistema operacional vêm sendo também introduzidos nos benchmarks. A Tabela 2.4 ilustra um exemplo de benchmark (SPEC, 2001).

Tabela 2.4 Benchmark entre diversos sistemas

Fabricantes	Sistemas	Número de processadores	SPECint95	SPECfp95
Compaq Computer	Compaq AlphaServer DS20	1	27,7	58,7
Fujitsu Limited	GP7000F Model600 300	1	19,2	30,5
Hewlett-Packard	HP 9000 Model J5000	2	32,5	52,3
IBM Corporation	RISC System/6000 43P	1	4,72	3,38
Intel Corporation	Intel SE440BX motherboard (233MH)	1	9,38	7,40

2.3 Software

Para que o hardware tenha utilidade prática, deve existir um conjunto de programas utilizado como interface entre as necessidades do usuário e as capacidades do hardware. A utilização de softwares adequados às diversas tarefas e aplicações torna o trabalho dos usuários muito mais simples e eficiente.

No decorrer do texto, utilizaremos o termo *utilitário* sempre que desejarmos fazer referência a softwares relacionados mais diretamente com serviços complementares do sistema operacional, como compiladores, linkers e depuradores. Os softwares desenvolvidos pelos usuários serão denominados aplicativos ou apenas aplicações.

2.3.1 TRADUTOR

Nos primeiros sistemas computacionais, o ato de programar era bastante complicado, já que o programador deveria possuir conhecimento da arquitetura da máquina e programar em painéis através de fios. Esses programas eram desenvolvidos em linguagem de máquina e carregados diretamente na memória principal para execução.

Com o surgimento das primeiras *linguagens de montagem* ou *assembly* e das *linguagens de alto nível*, o programador deixou de se preocupar com muitos aspectos pertinentes ao hardware, como em qual região da memória o programa deveria ser carregado ou quais endereços de memória seriam reservados para as variáveis. A utilização dessas linguagens facilitou a construção de programas, documentação e manutenção.

Apesar das inúmeras vantagens proporcionadas pelas linguagens de montagem e de alto nível, os programas escritos nessas linguagens não estão prontos para ser diretamente executados pelo processador (programas-fonte). Para isso, eles têm de passar por uma etapa de conversão, onde toda representação simbólica das instruções é traduzida para código de máquina. Esta conversão é realizada por um utilitário denominado *tradutor*.

O módulo gerado pelo tradutor é denominado *módulo-objeto*, que, apesar de estar em código de máquina, na maioria das vezes não pode ser ainda executado. Isso ocorre em função de um programa poder chamar sub-rotinas externas, e, neste caso, o tradutor não tem como associar o programa principal às sub-rotinas chamadas. Esta função é realizada por outro utilitário denominado *linker*, e será apresentado adiante.

Dependendo do tipo do programa-fonte, existem dois tipos distintos de tradutores que geram módulos-objeto: montador e compilador (Fig. 2.8).

O *montador (assembler)* é o utilitário responsável por traduzir um programa-fonte em linguagem de montagem em um programa-objeto não executável (módulo-objeto). A linguagem de montagem é particular para cada processador, assim como a linguagem de máquina, o que não permite que programas assembly possam ser portados entre máquinas diferentes.

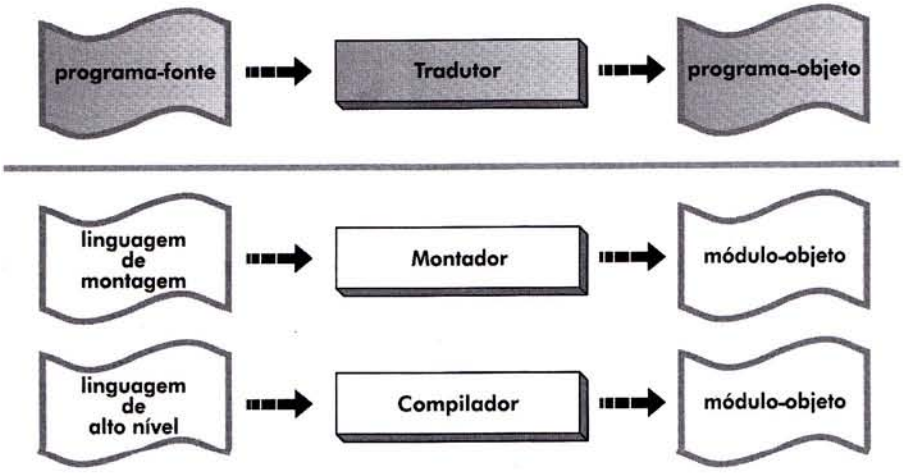

Fig. 2.8 Tradutor.

O *compilador* é o utilitário responsável por gerar, a partir de um programa escrito em uma linguagem de alto nível, um programa em linguagem de máquina não executável. As linguagens de alto nível, como Pascal, FORTRAN e COBOL, não têm nenhuma relação direta com a máquina, ficando essa preocupação exclusivamente com o compilador. Os programadores de alto nível devem se preocupar apenas com o desenvolvimento de suas aplicações, não tendo que se envolver com detalhes sobre a arquitetura do processador. Assim, os programas-fonte podem ser portados entre computadores de diversos fabricantes, desde que existam padrões para a sintaxe da linguagem. Isso permite o desenvolvimento de aplicações independentes do equipamento.

Um compilador é um utilitário que opera de modo integrado aos componentes do sistema de programação disponíveis, sob a supervisão do sistema operacional (Neto, 1987). Podemos visualizar, então, o compilador como uma interface entre o sistema operacional e o usuário, de maneira que é possível acessar diversos serviços do sistema sem a necessidade da utilização de linguagem de controle ou de outros utilitários.

2.3.2 INTERPRETADOR

O *interpretador* é considerado um tradutor que não gera módulo-objeto. A partir de um programa-fonte escrito em linguagem de alto nível, o interpretador, durante a execução do programa, traduz cada instrução e a executa imediatamente. Algumas linguagens tipicamente interpretadas são o Basic e o Perl.

A maior desvantagem na utilização de interpretadores é o tempo gasto na tradução das instruções de um programa toda vez que este for executado, já que não existe a geração de um código executável. A vantagem é permitir a implementação de tipos de dados dinâmicos, ou seja, que podem mudar de tipo durante a execução do programa, aumentando, assim, sua flexibilidade.

2.3.3 LINKER

O *linker* ou *editor de ligação* é o utilitário responsável por gerar, a partir de um ou mais módulos-objeto, um único programa executável (Fig. 2.9). Suas funções básicas são resolver todas as referências simbólicas existentes entre os módulos e reservar memória para a execução do programa.

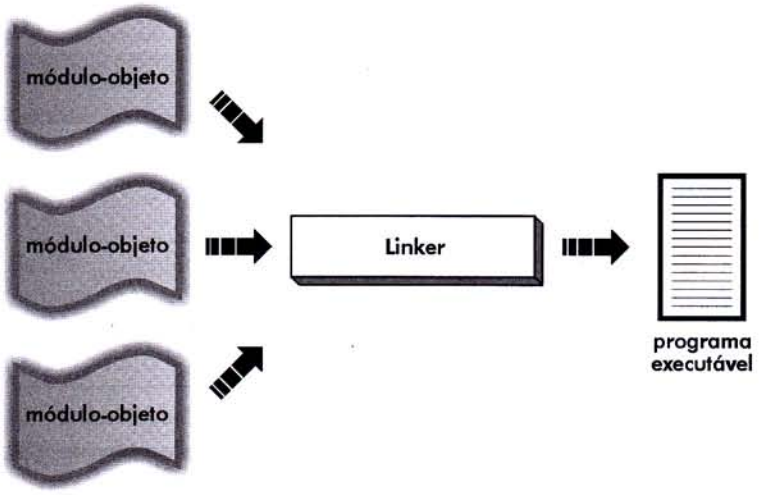

Fig. 2.9 Linker.

Para resolver todas as referências a símbolos, o linker também pode pesquisar em bibliotecas do sistema ou do próprio usuário. *Bibliotecas* são arquivos que contêm diversos módulos-objeto e/ou definições de símbolos.

Outra função importante do linker é a *relocação*, que determina a região de memória na qual o programa será carregado para execução. Nos primeiros sistemas operacionais, a relocação era realizada somente uma vez, na etapa de linkedição. Todos os endereços simbólicos do programa eram traduzidos para endereços físicos, e o programa executável gerado podia ser carregado a partir de uma posição prefixada na memória (código absoluto). Nesse tipo de relocação, o programa poderia ser carregado, apenas, a partir de uma única posição na memória.

Em sistemas multiprogramáveis esse tipo de relocação é de difícil implementação, já que a memória é compartilhada entre diversos programas, e é pouco provável que, no momento em que o sistema carrega um programa, sua área de memória prefixada esteja disponível. A solução para este problema é permitir que o programa seja carregado em regiões diferentes toda vez que for trazido para a memória (código relocável). Esse tipo de relocação não é realizado pelo linker, mas sim por outro utilitário denominado *loader*, responsável por carregar os programas na memória.

Em alguns sistemas, o compilador pode realizar mais do que suas funções básicas, como resolver referências de endereço, sendo que, dessa forma, o programa não necessita passar pela etapa de linkedição independente. Nesse caso, um outro utilitário (linking loader) fica responsável pela carga do programa na memória e pela sua execução. Nesse tipo de sistema, o programa passa por um processo de *link dinâmico*, onde as referências globais são resolvidas no momento da execução. A grande desvantagem dessa implementação é a sobrecarga de processamento (overhead) existente em cada execução do programa, problema que não ocorre em sistemas que possuem linkers independentes (Levy, 1980).

2.3.4 Loader

O *loader* ou *carregador* é o utilitário responsável por carregar na memória principal um programa para ser executado. O procedimento de carga varia com o código gerado pelo linker e, em função deste, o loader é classificado como sendo do tipo absoluto ou relocável.

Se o código executável for do tipo absoluto, o loader só necessita conhecer o endereço de memória inicial e o tamanho do módulo para realizar o carregamento. Então, o loader transfere o programa da memória secundária para a memória principal e inicia sua execução (*loader absoluto*).

No caso do código relocável, o programa pode ser carregado em qualquer posição de memória, e o loader é responsável pela relocação no momento do carregamento (*loader relocável*).

2.3.5 Depurador

O desenvolvimento de programas está sujeito a erros de lógica, independentemente de metodologias utilizadas pelo programador. A depuração é um dos estágios desse desenvolvimento, e a utilização de ferramentas adequadas é essencial para acelerar o processo de correção dos programas. O *depurador* (debugger) é o utilitário que permite ao usuário acompanhar toda a execução de um programa a fim de detectar erros na sua lógica. Este utilitário oferece ao usuário recursos como:

- acompanhar a execução de um programa instrução por instrução;
- possibilitar a alteração e a visualização do conteúdo de variáveis;
- implementar pontos de parada dentro do programa (breakpoint), de forma que, durante a execução, o programa pare nesses pontos;
- especificar que, toda vez que o conteúdo de uma variável for modificado, o programa envie uma mensagem (watchpoint).

2.4 Exercícios

1. Quais são as unidades funcionais de um sistema computacional?
2. Quais os componentes de um processador e quais são suas funções?
3. Como a memória principal de um computador é organizada?
4. Descreva os ciclos de leitura e gravação da memória principal.
5. Qual o número máximo de células endereçadas em arquiteturas com MAR de 16, 32 e 64 bits?
6. O que são memórias voláteis e não voláteis?
7. Conceitue memória cache e apresente as principais vantagens no seu uso.
8. Qual a importância do princípio da localidade na eficiência da memória cache?
9. Quais os benefícios de uma arquitetura de memória cache com múltiplos níveis?
10. Quais as diferenças entre a memória principal e a memória secundária?
11. Diferencie as funções básicas dos dispositivos de E/S.
12. Caracterize os barramentos processador-memória, E/S e backplane.
13. Como a técnica de pipelining melhora o desempenho dos sistemas computacionais?
14. Compare as arquiteturas de processadores RISC e CISC.
15. Conceitue a técnica de benchmark e como é sua realização.
16. Por que o código-objeto gerado pelo tradutor ainda não pode ser executado?
17. Por que a execução de programas interpretados é mais lenta que a de programas compilados?
18. Quais as funções do linker?
19. Qual a principal função do loader?
20. Quais as facilidades oferecidas pelo depurador?

3

CONCORRÊNCIA

3.1 Introdução

Sistemas operacionais podem ser vistos como um conjunto de rotinas executadas de forma concorrente e ordenada (Pinkert, 1990). A possibilidade de o processador executar instruções ao mesmo tempo que outras operações, como, por exemplo, operações de E/S, permite que diversas tarefas sejam executadas concorrentemente pelo sistema. O conceito de concorrência é o princípio básico para o projeto e a implementação dos sistemas multiprogramáveis.

Neste capítulo serão apresentados mecanismos, técnicas e dispositivos que possibilitam a implementação da concorrência como interrupções e exceções, buffering, spooling e reentrância. Todos estes conceitos são fundamentais para a arquitetura de um sistema operacional multiprogramável. Inicialmente será apresentada uma comparação entre os sistemas monoprogramáveis e multiprogramáveis para ilustrar a importância do conceito de concorrência.

3.2 Sistemas Monoprogramáveis × Multiprogramáveis

Os sistemas multiprogramáveis surgiram a partir de limitações existentes nos sistemas operacionais monoprogramáveis. Neste tipo de sistema, os recursos computacionais, como processador, memória e dispositivos de E/S, eram utilizados de maneira pouco eficiente, limitando o desempenho destas arquiteturas. Muitos destes recursos de alto custo permaneciam muitas vezes ociosos por longos períodos de tempo.

Nos sistemas monoprogramáveis somente um programa pode estar em execução por vez, permanecendo o processador dedicado, exclusivamente, a essa tarefa. Podemos observar que, nesse tipo de sistema, ocorre um desperdício na utilização do processador (Fig. 3.1a), pois enquanto uma leitura em disco é realizada, o processador permanece ocioso. O tempo de espera é relativamente longo, já que as operações com dispositivos de entrada e saída são muito lentas, se comparadas com a velocidade do processador em executar instruções.

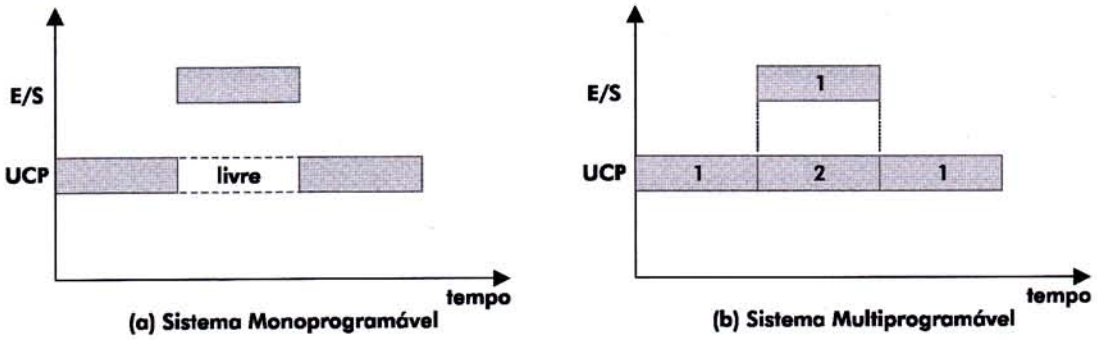

Fig. 3.1 Sistema monoprogramável × sistema multiprogramável.

A Tabela 3.1 apresenta um exemplo de um programa que lê registros de um arquivo e executa, em média, 100 instruções por registro lido. Neste caso, o processador gasta aproximadamente 93% do tempo esperando o dispositivo de E/S concluir a operação para continuar o processamento (Stallings, 1997). Em sistemas monoprogramáveis o processador é subutilizado, permanecendo livre grande parte do tempo.

Tabela 3.1 Exemplo de utilização do sistema

Leitura de um registro	0,0015 s
Execução de 100 instruções	0,0001 s
Total	0,0016 s
% utilização da CPU (0,0001 / 0,0015) = 0,066 = 6,6%	

Outro aspecto a ser considerado é a subutilização da memória principal. Um programa que não ocupe totalmente a memória ocasiona a existência de áreas livres sem utilização. Nos sistemas multiprogramáveis, vários programas podem estar residentes em memória, concorrendo pela utilização do processador. Dessa forma, quando um programa solicita uma operação de E/S outros programas poderão utilizar o processador. Nesse caso, a UCP permanece menos tempo ociosa (Fig. 3.1b) e a memória principal é utilizada de forma mais eficiente, pois existem vários programas residentes se revezando na utilização do processador.

A utilização concorrente da UCP deve ser implementada de maneira que, quando um programa perde o uso do processador e depois retorna para continuar o processamento, seu estado deve ser idêntico ao do momento em que foi interrompido. O programa deverá continuar sua execução exatamente na instrução seguinte àquela em que havia parado, aparentando ao usuário que nada aconteceu. Em sistemas de tempo compartilhado existe a impressão de que o computador está inteiramente dedicado ao usuário, ficando esse mecanismo totalmente transparente.

No caso de periféricos, é comum termos, em sistemas monoprogramáveis, impressoras paradas por um grande período de tempo e discos com acesso restrito a um único usuário. Esses problemas são solucionados em sistemas multiprogramáveis, onde é possível compartilhar dispositivos de E/S, como impressoras e discos, entre diversos aplicativos.

As vantagens proporcionadas pela multiprogramação podem ser percebidas onde existe um sistema computacional com um disco, um terminal e uma impressora, como mos-

Tabela 3.2 Características de execução dos programas

Características	Prog1	Prog2	Prog3
Utilização da UCP	Alta	Baixa	Baixa
Operação de E/S	Poucas	Muitas	Muitas
Tempo de processamento	5 min	15 min	10 min
Memória utilizada	50 Kb	100 Kb	80 Kb
Utilização de disco	Não	Não	Sim
Utilização de terminal	Não	Sim	Não
Utilização de impressora	Não	Não	Sim

tra a Tabela 3.2. Neste ambiente são executados três programas (Prog1, Prog2 e Prog3), que possuem características de processamento descritas na Tabela 3.2, na qual podemos notar que o Prog1 não realiza operações de E/S, ao contrário de Prog2 e Prog3 (Stallings, 1997).

Em um ambiente monoprogramável, os programas são executados seqüencialmente. Sendo assim, o Prog1 é processado em cinco minutos, enquanto o Prog2 espera para começar sua execução, que leva 15 minutos. Finalmente, o Prog3 inicia sua execução após 20 minutos e completa seu processamento em 10 minutos, totalizando 30 minutos na execução dos três programas. No caso de os programas serem executados concorrentemente, em um sistema multiprogramável, o ganho na utilização do processador, memória, periféricos e também no tempo de resposta é considerável, como mostra a Tabela 3.3.

Tabela 3.3 Comparação entre monoprogramação e multiprogramação

	Monoprogramação	Multiprogramação
Utilização da UCP	17%	33%
Utilização da memória	30%	67%
Utilização de disco	33%	67%
Utilização de impressora	33%	67%
Tempo total de processamento	30 min	15 min
Taxa de throughput	6 prog./hora	12 prog./hora

3.3 Interrupções e Exceções

Durante a execução de um programa podem ocorrer alguns eventos inesperados, ocasionando um desvio forçado no seu fluxo de execução. Estes tipos de eventos são conhecidos por *interrupção* ou *exceção* e podem ser conseqüência da sinalização de algum dispositivo de hardware externo ao processador ou da execução de instruções do próprio programa. A diferença entre interrupção e exceção é dada pelo tipo de evento ocorrido, porém alguns autores e fabricantes não fazem esta distinção.

A interrupção é o mecanismo que tornou possível a implementação da concorrência nos computadores, sendo o fundamento básico dos sistemas multiprogramáveis. É em função desse mecanismo que o sistema operacional sincroniza a execução de todas as suas rotinas e dos programas dos usuários, além de controlar dispositivos.

Uma interrupção é sempre gerada por algum evento externo ao programa e, nesse caso, independe da instrução que está sendo executada. Um exemplo de interrupção ocorre

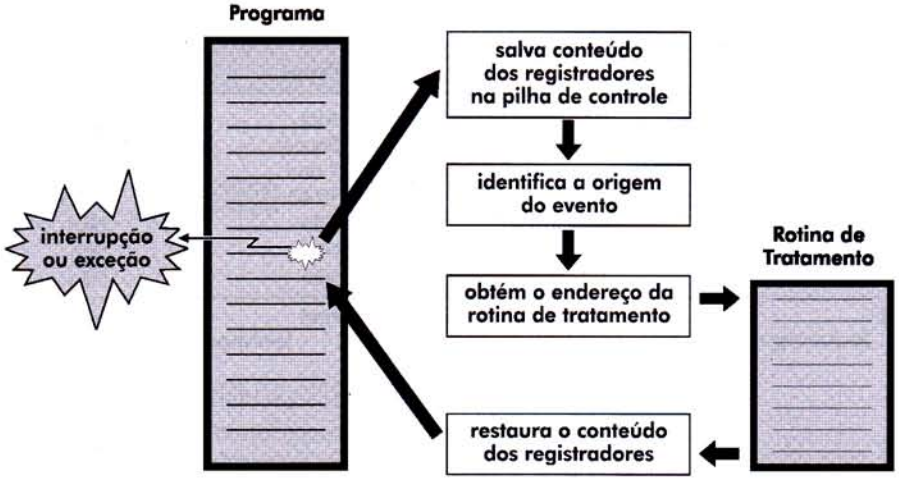

Fig. 3.2 Mecanismos de interrupção e exceção.

quando um dispositivo avisa ao processador que alguma operação de E/S está completa. Nesse caso, o processador deve interromper o programa para tratar o término da operação.

Ao final da execução de cada instrução, a unidade de controle verifica a ocorrência de algum tipo de interrupção. Nesse caso, o programa em execução é interrompido e o controle desviado para uma rotina responsável por tratar o evento ocorrido, denominada *rotina de tratamento de interrupção*. Para que o programa possa posteriormente voltar a ser executado é necessário que, no momento da interrupção, um conjunto de informações sobre a sua execução seja preservado. Essas informações consistem no conteúdo de registradores, que deverão ser restaurados para a continuação do programa (Fig. 3.2).

A Tabela 3.4 descreve como é o mecanismo de interrupção. Este mecanismo é realizado tanto por hardware quanto por software.

Tabela 3.4 Mecanismo de interrupção

Via hardware	1. Um sinal de interrupção é gerado para o processador;
	2. após o término da execução da instrução corrente, o processador identifica o pedido de interrupção;
	3. os conteúdos dos registradores PC e de status são salvos;
	4. o processador identifica qual a rotina de tratamento que será executada e carrega o PC com o endereço inicial desta rotina;
Via software	5. a rotina de tratamento salva o conteúdo dos demais registradores do processador na pilha de controle do programa;
	6. a rotina de tratamento é executada;
	7. após o término da execução da rotina de tratamento, os registradores de uso geral são restaurados, além do registrador de status e o PC, retornando à execução do programa interrompido.

Para cada tipo de interrupção existe uma rotina de tratamento associada, para a qual o fluxo de execução deve ser desviado. A identificação do tipo de evento ocorrido é fundamental para determinar o endereço da rotina de tratamento. No momento da ocorrência de uma interrupção, o processador deve saber para qual rotina de tratamento deve ser desviado o fluxo de execução.

Existem dois métodos para o tratamento de interrupções. O primeiro método utiliza uma estrutura de dados chamada *vetor de interrupção*, que contém o endereço inicial de todas as rotinas de tratamento existentes associadas a cada tipo de evento. Um segundo método utiliza um registrador de status que armazena o tipo do evento ocorrido. Neste método só existe uma única rotina de tratamento que, no seu início, testa o registrador para identificar o tipo de interrupção e tratá-la de maneira adequada.

As interrupções são decorrentes de eventos *assíncronos*, ou seja, não relacionados à instrução do programa corrente. Esses eventos, por serem imprevisíveis, podem ocorrer múltiplas vezes, como no caso de diversos dispositivos de E/S informarem ao processador que estão prontos para receber ou transmitir dados. Isso possibilita a ocorrência de múltiplas interrupções simultâneas. Uma maneira de evitar esta situação é a rotina de tratamento inibir as demais interrupções. Nesse caso, na ocorrência de outras interrupções durante a execução da rotina de tratamento elas serão ignoradas, ou seja, não receberão tratamento. Interrupções com esta característica são denominadas *interrupções mascaráveis.*

Alguns processadores não permitem que interrupções sejam desabilitadas, fazendo com que exista um tratamento para a ocorrência de múltiplas interrupções. Nesse caso, o processador necessita saber qual a ordem de atendimento que deverá seguir. Para isso, as interrupções deverão possuir prioridades, em função da importância no atendimento de cada uma. Normalmente, existe um dispositivo denominado *controlador de pedidos de interrupção*, responsável por avaliar as interrupções geradas e suas prioridades de atendimento.

Uma exceção é semelhante a uma interrupção, sendo a principal diferença o motivo pelo qual o evento é gerado. A exceção é resultado direto da execução de uma instrução do próprio programa, como a divisão de um número por zero ou a ocorrência de overflow em uma operação aritmética.

A diferença fundamental entre exceção e interrupção é que a primeira é gerada por um evento síncrono, enquanto a segunda é gerada por eventos assíncronos. Um evento é *síncrono* quando é resultado direto da execução do programa corrente. Tais eventos são previsíveis e, por definição, só podem ocorrer um de cada vez. Se um programa que causa esse tipo de evento for reexecutado com a mesma entrada de dados, a exceção ocorrerá sempre na mesma instrução.

Da mesma forma que na interrupção, sempre que uma exceção é gerada o programa em execução é interrompido e o controle é desviado para uma *rotina de tratamento de exceção* (Fig. 3.2). Para cada tipo de exceção existe uma rotina de tratamento adequada, para a qual o fluxo de execução deve ser desviado. O mecanismo de tratamento de exceções, muitas vezes, pode ser escrito pelo próprio programador. Desta forma, é possível evitar que um programa seja encerrado no caso de ocorrer, por exemplo, um overflow.

3.4 Operações de Entrada/Saída

Nos primeiros sistemas computacionais, a comunicação entre o processador e os periféricos era controlada por um conjunto de instruções especiais, denominadas *instru-*

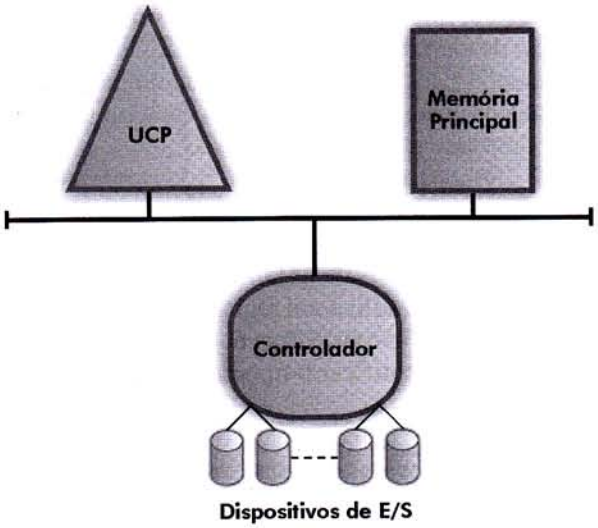

Fig. 3.3 Controlador.

ções de entrada/saída, executadas pelo próprio processador. Essas instruções continham detalhes específicos de cada periférico, como em qual trilha e setor de um disco deveria ser lido ou gravado um determinado bloco de dados. Esse modelo criava uma forte dependência entre o processador e os dispositivos de E/S.

O surgimento do *controlador* ou *interface* permitiu ao processador agir de maneira independente dos dispositivos de E/S. Com esse novo elemento, o processador não se comunicava mais diretamente com os periféricos, mas sim através do controlador (Fig. 3.3). Isso simplificou as instruções de E/S por não ser mais necessário especificar detalhes de operação dos periféricos, tarefa esta realizada pelo controlador.

Com a utilização do controlador, existiam duas maneiras básicas pelas quais o processador gerenciava as operações de E/S. Na primeira, o processador sincronizava-se com o periférico para o início da transferência de dados e, após iniciada a transferência, o sistema ficava permanentemente testando o estado do periférico para saber quando a operação chegaria ao seu final. Este controle, chamado *E/S controlada por programa*, mantinha o processador ocupado até o término da operação de E/S (busy wait). Como o processador executa uma instrução muito mais rapidamente que a realização de uma operação de E/S pelo controlador, havia um enorme desperdício de tempo da UCP.

A evolução do modelo anterior foi permitir que, após o início da transferência dos dados, o processador permanecesse livre para realizar outras tarefas. Assim, em determinados intervalos de tempo o sistema operacional deveria testar cada dispositivo para saber do término da operação de E/S (*polling*). Esse tipo de operação introduziu certo grau de paralelismo, visto que um programa poderia ser processado enquanto outro esperava pelo término de uma operação de E/S (Guimarães, 1980). Isso permitiu o surgimento dos primeiros sistemas multiprogramáveis, onde vários programas poderiam ser executados concorrentemente, já que o tempo de uma operação de E/S é relativamente grande. O problema dessa implementação é que, no caso de existir um grande número de periféricos, o processamento é interrompido freqüentemente para testar os diversos periféricos, já que é difícil determinar o momento exato do término das operações de E/S em andamento.

Com a implementação do mecanismo de interrupção, as operações de E/S puderam ser realizadas de uma forma mais eficiente. Em vez de o sistema periodicamente verificar o estado de uma operação pendente, o próprio controlador interrompia o processador para avisar do término da operação. Com esse mecanismo, denominado *E/S controlada por interrupção*, o processador, após a execução de um comando de leitura ou gravação, permanece livre para o processamento de outras tarefas. O controlador por sua vez, ao receber, por exemplo, um sinal de leitura, fica encarregado de ler os blocos do disco e armazená-los em memória ou registradores próprios. Em seguida, o controlador sinaliza uma interrupção ao processador. Quando o processador atende à interrupção, a rotina responsável pelo tratamento transfere os dados dos registradores do controlador para a memória principal. Ao término da transferência, o processador pode voltar a executar o programa interrompido e o controlador fica novamente disponível para outra operação.

A operação de E/S controlada por interrupção é muito mais eficiente que a controlada por programa, já que elimina a necessidade de o processador esperar pelo término da operação, além de permitir que várias operações de E/S sejam executadas simultaneamente. Apesar disso, a transferência de grande volume de dados exige muitas intervenções do processador, reduzindo sua eficiência. A solução para esse problema foi a implementação de uma técnica de transferência de dados denominada DMA (Direct Memory Access).

A *técnica de DMA* permite que um bloco de dados seja transferido entre a memória principal e dispositivos de E/S sem a intervenção do processador, exceto no início e no final da transferência. Quando o sistema deseja ler ou gravar um bloco de dados, o processador informa ao controlador sua localização, o dispositivo de E/S, a posição inicial da memória de onde os dados serão lidos ou gravados e o tamanho do bloco. Com estas informações, o controlador realiza a transferência entre o periférico e a memória principal, e o processador é somente interrompido no final da operação. A área de memória utilizada pelo controlador na técnica de DMA é chamada de *buffer de entrada e saída*.

No momento em que uma transferência de dados através da técnica de DMA é realizada, o controlador deve assumir, momentaneamente, o controle do barramento. Como a utilização do barramento é exclusiva de um dispositivo, o processador deve suspender o acesso ao bus, temporariamente, durante a operação de transferência. Este procedimento não gera uma interrupção, e o processador pode realizar tarefas, desde que sem a utilização do barramento, como um acesso à memória cache.

A extensão do conceito do DMA possibilitou o surgimento do *canal de entrada e saída* introduzido pela IBM no Sistema 7094. O canal é um processador com capacidade de executar programas de E/S, permitindo o controle total sobre operações de E/S. As instruções de E/S são armazenadas na memória principal pelo processador, porém o canal é responsável pela sua execução. Assim, o processador realiza uma operação de E/S, instruindo o canal para executar um programa localizado na memória (programa de canal). Este programa especifica os dispositivos para transferência, buffers e ações a serem tomadas em caso de erros. O canal de E/S realiza a transferência e, ao final, gera uma interrupção, avisando do término da operação. Um canal de E/S pode controlar múltiplos dispositivos através de diversos controladores (Fig. 3.4). Cada dispositivo, ou conjunto de dispositivos, é manipulado por um único controlador. O canal atua como um elo entre o processador principal e o controlador.

A evolução do canal permitiu que este possuísse sua própria memória, eliminando a necessidade de os programas de E/S serem carregados para a memória principal. Com

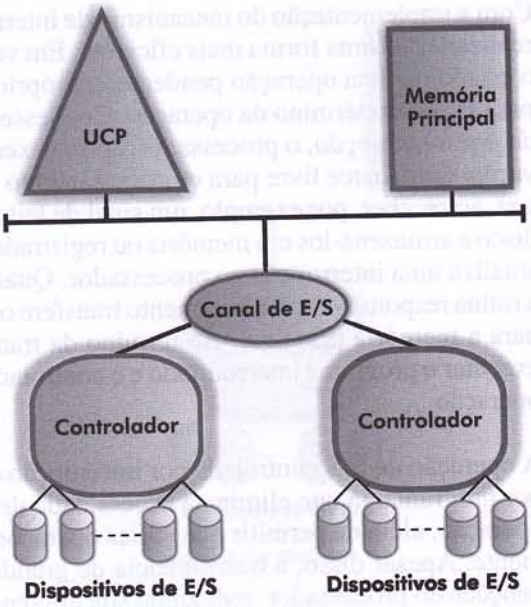

Fig. 3.4 Canal de E/S.

essa nova arquitetura, várias funções de E/S puderam ser controladas com mínima intervenção da UCP. Este último estágio do canal é também denominado *processador de entrada e saída*, embora seja comum encontrarmos os dois termos empregados indistintamente (Stallings, 1997).

3.5 Buffering

A técnica de *buffering* consiste na utilização de uma área na memória principal, denominada buffer, para a transferência de dados entre os dispositivos de E/S e a memória. Esta técnica permite que em uma operação de leitura o dado seja transferido primeiramente para o buffer, liberando imediatamente o dispositivo de entrada para realizar uma nova leitura. Nesse caso, enquanto o processador manipula o dado localizado no buffer, o dispositivo realiza outra operação de leitura no mesmo instante. Este mesmo mecanismo pode ser aplicado nas operações de gravação (Fig. 3.5).

O buffering permite minimizar o problema da disparidade da velocidade de processamento existente entre o processador e os dispositivos de E/S. O objetivo principal

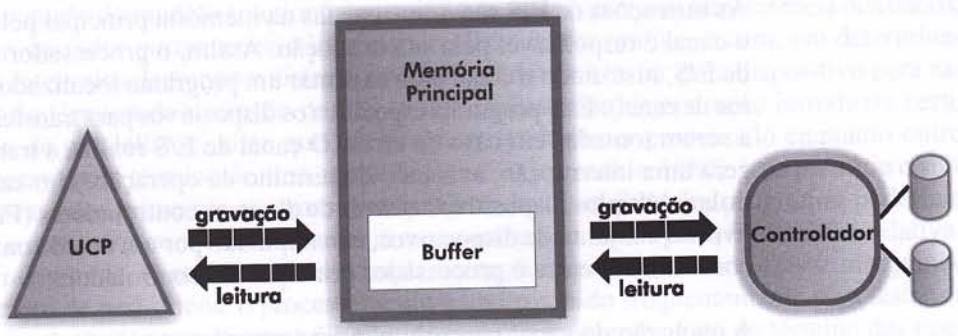

Fig. 3.5 Operações de E/S utilizando buffer.

desta técnica é manter, na maior parte do tempo, processador e dispositivos de E/S ocupados.

A unidade de transferência usada no mecanismo de buffering é o *registro*. O tamanho do registro pode ser especificado em função da natureza do dispositivo, como uma linha gerada por uma impressora ou um caractere de um teclado, ou da aplicação, como um registro lógico definido em um arquivo.

O buffer deve permitir armazenar diversos registros, de forma que existam dados lidos, mas ainda não processados (operação de leitura), ou processados, mas ainda não gravados (operação de gravação). Desta forma, o dispositivo de entrada poderá ler diversos registros antes que o processador manipule os dados, ou o processador poderá manipular diversos registros antes de o dispositivo de saída realizar a gravação. Isso é extremamente eficiente, pois, dessa maneira, é possível compatibilizar a diferença existente entre o tempo em que o processador executa instruções e o tempo em que o dispositivo de E/S realiza as operações de leitura e gravação.

3.6 Spooling

A técnica de *spooling* (simultaneous peripheral operation on-line) foi introduzida no final dos anos 1950 para aumentar o grau de concorrência e a eficiência dos sistemas operacionais. Naquela época, os programas dos usuários eram submetidos um a um ao processamento pelo operador. Como a velocidade de operação dos dispositivos de E/S é muito menor que a do processador, era comum que a UCP permanecesse ociosa à espera de programas e dados de entrada ou pelo término de uma impressão.

A solução foi armazenar os vários programas e seus dados, também chamados de *jobs*, em uma fita magnética e, em seguida, submetê-los a processamento. Dessa forma, o processador poderia executar seqüencialmente cada job, diminuindo o tempo de processamento e transição entre eles. Da mesma forma, em vez de um job gravar suas saídas diretamente na impressora, poderia direcioná-las para uma outra fita, que depois seria impressa integralmente. Esta forma de processamento é chamada de *spooling*, e foi a base dos sistemas batch.

A utilização de fitas magnéticas obrigava o processamento a ser estritamente seqüencial, ou seja, o primeiro job a ser gravado na fita era o primeiro a ser processado. Assim, se um job que levasse várias horas antecedesse pequenos jobs, seus tempos de resposta ficariam seriamente comprometidos. Com o surgimento de dispositivos de acesso direto, como discos, foi possível tornar o spooling mais eficiente e, principalmente, possibilitar o processamento não seqüencial dos jobs.

A técnica de spooling, semelhante à técnica de buffering já apresentada, utiliza uma área em disco como se fosse um grande buffer. Neste caso, dados podem ser lidos ou gravados em disco, enquanto programas são executados concorrentemente.

Atualmente essa técnica está presente na maioria dos sistemas operacionais, sendo utilizada no gerenciamento de impressão. No momento em que um comando de impressão é executado, as informações que serão impressas são gravadas antes em um arquivo em disco, conhecido como *arquivo de spool*, liberando imediatamente o programa para outras atividades. Posteriormente, o sistema operacional encarrega-se de direcionar o conteúdo do arquivo de spool para a impressora (Fig. 3.6).

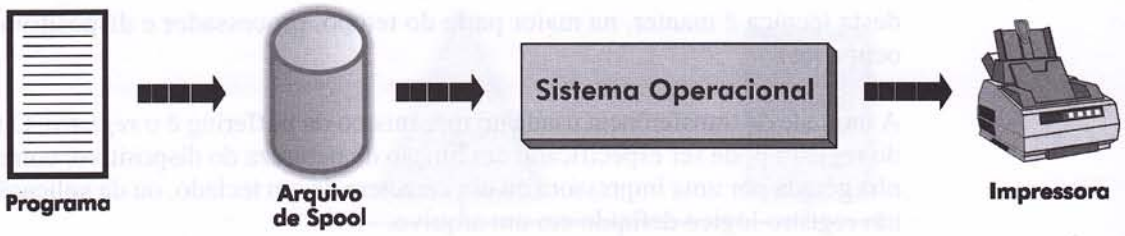

Fig. 3.6 Técnica de spooling.

O uso do spooling permite desvincular o programa do dispositivo de impressão, impedindo que um programa reserve a impressora para uso exclusivo. O sistema operacional é o responsável por gerenciar a seqüência de impressões solicitadas pelos programas, seguindo critérios que garantam a segurança e o uso eficiente das impressoras.

3.7 Reentrância

É comum, em sistemas multiprogramáveis, vários usuários utilizarem os mesmos aplicativos simultaneamente, como editores de textos e compiladores. Se cada usuário que utilizasse um desses aplicativos trouxesse o código executável para a memória, haveria diversas cópias de um mesmo programa na memória principal, o que ocasionaria um desperdício de espaço.

Reentrância é a capacidade de um código executável (*código reentrante*) ser compartilhado por diversos usuários, exigindo que apenas uma cópia do programa esteja na memória. A reentrância permite que cada usuário possa estar em um ponto diferente do código reentrante, manipulando dados próprios, exclusivos de cada usuário (Fig. 3.7).

Os utilitários do sistema, como editores de texto, compiladores e linkers, são exemplos de código reentrante que proporcionam uma utilização mais eficiente da memória

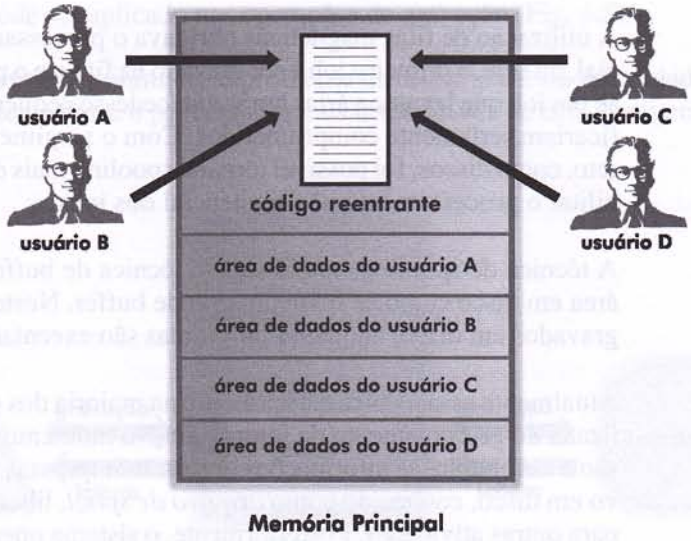

Fig. 3.7 Reentrância.

principal e aumento no desempenho do sistema. Em alguns sistemas operacionais existe a possibilidade de implementar o conceito de reentrância em aplicativos desenvolvidos pelos próprios usuários.

3.8 Exercícios

1. O que é concorrência e como este conceito está presente nos sistemas operacionais multiprogramáveis?
2. Por que o mecanismo de interrupção é fundamental para a implementação da multiprogramação?
3. Explique o mecanismo de funcionamento das interrupções.
4. O que são eventos síncronos e assíncronos? Como estes eventos estão relacionados ao mecanismo de interrupção e exceção?
5. Dê exemplos de eventos associados ao mecanismo de exceção.
6. Qual a vantagem da E/S controlada por interrupção comparada com a técnica de spooling?
7. O que é DMA e qual a vantagem desta técnica?
8. Como a técnica de buffering permite aumentar a concorrência em um sistema computacional?
9. Explique o mecanismo de spooling de impressão.
10. Em um sistema multiprogramável, seus usuários utilizam o mesmo editor de textos (200 Kb), compilador (300 Kb), software de correio eletrônico (200 Kb) e uma aplicação corporativa (500 Kb). Caso o sistema não implemente reentrância, qual o espaço de memória principal ocupado pelos programas quando 10 usuários estiverem utilizando todas as aplicações simultaneamente? Qual o espaço liberado quando o sistema implementa reentrância em todas as aplicações?

4

ESTRUTURA DO SISTEMA OPERACIONAL

4.1 Introdução

O sistema operacional é formado por um conjunto de rotinas que oferece serviços aos usuários e às suas aplicações. Esse conjunto de rotinas é denominado *núcleo do sistema*, ou *kernel*. A maioria dos sistemas operacionais é fornecida acompanhada de utilitários e linguagem de comandos, que são ferramentas de apoio ao usuário, porém não são parte do núcleo do sistema. Na Fig. 4.1 é apresentado um modelo de camadas detalhando a estrutura do sistema operacional e suas interfaces.

Há três maneiras distintas de os usuários se comunicarem com o kernel do sistema operacional. Uma delas é por intermédio das chamadas rotinas do sistema realizadas por aplicações. Além disso, os usuários podem interagir com o núcleo mais amigavelmente por meio de utilitários ou linguagem de comandos. Cada sistema operacional oferece seus próprios utilitários, como compiladores e editores de texto. A linguagem de comandos também é particular de cada sistema, com estruturas e sintaxe próprias.

A estrutura do núcleo, ou seja, a maneira como o código do sistema é organizado e o inter-relacionamento entre seus diversos componentes, pode variar conforme a concepção do projeto. Existem diversas abordagens em relação à estrutura de sistemas operacionais que serão apresentadas na parte final deste capítulo.

Inicialmente serão apresentadas as funções do núcleo e os conceitos relativos à segurança, proteção do sistema, modos de acesso, rotinas do sistema, system calls, linguagem de comandos e ativação/desativação do sistema.

4.2 Funções do Núcleo

A compreensão da estrutura e do funcionamento de um sistema operacional não é simples. Diferentemente de uma aplicação convencional, com seqüenciamento de início, meio e fim, as rotinas do sistema são executadas concorrentemente sem uma ordem predefinida, com base em eventos dissociados do tempo (eventos assíncronos). Mui-

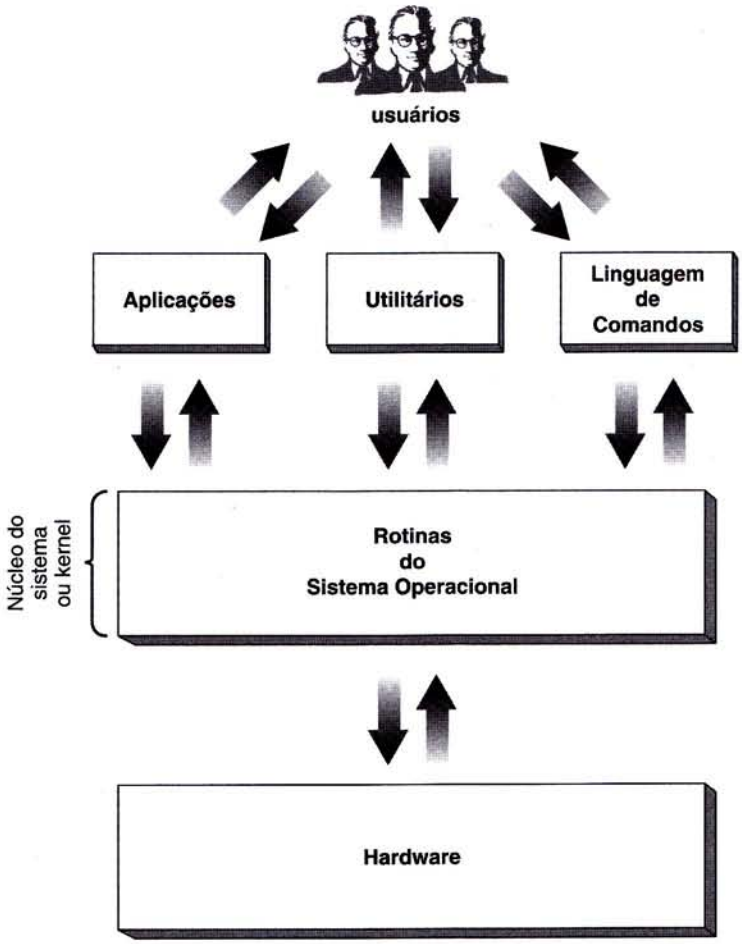

Fig. 4.1 Estrutura do sistema operacional.

tos desses eventos estão relacionados ao hardware e a tarefas internas do próprio sistema operacional.

As principais funções do núcleo encontradas nos sistemas operacionais estão listadas a seguir e, no decorrer do livro, serão abordadas com detalhes:

- tratamento de interrupções e exceções;
- criação e eliminação de processos e threads;
- sincronização e comunicação entre processos e threads;
- escalonamento e controle dos processos e threads;
- gerência de memória;
- gerência do sistema de arquivos;
- gerência de dispositivos de E/S;
- suporte a redes locais e distribuídas;
- contabilização do uso do sistema;
- *auditoria e segurança do sistema.*

Como decorrência da complexidade da arquitetura de um sistema multiprogramável, é natural que surjam problemas relativos à segurança no inter-relacionamento dos diversos subsistemas existentes. Como exemplo, podemos considerar a situação em que diversos usuários compartilham os mesmos recursos, como memória, processador e

dispositivos de E/S. Esta situação exige que o sistema operacional garanta a confiabilidade na execução concorrente de todos os programas e nos dados dos usuários, além da garantia da integridade do próprio sistema operacional.

Uma das principais características da multiprogramação é permitir que vários programas compartilhem o processador. O sistema operacional deve ser responsável pelo controle da utilização da UCP, de forma a impedir que algum programa monopolize o seu uso inadequadamente.

Como vários programas ocupam a memória simultaneamente, cada usuário deve possuir uma área reservada onde seus dados e código são armazenados. O sistema operacional implementa mecanismos de proteção, de forma a preservar estas informações de maneira reservada. Caso um programa tente acessar uma posição de memória fora de sua área ocorrerá um erro indicando a violação de acesso. Para que diferentes programas tenham o direito de compartilhar uma mesma área de memória, o sistema operacional deve oferecer mecanismos para que a comunicação seja feita de forma sincronizada e controlada, evitando, desta forma, problemas de inconsistência.

De modo semelhante ao compartilhamento de memória, um disco pode armazenar arquivos de diferentes usuários. Mais uma vez o sistema operacional deve garantir a integridade e a confidencialidade dos dados, permitindo ainda que dois ou mais usuários possam ter acesso simultâneo ao mesmo arquivo.

Para solucionar esses diversos problemas originados pelo ambiente multiprogramável, o sistema operacional deve implementar mecanismos de proteção que controlem o acesso concorrente aos diversos recursos do sistema.

4.3 Modo de Acesso

Uma preocupação que surge nos projetos de sistemas operacionais é a implementação de mecanismos de proteção ao núcleo do sistema e de acesso aos seus serviços. Caso uma aplicação, que tenha acesso ao núcleo, realize uma operação que altere sua integridade, todo o sistema poderá ficar comprometido e inoperante. Muitas das principais implementações de segurança de um sistema operacional utilizam um mecanismo presente no hardware dos processadores, conhecido como *modo de acesso*.

Em geral, os processadores possuem dois modos de acesso: *modo usuário* e *modo kernel*. Quando o processador trabalha no modo usuário, uma aplicação só pode executar instruções conhecidas como não-privilegiadas, tendo acesso a um número reduzido de instruções, enquanto no modo kernel a aplicação pode ter acesso ao conjunto total de instruções do processador. O modo de acesso é determinado por um conjunto de bits, localizado no registrador de status do processador, que indica o modo de acesso corrente. Por intermédio desse registrador, o hardware verifica se a instrução pode ou não ser executada.

As *instruções privilegiadas* não devem ser utilizadas de maneira indiscriminada pelas aplicações, pois isso poderia ocasionar sérios problemas à integridade do sistema. Suponha que uma aplicação atualize um arquivo em disco. O programa, por si só, não deve especificar diretamente as instruções que acessam seus dados no disco. Como o disco é um recurso compartilhado, sua utilização deverá ser gerenciada unicamente pelo sistema operacional, evitando que a aplicação possa ter acesso a qualquer área do disco sem autorização, o que poderia comprometer a segurança e a integridade do sistema de arquivos. Como visto, fica claro que existem certas instruções que só devem ser executadas pelo sistema operacional ou sob sua supervisão, impedindo, assim, a ocor-

rência de problemas de segurança e integridade do sistema. As instruções privilegiadas só podem ser executadas quando o modo de acesso do processador encontra-se em kernel, caso contrário o hardware irá impedir a execução da instrução. As *instruções não-privilegiadas* são as que não oferecem risco ao sistema e podem ser executadas em modo não-privilegiado, ou seja, modo usuário.

Um outro exemplo do uso dos modos de acessos é a proteção do próprio núcleo do sistema residente na memória principal. Caso uma aplicação tenha acesso a áreas de memória onde está carregado o sistema operacional, um programador mal-intencionado ou um erro de programação poderia gravar nesta área, violando o sistema. Com o mecanismo de modo de acesso, para uma aplicação escrever numa área onde resida o sistema operacional o programa deve estar sendo executado no modo kernel.

4.4 Rotinas do Sistema Operacional e System Calls

As *rotinas do sistema operacional* compõem o núcleo do sistema, oferecendo serviços aos usuários e suas aplicações. Todas as funções do núcleo são implementadas por rotinas do sistema que necessariamente possuem em seu código instruções privilegiadas. A partir desta condição, para que estas rotinas possam ser executadas o processador deve estar obrigatoriamente em modo kernel, o que exige a implementação de mecanismos de proteção para garantir a confiabilidade do sistema.

Todo o controle de execução de rotinas do sistema operacional é realizado pelo mecanismo conhecido como *system call*. Toda vez que uma aplicação desejar chamar uma rotina do sistema operacional, o mecanismo de system call é ativado. Inicialmente, o sistema operacional verificará se a aplicação possui privilégios necessários para executar a rotina desejada. Em caso negativo, o sistema operacional impedirá o desvio para a rotina do sistema, sinalizando ao programa chamador que a operação não é possível. Este é um *mecanismo de proteção por software*, no qual o sistema operacional garante que as aplicações só poderão executar rotinas do sistema que estão previamente autorizadas. Esta autorização prévia é realizada pelo administrador do sistema, e será vista com mais detalhes no Cap. 5 — Processo.

Considerando que a aplicação possua o devido privilégio para chamar a rotina do sistema desejada, o sistema operacional primeiramente salva o conteúdo corrente dos registradores, troca o modo de acesso do processador de usuário para kernel e realiza o desvio para a rotina alterando o registrador PC com o endereço da rotina chamada (Fig. 4.2). Ao término da execução da rotina do sistema, o modo de acesso é alterado de kernel para usuário e o contexto dos registradores restaurados para que a aplicação continue a execução a partir da instrução que chamou a rotina do sistema.

Uma aplicação sempre deve executar com o processador em modo usuário. Caso uma aplicação tente executar diretamente uma instrução privilegiada sem ser por intermédio de uma chamada à rotina do sistema, um *mecanismo de proteção por hardware* garantirá a segurança do sistema, impedindo a operação. Nesta situação, em que a aplicação tenta executar uma instrução privilegiada em modo usuário e sem a supervisão do sistema operacional, o próprio hardware do processador sinalizará um erro. Uma exceção é gerada e a execução do programa é interrompida, protegendo desta forma o núcleo do sistema.

Utilizando o mesmo problema apresentado anteriormente do acesso ao disco, para o programa atualizar um arquivo, a aplicação deve solicitar a operação de E/S ao sistema operacional por meio de uma chamada a uma rotina do sistema. O mecanismo de

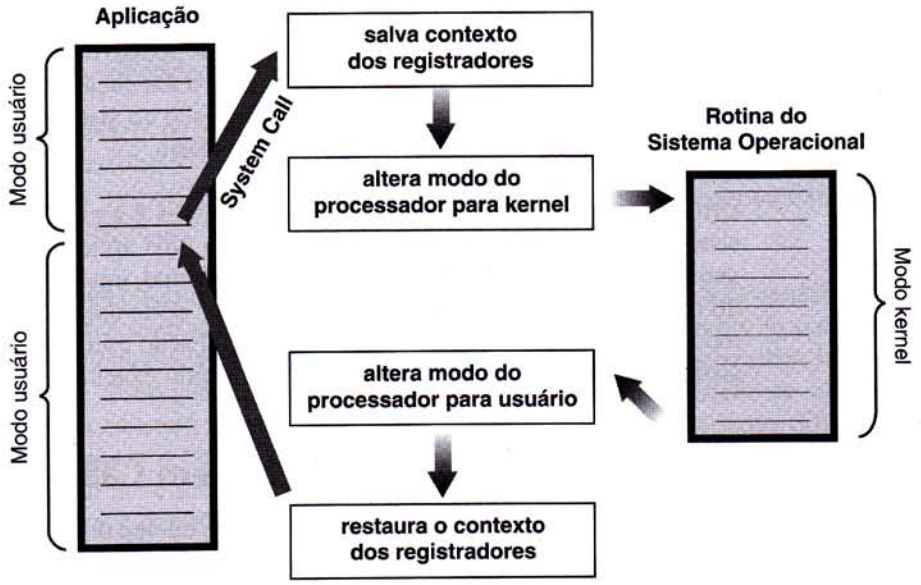

Fig. 4.2 Chamada a uma rotina do sistema (a).

system call verificará se a aplicação possui privilégio para a operação e, em caso afirmativo, irá alterar o modo de acesso do processador de usuário para kernel. Após executar a rotina de leitura, o modo de acesso volta ao estado usuário para continuar a execução do programa.

Os mecanismos de system call e de proteção por hardware garantem a segurança e a integridade do sistema. Com isso, as aplicações estão impedidas de excutarem instruções privilegiadas sem a autorização e a supervisão do sistema operacional.

4.5 Chamada a Rotinas do Sistema Operacional

As rotinas do sistema e o mecanismo de system call podem ser entendidos como uma porta de entrada para o núcleo do sistema operacional e a seus serviços. Sempre que uma aplicação desejar algum serviço do sistema, deve ser realizada uma chamada a uma de suas rotinas através de uma system call (Fig. 4.3). Por intermédio dos parâmetros fornecidos na system call, a solicitação é processada e uma resposta é retornada à aplicação juntamente com um estado de conclusão indicando se houve algum erro. O mecanismo de ativação e comunicação entre o programa e o sistema operacional é semelhante ao mecanismo implementado quando um programa chama uma sub-rotina.

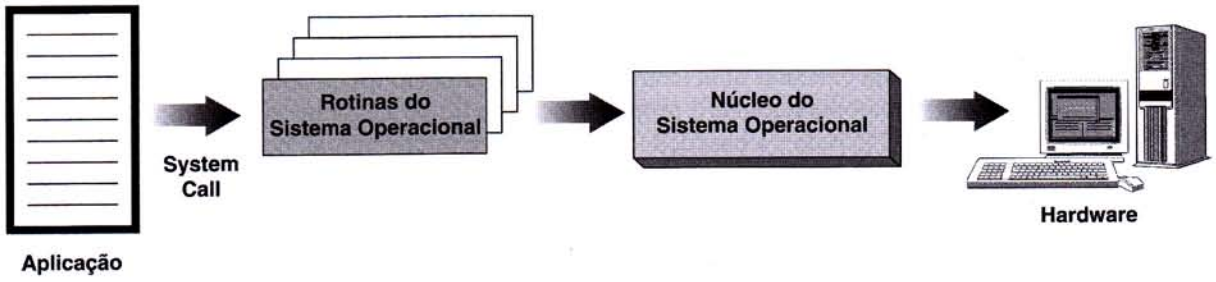

Fig. 4.3 Chamada a uma rotina do sistema (b).

O termo system call é tipicamente utilizado em sistemas Unix, porém em outros sistemas o mesmo conceito é apresentado com diferentes nomes, como system services, no OpenVMS, e Application Program Interface (API), no MS Windows. No exemplo a seguir, desenvolvido em Delphi, é utilizada a API `GetSystemTime` para obter a data e a hora do sistema MS Windows. A função `SystemTimeToDateTime` converte a data e a hora para o formato `DataHoraT` do Delphi e, em seguida, para o formato texto utilizando a função `DateTimeToStr`. A última linha exibe a data e a hora do sistema em uma janela previamente criada.

```
GetSystemTime(SystemTime);
DataHoraT := SystemTimeToDateTime(SystemTime);
DataHoraS := DateTimeToStr(DataHoraT);
RichEdit1.Lines.Add(DataHoraS);
```

A maioria dos programadores e usuários desconhece os detalhes envolvidos, por exemplo, em um simples comando de leitura a um arquivo utilizando uma linguagem de alto nível. De forma simplificada, o comando da linguagem de alto nível é convertido pelo compilador para uma chamada a uma rotina específica que, quando executada, verifica a ocorrência de erros e retorna os dados ao programa de forma transparente ao usuário. As rotinas do sistema podem ser divididas por grupos de função (Tabela 4.1).

Tabela 4.1 Funções das system calls

Funções	System calls
Gerência de processos e threads	Criação e eliminação de processos e threads Alteração das características de processos e threads Sincronização e comunicação entre processos e threads Obtenção de informações sobre processos e threads
Gerência de memória	Alocação e desalocação de memória
Gerência do sistema de arquivos	Criação e eliminação de arquivos e diretórios Alteração das características de arquivos e diretórios Abrir e fechar arquivos Leitura e gravação em arquivos Obtenção de informações sobre arquivos e diretórios
Gerência de dispositivos	Alocação e desalocação de dispositivos Operações de entrada/saída em dispositivos Obtenção de informações sobre dispositivos

Cada sistema operacional possui seu próprio conjunto de rotinas, com nomes, parâmetros e formas de ativação específicos. Conseqüentemente, uma aplicação desenvolvida utilizando serviços de um determinado sistema operacional não pode ser portada diretamente para um outro sistema, exigindo algumas correções no código-fonte. Uma tentativa de criar uma biblioteca de chamadas objetivando uma padronização foi elaborada pelos institutos ISO e IEEE, resultando um conjunto conhecido como POSIX (Portable Operating System Interface for Unix). Inicialmente voltado para a unificação das várias versões do sistema operacional Unix, o POSIX estabeleceu uma biblioteca-padrão, permitindo que uma aplicação desenvolvida seguindo este conjunto de chamadas possa ser portada para os demais sistemas. A maioria dos sistemas operacionais modernos oferece algum suporte ao padrão POSIX como o MS Windows, IBM-AIX, HP-UX e o SUN-Solaris.

4.6 Linguagem de Comandos

A *linguagem de comandos*, ou *linguagem de controle*, permite que o usuário se comunique de uma forma simples com o sistema operacional, capacitando-o a executar diversas tarefas específicas do sistema como criar, ler ou eliminar arquivos, consultar diretórios ou verificar a data e a hora armazenadas no sistema. Dessa forma, o usuário dispõe de uma interface direta com o sistema operacional. A Tabela 4.2 apresenta exemplos de comandos disponíveis no sistema Microsoft Windows. Cada sistema operacional possui a sua linguagem de comandos como, por exemplo, a DCL (Digital Command Language) utilizada no OpenVMS, JCL (Job Control Language) no MVS da IBM e os comandos do shell disponíveis nos diversos sistemas Unix.

Tabela 4.2 Exemplos de Comandos do MS Windows

Comando	Descrição
dir	Lista o conteúdo de um diretório
cd	Altera o diretório default
type	Exibe o conteúdo de um arquivo
del	Elimina arquivos
mkdir	Cria um diretório
ver	Mostra a versão do Windows

Cada comando, depois de digitado pelo usuário, é interpretado pelo *shell* ou *interpretador de comandos*, que verifica a sintaxe do comando, faz chamadas a rotinas do sistema e apresenta um resultado ou uma mensagem informativa (Fig. 4.4a). Em geral, o interpretador de comandos não faz parte do núcleo do sistema operacional, possibilitando maior flexibilidade na criação de diferentes linguagens de controle para um mesmo sistema. Por exemplo, o Unix oferece, basicamente, três interpretadores de comandos: Bourne Shell, C Shell e Korn Shell.

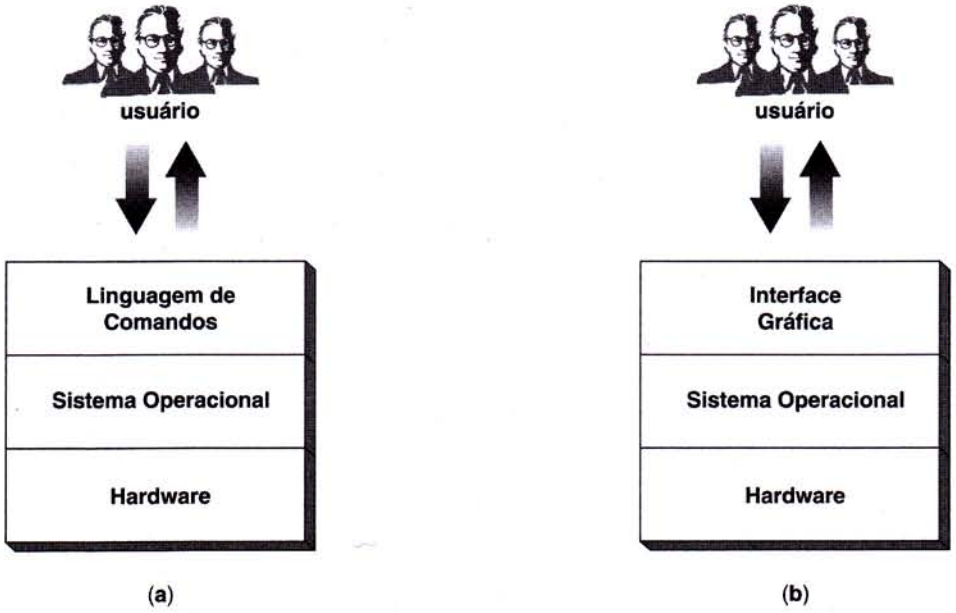

Fig. 4.4 Interface do usuário com o sistema operacional.

Na maioria dos sistemas operacionais, as linguagens de comandos evoluíram no sentido de permitir a interação mais amigável com os usuários, utilizando interfaces gráficas como janelas e ícones, a exemplo dos sistemas MS Windows. Na maioria dos casos, a interface gráfica é apenas mais um nível de abstração entre o usuário e os serviços do sistema operacional (Fig. 4.4b).

As linguagens de comandos são poderosas a ponto de oferecer a possibilidade de criar programas com estruturas de decisão e iteração. Esses programas nada mais são do que uma seqüência de comandos armazenados em um arquivo texto, denominados *arquivos de comandos*, *arquivos batch* ou *shell scripts*, que podem ser executados sempre que necessário. Uma das principais vantagens no uso de arquivos de comandos é possibilitar a automatização de diversas tarefas ligadas à gerência do sistema.

4.7 Ativação/Desativação do Sistema

Inicialmente, quando um computador é ligado não há sistema operacional carregado na memória da máquina. Em geral, o sistema operacional reside em um disco rígido, podendo também estar armazenado em outros dispositivos de memória secundária, como CD ou DVD. Os componentes do sistema operacional devem ser carregados para a memória principal toda vez que o computador é ligado por intermédio de um procedimento denominado *ativação do sistema* ou *boot*.

O procedimento de ativação se inicia com a execução de um programa chamado *boot loader*, que se localiza em um endereço fixo de uma memória ROM da máquina. Este programa chama a execução de outro programa conhecido como POST (Power-On Self Test), que identifica possíveis problemas de hardware no equipamento. Após esta fase, o procedimento de ativação verifica se há no sistema computacional algum dispositivo de armazenamento onde há um sistema operacional residente. Caso nenhum dispositivo seja encontrado, uma mensagem de erro é apresentada e o procedimento de ativação é interrompido. Se um dispositivo com o sistema operacional é encontrado, um conjunto de instruções é carregado para memória e localizado em um bloco específico do dispositivo conhecido como *setor de boot* (*boot sector*). A partir da execução deste código, o sistema operacional é finalmente carregado para a memória principal. Além da carga, a ativação do sistema também consiste na execução de arquivos de inicialização onde são especificados procedimentos de customização e configuração de hardware e software específicos para cada ambiente (Fig. 4.5).

Na maioria dos sistemas também existe o processo de *desativação* ou *shutdown*. Este procedimento permite que as aplicações e componentes do sistema operacional sejam desativados ordenadamente, garantindo, desta forma, sua integridade.

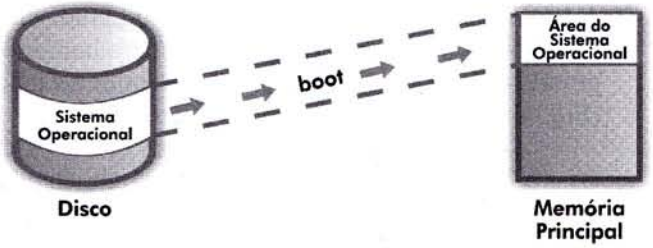

Fig. 4.5 Ativação do sistema.

4.8 Arquiteturas do Núcleo

O projeto de um sistema operacional é bastante complexo e deve atender a diversos requisitos, algumas vezes conflitantes, como confiabilidade, portabilidade, fácil manutenção, flexibilidade e *desempenho. O projeto do sistema irá depender muito da arquitetura do hardware a ser utilizado e do tipo de sistema que se deseja construir: batch, tempo compartilhado, monousuário ou multiusuário, tempo real etc.

Os primeiros sistemas operacionais foram desenvolvidos integralmente em assembly, e o código possuía cerca de um milhão de instruções (IBM OS/360). Com a evolução dos sistemas e o aumento do número de linhas de código para algo perto de 20 milhões (MULTICS), técnicas de programação modular foram incorporadas ao projeto, além de linguagens de alto nível, como PL/I e Algol. Nos sistemas operacionais atuais, o número de linhas de código pode chegar a mais de 40 milhões (Windows 2000), sendo que grande parte do código é escrita em Linguagem C/C++.

Além de facilitar o desenvolvimento e a manutenção do sistema, a utilização de linguagens de alto nível permite uma maior portabilidade, ou seja, que o sistema operacional seja facilmente alterado em outra arquitetura de hardware. Uma desvantagem do uso de linguagens de alto nível em relação à programação assembly é a perda de desempenho. Por isso, as partes críticas do sistema, como os device drivers, o escalonador e as rotinas de tratamento de interrupções, são desenvolvidas em assembly.

Uma tendência no projeto de sistemas operacionais modernos é a utilização de técnicas de orientação por objetos, o que leva para o projeto do núcleo do sistema todas as vantagens deste modelo de desenvolvimento de software. Existe uma série de vantagens na utilização de programação por objetos no projeto e na implementação de sistemas operacionais. A seguir, os principais benefícios são apresentados:

- melhoria na organização das funções e recursos do sistema;
- redução no tempo de desenvolvimento;
- maior facilidade na manutenção e extensão do sistema;
- facilidade de implementação do modelo de computação distribuída.

A estrutura do núcleo do sistema operacional, ou seja, a maneira como o código do sistema é organizado e o inter-relacionamento entre seus diversos componentes, pode variar conforme a concepção do projeto. A seguir serão abordadas as principais arquiteturas dos sistemas operacionais: arquitetura monolítica, arquitetura de camadas, máquina virtual e arquitetura microkernel.

4.8.1 Arquitetura Monolítica

A *arquitetura monolítica* pode ser comparada com uma aplicação formada por vários módulos que são compilados separadamente e depois linkados, formando um grande e único programa executável, onde os módulos podem interagir livremente (Fig. 4.6).

Os primeiros sistemas operacionais foram desenvolvidos com base neste modelo, o que tornava seu desenvolvimento e, principalmente, sua manutenção bastante difíceis. Devido a sua simplicidade e bom desempenho, a estrutura monolítica foi adotada no projeto do MS-DOS e nos primeiros sistemas Unix.

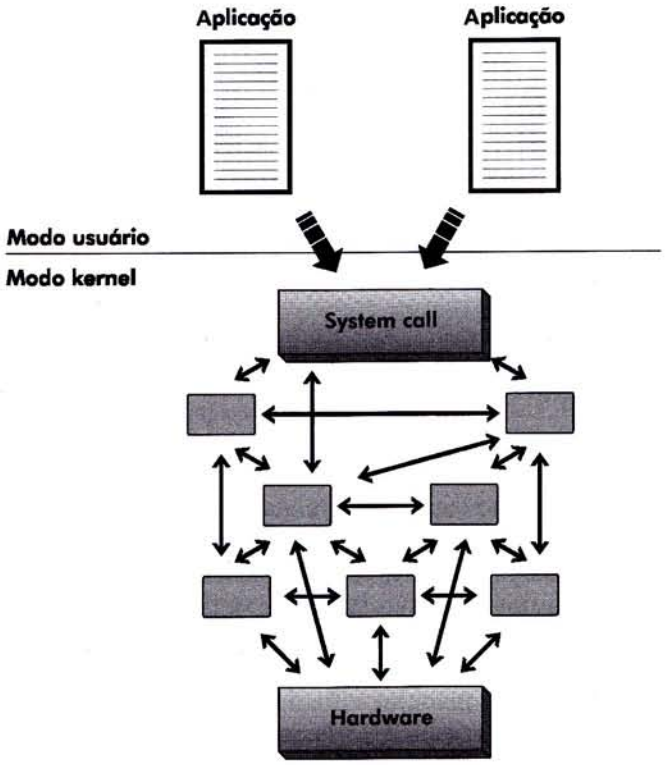

Fig. 4.6 Arquitetura monolítica.

4.8.2 Arquitetura de Camadas

Com o aumento da complexidade e do tamanho do código dos sistemas operacionais, técnicas de programação estruturada e modular foram incorporadas ao seu projeto. Na *arquitetura de camadas*, o sistema é dividido em níveis sobrepostos. Cada camada oferece um conjunto de funções que podem ser utilizadas apenas pelas camadas superiores.

O primeiro sistema com base nesta abordagem foi o sistema THE (Technische Hogeschool Eindhoven), construído por Dijkstra na Holanda em 1968 e que utilizava seis camadas. Posteriormente, os sistemas MULTICS e OpenVMS também implementaram o conceito de camadas, sendo estas concêntricas (Fig. 4.7). Neste tipo de implementação, as camadas mais internas são mais privilegiadas que as mais externas.

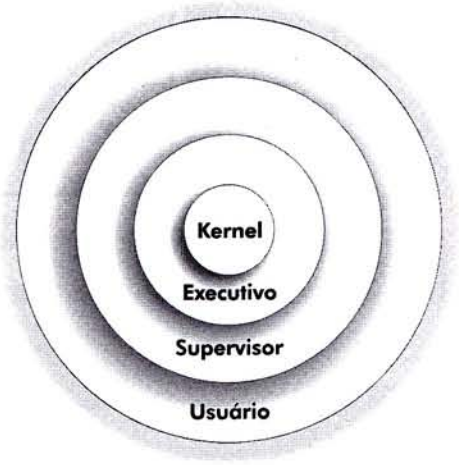

Fig. 4.7 Arquitetura em camadas do OpenVMS.

A vantagem da estruturação em camadas é isolar as funções do sistema operacional, facilitando sua manutenção e depuração, além de criar uma hierarquia de níveis de modos de acesso, protegendo as camadas mais internas. Uma desvantagem para o modelo de camadas é o desempenho. Cada nova camada implica uma mudança no modo de acesso. Por exemplo, no caso do OpenVMS, para se ter acesso aos serviços oferecidos pelo kernel é preciso passar por três camadas ou três mudanças no modo de acesso.

Atualmente, a maioria dos sistemas comerciais utiliza o modelo de duas camadas, onde existem os modos de acesso usuário (não-privilegiado) e kernel (privilegiado). A maioria das versões do Unix e o Windows da Microsoft está baseada neste modelo.

4.8.3 Máquina Virtual

Um sistema computacional é formado por níveis, onde a camada de nível mais baixo é o hardware. Acima desta camada encontramos o sistema operacional que oferece suporte para as aplicações, como visto na Fig. 4.1. O modelo de *máquina virtual*, ou *virtual machine* (VM), cria um nível intermediário entre o hardware e o sistema operacional, denominado gerência de máquinas virtuais (Fig. 4.8). Este nível cria diversas máquinas virtuais independentes, onde cada uma oferece uma cópia virtual do hardware, incluindo os modos de acesso, interrupções, dispositivos de E/S etc.

Como cada máquina virtual é independente das demais, é possível que cada VM tenha seu próprio sistema operacional e que seus usuários executem suas aplicações como se todo o computador estivesse dedicado a cada um deles. Na década de 1960, a IBM implementou este modelo no sistema VM/370, permitindo que aplicações batch, originadas de antigos sistemas OS/360, e aplicações de tempo compartilhado pudessem conviver na mesma máquina de forma transparente a seus usuários e aplicações.

Além de permitir a convivência de sistemas operacionais diferentes no mesmo computador, este modelo cria o isolamento total entre cada VM, oferecendo grande segurança para cada máquina virtual. Se, por exemplo, uma VM executar uma aplicação que comprometa o funcionamento do seu sistema operacional, as demais máquinas

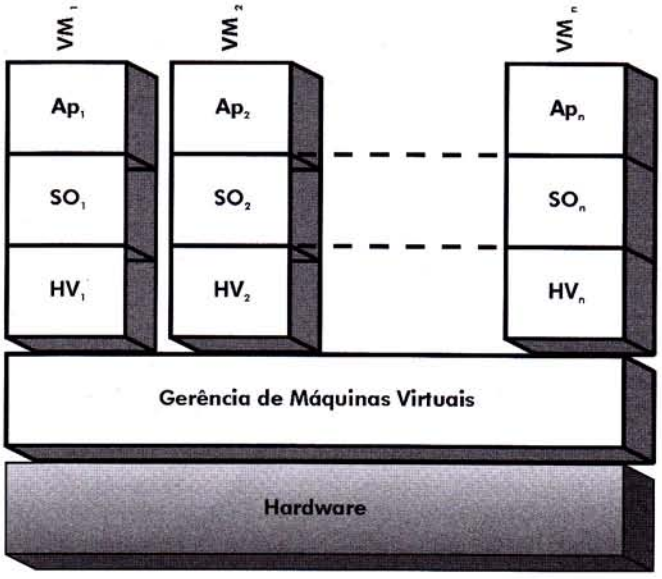

Fig. 4.8 Máquina virtual.

virtuais não sofrerão qualquer problema. A desvantagem desta arquitetura é a sua grande complexidade, devido à necessidade de se compartilhar e gerenciar os recursos do hardware entre as diversas VMs.

4.8.4 Arquitetura Microkernel

Uma tendência nos sistemas operacionais modernos é tornar o núcleo do sistema operacional o menor e mais simples possível. Para implementar esta idéia, os serviços do sistema são disponibilizados através de processos, onde cada um é responsável por oferecer um conjunto específico de funções, como gerência de arquivos, gerência de processos, gerência de memória e escalonamento.

Sempre que uma aplicação deseja algum serviço, é realizada uma solicitação ao processo responsável. Neste caso, a aplicação que solicita o serviço é chamada de *cliente*, enquanto o processo que responde à solicitação é chamado de *servidor*. Um cliente, que pode ser uma aplicação de um usuário ou um outro componente do sistema operacional, solicita um serviço enviando uma mensagem para o servidor. O servidor responde ao cliente através de uma outra mensagem. A principal função do núcleo é realizar a comunicação, ou seja, a troca de mensagens entre cliente e servidor (Fig. 4.9).

O conceito da *arquitetura microkernel* surgiu no sistema operacional Mach, na década de 80, na Universidade Carnegie-Mellon. O núcleo do sistema Mach oferece basicamente quatro serviços: gerência de processos, gerência de memória, comunicação por troca de mensagens e operações de E/S, todos em modo usuário.

A utilização deste modelo permite que os servidores executem em modo usuário, ou seja, não tenham acesso direto a certos componentes do sistema. Apenas o núcleo do sistema, responsável pela comunicação entre clientes e servidores, executa no modo kernel. Como conseqüência, se ocorrer um erro em um servidor, este poderá parar, mas o sistema não ficará inteiramente comprometido, aumentando assim a sua disponibilidade.

Como os servidores se comunicam através de trocas de mensagens, não importa se os clientes e servidores são processados em um sistema com um único processador, com múltiplos processadores (fortemente acoplado) ou ainda em um ambiente de sistema distribuído (fracamente acoplado). A implementação de sistemas microkernel em

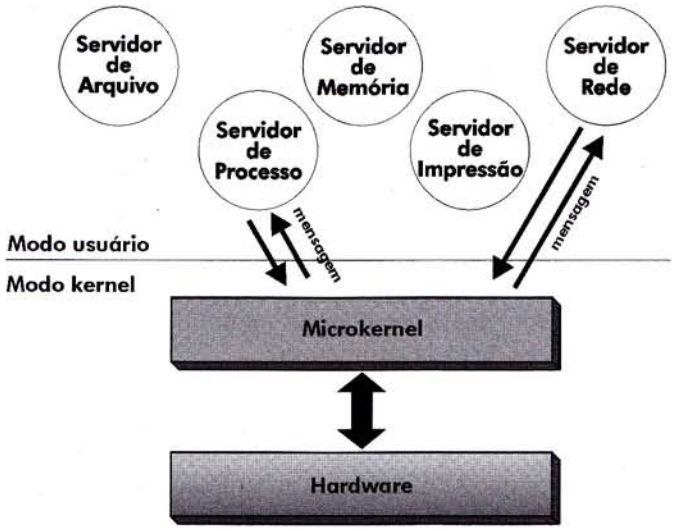

Fig. 4.9 Arquitetura microkernel.

ambientes distribuídos permite que um cliente solicite um serviço e a resposta seja processada remotamente. Esta característica permite acrescentar novos servidores à medida que o número de clientes aumenta, conferindo uma grande escalabilidade ao sistema operacional.

Além disso, a arquitetura microkernel permite isolar as funções do sistema operacional por diversos processos servidores pequenos e dedicados a serviços específicos, tornando o núcleo menor, mais fácil de depurar e, conseqüentemente, aumentando sua confiabilidade. Na arquitetura microkernel, o sistema operacional passa a ser de mais fácil manutenção, flexível e de maior portabilidade.

Apesar de todas as vantagens deste modelo, sua implementação, na prática, é muito difícil. Primeiro existe o problema de desempenho, devido à necessidade de mudança de modo de acesso a cada comunicação entre clientes e servidores. Outro problema é que certas funções do sistema operacional exigem acesso direto ao hardware, como operações de E/S. Na realidade, o que é implementado mais usualmente é uma combinação do modelo de camadas com a arquitetura microkernel. O núcleo do sistema, além de ser responsável pela comunicação entre cliente e servidor, passa a incorporar outras funções críticas do sistema, como escalonamento, tratamento de interrupções e gerência de dispositivos.

Existem vários projetos baseados em sistemas microkernel, principalmente em instituições de ensino e centros de pesquisa, como o Exokernel, do MIT (Massachusetts Institute of Technology), L4, da Universidade de Dresden, e Amoeba, da Vrije Universiteit. A maioria das iniciativas nesta área está relacionada ao desenvolvimento de sistemas operacionais distribuídos.

4.9 Exercícios

1. O que é o núcleo do sistema e quais são suas principais funções?
2. O que são instruções privilegiadas e não-privilegiadas? Qual a relação dessas instruções com os modos de acesso?
3. Explique como funciona a mudança de modos de acesso e dê um exemplo de como um programa faz uso desse mecanismo.
4. Como o kernel do sistema operacional pode ser protegido pelo mecanismo de modos de acesso?
5. Por que as rotinas do sistema operacional possuem instruções privilegiadas?
6. O que é uma system call e qual sua importância para a segurança do sistema? Como as system calls são utilizadas por um programa?
7. Quais das instruções a seguir devem ser executas apenas em modo kernel? Desabilitar todas as interrupções, consultar a data e a hora do sistema, alterar a data e a hora do sistema, alterar informações residentes no núcleo do sistema, somar duas variáveis declaradas dentro do programa, realizar um desvio para uma instrução dentro do próprio programa e acessar diretamente posições no disco.
8. Pesquise comandos disponíveis em linguagens de controle de sistemas operacionais.
9. Explique o processo de ativação (boot) do sistema operacional.
10. Compare as arquiteturas monolítica e de camadas. Quais as vantagens e desvantagens de cada arquitetura?
11. Quais as vantagens do modelo de máquina virtual?
12. Como funciona o modelo cliente-servidor na arquitetura microkernel? Quais as vantagens e desvantagens dessa arquitetura?
13. Por que a utilização da programação orientada a objetos é um caminho natural para o projeto de sistemas operacionais?

PARTE II

PROCESSOS E THREADS

"Anyone who stops learning is old, whether twenty or eighty.
Anyone who keeps learning stays young.
The greatest thing in life is to keep your mind young."

HENRY FORD (1863-1947)
Empreendedor americano

"O homem nasceu para aprender, aprender tanto quanto a vida lhe permita."

GUIMARÃES ROSA (1908-1967)
Escritor e diplomata brasileiro

"O reconhecimento da ignorância é o princípio da sabedoria."

SÓCRATES (470 a.C.-399 a.C.)
Filósofo grego

"Feliz aquele que transfere o que sabe e aprende o que ensina."

CORA CORALINA (1889-1985)
Poetisa brasileira

5

PROCESSO

5.1 Introdução

A gerência de um ambiente multiprogramável é função exclusiva do sistema operacional que deve controlar a execução dos diversos programas e o uso concorrente do processador e demais recursos. Para isso, um programa ao ser executado deve estar sempre associado a um processo. O conceito de processo é a base para a implementação de um sistema multiprogramável.

A gerência de processos é uma das principais funções de um sistema operacional, possibilitando aos programas alocar recursos, compartilhar dados, trocar informações e sincronizar suas execuções. Nos sistemas multiprogramáveis os processos são executados concorrentemente, compartilhando o uso do processador, memória principal e dispositivos de E/S, dentre outros recursos. Nos sistemas com múltiplos processadores não só existe a concorrência de processos pelo uso do processador como também a possibilidade de execução simultânea de processos nos diferentes processadores.

Neste capítulo serão abordados os principais conceitos relacionados a processos, como sua estrutura, estados de execução, tipos de processos e sinais.

5.2 Estrutura do Processo

O processador é projetado para executar instruções a partir do ciclo de busca e execução. Neste ciclo, o processador busca a instrução a ser executada na memória principal, armazena-a no registrador de instruções para, finalmente, decodificar seus bits e realizar a execução. O registrador PC tem a função de armazenar sempre o endereço da próxima instrução a ser executada, e as alterações do seu conteúdo determinam o seqüenciamento de execução das instruções armazenadas na memória principal.

Na visão da camada de hardware, o processador executa instruções sem distinguir qual programa encontra-se em processamento. É de responsabilidade do sistema operacional implementar a concorrência entre programas gerenciando a alternância da execução de instruções na UCP de maneira controlada e segura. Neste sentido, o

conceito de processo torna-se essencial para que os sistemas multiprogramáveis implementem a concorrência de diversos programas e atendam a múltiplos usuários simultaneamente.

Um *processo* pode ser entendido inicialmente como um programa em execução, só que seu conceito é mais abrangente. Para que a concorrência entre os programas ocorra sem problemas, é necessário que todas as informações do programa interrompido sejam guardadas para que, quando este voltar a ser executado, não lhe falte nenhuma informação necessária à continuação do processamento. Estas informações são fundamentais para que o sistema operacional possa gerenciar a execução concorrente de programas, e é a base de qualquer ambiente multiprogramável. O conceito de processo pode ser definido como sendo o conjunto necessário de informações para que o sistema operacional implemente a concorrência de programas.

A Fig. 5.1 ilustra a concorrência de três programas (PROG_1, PROG_2, PROG_3) associados aos Processos X, Y e Z. No intervalo de tempo Δt_1, o processador executa instruções do PROG_1. No instante de tempo t_4, o sistema operacional decide interromper temporariamente a execução do PROG_1 e salva o conteúdo dos registradores do processador, armazenando-os no Processo X. A seguir, o PROG_2 é iniciado e executado ao longo do intervalo Δt_2. No instante t_7, o sistema operacional decide interromper o PROG_2 e salva o conteúdo dos registradores no Processo Y. Neste momento o PROG_3 é iniciado, executa no intervalo de tempo Δt_3 até que o sistema operacional decide interrompê-lo, salvar seus registradores no Processo Z e retomar a execução de PROG_1. Para isso, no instante t_{12} o conteúdo dos registradores do Processo X é carregado no processador, fazendo com que PROG_1 continue sua

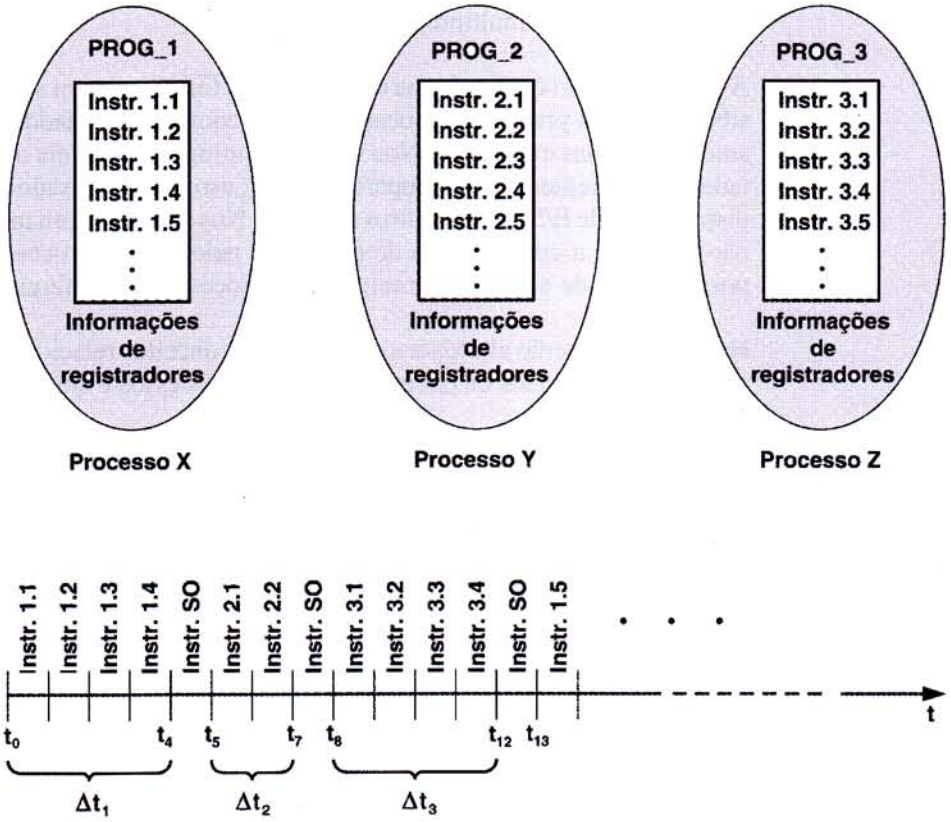

Fig. 5.1 Concorrência de programas e processos.

execução como se não tivesse sido interrompido. A troca de um processo por outro no processador, comandada pelo sistema operacional, é denominada *mudança de contexto*. É dessa maneira que o sistema operacional implementa e gerencia um ambiente multiprogramável.

Em um sistema multiusuário, cada usuário tem seu programa associado a um processo. Ao executar um programa, o usuário tem a impressão de possuir o processador e todos os demais recursos reservados exclusivamente para seu uso. De fato isto não é verdade, visto que todos os recursos estão sendo compartilhados, inclusive a UCP. Nesse caso, o processador executa o programa de um usuário durante um intervalo de tempo e, conforme observado, no instante seguinte estará processando um outro programa.

Um processo também pode ser definido como o ambiente onde um programa é executado. Este ambiente, além das informações sobre a execução, possui também a quantidade de recursos do sistema que cada programa pode utilizar, como o espaço de endereçamento da memória principal, tempo de processador e área em disco.

O resultado da execução de um mesmo programa pode variar, dependendo do processo em que é executado, ou seja, em função dos recursos que são disponibilizados para o programa. A falta de recursos pode impedir a execução com sucesso de um programa. Caso um programa, por exemplo, necessite utilizar uma área em disco superior ao seu limite, o sistema operacional irá interromper sua execução por falta de recursos disponíveis.

Um processo é formado por três partes, conhecidas como contexto de hardware, contexto de software e espaço de endereçamento, que juntos mantêm todas as informações necessárias à execução de um programa. A Fig. 5.2 ilustra de maneira abstrata os componentes da estrutura do processo.

Fig. 5.2 Estrutura do processo.

5.2.1 Contexto de Hardware

O *contexto de hardware* de um processo armazena o conteúdo dos registradores gerais da UCP, além dos registradores de uso específico, como program counter (PC), stack pointer (SP) e registrador de status. Quando um processo está em execução, o seu contexto de hardware está armazenado nos registradores do processador. No momento em que o processo perde a utilização da UCP, o sistema salva as informações no contexto de hardware do processo.

O contexto de hardware é fundamental para a implementação dos sistemas multiprogramáveis, onde os processos se alternam na utilização da UCP, podendo ser interrompidos e, posteriormente, restaurados. O sistema operacional gerencia a mudança de contexto, base para a implementação da concorrência, que consiste em salvar o conteúdo dos registradores do processo que está deixando a UCP e carregá-lo com os valores referentes ao do novo processo que será executado. Essa operação se resume em substituir o contexto de hardware de um processo pelo de outro (Fig. 5.3).

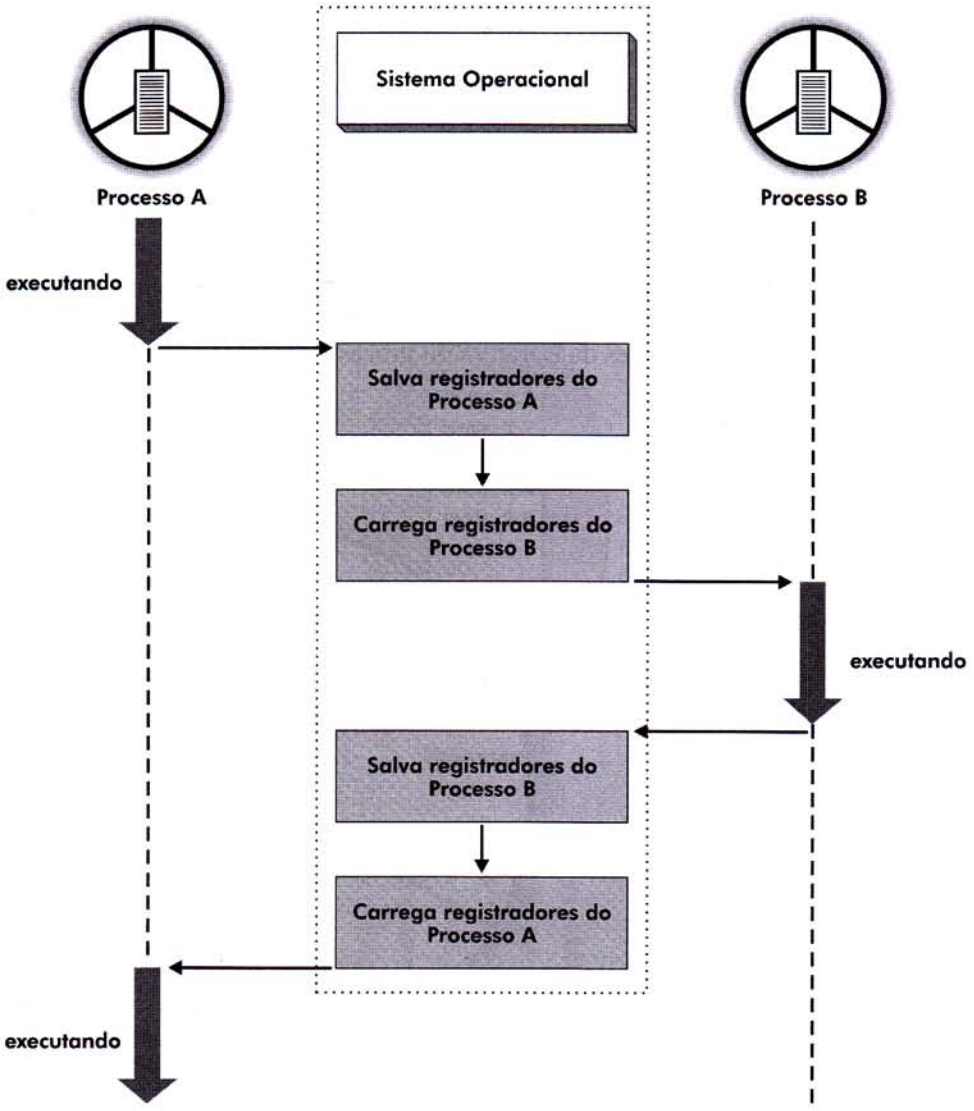

Fig. 5.3 Mudança de contexto.

5.2.2 Contexto de Software

No *contexto de software* de um processo são especificados limites e características dos recursos que podem ser alocados pelo processo, como o número máximo de arquivos abertos simultaneamente, prioridade de execução e tamanho do buffer para operações de E/S. Muitas destas características são determinadas no momento da criação do processo, enquanto outras podem ser alteradas durante sua existência.

A maior parte das informações do contexto de software do processo provém de um arquivo do sistema operacional, conhecido como *arquivo de usuários*. Neste arquivo são especificados os limites dos recursos que cada processo pode alocar, sendo gerenciado pelo administrador do sistema. Outras informações presentes no contexto de software são geradas dinamicamente ao longo da execução do processo.

O contexto de software é composto por três grupos de informações sobre o processo: identificação, quotas e privilégios.

- Identificação

  Cada processo criado pelo sistema recebe uma identificação única (PID — process identification) representada por um número. Através do PID, o sistema operacional e outros processos podem fazer referência a qualquer processo existente, consultando seu contexto ou alterando uma de suas características. Alguns sistemas, além do PID, identificam o processo através de um nome.

  O processo também possui a identificação do usuário ou processo que o criou (owner). Cada usuário possui uma identificação única no sistema (UID — user identification), atribuída ao processo no momento de sua criação. A UID permite implementar um modelo de segurança, onde apenas os objetos (processos, arquivos, áreas de memória etc.) que possuem a mesma UID do usuário (processo) podem ser acessados.

- Quotas

  As quotas são os limites de cada recurso do sistema que um processo pode alocar. Caso uma quota seja insuficiente, o processo poderá ser executado lentamente, interrompido durante seu processamento ou mesmo não ser executado. Alguns exemplos de quotas presentes na maioria dos sistemas operacionais são:

  - número máximo de arquivos abertos simultaneamente;
  - tamanho máximo de memória principal e secundária que o processo pode alocar;
  - número máximo de operações de E/S pendentes;
  - tamanho máximo do buffer para operações de E/S;
  - número máximo de processos, subprocessos e threads que podem ser criados.

- Privilégios

  Os privilégios ou direitos definem as ações que um processo pode fazer em relação a ele mesmo, aos demais processos e ao sistema operacional.

  Privilégios que afetam o próprio processo permitem que suas características possam ser alteradas, como prioridade de execução, limites alocados na memória principal e secundária etc. Já os privilégios que afetam os demais processos permitem, além da alteração de suas próprias características, alterar as de outros processos.

Privilégios que afetam o sistema são os mais amplos e poderosos, pois estão relacionados à operação e à gerência do ambiente, como a desativação do sistema, alteração de regras de segurança, criação de outros processos privilegiados, modificação de parâmetros de configuração do sistema, entre outros. A maioria dos sistemas operacionais disponibiliza uma conta de acesso com todos estes privilégios disponíveis, com o propósito de o administrador gerenciar o sistema operacional. No sistema Unix existe a conta "root", no MS Windows a conta "administrator" e no OpenVMS existe a conta "system" com este mesmo perfil.

5.2.3 Espaço de Endereçamento

O espaço de endereçamento é a área de memória pertencente ao processo onde instruções e dados do programa são armazenados para execução. Cada processo possui seu próprio espaço de endereçamento, que deve ser devidamente protegido do acesso dos demais processos. No Capítulo 9 — Gerência de Memória e no Capítulo 10 — Gerência de Memória Virtual serão apresentados diversos mecanismos de implementação e administração do espaço de endereçamento.

A Fig. 5.4 ilustra as características da estrutura de um processo.

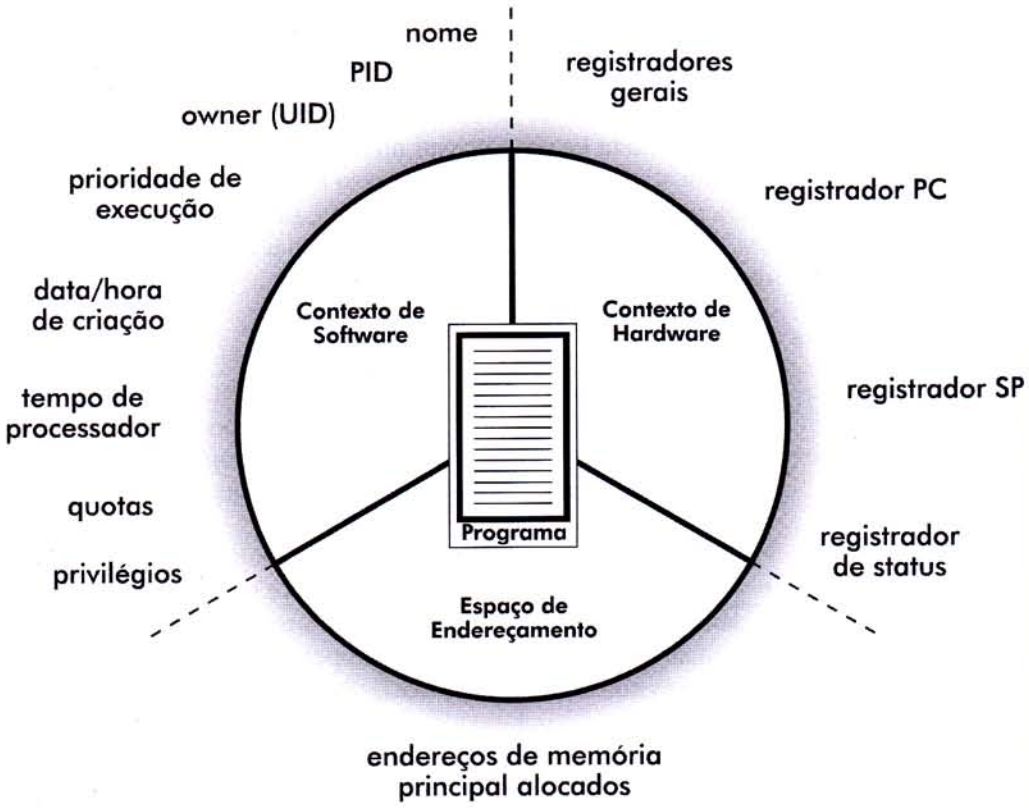

Fig. 5.4 Características da estrutura de um processo.

5.2.4 Bloco de Controle do Processo

O processo é implementado pelo sistema operacional através de uma estrutura de dados chamada *bloco de controle do processo* (*Process Control Block — PCB*). A partir

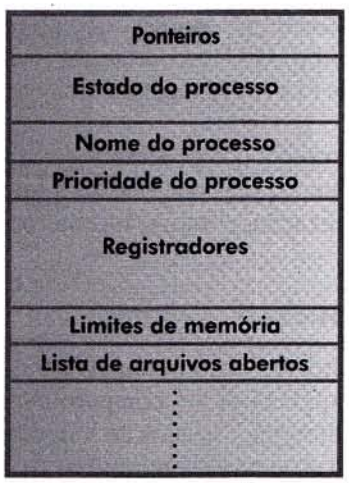

Fig. 5.5 Bloco de Controle do Processo (PCB).

do PCB, o sistema operacional mantém todas as informações sobre o contexto de hardware, contexto de software e espaço de endereçamento de cada processo (Fig. 5.5).

Os PCBs de todos os processos ativos residem na memória principal em uma área exclusiva do sistema operacional. O tamanho desta área, geralmente, é limitado por um parâmetro do sistema operacional que permite especificar o número máximo de processos que podem ser suportados simultaneamente pelo sistema.

A Fig. 5.6 exibe, a partir da execução do comando `ps` (process status), a listagem de alguns dos processos existentes em uma estação de trabalho com sistema operacional Linux. Diversas características do contexto de software do processo são apresentadas. Por exemplo, a coluna `PID` indica a identificação do processo, `PRI` indica a priorida-

```
# ps -l -A
F S   UID   PID  PPID  C PRI  NI ADDR    SZ WCHAN  TTY          TIME CMD
4 S     0     1     0  0  75   0    -   378 schedu ?        00:00:04 init
1 S     0     2     1  0  75   0    -     0 contex ?        00:00:00 keventd
1 S     0     3     1  0  94  19    -     0 ksofti ?        00:00:00 ksoftirqd/0
1 S     0     6     1  0  85   0    -     0 bdflus ?        00:00:00 bdflush
1 S     0     4     1  0  75   0    -     0 schedu ?        00:05:35 kswapd
1 S     0     5     1  0  75   0    -     0 schedu ?        00:03:45 kscand
1 S     0     7     1  0  75   0    -     0 schedu ?        00:00:00 kupdated
1 S     0     8     1  0  85   0    -     0 md_thr ?        00:00:00 mdrecoveryd
1 S     0    21     1  0  75   0    -     0 end    ?        00:05:40 kjournald
1 S     0   253     1  0  75   0    -     0 end    ?        00:00:00 kjournald
1 S     0   254     1  0  75   0    -     0 end    ?        00:00:00 kjournald
1 S     0   255     1  0  75   0    -     0 end    ?        00:55:28 kjournald
1 S     0   579     1  0  75   0    -   399 schedu ?        00:02:00 syslogd
5 S     0   583     1  0  75   0    -   383 do_sys ?        00:00:00 klogd
5 S    32   600     1  0  75   0    -   414 schedu ?        00:00:00 portmap
5 S    29   619     1  0  85   0    -   416 schedu ?        00:00:00 rpc.statd
1 S     0   631     1  0  75   0    -   393 schedu ?        00:00:00 mdadm
5 S     0   702     1  0  75   0    -   917 schedu ?        00:00:30 sshd
5 S     0   716     1  0  75   0    -   539 schedu ?        00:00:00 xinetd
5 S     0   745     1  0  75   0    -   398 schedu ?        00:00:00 gpm
5 S     0   765     1  0  75   0    -   607 schedu ?        00:00:16 crond
```

Fig. 5.6 Visualização de processos no Linux.

de e `TIME` o tempo de utilização do processador. De forma semelhante, é possível visualizar os processos existentes em um sistema MS Windows utilizando o Gerenciador de Tarefas (Task Manager).

Toda a gerência dos processos é realizada por intermédio de chamadas a rotinas do sistema operacional que realizam operações como criação, alteração de características, visualização, eliminação, sincronização, suspensão de processos, dentre outras.

5.3 Estados do Processo

Em um sistema multiprogramável, um processo não deve alocar exclusivamente a UCP, de forma que exista um compartilhamento no uso do processador. Os processos passam por diferentes estados ao longo do seu processamento, em função de eventos gerados pelo sistema operacional ou pelo próprio processo. Um processo ativo pode encontrar-se em três diferentes estados:

- Execução (running)

  Um processo é dito no *estado de execução* quando está sendo processado pela UCP. Em sistemas com apenas uma UCP, somente um processo pode estar sendo executado em um dado instante de tempo. Os processos se alternam na utilização do processador seguindo uma política estabelecida pelo sistema operacional.

  Em sistemas com múltiplos processadores, existe a possibilidade de mais de um processo ser executado ao mesmo tempo. Neste tipo de sistema, também é possível um mesmo processo ser executado simultaneamente em mais de uma UCP (processamento paralelo).

- Pronto (ready)

  Um processo está no *estado de pronto* quando aguarda apenas para ser executado. O sistema operacional é responsável por determinar a ordem e os critérios pelos quais os processos em estado de pronto devem fazer uso do processador. Este mecanismo é conhecido como escalonamento.

  Em geral existem vários processos no sistema no estado de pronto organizados em listas encadeadas. Os processos devem estar ordenados pela sua importância, permitindo que processos mais prioritários sejam selecionados primeiramente para execução (Fig. 5.7).

- Espera (wait)

  Um processo no *estado de espera* aguarda por algum evento externo ou por algum recurso para prosseguir seu processamento. Como exemplo, podemos citar o término de uma operação de entrada/saída ou a espera de uma determinada data e/ou hora para continuar sua execução. Em alguns sistemas operacionais, o estado de espera pode ser chamado de bloqueado (blocked).

  O sistema organiza os vários processos no estado de espera também em listas encadeadas. Em geral, os processos são separados em listas de espera associadas a cada tipo de evento (Fig. 5.7). Nesse caso, quando um evento acontece, todos os processos da lista associada ao evento são transferidos para o estado de pronto.

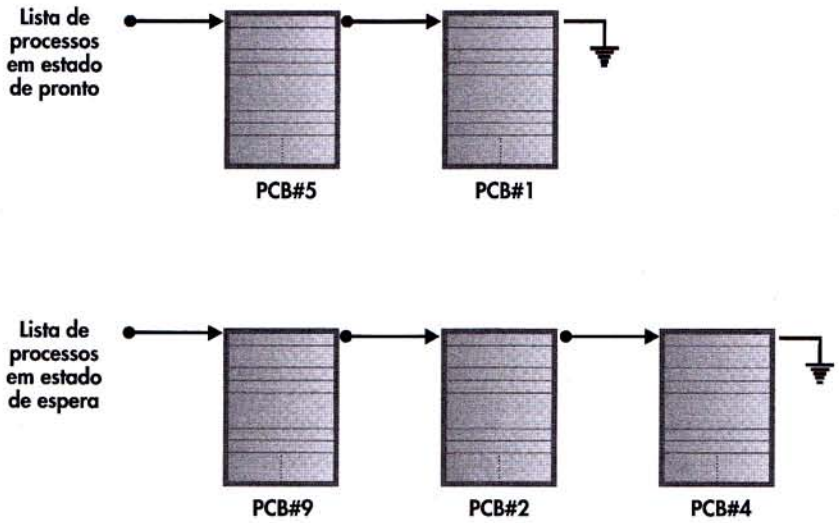

Fig. 5.7 Lista de PCBs nos estados de pronto e de espera.

5.4 Mudanças de Estado do Processo

Um processo muda de estado durante seu processamento em função de eventos originados por ele próprio (*eventos voluntários*) ou pelo sistema operacional (*eventos involuntários*). Basicamente, existem quatro mudanças de estado que podem ocorrer a um processo:

- Pronto → Execução

  Após a criação de um processo, o sistema o coloca em uma lista de processos no estado de pronto, onde aguarda por uma oportunidade para ser executado (Fig. 5.8a). Cada sistema operacional tem seus próprios critérios e algoritmos para a escolha da ordem em que os processos serão executados (política de escalonamento). No Capítulo 8 — Gerência do Processador, esses critérios e seus algoritmos serão analisados com detalhes.

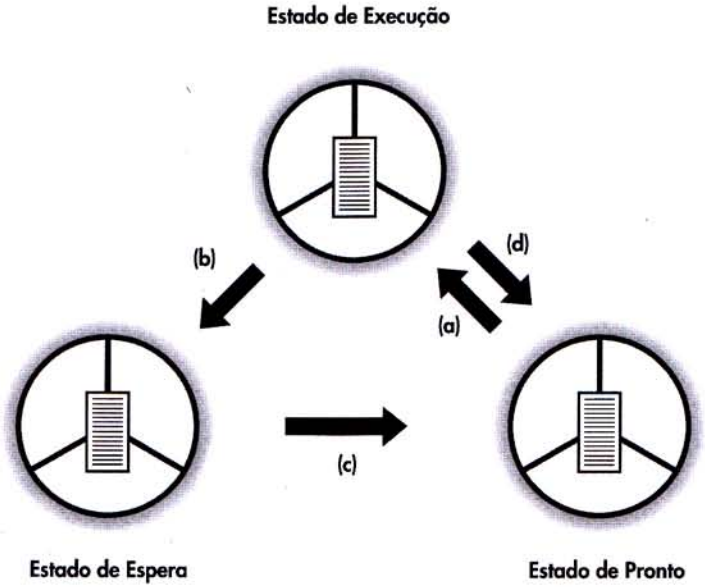

Fig. 5.8 Mudanças de estado do processo.

- Execução → Espera

  Um processo em execução passa para o estado de espera por eventos gerados pelo próprio processo, como uma operação de E/S, ou por eventos externos (Fig. 5.8b). Um evento externo é gerado, por exemplo, quando o sistema operacional suspende por um período de tempo a execução de um processo.

- Espera → Pronto

  Um processo no estado de espera passa para o estado de pronto quando a operação solicitada é atendida ou o recurso esperado é concedido. Um processo no estado de espera sempre terá de passar pelo estado de pronto antes de poder ser novamente selecionado para execução. Não existe a mudança do estado de espera para o estado de execução diretamente (Fig. 5.8c).

- Execução → Pronto

  Um processo em execução passa para o estado de pronto por eventos gerados pelo sistema, como o término da fatia de tempo que o processo possui para sua execução (Fig. 5.8d). Nesse caso, o processo volta para a fila de pronto, onde aguarda por uma nova oportunidade para continuar seu processamento.

Um processo em estado de pronto ou de espera pode não se encontrar na memória principal. Esta condição ocorre quando não existe espaço suficiente para todos os proces-

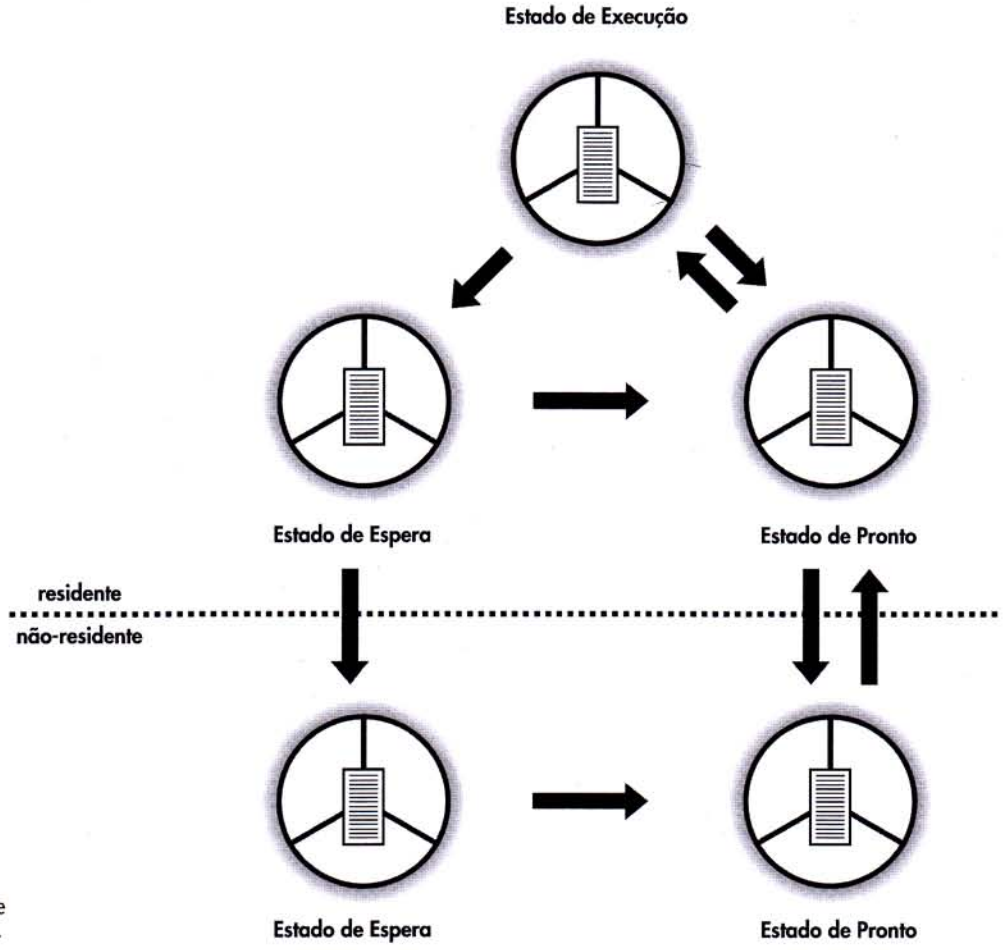

Fig. 5.9 Mudanças de estado do processo (2).

sos na memória principal e parte do contexto do processo é levado para memória secundária. A técnica conhecida como swapping, na condição citada, retira processos da memória principal (*swap out*) e os traz de volta (*swap in*) seguindo critérios de cada sistema operacional. Neste caso, os processos em estados de espera e pronto podem estar residentes ou não residentes (*outswapped*) na memória principal (Fig. 5.9).

5.5 Criação e Eliminação de Processos

Processos são criados e eliminados por motivos diversos. A criação de um processo ocorre a partir do momento em que o sistema operacional adiciona um novo PCB à sua estrutura e aloca um espaço de endereçamento na memória para uso. A partir da criação do PCB, o sistema operacional já reconhece a existência do processo, podendo gerenciá-lo e associar programas ao seu contexto para serem executados. No caso da eliminação de um processo, todos os recursos associados ao processo são desalocados e o PCB eliminado pelo sistema operacional.

Além dos três estados apresentados anteriormente para o processo, a maioria dos sistemas operacionais estabelece para os momentos de criação e eliminação de um processo dois estados adicionais. A Fig. 5.10 ilustra as mudanças de estado do processo considerando estes dois novos estados.

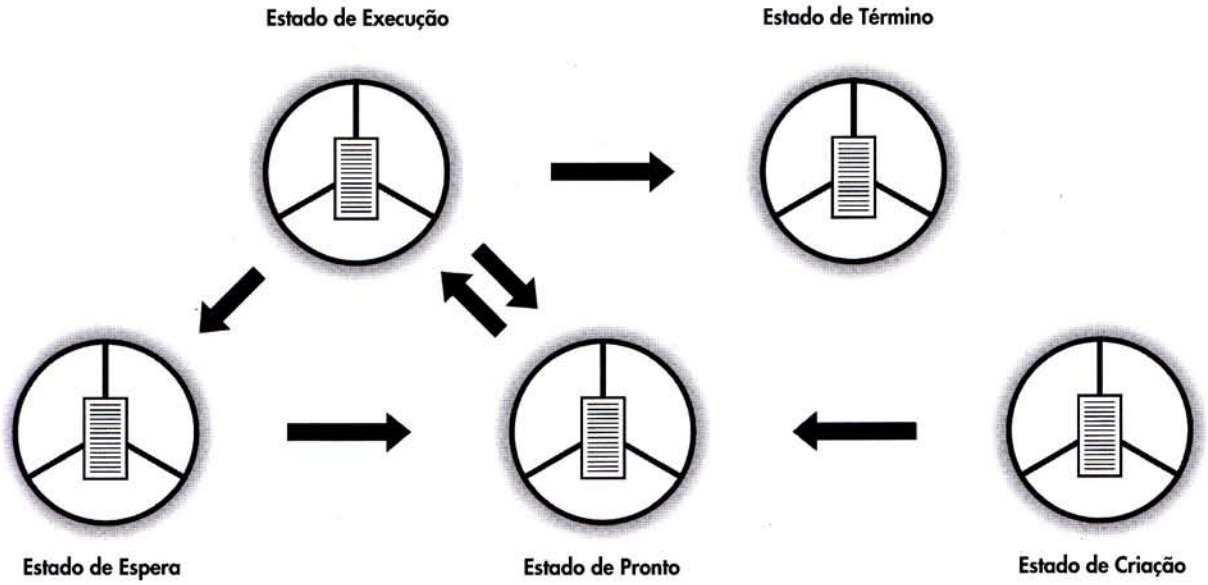

Fig. 5.10 Mudanças de estado do processo (3).

- Criação (new)

  Um processo é dito no *estado de criação* quando o sistema operacional já criou um novo PCB, porém ainda não pode colocá-lo na lista de processos do estado de pronto. Alguns sistemas operacionais limitam o número de processos ativos em função dos recursos disponíveis ou de desempenho. Esta limitação pode ocasionar que processos criados permaneçam no estado de criação até que possam passar para ativos. No item 5.8 são descritas diferentes maneiras de criação de processos.

- Terminado (exit)

  Um processo no *estado de terminado* não poderá ter mais nenhum programa executado no seu contexto, porém o sistema operacional ainda mantém suas informações de controle presentes em memória. Um processo neste estado não é considerado mais ativo, mas como o PCB ainda existe, o sistema operacional pode recuperar informações sobre a contabilização de uso de recursos do processo, como o tempo total do processador. Após as informações serem extraídas, o processo pode deixar de existir.

  O término de processo pode ocorrer por razões como:

  - término normal de execução;
  - eliminação por um outro processo;
  - eliminação forçada por ausência de recursos disponíveis no sistema.

5.6 Processos CPU-bound e I/O-bound

Processos podem ser classificados como CPU-bound ou I/O-bound de acordo com a utilização do processador e dos dispositivos de E/S.

Um processo é definido como *CPU-bound* (ligado à UCP) quando passa a maior parte do tempo no estado de execução, utilizando o processador, ou pronto (Fig. 5.11a). Esse tipo de processo realiza poucas operações de leitura e gravação, e é encontrado em aplicações científicas que efetuam muitos cálculos.

Um processo é classificado como *I/O-bound* (ligado à E/S) quando passa a maior parte do tempo no estado de espera, pois realiza um elevado número de operações de E/S (Fig. 5.11b). Esse tipo de processo é encontrado em aplicações comerciais, que se baseiam em leitura, processamento e gravação. Os processos interativos também são bons exemplos de processos I/O-bound, pela forma de comunicação entre o usuário e o sistema, normalmente lenta, devido à utilização de terminais.

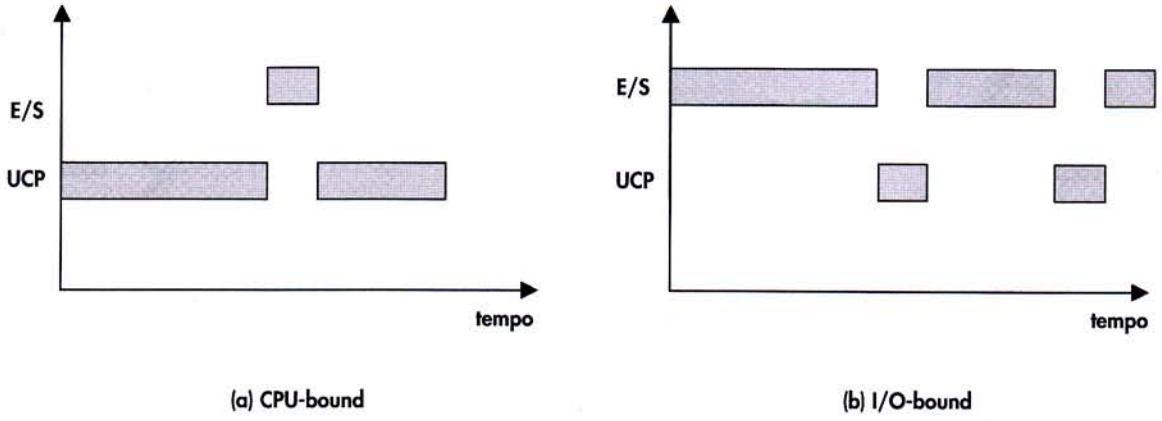

Fig. 5.11 Processos CPU-bound × I/O-bound.

5.7 Processos Foreground e Background

Um processo possui sempre pelo menos dois canais de comunicação associados a sua estrutura, pelos quais são realizadas todas as entradas e saídas de dados ao longo do

seu processamento. Os canais de entrada (input) e saída (output) de dados podem estar associados a terminais, arquivos, impressoras e até mesmo a outros processos.

Um *processo foreground* é aquele que permite a comunicação direta do usuário com o processo durante o seu processamento. Neste caso, tanto o canal de entrada quanto o de saída estão associados a um terminal com teclado, mouse e monitor, permitindo, assim, a interação com o usuário (Fig. 5.12a). O processamento interativo tem como base processos foreground.

Um *processo background* é aquele onde não existe a comunicação com o usuário durante o seu processamento (Fig. 5.12b). Neste caso, os canais de E/S não estão associados a nenhum dispositivo de E/S interativo, mas em geral a arquivos de E/S. O processamento do tipo batch é realizado através de processos background.

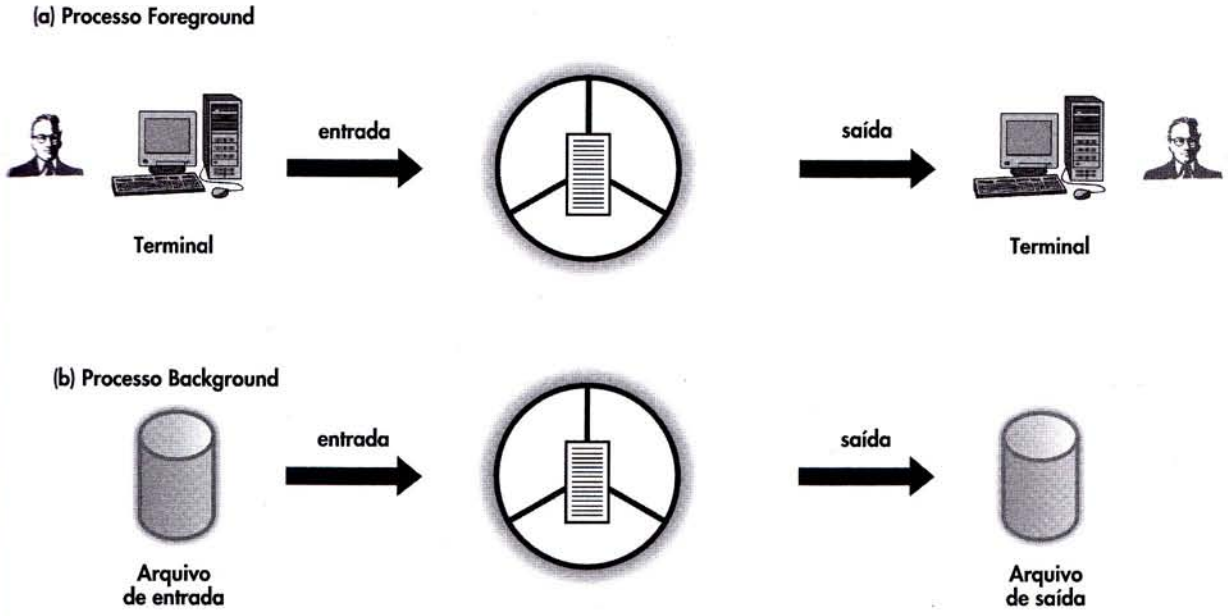

Fig. 5.12 Processos foreground e background.

É possível associar o canal de saída de um processo ao canal de entrada de um outro processo. Neste caso dizemos que existe um *pipe* ligando os dois processos. Se um Processo A gera uma listagem e o Processo B tem como função ordená-la, basta associar o canal de saída do processo A ao canal de entrada do processo B (Fig. 5.13).

5.8 Formas de Criação de Processos

Um processo pode ser criado de diversas maneiras. A seguir, são apresentadas as três principais formas de criação de processos:

- Logon Interativo

  No *logon interativo* o usuário, por intermédio de um terminal, fornece ao sistema um nome de identificação (username ou logon) e uma senha (password). O sistema operacional autentica estas informações verificando se estão corretamente cadastradas no arquivo de usuários. Em caso positivo, um processo foreground é criado, pos-

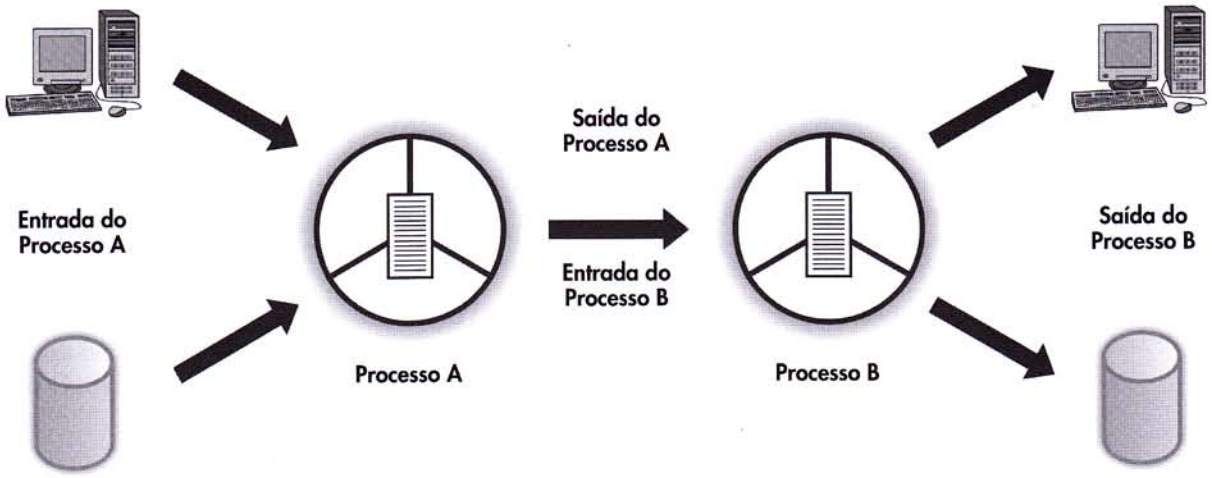

Fig. 5.13 Pipe.

sibilitando ao usuário interagir com o sistema utilizando uma linguagem de comandos. Na Fig. 5.14 é apresentado um exemplo de logon interativo em um sistema Unix.

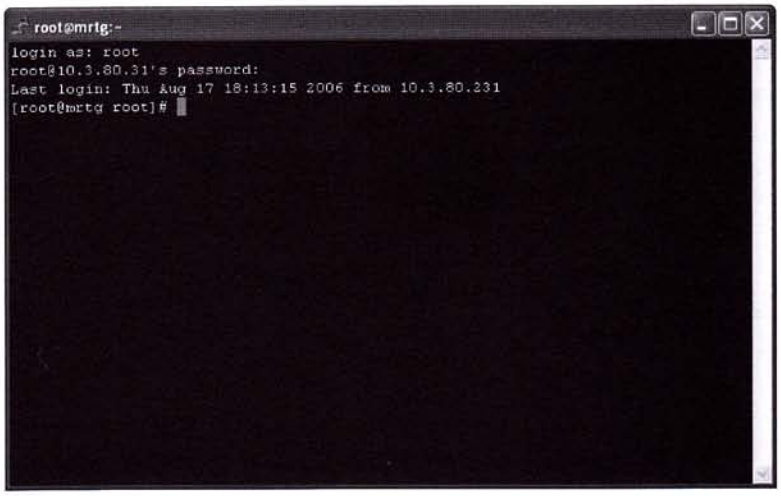

Fig. 5.14 Tela de logon interativo.

Conforme apresentado anteriormente, o *arquivo de usuários* é um arquivo do sistema operacional onde são armazenados todos os usuários autorizados a ter acesso ao sistema. Para cada usuário existe um registro com informações como, por exemplo, username, senha, quotas e privilégios. Apenas o administrador do sistema pode criar, modificar e eliminar registros no arquivo de usuários. Grande parte das informações do contexto de software de um processo provém do arquivo de usuários.

O processo também pode ser eliminado interativamente quando o usuário realiza o procedimento de saída do sistema, também chamado *logout* ou *logoff*, digitando um comando da linguagem de comandos para encerramento da sessão.

- Via Linguagem de Comandos

Um usuário pode, a partir do seu processo, criar novos processos por intermédio de comandos da linguagem de comandos. O principal objetivo para que um usuário crie diversos processos é a possibilidade de execução de programas concorrentemente. Por exemplo, no sistema OpenVMS o comando *spawn* permite executar uma outra tarefa de forma concorrente. Esta é uma maneira de criar um processo a partir de outro processo já existente. O processo criado pode ser foreground ou background, dependendo do comando de criação utilizado.

- Via Rotina do Sistema Operacional

Um processo pode ser criado a partir de qualquer programa executável com o uso de rotinas do sistema operacional. A criação deste processo possibilita a execução de outros programas concorrentemente ao programa chamador. A rotina de criação de processos depende do sistema operacional e possui diversos parâmetros, como nome do processo a ser criado, nome do programa executável que será executado dentro do contexto do processo, prioridade de execução, estado do processo, se o processo é do tipo foreground ou background etc.

Como exemplos de rotinas do sistema para a criação de processos temos `sys$createprocess` no OpenVMS, `fork` no Unix e `CreateProcess` no MS Windows. No trecho de programa em Delphi, a seguir, desenvolvido para o MS Windows, há um exemplo da criação de um processo, sendo que o executável é o programa NOTEPAD.EXE (bloco de notas). Neste caso, a API abrirá uma janela para a execução concorrente do bloco de notas independente do programa chamador.

```
procedure TForm1.CriaProcesso(Sender: TObject);
var
    status: boolean;
    si: STARTUPINFO;
    pi: PROCESS_INFORMATION;
    Handle: THandle;
    NomeExe: PChar;
begin
    NomeExe := PChar('\WINNT\NOTEPAD.EXE');
    FillChar(si, SizeOf(si), 0);
    si.cb := SizeOf(si);
    status := CreateProcess(NomeExe, nil, nil, nil, TRUE,
                            NORMAL_PRIORITY_CLASS, nil, nil, si, pi);
    if (not status) then MessageBox (Handle, 'Erro na criação do
                                     processo', nil, MB_OK);
   end;
```

No exemplo do procedimento `TForm1.CriaProcesso`, o primeiro parâmetro da API `CreateProcess` indica o nome do executável, ou seja, no exemplo será criado um processo para a execução do programa NOTEPAD.EXE. O sexto parâmetro especifica a prioridade do processo, o nono dá informações para a criação do processo e o último retorna informações sobre o processo criado. A instrução seguinte à rotina `CreateProcess` testa se o processo foi criado com sucesso.

5.9 Processos Independentes, Subprocessos e Threads

Processos independentes, subprocessos e threads são maneiras diferentes de implementar a concorrência dentro de uma aplicação. Neste caso, busca-se subdividir

o código em partes para trabalharem de forma cooperativa. Considere um banco de dados com produtos de uma grande loja, onde vendedores fazem freqüentes consultas. Neste caso, a concorrência na aplicação proporciona um tempo de espera menor entre as consultas, melhorando o desempenho da aplicação e beneficiando os usuários.

O uso de *processos independentes* é a maneira mais simples de implementar a concorrência em sistemas multiprogramáveis. Neste caso não existe vínculo do processo criado com o seu criador. A criação de um processo independente exige a alocação de um PCB, possuindo contextos de hardware, contextos de software e espaços de endereçamento próprios.

Subprocessos são processos criados dentro de uma estrutura hierárquica. Neste modo, o processo criador é denominado *processo-pai*, enquanto o novo processo é chamado de *subprocesso* ou *processo-filho*. O subprocesso, por sua vez, pode criar outras estruturas de subprocessos. Uma característica desta implementação é a dependência existente entre o processo criador e o subprocesso. Caso um processo-pai deixe de existir, os subprocessos subordinados são automaticamente eliminados. De modo semelhante aos processos independentes, subprocessos possuem seu próprio PCB. A Fig. 5.15 ilustra cinco processos em uma estrutura hierárquica, cada qual com seu próprio contexto de hardware, contexto de software e espaço de endereçamento.

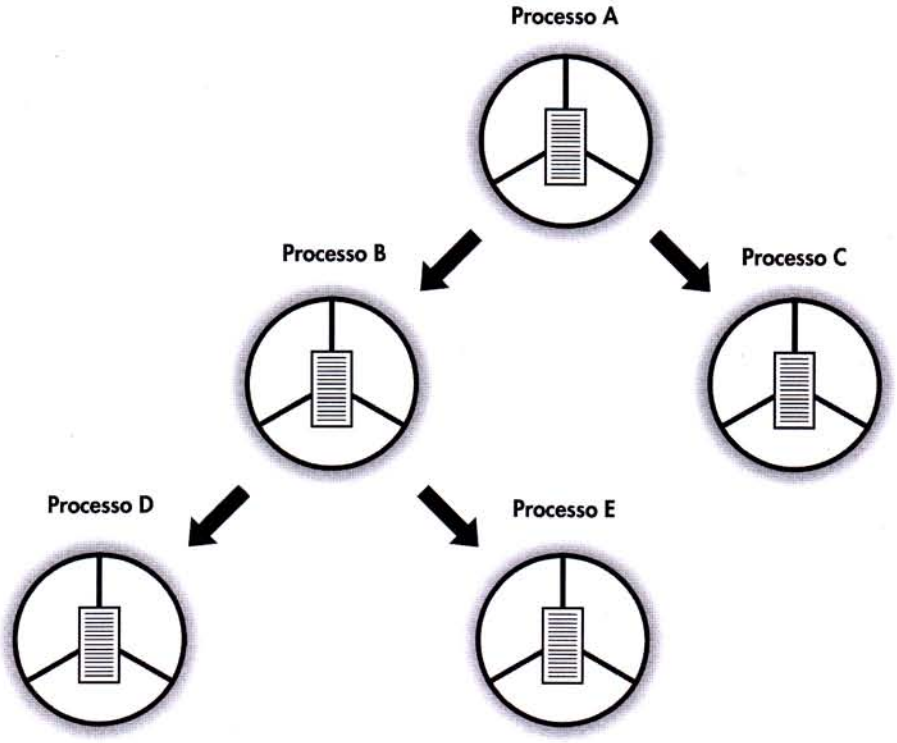

Fig. 5.15 Estrutura de processos e subprocessos.

Além da dependência hierárquica entre processos e subprocessos, uma outra característica neste tipo de implementação é que subprocessos podem compartilhar quotas com o processo-pai. Neste caso, quando um subprocesso é criado o processo-pai cede parte de suas quotas ao processo-filho.

O uso de processos independentes e subprocessos no desenvolvimento de aplicações concorrentes demanda consumo de diversos recursos do sistema. Sempre que um novo processo é criado, o sistema deve alocar recursos (contexto de hardware, contexto de

software e espaço de endereçamento), consumindo tempo de UCP neste trabalho. No momento do término dos processos, o sistema operacional também dispensa tempo para desalocar recursos previamente alocados. Outro problema é a comunicação e a sincronização entre processos consideradas pouco eficientes, visto que cada processo possui seu próprio espaço de endereçamento.

O conceito de *thread* foi introduzido na tentiva de reduzir o tempo gasto em criação, eliminação e troca de contexto de processos nas aplicações concorrentes, bem como economizar recursos do sistema como um todo. Em um ambiente multithread, um único processo pode suportar múltiplos threads, cada qual associado a uma parte do código da aplicação (Fig. 5.16). Neste caso não é necessário haver diversos processos para a implementação da concorrência. Threads compartilham o processador da mesma maneira que um processo, ou seja, enquanto um thread espera por uma operação de E/S, outro thread pode ser executado.

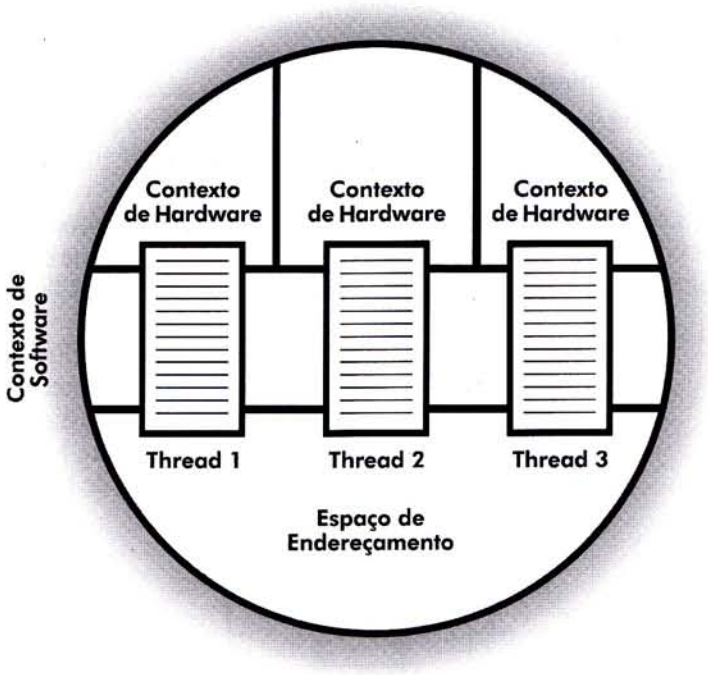

Fig. 5.16 Processo multithread.

Cada thread possui seu próprio contexto de hardware, porém compartilha o mesmo contexto de software e espaço de endereçamento com os demais threads do processo. O compartilhamento do espaço de endereçamento permite que a comunicação de threads dentro de um mesmo processo seja realizada de forma simples e rápida. Este assunto é mais bem detalhado no Capítulo 6 — Thread.

5.10 Processos do Sistema Operacional

O conceito de processo, além de estar associado a aplicações de usuários, pode também ser implementado na própria arquitetura do sistema operacional. Como visto no Capítulo 4 — Estrutura do Sistema Operacional, a arquitetura microkernel implementa

o uso intensivo de processos que disponibilizam serviços para processos das aplicações e do próprio sistema operacional.

Quando processos são utilizados para a implementação de serviços do sistema, estamos retirando código do seu núcleo, tornando-o menor e mais estável. No caso de um ou mais serviços não serem desejados, basta não ativar os processos responsáveis, o que permitirá liberar memória para os processos dos usuários.

A seguir, são apresentados alguns serviços que o sistema operacional pode implementar através de processos:

- auditoria e segurança;
- serviços de rede;
- contabilização do uso de recursos;
- contabilização de erros;
- gerência de impressão;
- gerência de jobs batch;
- temporização;
- comunicação de eventos;
- interface de comandos (shell).

5.11 Sinais

Sinais é um mecanismo que permite notificar processos de eventos gerados pelo sistema operacional ou por outros processos. O uso de sinais é fundamental para a gerência de processos, além de possibilitar a comunicação e sincronização entre processos.

Um exemplo de uso de sinais é quando um usuário utiliza uma seqüência de caracteres do teclado, como [Ctrl-C], para interromper a execução de um programa. Neste caso, o sistema operacional gera um sinal a partir da digitação desta combinação de teclas, sinalizando ao processo a ocorrência do evento. No momento que o processo identifica a chegada do sinal, uma rotina específica de tratamento é executada (Fig. 5.17).

Fig. 5.17 Uso de sinais.

Sinais podem ser utilizados em conjunto com temporizadores, no intuito de sinalizar ao processo algum evento associado ao tempo. Como exemplo, podemos citar a situação em que um processo deve ser avisado periodicamente para realizar alguma tarefa, como monitorar uma fila de pedidos. Depois de realizada a tarefa, o processo deve voltar a esperar pelo próximo sinal de temporização.

A maior parte dos eventos associados a sinais são gerados pelo sistema operacional ou pelo hardware, como a ocorrência de exceções, interrupções geradas por terminais, limites de quotas excedidos durante a execução dos processos e alarmes de tempo. Em outras situações, os eventos são gerados a partir de outros processos com o propósito de sincronizar suas execuções.

A geração de um sinal ocorre quando o sistema operacional, a partir da ocorrência de eventos síncronos ou assíncronos, notifica ao processo através de bits de sinalização localizados no seu PCB. Um processo não responde instantaneamente a um sinal. Os sinais ficam pendentes até que o processo seja escalonado, quando então serão tratados. Por exemplo, quando um processo é eliminado o sistema ativa o bit associado a este evento. O processo somente será excluído do sistema quando for selecionado para execução. Neste caso, é possível que o processo demore algum tempo até ser eliminado de fato.

O tratamento de um sinal é muito semelhante ao mecanismo de interrupções. Quando um sinal é tratado, o contexto do processo é salvo e a execução desviada para um código de tratamento de sinal (signal handler), geralmente no núcleo do sistema. Após a execução do tratador de sinais, o programa pode voltar a ser processado do ponto onde foi interrompido. Em certas implementações, o próprio processo pode tratar o sinal através de um tratador de sinais definido no código programa. É possível também que um processo bloqueie temporariamente ou ignore por completo alguns sinais.

O mecanismo de sinais assemelha-se ao tratamento de interrupções e exceções vistos no Capítulo 3 — Concorrência, porém com propósitos diferentes. O sinal está para o processo assim como as interrupções e exceções estão para o sistema operacional (Fig. 5.18).

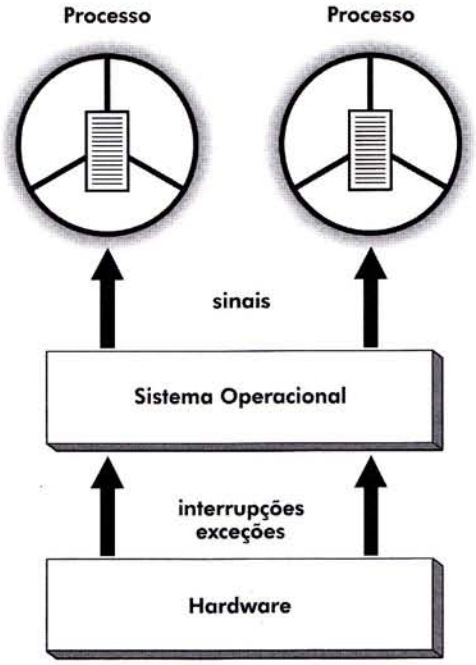

Fig. 5.18 Sinais, interrupções e exceções.

5.12 Exercícios

1. Defina o conceito de processo.
2. Por que o conceito de processo é tão importante no projeto de sistemas multiprogramáveis?
3. É possível que um programa execute no contexto de um processo e não execute no contexto de um outro? Por quê?
4. Quais partes compõem um processo?
5. O que é o contexto de hardware de um processo e como é a implementação da troca de contexto?
6. Qual a função do contexto de software? Exemplifique cada grupo de informação.
7. O que é o espaço de endereçamento de um processo?
8. Como o sistema operacional implementa o conceito de processo? Qual a estrutura de dados indicada para organizar os diversos processos na memória principal?
9. Defina os cinco estados possíveis de um processo.
10. Dê um exemplo que apresente todas as mudanças de estado de um processo, juntamente com o evento associado a cada mudança.
11. Diferencie processos multithreads, subprocessos e processos independentes.
12. Explique a diferença entre processos foreground e background.
13. Qual a relação entre processo e arquitetura microkernel?
14. Dê exemplos de aplicações CPU-bound e I/O-bound.
15. Justifique com um exemplo a frase "o sinal está para o processo assim como as interrupções e exceções estão para o sistema operacional".
16. Explique como a eliminação de um processo utiliza o mecanismo de sinais.

5.13 Laboratório com o Simulador SOsim

Atividade 1: Criação de Processos

a) Práticas de simulação

- Execute o simulador SOsim e identifique as quatro janelas que são abertas na inicialização.
- Crie um processo: janela *Gerência de Processos / Criar* – janela *Criação de Processos / Criar.*

b) Análise prática

- Na janela *Gerência de Processos*, observe algumas informações sobre o contexto de software do processo como PID, prioridade, estado do processo e tempo de processador.
- Na janela *Gerência de Processador*, observe o processo transicionado entre estados.
- Na janela *Gerência de Processador*, movimente a barra de *Clock de UCP* e observe as variações ocorridas.

c) Questão teórica para responder com a ajuda do simulador

Com base na observação do comportamento do processo criado, identifique se o processo é I/O-bound ou CPU-bound. Justifique a resposta.

Atividade 2: Tipos de Processos

a) Práticas de simulação

- Reinicialize o simulador.
- Crie um processo do tipo CPU-bound: janela *Gerência de Processos / Criar* – janela *Criação de Processos / Criar (tipo de processo deve ser CPU-bound).*
- Crie outro processo do tipo I/O-bound: janela *Gerência de Processos / Cria* – janela *Criação de Processos / Criar (tipo de processo deve ser I/O-bound).*

b) Análise prática

- Na janela *Gerência de Processos*, observe as mudanças de estado dos dois processos.
- Na janela *Gerência de Processador*, observe o comportamento dos processos e as mudanças de contexto em função do tipo I/O-bound e CPU-bound.
- Na janela *Gerência de Processos*, compare a taxa de crescimento do tempo de processador dos dois processos.

c) Questão teórica para responder com a ajuda do simulador

Analise os efeitos gerados no caso de redução do tempo gasto na operação de E/S pelo processo I/O-bound.

Atividade 3: PCB

a) Práticas de simulação

- Reinicialize o simulador.
- Crie dois novos processos: janela *Gerência de Processos / Criar* – janela *Criação de Processos / Criar.*

b) Análise prática

- Na janela *Gerência de Processos / PCB*, observe as informações sobre o contexto de software e hardware dos processos criados.

c) Questão teórica para responder com a ajuda do simulador

Identifique quais informações do PCB são estáticas ou dinâmicas e quais fazem parte do contexto de software e do contexto de hardware.

Atividade 4: Estatísticas

a) Práticas de simulação

- Reinicialize o simulador.
- Ative a janela de Estatísticas em *Console SOsim / Janelas / Estatísticas.*
- Crie dois novos processos: janela *Gerência de Processos / Criar* – janela *Criação de Processos / Criar.*

Atividade 2: Tipos de Processos

a) Práticas de simulação

- Reinicialize o simulador.
- Crie um processo do tipo CPU-bound: janela *Gerência de Processos / Criar* – janela *Criação de Processos / Criar (tipo de processo deve ser CPU-bound).*
- Crie outro processo do tipo I/O-bound: janela *Gerência de Processos / Cria* – janela *Criação de Processos / Criar (tipo de processo deve ser I/O-bound).*

b) Análise prática

- Na janela *Gerência de Processos*, observe as mudanças de estado dos dois processos.
- Na janela *Gerência de Processador*, observe o comportamento dos processos e as mudanças de contexto em função do tipo I/O-bound e CPU-bound.
- Na janela *Gerência de Processos*, compare a taxa de crescimento do tempo de processador dos dois processos.

c) Questão teórica para responder com a ajuda do simulador

Analise os efeitos gerados no caso de redução do tempo gasto na operação de E/S pelo processo I/O-bound.

Atividade 3: PCB

a) Práticas de simulação

- Reinicialize o simulador.
- Crie dois novos processos: janela *Gerência de Processos / Criar* – janela *Criação de Processos / Criar.*

b) Análise prática

- Na janela *Gerência de Processos / PCB*, observe as informações sobre o contexto de software e hardware dos processos criados.

c) Questão teórica para responder com a ajuda do simulador

Identifique quais informações do PCB são estáticas ou dinâmicas e quais fazem parte do contexto de software e do contexto de hardware.

Atividade 4: Estatísticas

a) Práticas de simulação

- Reinicialize o simulador.
- Ative a janela de Estatísticas em *Console SOsim / Janelas / Estatísticas.*
- Crie dois novos processos: janela *Gerência de Processos / Criar* – janela *Criação de Processos / Criar.*

b) Análise prática

- Na janela *Estatísticas,* observe as informações: número de processos, estados dos processos e processos escalonados.

c) Questão teórica para responder com a ajuda do simulador

Observe que em alguns momentos existem processos no estado de pronto, porém nenhum em estado de execução. Explique a razão dessa situação.

Atividade 5: Log de Execução dos Processos

a) Práticas de simulação

- Reinicialize o simulador.
- Ative a janela de Log em *Console SOsim / Janelas / Log.*
- Crie dois novos processos do tipo CPU-bound: janela *Gerência de Processos / Cria* — janela *Criação de Processos / Criar (tipo de processo deve ser CPU-bound).*

b) Análise prática

- Na janela *Log,* observe as informações sobre as mudanças de estado dos processos levando em conta o tempo que cada processo permanece nos estados de Execução e Pronto.
- Configure o simulador com um valor de fatia de tempo diferente.
- Reinicie o simulador SOsim para que a nova parametrização passe a ser válida.
- Observe as diferenças na janela *Log.*

c) Questão teórica para responder usando o simulador

Analise comparativamente a concorrência de dois processos CPU-bound executando em dois sistemas operacionais que se diferenciam apenas pelo valor da fatia de tempo.

Atividade 6: Suspensão e Eliminação de Processos

a) Práticas de simulação

- Reinicialize o simulador.
- Crie dois novos processos: janela *Gerência de Processos / Cria* – janela *Criação de Processos / Criar.*

b) Análise prática

- Na janela *Gerência de Processos,* observe as informações sobre o contexto de software dos processos criados.
- Na janela *Gerência de Processador,* observe a concorrência no uso do processador pelos dois processos.
- Compare percentualmente os tempos de uso do processador entre os dois processos.

- Suspenda temporariamente um dos processos na janela *Gerência de Processos/ Suspender.*
- Observe os estados dos processos, a concorrência no uso do processador e novamente compare percentualmente os tempos de uso do processador entre os dois processos.
- Libere o processo do estado de espera (suspenso) na janela *Gerência de Processos/Prosseguir.*
- Elimine um dos processos na janela *Gerência de Processos/Finalizar.*

c) Questão teórica para responder com a ajuda do simulador

Ao se eliminar um processo em estado de suspenso, o processo não é eliminado imediatamente. Reproduza essa situação no simulador e explique a razão da situação.

6

THREAD

6.1 Introdução

Até o final da década de 1970, sistemas operacionais, como Tops-10 (DEC), MVS (IBM) e Unix (Bell Labs), suportavam apenas processos com um único thread (monothread), ou seja, um processo com apenas um único programa fazendo parte do seu contexto. Em 1979, durante o desenvolvimento do sistema operacional Toth, foi introduzido o conceito de processos lightweight (peso leve), onde o espaço de endereçamento de um processo era compartilhado por vários programas. Apesar do conceito revolucionário, a idéia não foi utilizada comercialmente, e somente em meados de 1980, com o desenvolvimento do sistema operacional Mach na Universidade de Carnegie Mellon, ficou clara a separação entre o conceito de processo e thread.

A partir do conceito de múltiplos threads (multithread) é possível projetar e implementar aplicações concorrentes de forma eficiente, pois um processo pode ter partes diferentes do seu código sendo executadas em paralelo, com um menor overhead do que utilizando múltiplos processos. Como os threads de um mesmo processo compartilham o mesmo espaço de endereçamento, a comunicação entre threads não envolve mecanismos lentos de intercomunicação entre processos, aumentando, conseqüentemente, o desempenho da aplicação.

O desenvolvimento de programas que exploram os benefícios da programação multithread não é simples. A presença do paralelismo introduz um novo conjunto de problemas como a comunicação e sincronização de threads. Existem diferentes modelos para a implementação de threads em um sistema operacional, onde desempenho, flexibilidade e custo devem ser avaliados.

Atualmente, o conceito de multithread pode ser encontrado em diversos sistemas operacionais, como no Sun Solaris e Microsoft Windows 2000. A utilização comercial de sistemas operacionais multithread é crescente em função do aumento de popularidade dos sistemas com múltiplos processadores, do modelo cliente-servidor e dos sistemas distribuídos.

6.2 Ambiente Monothread

Um programa é uma seqüência de instruções, composta por desvios, repetições e chamadas a procedimentos e funções. Em um *ambiente monothread*, um processo

suporta apenas um programa no seu espaço de endereçamento. Neste ambiente, aplicações concorrentes são implementadas apenas com o uso de múltiplos processos independentes ou subprocessos.

A utilização de processos independentes e subprocessos permite dividir uma aplicação em partes que podem trabalhar de forma concorrente. Um exemplo do uso de concorrência pode ser encontrado nas aplicações com interface gráfica, como em um software de gerenciamento de e-mails. Neste ambiente, um usuário pode estar lendo suas mensagens antigas, ao mesmo tempo que pode estar enviando e-mails e recebendo novas mensagens. Com o uso de múltiplos processos, cada funcionalidade do software implicaria a criação de um novo processo para atendê-la, aumentando o desempenho da aplicação (Fig. 6.1).

O problema neste tipo de implementação é que o uso de processos no desenvolvimento de aplicações concorrentes demanda consumo de diversos recursos do sistema. Sempre que um novo processo é criado, o sistema deve alocar recursos para cada processo, consumindo tempo de processador neste trabalho. No caso do término do processo, o sistema dispensa tempo para desalocar recursos previamente alocados.

Outro problema a ser considerado é quanto ao compartilhamento do espaço de endereçamento. Como cada processo possui seu próprio espaço de endereçamento, a comunicação entre processos torna-se difícil e lenta, pois utiliza mecanismos como pipes, sinais, semáforos, memória compartilhada ou troca de mensagem. Além disto, o compartilhamento de recursos comuns aos processos concorrentes, como memória e arquivos abertos, não é simples. Na Fig. 6.2 existem três processos monothreads,

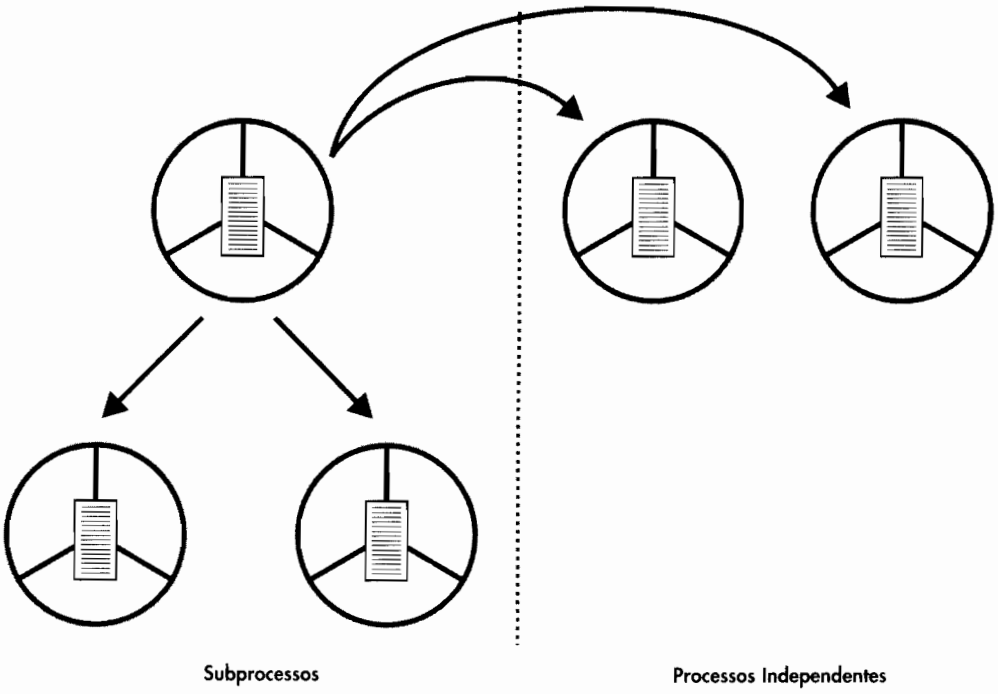

Fig. 6.1 Concorrência com subprocessos e processos independentes.

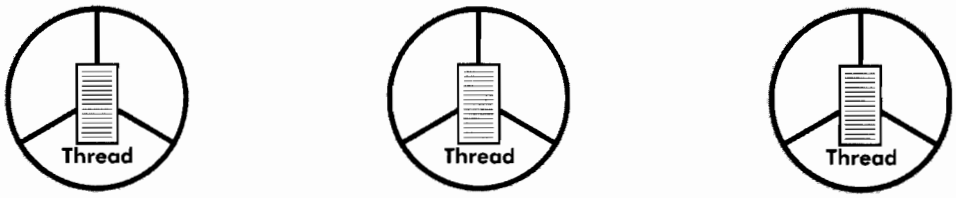

Fig. 6.2 Ambiente monothread.

cada um com seu próprio contexto de hardware, contexto de software e espaço de endereçamento.

São exemplos de sistemas monothread o Microsoft MS-DOS e as primeiras versões do MS-Windows. Mesmo em ambientes multiprogramáveis e multiusuário, encontramos exemplos de implementações monothread, como nas versões mais antigas dos sistemas VAX VMS e Unix.

6.3 Ambiente Multithread

Em um *ambiente multithread*, ou seja, com múltiplos threads, não existe a idéia de programas associados a processos, mas, sim, a threads. O processo, neste ambiente, tem pelo menos um thread de execução, mas pode compartilhar o seu espaço de endereçamento com inúmeros outros threads. Na Fig. 6.3 existe apenas um processo com três threads de execução compartilhando o mesmo espaço de endereçamento.

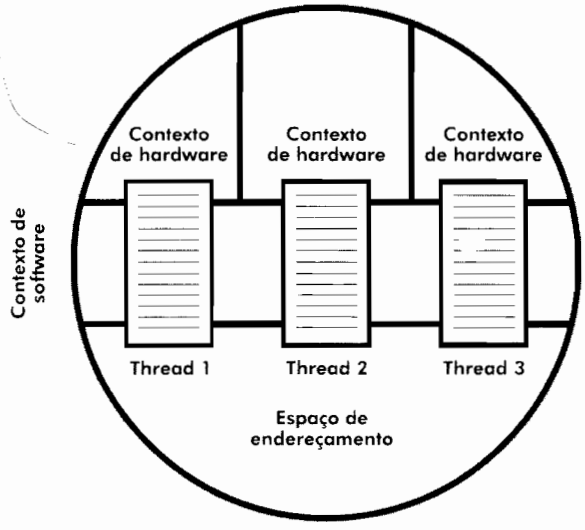

Fig. 6.3 Ambiente multithread.

De forma simplificada, um thread pode ser definido como uma sub-rotina de um programa que pode ser executada de forma assíncrona, ou seja, executada paralelamente ao programa chamador. O programador deve especificar os threads, associando-os às sub-rotinas assíncronas. Desta forma, um ambiente multithread possibilita a execução concorrente de sub-rotinas dentro de um mesmo processo.

Na Fig. 6.4 existe um programa principal que realiza a chamada de duas sub-rotinas assíncronas (Sub_1 e Sub_2). Inicialmente, o processo é criado apenas com o Thread_1 para a execução do programa principal. Quando o programa principal chama as sub-rotinas Sub_1 e Sub_2, são criados os Thread_2 e Thread_3, respectivamente, e executados independentemente do programa principal. Neste processo, os três threads são executados concorrentemente.

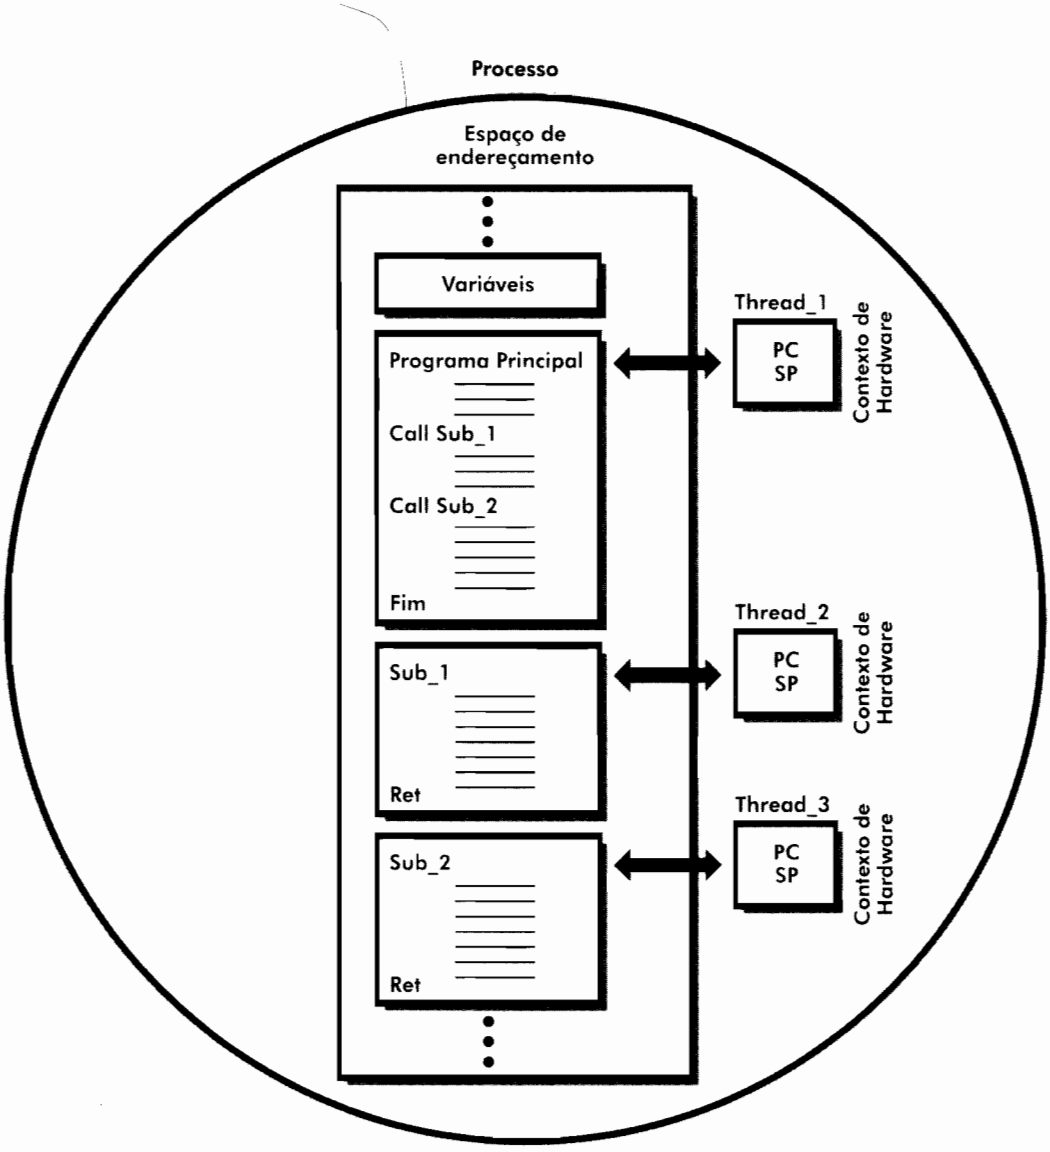

Fig. 6.4 Aplicação Multithread (a).

No ambiente multithread, cada processo pode responder a várias solicitações concorrentemente ou mesmo simultaneamente, caso haja mais de um processador. A grande vantagem no uso de threads é a possibilidade de minimizar a alocação de recursos do sistema, além de diminuir o overhead na criação, troca e eliminação de processos.

Threads compartilham o processador da mesma maneira que processos e passam pelas mesmas mudanças de estado (execução, espera e pronto). Por exemplo, enquanto um thread espera por uma operação de E/S, outro thread pode ser executado. Para permitir a troca de contexto entre os diversos threads, cada thread possui seu próprio contexto de hardware, com o conteúdo dos registradores gerais, PC e SP. Quando um thread está sendo executado, seu contexto de hardware está armazenado nos registradores do processador. No momento em que o thread perde a utilização da UCP, as informações são atualizadas no seu contexto de hardware.

Dentro de um mesmo processo, threads compartilham o mesmo contexto de software e espaço de endereçamento com os demais threads, porém cada thread possui seu contexto de hardware individual. Threads são implementados internamente através de uma estrutura de dados denominada *bloco de controle do thread* (*Thread Control Block — TCB*). O TCB armazena, além do contexto de hardware, mais algumas informações relacionadas exclusivamente ao thread, como prioridade, estado de execução e bits de estado.

Em ambientes monothread, o processo é ao mesmo tempo a unidade de alocação de recursos e a unidade de escalonamento. A independência entre os conceitos de processo e thread permite separar a unidade de alocação de recursos da unidade de escalonamento, que em ambientes monothread estão fortemente relacionadas. Em um ambiente multithread, a unidade de alocação de recursos é o processo, onde todos os seus threads compartilham o espaço de endereçamento, descritores de arquivos e dispositivos de E/S. Por outro lado, cada thread representa uma unidade de escalonamento independente. Neste caso, o sistema não seleciona um processo para a execução, mas sim um de seus threads.

A grande diferença entre aplicações monothread e multithread está no uso do espaço de endereçamento. Processos independentes e subprocessos possuem espaços de endereçamento individuais e protegidos, enquanto threads compartilham o espaço dentro de um mesmo processo. Esta característica permite que o compartilhamento de dados entre threads de um mesmo processo seja mais simples e rápido, se comparado a ambientes monothread.

Como threads de um mesmo processo compartilham o mesmo espaço de endereçamento, não existe qualquer proteção no acesso à memória, permitindo que um thread possa alterar facilmente dados de outros. Para que threads trabalhem de forma cooperativa, é fundamental que a aplicação implemente mecanismos de comunicação e sincronização entre threads, a fim de garantir o acesso seguro aos dados compartilhados na memória.

O uso de multithreads proporciona uma série de benefícios. Programas concorrentes com múltiplos threads são mais rápidos do que programas concorrentes implementados com múltiplos processos, pois operações de criação, troca de contexto e eliminação dos threads geram menor overhead (Tabela 6.1). Como os threads dentro de um processo dividem o mesmo espaço de endereçamento, a comunicação entre eles

Tabela 6.1 Latência de processos e threads (Vahalia, 1996)

Implementação	Tempo de Criação (μs)	Tempo de Sincronização (μs)
Processo	1700	200
Processo Lightweight	350	390
Thread	52	66

pode ser realizada de forma rápida e eficiente. Além disso, threads em um mesmo processo podem compartilhar facilmente outros recursos, como descritores de arquivos, temporizadores, sinais, atributos de segurança etc.

A utilização do processador, dos discos e de outros periféricos pode ser feita de forma concorrente pelos diversos threads, significando melhor utilização dos recursos computacionais disponíveis. Em algumas aplicações, a utilização de threads pode melhorar o desempenho da aplicação apenas executando tarefas em background enquanto operações E/S estão sendo processadas (Fig. 6.5). Aplicações como editores

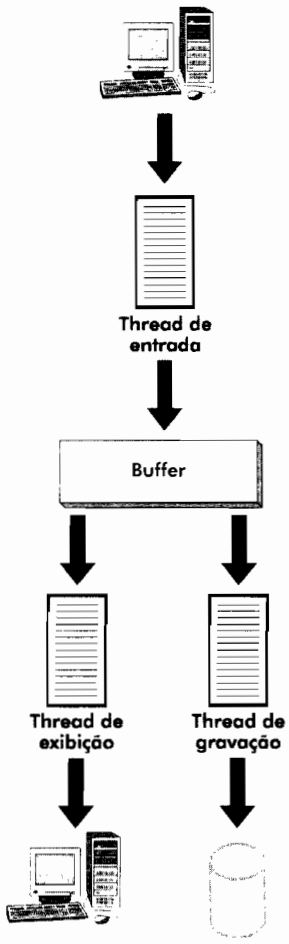

Fig. 6.5 Aplicação multithread (b).

de texto, planilhas, aplicativos gráficos e processadores de imagens são especialmente beneficiados quando desenvolvidos com base em threads.

Em ambientes cliente-servidor, threads são essenciais para solicitações de serviços remotos. Em um ambiente monothread, se uma aplicação solicita um serviço remoto, ela pode ficar esperando indefinidamente, enquanto aguarda pelo resultado. Em um ambiente multithread, um thread pode solicitar o serviço remoto, enquanto a aplicação pode continuar realizando outras atividades. Já para o processo que atende a solicitação, múltiplos threads permitem que diversos pedidos sejam atendidos simultaneamente (Fig. 6.6).

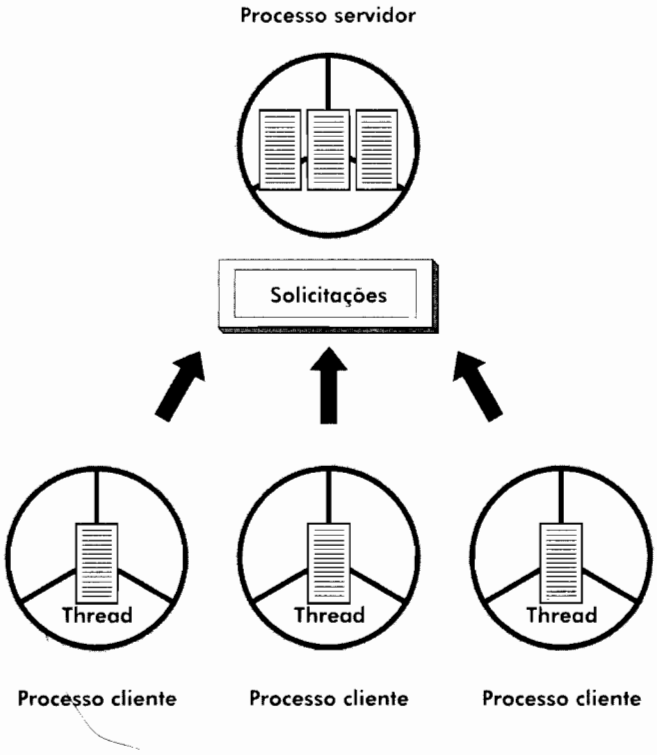

Fig. 6.6 Aplicação multithread (c).

Não apenas aplicações tradicionais podem fazer uso dos benefícios do multithreading. O núcleo do sistema operacional também pode ser implementado com o uso desta técnica de forma vantajosa, como na arquitetura microkernel, apresentada no capítulo Estrutura do Sistema Operacional.

6.4 Arquitetura e Implementação

O conjunto de rotinas disponíveis para que uma aplicação utilize as facilidades dos threads é chamado de *pacote de threads*. Existem diferentes abordagens na implementação deste pacote em um sistema operacional, o que influenciará no desempenho, na concorrência e na modularidade das aplicações multithread.

Threads podem ser oferecidos por uma biblioteca de rotinas fora do núcleo do sistema operacional (modo usuário), pelo próprio núcleo do sistema (modo kernel), por uma combinação de ambos (modo híbrido) ou por um modelo conhecido como scheduler activations. A Tabela 6.2 resume as diversas arquiteturas para diferentes ambientes operacionais.

Tabela 6.2 Arquitetura de threads para diversos ambientes operacionais

Ambientes	Arquitetura
Distributed Computing Environment (DCE)	Modo usuário
Compaq OpenVMS versão 6	Modo usuário
Microsoft Windows 2000	Modo kernel
Compaq Unix	Modo kernel
Compaq OpenVMS versão 7	Modo kernel
Sun Solaris versão 2	Modo híbrido
University of Washington FastThreads	Scheduler activations

Uma das grandes dificuldades para a utilização de threads foi a ausência de um padrão. Em 1995, o padrão POSIX P1003.1c foi aprovado e posteriormente atualizado para a versão POSIX 1003.4a. Com este padrão, também conhecido como Pthreads, aplicações comerciais multithreading tornaram-se mais simples e de fácil implementação. O padrão Pthreads é largamente utilizado em ambientes Unix, como o Sun Solaris Pthreads e o DECthreads para Digital OSF/1.

6.4.1 Threads em Modo Usuário

Threads em modo usuário (TMU) são implementados pela aplicação e não pelo sistema operacional. Para isso, deve existir uma biblioteca de rotinas que possibilite à aplicação realizar tarefas como criação/eliminação de threads, troca de mensagens entre threads e uma política de escalonamento. Neste modo, o sistema operacional não sabe da existência de múltiplos threads, sendo responsabilidade exclusiva da aplicação gerenciar e sincronizar os diversos threads existentes.

A vantagem deste modelo é a possibilidade de implementar aplicações multithreads mesmo em sistemas operacionais que não suportam threads. Utilizando a biblioteca, múltiplos threads podem ser criados, compartilhando o mesmo espaço de endereçamento do processo, além de outros recursos (Fig. 6.7). TMU são rápidos e eficientes por dispensarem acessos ao kernel do sistema operacional, evitando assim a mudança de modo de acesso (usuário-kernel-usuário).

TMU possuem uma grande limitação, pois o sistema operacional gerencia cada processo como se existisse apenas um único thread. No momento em que um thread chama uma rotina do sistema que o coloca em estado de espera (rotina bloqueante), todo o processo é colocado no estado de espera, mesmo havendo outros threads prontos para execução. Para contornar esta limitação, a biblioteca tem que possuir rotinas que substituam as rotinas bloqueantes por outras que não possam causar o

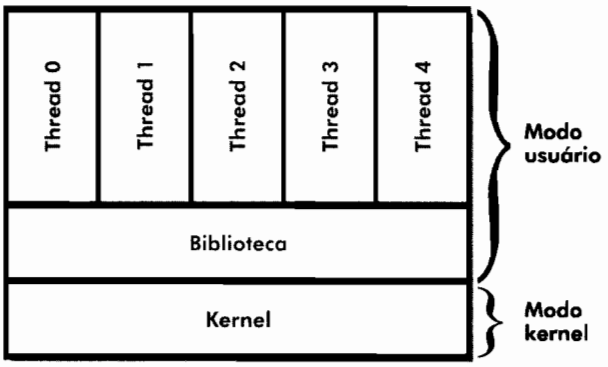

Fig. 6.7 Threads em modo usuário.

bloqueio de um thread (rotinas não-bloqueantes). Todo este controle é transparente para o usuário e para o sistema operacional.

Talvez um dos maiores problemas na implementação de TMU seja o tratamento individual de sinais. Como o sistema reconhece apenas processos e não threads, os sinais enviados para um processo devem ser reconhecidos e encaminhados a cada thread para tratamento. No caso do recebimento de interrupções de clock, fundamental para a implementação do tempo compartilhado, esta limitação é crítica. Neste caso, os sinais de temporização devem ser interceptados, para que se possa interromper o thread em execução e realizar a troca de contexto.

Em relação ao escalonamento em ambientes com múltiplos processadores, não é possível que múltiplos threads de um processo possam ser executados em diferentes UCPs simultaneamente, pois o sistema seleciona apenas processos para execução e não threads. Esta restrição limita drasticamente o grau de paralelismo da aplicação, já que os threads de um mesmo processo podem ser executados em somente um processador de cada vez.

6.4.2 Threads em Modo Kernel

Threads em modo kernel (TMK) são implementados diretamente pelo núcleo do sistema operacional, através de chamadas a rotinas do sistema que oferecem todas as funções de gerenciamento e sincronização (Fig. 6.8). O sistema operacional sabe da existência de cada thread e pode escaloná-los individualmente. No caso de múltiplos processadores, os threads de um mesmo processo podem ser executados simultaneamente.

O grande problema para pacotes em modo kernel é o seu baixo desempenho. Enquanto nos pacotes em modo usuário todo tratamento é feito sem a ajuda do sistema operacional, ou seja, sem a mudança do modo de acesso (usuário-kernel-usuário), pacotes em modo kernel utilizam chamadas a rotinas do sistema e, conseqüentemente, várias mudanças no modo de acesso. A Tabela 6.3 compara o desempenho de duas operações distintas envolvendo a criação, escalonamento, execução e eliminação de um processo/thread.

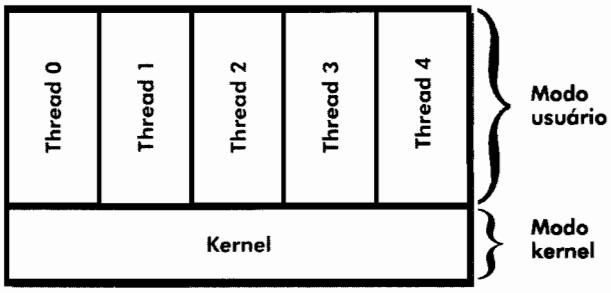

Fig. 6.8 Threads em modo kernel.

Tabela 6.3 Comparação entre tempos de latência (Anderson et al., 1992)

Implementação	Operação 1 (μs)	Operação 2 (μs)
Subprocessos	11.300	1.840
Threads em Modo Kernel	948	441
Threads em Modo Usuário	34	37

6.4.3 Threads em Modo Híbrido

A arquitetura de *threads em modo híbrido* combina as vantagens de threads implementados em modo usuário (TMU) e threads em modo kernel (TMK). Um processo pode ter vários TMK e, por sua vez, um TMK pode ter vários TMU. O núcleo do sistema reconhece os TMK e pode escaloná-los individualmente. Um TMU pode ser executado em um TMK, em um determinado momento, e no instante seguinte ser executado em outro.

O programador desenvolve a aplicação em termos de TMU e especifica quantos TMK estão associados ao processo. Os TMU são mapeados em TMK enquanto o processo está sendo executado. O programador pode utilizar apenas TMK, TMU ou uma combinação de ambos (Fig. 6.9).

O modo híbrido, apesar da maior flexibilidade, apresenta problemas herdados de ambas as implementações. Por exemplo, quando um TMK realiza uma chamada bloqueante, todos os TMU são colocados no estado de espera. TMU que desejam utilizar vários processadores devem utilizar diferentes TMK, o que influenciará no desempenho.

6.4.4 Scheduler Activations

Os problemas apresentados no pacote de threads em modo híbrido existem devido à falta de comunicação entre os threads em modo usuário e em modo kernel. O modelo ideal deveria utilizar as facilidades do pacote em modo kernel com o desempenho e flexibilidade do modo usuário.

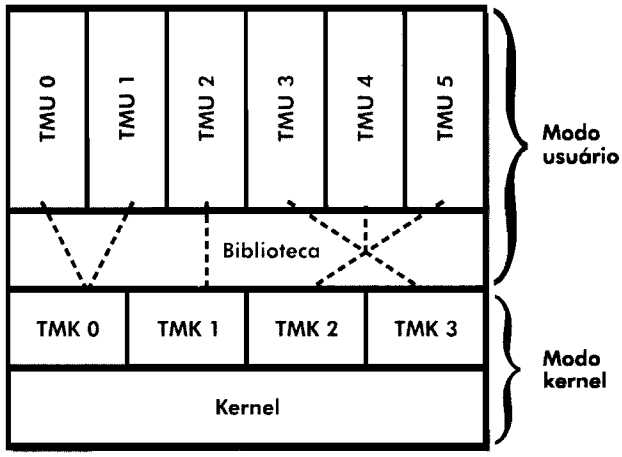

Fig. 6.9 Threads em modo híbrido.

Introduzido no início da década de 1990 na Universidade de Washington, este pacote combina o melhor das duas arquiteturas, mas em vez de dividir os threads em modo usuário entre os de modo kernel, o núcleo do sistema troca informações com a biblioteca de threads utilizando uma estrutura de dados chamada *scheduler activations* (Fig. 6.10).

A maneira de alcançar um melhor desempenho é evitar as mudanças de modos de acesso desnecessárias (usuário-kernel-usuário). Caso um thread utilize uma chamada ao sistema que o coloque no estado de espera, não é necessário que o kernel seja ativado, bastando que a própria biblioteca em modo usuário escalone outro thread. Isto é possível porque a biblioteca em modo usuário e o kernel se comunicam e trabalham de forma cooperativa. Cada camada implementa seu escalonamento de forma independente, porém trocando informações quando necessário.

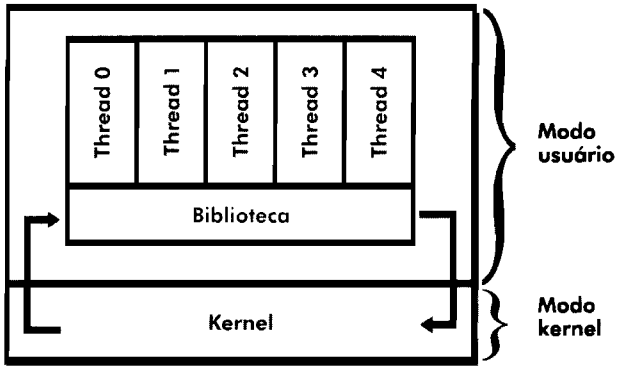

Fig. 6.10 Scheduler activations.

6.5 Modelos de Programação

O desenvolvimento de aplicações multithread não é simples, pois exige que a comunicação e o compartilhamento de recursos entre os diversos threads seja feito de forma sincronizada para evitar problemas de inconsistências e deadlock. Além das dificuldades naturais no desenvolvimento de aplicações concorrentes, o procedimento de depuração é bastante complexo.

Um fator importante em aplicações multithread é o número total de threads e a forma como são criados e eliminados. Se uma aplicação cria um número excessivo de threads, poderá ocorrer um overhead no sistema, ocasionando uma queda de desempenho.

Dependendo da implementação, a definição do número de threads pode ser dinâmica ou estática. Quando a criação/eliminação é dinâmica, os threads são criados/eliminados conforme a demanda da aplicação, oferecendo grande flexibilidade. Já em ambientes estáticos, o número de threads é definido na criação do processo onde a aplicação será executada.

Para obter os benefícios do uso de threads, uma aplicação deve permitir que partes diferentes do seu código sejam executadas em paralelo de forma independente. Se um aplicativo realiza várias operações de E/S e trata eventos assíncronos, a programação multithread aumenta seu desempenho até mesmo em ambientes com um único processador. Sistemas gerenciadores de banco de dados (SGBDs), servidores de arquivos ou impressão são exemplos onde o uso de múltiplos threads proporciona grandes vantagens e benefícios.

6.6 Exercícios

1. Como uma aplicação pode implementar concorrência em um ambiente monothread?
2. Quais os problemas de aplicações concorrentes desenvolvidas em ambientes monothread?
3. O que é um ambiente multithread e quais as vantagens de sua utilização?
4. Explique a diferença entre unidade de alocação de recursos e unidade de escalonamento.
5. Quais as vantagens e desvantagens do compartilhamento do espaço de endereçamento entre threads de um mesmo processo?
6. Compare os pacotes de threads em modo usuário e modo kernel.
7. Qual a vantagem do scheduler activations comparado ao pacote híbrido?
8. Dê exemplos do uso de threads no desenvolvimento de aplicativos como editores de textos e planilhas eletrônicas.
9. Como o uso de threads pode melhorar o desempenho de aplicações paralelas em ambientes com múltiplos processadores?
10. Quais os benefícios do uso de threads em ambientes cliente-servidor?
11. Como o uso de threads pode ser útil em arquiteturas microkernel?

7

SINCRONIZAÇÃO E COMUNICAÇÃO ENTRE PROCESSOS

7.1 Introdução

Na década de 1960, com o surgimento dos sistemas multiprogramáveis, passou a ser possível estruturar aplicações de maneira que partes diferentes do código do programa pudessem executar concorrentemente. Este tipo de aplicação, denominado *aplicação concorrente*, tem como base a execução cooperativa de múltiplos processos ou threads, que trabalham em uma mesma tarefa na busca de um resultado comum.

Em um sistema multiprogramável com único processador, os processos alternam sua execução segundo critérios de escalonamento estabelecidos pelo sistema operacional. Mesmo não havendo neste tipo de sistema um paralelismo na execução de instruções, uma aplicação concorrente pode obter melhoras no seu desempenho. Em sistemas com múltiplos processadores, a possibilidade do paralelismo na execução de instruções somente estende as vantagens que a programação concorrente proporciona.

É natural que processos de uma aplicação concorrente compartilhem recursos do sistema, como arquivos, registros, dispositivos de E/S e áreas de memória. O compartilhamento de recursos entre processos pode ocasionar situações indesejáveis, capazes até de comprometer a execução das aplicações. Para evitar esse tipo de problema, os processos concorrentes devem ter suas execuções sincronizadas, a partir de mecanismos oferecidos pelo sistema operacional, com o objetivo de garantir o processamento correto dos programas.

Este capítulo apresenta como a concorrência de processos pode ser implementada, os problemas do compartilhamento de recursos, soluções e mecanismos do sistema operacional para sincronizar processos como semáforos e monitores. No final do capítulo é também apresentado o problema do deadlock, suas conseqüências e análise de soluções.

7.2 Aplicações Concorrentes

Muitas vezes, em uma aplicação concorrente, é necessário que processos comuniquem-se entre si. Esta comunicação pode ser implementada através de diversos meca-

nismos, como variáveis compartilhadas na memória principal ou trocas de mensagens. Nesta situação, é necessário que os processos concorrentes tenham sua execução sincronizada através de mecanismos do sistema operacional.

A Fig. 7.1 apresenta um exemplo onde dois processos concorrentes compartilham um buffer para trocar informações através de operações de gravação e leitura. Neste exemplo, um processo só poderá gravar dados no buffer caso este não esteja cheio. Da mesma forma, um processo só poderá ler dados armazenados do buffer caso exista algum dado para ser lido. Em ambas as situações, os processos deverão aguardar até que o buffer esteja pronto para as operações, seja de gravação, seja de leitura.

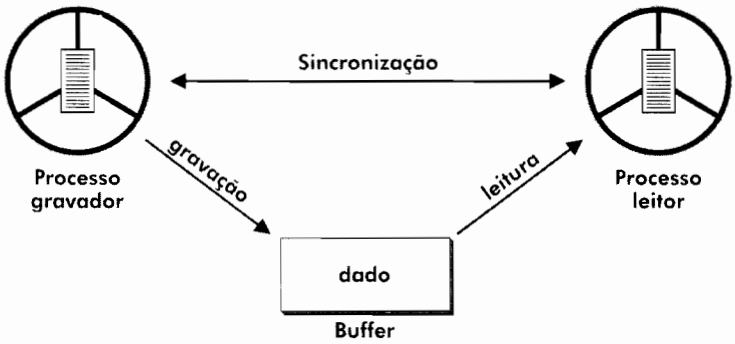

Fig. 7.1 Sincronização e comunicação entre processos.

Os mecanismos que garantem a comunicação entre processos concorrentes e o acesso a recursos compartilhados são chamados *mecanismos de sincronização*. No projeto de sistemas operacionais multiprogramáveis, é fundamental a implementação destes mecanismos para garantir a integridade e a confiabilidade na execução de aplicações concorrentes.

Apesar de o termo processo ser utilizado na exemplificação de aplicações concorrentes, os termos subprocesso e thread têm o mesmo significado nesta abordagem.

7.3 Especificação de Concorrência em Programas

Existem várias notações utilizadas para especificar a concorrência em programas, ou seja, as partes de um programa que devem ser executadas concorrentemente. As técnicas mais recentes tentam expressar a concorrência no código dos programas de uma forma mais clara e estruturada.

A primeira notação para a especificação da concorrência em um programa foram os comandos FORK e JOIN, introduzidos por Conway (1963) e Dennis e Van Horn (1966). O exemplo a seguir apresenta a implementação da concorrência em um programa com uma sintaxe simplificada:

```
PROGRAM A;          PROGRAM B;
    .                   .
    .                   .
    FORK B;             .
    .                   .
    .                   .
    JOIN B;         END.
    .
    .
END.
```

O programa A começa a ser executado e, ao encontrar o comando FORK, faz com que seja criado um outro processo para a execução do programa B, concorrentemente ao programa A. O comando JOIN permite que o programa A sincronize-se com B, ou seja, quando o programa A encontrar o comando JOIN, só continuará a ser processado após o término da execução do programa B. Os comandos FORK e JOIN são bastante poderosos e práticos, sendo utilizados de forma semelhante no sistema operacional Unix.

Uma das implementações mais claras e simples de expressar concorrência em um programa é a utilização dos comandos PARBEGIN e PAREND (Dijkstra, 1965a), que, posteriormente, foram chamados de COBEGIN e COEND. No decorrer deste capítulo, os comandos PARBEGIN e PAREND serão utilizados nos algoritmos apresentados.

O comando PARBEGIN especifica que a seqüência de comandos seja executada concorrentemente em uma ordem imprevisível, através da criação de um processo (Processo_1, Processo_2, Processo_n) para cada comando (Comando_1, Comando_2, Comando_n). O comando PAREND define um ponto de sincronização, onde o processamento só continuará quando todos os processos ou threads criados já tiverem terminado suas execuções. Os comandos delimitados pelos comandos PARBEGIN e PAREND podem ser comandos simples, como atribuições ou chamadas a procedimentos (Fig. 7.2).

Para exemplificar o funcionamento dos comandos PARBEGIN e PAREND em uma aplicação concorrente, o programa Expressao realiza o cálculo do valor da expressão aritmética descrita a seguir:

```
X := SQRT (1024) + (35.4 * 0.23) - (302 / 7)
```

Os comandos de atribuição situados entre PARBEGIN e PAREND são executados concorrentemente. O cálculo final de X só pode ser realizado quando todas as variáveis dentro da estrutura tiverem sido calculadas.

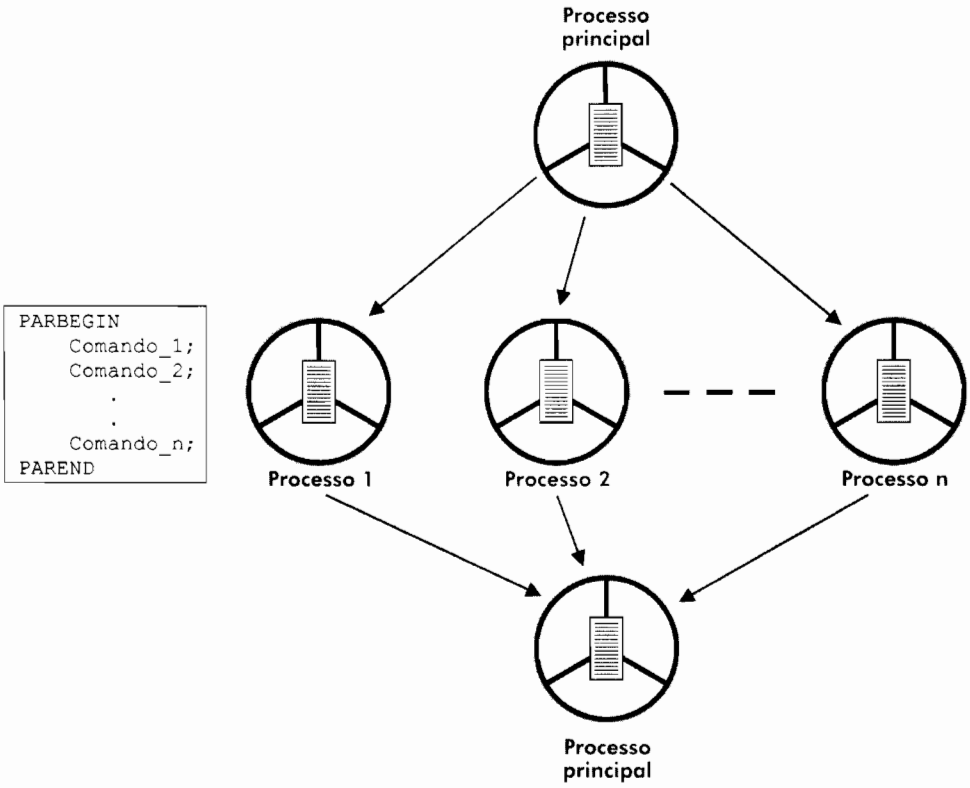

Fig. 7.2 Concorrência em programas.

```
PROGRAM Expressao;
    VAR X, Temp1, Temp2, Temp3 : REAL;
BEGIN
    PARBEGIN
        Temp1 := SQRT (1024);
        Temp2 := 35.4 * 0.23;
        Temp3 := 302 / 7;
    PAREND;
    X := Temp1 + Temp2 - Temp3;
    WRITELN ('x = ', X);
END.
```

7.4 Problemas de Compartilhamento de Recursos

Para a compreensão de como a sincronização entre processos concorrentes é fundamental para a confiabilidade dos sistemas multiprogramáveis, são apresentados alguns problemas de compartilhamento de recursos. A primeira situação envolve o compartilhamento de um arquivo em disco; a segunda apresenta uma variável na memória principal sendo compartilhada por dois processos.

O primeiro problema é analisado a partir do programa Conta_Corrente, que atualiza o saldo bancário de um cliente após um lançamento de débito ou crédito no arquivo de contas-correntes Arq_Contas. Neste arquivo são armazenados os saldos de todos os

correntistas do banco. O programa lê o registro do cliente no arquivo (Reg_Cliente), lê o valor a ser depositado ou retirado (Valor_Dep_Ret) e, em seguida, atualiza o saldo no arquivo de contas.

```
PROGRAM Conta_Corrente;
    .
    .
    READ (Arq_Contas, Reg_Cliente);
    READLN (Valor_Dep_Ret);
    Reg_Cliente.Saldo := Reg_Cliente.Saldo + Valor_Dep_Ret;
    WRITE (Arq_Contas, Reg_Cliente);
    .
    .
END.
```

Considerando processos concorrentes pertencentes a dois funcionários do banco que atualizam o saldo de um mesmo cliente simultaneamente, a situação de compartilhamento do recurso pode ser analisada. O processo do primeiro funcionário (Caixa 1) lê o registro do cliente e soma ao campo Saldo o valor do lançamento de débito. Antes de gravar o novo saldo no arquivo, o processo do segundo funcionário (Caixa 2) lê o registro do mesmo cliente, que está sendo atualizado, para realizar outro lançamento, desta vez de crédito. Independentemente de qual dos processos atualize primeiro o saldo no arquivo, o dado gravado estará inconsistente.

Caixa	Comando	Saldo arquivo	Valor dep/ret	Saldo memória
1	READ	1.000	*	1.000
1	READLN	1.000	-200	1.000
1	:=	1.000	-200	800
2	READ	1.000	*	1.000
2	READLN	1.000	+300	1.000
2	:=	1.000	+300	1.300
1	WRITE	800	-200	800
2	WRITE	1.300	+300	1.300

Um outro exemplo, ainda mais simples, onde o problema da concorrência pode levar a resultados inesperados, é a situação onde dois processos (A e B) executam um comando de atribuição. O Processo A soma 1 à variável X e o Processo B diminui 1 da mesma variável que está sendo compartilhada. Inicialmente, a variável X possui o valor 2.

```
Processo A        Processo B

X := X + 1 ;      X := X - 1;
```

Seria razoável pensar que o resultado final da variável X, após a execução dos Processos A e B, continuasse 2, porém isto nem sempre será verdade. Os comandos de atribuição, em uma linguagem de alto nível, podem ser decompostos em comandos mais elementares, como visto a seguir:

Processo A	Processo B
LOAD x,R_a	LOAD x,R_b
ADD 1,R_a	SUB 1,R_b
STORE R_a,x	STORE R_b,x

Considere que o Processo A carregue o valor de X no registrador R_a, some 1 e, no momento em que vai armazenar o valor em X, seja interrompido. Nesse instante, o Processo B inicia sua execução, carrega o valor de X em R_b e subtrai 1. Dessa vez, o Processo B é interrompido e o Processo A volta a ser processado, atribuindo o valor 3 à variável X e concluindo sua execução. Finalmente, o Processo B retorna a execução, atribui o valor 1 a X, e sobrepõe o valor anteriormente gravado pelo Processo A. O valor final da váriável X é inconsistente em função da forma concorrente com que os dois processos executaram.

Processo	Comando	X	R_a	R_b
A	LOAD X,R_a	2	2	*
A	ADD 1,R_a	2	3	*
B	LOAD X,R_b	2	*	2
B	SUB 1,R_b	2	*	1
A	STORE R_a,X	3	3	*
B	STORE R_b,X	1	*	1

Analisando os dois exemplos apresentados, é possível concluir que em qualquer situação, onde dois ou mais processos compartilham um mesmo recurso, devem existir mecanismos de controle para evitar esses tipos de problemas, conhecidos como *race conditions* (condições de corrida).

7.5 Exclusão Mútua

A solução mais simples para evitar os problemas de compartilhamento apresentados no item anterior é impedir que dois ou mais processos acessem um mesmo recurso simultaneamente. Para isso, enquanto um processo estiver acessando determinado recurso, todos os demais processos que queiram acessá-lo deverão esperar pelo término da utilização do recurso. Essa idéia de exclusividade de acesso é chamada *exclusão mútua* (*mutual exclusion*).

A exclusão mútua deve afetar apenas os processos concorrentes somente quando um deles estiver fazendo acesso ao recurso compartilhado. A parte do código do programa onde é feito o acesso ao recurso compartilhado é denominada *região crítica* (*critical region*). Se for possível evitar que dois processos entrem em suas regiões críticas ao mesmo tempo, ou seja, se for garantida a execução mutuamente exclusiva das regiões críticas, os problemas decorrentes do compartilhamento serão evitados.

Os mecanismos que implementam a exclusão mútua utilizam protocolos de acesso à região crítica. Toda vez que um processo desejar executar instruções de sua região crítica, obrigatoriamente deverá executar antes um protocolo de entrada nessa região. Da mesma forma, ao sair da região crítica um protocolo de saída deverá ser executado. Os protocolos de entrada e saída garantem a exclusão mútua da região crítica de um programa.

```
BEGIN
    .
    .
    Entra_Regiao_Critica ; (* Protocolo de Entrada *)
    Regiao_Critica;
    Sai_Regiao_Critica;  (* Protocolo de Saída *)
    .
    .
END.
```

Utilizando o programa Conta_Corrente apresentado no item anterior, a aplicação dos protocolos para dois processos (A e B) pode ser implementada no compartilhamento do arquivo de contas-correntes. Sempre que o Processo A for atualizar o saldo de um cliente, antes de ler o registro o acesso exclusivo ao arquivo deve ser garantido através do protocolo de entrada da sua região crítica. O protocolo indica se já existe ou não algum processo acessando o recurso. Caso o recurso esteja livre, o Processo A pode entrar em sua região crítica para realizar a atualização. Durante este período, caso o Processo B tente acessar o arquivo, o protocolo de entrada faz com que esse processo permaneça aguardando até que o Processo A termine o acesso ao recurso. Quando o Processo A terminar a execução de sua região crítica, deve sinalizar aos demais processos concorrentes que o acesso ao recurso foi concluído. Isso é realizado através do protocolo de saída, que informa aos outros processos que o recurso já está livre e pode ser utilizado de maneira exclusiva por um outro processo.

Como é possível, então, observar, para garantir a implementação da exclusão mútua os processos envolvidos devem fazer acesso aos recursos de forma sincronizada. Diversas soluções foram desenvolvidas com esse propósito; porém, além da garantia da exclusão mútua, duas situações indesejadas também devem ser evitadas.

A primeira situação indesejada é conhecida como *starvation* ou *espera indefinida*. Starvation é a situação em que um processo nunca consegue executar sua região crítica e, conseqüentemente, acessar o recurso compartilhado. No momento em que um recurso alocado é liberado, o sistema operacional possui um critério para selecionar, dentre os processos que aguardam pelo uso do recurso, qual será o escolhido. Em função do critério de escolha, o problema do starvation pode ocorrer. Os critérios de escolha aleatória ou com base em prioridades são exemplos de situações que podem gerar o problema. No primeiro caso, não é garantido que um processo em algum momento fará o uso do recurso, pois a seleção é randômica. No segundo caso, a baixa prioridade de um processo em relação aos demais pode impedir o processo de acessar o recurso compartilhado. Uma solução bastante simples para o problema é a criação de filas de pedidos de alocação para cada recurso, utilizando o esquema FIFO. Sempre que um processo solicita um recurso, o pedido é colocado no final da fila associada ao recurso. Quando o recurso é liberado, o sistema seleciona o primeiro processo da fila.

Outra situação indesejada na implementação da exclusão mútua é aquela em que um processo fora da sua região crítica impede que outros processos entrem nas suas próprias regiões críticas. No caso de esta situação ocorrer, um recurso estaria livre, porém alocado a um processo. Com isso, vários processos estariam sendo impedidos de utilizar o recurso, reduzindo o grau de compartilhamento.

Diversas soluções foram propostas para garantir a exclusão mútua de processos concorrentes. A seguir, são apresentadas algumas soluções de hardware e de software com discussões sobre benefícios e problemas de cada proposta.

7.5.1 Soluções de Hardware

A exclusão mútua pode ser implementada através de mecanismos de hardware. Neste item são apresentadas as soluções de desabilitação de interrupções e instruções test-and-set.

- Desabilitação de interrupções

  A solução mais simples para o problema da exclusão mútua é fazer com que o processo desabilite todas as interrupções antes de entrar em sua região crítica, e as reabilite após deixar a região crítica. Como a mudança de contexto de processos só pode ser realizada através de interrupções, o processo que as desabilitou terá acesso exclusivo garantido.

```
BEGIN
    .
    .
    Desabilita_Interrupcoes;
    Regiao_Critica;
    Habilita_Interrupcoes;
    .
    .
END.
```

Esta solução, apesar de simples, apresenta algumas limitações. Primeiramente, a multiprogramação pode ficar seriamente comprometida, já que a concorrência entre processos tem como base o uso de interrupções. Um caso mais grave poderia ocorrer caso um processo desabilitasse as interrupções e não tornasse a habilitá-las. Neste caso, o sistema, provavelmente, teria seu funcionamento seriamente comprometido.

Em sistemas com múltiplos processadores, essa solução torna-se ineficiente devido ao tempo de propagação quando um processador sinaliza aos demais que as interrupções devem ser habilitadas ou desabilitadas. Outra consideração é que o mecanismo de clock do sistema é implementado através de interrupções, devendo esta solução ser utilizada com bastante critério.

Apesar das limitações apresentadas, essa solução pode ser útil quando se deseja que a execução de parte do núcleo do sistema operacional ocorra sem que haja interrupção. Dessa forma, o sistema pode garantir que não ocorrerão problemas de inconsistência em suas estruturas de dados durante a execução de algumas rotinas.

- Instrução test-and-set

Muitos processadores possuem uma instrução de máquina especial que permite ler uma variável, armazenar seu conteúdo em uma outra área e atribuir um novo valor à mesma variável. Essa instrução especial é chamada *instrução test-and-set* e tem como característica ser executada sem interrupção, ou seja, trata-se de uma instrução indivisível. Dessa forma, é garantido que dois processos não manipulem uma variável compartilhada ao mesmo tempo, possibilitando a implementação da exclusão mútua.

A instrução test-and-set possui o formato a seguir, e quando executada o valor lógico da variável Y é copiado para X, sendo atribuído à variável Y o valor lógico verdadeiro.

```
Test-and-Set (X,Y);
```

Para coordenar o acesso concorrente a um recurso, a instrução test-and-set utiliza uma variável lógica global, que no programa Test_and_Set é denominada Bloqueio. Quando a variável Bloqueio for falsa, qualquer processo poderá alterar seu valor para verdadeiro através da instrução test-and-set e, assim, acessar o recurso de forma exclusiva. Ao terminar o acesso, o processo deve simplesmente retornar o valor da variável para falso, liberando o acesso ao recurso.

```
PROGRAM Test_and_Set;
    VAR Bloqueio : BOOLEAN;
PROCEDURE Processo_A;
    VAR Pode_A : BOOLEAN;
BEGIN
    REPEAT
        Pode_A := True;
        WHILE (Pode_A) DO
            Test_and_Set (Pode_A, Bloqueio);
        Regiao_Critica_A;
        Bloqueio := False;
    UNTIL False;
END;
PROCEDURE Processo_B;
    VAR Pode_B : BOOLEAN;
BEGIN
    REPEAT
        Pode_B := True;
        WHILE (Pode_B) DO
            Test_and_Set (Pode_B, Bloqueio);
        Regiao_Critica_B;
        Bloqueio := False;
    UNTIL False;
END;
BEGIN
    Bloqueio := False;
    PARBEGIN
        Processo_A;
        Processo_B;
    PAREND;
END.
```

Processo	Instrução	Pode_A	Pode_B	Bloqueio
A	REPEAT	*	*	False
B	REPEAT	*	*	False
A	Pode_A := True	True	*	False
B	Pode_B := True	*	True	False
B	WHILE	*	True	False
B	Test_and_Set	*	False	True
A	WHILE	True	*	True
A	Test_and_Set	True	*	True
B	Regiao_Critica_B	*	False	True
A	WHILE	True	*	True
A	Test_and_Set	True	*	True
B	Bloqueio := False	*	False	False
B	UNTIL False	*	False	False
B	REPEAT	*	False	False
A	WHILE	True	*	False
A	Test_and_Set	False	*	True
A	Regiao_Critica_A	False	*	True

O uso de uma instrução especial de máquina oferece algumas vantagens, como a simplicidade de implementação da exclusão mútua em múltiplas regiões críticas e o uso da solução em arquiteturas com múltiplos processadores. A principal desvantagem é a possibilidade do starvation, pois a seleção do processo para acesso ao recurso é arbitrária.

7.5.2 Soluções de Software

Diversos algoritmos foram propostos na tentativa de implementar a exclusão mútua através de soluções de software. As primeiras soluções tratavam apenas da exclusão mútua para dois processos e, inicialmente, apresentavam alguns problemas. A seguir é apresentado de forma evolutiva como foi o desenvolvimento de uma solução definitiva para a exclusão mútua entre N processos.

- Primeiro algoritmo

Este algoritmo apresenta uma solução para exclusão mútua entre dois processos, onde um mecanismo de controle alterna a execução das regiões críticas. Cada processo (A e B) é representado por um procedimento que possui um loop infinito (REPEAT/UNTIL), onde é feito o acesso a um recurso por diversas vezes. A seqüência de comandos, dentro do loop, é formada por um protocolo de entrada, uma região crítica e um protocolo de saída. A região crítica é representada por uma rotina, onde o acesso ao recurso realmente acontece. Após o acesso à região crítica, tanto o Processo A quanto o Processo B realizam processamentos individuais.

O mecanismo utiliza uma variável de bloqueio, indicando qual processo pode ter acesso à região crítica. Inicialmente, a variável global Vez é igual a 'A', indicando que o Processo A pode executar sua região crítica. O Processo B, por sua vez, fica esperando enquanto Vez for igual a 'A'. O Processo B só executará sua região crítica quando o Processo A atribuir o valor 'B' à variável de bloqueio Vez. Desta forma, estará garantida a exclusão mútua entre os dois processos.

```
PROGRAM Algoritmo_1;
    VAR Vez : CHAR;
PROCEDURE Processo_A;
BEGIN
    REPEAT
        WHILE (Vez = 'B') DO (* Nao faz nada *);
        Regiao_Critica_A;
        Vez := 'B';
        Processamento_A;
    UNTIL False;
END;
PROCEDURE Processo_B;
BEGIN
    REPEAT
      WHILE (Vez = 'A') DO (* Nao faz nada *);
      Regiao_Critica_B;
      Vez := 'A';
      Processamento_B;
    UNTIL False;
END;
BEGIN
    Vez := 'A';
    PARBEGIN
      Processo_A;
      Processo_B;
    PAREND;
END.
```

Este algoritmo, apesar de implementar a exclusão mútua, apresenta duas limitações, das quais a primeira surge do próprio mecanismo de controle utilizado. O acesso ao recurso compartilhado só pode ser realizado por dois processos e sempre de maneira alternada. Com isso, um processo que necessite utilizar o recurso mais vezes do que outro, permanecerá grande parte do tempo bloqueado. No algoritmo apresentado, caso o Processo A pemaneça muito tempo na rotina Processamento_A, é possível que o Processo B queira executar sua região crítica e não consiga, mesmo que o Processo A não esteja utilizando o recurso. Como o Processo B pode executar seu loop mais rapidamente que o Processo A, a possibilidade de executar sua região crítica fica limitada pela velocidade de processamento do Processo A.

Processo_A	Processo_B	Vez
WHILE (Vez = 'B')	WHILE (Vez = 'A')	A
Regiao_Critica_A	WHILE (Vez = 'A')	A
Vez := 'B'	WHILE (Vez = 'A')	B
Processamento_A	Regiao_Critica_B	B
Processamento_A	Vez := 'A'	A
Processamento_A	Processamento_B	A
Processamento_A	WHILE (Vez = 'A')	A

Outro problema existente nesta solução é que, no caso da ocorrência de algum problema com um dos processos, de forma que a variável de bloqueio não seja alterada, o outro processo permanecerá indefinidamente bloqueado, aguardando o acesso ao recurso.

- Segundo algoritmo

O problema principal do primeiro algoritmo é que ambos os processos trabalham com uma mesma variável global, cujo conteúdo indica qual processo tem o direito de entrar na região crítica. Para evitar esta situação, o segundo algoritmo introduz uma variável para cada processo (CA e CB) que indica se o processo está ou não em sua região crítica. Neste caso, toda vez que um processo desejar entrar em sua região crítica, a variável do outro processo é testada para verificar se o recurso está livre para uso.

```
PROGRAM Algoritmo_2;
    VAR CA, CB : BOOLEAN;
PROCEDURE Processo_A;
BEGIN
    REPEAT
        WHILE (CB) DO (* Nao faz nada *);
        CA := true;
        Regiao_Critica_A;
        CA := false;
        Processamento_A;
    UNTIL False;
END;
PROCEDURE Processo_B;
BEGIN
    REPEAT
        WHILE (CA) DO (* Nao faz nada *);
        CB := true;
        Regiao_Critica_B;
        CB := false;
        Processamento_B;
    UNTIL False;
END;
BEGIN
    CA := false;
    CB := false;
    PARBEGIN
        Processo_A;
        Processo_B;
    PAREND;
END.
```

Neste segundo algoritmo, o uso do recurso não é realizado necessariamente alternado. Caso ocorra algum problema com um dos processo fora da região crítica, o outro processo não ficará bloqueado, o que, porém, não resolve por completo o problema. Caso um processo tenha um problema dentro da sua região crítica ou antes de alterar a variável, o outro processo permanecerá indefinidamente bloqueado. Mais grave que o problema do bloqueio é que esta solução, na prática, é pior do que o primeiro algoritmo apresentado, pois nem sempre a exclusão mútua é garantida. O exemplo a seguir ilustra o problema, considerando que cada processo executa cada instrução alternadamente.

Processo_A	Processo_B	CA	CB
WHILE (CB)	WHILE (CA)	false	false
CA := true	CB := true	true	true
Regiao_Critica_A	Regiao_Critica_B	true	true

- Terceiro algoritmo

O terceiro algoritmo tenta solucionar o problema apresentado no segundo, colocando a instrução de atribuição das variáveis CA e CB antes do loop de teste.

```
PROGRAM Algoritmo_3;
    VAR CA, CB : BOOLEAN;
PROCEDURE Processo_A;
BEGIN
    REPEAT
        CA := true;
        WHILE (CB) DO (* Nao faz nada *);
        Regiao_Critica_A;
        CA := false;
        Processamento_A;
    UNTIL False;
END;
PROCEDURE Processo_B;
BEGIN
    REPEAT
        CB := true;
        WHILE (CA) DO (* Nao faz nada *);
        Regiao_Critica_B;
        CB := false;
        Processamento_B;
    UNTIL False;
END;
```

Esta alteração resulta na garantia da exclusão mútua, porém introduz um novo problema, que é a possibilidade de bloqueio indefinido de ambos os processos. Caso os dois processos alterem as variáveis CA e CB antes da execução da instrução WHILE, ambos os processos não poderão entrar em suas regiões críticas, como se o recurso já estivesse alocado.

- Quarto algoritmo

No terceiro algoritmo, cada processo altera o estado da sua variável indicando que irá entrar na região crítica sem conhecer o estado do outro processo, o que acaba resultando no problema apresentado. O quarto algoritmo apresenta uma implementação onde o processo, da mesma forma, altera o estado da variável antes de entrar na sua região crítica, porém existe a possibilidade de esta alteração ser revertida.

```
PROGRAM Algoritmo_4;
    VAR CA,CB : BOOLEAN;
PROCEDURE Processo_A;
BEGIN
    REPEAT
        CA := true;
        WHILE (CB) DO
        BEGIN
           CA := false;
           { pequeno intervalo de tempo aleatório }
           CA := true
        END;
        Regiao_Critica_A;
        CA := false;
    UNTIL False;
END;

PROCEDURE Processo_B;
BEGIN
    REPEAT
        CB := true;
        WHILE (CA) DO
        BEGIN
            CB := false;
            { pequeno intervalo de tempo aleatório }
            CB := true;
        END;
        Regiao_Critica_B;
        CB := false;
    UNTIL False;
END;

BEGIN
    CA := false;
    CB := false;
    PARBEGIN
        Processo_A;
        Processo_B;
    PAREND;
END.
```

Apesar de esta solução garantir a exclusão mútua e não gerar o bloqueio simultâneo dos processos, uma nova situação indesejada pode ocorrer eventualmente. No caso de os tempos aleatórios serem próximos e a concorrência gerar uma situação onde os dois processos alterem as variáveis CA e CB para falso antes do término do loop, nenhum dos dois processos conseguirá executar sua região crítica. Mesmo com esta situação não sendo permanente, pode gerar alguns problemas.

- Algoritmo de Dekker

A primeira solução de software que garantiu a exclusão mútua entre dois processos sem a incorrência de outros problemas foi proposta pelo matemático holandês T. Dekker com base no primeiro e quarto algoritmos. O algoritmo de Dekker possui uma lógica bastante complexa e pode ser encontrado em Ben-Ari (1990) e Stallings (1997). Posteriormente, G. L. Peterson propôs outra solução mais simples para o mesmo problema, conforme apresentado a seguir.

- Algoritmo de Peterson

O algoritmo proposto por G. L. Peterson apresenta uma solução para o problema da exclusão mútua entre dois processos que pode ser facilmente generalizada para o caso de N processos. Similar ao terceiro algoritmo, esta solução, além das variáveis de condição (CA e CB) que indicam o desejo de cada processo entrar em sua região crítica, introduz a variável Vez para resolver os conflitos gerados pela concorrência.

Antes de acessar a região crítica, o processo sinaliza esse desejo através da variável de condição, porém o processo cede o uso do recurso ao outro processo, indicado pela variável Vez. Em seguida, o processo executa o comando WHILE como protocolo de entrada da região crítica. Neste caso, além da garantia da exclusão mútua, o bloqueio indefinido de um dos processos no loop nunca ocorrerá, já que a variável Vez sempre permitirá a continuidade da execução de um dos processos.

```
PROGRAM Algoritmo_Peterson;
    VAR CA,CB: BOOLEAN;
        Vez : CHAR;
PROCEDURE Processo_A;
BEGIN
    REPEAT
        CA := true;
        Vez := 'B';
        WHILE (CB and Vez = 'B') DO (* Nao faz nada *);
        Regiao_Critica_A;
        CA := false;
        Processamento_A;
    UNTIL False;
END;

PROCEDURE Processo_B;
BEGIN
    REPEAT
        CB := true;
        Vez := 'A';
        WHILE (CA and Vez = 'A') DO (* Nao faz nada *);
        Regiao_Critica_B;
        CB := false;
         Processamento_B;
    UNTIL False;
END;

BEGIN
    CA := false;
    CB := false;
    PARBEGIN
        Processo_A;
        Processo_B;
    PAREND;
END.
```

- Algoritmo para exclusão mútua entre N processos

O algoritmo de Dekker e a versão inicial do algoritmo de Peterson garantem a exclusão mútua de dois processsos. Posteriormente, o algoritmo de Peterson foi generalizado para o caso de N processos Hofri (1990). O algoritmo do Padeiro (Bakery Algorithm), proposto por Lamport (1974), é uma solução clássica para o problema da exclusão mútua entre N processos e pode ser encontrado em Ben-Ari (1990) e Silberschatz, Galvin e Gagne (2001). Outros algoritmos que também foram apresentados para exclusão mútua de N processos podem ser consultados em Peterson (1983) e Lamport (1987).

Apesar de todas soluções até então apresentadas implementarem a exclusão mútua, todas possuíam uma deficiência conhecida como *espera ocupada* (*busy wait*). Na espera ocupada, toda vez que um processo não consegue entrar em sua região crítica, por já existir outro processo acessando o recurso, o processo permanece em looping, testando uma condição, até que lhe seja permitido o acesso. Dessa forma, o processo em looping consome tempo do processador desnecessariamente, podendo ocasionar problemas ao desempenho do sistema.

A solução para o problema da espera ocupada foi a introdução de mecanismos de sincronização que permitiram que um processo, quando não pudesse entrar em sua região crítica, fosse colocado no estado de espera. Esses mecanismos, conhecidos como semáforos e monitores, são apresentados posteriormente.

7.6 Sincronização Condicional

Sincronização condicional é uma situação onde o acesso ao recurso compartilhado exige a sincronização de processos vinculada a uma condição de acesso. Um recurso pode não se encontrar pronto para uso devido a uma condição específica. Nesse caso, o processo que deseja acessá-lo deverá permanecer bloqueado até que o recurso fique disponível.

Um exemplo clássico desse tipo de sincronização é a comunicação entre dois processos através de operações de gravação e leitura em um buffer, como foi visto na Fig. 7.1, onde processos geram informações (*processos produtores*) utilizadas por outros processos (*processos consumidores*). Nessa comunicação, enquanto um processo grava dados em um buffer, o outro lê os dados, concorrentemente. Os processos envolvidos devem estar sincronizados a uma variável de condição, de forma que um processo não tente gravar dados em um buffer cheio ou realizar uma leitura em um buffer vazio.

O programa a seguir exemplifica o problema da sincronização condicional, também conhecido como *problema do produtor/consumidor* ou do *buffer limitado*. O recurso compartilhado é um buffer, definido no algoritmo com o tamanho TamBuf e sendo controlado pela variável Cont. Sempre que a variável Cont for igual a 0, significa que o buffer está vazio e o processo Consumidor deve permanecer aguardando até que se grave um dado. Da mesma forma, quando a variável Cont for igual a TamBuf, significa que o buffer está cheio e o processo Produtor deve aguardar a leitura de um novo dado. Nessa solução, a tarefa de colocar e retirar os dados do buffer é realizada, respectiva-

mente, pelos procedimentos Grava_Buffer e Le_Buffer, executados de forma mutuamente exclusiva. Não está sendo considerada, neste algoritmo, a implementação da exclusão mútua na variável compartilhada Cont.

```
PROGRAM Produtor_Consumidor_1;
    CONST TamBuf  = (* Tamanho qualquer *);
    TYPE Tipo_Dado = (* Tipo qualquer *);
    VAR Buffer : ARRAY [1..TamBuf] OF Tipo_Dado;
        Dado_1 : Tipo_Dado;
        Dado_2 : Tipo_Dado;
        Cont   : 0..TamBuf;

PROCEDURE Produtor;
BEGIN
    REPEAT
        Produz_Dado (Dado_1);
        WHILE (Cont = TamBuf) DO (* Nao faz nada *);
        Grava_Buffer (Dado_1, Buffer);
        Cont := Cont + 1;
    UNTIL False;
END;

PROCEDURE Consumidor;
BEGIN
    REPEAT
        WHILE (Cont = 0) DO (* Nao faz nada *);
        Le_Buffer (Dado_2, Buffer);
        Consome_Dado (Dado_2);
        Cont := Cont - 1;
    UNTIL False;
END;

BEGIN
    Cont := 0;
    PARBEGIN
        Produtor;
        Consumidor;
    PAREND;
END.
```

Apesar de o algoritmo apresentado resolver a questão da sincronização condicional, o problema da espera ocupada também se faz presente, sendo somente solucionado pelos mecanismos de sincronização semáforos e monitores.

7.7 Semáforos

O conceito de *semáforos* foi proposto por E. W. Dijkstra em 1965, sendo apresentado como um mecanismo de sincronização que permitia implementar, de forma simples, a exclusão mútua e sincronização condicional entre processos. De fato, o uso de semáforos tornou-se um dos principais mecanismos utilizados em projetos de sistemas operacionais e em aplicações concorrentes. Atualmente, a maioria das linguagens de programação disponibiliza rotinas para uso de semáforos.

Um semáforo é uma variável inteira, não-negativa, que só pode ser manipulada por duas instruções: DOWN e UP, também chamadas originalmente por Dijkstra instru-

ções P (*proberen*, teste em holandês) e V (*verhogen*, incremento em holandês). As instruções DOWN e UP são indivisíveis, ou seja, a execução destas instruções não pode ser interrompida. A instrução UP incrementa uma unidade ao valor do semáforo, enquanto a DOWN decrementa a variável. Como, por definição, valores negativos não podem ser atribuídos a um semáforo, a instrução DOWN executa em um semáforo com valor 0, faz com que o processo entre no estado de espera. Em geral, essas instruções são implementadas no processador, que deve garantir todas essas condições.

Os semáforos podem ser classificados como binários ou contadores. Os *semáforos binários*, também chamados de *mutexes* (*mutual exclusion semaphores*), só podem assumir os valores 0 e 1, enquanto os *semáforos contadores* podem assumir qualquer valor inteiro positivo, além do 0.

A seguir, será apresentado o uso de semáforos na implementação da exclusão mútua e da sincronização condicional. Ao final deste item, alguns problemas clássicos de sincronização são também apresentados.

7.7.1 Exclusão Mútua Utilizando Semáforos

A exclusão mútua pode ser implementada através de um semáforo binário associado ao recurso compartilhado. A principal vantagem desta solução em relação aos algoritmos anteriormente apresentados é a não ocorrência da espera ocupada.

As instruções DOWN e UP funcionam como protocolos de entrada e saída, respectivamente, para que um processo possa entrar e sair de sua região crítica. O semáforo fica associado a um recurso compartilhado, indicando quando o recurso está sendo acessado por um dos processos concorrentes. O valor do semáforo igual a 1 indica que nenhum processo está utilizando o recurso, enquanto o valor 0 indica que o recurso está em uso.

Sempre que deseja entrar na sua região crítica, um processo executa uma instrução DOWN. Se o semáforo for igual a 1, este valor é decrementado, e o processo que solicitou a operação pode executar as instruções da sua região crítica. De outra forma, se uma instrução DOWN é executada em um semáforo com valor igual a 0, o processo fica impedido do acesso, permanecendo em estado de espera e, conseqüentemente, não gerando overhead no processador.

O processo que está acessando o recurso, ao sair de sua região crítica, executa uma instrução UP, incrementando o valor do semáforo e liberando o acesso ao recurso. Se um ou mais processos estiverem esperando pelo uso do recurso (operações DOWN pendentes), o sistema selecionará um processo na fila de espera associada ao recurso e alterará o seu estado para pronto (Fig. 7.3).

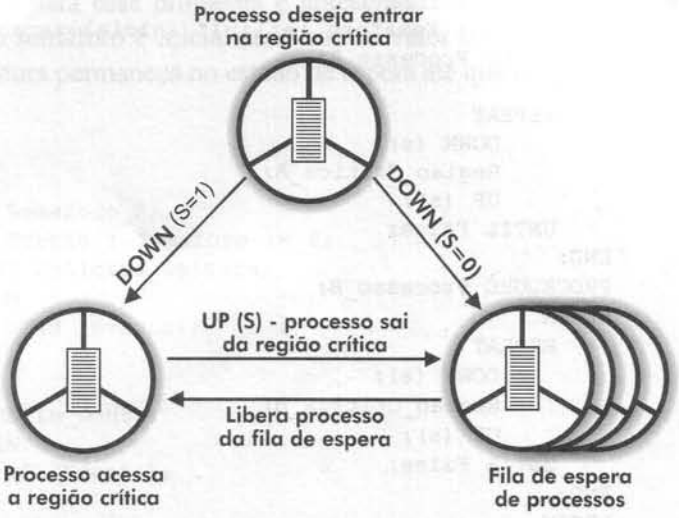

Fig. 7.3 Utilização do semáforo binário na exclusão mútua.

As instruções DOWN e UP, aplicadas a um semáforo S, podem ser representadas pelas definições a seguir, em uma sintaxe Pascal não convencional:

```
TYPE Semaforo = RECORD
        Valor : INTEGER;
        Fila_Espera : (* Lista de processos pendentes *);
    END;
PROCEDURE DOWN (VAR S : Semaforo);
BEGIN
    IF (S = 0) THEN Coloca_Processo_na_Fila_de_Espera
    ELSE
        S := S - 1;
END;

PROCEDURE UP (VAR S : Semaforo);
BEGIN
    S := S + 1;
    IF (Tem_Processo_Esperando) THEN Retira_da_Fila_de_Espera;
END;
```

O programa Semaforo_1 apresenta uma solução para o problema da exclusão mútua entre dois processos utilizando semáforos. O semáforo é inicializado com o valor 1, indicando que nenhum processo está executando sua região crítica.

```
PROGRAM Semaforo_1;
    VAR s : Semaforo := 1; (* inicializacao do semaforo *)
PROCEDURE Processo_A;
BEGIN
    REPEAT
        DOWN (s);
        Regiao_Critica_A;
        UP (s);
    UNTIL False;
END;
PROCEDURE Processo_B;
BEGIN
    REPEAT
        DOWN (s);
        Regiao_Critica_B;
        UP (s);
    UNTIL False;
END;
BEGIN
    PARBEGIN
        Processo_A;
        Processo_B;
    PAREND;
END.
```

O exemplo a seguir ilustra a execução do programa Semaforo_1, onde o Processo A executa a instrução DOWN, fazendo com que o semáforo seja decrementado de 1 e passe a ter o valor 0. Em seguida, o Processo A ganha o acesso à sua região crítica. O Processo B também executa a instrução DOWN, mas como seu valor é igual a 0, ficará aguardando até que o Processo A execute a instrução UP, ou seja, volte o valor do semáforo para 1.

Processo_A	Processo_B	S	Pendente
REPEAT	REPEAT	1	*
DOWN (s)	REPEAT	0	*
Regiao_Critica_A	DOWN (s)	0	Processo_B
UP (s)	DOWN (s)	1	Processo_B
REPEAT	Regiao_Critica_B	0	*

7.7.2 Sincronização Condicional Utilizando Semáforos

Além de permitirem a implementação da exclusão mútua, os semáforos podem ser utilizados nos casos onde a sincronização condicional é exigida. Um exemplo desse tipo de sincronização ocorre quando um processo solicita uma operação de E/S. O pedido faz com que o processo execute uma instrução DOWN no semáforo associado ao evento e fique no estado de espera, até que a operação seja completada. Quando a operação termina, a rotina de tratamento da interrupção executa um UP no semáforo, liberando o processo do estado de espera.

Uma solução para esse problema é apresentada no programa Semaforo_2. Neste algoritmo, o semáforo é inicializado com o valor 0, o que garante que o processo Solicita_Leitura permaneça no estado de espera até que o processo Le_Dados o libere.

```
PROGRAM Semaforo_2;
    VAR Evento : Semaforo := 0;
PROCEDURE Solicita_Leitura;
    BEGIN
        DOWN (Evento);
    END;

PROCEDURE Le_Dados;
    BEGIN
        UP (Evento);
    END;
BEGIN
    PARBEGIN
        Solicita_Leitura;
        Le_Dados;
    PAREND;
END.
```

O problema do produtor/consumidor já apresentado é um outro exemplo de como a exclusão mútua e a sincronização condicional podem ser implementadas com o uso de semáforos. O programa Produtor_Consumidor_2 apresenta uma solução para esse problema, utilizando um buffer de apenas duas posições. O programa utiliza três semáforos, sendo um do tipo binário, utilizado para implementar a exclusão mútua, e dois semáforos contadores para a sincronização condicional. O semáforo binário Mutex permite a execução das regiões críticas Grava_Buffer e Le_Buffer de forma mutuamente exclusiva. Os semáforos contadores Vazio e Cheio representam, respectivamente, se há posições livres no buffer para serem gravadas e posições ocupadas a serem lidas. Quando o semáforo Vazio for igual a 0, significa que o buffer está cheio e o processo produtor deverá aguardar até que o consumidor leia algum dado. Da mesma forma, quando o semáforo Cheio for igual a 0, significa que o buffer está vazio e o consumidor deverá aguardar até que o produtor grave algum dado. Em ambas as situações, o semáforo sinaliza a impossibilidade de acesso ao recurso.

```
PROGRAM Produtor_Consumidor_2;
    CONST TamBuf   = 2;
    TYPE  Tipo_Dado = (* Tipo qualquer *);
    VAR   Vazio : Semaforo := TamBuf;
          Cheio : Semaforo := 0;
          Mutex : Semaforo := 1;
          Buffer : ARRAY [1..TamBuf] OF Tipo_Dado;
          Dado_1 : Tipo_Dado;
          Dado_2 : Tipo_Dado;

PROCEDURE Produtor;
BEGIN
    REPEAT
        Produz_Dado (Dado_1);
        DOWN (Vazio);
        DOWN (Mutex);
        Grava_Buffer (Dado_1, Buffer);
        UP (Mutex);
        UP (Cheio);
    UNTIL False;
END;

PROCEDURE Consumidor;
BEGIN
    REPEAT
        DOWN (Cheio);
        DOWN (Mutex);
        Le_Buffer (Dado_2, Buffer);
        UP (Mutex);
        UP (Vazio);
        Consome_Dado (Dado_2);
    UNTIL False;
END;

BEGIN
    PARBEGIN
        Produtor;
        Consumidor;
    PAREND;
END.
```

O exemplo a seguir considera que o processo Consumidor é o primeiro a ser executado. Como o buffer está vazio (Cheio = 0), a operação DOWN (Cheio) faz com que o processo Consumidor permaneça no estado de espera. Em seguida, o processo Produtor grava um dado no buffer e, após executar o UP (Cheio), libera o processo Consumidor, que estará apto para ler o dado do buffer.

Produtor	Consumidor	Vazio	Cheio	Mutex	Pendente
*	*	2	0	1	*
*	DOWN (Cheio)	2	0	1	Consumidor
DOWN (Vazio)	DOWN (Cheio)	1	0	1	Consumidor
DOWN (Mutex)	DOWN (Cheio)	1	0	0	Consumidor
Grava_Buffer	DOWN (Cheio)	1	0	0	Consumidor
UP (Mutex)	DOWN (Cheio)	1	0	1	Consumidor

Produtor	Consumidor	Vazio	Cheio	Mutex	Pendente
UP (Cheio)	DOWN (Cheio)	1	1	1	*
UP (Cheio)	DOWN (Cheio)	1	0	1	*
UP (Cheio)	DOWN (Mutex)	1	0	0	*
UP (Cheio)	Lê_Dado	1	0	0	*
UP (Cheio)	UP (Mutex)	1	0	1	*
UP (Cheio)	UP (Vazio)	2	0	1	*

Semáforos contadores são bastante úteis quando aplicados em problemas de sincronização condicional onde existem processos concorrentes alocando recursos do mesmo tipo (pool de recursos). O semáforo é inicializado com o número total de recursos do pool, e, sempre que um processo deseja alocar um recurso, executa um DOWN, subtraindo 1 do número de recursos disponíveis. Da mesma forma, sempre que o processo libera um recurso para o pool, executa um UP. Se o semáforo contador ficar com o valor igual a 0, isso significa que não existem mais recursos a serem utilizados, e o processo que solicita um recurso permanece em estado de espera, até que outro processo libere algum recurso para o pool.

7.7.3 Problema dos Filósofos

O problema dos filósofos é um exemplo clássico de sincronização de processos proposto por Dijkstra. Nesse problema, há uma mesa com cinco pratos e cinco garfos, onde os filósofos podem sentar, comer e pensar. Toda vez que um filósofo pára de pensar e deseja comer, é necessário que ele utilize dois garfos, posicionados à sua direita e à sua esquerda.

O algoritmo Filosofo_1 apresenta uma solução que não resolve o problema totalmente, pois se todos os filósofos estiverem segurando apenas um garfo cada um, nenhum filosófo conseguirá comer. Esta situação é conhecida como deadlock.

```
PROGRAM Filosofo_1;
    VAR Garfos : ARRAY [0..4] of Semaforo := 1;
        I      : INTEGER;

PROCEDURE Filosofo (I : INTEGER);
BEGIN
    REPEAT
        Pensando;
        DOWN (Garfos[I]);
        DOWN (Garfos[(I+1) MOD 5]);
        Comendo;
        UP (Garfos[I]);
        UP (Garfos[(I+1) MOD 5]);
    UNTIL False;
END;

BEGIN
    PARBEGIN
        FOR I := 0 TO 4 DO
            Filosofo (I);
    PAREND;
END.
```

Existem várias soluções para resolver o problema dos filósofos sem a ocorrência do deadlock, como as apresentadas a seguir. A solução (a) é descrita no algoritmo Filosofo_2.

(a) Permitir que apenas quatro filósofos sentem à mesa simultaneamente;

(b) Permitir que um filósofo pegue um garfo apenas se o outro estiver disponível;

(c) Permitir que um filósofo ímpar pegue primeiro o seu garfo da esquerda e depois o da direita, enquanto um filósofo par pegue o garfo da direita e, em seguida, o da esquerda.

```
PROGRAM Filosofo_2;
    VAR Garfos  : ARRAY [0..4] of Semaforo := 1;
        Lugares : Semaforo := 4;
        I       : INTEGER;

PROCEDURE Filosofo (I : INTEGER);
BEGIN
    REPEAT
        Pensando;
        DOWN (Lugares);
        DOWN (Garfos[I]);
        DOWN (Garfos[(I+1) MOD 5]);
        Comendo;
        UP (Garfos[I]);
        UP (Garfos[(I+1) MOD 5]);
        UP (Lugares);
    UNTIL False;
END;

BEGIN
    PARBEGIN
        FOR I := 0 TO 4 DO
            Filosofo (I);
    PAREND;
END.
```

7.7.4 Problema do Barbeiro

O problema do barbeiro é outro exemplo clássico de sincronização de processos. Neste problema, um barbeiro recebe clientes para cortar o cabelo. Na barbearia há uma cadeira de barbeiro e apenas cincos cadeiras para clientes esperarem. Quando um cliente chega, caso o barbeiro esteja trabalhando, ele senta se houver cadeira vazia ou vai embora se todas as cadeiras estiverem ocupadas. No caso de o barbeiro não ter nenhum cliente para atender, ele senta na cadeira e dorme até que um novo cliente apareça.

```
PROGRAM Barbeiro;
    CONST Cadeiras = 5;
    VAR  Clientes   : Semaforo := 0;
         Barbeiro   : Semaforo := 0;
         Mutex      : Semaforo := 1;
         Espera     : integer  := 0;

PROCEDURE Barbeiro;
BEGIN
    REPEAT
        DOWN (Clientes);
        DOWN (Mutex);
        Espera := Espera - 1;
        UP (Barbeiro);
        UP (Mutex);
        Corta_Cabelo;
    UNTIL False;
END;

PROCEDURE Cliente;
BEGIN
    DOWN (Mutex);
    IF (Espera < Cadeiras)
    BEGIN
        Espera := Espera + 1;
        UP (Clientes);
        UP (Mutex);
        DOWN (Barbeiro);
        Ter_Cabelo_Cortado;
    END
    ELSE UP (Mutex);
END;
```

A solução utiliza o semáforo contador Clientes e os semáforos binários Barbeiro e Mutex. No processo Barbeiro, é executado um DOWN no semáforo Clientes com o objetivo de selecionar um cliente para o corte. Caso não exista nenhum cliente aguardando, o processo Barbeiro permanece no estado de espera. No caso de existir algum cliente, a variável Espera é decrementada, e para isso é utilizado o semáforo Mutex visando garantir o uso exclusivo da variável. Uma instrução UP é executada no semáforo Barbeiro para indicar que o recurso barbeiro está trabalhando.

No processo Cliente, o semáforo Mutex garante a exclusão mútua da variável Espera, que permite verificar se todas as cadeiras já estão ocupadas. Nesse caso, o cliente vai embora, realizando um UP no Mutex. Caso contrário, a variável Espera é incrementada e o processo solicita o uso do recurso barbeiro através da instrução DOWN no semáforo Barbeiro.

7.8 Monitores

Monitores são mecanismos de sincronização de alto nível que tornam mais simples o desenvolvimento de aplicações concorrentes. O conceito de monitores foi proposto por Brinch Hansen em 1972, e desenvolvido por C.A.R. Hoare em 1974, como um mecanismo de sincronização estruturado, ao contrário dos semáforos, que são considerados não-estruturados.

O uso de semáforos exige do desenvolvedor bastante cuidado, pois qualquer engano pode levar a problemas de sincronização imprevisíveis e difíceis de serem reproduzidos devido à execução concorrente dos processos. Monitores são considerados mecanismos de alto nível e estruturados em função de serem implementados pelo compilador. Assim, o desenvolvimento de programas concorrentes fica mais fácil e as chances de erro são menores. Inicialmente, algumas poucas linguagens de programação, como Concurrent Pascal, Modula-2 e Modula-3, ofereciam suporte ao uso de monitores. Atualmente, a maioria das linguagens de programação disponibiliza rotinas para uso de monitores.

O monitor é formado por procedimentos e variáveis encapsulados dentro de um módulo. Sua característica mais importante é a implementação automática da exclusão mútua entre os procedimentos declarados, ou seja, somente um processo pode estar executando um dos procedimentos do monitor em um determinado instante. Toda vez que algum processo faz uma chamada a um desses procedimentos, o monitor verifica se já existe outro processo executando algum procedimento do monitor. Caso exista, o processo ficará aguardando a sua vez em uma fila de entrada. As variáveis globais de um monitor são visíveis apenas aos procedimentos da sua estrutura, sendo inacessíveis fora do contexto do monitor. Toda a inicialização das variáveis é realizada por um bloco de comandos do monitor, sendo executado apenas uma vez, na ativação do programa onde está declarado o monitor (Fig. 7.4).

Um monitor é definido especificando-se um nome, declarando-se variáveis locais, procedimentos e um código de inicialização. A estrutura de um monitor é mostrada a seguir, utilizando uma sintaxe Pascal não convencional:

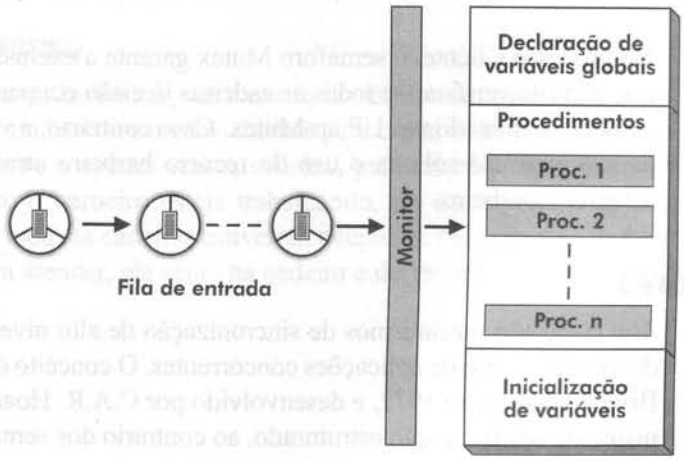

Fig. 7.4 Estrutura do monitor.

```
MONITOR Exclusao_Mutua;
    (* Declaracao das variaveis do monitor *)
    PROCEDURE Regiao_Critica_1;
    BEGIN
        .
        .
    END;

    PROCEDURE Regiao_Critica_2;
    BEGIN
        .
        .
    END;

    PROCEDURE Regiao_Critica_3;
    BEGIN
        .
        .
    END;

    BEGIN
        (* Codigo de inicializacao *)
    END;
```

7.8.1 Exclusão Mútua Utilizando Monitores

A implementação da exclusão mútua utilizando monitores não é realizada diretamente pelo programador, como no caso do uso de semáforos. As regiões críticas devem ser definidas como procedimentos no monitor, e o compilador se encarregará de garantir a exclusão mútua entre esses procedimentos.

A comunicação do processo com o monitor é feita unicamente através de chamadas a seus procedimentos e dos parâmetros passados. O programa Monitor_1 apresenta a solução para o problema anteriormente apresentado, onde dois processos somam e diminuem, concorrentemente, o valor 1 da variável compartilhada X.

```
PROGRAM Monitor_1;
    MONITOR Regiao_Critica;
        VAR X : INTEGER;

        PROCEDURE Soma;
        BEGIN
            X := X + 1;
        END;

        PROCEDURE Diminui;
        BEGIN
            X := X - 1;
        END;

    BEGIN
        X := 0;
    END;

BEGIN
    PARBEGIN
        Regiao_Critica.Soma;
        Regiao_Critica.Diminui;
    PAREND;
END.
```

A inicialização da variável X com o valor zero só acontecerá uma vez, no momento da inicialização do monitor Regiao_Critica. Neste exemplo, podemos garantir que o valor de X ao final da execução concorrente de Soma e Diminui será igual a zero, porque, como os procedimentos estão definidos dentro do monitor, estará garantida a execução mutuamente exclusiva.

7.8.2 Sincronização Condicional Utilizando Monitores

Monitores também podem ser utilizados na implementação da sincronização condicional. Através de *variáveis especiais de condição*, é possível associar a execução de um procedimento que faz parte do monitor a uma determinada condição, garantindo a sincronização condicional.

As variáveis especiais de condição são manipuladas por intermédio de duas instruções, conhecidas como WAIT e SIGNAL. A instrução WAIT faz com que o processo seja colocado no estado de espera, até que algum outro processo sinalize com a instrução SIGNAL que a condição de espera foi satisfeita. Caso a instrução SIGNAL seja executada e não haja processo aguardando a condição, nenhum efeito surtirá.

É possível que vários processos estejam com suas execuções suspensas, aguardando a sinalização de diversas condições. Para isso, o monitor organiza os processos em espera utilizando filas associadas às condições de sincronização. A execução da instrução SIGNAL libera apenas um único processo da fila de espera da condição associada. Um processo pode executar um procedimento de um monitor, mesmo quando um ou mais processos estão na fila de espera de condições (Fig. 7.5).

O problema do produtor/consumidor é mais uma vez apresentado, desta vez com o uso de um monitor para a solução. O monitor Condicional é estruturado com duas variáveis especiais de condição (Cheio e Vazio) e dois procedimentos (Produz e Consome).

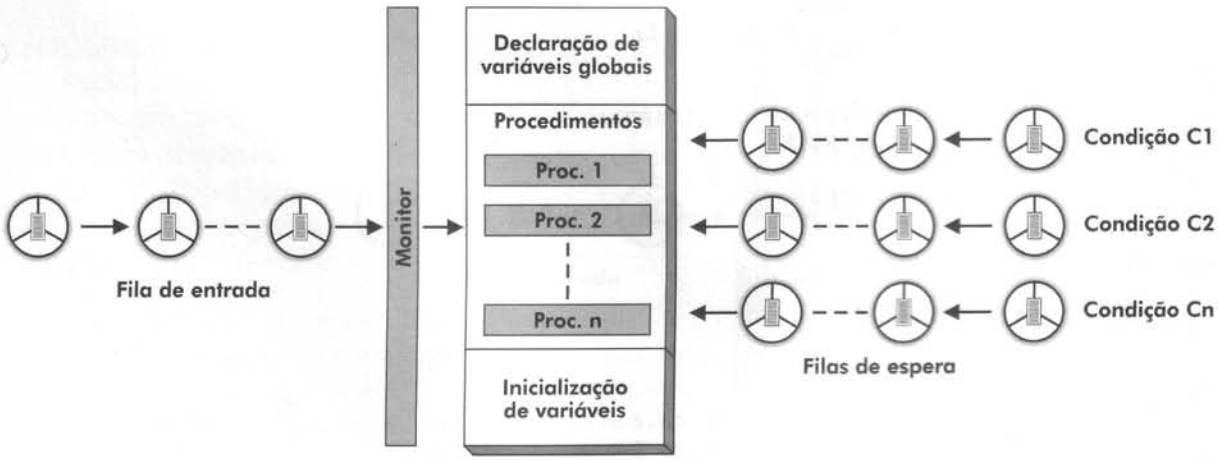

Fig. 7.5 Estrutura do monitor com variáveis de condição.

```
MONITOR Condicional;
    VAR Cheio, Vazio : (* Variaveis especiais de condicao *);

    PROCEDURE Produz;
    BEGIN
        IF (Cont = TamBuf) THEN WAIT (Cheio);
        .
        .
        IF (Cont = 1) THEN SIGNAL (Vazio);
    END;

    PROCEDURE Consome;
    BEGIN
        IF (Cont = 0) THEN WAIT (Vazio);
        .
        .
        IF (Cont = TamBuf - 1) THEN SIGNAL (Cheio);
    END;

BEGIN
END;
```

Sempre que o processo produtor desejar gravar um dado no buffer, deverá fazê-lo através de uma chamada ao procedimento Produz do monitor (Condicional.Produz). Neste procedimento, deve ser testado se o número de posições ocupadas no buffer é igual ao seu tamanho, ou seja, se o buffer está cheio. Caso o teste seja verdadeiro, o processo deve executar um WAIT em Cheio, indicando que a continuidade da sua execução depende dessa condição, e permanecer aguardando em uma fila de espera associada à variável Cheio. O processo bloqueado só poderá prosseguir sua execução quando um processo consumidor executar um SIGNAL na variável Cheio, indicando que um elemento do buffer foi consumido.

No caso do processo consumidor, sempre que desejar ler um dado do buffer, deverá fazê-lo através de uma chamada ao procedimento Consome do monitor (Condicional.Consome). Sua condição de execução é existir ao menos um elemento no buffer. Caso o buffer esteja vazio, o processo deve executar um WAIT em Vazio, indicando que a continuidade da sua execução depende dessa condição, e permanecer aguardando em uma fila de espera associada à variável Vazio. O processo produtor que inserir o primeiro elemento no buffer deverá sinalizar esta condição através do comando SIGNAL na variável Vazio, liberando o consumidor.

O programa Produtor_Consumidor_3 descreve a solução completa com o uso do monitor Condicional apresentado. Os procedimentos Produz_Dado e Consome_Dado servem, respectivamente, como entrada e saída de dados para o programa. Os procedimentos Grava_Dado e Le_Dado são responsáveis, respectivamente, pela transferência e recuperação do dado no buffer.

```
PROGRAM Produtor_Consumidor_3;
  CONST TamBuf  = (* Tamanho qualquer *);
    TYPE Tipo_Dado = (* Tipo qualquer  *);
     VAR Buffer : ARRAY [1..TamBuf] OF Tipo_Dado;
         Dado   : Tipo_Dado;

MONITOR Condicional;
  VAR Vazio, Cheio : (* Variaveis de condicao *);
      Cont : INTEGER;

  PROCEDURE Produz;
  BEGIN
      IF (Cont = TamBuf) THEN WAIT (Cheio);
      Grava_Dado (Dado, Buffer);
      Cont = Cont + 1;
      IF (Cont = 1) THEN SIGNAL (Vazio);
  END;

  PROCEDURE Consome;
  BEGIN
      IF (Cont = 0) THEN WAIT (Vazio);
      Le_Dado (Dado, Buffer);
      Cont := Cont - 1;
      IF (Cont = TamBuf - 1) THEN SIGNAL(Cheio);
  END;

BEGIN
    Cont := 0;
END;

PROCEDURE Produtor;
BEGIN
    REPEAT
        Produz_Dado (Dado);
        Condicional.Produz;
    UNTIL False;
END;

PROCEDURE Consumidor;
BEGIN
    REPEAT
        Condicional.Consome;
        Consome_Dado (Dado);
    UNTIL False;
END;

BEGIN
    PARBEGIN
        Produtor;
        Consumidor;
    PAREND;
END.
```

7.9 Troca de Mensagens

Troca de mensagens é um mecanismo de comunicação e sincronização entre processos. O sistema operacional possui um subsistema de mensagem que suporta esse mecanismo sem que haja necessidade do uso de variáveis compartilhadas. Para que haja a

comunicação entre os processos, deve existir um canal de comunicação, podendo esse meio ser um buffer ou um link de uma rede de computadores.

Os processos cooperativos podem fazer uso de um buffer para trocar mensagens através de duas rotinas: SEND (receptor, mensagem) e RECEIVE (transmissor, mensagem). A rotina SEND permite o envio de uma mensagem para um *processo receptor*, enquanto a rotina RECEIVE possibilita o recebimento de mensagem enviada por um *processo transmissor* (Fig. 7.6).

Fig. 7.6 Transmissão de mensagem.

O mecanismo de troca de mensagens exige que os processos envolvidos na comunicação tenham suas execuções sincronizadas. A sincronização é necessária, já que uma mensagem somente pode ser tratada por um processo após ter sido recebida, ou o envio de mensagem pode ser uma condição para a continuidade de execução de um processo.

A troca de mensagens entre processos pode ser implementada de duas maneiras distintas, comunicação direta e comunicação indireta. A *comunicação direta* entre dois processos exige que, ao enviar ou receber uma mensagem, o processo enderece explicitamente o nome do processo receptor ou transmissor. Uma característica deste tipo de comunicação é só permitir a troca de mensagem entre dois processos. O principal problema da comunicação direta é a necessidade da especificação do nome dos processos envolvidos na troca de mensagens. No caso de mudança na identificação dos processos, o código do programa deve ser alterado e recompilado (Fig. 7.7).

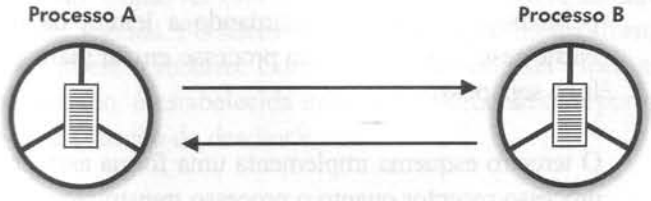

Fig. 7.7 Comunicação direta.

A *comunicação indireta* entre processos utiliza uma área compartilhada, onde as mensagens podem ser colocadas pelo processo transmissor e retiradas pelo receptor. Esse tipo de buffer é conhecido como *mailbox* ou *port,* e suas características, como identificação e capacidade de armazenamento de mensagens, são definidas no momento de criação. Na comunicação indireta, vários processos podem estar associados a mailbox, e os parâmetros dos procedimentos SEND e RECEIVE passam a ser nomes de mailboxes e não mais nomes de processos (Fig. 7.8).

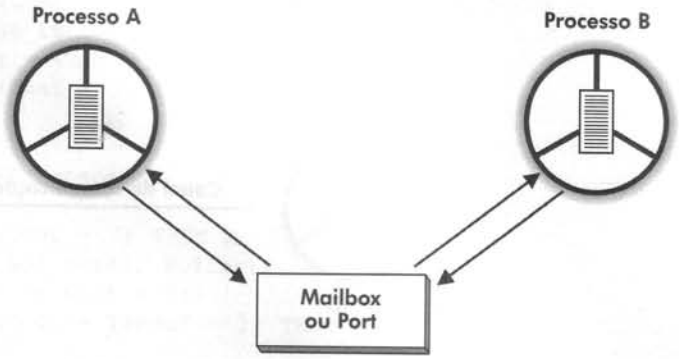

Fig. 7.8 Comunicação indireta.

Independente do mecanismo de comunicação utilizado, processos que estão trocando mensagens devem ter suas execuções sincronizadas em função do fluxo de mensagens. Um processo não pode tratar uma mensagem até que esta tenha sido enviada por outro processo, ou um processo não pode receber uma mesma mensagem mais de uma vez. Existem três diferentes esquemas de implementar a sincronização entre processos que trocam mensagens.

O primeiro esquema de sincronização é garantir que um processo, ao enviar uma mensagem, permaneça esperando até que o processo receptor a leia. Na mesma condição, um processo, ao tentar receber uma mensagem ainda não enviada, deve permanecer aguardando até que o processo transmissor faça o envio. Esse tipo de comunicação implementa uma forma síncrona de comunicação entre os processos que é conhecida como *rendezvous*. O problema desta implementação é que a execução dos processos fica limitada ao tempo de processamento no tratamento das mensagens.

Uma variação mais eficiente do *rendezvous* é permitir que o processo transmissor não permaneça bloqueado aguardando a leitura da mensagem pelo processo receptor. Neste caso, é possível a um processo enviar mensagens para diversos destinatários tão logo seja possível.

O terceiro esquema implementa uma forma assíncrona de comunicação, onde tanto o processo receptor quanto o processo transmissor não permanecem aguardando o envio e o recebimento de mensagens. Nesse caso, além da necessidade de buffers para arma-

zenar as mensagens, deve haver outros mecanismos de sincronização que permitam ao processo identificar se uma mensagem já foi enviada ou recebida. A grande vantagem deste mecanismo é aumentar a eficiência de aplicações concorrentes.

Uma solução para o problema do produtor/consumidor é apresentada utilizando a troca de mensagens.

```
PROGRAM Produtor_Consumidor_4;
   PROCEDURE Produtor;
      VAR Msg : Tipo_Msg;
   BEGIN
       REPEAT
           Produz_Mensagem (Msg);
           SEND (Msg);
       UNTIL False;
   END;

   PROCEDURE Consumidor;
      VAR Msg : Tipo_Msg;
   BEGIN
       REPEAT
           RECEIVE (Msg);
           Consome_Mensagem (Msg);
       UNTIL False;
   END;

   BEGIN
       PARBEGIN
           Produtor;
           Consumidor;
       PAREND;
   END.
```

7.10 Deadlock

Deadlock é a situação em que um processo aguarda por um recurso que nunca estará disponível ou um evento que não ocorrerá. Essa situação é conseqüência, na maioria das vezes, do compartilhamento de recursos, como dispositivos, arquivos e registros, entre processos concorrentes onde a exclusão mútua é exigida. O problema do deadlock torna-se cada vez mais freqüente e crítico na medida em que os sistemas operacionais evoluem no sentido de implementar o paralelismo de forma intensiva e permitir a alocação dinâmica de um número ainda maior de recursos.

A Fig. 7.9 ilustra graficamente o problema do deadlock entre os processos PA e PB, quando utilizam os recursos R1 e R2. Inicialmente, PA obtém acesso exclusivo de R1, da mesma forma que PB obtém de R2. Durante o processamento, PA necessita de R2 para poder prosseguir. Como R2 está alocado a PB, PA ficará aguardando que o recurso seja liberado. Em seguida, PB necessita utilizar R1 e, da mesma forma, ficará aguardando até que PA libere o recurso. Como cada processo está esperando que o outro libere o recurso alocado, é estabelecida uma condição conhecida por *espera circular*, caracterizando uma situação de deadlock.

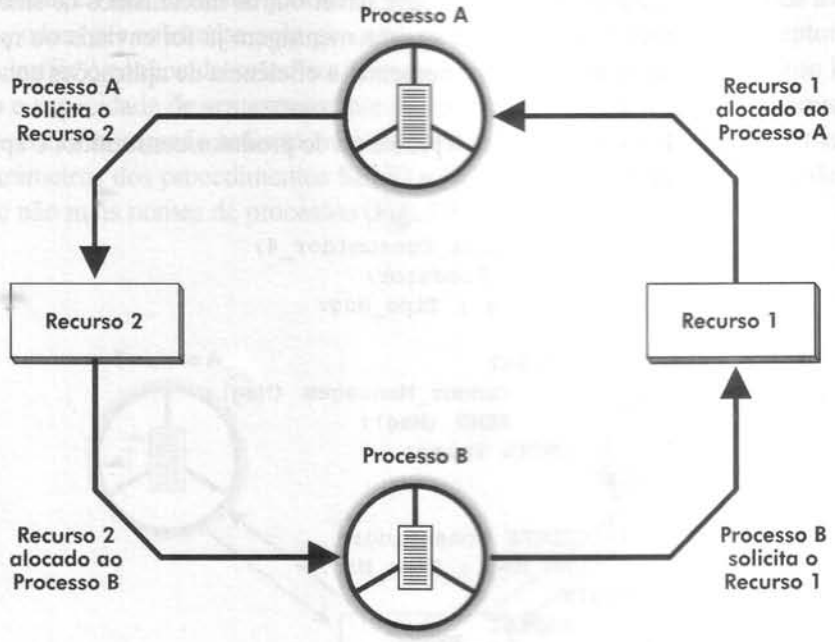

Fig. 7.9 Espera circular.

Para que ocorra a situação de deadlock, quatro condições são necessárias simultaneamente (Coffman, Elphick e Shoshani, 1971):

1. Exclusão mútua: cada recurso só pode estar alocado a um único processo em um determinado instante;
2. Espera por recurso: um processo, além dos recursos já alocados, pode estar esperando por outros recursos;
3. Não-preempção: um recurso não pode ser liberado de um processo só porque outros processos desejam o mesmo recurso;
4. Espera circular: um processo pode ter de esperar por um recurso alocado a outro processo e vice-versa.

O problema do deadlock existe em qualquer sistema multiprogramável; no entanto, as soluções implementadas devem considerar o tipo do sistema e o impacto em seu desempenho. Por exemplo, um deadlock em um sistema de tempo real, que controla uma usina nuclear, deve ser tratado com mecanismos voltados para esse tipo de aplicação, diferentes dos adotados por um sistema de tempo compartilhado comum.

A seguir, são examinados os principais mecanismos de prevenção, detecção e correção de deadlocks.

7.10.1 Prevenção de Deadlock

Para prevenir a ocorrência de deadlocks, é preciso garantir que uma das quatro condições apresentadas, necessárias para sua existência, nunca se satisfaça.

A ausência da primeira condição (exclusão mútua) certamente acaba com o problema do deadlock, pois nenhum processo terá que esperar para ter acesso a um recurso, mesmo que já esteja sendo utilizado por outro processo. Os problemas decorrentes do compartilhamento de recursos entre processos concorrentes sem a exclusão mútua já foram apresentados, inclusive com a exemplificação das sérias inconsistências geradas.

Para evitar a segunda condição (espera por recurso), processos que já possuam recursos garantidos não devem requisitar novos recursos. Uma maneira de implementar esse mecanismo de prevenção é que, antes do início da execução, um processo deve pré-alocar todos os recursos necessários. Nesse caso, todos os recursos necessários ao processo devem estar disponíveis para o início da execução, caso contrário, nenhum recurso será alocado e o processo permanecerá aguardando. Esse mecanismo pode produzir um grande desperdício na utilização dos recursos do sistema, pois um recurso pode permanecer alocado por um grande período de tempo, sendo utilizado apenas por um breve momento. Outra dificuldade, decorrente desse mecanismo, é a determinação do número de recursos que um processo deve alocar antes da sua execução. O mais grave, no entanto, é a possibilidade de um processo sofrer starvation caso os recursos necessários à sua execução nunca estarem disponíveis ao mesmo tempo.

A terceira condição (não-preempção) pode ser evitada quando é permitido que um recurso seja retirado de um processo no caso de outro processo necessitar do mesmo recurso. A liberação de recursos já garantidos por um processo pode ocasionar sérios problemas, podendo até impedir a continuidade de execução do processo. Outro problema desse mecanismo é a possibilidade de um processo sofrer starvation, pois, após garantir os recursos necessários à sua execução, um processo pode ter que liberá-los sem concluir seu processamento.

A última maneira de evitar um deadlock é excluir a possibilidade da quarta condição (espera circular). Uma forma de implementar esse mecanismo é forçar o processo a ter apenas um recurso por vez. Caso o processo necessite de outro recurso, o recurso já alocado deve ser liberado. Esta condição restringiria muito o grau de compartilhamento e o processamento de programas.

A prevenção de deadlocks evitando-se a ocorrência de qualquer uma das quatro condições é bastante limitada e, por isso, não é utilizada na prática. É possível evitar o deadlock, mesmo se todas as condições necessárias à sua ocorrência estejam presentes. A solução mais conhecida para essa situação é o Algoritmo do Banqueiro (Banker's Algorithm) proposto por Dijkstra (1965). Basicamente, este algoritmo exige que os processos informem o número máximo de cada tipo de recurso necessário à sua execução. Com essas informações, é possível definir o estado de alocação de um recurso, que é a relação entre o número de recursos alocados e disponíveis e o número máximo de processos que necessitam desses recursos. Com base nessa relação, o sistema pode fazer a alocação dos recursos de forma segura e evitar a ocorrência de deadlocks. Muitos livros abordam esse algoritmo com detalhes, podendo ser encontrado em Tanenbaum (2001).

Apesar de evitar o problema do deadlock, essa solução possui também várias limitações. A maior delas é a necessidade de um número fixo de processos ativos e de recursos disponíveis no sistema. Essa limitação impede que a solução seja implementada na prática, pois é muito difícil prever o número de usuários no sistema e o número de recursos disponíveis.

7.10.2 Detecção do Deadlock

Em sistemas que não possuam mecanismos que previnam a ocorrência de deadlocks, é necessário um esquema de detecção e correção do problema. A *detecção do deadlock* é o mecanismo que determina, realmente, a existência da situação de deadlock, permitindo identificar os recursos e processos envolvidos no problema.

Para detectar deadlocks, os sistemas operacionais devem manter estruturas de dados capazes de identificar cada recurso do sistema, o processo que o está alocando e os processos que estão à espera da liberação do recurso. Toda vez que um recurso é alocado ou liberado por um processo, a estrutura deve ser atualizada. Geralmente, os algoritmos que implementam esse mecanismo verificam a existência da espera circular, percorrendo toda a estrutura sempre que um processo solicita um recurso e ele não pode ser imediatamente garantido.

Dependendo do tipo de sistema, o ciclo de busca por um deadlock pode variar. Em sistemas de tempo compartilhado, o tempo de busca pode ser maior, sem comprometer o desempenho e a confiabilidade do sistema. Sistemas de tempo real, por sua vez, devem constantemente certificar-se da ocorrência de deadlocks, porém a maior segurança gera maior overhead.

7.10.3 Correção do Deadlock

Após a detecção do deadlock, o sistema operacional deverá de alguma forma corrigir o problema. Uma solução bastante utilizada pela maioria dos sistemas é, simplesmente, eliminar um ou mais processos envolvidos no deadlock e desalocar os recursos já garantidos por eles, quebrando, assim, a espera circular.

A eliminação dos processos envolvidos no deadlock e, conseqüentemente, a liberação de seus recursos podem não ser simples, dependendo do tipo do recurso envolvido. Se um processo estiver atualizando um arquivo ou imprimindo uma listagem, o sistema deve garantir que esses recursos sejam liberados sem problemas. Os processos eliminados não têm como ser recuperados, porém outros processos, que antes estavam em deadlock, poderão prosseguir a execução.

A escolha do processo a ser eliminado é feita, normalmente, de forma aleatória ou, então, com base em algum tipo de prioridade. Este esquema, porém, pode consumir considerável tempo do processador, ou seja, gerando elevado overhead ao sistema.

Uma solução menos drástica envolve a liberação de apenas alguns recursos alocados aos processos para outros processos, até que o ciclo de espera termine. Para que esta solução seja realmente eficiente, é necessário que o sistema possa suspender um pro-

cesso, liberar seus recursos e, após a solução do problema, retornar à execução do processo, sem perder o processamento já realizado. Este mecanismo é conhecido como *rollback* e, além do overhead gerado, é muito difícil de ser implementado, por ser bastante dependente da aplicação que está sendo processada.

7.11 Exercícios

1. Defina o que é uma aplicação concorrente e dê um exemplo de sua utilização.
2. Considere uma aplicação que utilize uma matriz na memória principal para a comunicação entre vários processos concorrentes. Que tipo de problema pode ocorrer quando dois ou mais processos acessam uma mesma posição da matriz?
3. O que é exclusão mútua e como é implementada?
4. Como seria possível resolver os problemas decorrentes do compartilhamento da matriz, apresentado anteriormente, utilizando o conceito de exclusão mútua?
5. O que é starvation e como podemos solucionar esse problema?
6. Qual o problema com a solução que desabilita as interrupções para implementar a exclusão mútua?
7. O que é espera ocupada e qual o seu problema?
8. Explique o que é sincronização condicional e dê um exemplo de sua utilização.
9. Explique o que são semáforos e dê dois exemplos de sua utilização: um para a solução da exclusão mútua e outro para a sincronização condicional.
10. Apresente uma solução para o problema dos Filósofos que permita que os cinco pensadores sentem à mesa, porém evite a ocorrência de starvation e deadlock.
11. Explique o que são monitores e dê dois exemplos de sua utilização: um para a solução da exclusão mútua e outro para a sincronização condicional.
12. Qual a vantagem da forma assíncrona de comunicação entre processos e como esta pode ser implementada?
13. O que é deadlock, quais as condições para obtê-lo e quais as soluções possíveis?
14. Em uma aplicação concorrente que controla saldo bancário em contas-correntes, dois processos compartilham uma região de memória onde estão armazenados os saldos dos clientes A e B. Os processos executam concorrentemente os seguintes passos:

```
Processo 1 (Cliente A)                Processo 2 (Cliente B)
------------------------------------------------------------
/* saque em A */                      /*saque em A */
1a. x := saldo_do_cliente_A;          2a. y := saldo_do_cliente_A;
1b. x := x - 200;                     2b. y := y - 100;
1c. saldo_do_cliente_A := x;          2c. saldo_do_cliente_A := y;

/* deposito em B */                   /* deposito em B */
1d. x := saldo_do_cliente_B;          2d. y := saldo_do_cliente_B;
1e. x := x + 100;                     2e. y := y + 200;
1f. saldo_do_cliente_B := x;          2f. saldo_do_cliente_B := y;
```

Supondo que os valores dos saldos de A e B sejam, respectivamente, 500 e 900, antes de os processos executarem, pede-se:

a) Quais os valores corretos esperados para os saldos dos clientes A e B após o término da execução dos processos?

b) Quais os valores finais dos saldos dos clientes se a seqüência temporal de execução das operações for: 1a, 2a, 1b, 2b, 1c, 2c, 1d, 2d, 1e, 2e, 1f, 2f?

c) Utilizando semáforos, proponha uma solução que garanta a integridade dos saldos e permita o maior compartilhamento possível dos recursos entre os processos, não esquecendo a especificação da inicialização dos semáforos.

15. O problema dos leitores/escritores, apresentado a seguir, consiste em sincronizar processos que consultam/atualizam dados em uma base comum. Pode haver mais de um leitor lendo ao mesmo tempo; no entanto, enquanto um escritor está atualizando a base, nenhum outro processo pode ter acesso a ela (nem mesmo leitores).

```
VAR Acesso: Semaforo := 1;
    Exclusao: Semaforo := 1;
    Nleitores: integer := 0;

PROCEDURE Escritor;
BEGIN
    ProduzDado;
    DOWN (Acesso);
    Escreve;
    UP (Acesso);
END;

PROCEDURE Leitor;
BEGIN
    DOWN (Exclusao);
    Nleitores := Nleitores + 1;
    IF ( Nleitores = 1 ) THEN DOWN (Acesso);
    UP (Exclusao);
    Leitura;
    DOWN (Exclusao);
    Nleitores := Nleitores - 1;
    IF ( Nleitores = 0 ) THEN UP (Acesso);
    UP (Exclusao);
    ProcessaDado;
END;
```

a) Suponha que exista apenas um leitor fazendo acesso à base. Enquanto este processo realiza a leitura, quais os valores das três variáveis?

b) Chega um escritor enquanto o leitor ainda está lendo. Quais os valores das três variáveis após o bloqueio do escritor? Sobre qual(is) semáforo(s) se dá o bloqueio?

c) Chega mais um leitor enquanto o primeiro ainda não acabou de ler e o escritor está bloqueado. Descreva os valores das três variáveis quando o segundo leitor inicia a leitura.

d) Os dois leitores terminam simultaneamente a leitura. É possível haver problemas quanto à integridade do valor da variável Nleitores? Justifique.

e) Descreva o que acontece com o escritor quando os dois leitores terminam suas leituras. Descreva os valores das três variáveis quando o escritor inicia a escrita.

f) Enquanto o escritor está atualizando a base, chegam mais um escritor e mais um leitor. Sobre qual(is) semáforo(s) eles ficam bloqueados? Descreva os valores das três variáveis após o bloqueio dos recém-chegados.
g) Quando o escritor houver terminado a atualização, é possível prever qual dos processos bloqueados (leitor ou escritor) terá acesso primeiro à base?
h) Descreva uma situação onde os escritores sofram starvation (adiamento indefinido).

PARTE III

GERÊNCIA DE RECURSOS

"O que sabemos é uma gota, o que ignoramos é um oceano."

Isaac Newton

"Senhor, dai-nos coragem para mudar as coisas que podem ser mudadas, paciência para aceitar as imutáveis e sabedoria para distinguir umas das outras."

Abraham Lincoln

8

GERÊNCIA DO PROCESSADOR

8.1 Introdução

Com o surgimento dos sistemas multiprogramáveis, onde múltiplos processos poderiam permanecer na memória principal compartilhando o uso da UCP, a gerência do processador tornou-se uma das atividades mais importantes em um sistema operacional. A partir do momento em que diversos processos podem estar no estado de pronto, devem ser estabelecidos critérios para determinar qual processo será escolhido para fazer uso do processador. Os critérios utilizados para esta seleção compõem a chamada *política de escalonamento*, que é a base da gerência do processador e da multiprogramação em um sistema operacional.

Neste capítulo serão abordadas as funções básicas do escalonamento, políticas e algoritmos, e descritos os mecanismos implementados na gerência do processador.

8.2 Funções Básicas

A política de escalonamento de um sistema operacional possui diversas funções básicas, como a de manter o processador ocupado a maior parte do tempo, balan-

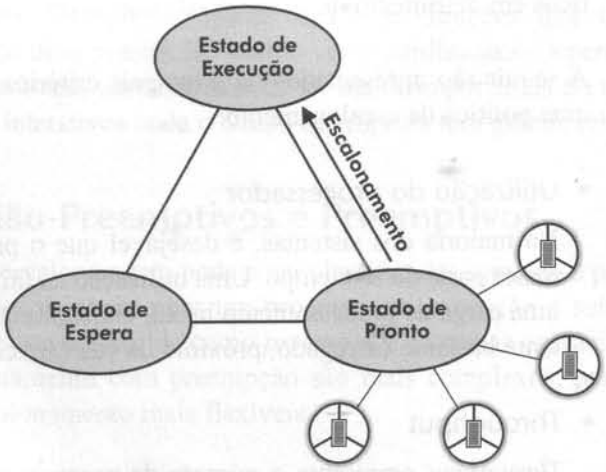

Fig. 8.1 Escalonamento.

cear o uso da UCP entre processos, privilegiar a execução de aplicações críticas, maximizar o throughput do sistema e oferecer tempos de resposta razoáveis para usuários interativos. Cada sistema operacional possui sua política de escalonamento adequada ao seu propósito e às suas características. Sistemas de tempo compartilhado, por exemplo, possuem requisitos de escalonamento distintos dos sistemas de tempo real.

A rotina do sistema operacional que tem como principal função implementar os critérios da política de escalonamento é denominada *escalonador (scheduler)*. Em um sistema multiprogramável, o escalonador é fundamental, pois todo o compartilhamento do processador é dependente dessa rotina.

Outra rotina importante na gerência do processador é conhecida como *dispatcher*, responsável pela troca de contexto dos processos após o escalonador determinar qual processo deve fazer uso do processador. O período de tempo gasto na substituição de um processo em execução por outro é denominado *latência do dispatcher*.

Em ambientes que implementam apenas processos, o escalonamento é realizado com base nos processos prontos para execução. Em sistemas que implementam threads, o escalonamento é realizado considerando os threads no estado de pronto, independente do processo. Neste caso, podemos considerar o processo como sendo a unidade de alocação de recursos, enquanto o thread é a unidade de escalonamento. No decorrer do capítulo, utilizaremos o termo processo de forma genérica, como sendo o elemento selecionado pelo escalonador.

8.3 Critérios de Escalonamento

As características de cada sistema operacional determinam quais são os principais aspectos para a implementação de uma política de escalonamento adequada. Por exemplo, sistemas de tempo compartilhado exigem que o escalonamento trate todos os processos de forma igual, evitando, assim, a ocorrência de starvation, ou seja, que um processo fique indefinidamente esperando pela utilização do processador. Já em sistemas de tempo real, o escalonamento deve priorizar a execução de processos críticos em detrimento da execução de outros processos.

A seguir são apresentados os principais critérios que devem ser considerados em uma política de escalonamento:

- Utilização do processador

  Na maioria dos sistemas, é desejável que o processador permaneça ocupado a maior parte do seu tempo. Uma utilização na faixa de 30% indica um sistema com uma carga de processamento baixa, enquanto que na faixa de 90% indica um sistema bastante carregado, próximo da sua capacidade máxima.

- Throughput

  Throughput representa o número de processos executados em um determinado intervalo de tempo. Quanto maior o throughput, maior o número de tarefas exe-

cutadas em função do tempo. A maximização do throughput é desejada na maioria dos sistemas.

- Tempo de Processador / Tempo de UCP

  Tempo de processador ou *tempo de UCP* é o tempo que um processo leva no estado de execução durante seu processamento. As políticas de escalonamento não influenciam o tempo de processador de um processo, sendo este tempo função apenas do código da aplicação e da entrada de dados.

- Tempo de Espera

  Tempo de espera é o tempo total que um processo permanece na fila de pronto durante seu processamento, aguardando para ser executado. A redução do tempo de espera dos processos é desejada pela maioria das políticas de escalonamento.

- Tempo de Turnaround

  Tempo de turnaround é o tempo que um processo leva desde a sua criação até ao seu término, levando em consideração todo o tempo gasto na espera para alocação de memória, espera na fila de pronto (tempo de espera), processamento na UCP (tempo de processador) e na fila de espera, como nas operações de E/S. As políticas de escalonamento buscam minimizar o tempo de turnaround.

- Tempo de Resposta

  Tempo de resposta é o tempo decorrido entre uma requisição ao sistema ou à aplicação e o instante em que a resposta é exibida. Em sistemas interativos, podemos entender tempo de resposta como o tempo decorrido entre a última tecla digitada pelo usuário e o início da exibição do resultado no monitor. Em geral, o tempo de resposta não é limitado pela capacidade de processamento do sistema computacional, mas pela velocidade dos dispositivos de E/S. Em sistemas interativos, como aplicações on line ou acesso à Web, os tempos de resposta devem ser da ordem de poucos segundos.

De uma maneira geral, qualquer política de escalonamento busca otimizar a utilização do processador e o throughput, enquanto tenta diminuir os tempos de turnaround, espera e resposta. Apesar disso, as funções que uma política de escalonamento deve possuir são muitas vezes conflitantes. Dependendo do tipo de sistema operacional, um critério pode ter maior importância do que outros, como nos sistemas interativos onde o tempo de resposta tem grande relevância.

8.4 Escalonamentos Não-Preemptivos e Preemptivos

As políticas de escalonamento podem ser classificadas segundo a possibilidade de o sistema operacional interromper um processo em execução e substituí-lo por um outro, atividade esta conhecida como *preempção*. Sistemas operacionais que implementam escalonamento com preempção são mais complexos, porém possibilitam políticas de escalonamento mais flexíveis.

O *escalonamento não-preemptivo* foi o primeiro tipo de escalonamento implementado nos sistemas multiprogramáveis, onde predominava tipicamente o processa-

mento batch. Nesse tipo de escalonamento, quando um processo está em execução nenhum evento externo pode ocasionar a perda do uso do processador. O processo somente sai do estado de execução caso termine seu processamento ou execute instruções do próprio código que ocasionem uma mudança para o estado de espera.

O *escalonamento preemptivo* é caracterizado pela possibilidade do sistema operacional interromper um processo em execução e passá-lo para o estado de pronto, com o objetivo de alocar outro processo na UCP. Com o uso da preempção, é possível ao sistema priorizar a execução de processos, como no caso de aplicações de tempo real onde o fator tempo é crítico. Outro benefício é a possibilidade de implementar políticas de escalonamento que compartilhem o processador de uma maneira mais uniforme, distribuindo de forma balanceada o uso da UCP entre os processos.

Atualmente, a maioria dos sistemas operacionais possui políticas de escalonamento preemptivas que, apesar de tornarem os sistemas mais complexos, possibilitam a implementação dos diversos critérios de escalonamento apresentados.

8.5 Escalonamento First-In-First-Out (FIFO)

No *escalonamento first-in-first-out (FIFO scheduling)*, também conhecido como *first-come-first-served (FCFS scheduling)*, o processo que chegar primeiro ao estado de pronto é o selecionado para execução. Este algoritmo é bastante simples, sendo necessária apenas uma fila, onde os processos que passam para o estado de pronto entram no seu final e são escalonados quando chegam ao seu início. Quando o processo em execução termina seu processamento ou vai para o estado de espera, o primeiro processo da fila de pronto é escalonado. Quando saem do estado de espera, todos os processos entram no final da fila de pronto (Fig. 8.2).

Na Fig. 8.3 é possível comparar o uso do escalonamento FIFO em duas situações distintas, onde os processos A, B e C são criados no instante de tempo 0, com os tempos de processador 10, 4 e 3, respectivamente. A diferença entre os exemplos da Fig. 8.3 é o posicionamento dos processos na fila de pronto. O tempo médio de espera dos três processos no exemplo (a) é igual a (0 + 10 + 14)/3 = 8 u.t., enquanto que no exemplo (b) é de aproximadamente (7 + 0 + 4)/3 = 3,7 u.t. A diferença entre as médias é bastante significativa, justificada pela diferença dos tempos de processador entre os processos.

Fig. 8.2 Escalonamento FIFO.

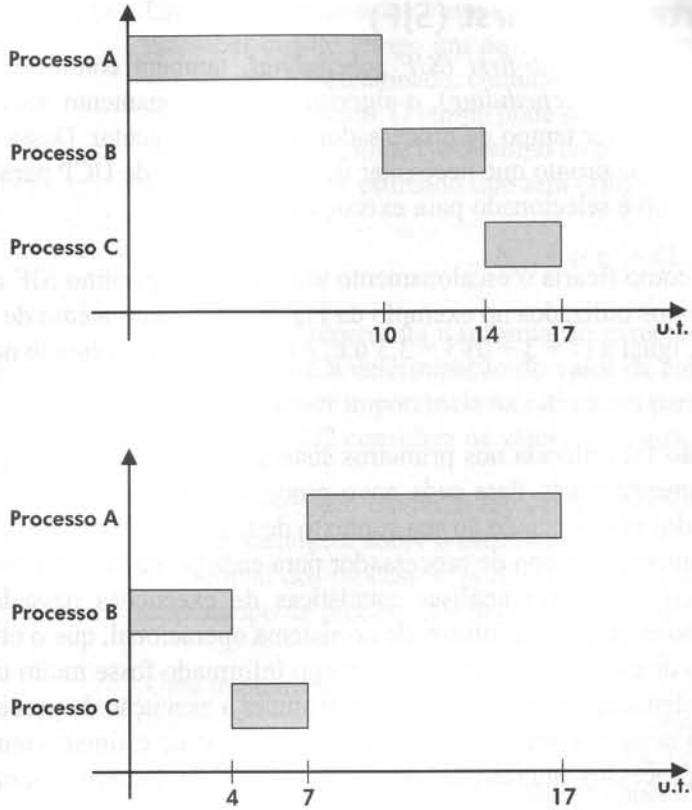

Processo	Tempo de processador (u.t.)
A	10
B	4
C	3

Fig. 8.3 Escalonamento FIFO (exemplo).

Apesar de simples, o escalonamento FIFO apresenta algumas deficiências. O principal problema é a impossibilidade de se prever quando um processo terá sua execução iniciada, já que isso varia em função do tempo de execução dos demais processos posicionados à sua frente na fila de pronto. Como vimos no exemplo da Fig. 8.3, o algoritmo de escalonamento não se preocupa em melhorar o tempo médio de espera dos processos, utilizando apenas a ordem de chegada dos processo à fila de pronto. Esse problema pode ser melhor percebido nos tempos de turnaround dos processos que demandam menor tempo de UCP.

Outro problema nesse tipo de escalonamento é que processos CPU-bound levam vantagem no uso do processador sobre processos I/O-bound. No caso de existirem processos I/O-bound mais importantes do que os CPU-bound, não é possível tratar esse tipo de diferença.

O escalonamento FIFO é do tipo não-preemptivo e foi inicialmente implementado em sistemas monoprogramáveis com processamento batch, sendo ineficiente se aplicado na forma original em sistemas interativos de tempo compartilhado. Atualmente, sistemas de tempo compartilhado utilizam o escalonamento FIFO com variações, permitindo, assim, parcialmente sua implementação.

8.6 Escalonamento Shortest-Job-First (SJF)

No *escalonamento shortest-job-first (SJF scheduling)*, também conhecido como *shortest-process-next (SPN scheduling)*, o algoritmo de escalonamento seleciona o processo que tiver o menor tempo de processador ainda por executar. Dessa forma, o processo em estado de pronto que necessitar de menos tempo de UCP para terminar seu processamento é selecionado para execução.

A Fig. 8.4 mostra como ficaria o escalonamento utilizando o algoritmo SJF a partir dos mesmos processos utilizados no exemplo da Fig. 8.3. O tempo médio de espera dos três processos, igual a (7 + 3 + 0)/3 = 3,3 u.t., é inferior ao apresentado no escalonamento FIFO.

Essa implementação foi utilizada nos primeiros sistemas operacionais com processamento exclusivamente batch. Para cada novo processo admitido no sistema, um tempo de processador era associado ao seu contexto de software. Como não é possível precisar previamente o tempo de processador para cada processo, uma estimativa era realizada com base em análises estatísticas de execuções passadas dos programas. O tempo estimado era informado ao sistema operacional, que o utilizava como no algoritmo de escalonamento. Caso o tempo informado fosse muito inferior ao tempo real, o sistema operacional poderia interromper a execução do processo. O principal problema nesta implementação é a impossibilidade de estimar o tempo de processador para processos interativos, devido à entrada de dados ser uma ação imprevisível.

Uma maneira de implementar o escalonamento SJF em sistemas interativos foi considerar o comportamento do processo nesse ambiente. A característica de um processo interativo é ser escalonado, executar algumas poucas instruções e fazer uma operação de E/S. Após o término da operação, o processo é novamente escalonado, executa mais algumas instruções e faz outra operação de E/S. Esse comportamento se repete até o término do processamento. Nesse caso, o escalonamento é realizado com base no tempo que um processo irá utilizar a UCP na próxima vez em que for escalonado, e não mais no tempo total de processador que utilizará até o término do seu processamento.

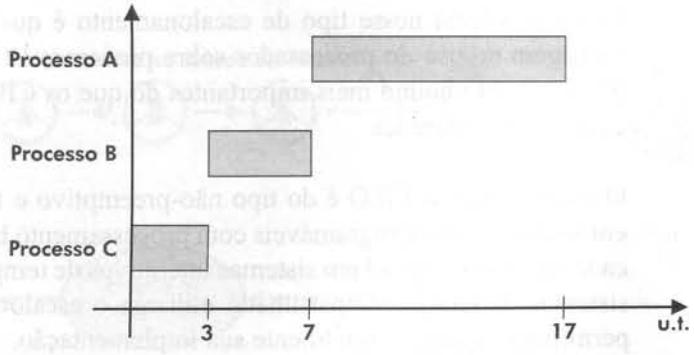

Fig. 8.4 Escalonamento SJF (exemplo).

Um problema existente nesta implementação é não ser possível ao sistema operacional saber quanto tempo um processo irá permanecer utilizando a UCP na próxima vez em que for escalonado, contudo é possível prever o tempo com base no seu comportamento passado. O tempo pode ser estimado com base na média exponencial dos tempos passados, onde t_n é o tempo do processador utilizado no último escalonamento e δ_{n+1} é o valor estimado que será utilizado no escalonamento seguinte:

$$\delta_{n+1} = \alpha\, t_n + (1 - \alpha)\, \delta_n$$

O valor de t_n representa a informação mais recente enquanto que δ_n possui o valor histórico. Com a determinação do valor da constante α $(0 < \alpha < 1)$ é possível ponderar uma maior importância na estimativa para os valores recentes ou passados. Um valor de $\alpha = 1/2$ considera os valores recentes e passados com o mesmo peso.

Na sua concepção inicial, o escalonamento SJF é um escalonamento não-preemptivo. Sua vantagem sobre o escalonamento FIFO está na redução do tempo médio de turnaround dos processos, porém no SJF é possível haver starvation para processos com tempo de processador muito longo ou do tipo CPU-bound.

Uma implementação do escalonamento SJF com preempção é conhecida como *escalonamento shortest remaining time (SRT scheduling)*. Nessa política, toda vez que um processo no estado de pronto tem um tempo de processador estimado menor do que o processo em execução, o sistema operacional realiza uma preempção, substituindo-o pelo novo processo. Semelhante ao SJF, o sistema operacional deve ser o responsável por estimar os tempos de processador dos processos, mas o risco de starvation permanece.

8.7 Escalonamento Cooperativo

O *escalonamento cooperativo* é uma implementação que busca aumentar o grau de multiprogramação em políticas de escalonamentos que não possuam mecanismos de preempção, como o FIFO e o SJF não-preemptivo. Neste caso, um processo em execução pode voluntariamente liberar o processador retornando à fila de pronto, possibilitando que um novo processo seja escalonado e, assim, permitir melhor distribuição no uso do processador.

A principal característica do escalonamento cooperativo está no fato de a liberação do processador ser uma tarefa realizada exclusivamente pelo processo em execução, que de uma maneira cooperativa libera a UCP para um outro processo. Neste mecanismo, o processo em execução verifica periodicamente uma fila de mensagens para determinar se existem outros processos na fila de pronto.

Como a interrupção do processo em execução não é responsabilidade do sistema operacional, algumas situações indesejadas podem ocorrer. No caso de um processo não verificar a fila de mensagens, os demais não terão chance de ser executados até a liberação da UCP pelo processo em execução. Isto pode ocasionar sérios problemas para a multiprogramação cooperativa, na medida em que um programa pode permanecer por um longo período de tempo alocando o processador.

Um exemplo deste tipo de escalonamento pode ser encontrado nos primeiros sistemas operacionais da família Microsoft Windows, sendo conhecido como multitarefa cooperativa.

8.8 Escalonamento Circular

O *escalonamento circular* (*round robin scheduling*) é um escalonamento do tipo preemptivo, projetado especialmente para sistemas de tempo compartilhado. Esse algoritmo é bastante semelhante ao FIFO; porém, quando um processo passa para o estado de execução, existe um tempo limite para o uso contínuo do processador denominado *fatia de tempo* (*time-slice*) ou *quantum*.

No escalonamento circular, toda vez que um processo é escalonado para execução, uma nova fatia de tempo é concedida. Caso a fatia de tempo expire, o sistema operacional interrompe o processo em execução, salva seu contexto e direciona-o para o final da fila de pronto. Esse mecanismo é conhecido como *preempção por tempo*.

A Fig. 8.5 ilustra o escalonamento circular, onde a fila de processos em estado de pronto é tratada como uma fila circular. O escalonamento é realizado alocando a UCP ao primeiro processo da fila de pronto. O processo permanecerá no estado de execução até que termine seu processamento, voluntariamente passe para o estado de espera, ou que sua fatia de tempo expire, sofrendo, neste caso, uma preempção pelo sistema operacional. Após isso, um novo processo é escalonado com base na política de FIFO.

A Fig. 8.6 exemplifica o escalonamento circular com três processos, onde a fatia de tempo é igual a 2 u.t. No exemplo não está sendo levado em consideração o tempo de latência do dispatcher, ou seja, o tempo de troca de contexto entre os processos.

O valor da fatia de tempo depende da arquitetura de cada sistema operacional e, em geral, varia entre 10 e 100 milissegundos. Este valor afeta diretamente o desempenho da política de escalonamento circular. Caso a fatia de tempo tenha um valor muito alto, este escalonamento tenderá a ter o mesmo comportamento do escalonamento

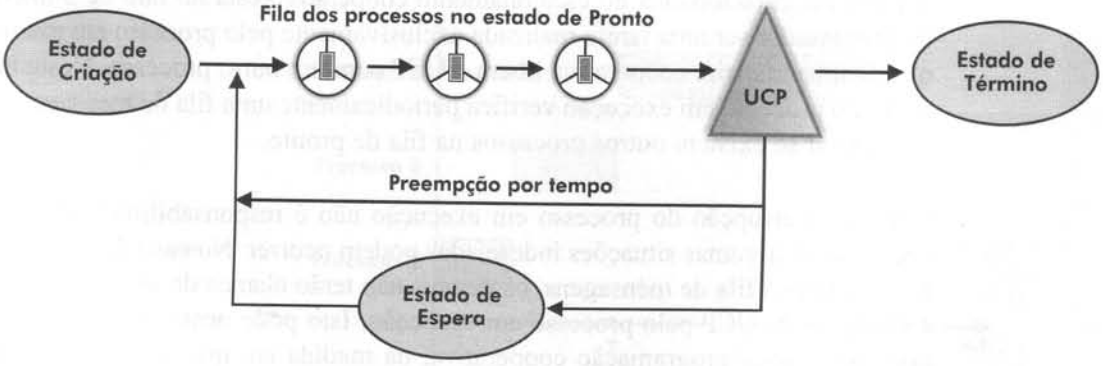

Fig. 8.5 Escalonamento circular.

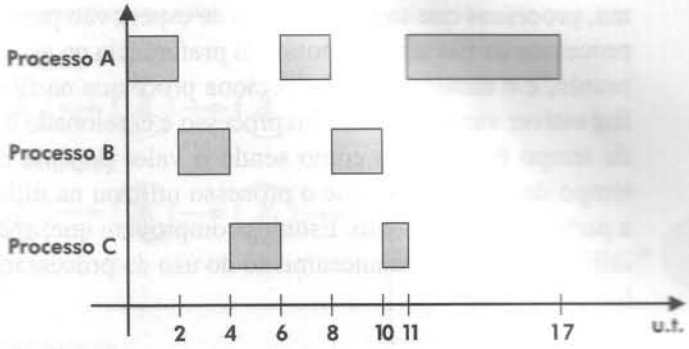

Fig. 8.6 Escalonamento circular (exemplo).

FIFO. Caso o valor do time slice seja pequeno, a tendência é que haja um grande número de preempções, o que ocasionaria excessivas mudanças de contexto, prejudicando o desempenho do sistema e afetando o tempo de turnaround dos processos.

A principal vantagem do escalonamento circular é não permitir que um processo monopolize a UCP, sendo o tempo máximo alocado continuamente igual à fatia de tempo definido no sistema. No caso de sistemas de tempo compartilhado, onde existem diversos processos interativos concorrendo pelo uso do processador, o escalonamento circular é adequado.

Um problema presente nessa política é que processos CPU-bound são beneficiados no uso do processador em relação aos processos I/O-bound. Devido às suas características, os processos CPU-bound tendem a utilizar por completo a fatia de tempo, enquanto os processos I/O-bound têm mais chances de passar para o estado de espera antes de sofrerem preempção por tempo. Estas características distintas ocasionam um balanceamento desigual no uso do processsador entre os processos.

Um refinamento do escalonamento circular, que busca reduzir este problema, é conhecido como *escalonamento circular virtual*, ilustrado na Fig. 8.7. Nesse esque-

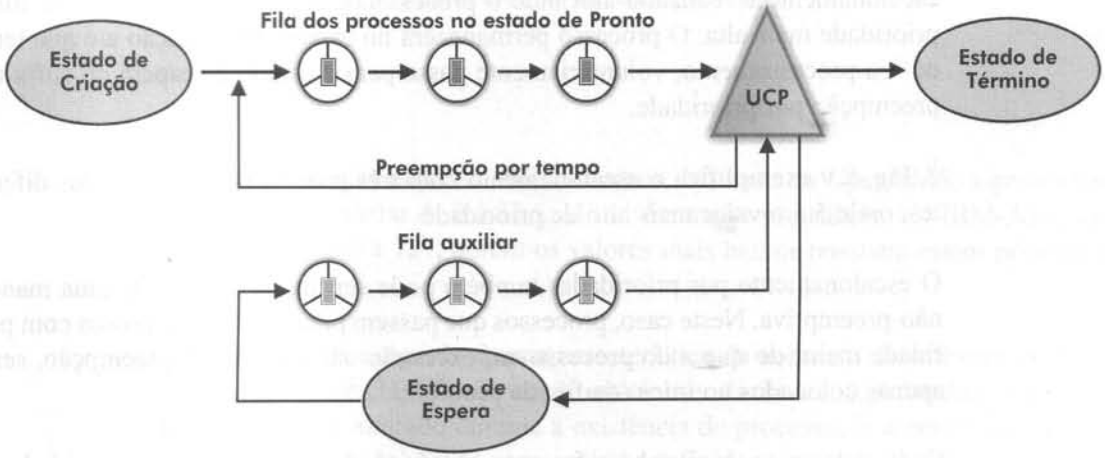

Fig. 8.7 Escalonamento circular virtual.

ma, processos que saem do estado de espera vão para uma fila de pronto auxiliar. Os processos da fila auxiliar possuem preferência no escalonamento em relação à fila de pronto, e o escalonador só seleciona processos na fila de pronto quando a fila auxiliar estiver vazia. Quando um processo é escalonado a partir da fila auxiliar, sua fatia de tempo é calculada como sendo o valor da fatia de tempo do sistema menos o tempo de processador que o processo utilizou na última vez em que foi escalonado a partir da fila de pronto. Estudos comprovam que, apesar da maior complexidade na implementação, o balanceamento do uso do processador neste esquema é mais equilibrado.

8.9 Escalonamento por Prioridades

O *escalonamento por prioridades* é um escalonamento do tipo preemptivo realizado com base em um valor associado a cada processo denominado *prioridade de execução*. O processo com maior prioridade no estado de pronto é sempre o escolhido para execução, e processos com valores iguais são escalonados seguindo o critério de FIFO. Neste escalonamento, o conceito de fatia de tempo não existe; conseqüentemente, um processo em execução não pode sofrer preempção por tempo.

No escalonamento por prioridades, a perda do uso do processador só ocorrerá no caso de uma mudança voluntária para o estado de espera ou quando um processo de prioridade maior passa para o estado de pronto. Neste caso, o sistema operacional deverá interromper o processo corrente, salvar seu contexto e colocá-lo no estado de pronto. Esse mecanismo é conhecido como *preempção por prioridade*. Após isso, o processo de maior prioridade é escalonado.

A preempção por prioridade é implementada através de uma interrupção de clock, gerada em determinados intervalos de tempo, para que a rotina de escalonamento reavalie as prioridades dos processos no estado de pronto. Caso haja processos na fila de pronto com maior prioridade do que o processo em execução, o sistema operacional realiza a preempção.

A Fig. 8.8 ilustra o escalonamento por prioridades, onde para cada prioridade existe uma fila de processos em estado de pronto que é tratada como uma fila circular. O escalonamento é realizado alocando o processador ao primeiro processo da fila de prioridade mais alta. O processo permanecerá no estado de execução até que termine seu processamento, voluntariamente passe para o estado de espera ou sofra uma preempção por prioridade.

A Fig. 8.9 exemplifica o escalonamento com três processos de prioridades diferentes, onde 5 é o valor mais alto de prioridade.

O escalonamento por prioridades também pode ser implementado de uma maneira não-preemptiva. Neste caso, processos que passem para o estado de pronto com prioridade maior do que a do processo em execução não ocasionam preempção, sendo apenas colocados no início da fila de pronto.

Cada sistema operacional implementa sua faixa de valores para as prioridades de execução. Alguns sistemas associam as maiores prioridades a valores altos, enquan-

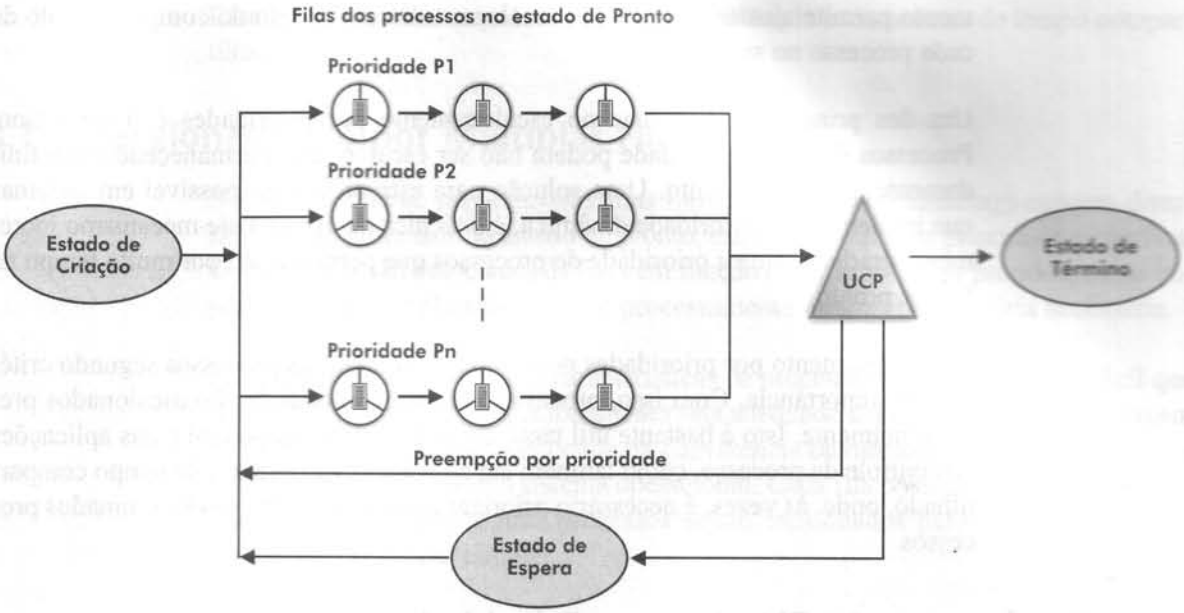

Fig. 8.8 Escalonamento por prioridades.

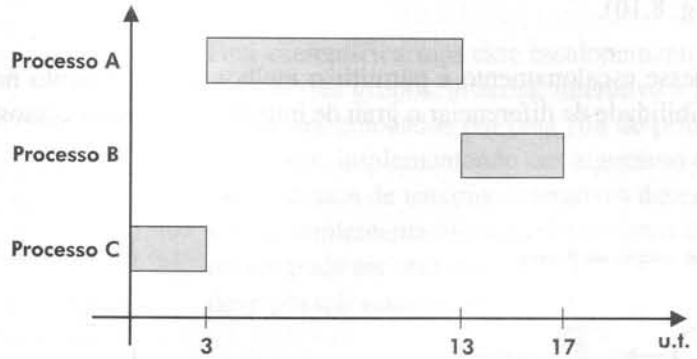

Processo	Tempo de processador (u.t.)	Prioridade
A	10	2
B	4	1
C	3	3

Fig. 8.9 Escalonamento por prioridades (exemplo).

to outros sistemas utilizam valores baixos. No caso do OpenVMS, a prioridade do processo pode variar de 0 a 31, onde 31 é a maior prioridade. No IBM-AIX, a prioridade varia de 0 a 127, porém os valores mais baixos possuem maior prioridade de execução.

A prioridade de execução é uma característica do contexto de software de um processo e pode ser classificada como estática ou dinâmica. A *prioridade estática* não tem o seu valor alterado durante a existência do processo, já a *prioridade dinâmica* pode ser ajustada de acordo com critérios definidos pelo sistema operacional. A possibilidade de alterar o valor da prioridade de um processo ao longo de seu processa-

mento permite ajustar o critério de escalonamento em função do comportamento de cada processo no sistema.

Um dos principais problemas no escalonamento por prioridades é o starvation. Processos de baixa prioridade podem não ser escalonados, permanecendo indefinidamente na fila de pronto. Uma solução para este problema, possível em sistemas que implementam prioridade dinâmica, é a técnica de *aging*. Este mecanismo incrementa gradualmente a prioridade de processos que permanecem por muito tempo na fila de pronto.

O escalonamento por prioridades possibilita diferenciar os processos segundo critérios de importância. Com isso, processos de maior prioridade são escalonados preferencialmente. Isto é bastante útil tanto em sistemas de tempo real e nas aplicações de controle de processo, como também em aplicações de sistemas de tempo compartilhado, onde, às vezes, é necessário priorizar o escalonamento de determinados processos.

8.10 Escalonamento Circular com Prioridades

O *escalonamento circular com prioridades* implementa o conceito de fatia de tempo e de prioridade de execução associada a cada processo. Neste tipo de escalonamento, um processo permanece no estado de execução até que termine seu processamento, voluntariamente passe para o estado de espera ou sofra uma preempção por tempo ou prioridade (Fig. 8.10).

A principal vantagem desse escalonamento é permitir o melhor balanceamento no uso da UCP, com a possibilidade de diferenciar o grau de importância dos processos.

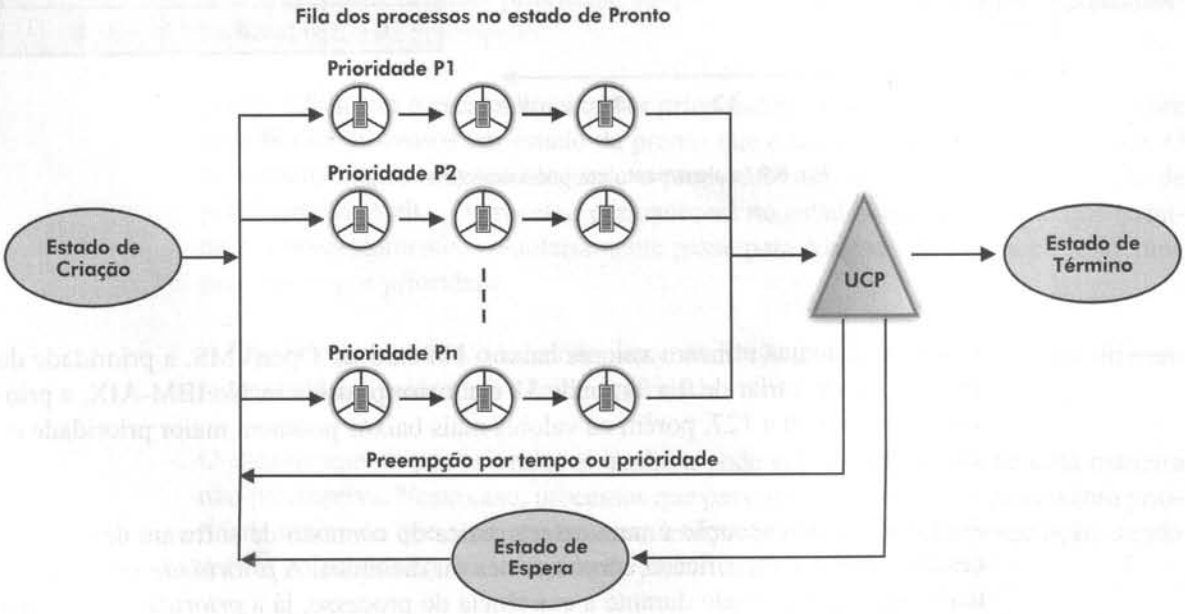

Fig. 8.10 Escalonamento circular com prioridades.

Esse tipo de escalonamento é amplamente utilizado em sistemas de tempo compartilhado.

8.11 Escalonamento por Múltiplas Filas

No *escalonamento por múltiplas filas* (*multilevel queue scheduling*) existem diversas filas de processos no estado de pronto, cada qual com uma prioridade específica. Os processos são associados às filas em função de características próprias, como importância para a aplicação, tipo de processamento ou área de memória necessária.

Como os processos possuem características de processamento distintas, é difícil que um único mecanismo de escalonamento seja adequado a todos. A principal vantagem de múltiplas filas é a possibilidade da convivência de mecanismos de escalonamento distintos em um mesmo sistema operacional. Cada fila possui um mecanismo próprio, permitindo que alguns processos sejam escalonados pelo mecanismo FIFO, enquanto outros pelo circular.

Neste mecanismo, o processo não possui prioridade, ficando esta característica associada à fila. O processo em execução sofre preempção caso um outro processo entre em uma fila de maior prioridade. O sistema operacional só pode escalonar processos de uma determinada fila caso todas as outras filas de maior prioridade estejam vazias. Uma boa prática é classificar os processos em função do tipo de processamento realizado e associá-los adequadamente às respectivas filas.

Para exemplificarmos esse escalonamento, considere que os processos sejam divididos em três grupos: sistema, interativo e batch (Fig. 8.11). Os processos do sistema devem ser colocados em uma fila de prioridade mais alta com relação à dos outros processos, implementando um algoritmo de escalonamento baseado em prioridades. Os processos de usuários interativos devem estar em uma fila de prioridade intermediária, implementando o escalonamento circular. O mesmo mecanismo de escalonamento pode ser utilizado na fila de processos batch, com a diferença de que esta fila deve possuir uma prioridade mais baixa.

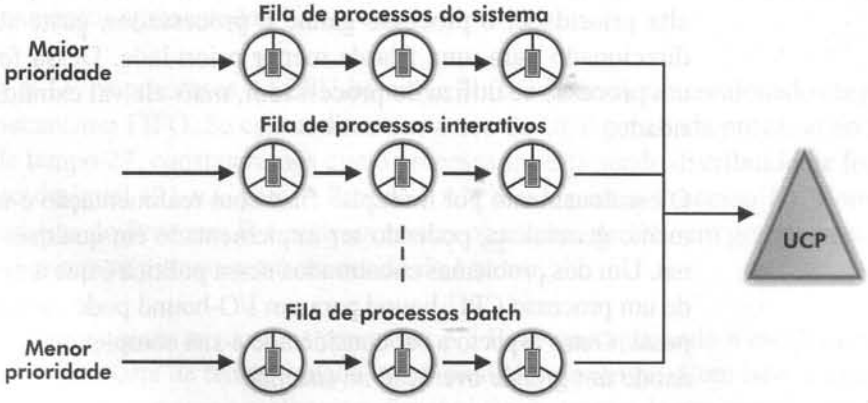

Fig. 8.11 Escalonamento por múltiplas filas.

Uma desvantagem deste escalonamento é que, no caso de um processo alterar seu comportamento no decorrer do tempo, o processo não poderá ser redirecionado para uma outra fila mais adequada. A associação de um processo à fila é determinada na criação do processo, permanecendo até o término do seu processamento.

8.12 Escalonamento por Múltiplas Filas com Realimentação

O *escalonamento por múltiplas filas com realimentação (multilevel feedback queues scheduling)* é semelhante ao escalonamento por múltiplas filas, porém os processos podem trocar de fila durante seu processamento. Sua grande vantagem é permitir ao sistema operacional identificar dinamicamente o comportamento de cada processo, direcionando-o para fila com prioridade de execução e mecanismo de escalonamento mais adequados ao longo de seu processamento.

Esse esquema permite que os processos sejam redirecionados entre as diversas filas, fazendo com que o sistema operacional implemente um mecanismo de ajuste dinâmico denominado *mecanismo adaptativo*. Os processos não são previamente associados às filas de pronto, e, sim, direcionados pelo sistema para as filas existentes com base no seu comportamento.

Um mecanismo FIFO adaptado com fatia de tempo é implementado para escalonamento em todas as filas, com exceção da fila de menor prioridade que utiliza o escalonamento circular. O escalonamento de um processo em uma fila ocorre apenas quando todas as outras filas de prioridades mais altas estiverem vazias. A fatia de tempo em cada fila varia em função da sua prioridade, ou seja, quanto maior a prioridade da fila, menor sua fatia de tempo (Fig. 8.12). Sendo assim, a fatia de tempo concedida aos processos varia em função da fila de pronto na qual ele se encontra. Um processo, quando criado, entra no final da fila de maior prioridade, porém durante sua execução, a cada preempção por tempo, o processo é redirecionado para uma fila de menor prioridade.

Este escalonamento atende às necessidades dos diversos tipos de processos. No caso de processos I/O-bound, um tempo de resposta adequado é obtido, já que esses processos têm prioridades mais altas por permanecerem a maior parte do tempo nas filas de maior prioridade, pois dificilmente sofrerão preempção por tempo. Por outro lado, em processos CPU-bound a tendência é de que, ao entrar na fila de mais alta prioridade, o processo ganhe o processador, gaste sua fatia de tempo, e seja direcionado para uma fila de menor prioridade. Dessa forma, quanto mais tempo um processo se utiliza do processador, mais ele vai caindo para filas de menor prioridade.

O escalonamento por múltiplas filas com realimentação é um algoritmo de escalonamento generalista, podendo ser implementado em qualquer tipo de sistema operacional. Um dos problemas encontrados nessa política é que a mudança de comportamento de um processo CPU-bound para um I/O-bound pode comprometer seu tempo de resposta. Outro aspecto a ser considerado é sua complexidade de implementação, ocasionando um grande overhead ao sistema.

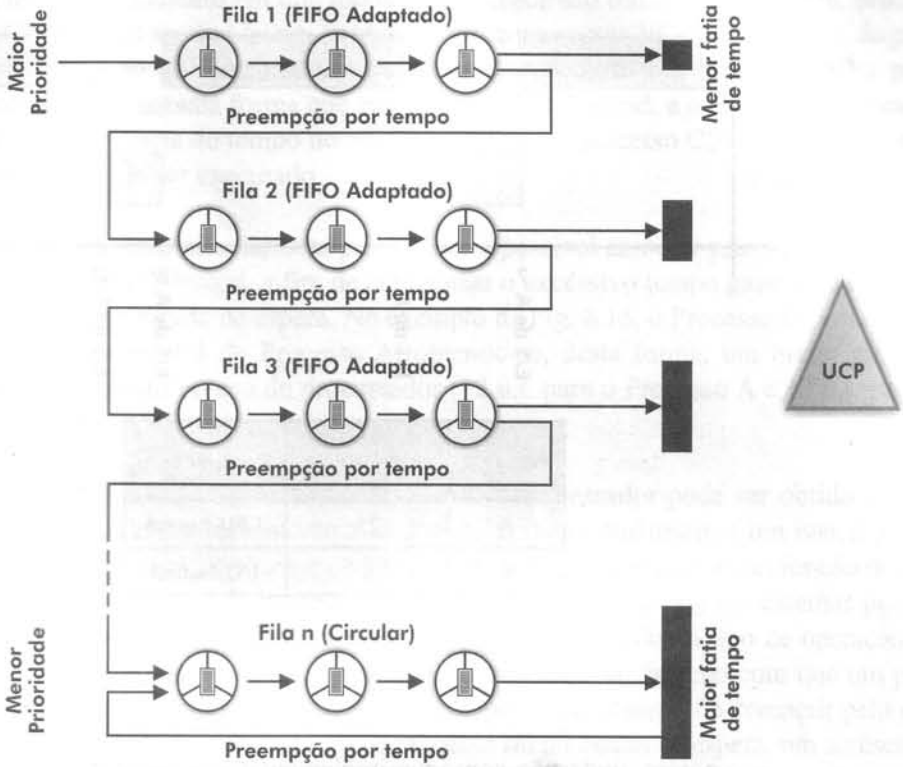

Fig. 8.12 Escalonamento por múltiplas filas com realimentação.

8.13 Política de Escalonamento em Sistemas de Tempo Compartilhado

Em geral, sistemas de tempo compartilhado caracterizam-se pelo processamento interativo, onde usuários interagem com as aplicações exigindo tempos de respostas baixos. A escolha de uma política de escalonamento para atingir este propósito deve levar em consideração o compartilhamento dos recursos de forma eqüitativa para possibilitar o uso balanceado da UCP entre processos. Neste item, serão analisados os comportamentos de um processo CPU-bound e outro I/O-bound, nos principais escalonamentos apresentados.

Na Fig. 8.13, os processos A (CPU-bound) e B (I/O-bound) são escalonados segundo o mecanismo FIFO. Se contabilizarmos o uso da UCP para cada processo no instante de tempo 27, constataremos que o processador está sendo distribuído de forma bastante desigual (21 u.t. para o Processo A e 6 u.t. para o Processo B). Como a característica do Processo B é realizar muitas operações de E/S, em grande parte do tempo o processo permanecerá no estado de espera.

A Fig. 8.14 apresenta os mesmos processos A e B, só que aplicando o escalonamento circular com fatia de tempo igual a cinco unidades de tempo. Com isso, o escalonamento circular consegue melhorar a distribuição do tempo de processador (15 u.t. para o Processo A e 10 u.t. para o Processo B) em relação ao escalonamento FIFO,

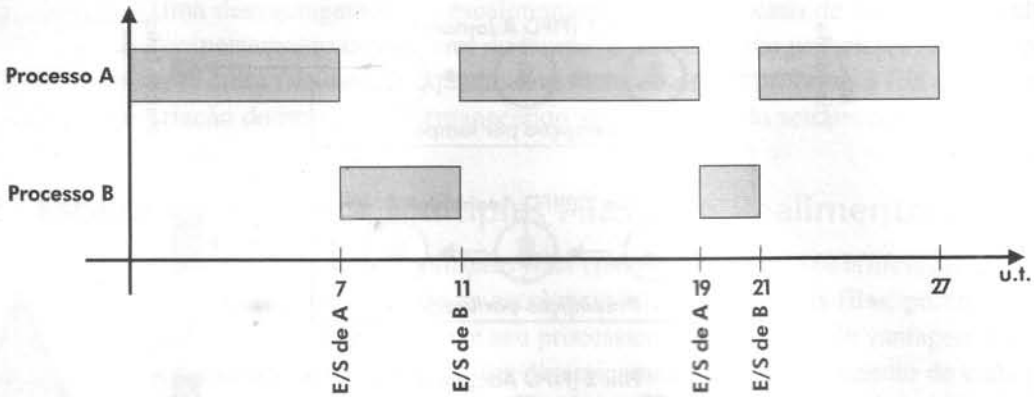

Processo	Tempo de processador (u.t.)	Característica
A	21	CPU-bound
B	6	I/O-bound

Fig. 8.13 Escalonamento FIFO (exemplo).

porém ainda não consegue implementar um compartilhamento eqüitativo entre os diferentes tipos de processos. Essa deficiência no escalonamento circular deve-se ao fato de todos os processos serem tratados de uma maneira igual, o que nem sempre é desejável.

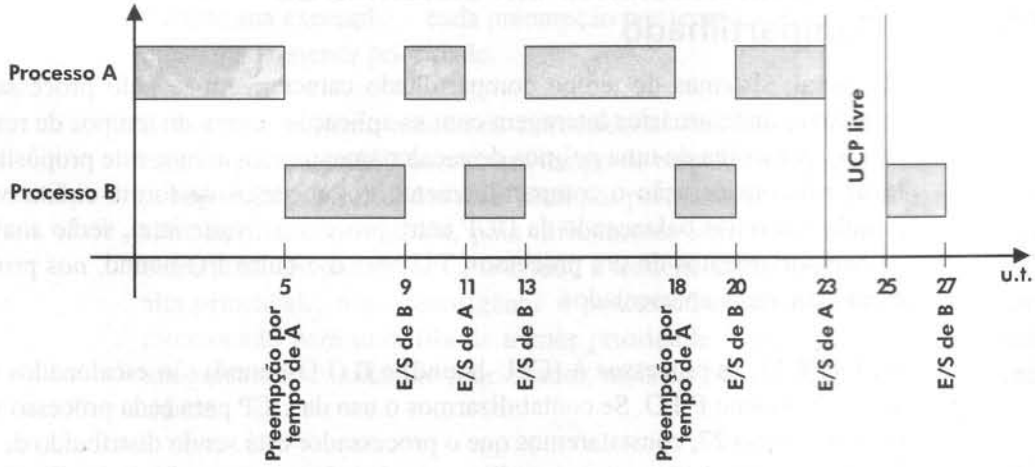

Processo	Tempo de processador (u.t.)	Característica
A	15	CPU-bound
B	10	I/O-bound

Fig. 8.14 Escalonamento circular (exemplo).

Em um escalonamento em que todos os processos são tratados igualmente, processos CPU-bound sempre levam vantagem sobre processos I/O-bound no uso do processador. Como no escalonamento circular um processo I/O-bound compete pelo processador da mesma forma que um processo CPU-bound, e o processo I/O-bound passa a maior parte do tempo no estado de espera, o processo CPU-bound tem mais oportunidade de ser executado.

No escalonamento circular com prioridades é possível associar prioridades maiores aos processos I/O-bound, a fim de compensar o excessivo tempo gasto por este tipo de processo no estado de espera. No exemplo da Fig. 8.15, o Processo B possui uma prioridade superior à do Processo A, obtendo-se, desta forma, um maior grau de compartilhamento no uso do processador (12 u.t. para o Processo A e 13 u.t. para o Processo B).

Um refinamento no balanceamento do uso do processador pode ser obtido implementando-se o escalonamento circular com prioridades dinâmicas. Com isso, é possível ao administrador do sistema alterar a prioridade de um processo em função do uso excessivo ou reduzido do processador. Outro benefício é que alguns sistemas podem alterar dinamicamente a prioridade dos processos em função do tipo de operação de E/S realizada. Algumas operações de E/S são mais lentas, fazendo com que um processo permaneça mais tempo no estado de espera sem chances de competir pelo uso do processador. Nesse caso, quando o processo sai do estado de espera, um acréscimo temporário à sua prioridade é concedido pelo sistema operacional. Dessa forma, os processos têm maiores chances de serem escalonados, compensando parcialmente o

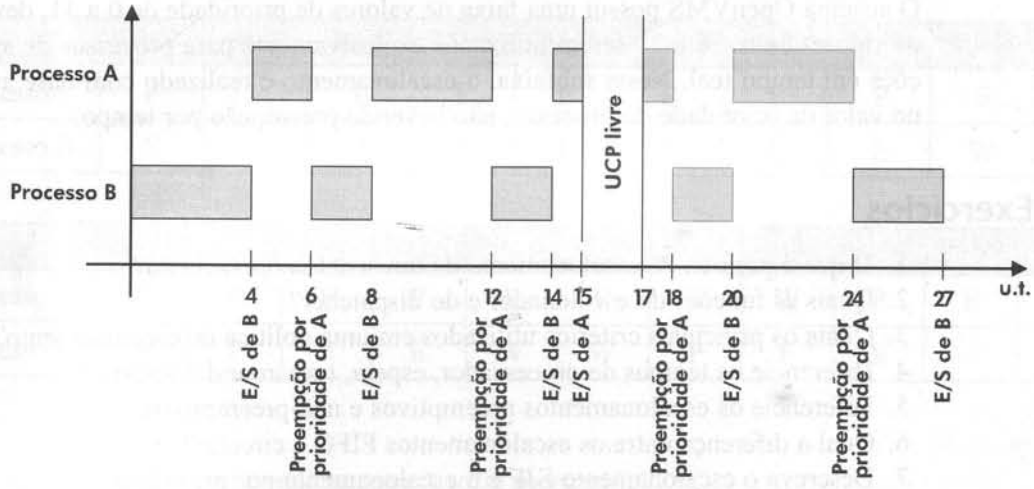

Processo	Tempo de processador (u.t.)	Característica	Prioridade
A	12	CPU-bound	Baixa
B	13	I/O-bound	Alta

Fig. 8.15 Escalonamento circular com prioridades (exemplo).

tempo gasto no estado de espera. É importante perceber que os processos CPU-bound não são prejudicados com essa política, pois podem ser executados durante o período em que os processos I/O-bound estão no estado de espera.

Embora os sistemas com prioridade dinâmica sejam mais complexos de implementar que os sistemas com prioridade estática, o tempo de resposta oferecido compensa. Atualmente, a maioria dos sistemas operacionais de tempo compartilhado utiliza o escalonamento circular com prioridades dinâmicas.

8.14 Política de Escalonamento em Sistemas de Tempo Real

Diferentemente dos sistemas de tempo compartilhado, onde a aplicação não é prejudicada pela variação no tempo de resposta, algumas aplicações específicas exigem respostas imediatas para a execução de determinadas tarefas. Nesse caso, a aplicação deve ser executada em sistemas operacionais de tempo real, onde é garantida a execução de processos dentro de limites rígidos de tempo, sem o risco de a aplicação ficar comprometida. Aplicações de controle de processos, como sistemas de controle de produção de bens industriais e controle de tráfego aéreo, são exemplos de aplicação de tempo real.

O escalonamento em sistemas de tempo real deve levar em consideração a importância relativa de cada tarefa na aplicação. Em função disso, o escalonamento por prioridades é o mais adequado, já que para cada processo uma prioridade é associada em função da importância do processo dentro da aplicação. No escalonamento para sistemas de tempo real não deve existir o conceito de fatia de tempo e a prioridade de cada processo deve ser estática.

O sistema OpenVMS possui uma faixa de valores de prioridade de 0 a 31, devendo os valores entre 16 e 31 serem utilizados exclusivamente para processos de aplicações em tempo real. Nesta subfaixa, o escalonamento é realizado com base apenas no valor da prioridade do processo, não havendo preempção por tempo.

8.15 Exercícios

1. O que é política de escalonamento de um sistema operacional?
2. Quais as funções do escalonador e do dispatcher?
3. Quais os principais critérios utilizados em uma política de escalonamento?
4. Diferencie os tempos de processador, espera, turnaround e resposta.
5. Diferencie os escalonamentos preemptivos e não-preemptivos.
6. Qual a diferença entre os escalonamentos FIFO e circular?
7. Descreva o escalonamento SJF e o escalonamento por prioridades.
8. Qual a diferença entre preempção por tempo e preempção por prioridade?
9. O que é um mecanismo de escalonamento adaptativo?
10. Que tipo de escalonamento as aplicações de tempo real exigem?
11. O escalonamento por múltiplas filas com realimentação favorece processos CPU-bound ou I/O-bound? Justifique.
12. Considere que cinco processos sejam criados no instante de tempo 0 (P1, P2, P3, P4 e P5) e possuam as características descritas na tabela a seguir:

Processo	Tempo de UCP	Prioridade
P1	10	3
P2	14	4
P3	5	1
P4	7	2
P5	20	5

Desenhe um diagrama ilustrando o escalonamento dos processos e seus respectivos tempos de turnaround, segundo as políticas especificadas a seguir. O tempo de troca de contexto deve ser desconsiderado.

a) FIFO
b) SJF
c) Prioridade (número menor implica prioridade maior)
d) Circular com fatia de tempo igual a 2 u.t.

13. Considere um sistema operacional com escalonamento por prioridades onde a avaliação do escalonamento é realizada em um intervalo mínimo de 5 ms. Neste sistema, os processos A e B competem por uma única UCP. Desprezando os tempos de processamento relativo às funções do sistema operacional, a tabela a seguir fornece os estados dos processos A e B ao longo do tempo, medido em intervalos de 5 ms (E = execução, P = pronto e W = espera). O processo A tem menor prioridade que o processo B.

	00-04	05-09	10-14	15-19	20-24	25-29	30-34	35-39	40-44	45-49
ProcessoA	P	P	E	E	E	P	P	P	E	W
Processo B	E	E	W	W	P	E	E	E	W	W

	50-54	55-59	60-64	65-69	70-74	75-79	80-84	85-89	90-94	95-99	100-105
Processo A	P	E	P	P	E	E	W	W	P	E	E
Processo B	W	P	E	E	W	W	P	E	E	–	–

a) Em que tempos A sofre preempção?
b) Em que tempos B sofre preempção?
c) Refaça a tabela anterior supondo que o processo A é mais prioritário que o processo B.

14. Como o valor do quantum pode afetar o grau de multiprogramação em um sistema operacional? Qual a principal desvantagem de um quantum com um valor muito pequeno?
15. Considere um sistema operacional que implemente escalonamento circular com fatia de tempo igual a 10 u.t. Em um determinado instante de tempo, existem

apenas três processos (P1, P2 e P3) na fila de pronto, e o tempo de UCP de cada processo é 18, 4 e 13 u.t., respectivamente. Qual o estado de cada processo no instante de tempo T, considerando a execução dos processos P1, P2 e P3, nesta ordem, e que nenhuma operação de E/S é realizada?

a) T = 8 u.t.

b) T = 11 u.t.

c) T = 33 u.t.

16. Considere um sistema operacional que implemente escalonamento circular com fatia de tempo igual a 10 u.t. Em um determinado instante de tempo, existem apenas três processos (P1, P2 e P3) na fila de pronto, e o tempo de UCP de cada processo é 14, 4 e 12 u.t., respectivamente. Qual o estado de cada processo no instante de tempo T, considerando a execução dos processos P1, P2 e P3, nesta ordem, e que apenas o processo P1 realiza operações de E/S? Cada operação de E/S é executada após 5 u.t. e consome 10 u.t.

a) T = 8 u.t.

b) T = 18 u.t.

c) T = 28 u.t.

17. Existem quatro processos (P1, P2, P3 e P4) na fila de pronto, com tempos de UCP estimados em 9, 6, 3 e 5, respectivamente. Em que ordem os processos devem ser executados para minimizar o tempo de turnaround dos processos?

18. Considere a tabela a seguir onde:

Processo	Tempo de UCP	Prioridade
P1	40	4
P2	20	3
P3	50	1
P4	30	3

Qual o tempo de turnaround médio dos processos, considerando o tempo de troca de contexto igual a 0 e a 5 u.t. para os seguintes escalonamentos:

a) FIFO

b) SJF

c) Circular com fatia de tempo igual a 20 u.t.

d) Prioridades

9

GERÊNCIA DE MEMÓRIA

9.1 Introdução

Historicamente, a memória principal sempre foi vista como um recurso escasso e caro. Uma das maiores preocupações dos projetistas foi desenvolver sistemas operacionais que não ocupassem muito espaço de memória e, ao mesmo tempo, otimizassem a utilização dos recursos computacionais. Mesmo atualmente, com a redução de custo e conseqüente aumento da capacidade da memória principal, seu gerenciamento é um dos fatores mais importantes no projeto de sistemas operacionais.

Enquanto nos sistemas monoprogramáveis a gerência da memória não é muito complexa, nos sistemas multiprogramáveis essa gerência se torna crítica, devido à necessidade de se maximizar o número de usuários e aplicações utilizando eficientemente o espaço da memória principal.

Neste capítulo apresentaremos os esquemas básicos de gerência da memória principal, mostrando suas vantagens, desvantagens e implementações, numa seqüência quase evolutiva. Esses conhecimentos serão úteis para a compreensão das motivações que levaram à ampla adoção do mecanismo de gerência de memória virtual nos sistemas operacionais modernos, apresentado no próximo capítulo.

9.2 Funções Básicas

Em geral, programas são armazenados em memórias secundárias, como disco ou fita, por ser um meio não-volátil, abundante e de baixo custo. Como o processador somente executa instruções localizadas na memória principal, o sistema operacional deve sempre transferir programas da memória secundária para a memória principal antes de serem executados. Como o tempo de acesso à memória secundária é muito superior ao tempo de acesso à memória principal, o sistema operacional deve buscar reduzir o número de operações de E/S à memória secundária, caso contrário, sérios problemas no desempenho do sistema podem ser ocasionados.

A gerência de memória deve tentar manter na memória principal o maior número de processos residentes, permitindo maximizar o compartilhamento do processador e demais recursos computacionais. Mesmo na ausência de espaço livre, o sistema deve permitir que novos processos sejam aceitos e executados. Isso é possível através da

transferência temporária de processos residentes na memória principal para a memória secundária, liberando espaço para novos processos. Este mecanismo é conhecido como swapping e será detalhado posteriormente.

Outra preocupação na gerência de memória é permitir a execução de programas que sejam maiores que a memória física disponível, implementado através de técnicas como overlay e memória virtual.

Em um ambiente de multiprogramação, o sistema operacional deve proteger as áreas de memória ocupadas por cada processo, além da área onde reside o próprio sistema. Caso um programa tente realizar algum acesso indevido à memória, o sistema de alguma forma deve impedi-lo. Apesar de a gerência de memória garantir a proteção de áreas da memória, mecanismos de compartilhamento devem ser oferecidos para que diferentes processos possam trocar dados de forma protegida.

9.3 Alocação Contígua Simples

A *alocação contígua simples* foi implementada nos primeiros sistemas operacionais, porém ainda está presente em alguns sistemas monoprogramáveis. Nesse tipo de organização, a memória principal é subdividida em duas áreas: uma para o sistema operacional e outra para o programa do usuário (Fig. 9.1). Dessa forma, o programador deve desenvolver suas aplicações, preocupado, apenas, em não ultrapassar o espaço de memória disponível, ou seja, a diferença entre o tamanho total da memória principal e a área ocupada pelo sistema operacional.

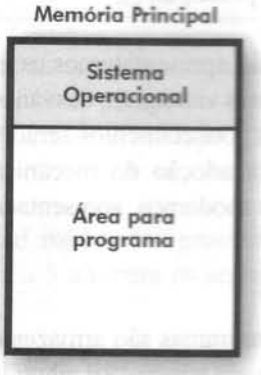

Fig. 9.1 Alocação contígua simples.

Nesse esquema, o usuário tem controle sobre toda a memória principal, podendo ter acesso a qualquer posição de memória, inclusive a área do sistema operacional. Para proteger o sistema desse tipo de acesso, que pode ser intencional ou não, alguns sistemas implementam proteção através de um registrador que delimita as áreas do sistema operacional e do usuário (Fig. 9.2). Dessa forma, sempre que um programa faz referência a um endereço na memória, o sistema verifica se o endereço está dentro dos limites

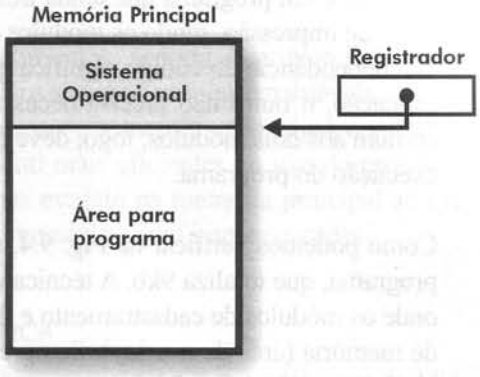

Fig. 9.2 Proteção na alocação contígua simples.

permitidos. Caso não esteja, o programa é cancelado e uma mensagem de erro é gerada, indicando que houve uma violação no acesso à memória principal.

Apesar da fácil implementação e do código reduzido, a alocação contígua simples não permite a utilização eficiente dos recursos computacioanais, pois apenas um usuário pode dispor desses recursos. Em relação à memória principal, caso o programa do usuário não a preencha totalmente, existirá um espaço de memória livre sem utilização (Fig. 9.3).

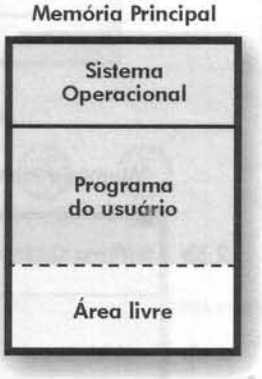

Fig. 9.3 Subutilização da memória principal.

9.4 Técnica de Overlay

Na alocação contígua simples, todos os programas estão limitados ao tamanho da área de memória principal disponível para o usuário. Uma solução encontrada para o problema é dividir o programa em módulos, de forma que seja possível a execução independente de cada módulo, utilizando uma mesma área de memória. Essa técnica é chamada de *overlay*.

Considere um programa que tenha três módulos: um principal, um de cadastramento e outro de impressão, sendo os módulos de cadastramento e de impressão independentes. A independência do código significa que quando um módulo estiver na memória para execução, o outro não precisa necessariamente estar presente. O módulo principal é comum aos dois módulos; logo, deve permanecer na memória durante todo o tempo da execução do programa.

Como podemos verificar na Fig. 9.4, a memória é insuficiente para armazenar todo o programa, que totaliza 9kb. A técnica de overlay utiliza uma área de memória comum, onde os módulos de cadastramento e de impressão poderão compartilhar a mesma área de memória (área de overlay). Sempre que um dos dois módulos for referenciado pelo módulo principal, o módulo será carregado da memória secundária para a área de overlay. No caso de uma referência a um módulo que já esteja na área de overlay, a carga não é realizada; caso contrário, o novo módulo irá sobrepor-se ao que já estiver na memória principal.

A definição das áreas de overlay é função do programador, através de comandos específicos da linguagem de programação utilizada. O tamanho de uma área de overlay é estabelecido a partir do tamanho do maior módulo. Por exemplo, se o módulo de cadastramento tem 4 Kb e o módulo de impressão 2 Kb, a área de overlay deverá ter o tamanho do maior módulo, ou seja, 4 Kb.

A técnica de overlay tem a vantagem de permitir ao programador expandir os limites da memória principal. A utilização dessa técnica exige muito cuidado, pois pode trazer implicações tanto na sua manutenção quanto no desempenho das aplicações, devido à possibilidade de transferência excessiva dos módulos entre a memória principal e a secundária.

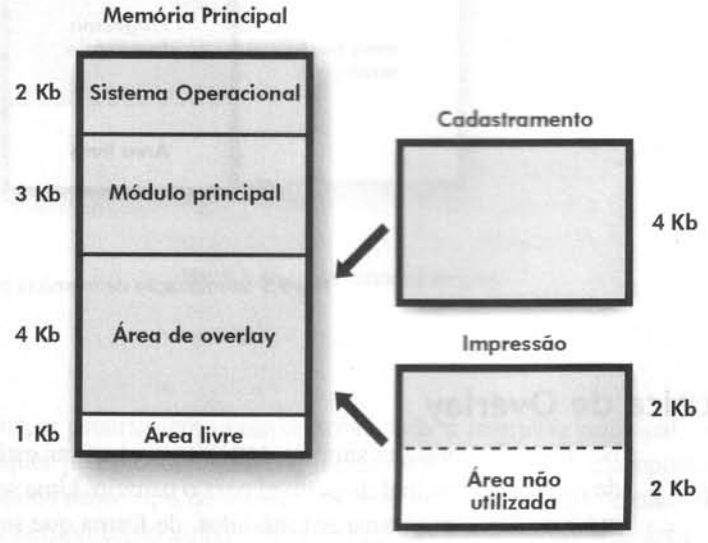

Fig. 9.4 Técnica de overlay.

9.5 Alocação Particionada

Os sistemas operacionais evoluíram no sentido de proporcionar melhor aproveitamento dos recursos disponíveis. Nos sistemas monoprogramáveis, o processador permanece grande parte do tempo ocioso e a memória principal é subutilizada. Os sistemas multiprogramáveis já são muito mais eficientes no uso do processador, necessitando, assim, que diversos programas estejam na memória principal ao mesmo tempo e que novas formas de gerência da memória sejam implementadas.

9.5.1 Alocação Particionada Estática

Nos primeiros sistemas multiprogramáveis, a memória era dividida em pedaços de tamanho fixo, chamados *partições*. O tamanho das partições, estabelecido na fase de inicialização do sistema, era definido em função do tamanho dos programas que executariam no ambiente (Fig. 9.5). Sempre que fosse necessária a alteração do tamanho de uma partição, o sistema deveria ser desativado e reinicializado com uma nova configuração. Esse tipo de gerência de memória é conhecido como *alocação particionada estática* ou *fixa*.

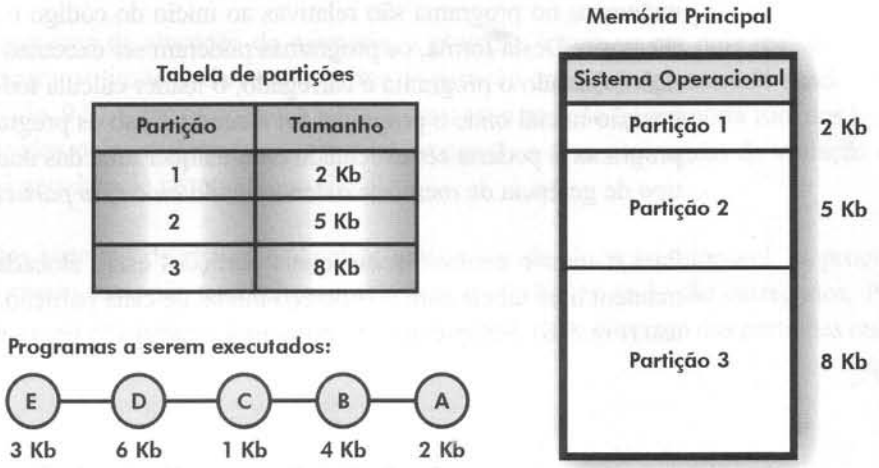

Fig. 9.5 Alocação particionada estática.

Inicialmente, os programas só podiam ser carregados e executados em apenas uma partição específica, mesmo se outras estivessem disponíveis. Essa limitação se devia aos compiladores e montadores, que geravam apenas código absoluto. No *código absoluto*, todas as referências a endereços no programa são posições físicas na memória principal, ou seja, o programa só poderia ser carregado a partir do endereço de memória especificado no seu próprio código. Se, por exemplo, os programas A e B estivessem sendo executados, e a terceira partição estivesse livre, os programas C e E não poderiam ser processados (Fig. 9.6). A esse tipo de gerência de memória chamou-se *alocação particionada estática absoluta*.

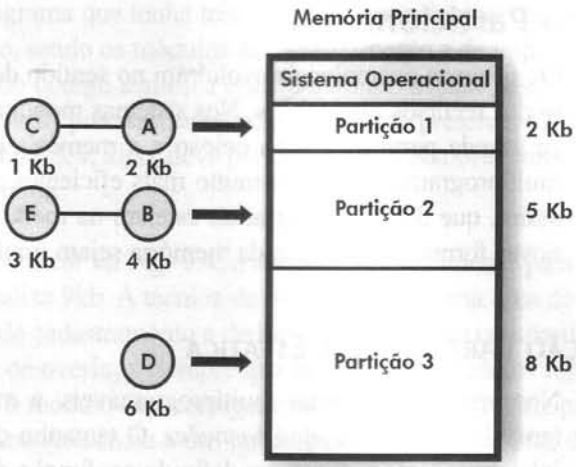

Fig. 9.6 Alocação particionada estática absoluta.

Com a evolução dos compiladores, montadores, linkers e loaders, o código gerado deixou de ser absoluto e passa a ser relocável. No *código relocável*, todas as referências a endereços no programa são relativas ao início do código e não a endereços físicos de memória. Desta forma, os programas puderam ser executados a partir de qualquer partição. Quando o programa é carregado, o loader calcula todos os endereços a partir da posição inicial onde o programa foi alocado. Caso os programas A e B terminassem, o programa E poderia ser executado em qualquer uma das duas partições (Fig. 9.7). Esse tipo de gerência de memória é denominado *alocação particionada estática relocável*.

Para manter o controle sobre quais partições estão alocadas, a gerência de memória mantém uma tabela com o endereço inicial de cada partição, seu tamanho, e se está em uso (Fig. 9.8). Sempre que um programa é carregado para a memória, o sistema percor-

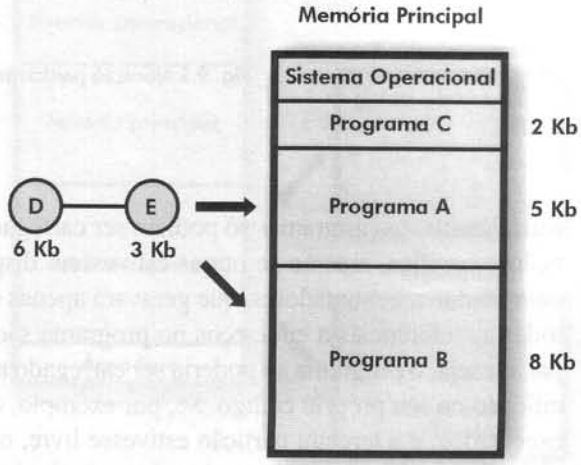

Fig. 9.7 Alocação particionada estática relocável.

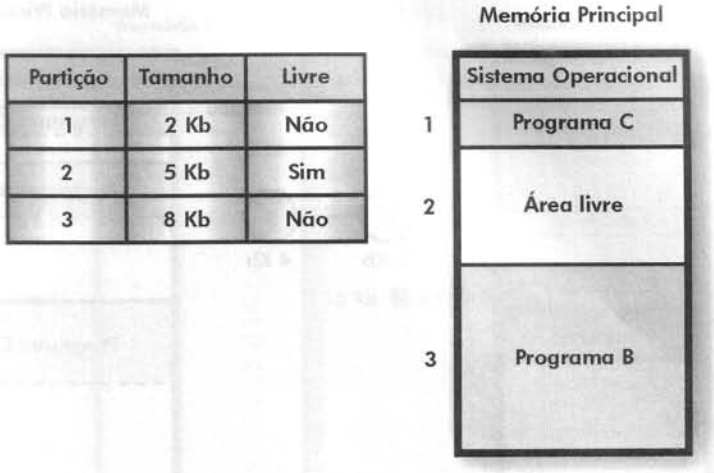

Fig. 9.8 Tabela de alocação de partições.

re a tabela, na tentativa de localizar uma partição livre, onde o programa possa ser carregado.

Nesse esquema de alocação de memória, a proteção baseia-se em dois registradores, que indicam os limites inferior e superior da partição onde o programa está sendo executado (Fig. 9.9). Caso o programa tente acessar uma posição de memória fora dos limites definidos pelos registradores, ele é interrompido e uma mensagem de violação de acesso é gerada pelo sistema operacional.

Tanto nos sistemas de alocação absoluta quanto nos de alocação relocável, os programas, normalmente, não preenchem totalmente as partições onde são carregados. Por exemplo, os programas C, A e E não ocupam integralmente o espaço das partições onde

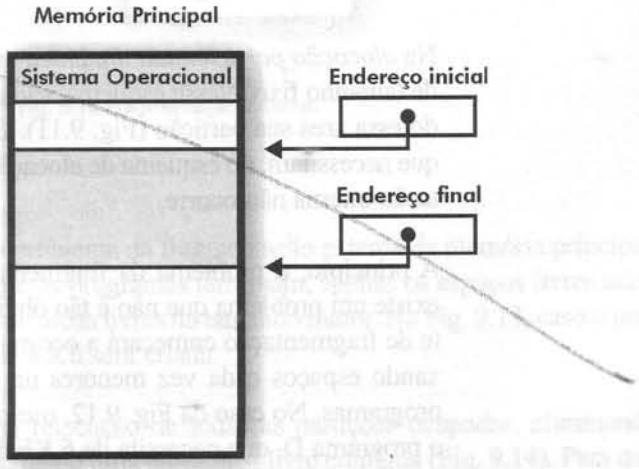

Fig. 9.9 Proteção na alocação particionada.

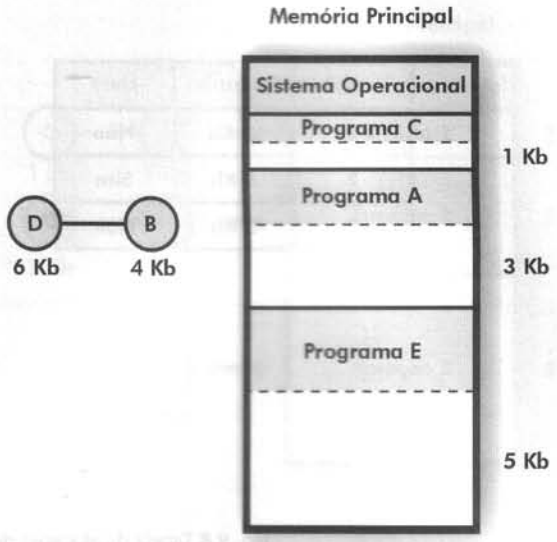

Fig. 9.10 Fragmentação interna.

estão alocados, deixando 1 Kb, 3 Kb e 5 Kb de áreas livres, respectivamente (Fig. 9.10). Este tipo de problema, decorrente da alocação fixa das partições, é conhecido como *fragmentação interna*.

Um exemplo de sistema operacional que implementou esse tipo de gerência de memória é o OS/MFT (Multiprogramming with a Fixed Number of Tasks) da IBM.

9.5.2 Alocação Particionada Dinâmica

A alocação particionada estática, analisada anteriormente, deixou evidente a necessidade de uma nova forma de gerência da memória principal, onde o problema da fragmentação interna fosse reduzido e, conseqüentemente, o grau de compartilhamento da memória aumentado.

Na *alocação particionada dinâmica* ou *variável*, foi eliminado o conceito de partições de tamanho fixo. Nesse esquema, cada programa utilizaria o espaço necessário, tornando essa área sua partição (Fig. 9.11). Como os programas utilizam apenas o espaço de que necessitam, no esquema de alocação particionada dinâmica o problema da fragmentação interna não ocorre.

A princípio, o problema da fragmentação interna está resolvido, porém, nesse caso, existe um problema que não é tão óbvio quanto no esquema anterior. Um tipo diferente de fragmentação começará a ocorrer, quando os programas forem terminando e deixando espaços cada vez menores na memória, não permitindo o ingresso de novos programas. No caso da Fig. 9.12, mesmo existindo 12 Kb livres de memória principal, o programa D, que necessita de 6 Kb de espaço, não poderá ser carregado para execução, pois este espaço não está disposto contiguamente. Esse tipo de problema é chamado *fragmentação externa*.

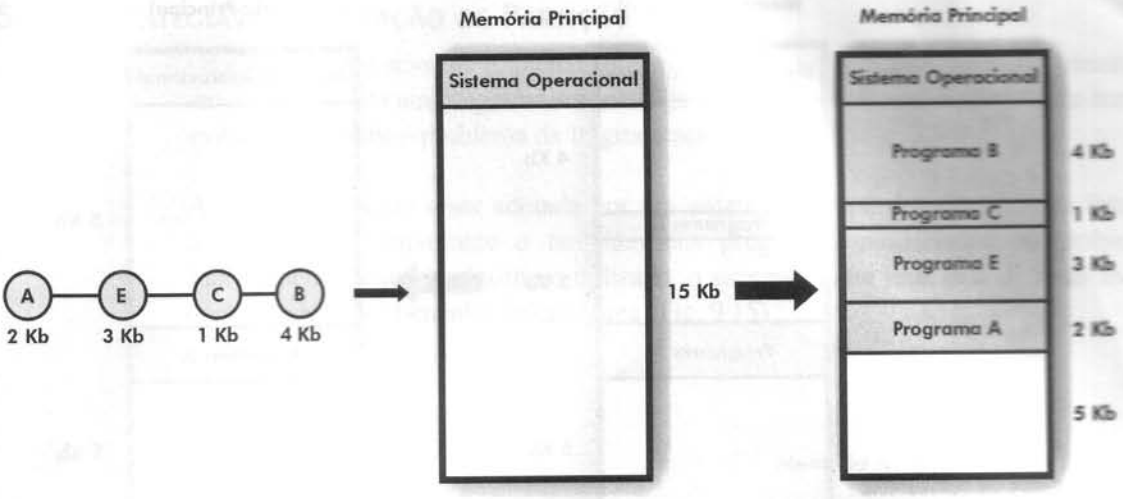

Fig. 9.11 Alocação particionada dinâmica.

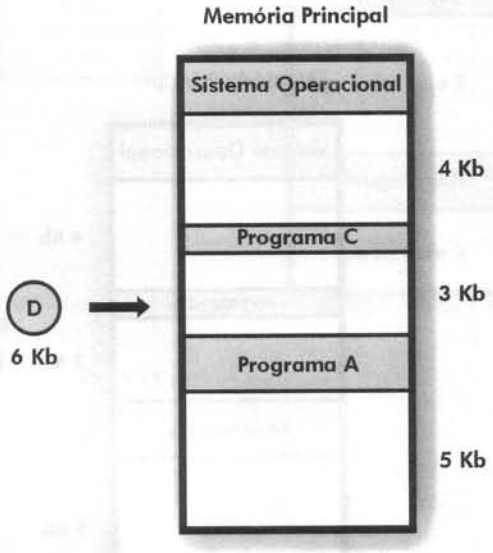

Fig. 9.12 Fragmentação externa.

Existem duas soluções para o problema da fragmentação externa da memória principal. Na primeira solução, conforme os programas terminam, apenas os espaços livres adjacentes são reunidos, produzindo áreas livres de tamanho maior. Na Fig. 9.13, caso o programa C termine, uma área de 8 Kb será criada.

A segunda solução envolve a relocação de todas as partições ocupadas, eliminando todos os espaços entre elas e criando uma única área livre contígua (Fig. 9.14). Para que esse processo seja possível, é necessário que o sistema tenha a capacidade de mover os diversos programas na memória principal, ou seja, realizar *relocação dinâmica*. Esse

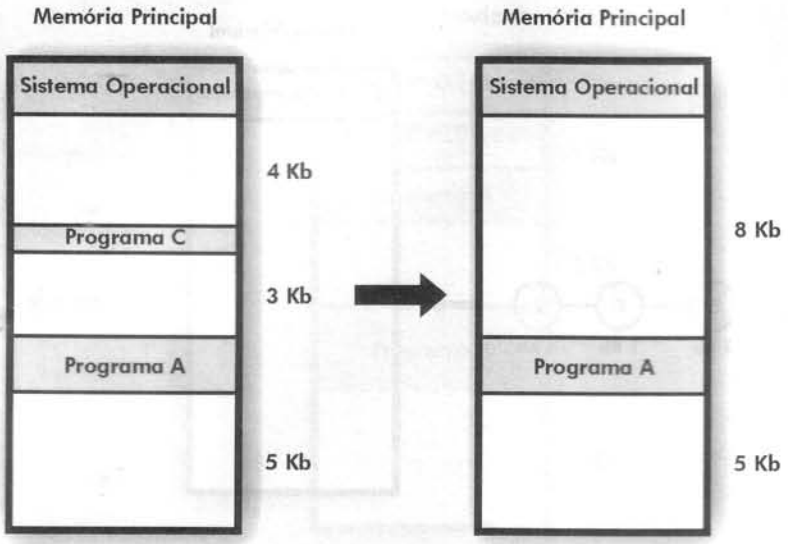

Fig. 9.13 Solução para a fragmentação externa (a).

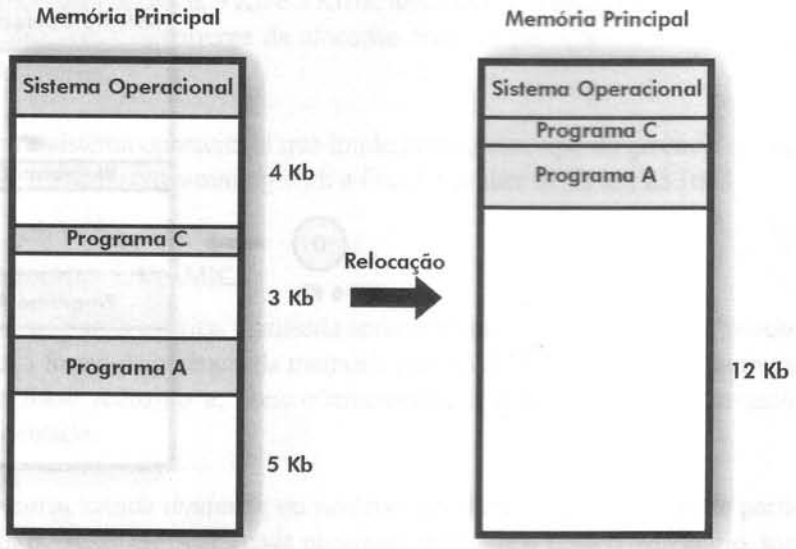

Fig. 9.14 Solução para a fragmentação externa (b).

mecanismo de compactação, também conhecido como *alocação particionada dinâmica com relocação*, reduz em muito o problema da fragmentação, porém a complexidade do seu algoritmo e o consumo de recursos do sistema, como processador e área em disco, podem torná-lo inviável.

Um exemplo de sistema operacional que implementou esse tipo de gerência de memória é o OS/MVT (Multiprogramming with a Variable Number of Tasks) da IBM.

9.5.3 Estratégias de Alocação de Partição

Os sistemas operacionais implementam, basicamente, três estratégias para determinar em qual área livre um programa será carregado para execução. Essas estratégias tentam evitar ou diminuir o problema da fragmentação externa.

A melhor estratégia a ser adotada por um sistema depende de uma série de fatores, sendo o mais importante o tamanho dos programas processados no ambiente. Independentemente do algoritmo utilizado, o sistema possui uma lista de áreas livres, com o endereço e tamanho de cada área (Fig. 9.15).

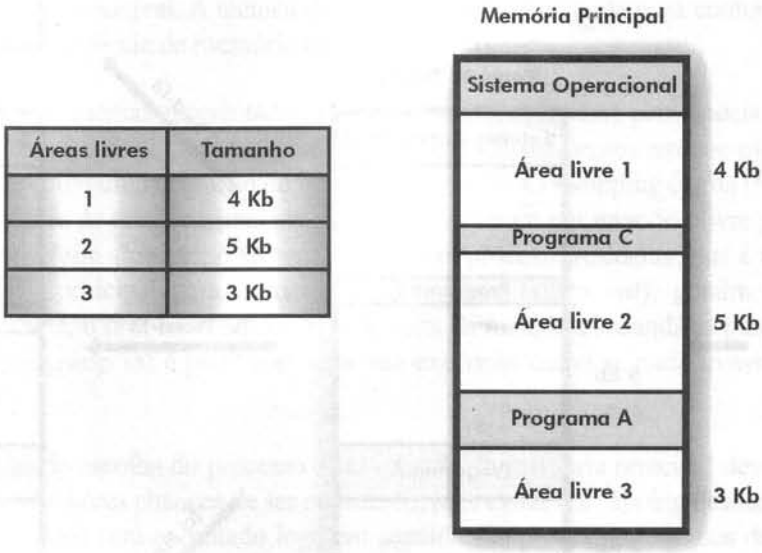

Fig. 9.15 Lista de áreas livres.

- Best-fit

  Na estratégia *best-fit*, a melhor partição é escolhida, ou seja, aquela em que o programa deixa o menor espaço sem utilização (Fig. 9.16a). Nesse algoritmo, a lista de áreas livres está ordenada por tamanho, diminuindo o tempo de busca por uma área desocupada. Uma grande desvantagem desse método é conseqüência do próprio algoritmo. Como é alocada a partição que deixa a menor área livre, a tendência é que cada vez mais a memória fique com pequenas áreas não-contíguas, aumentando o problema da fragmentação.

- Worst-fit

  Na estratégia *worst-fit*, a pior partição é escolhida, ou seja, aquela em que o programa deixa o maior espaço sem utilização (Fig. 9.16b). Apesar de utilizar as maiores partições, a técnica de worst-fit deixa espaços livres maiores que permitem a um maior número de programas utilizar a memória, diminuindo o problema da fragmentação.

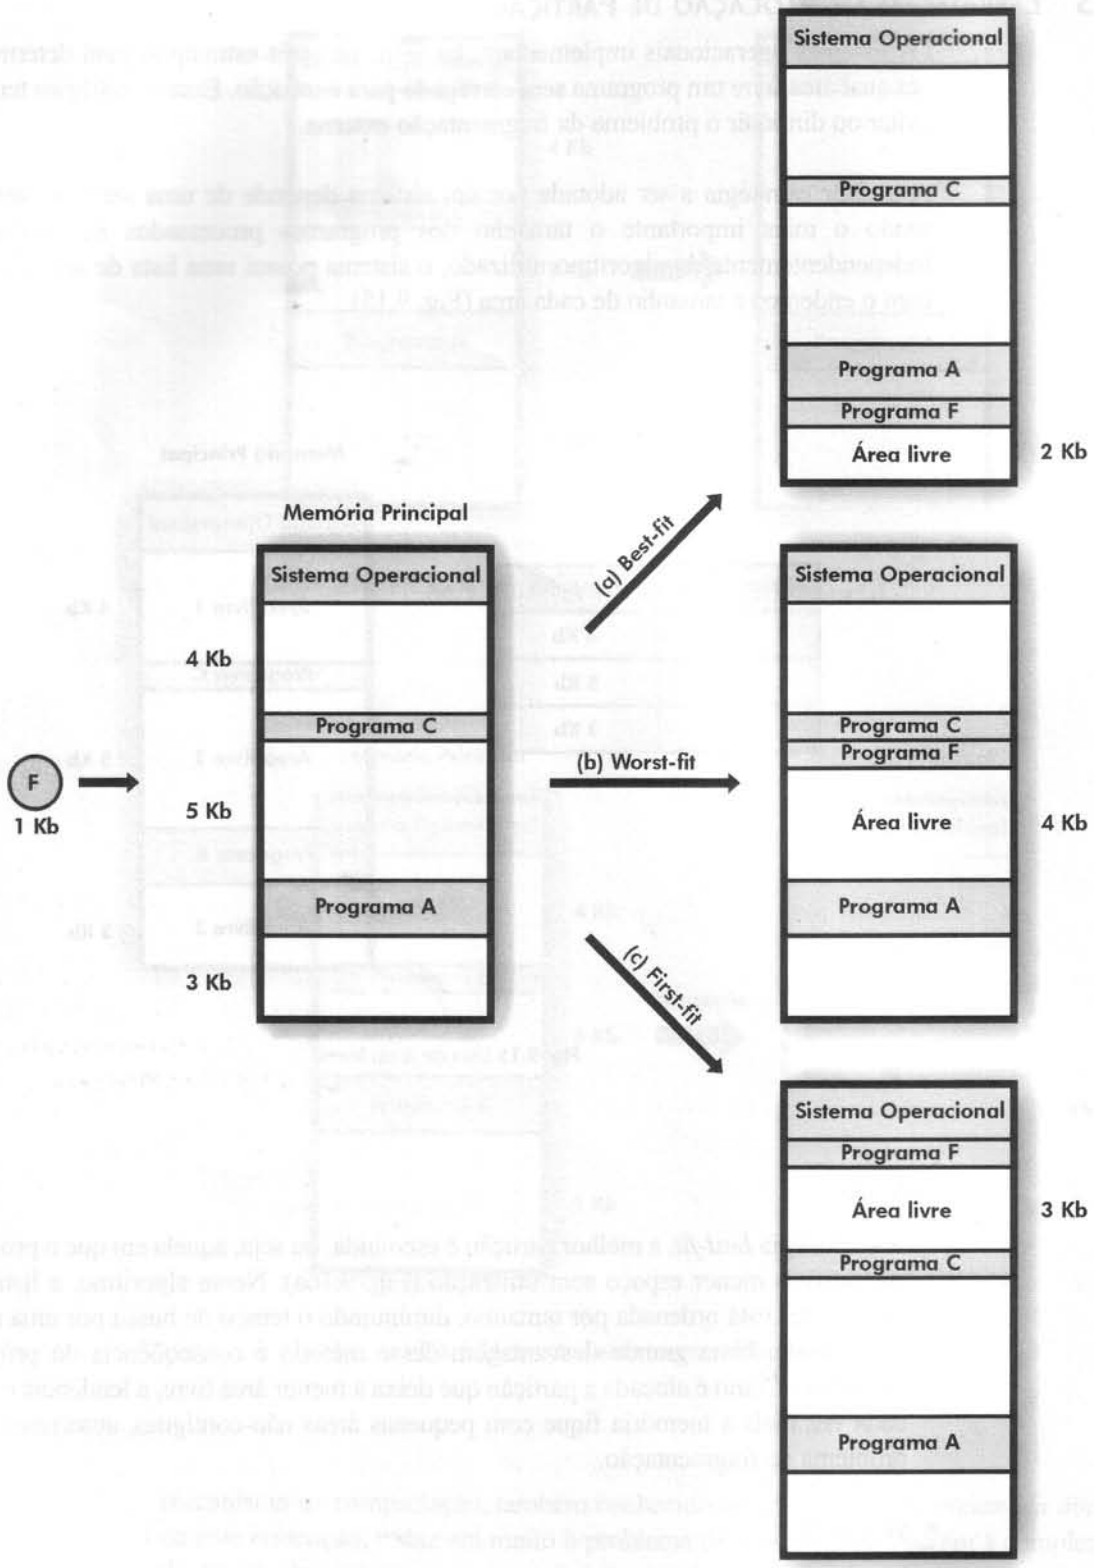

Fig. 9.16 Estratégias para a escolha da partição.

- First-fit

  Na estratégia *first-fit*, a primeira partição livre de tamanho suficiente para carregar o programa é escolhida (Fig. 9.16c). Nesse algoritmo, a lista de áreas livres está ordenada crescentemente por endereços. Como o método tenta primeiro utilizar as áreas livres de endereços mais baixos, existe uma grande chance de se obter uma grande partição livre nos endereços de memória mais altos. Das três estratégias apresentadas, a first-fit é a mais rápida, consumindo menos recursos do sistema.

9.6 Swapping

Mesmo com o aumento da eficiência da multiprogramação e, particularmente, da gerência de memória, muitas vezes um programa não podia ser executado por falta de uma partição livre disponível. A técnica de *swapping* foi introduzida para contornar o problema da insuficiência de memória principal.

Em todos os esquemas apresentados anteriormente, um processo permanecia na memória principal até o final da sua execução, inclusive nos momentos em que esperava por um evento, como uma operação de leitura ou gravação. O swapping é uma técnica aplicada à gerência de memória para programas que esperam por memória livre para serem executados. Nesta situação, o sistema escolhe um processo residente, que é transferido da memória principal para a memória secundária (*swap out*), geralmente disco. Posteriormente, o processo é carregado de volta da memória secundária para a memória principal (*swap in*) e pode continuar sua execução como se nada tivesse ocorrido (Fig. 9.17).

O algoritmo de escolha do processo a ser retirado da memória principal deve priorizar aquele com menores chances de ser executado, para evitar o swapping desnecessário de um processo que será executado logo em seguida. Os processos retirados da memória estão geralmente no estado de espera, mas existe a possibilidade de um processo no estado de pronto também ser selecionado. No primeiro caso, o processo é dito no estado de espera outswapped e no segundo caso no estado de pronto outswapped.

Para que a técnica de swapping seja implementada, é essencial que o sistema ofereça um loader que implemente a *relocação dinâmica* de programas. Um loader relocável que não ofereça esta facilidade permite que um programa seja colocado em qualquer posição de memória, porém a relocação é apenas realizada no momento do carregamento. No caso do swapping, um programa pode sair e voltar diversas vezes para a memória, sendo necessário que a relocação seja realizada pelo loader a cada carregamento.

A relocação dinâmica é realizada através de um registrador especial denominado *registrador de relocação*. No momento em que o programa é carregado na memória, o registrador recebe o endereço inicial da posição de memória que o programa irá ocupar. Toda vez que ocorrer uma referência a algum endereço, o endereço contido na instrução será somado ao conteúdo do registrador, gerando, assim, o endereço físico (Fig. 9.18). Dessa forma, um programa pode ser carregado em qualquer posição de memória.

O conceito de swapping permite maior compartilhamento da memória principal e, conseqüentemente, maior utilização dos recursos do sistema computacional. Seu maior problema é o elevado custo das operações de entrada/saída (swap in/out). Em situações

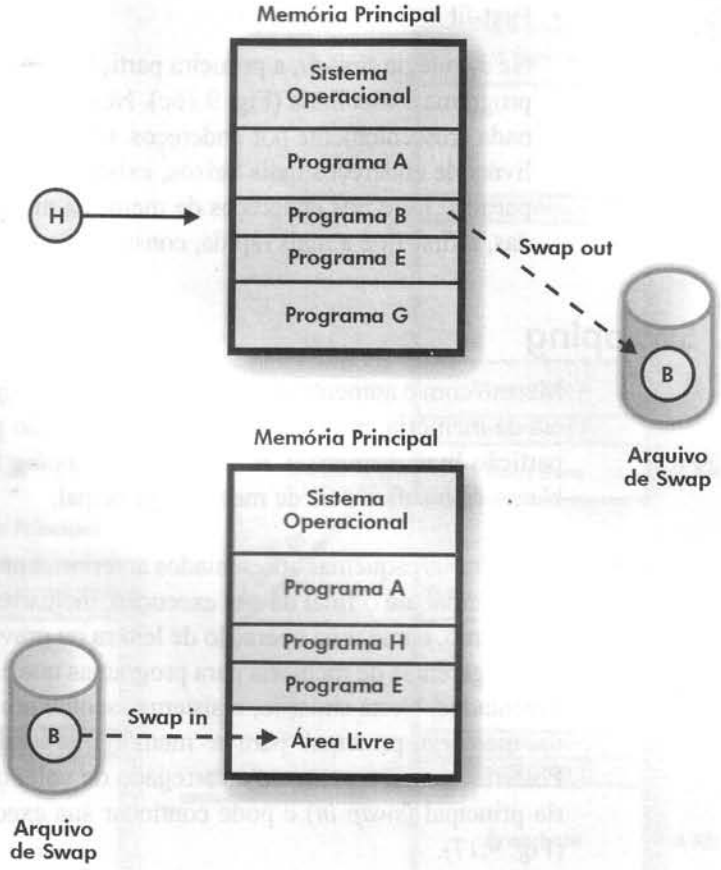

Fig. 9.17 Swapping.

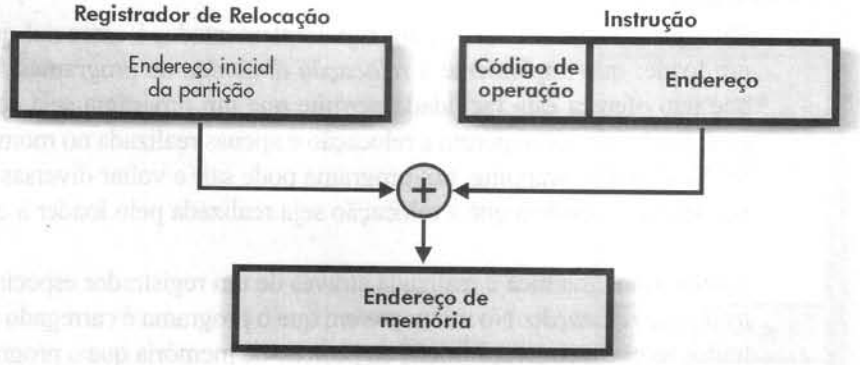

Fig. 9.18 Relocação dinâmica.

críticas, quando há pouca memória disponível, o sistema pode ficar quase que dedicado à execução de swapping, deixando de realizar outras tarefas e impedindo a execução dos processos residentes.

Os primeiros sistemas operacionais que implementaram esta técnica surgiram na década de 1960, como o CTSS do MIT e OS/360 da IBM. Com a evolução dos sistemas operacionais, novos esquemas de gerência de memória passaram a incorporar a técnica de swapping, como a gerência de memória virtual.

9.7 Exercícios

1. Quais as funções básicas da gerência de memória?
2. Considere um sistema computacional com 40 Kb de memória principal e que utilize um sistema operacional de 10 Kb que implemente alocação contígua de memória. Qual a taxa de subutilização da memória principal para um programa que ocupe 20 Kb de memória?
3. Suponha um sistema computacional com 64 Kb de memória principal e que utilize um sistema operacional de 14 Kb que implemente alocação contígua de memória. Considere também um programa de 90 Kb, formado por um módulo principal de 20 Kb e três módulos independentes, cada um com 10 Kb, 20 Kb e 30 Kb. Como o programa poderia ser executado utilizando-se apenas a técnica de overlay?
4. Considerando o exercício anterior, se o módulo de 30 Kb tivesse seu tamanho aumentado para 40 Kb, seria possível executar o programa? Caso não possa, como o problema poderia ser contornado?
5. Qual a diferença entre fragmentação interna e fragmentação externa da memória principal?
6. Suponha um sistema computacional com 128 Kb de memória principal e que utilize um sistema operacional de 64 Kb que implemente alocação particionada estática relocável. Considere também que o sistema foi inicializado com três partições: P1 (8 Kb), P2 (24 Kb) e P3 (32 Kb). Calcule a fragmentação interna da memória principal após a carga de três programas: PA, PB e PC.
   a) P1 ← PA (6 Kb); P2 ← PB (20 Kb); P3 ← PC (28 Kb)
   b) P1 ← PA (4 Kb); P2 ← PB (16 Kb); P3 ← PC (26 Kb)
   c) P1 ← PA (8 Kb); P2 ← PB (24 Kb); P3 ← PC (32 Kb)
7. Considerando o exercício anterior, seria possível executar quatro programas concorrentemente utilizando apenas a técnica de alocação particionada estática relocável? Se for possível, como? Considerando ainda o mesmo exercício, seria possível executar um programa de 36 Kb? Se for possível, como?
8. Qual a limitação da alocação particionada estática absoluta em relação à alocação estática relocável?
9. Considere que os processos da tabela a seguir estão aguardando para serem executados e que cada um permanecerá na memória durante o tempo especificado. O sistema operacional ocupa uma área de 20 Kb no início da memória e gerencia a memória utilizando um algoritmo de particionamento dinâmico modificado. A memória total disponível no sistema é de 64 Kb e é alocada em blocos múltiplos de 4 Kb. Os processos são alocados de acordo com sua identificação (em ordem crescente) e irão aguardar até obter a memória de que necessitam. Calcule a perda de memória por fragmentação interna e externa sempre que um processo é colocado ou retirado da memória. O sistema operacional compacta a memória apenas quando existem duas ou mais partições livres adjacentes.

Processos	Memória	Tempo
1	30 Kb	5
2	6 Kb	10
3	36 Kb	5

10. Considerando as estratégias para escolha da partição dinamicamente, conceitue as estratégias best-fit e worst-fit especificando prós e contras de cada uma.
11. Considere um sistema que possua as seguintes áreas livres na memória principal, ordenadas crescentemente: 10 Kb, 4 Kb, 20 Kb, 18 Kb, 7 Kb, 9 Kb, 12 Kb e 15 Kb. Para cada programa abaixo, qual seria a partição alocada utilizando-se as estratégias first-fit, best-fit e worst-fit (Tanenbaum, 1992)?
    a) 12 Kb
    b) 10 Kb
    c) 9 Kb
12. Um sistema utiliza alocação particionada dinâmica como mecanismo de gerência de memória. O sistema operacional aloca uma área de memória total de 50 Kb e possui, inicialmente, os programas da tabela a seguir:

5 Kb	Programa A
3 Kb	Programa B
10 Kb	Livre
6 Kb	Programa C
26 Kb	Livre

    Realize as operações abaixo seqüencialmente, mostrando o estado da memória após cada uma delas. Resolva a questão utilizando as estratégias best-fit, worst-fit e first-fit:
    a) alocar uma área para o programa D que possui 6 Kb;
    b) liberar a área do programa A;
    c) alocar uma área para o programa E que possui 4 Kb.
13. O que é swapping e para que é utilizada essa técnica?
14. Por que é importante o uso de um loader com relocação dinâmica para que a técnica de swapping possa ser implementada?

10

GERÊNCIA DE MEMÓRIA VIRTUAL

10.1 Introdução

No capítulo anterior foram apresentadas diversas técnicas de gerenciamento de memória que evoluíram no sentido de maximizar o número de processos residentes na memória principal e reduzir o problema da fragmentação, porém, os esquemas vistos se mostraram muitas vezes ineficientes. Além disso, o tamanho de um programa e de suas estruturas de dados estava limitado ao tamanho da memória disponível. A utilização da técnica de overlay para contornar este problema é de difícil implementação na prática e nem sempre uma solução garantida.

Memória virtual é uma técnica sofisticada e poderosa de gerência de memória, onde as memórias principal e secundária são combinadas, dando ao usuário a ilusão de existir uma memória muito maior que a capacidade real da memória principal. O conceito de memória virtual fundamenta-se em não vincular o endereçamento feito pelo programa dos endereços físicos da memória principal. Desta forma, programas e suas estruturas de dados deixam de estar limitados ao tamanho da memória física disponível, pois podem possuir endereços associados à memória secundária.

Outra vantagem da técnica de memória virtual é permitir um número maior de processos compartilhando a memória principal, já que apenas partes de cada processo estarão residentes. Isto leva a uma utilização mais eficiente também do processador. Além disso, essa técnica possibilita minimizar o problema da fragmentação da memória principal.

A primeira implementação de memória virtual foi realizada no início da década de 1960, no sistema Atlas, desenvolvido na Universidade de Manchester (Kilburn, 1962). Posteriormente, a IBM introduziria este conceito comercialmente na família System/370 em 1972. Atualmente, a maioria dos sistemas implementa memória virtual, com exceção de alguns sistemas operacionais de supercomputadores.

Existe um forte relacionamento entre a gerência da memória virtual e a arquitetura de hardware do sistema computacional. Por motivos de desempenho, é comum que algumas funções da gerência de memória virtual sejam implementadas diretamente no hardware. Além disso, o código do sistema operacional deve levar em considera-

ção várias características específicas da arquitetura, especialmente o esquema de endereçamento do processador.

Este capítulo apresenta conceitos relacionados à memória virtual e aborda as três técnicas que permitem sua implementação: paginação, segmentação e segmentação com paginação. Apesar da ênfase na gerência de memória virtual por paginação, diversos dos conceitos apresentados também podem ser aplicados nas técnicas de segmentação.

10.2 Espaço de Endereçamento Virtual

O conceito de memória virtual se aproxima muito da idéia de um vetor, existente nas linguagens de alto nível. Quando um programa faz referência a um elemento do vetor, não há preocupação em saber a posição de memória daquele dado. O compilador se encarrega de gerar instruções que implementam esse mecanismo, tornando-o totalmente transparente ao programador (Fig. 10.1).

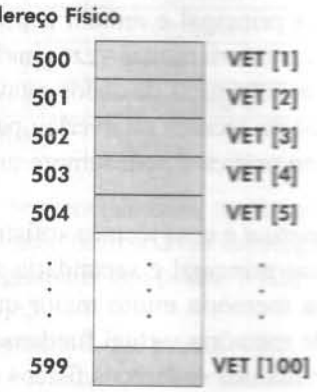

Fig. 10.1 Vetor de 100 posições.

A memória virtual utiliza abstração semelhante, só que em relação aos endereços dos programas e dados. Um programa no ambiente de memória virtual não faz referência a endereços físicos de memória (*endereços reais*), mas apenas a *endereços virtuais*. No momento da execução de uma instrução, o endereço virtual referenciado é traduzido para um endereço físico, pois o processador manipula apenas posições da memória principal. O mecanismo de tradução do endereço virtual para endereço físico é denominado mapeamento.

Um processo, conforme apresentado, é formado pelo contexto de hardware, contexto de software e pelo espaço de endereçamento. Em ambientes que implementam memória virtual, o espaço de endereçamento do processo é conhecido como *espaço de endereçamento virtual* e representa o conjunto de endereços virtuais que o processo pode endereçar. Analogamente, o conjunto de endereços reais que o processador pode referenciar é chamado *espaço de endereçamento real* (Fig. 10.2).

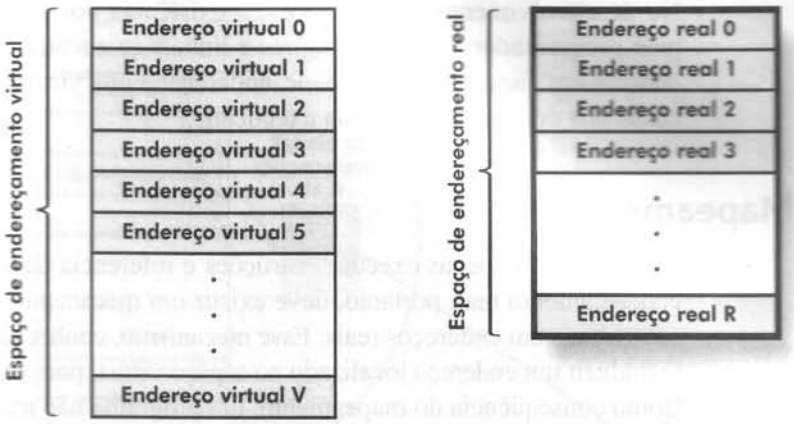

Fig. 10.2 Espaço de endereçamentos virtual e real.

Como o espaço de endereçamento virtual não tem nenhuma relação direta com os endereços no espaço real, um programa pode fazer referência a endereços virtuais que estejam fora dos limites da memória principal, ou seja, os programas e suas estruturas de dados não estão mais limitados ao tamanho da memória física disponível. Para que isso seja possível, o sistema operacional utiliza a memória secundária como extensão da memória principal. Quando um programa é executado, somente uma parte do seu código fica residente na memória principal, permanecendo o restante na memória secundária até o momento de ser referenciado. Esta condição permite aumentar o compartilhamento da memória principal entre muitos processos (Fig. 10.3).

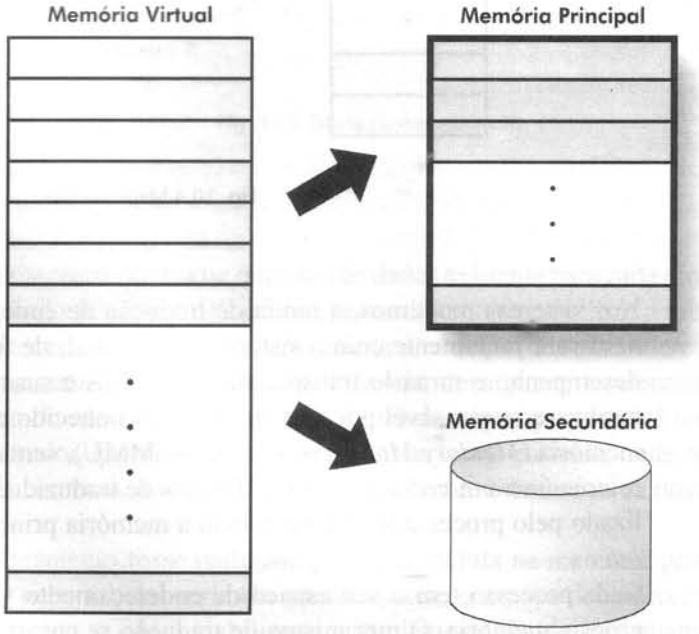

Fig. 10.3 Espaço de endereçamento virtual.

No desenvolvimento de aplicações, a existência dos endereços virtuais é ignorada pelo programador. Os compiladores e linkers se encarregam de gerar o código executável em função do espaço de endereçamento virtual, e o sistema operacional cuida dos detalhes durante sua execução.

10.3 Mapeamento

O processador apenas executa instruções e referencia dados residentes no espaço de endereçamento real; portanto, deve existir um mecanismo que transforme os endereços virtuais em endereços reais. Esse mecanismo, conhecido por *mapeamento*, permite traduzir um endereço localizado no espaço virtual para um associado no espaço real. Como conseqüência do mapeamento, um programa não mais precisa estar necessariamente em endereços contíguos na memória principal para ser executado (Fig. 10.4).

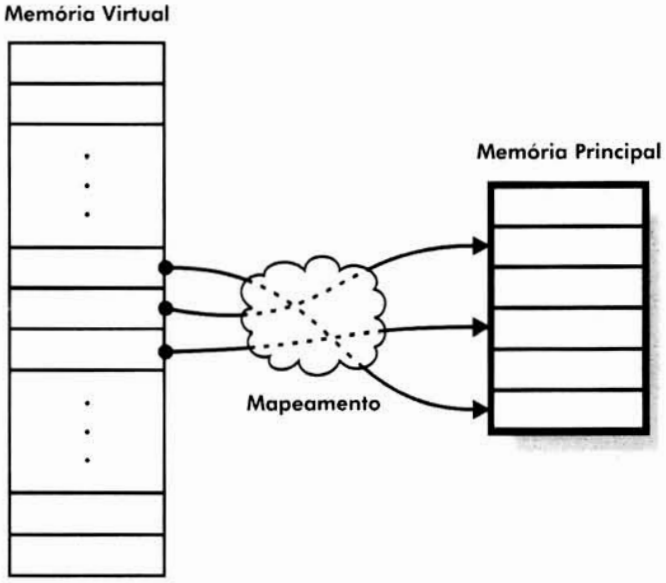

Fig. 10.4 Mapeamento.

Nos sistemas modernos, a tarefa de tradução de endereços virtuais é realizada por hardware juntamente com o sistema operacional, de forma a não comprometer seu desempenho e torná-lo transparente a usuários e suas aplicações. O dispositivo de hardware responsável por esta tradução é conhecido como unidade de gerência de memória (*Memory Management Unit* — MMU), sendo acionado sempre que se faz referência a um endereço virtual. Depois de traduzido, o endereço real pode ser utilizado pelo processador para o acesso à memória principal.

Cada processo tem o seu espaço de endereçamento virtual como se possuísse sua própria memória. O mecanismo de tradução se encarrega, então, de manter *tabelas de mapeamento* exclusivas para cada processo, relacionando os endereços virtuais do processo às suas posições na memória real (Fig. 10.5).

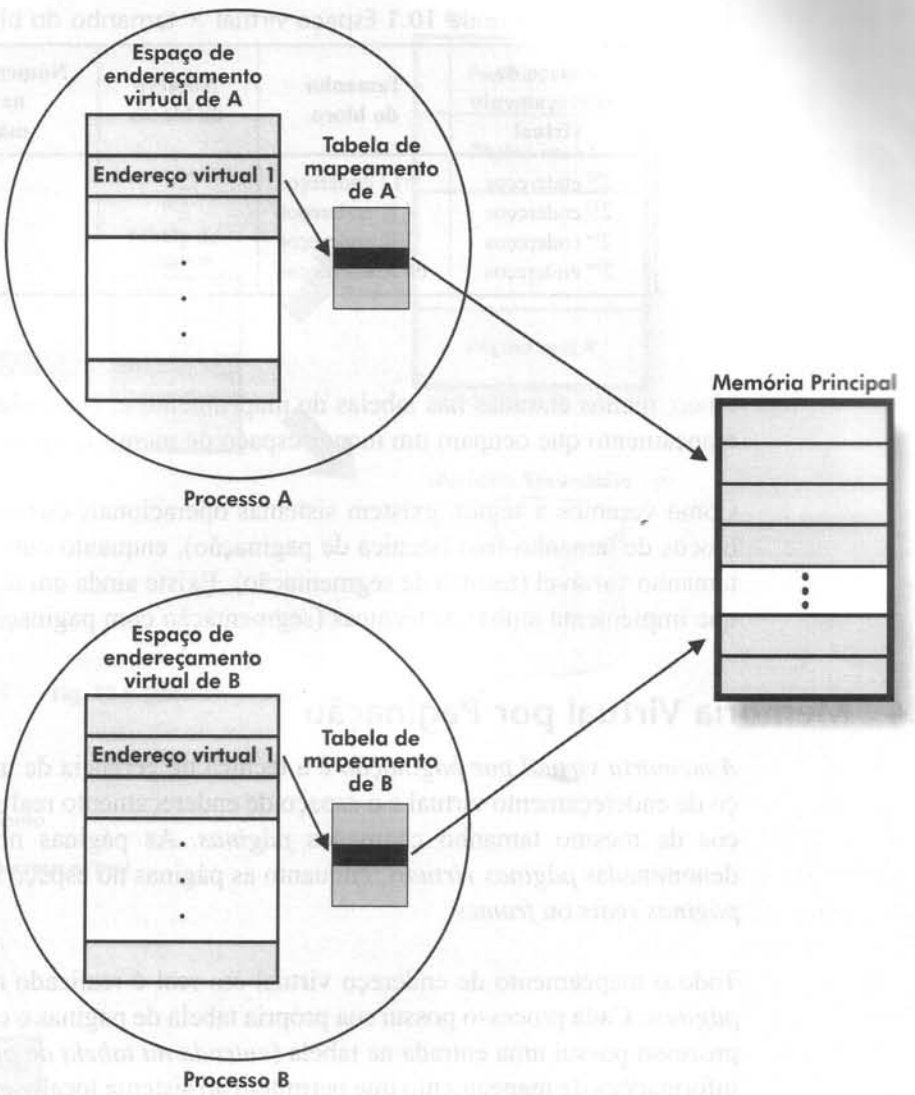

Fig. 10.5 Tabela de mapeamento.

A tabela de mapeamento é uma estrutura de dados existente para cada processo. Quando um determinado processo está sendo executado, o sistema utiliza a tabela de mapeamento do processo em execução para realizar a tradução de seus endereços virtuais. Se um outro processo vai ser executado, o sistema deve passar a referenciar a tabela de mapeamento do novo processo. A troca de tabelas de mapeamento é realizada através de um registrador, que indica a posição inicial da tabela corrente, onde, toda vez que há mudança de contexto, o registrador é atualizado com o endereço da nova tabela.

Caso o mapeamento fosse realizado para cada célula na memória principal, o espaço ocupado pelas tabelas seria tão grande quanto o espaço de endereçamento virtual de cada processo, o que inviabilizaria a implementação do mecanismo de memória virtual. Em função disso, as tabelas mapeiam blocos de dados, cujo tamanho determina o número de entradas existentes nas tabelas de mapeamento. Quanto maior o

Tabela 10.1 Espaço virtual × tamanho do bloco

Espaço de endereçamento virtual	Tamanho do bloco	Número de blocos	Número de entradas na tabela de mapeamento
2^{32} endereços	512 endereços	2^{23}	2^{23}
2^{32} endereços	4 K endereços	2^{20}	2^{20}
2^{64} endereços	4 K endereços	2^{52}	2^{52}
2^{64} endereços	64 K endereços	2^{48}	2^{48}

bloco, menos entradas nas tabelas de mapeamento e, conseqüentemente, tabelas de mapeamento que ocupam um menor espaço de memória (Tabela 10.1).

Como veremos a seguir, existem sistemas operacionais que trabalham apenas com blocos de tamanho fixo (técnica de paginação), enquanto outros utilizam blocos de tamanho variável (técnica de segmentação). Existe ainda um terceiro tipo de sistema que implementa ambas as técnicas (segmentação com paginação).

10.4 Memória Virtual por Paginação

A memória virtual por paginação é a técnica de gerência de memória onde o espaço de endereçamento virtual e o espaço de endereçamento real são divididos em blocos de mesmo tamanho chamados *páginas*. As páginas no espaço virtual são denominadas *páginas virtuais*, enquanto as páginas no espaço real são chamadas de *páginas reais* ou *frames*.

Todo o mapeamento de endereço virtual em real é realizado através de *tabelas de páginas*. Cada processo possui sua própria tabela de páginas e cada página virtual do processo possui uma entrada na tabela (*entrada na tabela de páginas* — ETP), com informações de mapeamento que permitem ao sistema localizar a página real correspondente (Fig. 10.6).

Quando um programa é executado, as páginas virtuais são transferidas da memória secundária para a memória principal e colocadas nos frames. Sempre que um programa fizer referência a um endereço virtual, o mecanismo de mapeamento localizará na ETP da tabela do processo o endereço físico do frame no qual se encontra o endereço real correspondente.

Nessa técnica, o endereço virtual é formado pelo *número da página virtual* (NPV) e por um *deslocamento*. O NPV identifica unicamente a página virtual que contém o endereço, funcionando como um índice na tabela de páginas. O deslocamento indica a posição do endereço virtual em relação ao início da página na qual se encontra. O endereço físico é obtido, então, combinando-se o endereço do frame, localizado na tabela de páginas, com o deslocamento, contido no endereço virtual (Fig. 10.7).

Além da informação sobre a localização da página virtual, a ETP possui outras informações, como o *bit de validade* (*valid bit*) que indica se uma página está ou

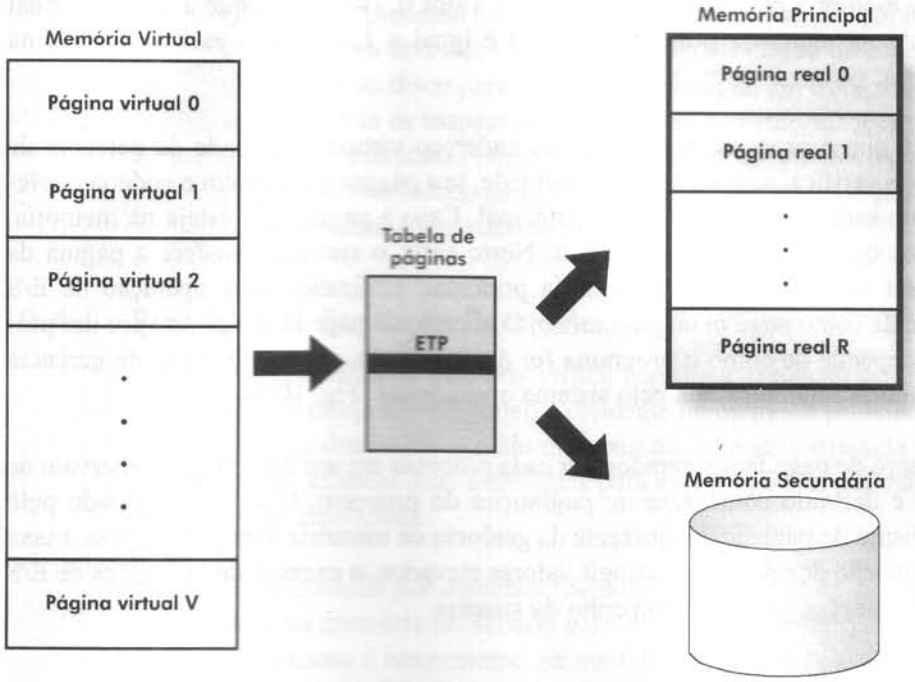

Fig. 10.6 Tabela de páginas.

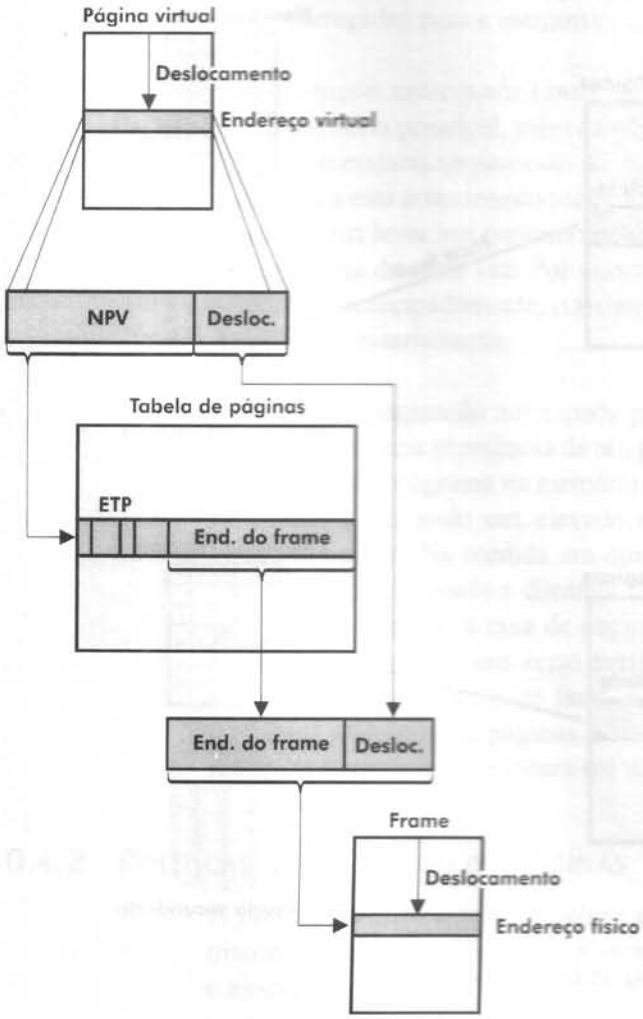

Fig. 10.7 Tradução do endereço virtual.

não na memória principal. Se o bit tem o valor 0, isto indica que a página virtual não está na memória principal, mas se é igual a 1, a página está localizada na memória.

Sempre que o processo referencia um endereço virtual, a unidade de gerência de memória verifica, através do bit de validade, se a página que contém o endereço referenciado está ou não na memória principal. Caso a página não esteja na memória, dizemos que ocorreu um *page fault*. Neste caso, o sistema transfere a página da memória secundária para a memória principal, realizando uma operação de E/S conhecida como *page in* ou *paginação*. O número de page faults gerado por um processo depende de como o programa foi desenvolvido, além da política de gerência de memória implementada pelo sistema operacional (Fig. 10.8).

O número de page faults gerados por cada processo em um determinado intervalo de tempo é definido como *taxa de paginação* do processo. O overhead gerado pelo mecanismo de paginação é inerente da gerência de memória virtual, porém se a taxa de paginação dos processos atingir valores elevados, o excesso de operações de E/S poderá comprometer o desempenho do sistema.

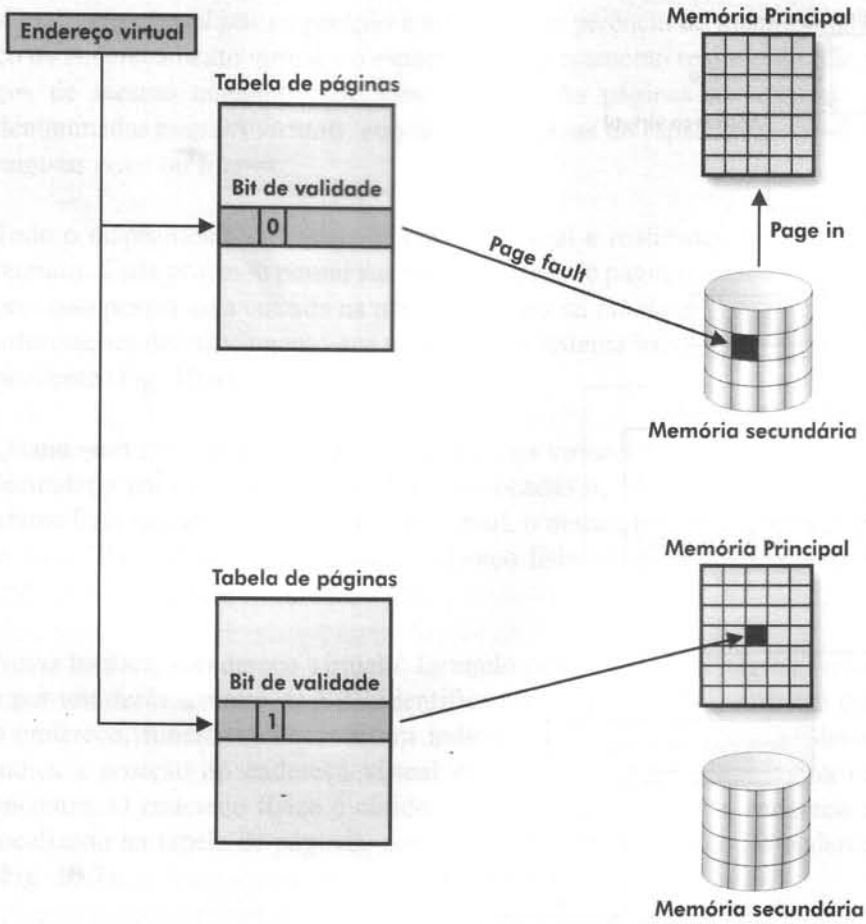

Fig. 10.8 Mecanismo de tradução.

Quando um processo referencia um endereço e ocorre um page fault, o processo em questão passa do estado de execução para o estado de espera, até que a página seja transferida do disco para a memória principal. Na troca de contexto, as informações sobre a tabela de mapeamento são salvas e as informações do novo processo escalonado são restauradas. Após a transferência da página para a memória principal, o processo é recolocado na fila de processos no estado de pronto, e quando for reescalonado poderá continuar sua execução.

10.4.1 Políticas de Busca de Páginas

O mecanismo de memória virtual permite a execução de um programa sem que seu código esteja completamente residente na memória principal. A *política de busca de páginas* determina quando uma página deve ser carregada para a memória. Basicamente, existem duas estratégias para este propósito: paginação por demanda e paginação antecipada.

Na *paginação por demanda* (*demand paging*), as páginas dos processos são transferidas da memória secundária para a principal apenas quando são referenciadas. Este mecanismo é conveniente, na medida em que leva para a memória principal apenas as páginas realmente necessárias à execução do programa. Desse modo, é possível que partes não executadas do programa, como rotinas de tratamento de erros, nunca sejam carregadas para a memória.

Na *paginação antecipada* (*antecipatory paging ou prepaging*), o sistema carrega para a memória principal, além da página referenciada, outras páginas que podem ou não ser necessárias ao processo ao longo do seu processamento. Se imaginarmos que o programa está armazenado seqüencialmente no disco, existe uma grande economia de tempo em levar um conjunto de páginas da memória secundária, ao contrário de carregar uma de cada vez. Por outro lado, caso o processo não precise das páginas carregadas antecipadamente, o sistema terá perdido tempo e ocupado memória principal desnecessariamente.

A técnica de paginação antecipada pode ser empregada no momento da criação de um processo ou na ocorrência de um page fault. Quando um processo é criado, diversas páginas do programa na memória secundária devem ser carregadas para a memória principal, gerando um elevado número de page faults e várias operações de leitura em disco. Na medida em que as páginas são carregadas para a memória, a taxa de paginação tende a diminuir. Se o sistema carregar não apenas uma, mas um conjunto de páginas, a taxa de paginação do processo deverá cair imediatamente e estabilizar-se durante um certo período de tempo. Seguindo o mesmo raciocínio, sempre que houver um page fault, o sistema poderá carregar para a memória, além da página referenciada, páginas adicionais, na tentativa de evitar novos page faults e sucessivas operações de leitura em disco.

10.4.2 Políticas de Alocação de Páginas

A *política de alocação de páginas* determina quantos frames cada processo pode manter na memória principal. Existem, basicamente, duas alternativas: alocação fixa e alocação variável.

Na *política de alocação fixa*, cada processo tem um número máximo de frames que pode ser utilizado durante a execução do programa. Caso o número de páginas reais seja insuficiente, uma página do processo deve ser descartada para que uma nova seja carregada. O *limite de páginas reais* pode ser igual para todos os processos ou definido individualmente. Apesar de parecer justo, alocar o mesmo número de páginas para todos os processos, pode não ser uma boa opção, pois a necessidade de memória de cada processo raramente é a mesma. O limite de páginas deve ser definido no momento da criação do processo, com base no tipo da aplicação que será executada. Essa informação faz parte do contexto de software do processo.

Apesar de sua simplicidade, a política de alocação fixa de páginas apresenta dois problemas. Se o número máximo de páginas alocadas for muito pequeno, o processo tenderá a ter um elevado número de page faults, o que pode impactar no desempenho de todo o sistema. Por outro lado, caso o número de páginas seja muito grande, cada processo irá ocupar na memória principal um espaço maior do que o necessário, reduzindo o número de processos residentes e o grau de multiprogramação. Nesse caso, o sistema pode implementar a técnica de swapping, retirando e carregando processos da/para a memória principal.

Na *política de alocação variável*, o número máximo de páginas alocadas ao processo pode variar durante sua execução em função de sua taxa de paginação e da ocupação da memória principal. Nesse modelo, processos com elevadas taxas de paginação podem ampliar o limite máximo de frames, a fim de reduzir o número de page faults. Da mesma forma, processos com baixas taxas de paginação podem ter páginas realocadas para outros processos. Este mecanismo, apesar de mais flexível, exige que o sistema operacional monitore constantemente o comportamento dos processos, gerando maior overhead.

10.4.3 Políticas de Substituição de Páginas

Em algumas situações, quando um processo atinge o seu limite de alocação de frames e necessita alocar novas páginas na memória principal, o sistema operacional deve selecionar, dentre as diversas páginas alocadas, qual deverá ser liberada. Este mecanismo é chamado de *política de substituição de páginas*. Uma página real, quando liberada por um processo, está livre para ser utilizada por qualquer outro processo. A partir dessa situação, qualquer estratégia de substituição de páginas deve considerar se uma página foi ou não modificada antes de liberá-la; caso contrário, os dados armazenados na página podem ser perdidos. No caso de páginas contendo código executável, que não sofrem alterações, não existe essa preocupação, pois existe uma cópia do código no arquivo executável em disco. As páginas modificáveis, que armazenam variáveis e estruturas de dados, podem sofrer alterações. Neste caso, o sistema deverá gravá-la na memória secundária antes do descarte, preservando seu conteúdo para uso em futuras referências. Este mecanismo é conhecido como *page out* (Fig. 10.9). Com este propósito, o sistema mantém um *arquivo de paginação* (*page file*) onde todas as páginas modificadas e descartadas são armazenadas. Sempre que uma página modificada for novamente referenciada, ocorrerá um page in, carregando-a para a memória principal a partir do arquivo de paginação.

O sistema operacional consegue identificar as páginas modificadas através de um bit que existe em cada entrada da tabela de páginas, chamado *bit de modificação* (*dirty*

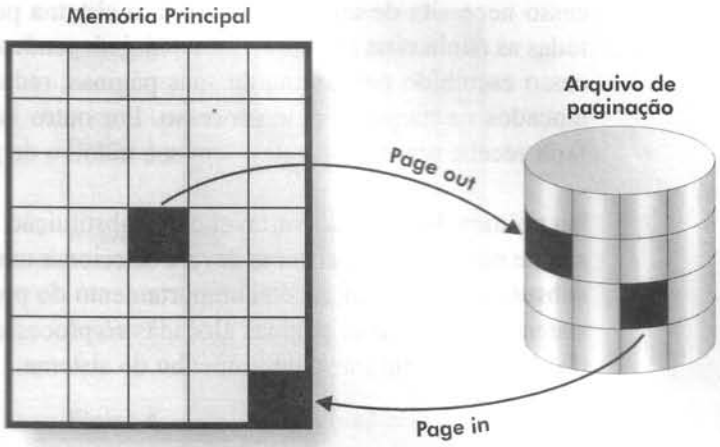

Fig. 10.9 Substituição de páginas.

bit ou modify bit). Sempre que uma página sofre uma alteração, o valor do bit de modificação é alterado, indicando que a página foi modificada.

A política de substituição de páginas pode ser classificada conforme seu escopo, ou seja, dentre os processos residentes na memória principal quais são candidatos a ter páginas realocadas. Em função desse escopo, a política de substituição pode ser definida como local ou global.

Na *política de substituição local,* apenas as páginas do processo que gerou o page fault são candidatas a realocação. Nesse modelo, sempre que um processo precisar de uma nova página, o sistema deverá selecionar, dentre os frames alocados pelo processo, a página a ser substituída. Os frames dos demais processos não são avaliados para substituição.

Já na *política de substituição global*, todas as páginas alocadas na memória principal são candidatas a substituição, independente do processo que gerou o page fault. Como qualquer processo pode ser escolhido, é possível que o processo selecionado sofra um aumento na sua taxa de paginação, em função da redução do número de páginas alocadas na memória. Na verdade, nem todas as páginas podem ser candidatas a substituição. Algumas páginas, como as do núcleo do sistema, são marcadas como bloqueadas e não podem ser realocadas.

Existe uma relação entre o escopo da política de substituição e a política de alocação de páginas, apresentada anteriormente. A política de alocação fixa permite apenas a utilização de uma política de substituição local. Nesse caso, sempre que um processo necessita de uma nova página, o sistema deverá selecionar um frame do próprio processo para ser realocado, mantendo assim o seu limite de páginas.

A política de alocação variável permite uma política de substituição tanto local quanto global. Na política de alocação variável com substituição global, quando um pro-

cesso necessita de uma nova página, o sistema poderá selecionar um frame dentre todas as páginas na memória principal, independente do processo. Nesse caso, o processo escolhido perde uma de suas páginas, reduzindo assim o número de frames alocados na memória pelo processo. Por outro lado, o processo que gerou o page fault recebe um novo frame e tem seu número de páginas aumentado.

Na política de alocação variável com substituição local, quando um processo necessita de nova página o sistema deverá selecionar uma página do próprio processo para substituição. Em função do comportamento do processo e do nível de utilização do sistema, o número de páginas alocadas ao processo pode ser aumentado ou diminuído, a fim de melhorar o desempenho do sistema.

10.4.4 Working Set

Apesar de suas diversas vantagens, o mecanismo de memória virtual introduz um sério problema. Como cada processo possui na memória principal apenas algumas páginas alocadas, o sistema deve manter um conjunto mínimo de frames buscando uma baixa taxa de paginação. Ao mesmo tempo, o sistema operacional deve impedir que os processos tenham um número excessivo de páginas na memória, de forma a aumentar o grau de compartilhamento da memória principal.

Caso os processos tenham na memória principal um número insuficiente de páginas para a execução do programa, é provável que diversos frames referenciados ao longo do seu processamento não estejam na memória. Esta situação provoca a ocorrência de um número elevado de page faults e, conseqüentemente, inúmeras operações de E/S. Neste caso, ocorre um problema conhecido como *thrashing*, provocando sérias conseqüências ao desempenho do sistema.

O conceito de *working set* surgiu com o objetivo de reduzir o problema do thrashing e está relacionado ao *princípio da localidade*. Existem dois tipos de localidade que são observados durante a execução da maioria dos programas. A *localidade espacial* é a tendência de que após uma referência a uma posição de memória sejam realizadas novas referências a endereços próximos. A *localidade temporal* é a tendência de que após a referência a uma posição de memória esta mesma posição seja novamente referenciada em um curto intervalo de tempo.

O princípio da localidade significa, na prática, que o processador tenderá a concentrar suas referências a um conjunto de páginas do processo durante um determinado período de tempo. Imaginando um loop, cujo código ocupe três páginas, a tendência de essas três páginas serem referenciadas diversas vezes é muito alta (Fig. 10.10).

No início da execução de um programa, observa-se um elevado número de page faults, pois não existe nenhum frame do processo na memória principal. Com o decorrer da sua execução, as páginas são carregadas para a memória e o número de page faults diminui. Após um período de estabilidade, o programa gera novamente uma elevada taxa de paginação, que depois de algum tempo volta a se estabilizar. Esse fenômeno pode repetir-se inúmeras vezes durante a execução de um processo e está relacionado com a forma com que a aplicação foi escrita. Normalmente, se um programa foi desenvolvido utilizando técnicas estruturadas, o conceito da localida-

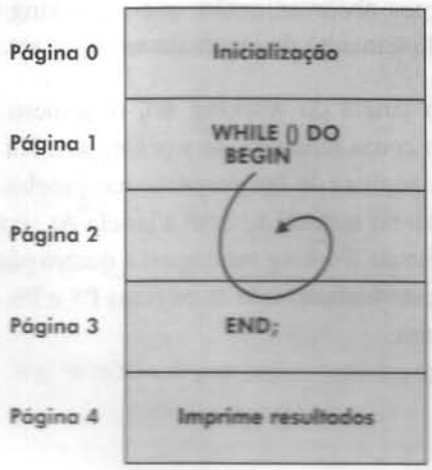

Fig. 10.10 Conceito de localidade.

de quase sempre é válido. Nesse caso, a localidade será percebida, por exemplo, durante a execução de repetições e sub-rotinas.

O princípio da localidade é indispensável para que a gerência de memória virtual funcione eficientemente. Como as referências aos endereços de um processo concentram-se em um determinado conjunto de páginas, é possível manter apenas parte do código de cada um dos diversos programas na memória principal, sem prejudicar a execução dos processos. Caso contrário, o sistema teria que manter integralmente o código de todos os programas na memória para evitar o problema do thrashing. Considerando um programa com rotinas de inicialização, um loop principal e rotinas de finalização, manter o programa inteiro na memória principal seria ineficiente. A má utilização da memória fica mais clara quando o programa possui rotinas de tratamento de erros na memória que, por muitas vezes, nunca serão executadas.

A partir da observação do princípio da localidade, Peter Denning formulou o *modelo de working set* (Denning, 1968, 1970, 1980). O conceito de *working set* é definido como sendo o conjunto das páginas referenciadas por um processo durante determinado intervalo de tempo. A Fig. 10.11 ilustra que no instante t_2, o working set do processo, $W(t_2, \Delta t)$, são as páginas referenciadas no intervalo Δt $(t_2 - t_1)$, isto é, as páginas P2, P3 e P8. O intervalo de tempo Δt é denominado *janela do working*

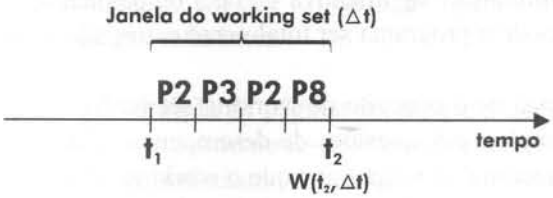

Fig. 10.11 Modelo de working set.

set. Podemos observar, então, que o working set de um processo é uma função do tempo e do tamanho da janela do working set.

Dentro da janela do working set, o número de páginas distintas referenciadas é conhecido como *tamanho do working set*. Na Fig. 10.12, são apresentadas as referências às páginas de um processo nas janelas Δt_a (t_2-t_1) e Δt_b (t_3-t_2). O working set do processo no instante t_2, com a janela Δt_a, corresponde às páginas P2, P3, P4 e P5, e o tamanho do working set é igual a quatro páginas. No instante t_3, com a janela Δt_b, o working set corresponde às páginas P5 e P6, e o tamanho do working set é igual a duas páginas.

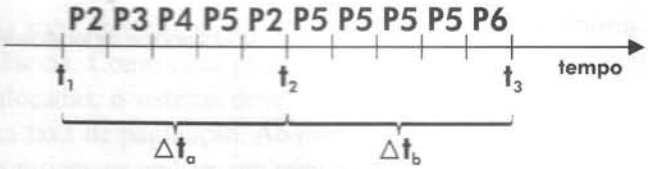

Fig. 10.12 Tamanho do working set.

O modelo de working set proposto por Denning possibilita prever quais páginas são necessárias à execução de um programa de forma eficiente. Caso a janela do working set seja apropriadamente selecionada, em função da localidade do programa, o sistema operacional deverá manter as páginas do working set de cada processo residentes na memória principal. Considerando que a localidade de um programa varia ao longo da sua execução, o tamanho do working set do processo também varia, ou seja, o seu limite de páginas reais deve acompanhar esta variação. O working set refletirá a localidade do programa, reduzindo a taxa de paginação dos processos e evitando, conseqüentemente, o thrashing.

Caso o limite de páginas reais de um processo seja maior do que o tamanho do working set, menor será a chance de ocorrer uma referência a uma página que não esteja na memória principal. Por outro lado, as páginas dos processos ocuparão excessivo espaço, reduzindo o grau de compartilhamento da memória. No caso de o limite de páginas reais ser menor, a taxa de paginação será alta, pois parte do working set não estará residente na memória principal. Outro fato que pode ser observado é a existência de um ponto onde o aumento do limite de páginas reais do processo não implica a diminuição significativa da taxa de paginação, sendo este ponto alcançado muito antes de o programa ser totalmente carregado para a memória (Fig. 10.13).

Apesar de o conceito de working set ser bastante intuitivo, sua implementação não é simples, por questões de desempenho. Para implementar esse modelo, o sistema operacional deve garantir que o working set de cada processo permaneça na memória principal, determinando quais páginas devem ser mantidas e retiradas em função da última janela de tempo. Em função disso, o modelo de working set deve ser

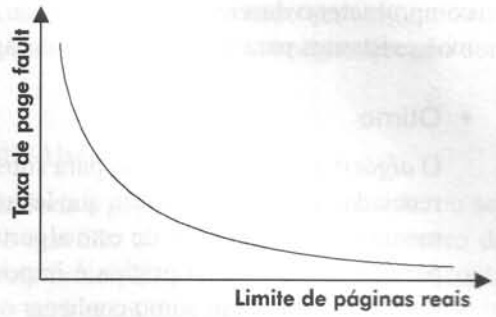

Fig. 10.13 Taxa de page fault × limite de páginas reais.

implementado somente em sistemas que utilizam a política de alocação de páginas variável, onde o limite de páginas reais não é fixo.

Uma maneira de implementar o modelo de working set é analisar a taxa de paginação de cada processo, conhecida como *estratégia de freqüência de page fault*. Caso um processo tenha uma taxa de paginação acima de um limite definido pelo sistema, o processo deverá aumentar o seu limite de páginas reais na tentativa de alcançar o seu working set. Por outro lado, se o processo tem uma taxa de paginação abaixo de um certo limite, o sistema poderá reduzir o limite de páginas sem comprometer seu desempenho. O sistema operacional OpenVMS implementa uma estratégia semelhante a esta. Na prática, o modelo de working set serve como base para inúmeros algoritmos de substituição de páginas, como os apresentados neste capítulo.

10.4.5 Algoritmos de Substituição de Páginas

O maior problema na gerência de memória virtual por paginação não é decidir quais páginas carregar para a memória principal, mas quais liberar (Denning, 1968). Quando um processo necessita de uma nova página e não existem frames disponíveis, o sistema deverá selecionar, dentre as diversas páginas alocadas na memória, qual deverá ser liberada pelo processo.

Os *algoritmos de substituição de páginas* têm o objetivo de selecionar os frames que tenham as menores chances de serem referenciados em um futuro próximo; caso contrário, o frame poderia retornar diversas vezes para a memória principal, gerando vários page faults e acessos à memória secundária. A partir do princípio da localidade, a maioria dos algoritmos tenta prever o comportamento futuro das aplicações em função do comportamento passado, avaliando o número de vezes que uma página foi referenciada, o momento em que foi carregada para a memória principal e o intervalo de tempo da última referência.

A melhor estratégia de substituição de páginas seria aquela que escolhesse um frame que não fosse mais utilizado no futuro ou levasse mais tempo para ser novamente referenciado. Porém, quanto mais sofisticado o algoritmo de substituição, maior overhead para o sistema operacional implementá-lo. O algoritmo de substituição deve tentar manter o working set dos processos na memória principal e, ao mesmo tempo, não

comprometer o desempenho do sistema. A seguir, analisaremos os principais algoritmos existentes para a substituição de páginas.

- Ótimo

O *algoritmo ótimo* seleciona para substituição uma página que não será mais referenciada no futuro ou aquela que levará o maior intervalo de tempo para ser novamente utilizada. Apesar de este algoritmo garantir as menores taxas de paginação para os processos, na prática é impossível de ser implementado, pois o sistema operacional não tem como conhecer o comportamento futuro das aplicações. Essa estratégia é utilizada apenas como modelo comparativo na análise de outros algoritmos de substituição.

- Aleatório

O *algoritmo aleatório*, como o nome já sugere, não utiliza critério algum de seleção. Todas as páginas alocadas na memória principal têm a mesma chance de serem selecionadas, inclusive os frames que são freqüentemente referenciados. Apesar de ser uma estratégia que consome poucos recursos do sistema, é raramente implementada, em função de sua baixa eficiência.

- FIFO (First-In-First-Out)

No *algoritmo FIFO*, a página que primeiro foi utilizada será a primeira a ser escolhida, ou seja, o algoritmo seleciona a página que está há mais tempo na memória principal. O algoritmo pode ser implementado associando-se a cada página o momento em que foi carregada para a memória ou utilizando-se uma estrutura de fila, onde as páginas mais antigas estão no início e as mais recentes no final (Fig. 10.14).

Parece razoável pensar que uma página que esteja há mais tempo na memória seja justamente aquela que deva ser selecionada, porém isto nem sempre é verdadeiro. No caso de uma página que seja constantemente referenciada, como é o caso de páginas que contêm dados, o fator tempo torna-se irrelevante e o sistema tem que referenciar a mesma página diversas vezes ao longo do processamento.

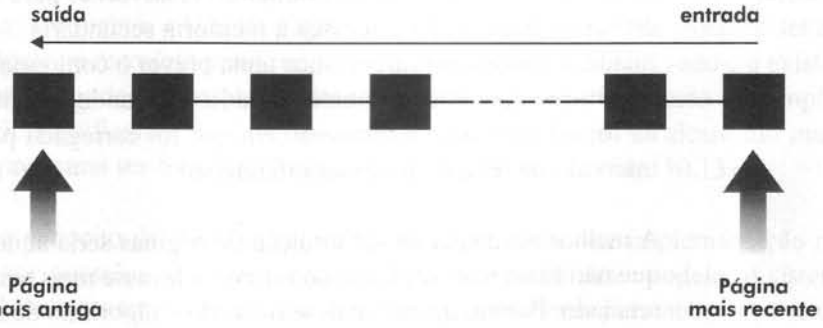

Fig. 10.14 FIFO.

O algoritmo FIFO é raramente implementado sem algum outro mecanismo que minimize o problema da seleção de páginas antigas que são constantemente referenciadas.

- LFU (Least-Frequently-Used)

O *algoritmo LFU* seleciona a página menos referenciada, ou seja, o frame menos utilizado. Para isso, é mantido um contador com o número de referências para cada página na memória principal. A página que possuir o contador com o menor número de referências será escolhida, ou seja, o algoritmo evita selecionar páginas que são bastante utilizadas.

Inicialmente, esta parece ser uma boa estratégia, porém as páginas que estão há pouco tempo na memória principal podem ser, justamente, aquelas selecionadas, pois seus contadores estarão com o menor número de referências. É possível também que uma página muito utilizada no passado não seja mais referenciada no futuro. Nesse caso, como o contador possuiria um número elevado de referências, a página não seria selecionada para substituição. Este esquema, como apresentado, é raramente implementado, servindo apenas de base para outros algoritmos de substituição.

- LRU (Least-Recently-Used)

O *algoritmo LRU* seleciona a página na memória principal que está há mais tempo sem ser referenciada. Se considerarmos o princípio da localidade, uma página que não foi utilizada recentemente provavelmente não será referenciada novamente em um futuro próximo.

Para implementar esse algoritmo, é necessário que cada página tenha associado o momento do último acesso, que deve ser atualizado a cada referência a um frame. Quando for necessário substituir uma página, o sistema fará uma busca por um frame que esteja há mais tempo sem ser referenciado. Outra maneira de implementar o LRU seria através de uma lista encadeada, onde todas as páginas estariam ordenadas pelo momento da última referência. Neste caso, cada acesso à memória exigiria um acesso à lista.

Apesar de ser uma estratégia com uma eficiência comparável ao algoritmo ótimo, é pouco empregada na prática, devido ao seu elevado custo de implementação.

- NRU (Not-Recently-Used)

O *algoritmo NRU* é bastante semelhante ao LRU, porém com menor sofisticação. Para a implementação deste algoritmo é necessário um bit adicional, conhecido como *bit de referência* (BR). O bit indica se a página foi utilizada recentemente e está presente em cada entrada da tabela de páginas.

Quando uma página é carregada para a memória principal, o bit de referência é alterado pelo hardware, indicando que a página foi referenciada (BR = 1). Periodicamente, o sistema altera o valor do bit de referência (BR = 0), e à medida que as páginas são utilizadas, o bit associado a cada frame retorna para 1. Desta forma, é possível distinguir quais frames foram recentemente referenciados. No momen-

to da substituição de uma página, o sistema seleciona um dos frames que não tenha sido utilizado recentemente, ou seja, com o bit de referência igual a zero.

O algoritmo NRU torna-se mais eficiente se o bit de modificação for utilizado em conjunto com o bit de referência. Neste caso, é possível classificar as páginas em quatro categorias (Tabela 10.2). O algoritmo, inicialmente, seleciona as páginas que não foram utilizadas recentemente e não foram modificadas, evitando assim um page out. O próximo passo é substituir as páginas que não tenham sido referenciadas recentemente, porém modificadas. Neste caso, apesar de existir um acesso à memória secundária para a gravação da página modificada, seguindo o princípio da localidade, há pouca chance de essa página ser novamente referenciada.

Tabela 10.2 Bits de referência e modificação

Categorias	Bits avaliados	Resultado
1	BR = 0 e BM = 0	Página não referenciada e não modificada.
2	BR = 0 e BM = 1	Página não referenciada e modificada.
3	BR = 1 e BM = 0	Página referenciada e não modificada.
4	BR = 1 e BM = 1	Página referenciada e modificada.

- FIFO com buffer de páginas

O algoritmo FIFO, anteriormente apresentado, é de fácil implementação e baixo overhead, porém apresenta uma séria limitação quando páginas antigas são constantemente referenciadas. Uma maneira de torná-lo uma política de substituição eficiente é implementar variações no algoritmo.

O *algoritmo FIFO com buffer de páginas* combina uma lista de páginas alocadas (LPA) com uma lista de páginas livres (LPL). A LPA organiza todas as páginas que estão sendo utilizadas na memória principal, podendo ser implementada como uma lista única para todos os processos ou uma lista individual para cada processo. Independente da política utilizada, a LPA organiza as páginas alocadas há mais tempo na memória no início da lista, enquanto as páginas mais recentes no seu final. Da mesma forma, a LPL organiza todos os frames livres da memória principal, sendo que as páginas livres há mais tempo estão no início e as mais recentes no final. Sempre que um processo necessita alocar uma nova página, o sistema utiliza a primeira página da LPL, colocando-a no final da LPA (Fig. 10.15a). Caso o processo tenha que liberar uma página, o mecanismo de substituição seleciona o frame em uso há mais tempo na memória, isto é, o primeiro da LPA, colocando-o no final da LPL (Fig. 10.15b).

É importante notar que a página selecionada e que entrou na LPL continua disponível na memória principal por um determinado intervalo de tempo. Caso esta página seja novamente referenciada e ainda não tenha sido alocada, basta retirá-la da LPL e devolvê-la ao processo (Fig. 10.15c). Nesse caso, a LPL funciona como um buffer de páginas, evitando o acesso à memória secundária. Por outro lado, se

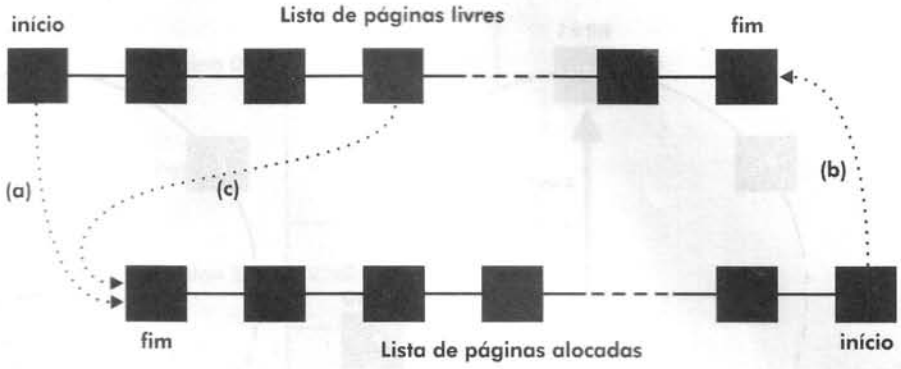

Fig. 10.15 FIFO com buffer de páginas.

a página não for mais referenciada, com o passar do tempo irá chegar ao início da LPL, quando será utilizada para um outro processo. Caso a página seja posteriormente referenciada, o sistema terá que carregá-la novamente da memória secundária.

O buffer de páginas permite criar um algoritmo de substituição de páginas simples e eficiente, sem o custo de outras implementações. O sistema operacional Mach utiliza o esquema de buffer de páginas único, enquanto o OpenVMS e o Windows 2000 utilizam dois buffers: um para páginas livres (*free page list*) e outro para páginas modificadas (*modified page list*).

- FIFO circular (clock)

O *algoritmo FIFO circular* utiliza como base o FIFO, porém as páginas alocadas na memória estão em uma estrutura de lista circular, semelhante a um relógio. Este algoritmo é implementado, com pequenas variações na maioria dos sistemas Unix.

Para a implementação do algoritmo existe um ponteiro que guarda a posição da página mais antiga na lista (Fig. 10.16a). Cada página possui associado um bit de referência, indicando se a página foi recentemente referenciada. Quando é necessário substituir uma página, o sistema verifica se o frame apontado tem o bit de referência desligado (BR = 0). Nesse caso, a página é selecionada para descarte, pois, além de ser a mais antiga, não foi utilizada recentemente. Por outro lado, se a página apontada tem o bit de referência ligado (BR = 1), o bit é desligado e o ponteiro incrementado, pois, apesar de ser a página mais antiga, foi utilizada recentemente. O processo se repete até ser encontrada uma página com bit de referência igual a zero (Fig. 10.16b).

Neste algoritmo, existe a possibilidade de todos os frames possuírem o bit de referência ligado. Nesse caso, o ponteiro percorrerá toda a lista, desligando o bit de referência de cada página. Ao final, a página mais antiga é selecionada. A utilização do bit de referência permite conceder a cada página uma segunda chance antes de ser substituída. É possível melhorar a eficiência do algoritmo utilizando

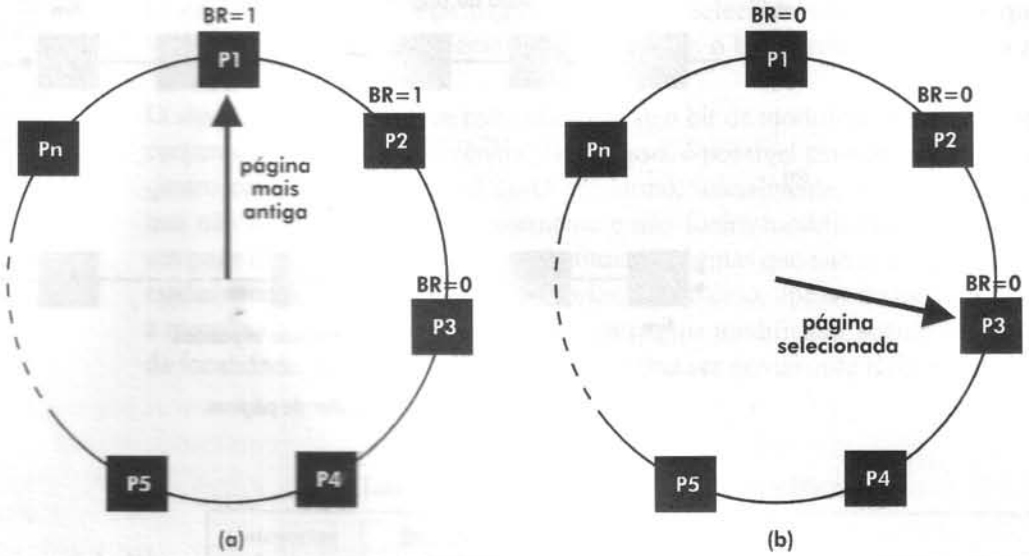

Fig. 10.16 FIFO circular.

o bit de modificação, juntamente com o bit de referência, como apresentado no esquema NRU.

10.4.6 Tamanho de Página

A definição do *tamanho de página* é um fator importante no projeto de sistemas que implementam memória virtual por paginação. O tamanho da página está associado à arquitetura do hardware e varia de acordo com o processador, mas normalmente está entre 512 e 16 M endereços. Algumas arquiteturas permitem a configuração do tamanho de página, oferecendo assim maior flexibilidade.

O tamanho da página tem impacto direto sobre o número de entradas na tabela de páginas e, conseqüentemente, no tamanho da tabela e no espaço ocupado na memória principal. Por exemplo, em uma arquitetura de 32 bits para endereçamento e páginas de 4 K endereços, teríamos tabelas de páginas de até 2^{20} entradas. Se cada entrada ocupasse 4 bytes, poderíamos ter tabelas de páginas de 4 Mb por processo. Logo, páginas pequenas necessitam de tabelas de mapeamento maiores, provocam maior taxa de paginação e aumentam o número de acessos à memória secundária.

Apesar de páginas grandes tornarem menor o tamanho das tabelas de páginas, ocorre o problema da *fragmentação interna*. Como podemos observar na Fig. 10.17, o programa ocupa quase que integralmente todas as páginas. A fragmentação só é encontrada, realmente, na última página, quando o código não ocupa o frame por completo.

O principal argumento a favor do uso de páginas pequenas é a melhor utilização da memória principal. A partir do princípio da localidade, com páginas pequenas teria-

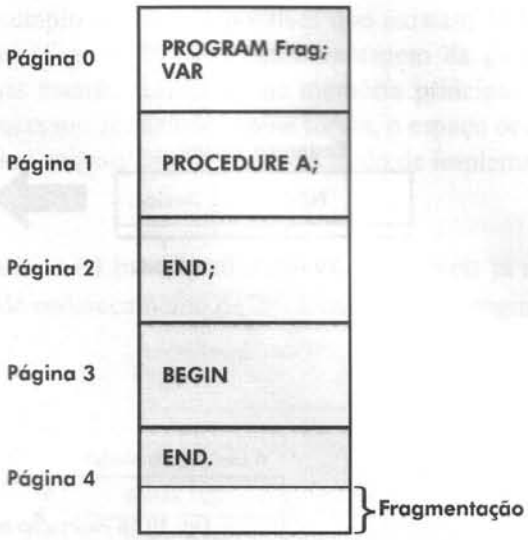

Fig. 10.17 Fragmentação interna.

mos na memória apenas as partes dos programas com maiores chances de serem executadas. Quanto maior o tamanho de página, maiores as chances de ter na memória código pouco referenciado, ocupando espaço desnecessariamente. Além disso, páginas pequenas reduzem o problema da fragmentação interna.

Outra preocupação quanto ao tamanho da página é a relacionada aos tempos de leitura e gravação na memória secundária. Devido ao modo de funcionamento dos discos, o tempo de operações de E/S com duas páginas de 512 bytes é muito maior do que em uma página de 1024 bytes.

Com o aumento do espaço de endereçamento e da velocidade de acesso à memória principal, a tendência no projeto de sistemas operacionais com memória virtual por paginação é a adoção de páginas maiores, apesar dos problemas citados.

10.4.7 Paginação em Múltiplos Níveis

Em sistemas que implementam apenas um nível de paginação, o tamanho das tabelas de páginas pode ser um problema. Como já visto, em uma arquitetura de 32 bits para endereçamento e páginas com 4 K endereços por processo, onde cada entrada na tabela de páginas ocupe 4 bytes, a tabela de páginas poderia ter mais de um milhão de entradas e ocuparia 4 Mb de espaço (Fig. 10.18). Imaginando vários processos residentes na memória principal, manter tabelas desse tamanho para cada processo certamente seria de difícil gerenciamento.

Uma boa solução para contornar o problema apresentado é a utilização de *tabelas de páginas em múltiplos níveis*. A idéia é que o princípio da localidade seja aplicado também às tabelas de mapeamento — apenas as informações sobre páginas realmente necessárias aos processos estariam residentes na memória principal.

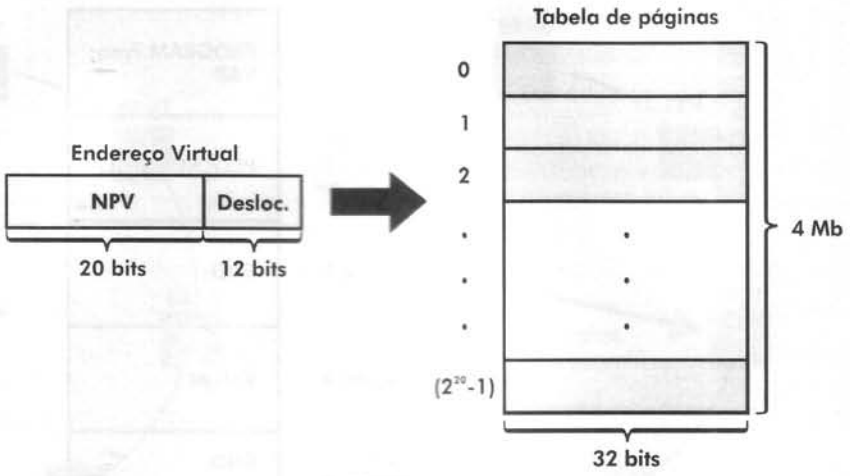

Fig. 10.18 Paginação em um nível.

No esquema de *paginação em dois níveis* existe uma tabela diretório, onde cada entrada aponta para uma tabela de página. A partir do exemplo anterior, podemos dividir o campo NPV em duas partes: número da página virtual de nível 1 (NPV1) e número da página virtual de nível 2 (NPV2), cada um com 10 bits. O NPV1 permite localizar a tabela de páginas na tabela diretório; por sua vez, o NPV2 permite localizar o frame desejado na tabela de páginas (Fig. 10.19).

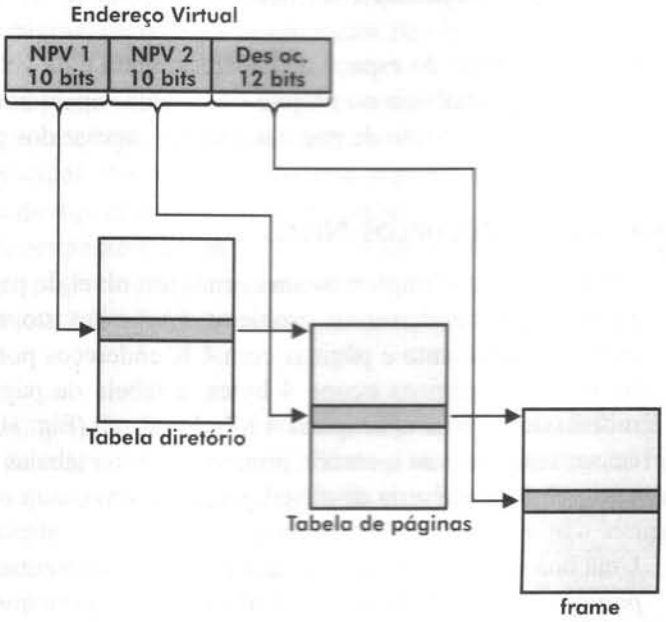

Fig. 10.19 Endereço virtual em dois níveis.

Utilizando-se o exemplo anterior, é possível que existam 1024 tabelas de páginas para cada processo (Fig. 10.20). A grande vantagem da paginação em múltiplos níveis é que apenas estarão residentes na memória principal as tabelas realmente necessárias aos processos, reduzindo, dessa forma, o espaço ocupado na memória. A arquitetura VAX da Compaq/Digital é um exemplo de implementação de paginação em dois níveis.

Em uma arquitetura de 64 bits, a estrutura em dois níveis já não é mais adequada devido ao espaço de endereçamento de 2^{64}. Considerando páginas de 4 K endereços,

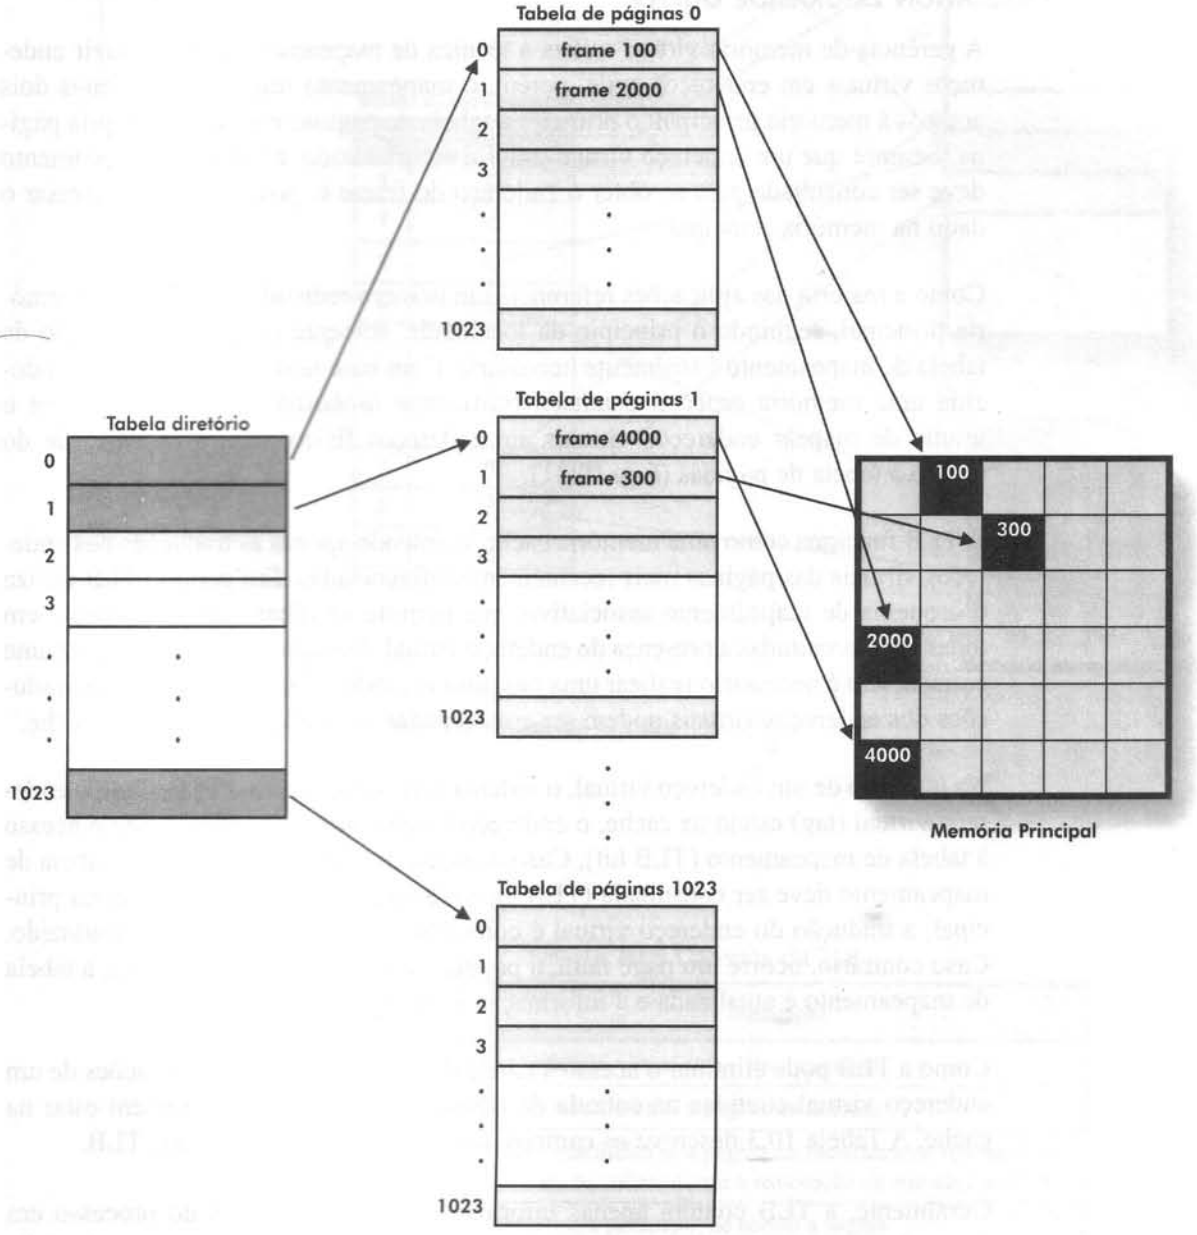

Fig. 10.20 Paginação em dois níveis.

NPV2 com 10 bits e NPV1 com 42 bits, teríamos tabelas com 2^{42} entradas. Novamente a solução passa por dividir a tabela diretório, criando uma estrutura em três níveis. Por exemplo, NPV1 com 32 bits, NPV2 com 10 bits e NPV3 com 10 bits. Esse tipo de implementação pode ser encontrado em alguns processadores da família SPARC, da Sun Microsystems.

A técnica de paginação em múltiplos níveis pode ser estendida para quatro níveis, como nos processadores Motorola 68030, cinco ou mais níveis. A cada nível introduzido há, pelo menos, mais um acesso à memória principal, o que sem dúvida gera problemas de desempenho. Tais problemas podem ser contornados utilizando-se caches, como será apresentado a seguir.

10.4.8 Translation Lookaside Buffer

A gerência de memória virtual utiliza a técnica de mapeamento para traduzir endereços virtuais em endereços reais, porém, o mapeamento implica pelo menos dois acessos à memória principal: o primeiro à tabela de páginas e o outro à própria página. Sempre que um endereço virtual precisa ser traduzido, a tabela de mapeamento deve ser consultada para se obter o endereço do frame e, posteriormente, acessar o dado na memória principal.

Como a maioria das aplicações referencia um número reduzido de frames na memória principal, seguindo o princípio da localidade, somente uma pequena fração da tabela de mapeamento é realmente necessária. Com base neste princípio, foi introduzida uma memória especial chamada *translation lookaside buffer* (TLB), com o intuito de mapear endereços virtuais em endereços físicos sem a necessidade do acesso à tabela de páginas (Fig. 10.21).

O TLB funciona como uma memória cache, mantendo apenas as traduções dos endereços virtuais das páginas mais recentemente referenciadas. Em geral, o TLB utiliza o esquema de mapeamento associativo, que permite verificar simultaneamente em todas as suas entradas a presença do endereço virtual. Dessa forma, para localizar uma entrada, não é necessário realizar uma pesquisa em todo o TLB. Além disso, as traduções dos endereços virtuais podem ser armazenadas em qualquer posição da cache.

Na tradução de um endereço virtual, o sistema verifica primeiro o TLB. Caso o endereço virtual (tag) esteja na cache, o endereço físico é utilizado, eliminando o acesso à tabela de mapeamento (TLB hit). Caso o endereço não esteja na cache, a tabela de mapeamento deve ser consultada (TLB miss). Se a página estiver na memória principal, a tradução do endereço virtual é colocada no TLB e o endereço é traduzido. Caso contrário, ocorre um page fault, a página é carregada para a memória, a tabela de mapeamento é atualizada e a informação é carregada para a TLB.

Como a TLB pode eliminar o acesso à tabela de mapeamento, as informações de um endereço virtual contidas na entrada da tabela de páginas devem também estar na cache. A Tabela 10.3 descreve os campos de uma entrada típica de uma TLB.

Geralmente, a TLB contém apenas informações sobre endereços do processo em execução, ou seja, quando há uma mudança de contexto, a TLB deve ser reinicializada com informações da tabela de mapeamento do novo processo. Caso a TLB

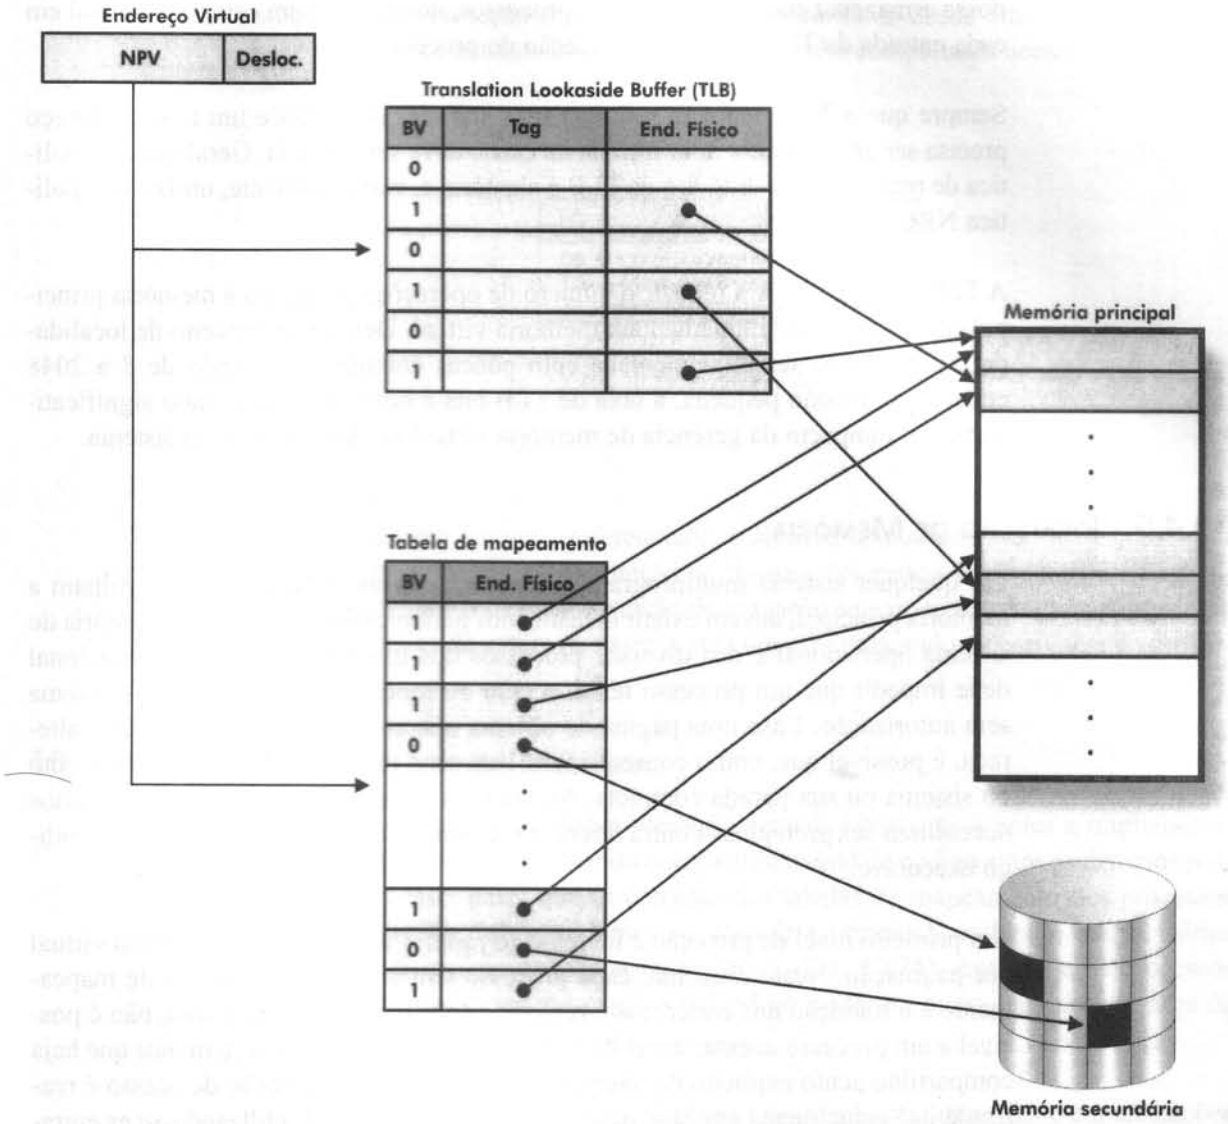

Fig. 10.21 Translation lookaside buffer (TLB).

Tabela 10.3 Campos da TLB

Campo	Descrição
Tag	Endereço virtual sem o deslocamento.
Modificação	Bit que indica se a página foi alterada.
Referência	Bit que indica se a página foi recentemente referenciada, sendo utilizada para a realocação de entradas na TLB.
Proteção	Define a permissão de acesso à página.
Endereço físico	Posição do frame na memória principal.

possa armazenar endereços de vários processos, deve existir um campo adicional em cada entrada da TLB para a identificação do processo.

Sempre que a TLB fica com todas as suas entradas ocupadas e um novo endereço precisa ser armazenado, uma entrada da cache deve ser liberada. Geralmente, a política de realocação de entradas da TLB é aleatória e, mais raramente, utiliza-se a política NRU.

A TLB é essencial para reduzir o número de operações de acesso à memória principal em sistemas que implementam memória virtual. Devido ao conceito de localidade, a TLB pode ser implementada com poucas entradas, mapeando de 8 a 2048 endereços. Mesmo pequena, a taxa de TLB hits é muito alta, reduzindo significativamente o impacto da gerência de memória virtual no desempenho do sistema.

10.4.9 Proteção de Memória

Em qualquer sistema multiprogramável, onde diversas aplicações compartilham a memória principal, devem existir mecanismos para preservar as áreas de memória do sistema operacional e dos diversos processos dos usuários. O sistema operacional deve impedir que um processo tenha acesso ou modifique uma página do sistema sem autorização. Caso uma página do sistema operacional seja indevidamente alterada, é possível que, como conseqüência, haja uma instabilidade no funcionamento do sistema ou sua parada completa. Até mesmo páginas dos processos de usuários necessitam ser protegidas contra alteração, como no caso de frames contendo código executável.

Um primeiro nível de proteção é inerente ao próprio mecanismo de memória virtual por paginação. Neste esquema, cada processo tem a sua própria tabela de mapeamento e a tradução dos endereços é realizada pelo sistema. Desta forma, não é possível a um processo acessar áreas de memória de outros processos, a menos que haja compartilhamento explícito de páginas entre processos. A proteção de acesso é realizada individualmente em cada página da memória principal, utilizando-se as entradas das tabelas de mapeamento, onde alguns bits especificam os acessos permitidos (Fig. 10.22).

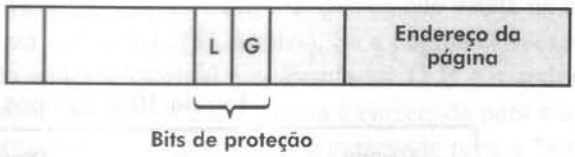

Fig. 10.22 Proteção para páginas.

De forma resumida, definiremos dois tipos de acessos básicos realizados em uma página: leitura e gravação. O acesso de leitura permite a leitura da página, enquanto o de gravação a sua alteração. Os dois tipos de acessos combinados produzem um

mecanismo de proteção simples e eficiente, permitindo desde o total acesso à página, passando por acessos intermediários, até a falta completa de acesso (Fig. 10.23).

LG	Descrição
00	Sem acesso
10	Acesso de leitura
11	Acesso para leitura/gravação

Fig. 10.23 Mecanismo de proteção.

Sempre que uma página é referenciada, o sistema operacional verifica na tabela de mapeamento do processo a proteção do frame e determina se a operação é permitida. Caso a tentativa de uma operação de gravação seja realizada em uma página com proteção apenas de leitura, o sistema gera um erro indicando a ocorrência do problema.

10.4.10 Compartilhamento de Memória

Em sistemas que implementam memória virtual, é bastante simples a implementação da reentrância, possibilitando compartilhamento de código entre os diversos processos. Para isso, basta que as entradas das tabelas de mapeamento dos processos apontem para os mesmos frames na memória principal, evitando, assim, várias cópias de um mesmo programa na memória (Fig. 10.24). Apesar de os processos compartilharem as mesmas páginas de código, cada um possui sua própria área de dados em páginas independentes.

O compartilhamento de memória também é extremamente importante em aplicações que precisam compartilhar dados na memória principal. Similar ao compartilhamento de código, o mecanismo de paginação permite que processos façam o mapeamento de uma mesma área na memória e, conseqüentemente, tenham acesso compartilhado de leitura e gravação. A única preocupação da aplicação é garantir o sincronismo no acesso à região compartilhada, evitando problemas de inconsistência.

10.5 Memória Virtual por Segmentação

Memória virtual por segmentação é a técnica de gerência de memória onde o espaço de endereçamento virtual é dividido em blocos de tamanhos diferentes chamados *segmentos*. Na técnica de segmentação, um programa é dividido logicamente em sub-rotinas e estruturas de dados, que são alocadas em segmentos na memória principal (Fig. 10.25).

Enquanto na técnica de paginação o programa é dividido em páginas de tamanho fixo, sem qualquer ligação com sua estrutura, na segmentação existe uma relação entre a lógica do programa e sua alocação na memória principal. Normalmente, a

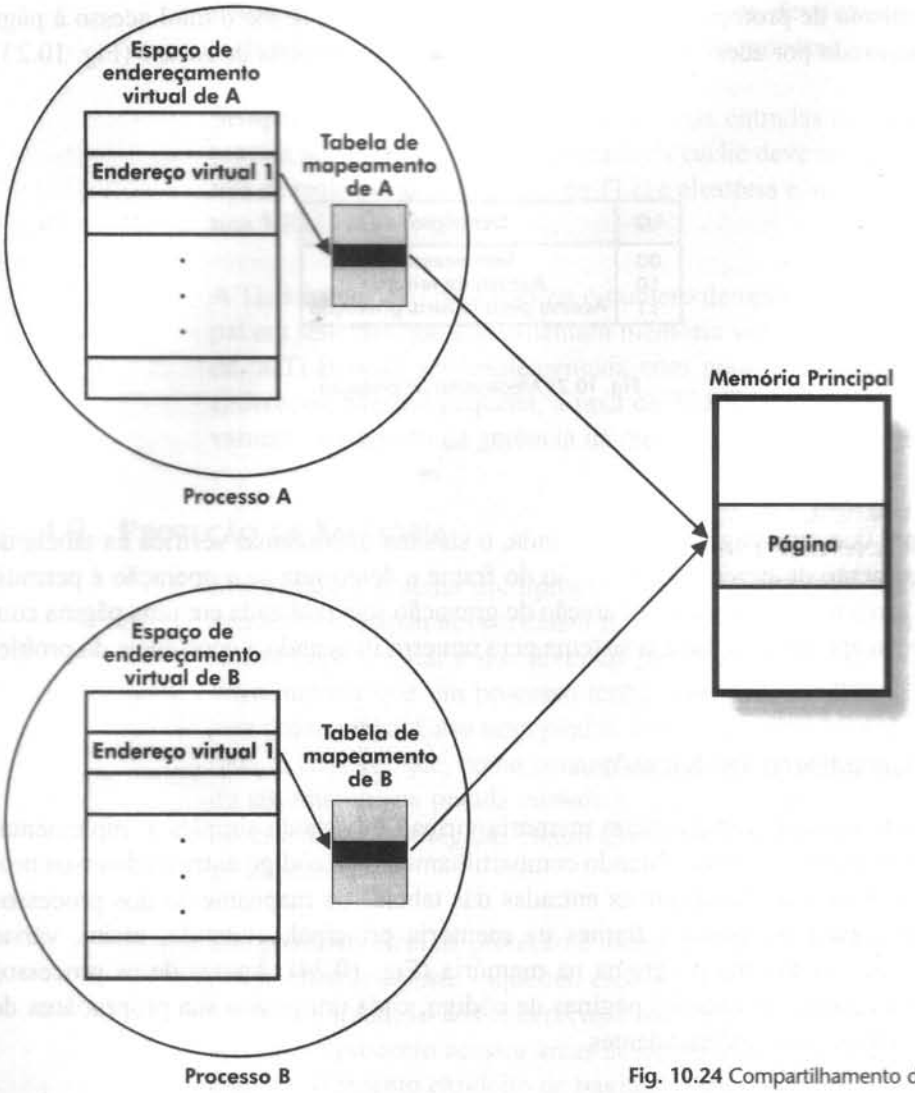

Fig. 10.24 Compartilhamento de memória.

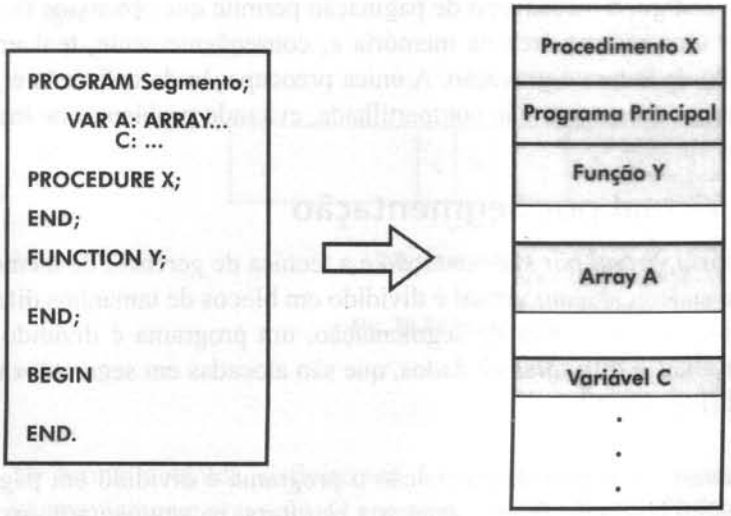

Fig. 10.25 Segmentação.

definição dos segmentos é realizada pelo compilador, a partir do código fonte do programa, e cada segmento pode representar um procedimento, função, vetor ou pilha.

O espaço de endereçamento virtual de um processo possui um número máximo de segmentos que podem existir, onde cada segmento pode variar de tamanho dentro de um limite. O tamanho do segmento pode ser alterado durante a execução do programa, facilitando a implementação de estruturas de dados dinâmicas. Espaços de endereçamento independentes permitem que uma sub-rotina seja alterada sem a necessidade de o programa principal e todas as suas sub-rotinas serem recompiladas e religadas. Em sistemas que implementam paginação, a alteração de uma sub-rotina do programa implica recompilar e religar a aplicação por completo.

O mecanismo de mapeamento é muito semelhante ao de paginação. Os segmentos são mapeados através de *tabelas de mapeamento de segmentos* (TMS), e os endereços são compostos pelo *número do segmento virtual* (NSV) e por um *deslocamento*. O NSV identifica unicamente o segmento virtual que contém o endereço, funcionando como um índice na TMS. O deslocamento indica a posição do endereço virtual em relação ao início do segmento no qual se encontra. O endereço físico é obtido, então, combinando-se o endereço do segmento, localizado na TMS, com o deslocamento, contido no endereço virtual (Fig. 10.26).

Cada ETS possui, além do endereço do segmento na memória principal, informações adicionais, como ilustra a Tabela 10.4.

Uma grande vantagem da segmentação em relação à paginação é a sua facilidade em lidar com estruturas de dados dinâmicas. Como o tamanho do segmento pode ser facilmente alterado na ETS, estruturas de dados, como pilhas e listas encadeadas, podem aumentar e diminuir dinamicamente, oferecendo grande flexibilidade ao desenvolvedor. Enquanto na paginação a expansão de um vetor implica a alocação de novas páginas e, conseqüentemente, o ajuste da tabela de paginação, na segmentação deve ser alterado apenas o tamanho do segmento.

Na técnica de segmentação, apenas os segmentos referenciados são transferidos da memória secundária para a memória principal. Se as aplicações não forem desenvolvidas em módulos, grandes segmentos estarão na memória desnecessariamente, reduzindo o compartilhamento da memória e o grau de multiprogramação. Logo, para que a segmentação funcione de forma eficiente, os programas devem estar bem modularizados.

Para alocar os segmentos na memória principal, o sistema operacional mantém uma tabela com as áreas livres e ocupadas da memória. Quando um novo segmento é referenciado, o sistema seleciona um espaço livre suficiente para que o segmento seja carregado na memória. A política de alocação de páginas pode ser a mesma utilizada na alocação particionada dinâmica (best-fit, worst-fit ou first-fit), apresentada no capítulo Gerência de Memória.

Enquanto na paginação existe o problema da fragmentação interna, na segmentação surge o problema da fragmentação externa. Este problema ocorre sempre que há

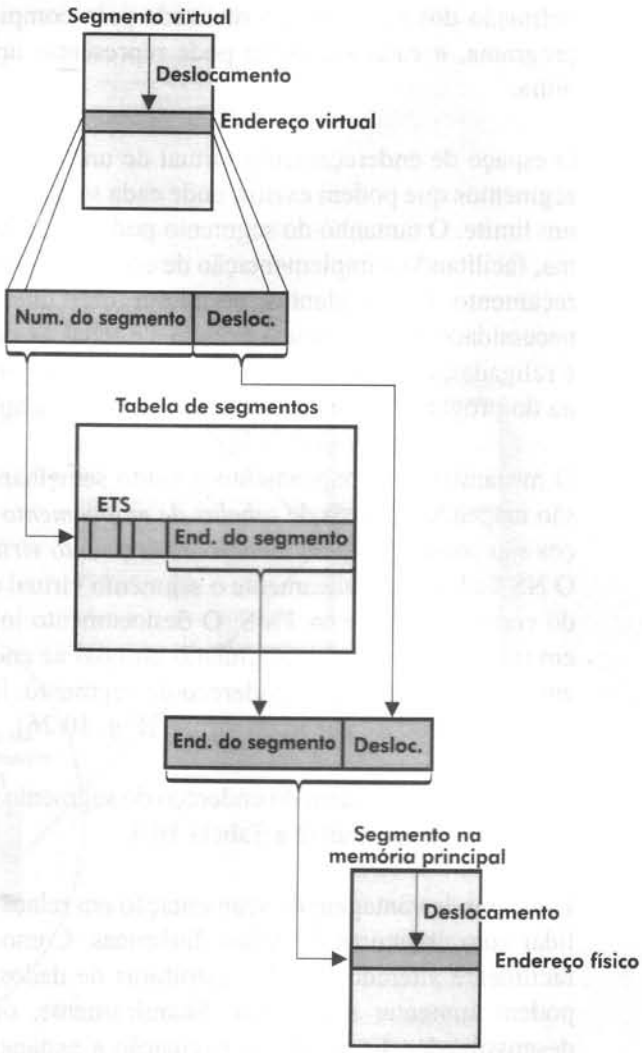

Fig. 10.26 Tradução do endereço virtual.

Tabela 10.4 Campos da ETS

Campo	Descrição
Tamanho	Especifica o tamanho do segmento.
Bit de validade	Indica se o segmento está na memória principal.
Bit de modificação	Indica se o segmento foi alterado.
Bit de referência	Indica se o segmento foi recentemente referenciado, sendo utilizado pelo algoritmo de substituição.
Proteção	Indica a proteção do segmento.

diversas áreas livres na memória principal, mas nenhuma é grande o suficiente para alocar um novo segmento. Neste caso, é necessário que os segmentos sejam realocados na memória de forma que os espaços livres sejam agrupados em uma única área maior.

Em sistemas com segmentação, a proteção de memória é mais simples de ser implementada do que em sistemas com paginação. Como cada segmento possui um conteúdo bem definido, ou seja, instruções ou dados, basta especificar a proteção do segmento na ETS, onde alguns bits podem especificar os tipos de acesso ao segmento.

Na segmentação é mais simples o compartilhamento de memória do que na paginação, pois a tabela de segmentos mapeia estruturas lógicas e não páginas. Para compartilhar um segmento, basta que as ETS dos diversos processos apontem para o mesmo segmento na memória principal. Por exemplo, enquanto o mapeamento de um vetor pode necessitar de várias entradas na tabela de páginas, na tabela de segmentos é necessária apenas uma única entrada.

A Tabela 10.5 compara as técnicas de paginação e segmentação em função de suas principais características.

Tabela 10.5 Paginação × segmentação

Característica	Paginação	Segmentação
Tamanho dos blocos de memória	Iguais	Diferentes
Proteção	Complexa	Mais simples
Compartilhamento	Complexo	Mais simples
Estruturas de dados dinâmicas	Complexo	Mais simples
Fragmentação interna	Pode existir	Não existe
Fragmentação externa	Não existe	Pode existir
Programação modular	Dispensável	Indispensável
Alteração do programa	Mais trabalhosa	Mais simples

10.6 Memória Virtual por Segmentação com Paginação

Memória virtual por segmentação com paginação é a técnica de gerência de memória onde o espaço de endereçamento é dividido em segmentos e, por sua vez, cada segmento dividido em páginas. Esse esquema de gerência de memória tem o objetivo de oferecer as vantagens tanto da técnica de paginação quanto da técnica de segmentação.

Nessa técnica, um endereço virtual é formado pelo *número do segmento virtual* (NSV), um *número de página virtual* (NPV) e um *deslocamento*. Através do NSV, obtém-se uma entrada na tabela de segmentos, que contém informações da tabela de páginas do segmento. O NPV identifica unicamente a página virtual que contém o

endereço, funcionando como um índice na tabela de páginas. O deslocamento indica a posição do endereço virtual em relação ao início da página na qual se encontra. O endereço físico é obtido, então, combinando-se o endereço do frame, localizado na tabela de páginas, com o deslocamento, contido no endereço virtual (Fig. 10.27).

Na visão do programador, sua aplicação continua sendo mapeada em segmentos de tamanhos diferentes, em função das sub-rotinas e estruturas de dados definidas no programa. Por outro lado, o sistema trata cada segmento como um conjunto de páginas de mesmo tamanho, mapeadas por uma tabela de páginas associada ao segmen-

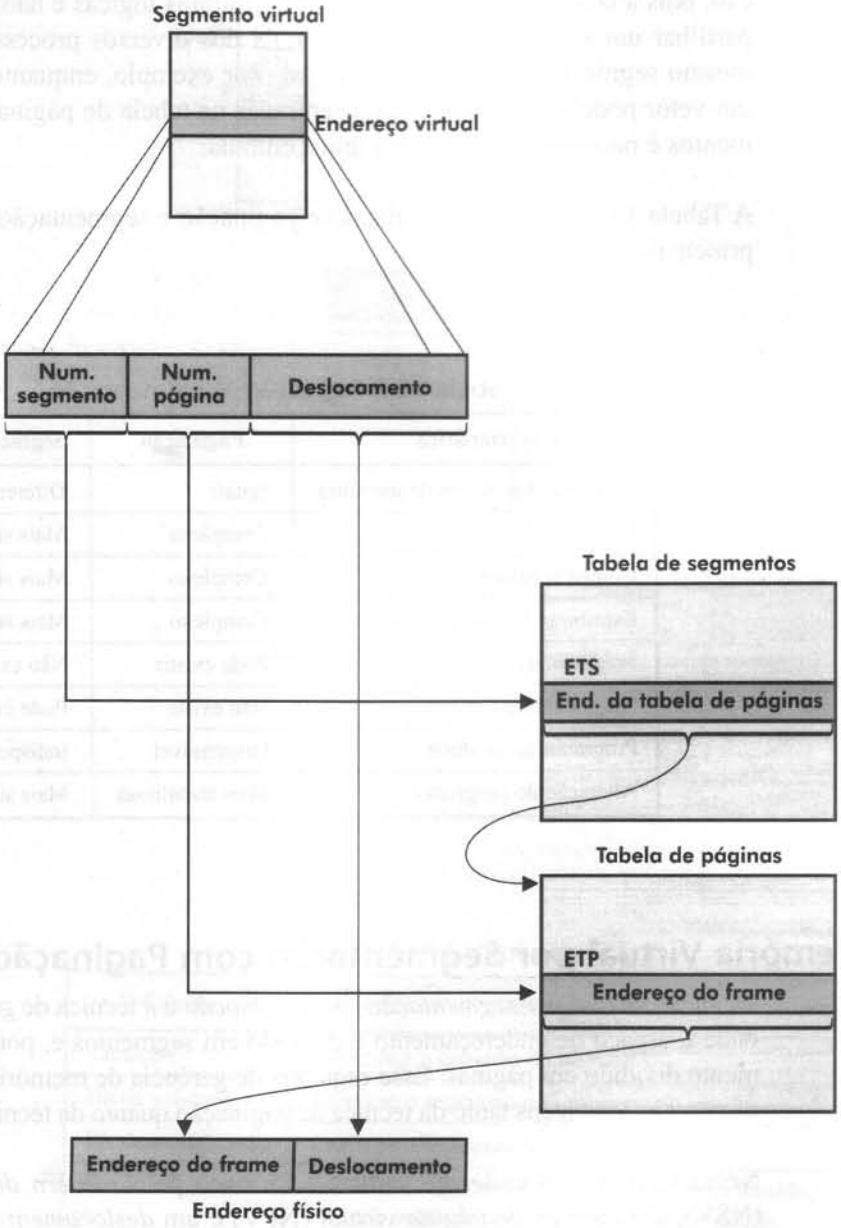

Fig. 10.27 Segmentação com paginação.

to. Dessa forma, um segmento não precisa estar contíguo na memória principal, eliminando o problema da fragmentação externa encontrado na segmentação pura.

10.7 Swapping em Memória Virtual

A técnica de *swapping*, apresentada no capítulo Gerência de Memória, também pode ser aplicada em sistemas com memória virtual, permitindo aumentar o número de processos que compartilham a memória principal e, conseqüentemente, o grau de multiprogramação do sistema.

Quando existem novos processos para serem executados e não há memória principal livre suficiente para alocação, o sistema utiliza o swapping, selecionando um ou mais processos para saírem da memória e oferecer espaço para novos processos. Depois de escolhidos, o sistema retira os processos da memória principal para a memória secundária (*swap out*), onde as páginas ou segmentos são gravados em um *arquivo de swap* (*swap file*). Com os processos salvos na memória secundária, os frames ou segmentos alocados são liberados para novos processos. Posteriormente, os processos que foram retirados da memória devem retornar para a memória principal (*swap in*) para serem novamente executados (Fig. 10.28).

Há várias políticas que podem ser aplicadas na escolha dos processos que devem ser retirados da memória principal. Independente do algoritmo utilizado, o sistema tenta selecionar os processos com as menores chances de serem executados em um futuro próximo. Na maioria das políticas, o critério de escolha considera o estado do processo e sua prioridade.

O swapping com base no estado dos processos seleciona, inicialmente, os processos que estão no estado de espera. A seleção pode ser refinada em função do tipo de espera de cada processo. É possível que não existam processos suficientes no estado de espera para atender as necessidades de memória do sistema. Nesse caso, os processos no estado de pronto com menor prioridade deverão ser selecionados.

O arquivo de swap é compartilhado por todos os processos que estão sendo executados no ambiente. Quando um processo é criado, o sistema reserva um espaço no arquivo de swap para o processo. Da mesma forma, quando um processo é eliminado o sistema libera a área alocada. Em alguns sistemas operacionais, o arquivo de swap é, na verdade, uma área em disco reservada exclusivamente para esta função. Independentemente da implementação, o arquivo de swap deve oferecer o melhor desempenho possível para as operações de swapping.

10.8 Thrashing

Thrashing pode ser definido como sendo a excessiva transferência de páginas/segmentos entre a memória principal e memória secundária. Esse problema está presente em sistemas que implementam tanto paginação como segmentação.

Na memória virtual por paginação, o thrashing ocorre em dois níveis: no do próprio processo e no do sistema. No nível do processo, a excessiva paginação ocorre devido ao elevado número de page faults gerado pelo programa em execução. Esse problema faz com que o processo passe mais tempo esperando por páginas que real-

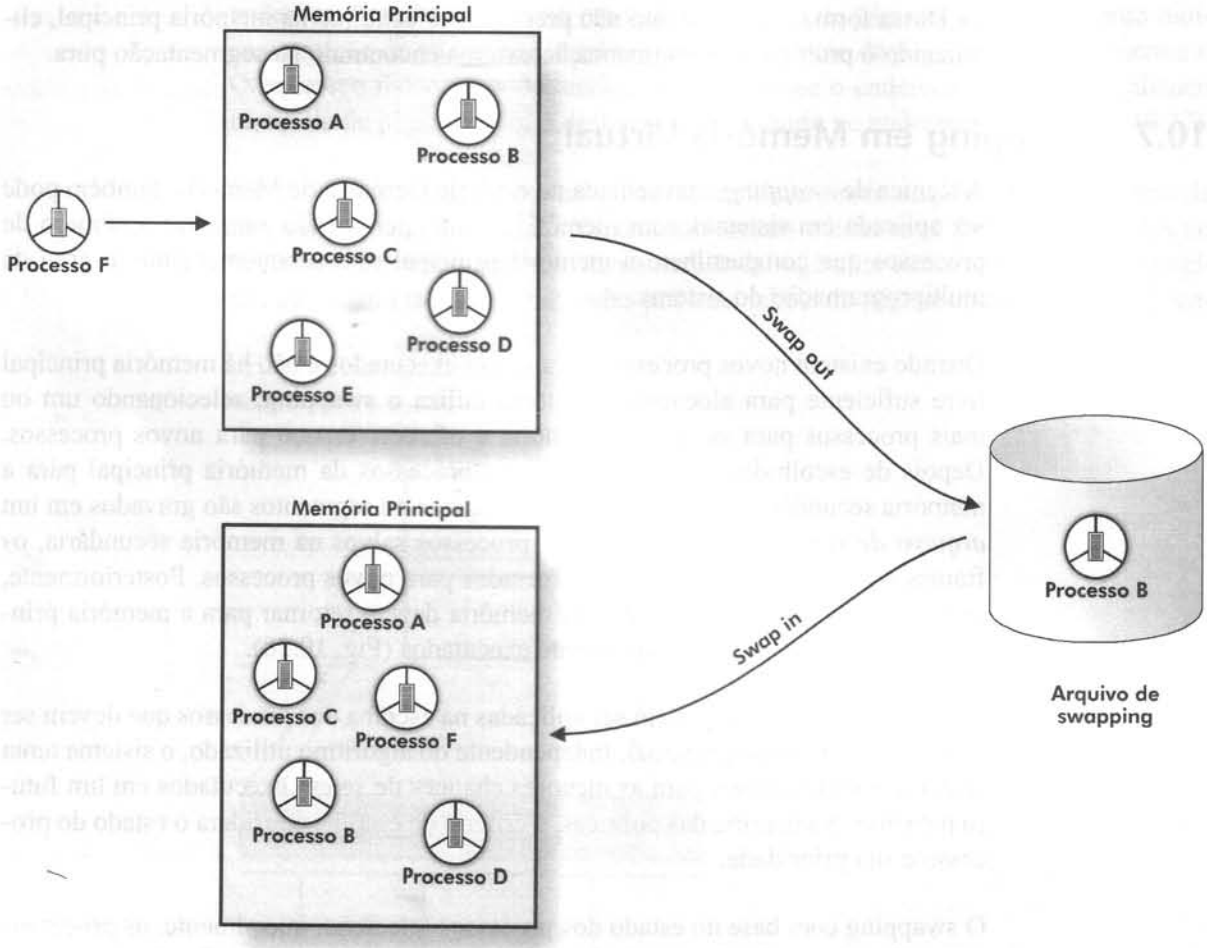

Fig. 10.28 Swapping em memória virtual.

mente sendo executado. Existem dois motivos que levam um processo a sofrer esse tipo de thrashing. O primeiro é o mau dimensionamento do limite máximo de páginas do processo, pequeno demais para acomodar seu working set. O segundo é a ausência do princípio da localidade.

O thrashing no sistema ocorre quando existem mais processos competindo por memória principal que espaço disponível. Nesse caso, o primeiro passo é a redução do número de páginas de cada processo na memória; porém, como já analisamos, esse mecanismo leva ao thrashing do processo. Caso a redução não seja suficiente, o sistema inicia o swapping, retirando processos da memória principal para a memória secundária. Se esse mecanismo for levado ao extremo, o sistema passará mais tempo realizando swapping que atendendo aos processos.

O thrashing em sistemas que implementam segmentação também ocorre em dois níveis. No nível do processo, a transferência excessiva de segmentos é devida à modularização extrema do programa. O thrashing no sistema é semelhante ao da paginação, com a ocorrência de swapping de processos para liberar memória para os demais.

Independentemente das soluções apresentadas, se existirem mais processos para serem executados que memória real disponível, a única solução é a expansão da memória principal. É importante ressaltar que este problema não ocorre apenas em sistemas que implementam memória virtual, mas também em sistemas com outros mecanismos de gerência de memória.

10.9 Exercícios

1. Quais os benefícios oferecidos pela técnica de memória virtual? Como este conceito permite que um programa e seus dados ultrapassem os limites da memória principal?
2. Explique como um endereço virtual de um processo é traduzido para um endereço real na memória principal?
3. Por que o mapeamento deve ser feito em blocos e não sobre células individuais? Apresente um exemplo numérico.
4. Qual a principal diferença entre os sistemas que implementam paginação e os que implementam segmentação?
5. Diferencie página virtual de página real.
6. O que são tabelas de páginas e tabelas de segmentos?
7. Para que serve o bit de validade nas tabelas de páginas e segmentos?
8. O que é um page fault, quando ocorre e quem controla a sua ocorrência? Como uma elevada taxa de page fault pode comprometer o sistema operacional?
9. Nos sistemas com paginação, a rotina para tratamento de page faults está residente na memória principal. Esta rotina pode ser removida da memória em algum momento? O que aconteceria se esta rotina não estivesse na memória principal durante a ocorrência de um page fault?
10. Descreva como ocorre a fragmentação interna em um sistema que implementa paginação.
11. Compare as políticas de busca de páginas apresentadas.
12. Quais as vantagens e desvantagens da política de alocação de páginas variável comparada à alocação fixa?
13. Um sistema com gerência de memória virtual por paginação possui tamanho de página com 512 posições, espaço de endereçamento virtual com 512 páginas endereçadas de 0 a 511 e memória real com 10 páginas numeradas de 0 a 9. O conteúdo atual da memória real contém apenas informações de um único processo e é descrito resumidamente na tabela abaixo:

Endereço Físico	Conteúdo
1536	Página Virtual 34
2048	Página Virtual 9
3072	Tabela de Páginas
3584	Página Virtual 65
4608	Página Virtual 10

a) Considere que a entrada da tabela de páginas contém, além do endereço do frame, o número da página virtual. Mostre o conteúdo da tabela de páginas deste processo.

b) Mostre o conteúdo da tabela de páginas após a página virtual 49 ser carregada na memória a partir do endereço real 0 e a página virtual 34 ser substituída pela página virtual 12.
c) Como é o formato do endereço virtual deste sistema?
d) Qual endereço físico está associado ao endereço virtual 4613?

14. Um sistema operacional implementa gerência de memória virtual por paginação, com frames de 2 Kb. A partir da tabela abaixo, que representa o mapeamento de páginas de um processo em um determinado instante de tempo, responda:

Página	Residente	Frame
0	Sim	20
1	Sim	40
2	Sim	100
3	Sim	10
4	Não	50
5	Não	70
6	Sim	1000

a) Qual o endereço físico de uma variável que ocupa o último byte da página 3?
b) Qual o endereço físico de uma variável que ocupa o primeiro byte da página 2?
c) Qual o endereço físico de uma variável que tem deslocamento 10 na página 3?
d) Quais páginas do processo estão na memória?

15. Um sistema operacional implementa gerência de memória virtual por paginação. Considere endereços virtuais com 16 bits, referenciados por um mesmo processo durante sua execução e sua tabela de páginas abaixo com no máximo 256 entradas. Estão representadas apenas as páginas presentes na memória real. Indique para cada endereço virtual a seguir a página virtual em que o endereço se encontra, o respectivo deslocamento e se a página se encontra na memória principal neste momento.
a) $(307)_{10}$
b) $(2049)_{10}$
c) $(2304)_{10}$

Página	Endereço Físico
0	8 K
1	4 K
2	24 K
3	0 K
4	16 K
5	12 K
9	20 K
11	28 K

16. Uma memória virtual possui páginas de 1024 endereços, existem 8 páginas virtuais e 4096 bytes de memória real. A tabela de páginas de um processo está descrita abaixo. O asterisco indica que a página não está na memória principal:

Página Virtual	Página Real
0	3
1	1
2	*
3	*
4	2
5	*
6	0
7	*

a) Faça a lista/faixa de todos os endereços virtuais que irão causar page fault.
b) Indique o endereço real correspondente aos seguintes endereços virtuais 0, 1023, 1024, 6500 e 3728.

17. Por que existe a necessidade de uma política de substituição de páginas? Compare as políticas de substituição local e global.
18. Para que serve o bit de modificação nas tabelas de páginas e segmentos?
19. Como o princípio da localidade viabiliza a implementação da gerência de memória virtual por paginação?
20. Por que programas não estruturados estão sujeitos a uma alta taxa de paginação?
21. Descreva os algoritmos de substituição de páginas FIFO e LRU, apresentando vantagens e desvantagens.
22. Considere um sistema com memória virtual por paginação com endereço virtual com 24 bits e página com 2048 endereços. Na tabela de páginas a seguir, de um processo em determinado instante de tempo, o bit de validade 1 indica página na memória principal e o bit de modificação 1 indica que a página sofreu alteração.

Página	BV	BM	End. do Frame
0	1	1	30.720
1	1	0	0
2	1	1	10.240
3	0	1	*
4	0	0	*
5	1	0	6.144

a) Quantos bits possui o campo deslocamento do endereço virtual?
b) Qual o número máximo de entradas que a tabela de páginas pode ter?
c) Qual o endereço físico que ocupa o último endereço da página 2?
d) Qual o endereço físico traduzido do endereço virtual $(00080A)_{16}$?
e) Caso ocorra um page fault e uma das páginas do processo deva ser descartada, quais páginas poderiam sofrer page out?

23. Considere um sistema de memória virtual que implemente paginação, onde o limite de frames por processo é igual a três. Descreva para os itens abaixo, onde é apresentada uma seqüência de referências a páginas pelo processo, o número total de page faults para as estratégias de realocação de páginas FIFO e LRU. Indique qual a mais eficaz para cada item.
    a) 1 / 2 / 3 / 1 / 4 / 2 / 5 / 3 / 4 / 3
    b) 1 / 2 / 3 / 1 / 4 / 1 / 3 / 2 / 3 / 3
24. Em um sistema de memória virtual que implementa paginação, as páginas têm 4 K endereços, a memória principal possui 32 Kb e o limite de páginas na memória principal é de 8 páginas. Um programa faz referência a endereços virtuais situados nas páginas 0, 2, 1, 9, 11, 4, 5, 2, 3, 1, nesta ordem. Após essa seqüência de acessos, a tabela de páginas completa desse programa tem a configuração abaixo. As entradas em branco correspondem a páginas ausentes.

Página	End. Físico
0	8 K
1	4 K
2	24 K
3	0 K
4	16 K
5	12 K
6	*
7	*
8	*
9	20 K
10	*
11	28 K
12	*
13	*
14	*
15	*

    a) Qual o tamanho (em bits) e o formato do endereço virtual?
    b) O processo faz novas referências a endereços virtuais situados nas páginas 5, 15, 12, 8 e 0, nesta ordem. Complete o quadro a seguir, que ilustra o processamento dessa seqüência de acessos utilizando a estratégia de remoção FIFO. Mostre o estado final da tabela de páginas.

Página Referenciada	Página Removida	Page Fault (sim/não)
5		
15		
12		
8		
0		

25. Em um computador, o endereço virtual é de 16 bits e as páginas têm tamanho de 2 K endereços. O limite de páginas reais de um processo qualquer é de quatro páginas. Inicialmente, nenhuma página está na memória principal. Um programa faz referência a endereços virtuais situados nas páginas 0, 7, 2, 7, 5, 8, 9, 2 e 4, nesta ordem.
    a) Quantos bits do endereço virtual destinam-se ao número da página? E ao deslocamento?
    b) Ilustre o comportamento da política de substituição LRU mostrando, a cada referência, quais páginas estão em memória, os page faults causados e as páginas escolhidas para descarte.
26. Um sistema trabalha com gerência de memória virtual por paginação. Para todos os processos do sistema, o limite de páginas na memória principal é igual a 10. Considere um processo que esteja executando um programa e em um determinado instante de tempo (T) a sua tabela de páginas possui o conteúdo a seguir. O bit de validade igual a 1 indica página na memória principal e o bit de modificação igual a 1 indica que a página sofreu alteração.

Número da Página	BV	BM	Endereço do Frame (hexadecimal)
0	1	0	3303A5
1	1	0	AA3200
2	1	0	111111
3	1	1	BFDCCA
4	1	0	765BFC
5	1	0	654546
6	1	1	B6B7B0
7	1	1	999950
8	1	0	888BB8
9	0	0	N/A
10	0	0	N/A

Responda às perguntas abaixo, considerando que os seguintes eventos ocorrerão nos instantes de tempo indicados:

(T + 1) O processo referencia um endereço na página 9 com page fault.
(T + 2) O processo referencia um endereço na página 1.
(T + 3) O processo referencia um endereço na página 10 com page fault.
(T + 4) O processo referencia um endereço da página 3 com page fault.
(T + 5) O processo referencia um endereço da página 6 com page fault.

a) Em quais instantes de tempo ocorrem um page out?
b) Em que instante de tempo o limite de páginas do processo na memória principal é atingido?
c) Caso a política de realocação de páginas utilizada seja FIFO, no instante (T + 1), qual a página que está há mais tempo na memória principal?
d) Como o sistema identifica que no instante de tempo (T + 2) não há ocorrência de page fault?

27. Um sistema possui quatro frames. A tabela abaixo apresenta para cada página o momento da carga, o momento do último acesso, o bit de referência e o bit de modificação (Tanenbaum, 1992).

Frame	Carga	Referência	BR	BM
0	126	279	0	0
1	230	260	1	0
2	120	272	1	1
3	160	280	1	1

a) Qual página será substituída utilizando o algoritmo NRU?
b) Qual página será substituída utilizando o algoritmo FIFO?
c) Qual página será substituída utilizando o algoritmo LRU?

28. Considere um processo com limite de páginas reais igual a quatro e um sistema que implemente a política de substituição de páginas FIFO. Quantos page faults ocorrerão considerando que as páginas virtuais são referenciadas na seguinte ordem: 0172327103. Repita o problema utilizando a política LRU.
29. Os sistemas operacionais OpenVMS e Windows NT/2000 utilizam dois buffers de páginas: um buffer de páginas livres e outro para páginas modificadas. Qual a vantagem de implementar um buffer de páginas modificadas?
30. Explique por que páginas pequenas podem aumentar a taxa de paginação.
31. A arquitetura VAX-11 utiliza 32 bits para endereçamento e páginas de 512 bytes. Calcule o número de bits para cada parte do endereço virtual, sabendo que o espaço de endereçamento é dividido em quatro partes: P0, P1, S0 e S1, sendo que cada uma possui sua própria tabela de páginas.
32. Um sistema computacional com espaço de endereçamento de 32 bits utiliza uma tabela de páginas de dois níveis. Os endereços virtuais são divididos em um campo de 9 bits para o primeiro nível da tabela, outro de 11 bits para o segundo nível, e um último campo para o deslocamento. Qual o tamanho das páginas? Quantas páginas podem existir no espaço de endereçamento virtual (Tanenbaum, 1992)?
33. Na arquitetura SPARC, o espaço de endereçamento virtual de 4 G pode ser dividido para cada processo em páginas de 4 Kb. A busca do endereço real correspondente ao endereço virtual gerado pelo processador envolve, em caso de

falha na TLB, três níveis de acesso à memória principal. No primeiro nível, é feito um acesso a uma tabela única por processo de 256 entradas. Essa tabela gera o endereço de uma das 256 possíveis tabelas de nível 2. Cada tabela de nível 2 possui 64 entradas e, quando acessada, gera o endereço da tabela de nível 3 que deve ser consultada. Essa tabela, que também possui 64 entradas, gera o endereço real procurado. As tabelas de níveis 1, 2 e 3 formam basicamente uma árvore de busca na memória e vão sendo criadas dinamicamente à medida que novas páginas na memória vão sendo alocadas para aquele processo. Qual a vantagem de se ter esse esquema de tabelas em múltiplos níveis, criadas dinamicamente sob demanda, em vez de uma tabela única criada integralmente quando da carga do processo? Justifique sua resposta com um exemplo.

34. Em um sistema computacional, a busca do endereço real correspondente ao endereço virtual gerado pelo processador envolve, em caso de falha na TLB, dois níveis de acesso à memória principal. Supondo que não existe memória cache, que a taxa de falha da TLB é de 2%, que o tempo de acesso à TLB é desprezível e que o tempo de acesso à memória principal é de 100 ns, calcule o tempo médio em acesso à memória gasto no processamento completo de uma instrução de soma de dois operandos. Considere que o primeiro operando é endereçado na memória em modo direto, o segundo operando é endereçado na memória em modo indireto, e o operando destino é um registrador interno do processador.
35. Descreva o mecanismo de tradução de um endereço virtual em um endereço real em sistemas que implementam gerência de memória virtual utilizando segmentação com paginação.
36. Na técnica de swapping que critérios o sistema operacional pode utilizar para selecionar os processos que sofrerão swap out?
37. Existe fragmentação em sistemas que implementam gerência de memória virtual? Se existe, que tipo de fragmentação é encontrado em sistemas com paginação? Que tipo de fragmentação é encontrado em sistemas com segmentação?
38. O que é o thrashing em sistemas que implementam memória virtual?

11

SISTEMA DE ARQUIVOS

11.1 Introdução

O armazenamento e a recuperação de informações é uma atividade essencial para qualquer tipo de aplicação. Um processo deve ser capaz de ler e gravar de forma permanente grande volume de dados em dispositivos como fitas e discos, além de poder compartilhá-los com outros processos. A maneira pela qual o sistema operacional estrutura e organiza estas informações é através da implementação de arquivos.

Os arquivos são gerenciados pelo sistema operacional de maneira a facilitar o acesso dos usuários ao seu conteúdo. A parte do sistema responsável por essa gerência é denominada *sistema de arquivos*. O sistema de arquivos é a parte mais visível de um sistema operacional, pois a manipulação de arquivos é uma atividade freqüentemente realizada pelos usuários, devendo sempre ocorrer de maneira uniforme, independente dos diferentes dispositivos de armazenamento.

Neste capítulo serão apresentados aspectos presentes nos sistemas de arquivos, como identificação, organização, compartilhamento, métodos de acesso, proteção e operações de entrada e de saída.

11.2 Arquivos

Um *arquivo* é constituído por informações logicamente relacionadas. Estas informações podem representar instruções ou dados. Um arquivo executável, por exemplo, contém instruções compreendidas pelo processador, enquanto um arquivo de dados pode ser estruturado livremente como um arquivo texto ou de forma mais rígida como em um banco de dados relacional. Na realidade, um arquivo é um conjunto de registros definidos pelo sistema de arquivos, tornando seu conceito abstrato e generalista. A partir dessa definição, o conteúdo do arquivo pode ser manipulado seguindo conceitos preestabelecidos.

Os arquivos são armazenados pelo sistema operacional em diferentes dispositivos físicos, como fitas magnéticas, discos magnéticos e discos ópticos. O tipo de dispositivo no qual o arquivo é armazenado deve ser isolado pelo sistema operacional, de forma que exista uma independência entre os arquivos a serem manipulados e o meio de armazenamento.

Um arquivo é identificado por um nome, composto por uma seqüência de caracteres. Em alguns sistemas de arquivos é feita distinção entre caracteres alfabéticos maiúsculos e minúsculos. Regras como extensão máxima do nome e quais são os caracteres válidos também podem variar.

Em alguns sistemas operacionais, a identificação de um arquivo é composta por duas partes separadas com um ponto. A parte após o ponto é denominada extensão do arquivo e tem como finalidade identificar o conteúdo do arquivo. Assim é possível convencionar que uma extensão TXT identifica um arquivo texto, enquanto EXE indica um arquivo executável. Na Tabela 11.1 são apresentadas algumas extensões de arquivos.

Tabela 11.1 Extensão de arquivos

Extensão	Descrição
ARQUIVO.BAS	Arquivo fonte em BASIC
ARQUIVO.COB	Arquivo fonte em COBOL
ARQUIVO.EXE	Arquivo executável
ARQUIVO.OBJ	Arquivo objeto
ARQUIVO.PAS	Arquivo fonte em Pascal
ARQUIVO.TXT	Arquivo texto

11.2.1 Organização de Arquivos

A *organização de arquivos* consiste em como os seus dados estão internamente armazenados. A estrutura dos dados pode variar em função do tipo de informação contida no arquivo. Arquivos textos possuem propósitos completamente distintos de arquivos executáveis, conseqüentemente, estruturas diferentes podem adequar-se melhor a um tipo do que a outro.

No momento da criação de um arquivo, seu criador pode definir qual a organização adotada. Esta organização pode ser uma estrutura suportada pelo sistema operacional ou definida pela própria aplicação.

A forma mais simples de organização de arquivos é através de uma seqüência não-estruturada de bytes (Fig. 11.1a). Neste tipo de organização, o sistema de arquivos não impõe nenhuma estrutura lógica para os dados. A aplicação deve definir toda a organização, estando livre para estabelecer seus próprios critérios. A grande vantagem deste modelo é a flexibilidade para criar diferentes estruturas de dados, porém todo o controle de acesso ao arquivo é de inteira responsabilidade da aplicação.

Alguns sistemas operacionais possuem diferentes organizações de arquivos. Neste caso, cada arquivo criado deve seguir um modelo suportado pelo sistema de arquivos. As organizações mais conhecidas e implementadas são a seqüencial, relativa e indexada (Fig 11.1b). Nestes tipos de organização, podemos visualizar um arquivo como um conjunto de registros. Os registros podem ser classificados em registros de tamanho fixo, quando possuírem sempre o mesmo tamanho, ou registros de tamanho variável.

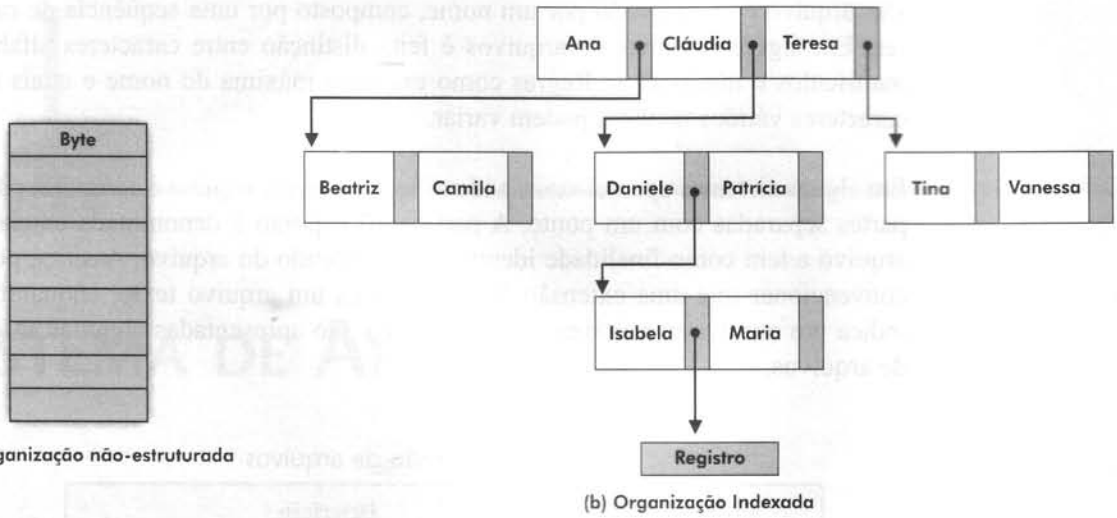

Fig. 11.1 Organização de arquivos.

11.2.2 Métodos de Acesso

Em função de como o arquivo está organizado, o sistema de arquivos pode recuperar registros de diferentes maneiras. Inicialmente, os primeiros sistemas operacionais só armazenavam arquivos em fitas magnéticas. Com isso, o acesso era restrito a leitura dos registros na ordem em que eram gravados, e a gravação de novos registros só era possível no final do arquivo. Este tipo de acesso, chamado de *acesso seqüencial,* era próprio da fita magnética, que, como meio de armazenamento, possuía esta limitação.

Com o advento dos discos magnéticos, foi possível a introdução de métodos de acesso mais eficientes. O primeiro a surgir foi o *acesso direto,* que permite a leitura/gravação de um registro diretamente na sua posição. Este método é realizado através do número do registro, que é a sua posição relativa ao início do arquivo. No acesso direto não existe restrição à ordem em que os registros são lidos ou gravados, sendo sempre necessária a especificação do número do registro. É importante notar que o acesso direto somente é possível quando o arquivo é definido com registros de tamanho fixo (Fig. 11.2).

O acesso direto pode ser combinado com o acesso seqüencial. Com isso é possível acessar diretamente um registro qualquer de um arquivo e, a partir deste, acessar seqüencialmente os demais.

Um método de acesso mais sofisticado, que tem como base o acesso direto, é o chamado *acesso indexado* ou *acesso por chave.* Para este acesso, o arquivo deve possuir uma área de índice onde existam ponteiros para os diversos registros. Sempre que a aplicação desejar acessar um registro, deverá ser especificada uma chave através da qual o sistema pesquisará na área de índice o ponteiro correspondente. A partir desta informação é realizado um acesso direto ao registro desejado.

Fig. 11.2 Acesso direto.

11.2.3 Operações de Entrada/Saída

O sistema de arquivos disponibiliza um conjunto de rotinas que permite às aplicações realizarem operações de E/S, como tradução de nomes em endereços, leitura e gravação de dados e criação/eliminação de arquivos. Na realidade, as rotinas de E/S têm como função disponibilizar uma interface simples e uniforme entre a aplicação e os diversos dipositivos. A Fig. 11.3 ilustra a comunicação entre aplicação e dispositivos de maneira simplificada.

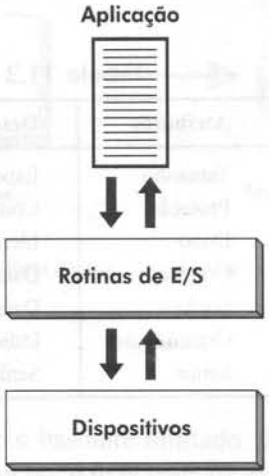

Fig. 11.3 Operações de entrada/saída.

A Tabela 11.2 apresenta algumas destas rotinas encontradas na maioria das implementações de sistemas de arquivos.

Tabela 11.2 Rotinas de entrada/saída

Rotina	Descrição
CREATE	Criação de arquivos.
OPEN	Abertura de um arquivo.
READ	Leitura de um arquivo.
WRITE	Gravação em um arquivo.
CLOSE	Fechamento de um arquivo.
DELETE	Eliminação de um arquivo.

11.2.4 Atributos

Cada arquivo possui informações de controle denominadas *atributos*. Os atributos variam dependendo do sistema de arquivos, porém alguns, como tamanho do arquivo, proteção, identificação do criador e data de criação estão presentes em quase todos os sistemas.

Alguns atributos especificados na criação do arquivo não podem ser modificados em função de sua própria natureza, como organização e data/hora de criação. Outros são alterados pelo próprio sistema operacional, como tamanho e data/hora do último backup realizado. Existem ainda atributos que podem ser modificados pelo próprio usuário, como proteção do arquivo, tamanho máximo e senha de acesso. Na Tabela 11.3 são apresentados os principais atributos presentes nos sistemas de arquivos.

Tabela 11.3 Atributos de arquivos

Atributos	Descrição
Tamanho	Especifica o tamanho do arquivo.
Proteção	Código de proteção de acesso.
Dono	Identifica o criador do arquivo.
Criação	Data e hora de criação do arquivo.
Backup	Data e hora do último backup realizado.
Organização	Indica a organização lógica dos registros.
Senha	Senha necessária para acessar o arquivo.

11.3 Diretórios

A estrutura de *diretórios* é como o sistema organiza logicamente os diversos arquivos contidos em um disco. O diretório é uma estrutura de dados que contém entradas associadas aos arquivos onde cada entrada armazena informações como localização física, nome, organização e demais atributos.

Quando um arquivo é aberto, o sistema operacional procura a sua entrada na estrutura de diretórios, armazenando as informações sobre atributos e localização do arquivo em uma tabela mantida na memória principal. Esta tabela contém todos os arquivos abertos, sendo fundamental para aumentar o desempenho das operações

com arquivos. É importante que ao término do uso de arquivos, este seja fechado, ou seja, que se libere o espaço na tabela de arquivos abertos.

A implementação mais simples de uma estrutura de diretórios é chamado de nível único (single-level directory). Neste caso, somente existe um único diretório contendo todos os arquivos do disco (Fig. 11.4). Este modelo é bastante limitado, já que não permite que usuários criem arquivos com o mesmo nome, o que ocasionaria um conflito no acesso aos arquivos.

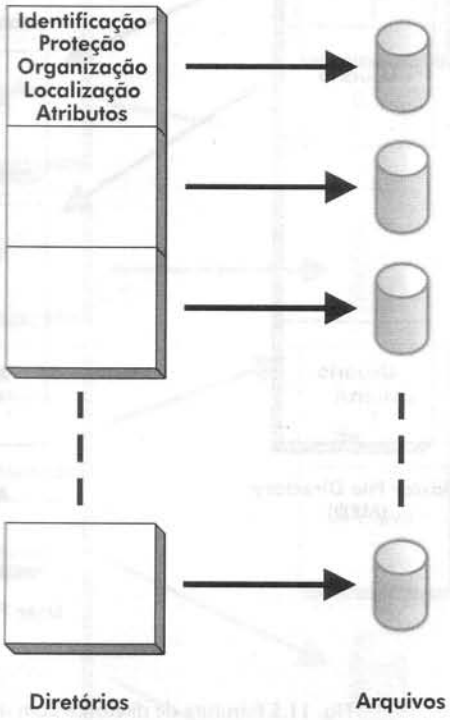

Fig. 11.4 Estrutura de diretórios de nível único.

Como o sistema de nível único é bastante limitado, uma evolução do modelo foi a implementação de uma estrutura onde para cada usuário existiria um diretório particular denominado User File Directory (UFD). Com esta implementação, cada usuário passa a poder criar arquivos com qualquer nome, sem a preocupação de conhecer os demais arquivos do disco.

Para que o sistema possa localizar arquivos nessa estrutura, deve haver um nível de diretório adicional para controlar os diretórios individuais dos usuários. Este nível, denominado Master File Directory (MFD), é indexado pelo nome do usuário, onde cada entrada aponta para o diretório pessoal. A Fig. 11.5 ilustra este modelo de estrutura de diretórios com dois níveis (two-level directory).

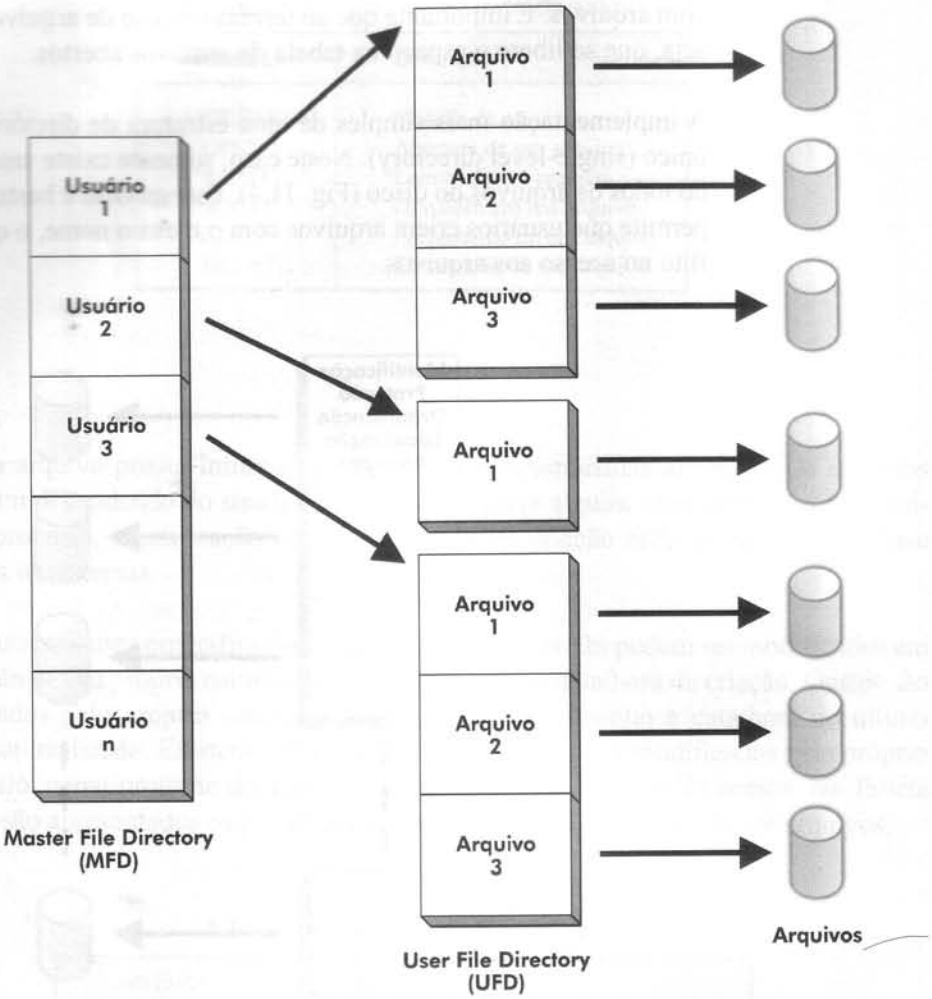

Fig. 11.5 Estrutura de diretórios com dois níveis.

A estrutura de diretórios com dois níveis é análoga a uma estrutura de dados em árvore, onde o MFD é a raiz, os galhos são os UFD e os arquivos são as folhas. Neste tipo de estrutura, quando se referencia um arquivo, é necessário especificar, além do seu nome, o diretório onde se localiza. Esta referência é chamada de path (caminho). Como exemplo, caso o usuário CARLOS necessite acessar um arquivo próprio chamado DOCUMENTO.TXT, este pode ser referenciado como /CARLOS/DOCUMENTO.TXT. Cada sistema de arquivos possui sua própria sintaxe para especificação de diretórios e arquivos.

Sob o ponto de vista do usuário, a organização dos seus arquivos em um único diretório não permite uma organização adequada. A extensão do modelo de dois níveis para um de múltiplos níveis permitiu que os arquivos fossem logicamente melhor organizados. Este novo modelo, chamado estrutura de diretórios, em árvore (tree-structured directory), é adotado pela maioria dos sistemas (Fig. 11.6).

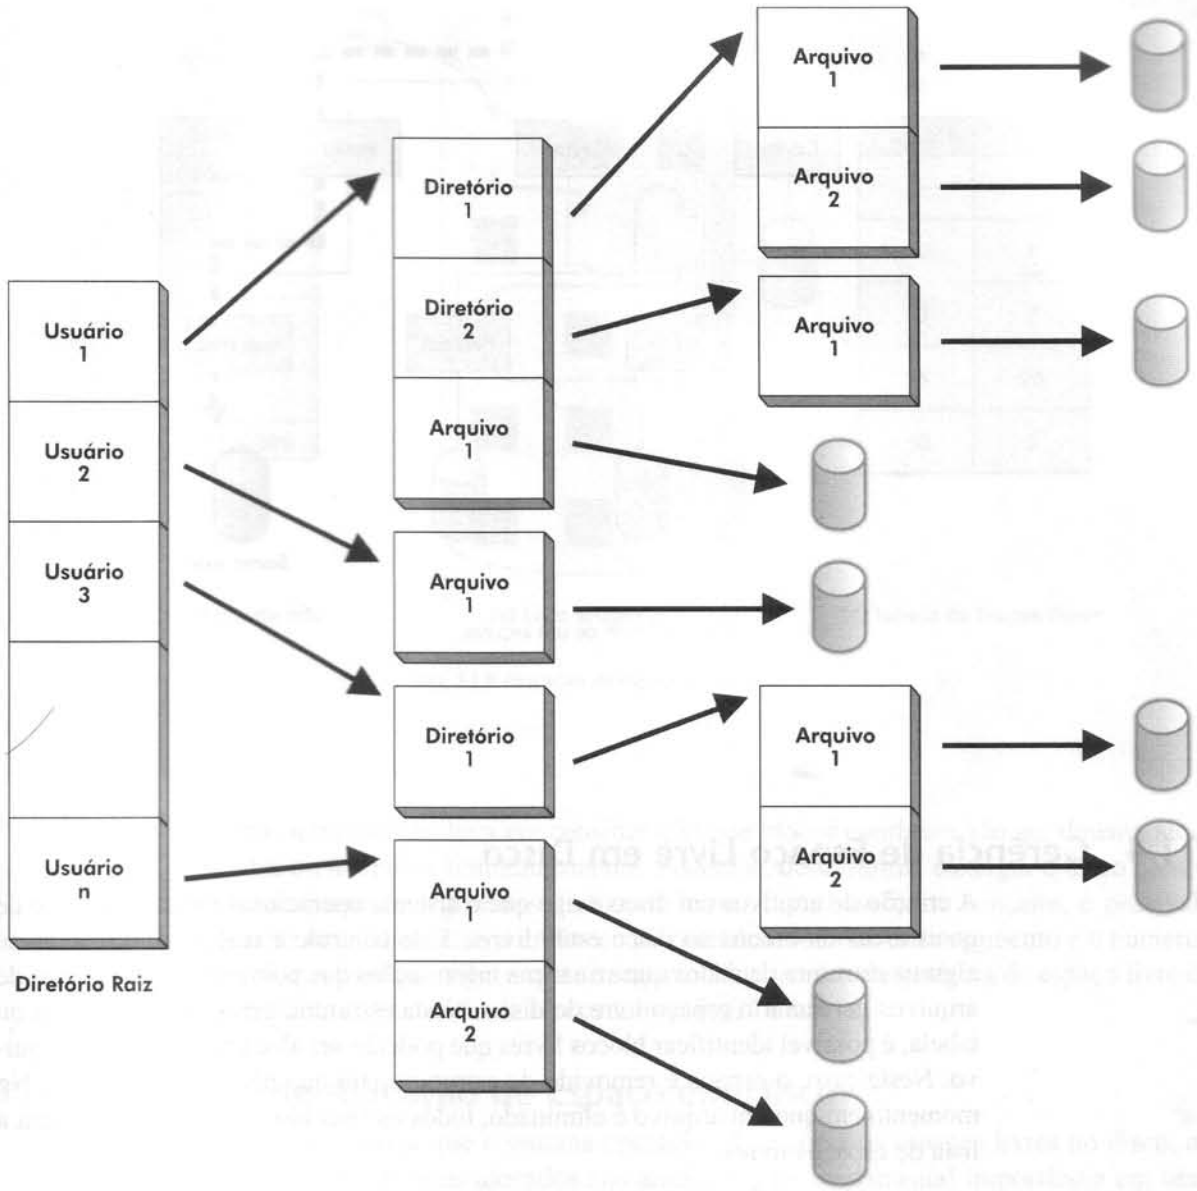

Fig. 11.6 Estrutura de diretórios em árvore.

Na estrutura em árvore, cada usuário pode criar diversos níveis de diretórios, também chamados subdiretórios. Cada diretório pode conter arquivos ou outros diretórios. O número de níveis de uma estrutura em árvore é dependente do sistema de arquivos de cada sistema operacional. No Open VMS são possíveis oito níveis de diretórios.

Um arquivo, nesta estrutura em árvore, pode ser especificado unicamente através de um path absoluto, descrevendo todos os diretórios percorridos a partir da raiz (MFD) até o diretório no qual o arquivo está ligado. Na Fig. 11.7, o path absoluto do arquivo SOMA.EXE é /PAULO/PROGRAMAS. Na maioria dos sistemas, os diretórios também são tratados como arquivos, possuindo identificação e atributos, como proteção, identificador do criador e data de criação.

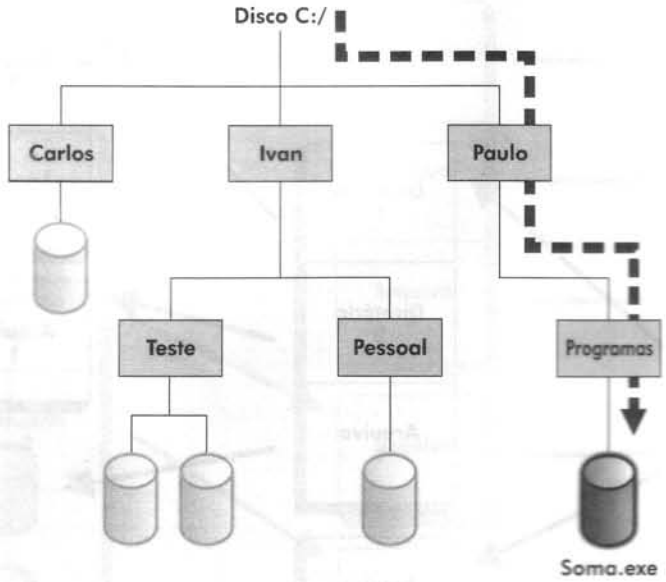

Fig. 11.7 Path de um arquivo.

11.4 Gerência de Espaço Livre em Disco

A criação de arquivos em disco exige que o sistema operacional tenha o controle de quais áreas ou blocos no disco estão livres. Este controle é realizado utilizando-se alguma estrutura de dados que armazena informações que possibilitam ao sistema de arquivos gerenciar o espaço livre do disco. Nesta estrutura, geralmente uma lista ou tabela, é possível identificar blocos livres que poderão ser alocados a um novo arquivo. Neste caso, o espaço é removido da estrutura para que não seja reutilizado. No momento em que um arquivo é eliminado, todos os seus blocos são liberados para a lista de espaços livres.

A forma mais simples de implementar uma estrutura de espaços livres é através de uma tabela denominada mapa de bits (bit map). Cada entrada na tabela é associada a um bloco do disco representado por um bit, podendo assumir valor igual a 0 (indicando bloco livre) ou 1 (indicando bloco alocado). Na Fig. 11.8a podemos observar um exemplo desta implementação que apresenta como principal problema um excessivo gasto de memória, já que para cada bloco do disco deve existir uma entrada na tabela.

Uma segunda maneira de realizar este controle é com uma estrutura de lista encadeada de todos os blocos livres do disco. Para que isto seja possível, cada bloco possui uma área reservada para armazenamento do endereço do próximo bloco. A partir do primeiro bloco livre é, então, possível o acesso seqüencial aos demais de forma encadeada (Fig. 11.8b). Este esquema apresenta algumas restrições se considerarmos que, além do espaço utilizado no bloco com informação de controle, o algoritmo de busca de espaço livre sempre deve realizar uma pesquisa seqüencial na lista.

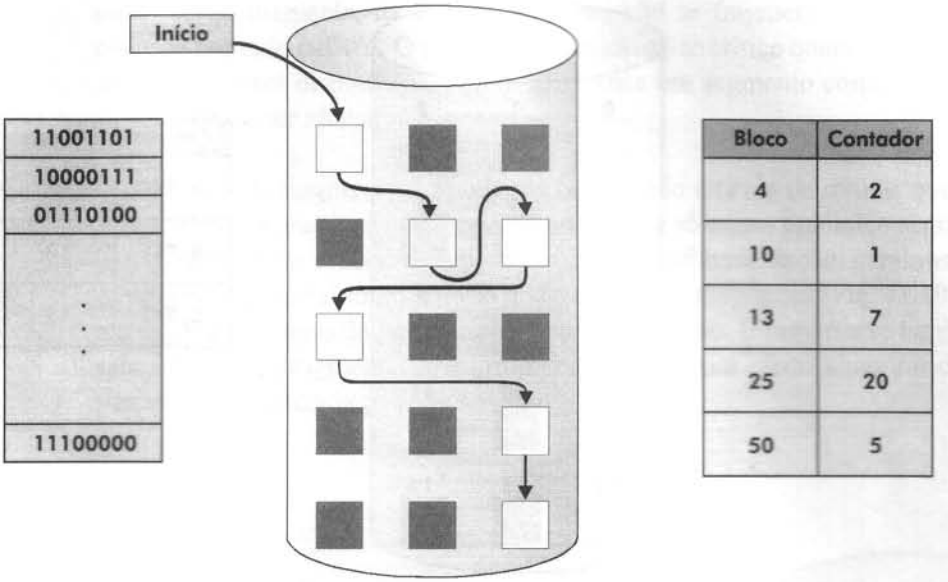

(a) Mapa de bits (b) Lista encadeada (c) Tabela de blocos livres

Fig. 11.8 Alocação de espaço em disco.

Uma outra solução leva em consideração que blocos contíguos são geralmente alocados ou liberados simultaneamente. Podemos, desta forma, enxergar o disco como um conjunto de segmentos de blocos livres. Com base neste conceito, é possível manter uma tabela com o endereço do primeiro bloco de cada segmento e o número de blocos livres contíguos que se seguem. Esta técnica de gerência de espaço livre é conhecida como tabela de blocos livres (Fig. 11.8c).

11.5 Gerência de Alocação de Espaço em Disco

Da mesma forma que o sistema operacional gerencia os espaços livres no disco, a gerência dos espaços alocados aos arquivos é de fundamental importância em um sistema de arquivos. A seguir, as principais técnicas de alocação serão apresentadas.

11.5.1 Alocação Contígua

A *alocação contígua* consiste em armazenar um arquivo em blocos seqüencialmente dispostos no disco. Neste tipo de alocação, o sistema localiza um arquivo através do endereço do primeiro bloco e da sua extensão em blocos (Fig. 11.9).

O acesso a arquivos dispostos contiguamente no disco é bastante simples tanto para a forma seqüencial quanto para a direta. Seu principal problema é a alocação de espaço livre para novos arquivos. Caso um arquivo deva ser criado com determinado tamanho, é necessário existir uma quantidade suficiente de blocos contíguos no disco para realizar a alocação.

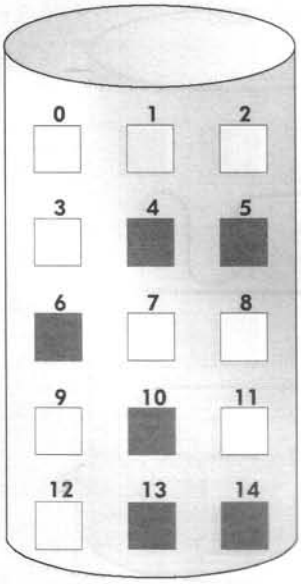

Arquivo	Bloco	Extensão
A. TXT	4	3
B. TXT	10	1
C. TXT	13	2

Fig. 11.9 Alocação contígua.

Para este tipo de alocação, podemos enxergar o disco como um grande vetor, onde os elementos podem ser considerados segmentos com tamanhos diferentes de blocos contíguos. Estes segmentos estão dispostos alternadamente entre segmentos ocupados (blocos alocados) e segmentos livres (blocos livres). No momento em que o sistema operacional deseja alocar espaço para armazenar um novo arquivo, pode existir mais de um segmento livre disponível com o tamanho exigido. Neste caso, é necessário que alguma estratégia de alocação seja adotada para selecionar qual o segmento na lista de blocos livres deve ser escolhido. Analisaremos a seguir as principais estratégias:

- First-fit

  Neste caso, o primeiro segmento livre com tamanho suficiente para alocar o arquivo é selecionado. A busca na lista é seqüencial, sendo interrompida tão logo se localize um segmento com tamanho adequado.

- Best-fit

  A alocação best-fit seleciona o menor segmento livre disponível com tamanho suficiente para armazenar o arquivo. A busca em toda lista se faz necessária para a seleção do segmento, a não ser que a lista esteja ordenada por tamanho.

- Worst-fit

  Neste caso, o maior segmento é alocado. Mais uma vez a busca em toda lista se faz necessária, a menos que exista uma ordenação por tamanho.

Independente da estratégia utilizada, a alocação contígua apresenta um problema chamado fragmentação dos espaços livres. Como os arquivos são criados e elimi-

nados freqüentemente, os segmentos livres vão se fragmentando em pequenos pedaços por todo o disco. O problema pode tornar-se crítico quando um disco possui blocos livres disponíveis, porém não existe um segmento contíguo em que o arquivo possa ser alocado.

O problema da fragmentação pode ser contornado através de rotinas que reorganizem todos os arquivos no disco de maneira que só exista um único segmento de blocos livres. Este procedimento, denominado desfragmentação, geralmente utiliza uma área de trabalho no próprio disco ou em fita magnética (Fig. 11.10). Existe um grande consumo de tempo neste tipo de operação. É importante também ressaltar que a desfragmentação é um procedimento com efeito temporário e deve, portanto, ser realizada periodicamente.

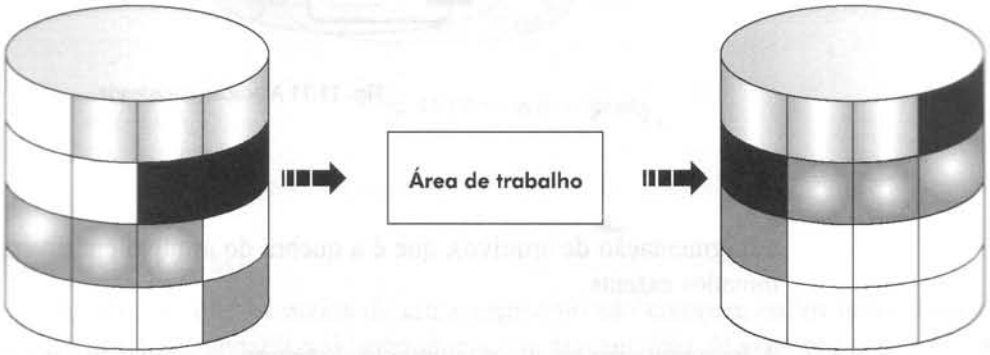

Fig. 11.10 Desfragmentação.

Podemos concluir que a alocação contígua apresenta alguns inconvenientes, sendo o principal problema a determinação do espaço em disco necessário a um arquivo. Nem sempre, no momento da criação de um arquivo, é possível determinar qual o seu tamanho em definitivo, podendo posteriormente existir a necessidade de extensão. Por esta operação ser complexa na alocação contígua, a pré-alocação de espaço é uma solução que, apesar de resolver o problema, pode ocasionar que parte do espaço alocado permaneça ocioso por um longo período de tempo.

11.5.2 Alocação Encadeada

Na *alocação encadeada,* um arquivo pode ser organizado como um conjunto de blocos ligados logicamente no disco, independente da sua localização física. Cada bloco deve possuir um ponteiro para o bloco seguinte do arquivo e assim sucessivamente (Fig. 11.11).

A fragmentação dos espaços livres, apresentado no método anterior, não ocasiona nenhum problema na alocação encadeada, pois os blocos livres alocados para um arquivo não precisam necessariamente estar contíguos. O que ocorre neste método é

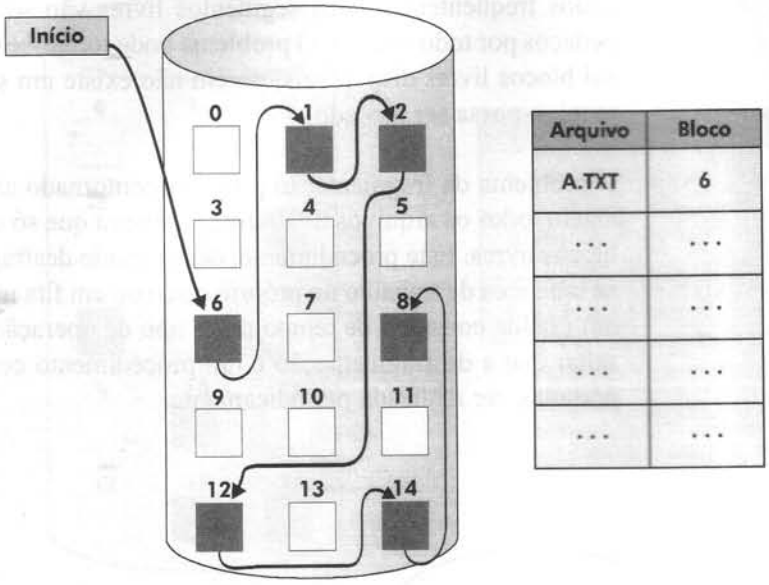

Fig. 11.11 Alocação encadeada.

a fragmentação de arquivos, que é a quebra do arquivo em diversos pedaços denominados extents.

A fragmentação resulta no aumento do tempo de acesso aos arquivos, pois o mecanismo de leitura/gravação do disco deve se deslocar diversas vezes sobre sua superfície para acessar cada extent (excessivo tempo de seek). Para otimizar o tempo das operações de E/S neste tipo de sistema, é importante que o disco seja periodicamente desfragmentado. Apesar de ter propósitos diferentes, o procedimento de desfragmentação é idêntico ao já apresentado na alocação contígua.

A alocação encadeada só permite que se realize acesso seqüencial aos blocos dos arquivos. Isto constitui uma das principais desvantagens desta técnica, já que não é possível o acesso direto aos blocos. Além disso, essa técnica desperdiça espaço nos blocos com o armazenamento de ponteiros.

11.5.3 Alocação Indexada

A *alocação indexada* soluciona uma das principais limitações da alocação encadeada, que é a impossibilidade do acesso direto aos blocos dos arquivos. O princípio desta técnica é manter os ponteiros de todos os blocos do arquivo em uma única estrutura denominada bloco de índice.

A alocação indexada, além de permitir o acesso direto aos blocos do arquivo, não utiliza informações de controle nos blocos de dados, como existente na alocação encadeada (Fig. 11.12).

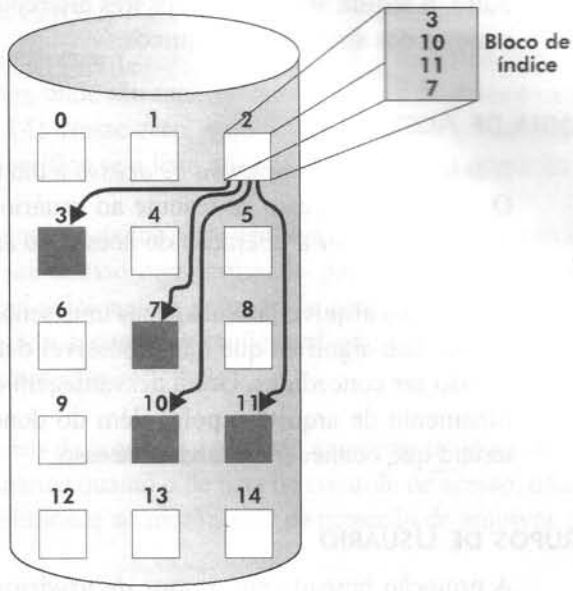

Fig. 11.12 Alocação indexada.

11.6 Proteção de Acesso

Considerando que os meios de armazenamento são compartilhados entre diversos usuários, é de fundamental importância que mecanismos de proteção sejam implementados para garantir a proteção individual de arquivos e diretórios. Qualquer sistema de arquivos deve possuir mecanismos próprios para proteger o acesso às informações gravadas em discos e fitas, além de possibilitar o compartilhamento de arquivos entre usuários, quando desejado.

Em geral, o tipo de acesso a arquivos é implementado mediante a concessão ou não dos diferentes acessos que podem ser realizados, como leitura (read), gravação (write), execução (execute) e eliminação (delete). O acesso de leitura está relacionado com qualquer tipo de operação em que o arquivo possa ser visualizado, como a exibição do seu conteúdo, edição através de um editor de textos ou até mesmo a cópia para criação de um novo arquivo. O acesso de gravação está relacionado à alteração no conteúdo do arquivo, como inclusão ou alteração de registros. O acesso de execução só tem sentido quando associado a arquivos executáveis ou arquivos de comandos, indicando o direito de execução do arquivo. Finalmente, o acesso de eliminação expressa a permissão para eliminação do arquivo.

O controle de acesso às operações realizadas com diretórios possui diferenças em relação às operações com arquivos. Controle da criação/eliminação de arquivos nos diretórios, visualização do seu conteúdo e eliminação do próprio diretório são operações que também devem ser protegidas.

Existem diferentes mecanismos e níveis de proteção, cada qual com suas vantagens e desvantagens — para cada tipo de sistema, um modelo é mais adequado do que

outro. A seguir, apresentaremos três diferentes mecanismos de proteção, presentes na maioria dos sistemas de arquivos.

11.6.1 Senha de Acesso

A associação de uma *senha de acesso* a um arquivo é um princípio bastante simples. O controle de acesso se resume ao usuário ter o conhecimento da senha e, conseqüentemente, ter a liberação do acesso ao arquivo concedida pelo sistema.

Como cada arquivo possui apenas uma senha, o acesso é liberado ou não na sua totalidade. Isto significa que não é possível determinar quais tipos de operação podem ou não ser concedidas. Outra desvantagem deste método é a dificuldade de compartilhamento de arquivos, pois, além do dono do arquivo, todos os demais usuários teriam que conhecer a senha de acesso.

11.6.2 Grupos de Usuário

A proteção baseada em *grupos de usuários* é implementada por diversos sistemas operacionais. Este tipo de proteção tem como princípio a associação de cada usuário do sistema a um grupo. Os grupos de usuários são organizados logicamente com o objetivo de compartilhar arquivos e diretórios — os usuários que desejam compartilhar arquivos entre si devem pertencer a um mesmo grupo.

Esse mecanismo implementa três níveis de proteção ao arquivo: owner (dono), group (grupo) e all (todos). Na criação do arquivo, o usuário especifica se o arquivo deve ser acessado somente pelo seu criador, pelos usuários do grupo ao qual ele pertence ou por todos os usuários do sistema. Nessa especificação é necessário associar o tipo de acesso (leitura, escrita, execução e eliminação) aos três níveis de proteção.

Vejamos um exemplo na Fig. 11.13, onde a proteção do arquivo DADOS.TXT libera completamente o acesso para o dono, permite somente o compartilhamento para leitura dentro do grupo e não libera qualquer tipo de acesso para os demais usuários do sistema. Em geral, somente o dono ou usuários privilegiados é que podem modificar a proteção dos arquivos.

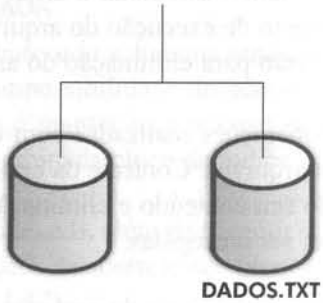

Nível de Proteção	Tipo de Acesso
Owner	Leitura Escrita Execução Eliminação
Group	Leitura
All	—

Fig. 11.13 Proteção por grupos de usuários.

11.6.3 Lista de Controle de Acesso

A *Lista de Controle de Acesso* (*Access Control List* – ACL) consiste em uma lista associada a cada arquivo, onde são especificados quais os usuários e os tipos de acesso permitidos (Fig. 11.14). Nesse caso, quando um usuário tenta acessar um arquivo, o sistema operacional verifica se a lista de controle autoriza a operação desejada.

O tamanho dessa estrutura de dados pode ser bastante extenso se considerarmos que um arquivo pode ter seu acesso compartilhado por diversos usuários. Além deste fato, existe um overhead adicional, se comparado com o mecanismo de proteção por grupo de usuários, devido à pesquisa seqüencial que o sistema deverá realizar na lista sempre que um acesso for solicitado.

Em determinados sistemas de arquivos é possível encontrar tanto o mecanismo de proteção por grupos de usuários quanto o de lista de controle de acesso, oferecendo, desta forma, uma maior flexibilidade ao mecanismo de proteção de arquivos e diretórios.

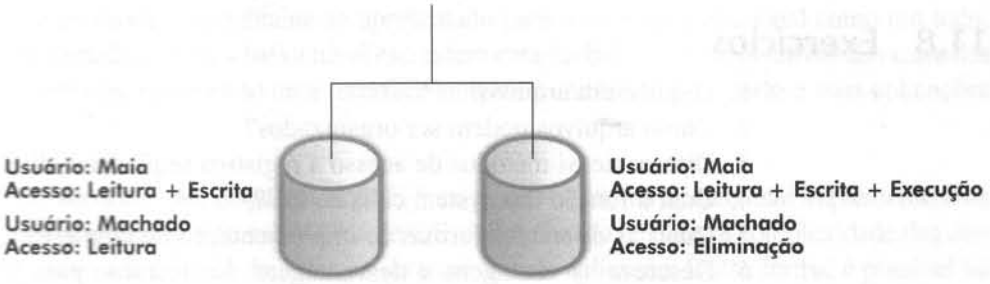

Fig. 11.14 Lista de controle de acessos.

11.7 Implementação de Caches

O acesso a disco é bastante lento se comparado ao acesso à memória principal, devido à arquitetura dos discos magnéticos. Este é o principal motivo das operações de E/S com discos serem um problema para o desempenho do sistema.

Com o objetivo de minimizar este problema, a maioria dos sistemas de arquivos implementa uma técnica denominada *buffer cache*. Neste esquema, o sistema operacional reserva uma área da memória para que se tornem disponíveis caches utilizados em operações de acesso ao disco. Quando uma operação é realizada, seja leitura ou gravação, o sistema verifica se a informação desejada se encontra no buffer cache. Em caso positivo, não é necessário o acesso ao disco. Caso o bloco requisitado não se encontre no cache, a operação de E/S é realizada e o cache é atualizado. Como existe uma limitação no tamanho do cache, cada sistema adota políticas para substituição de blocos como a FIFO ou a LRU.

Apesar de esta implementação melhorar o desempenho do sistema, aspectos de segurança devem ser levados em consideração. No caso de blocos de dados permanece-

rem por um longo período de tempo na memória principal, a ocorrência de problemas de energia pode ocasionar a perda de tarefas já realizadas e consideradas já salvas em disco.

Existem duas maneiras distintas de tratar este problema. No primeiro caso, o sistema operacional possui uma rotina que executa periodicamente em um intervalo de tempo, atualizando em disco todos os blocos modificados do cache. Uma segunda alternativa é, toda vez que um bloco do cache for modificado, que seja realizada imediatamente uma atualização no disco (write-through caches).

Analisando comparativamente as duas técnicas, podemos concluir que a primeira implica menor quantidade de operações de E/S, porém o risco de perda de dados é maior. Apesar de tal probabilidade ser pequena, pode ocorrer que dados atualizados de um arquivo e ainda no cache sejam perdidos no caso de falta de energia. Isto já não aconteceria nos caches do tipo write-through, em função do seu próprio funcionamento, porém o aumento considerável nas operações de E/S tornam este método menos eficiente. Atualmente, a maioria dos sistemas utiliza a primeira técnica de otimização.

11.8 Exercícios

1. O que é um arquivo?
2. Como arquivos podem ser organizados?
3. Diferencie os métodos de acesso a registros seqüencial, direto e indexado.
4. Qual a função das system calls de E/S?
5. Quais as diferentes formas de implementação de uma estrutura de diretório?
6. Descreva as vantagens e desvantagens das técnicas para gerência de espaços livres?
7. O que é alocação contígua de blocos e quais benefícios a desfragmentação pode proporcionar quando esta técnica é utilizada?
8. Descreva as vantagens e desvantagens das técnicas de alocação encadeada e indexada na gerência de alocação de espaço em disco.
9. Quais os tipos de proteção de acesso a arquivos existentes e quais suas principais vantagens?
10. O que é a técnica denominada buffer cache?

12

GERÊNCIA DE DISPOSITIVOS

12.1 Introdução

A gerência de dispositivos de entrada/saída é uma das principais e mais complexas funções de um sistema operacional. Sua implementação é estruturada através de camadas em um modelo semelhante ao apresentado para o sistema operacional como um todo. As camadas de mais baixo nível escondem características dos dispositivos das camadas superiores, oferecendo uma interface simples e confiável ao usuário e suas aplicações (Fig. 12.1).

A diversidade dos dispositivos de E/S exige que o sistema operacional implemente uma camada, chamada de subsistema de E/S, com a função de isolar a complexidade dos dispositivos da camada de sistemas de arquivo e da aplicação. Dessa forma, é possível ao sistema operacional ser flexível, permitindo a comunicação dos processos com qualquer tipo de periférico. Aspectos como velocidade de operação, unidade de transferência, representação dos dados, tipos de operações e demais detalhes de cada periférico são tratados pela camada de device driver, oferecendo uma interface uniforme entre o subsistema de E/S e todos os dispositivos.

As camadas são divididas em dois grupos, onde o primeiro grupo visualiza os diversos tipos de dispositivos do sistema de um modo único (Fig. 12.1a), enquanto o segundo é específico para cada dispositivo (Fig. 12.1b). A maior parte das camadas trabalha de forma independente do dispositivo.

Neste capítulo serão examinadas as diversas camadas que compõem a gerência de dispositivos de E/S, além dos conceitos envolvidos em cada nível. No final do capítulo serão abordados aspectos relacionados especificamente aos discos magnéticos, como desempenho e segurança de dados.

12.2 Acesso ao Subsistema de Entrada e Saída

O sistema operacional deve tornar as operações de E/S o mais simples possível para o usuário e suas aplicações. Para isso, o sistema possui um conjunto de rotinas que possibilita a comunicação com qualquer dispositivo que possa ser conectado ao computador. Esse conjunto de rotinas, denominado *rotinas de entrada/saída*, faz parte do subsistema de E/S e permite ao usuário realizar operações de E/S sem se preocupar com

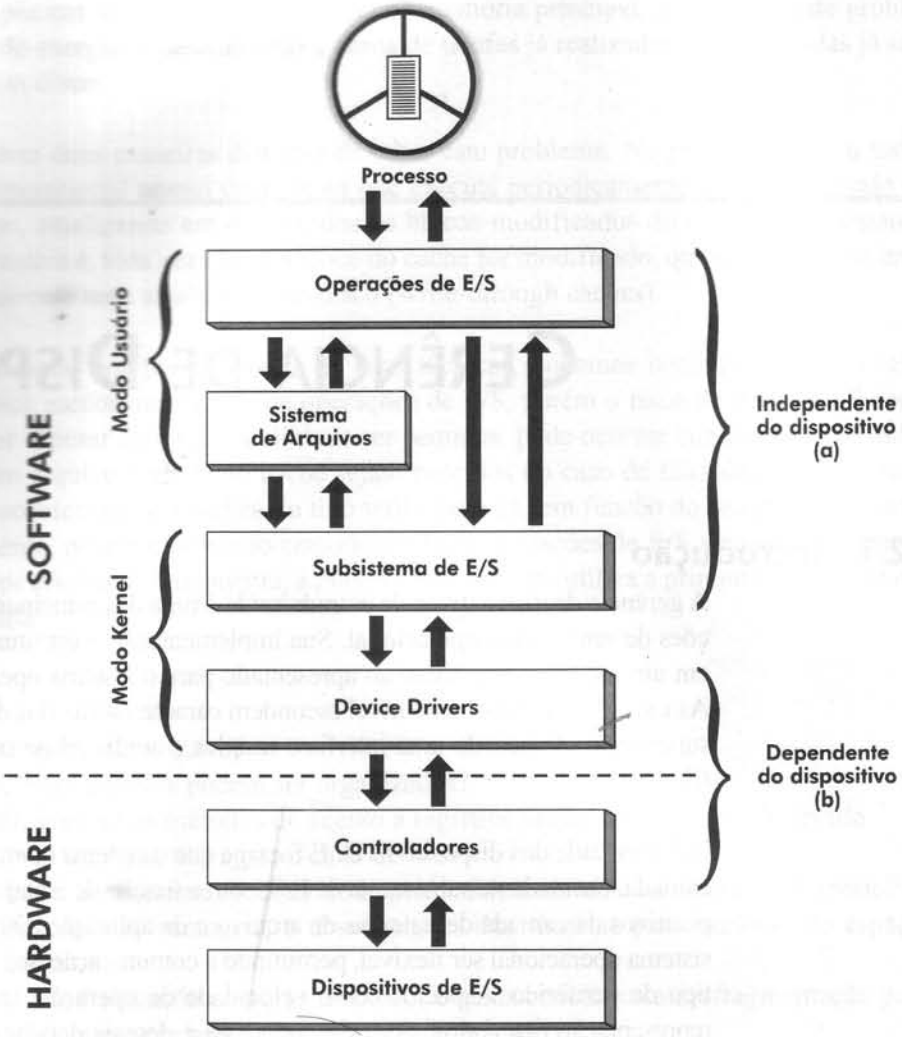

Fig. 12.1 Gerência de dispositivos.

detalhes do dispositivo que está sendo acessado. Nesse caso, quando um usuário cria um arquivo em disco, não lhe interessa como é a formatação do disco, nem em que trilha ou setor o arquivo será gravado.

As operações de E/S devem ser realizadas através de system calls que chamam as rotinas de E/S do núcleo do sistema operacional. Dessa forma, é possível escrever um programa que manipule arquivos, estejam eles em disquetes, discos rígidos ou fita magnética, sem ter que alterar o código para cada tipo de dispositivo. As system calls responsáveis por essa comunicação são denominadas *system calls de entrada/saída.*

A maneira mais simples de ter acesso a um dispositivo é através de comandos de leitura/gravação e chamadas a bibliotecas de rotinas oferecidas por linguagens de alto nível, como Pascal ou C. A comunicação entre os comandos de E/S oferecidos pelas linguagens de programação de alto nível e as system calls de E/S é feita simplesmente através

de passagem de parâmetros. O relacionamento entre o comando e a system call é criado na geração do código executável do programa. Uma outra forma de acessar um dispositivo é através de system call diretamente do código em alto nível. A maioria dos sistemas operacionais disponibiliza esta facilidade.

Um dos objetivos principais das system calls de E/S é simplificar a interface entre as aplicações e os dispositivos. Com isso, elimina-se a necessidade de duplicação de rotinas idênticas nos diversos aplicativos, além de esconder do programador características específicas associadas à programação de cada dispositivo. A Fig. 12.2 ilustra a comunicação entre aplicação e dispositivos de maneira simplificada.

As operações de E/S podem ser classificadas conforme o seu sincronismo. Uma operação é dita síncrona quando o processo que realizou a operação fica aguardando no estado de espera pelo seu término. A maioria dos comandos das linguagens de alto nível funciona desta forma. Uma operação é dita assíncrona quando o processo que realizou a operação não aguarda pelo seu término e continua pronto para ser executado. Neste caso, o sistema deve oferecer algum mecanismo de sinalização que avise ao processo que a operação foi terminada.

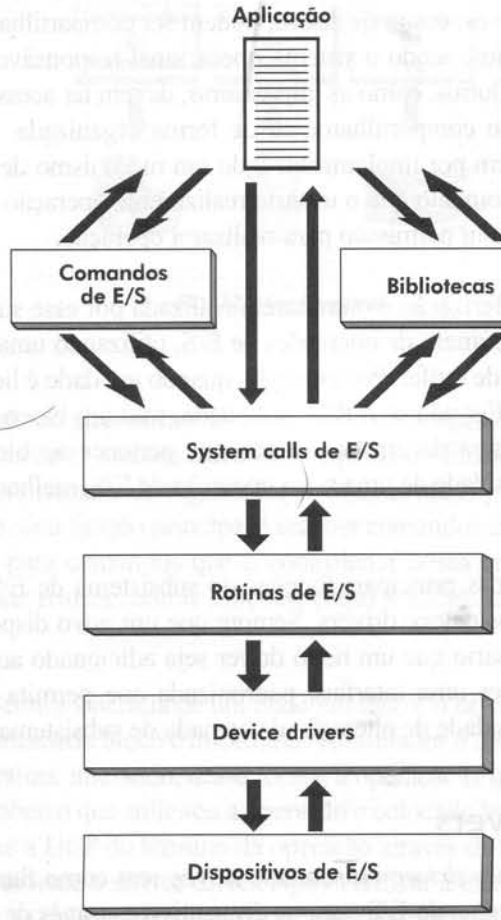

Fig. 12.2 Operações de entrada/saída.

12.3 Subsistema de Entrada e Saída

O *subsistema de entrada e saída* é responsável por realizar as funções comuns a todos os tipos de dispositivos, ficando os aspectos específicos de cada periférico como responsabilidade dos device drivers. Dessa forma, o subsistema de E/S é a parte do sistema operacional que oferece uma interface uniforme com as camadas superiores.

Cada dispositivo trabalha com unidades de informação de tamanhos diferentes, como caracteres ou blocos. O subsistema de E/S é responsável por criar uma unidade lógica de transferência independente do dispositivo e repassá-la para os níveis superiores, sem o conhecimento do conteúdo da informação. No caso de a camada superior ser o sistema de arquivos, esta informação poderá ser interpretada como um registro lógico de um arquivo, devendo obedecer a uma certa organização e método de acesso estabelecidos.

Normalmente, o tratamento de erros nas operações de E/S é realizado pelas camadas mais próximas ao hardware. Existem, porém, certos erros que podem ser tratados e reportados de maneira uniforme pelo sistema de arquivos, independentemente do dispositivo. Erros como a gravação em dispositivos de entrada, leitura em dispositivos de saída e operações em dispositivos inexistentes podem ser tratados neste nível.

Todos os dispositivos de E/S são controlados, com o objetivo de obter o maior compartilhamento possível entre os diversos usuários de forma segura e confiável. Alguns dispositivos, como os discos, podem ser compartilhados, simultaneamente, entre diversos usuários, sendo o sistema operacional responsável pela integridade dos dados acessados. Outros, como as impressoras, devem ter acesso exclusivo, e o sistema deve controlar seu compartilhamento de forma organizada. O subsistema de E/S é responsável também por implementar todo um mecanismo de proteção de acesso aos dispositivos. No momento que o usuário realiza uma operação de E/S, é verificado se o seu processo possui permissão para realizar a operação.

A bufferização é outra tarefa realizada por esse subsistema. Essa técnica permite reduzir o número de operações de E/S, utilizando uma área de memória intermediária chamada de buffer. Por exemplo, quando um dado é lido do disco, o sistema traz para a área de buffer não só o dado solicitado, mas um bloco de dados. Caso haja uma solicitação de leitura de um novo dado que pertença ao bloco anteriormente lido, não existe a necessidade de uma nova operação de E/S, melhorando desta forma a eficiência do sistema.

Uma das principais funções do subsistema de E/S é criar uma interface padronizada com os device drivers. Sempre que um novo dispositivo é instalado no computador, e necessário que um novo driver seja adicionado ao sistema. O subsistema de E/S deve oferecer uma interface padronizada que permita a inclusão de novos drivers sem a necessidade de alteração da camada de subsistema de E/S.

12.4 Device Drivers

O *device driver*, ou somente *driver*, tem como função implementar a comunicação do subsistema de E/S com os dispositivos, através de controladores. Enquanto o subsistema de E/S trata de funções ligadas a todos os dispositivos, os drivers tratam apenas dos seus aspectos particulares.

Os drivers têm como função receber comandos gerais sobre acessos aos dispositivos e traduzi-los para comandos específicos, que poderão ser executados pelos controladores (Fig. 12.3). Cada device driver manipula somente um tipo de dispositivo ou grupo de dispositivos semelhantes. Normalmente, um sistema possui diferentes drivers, como drivers para disco, fita magnética, rede e vídeo.

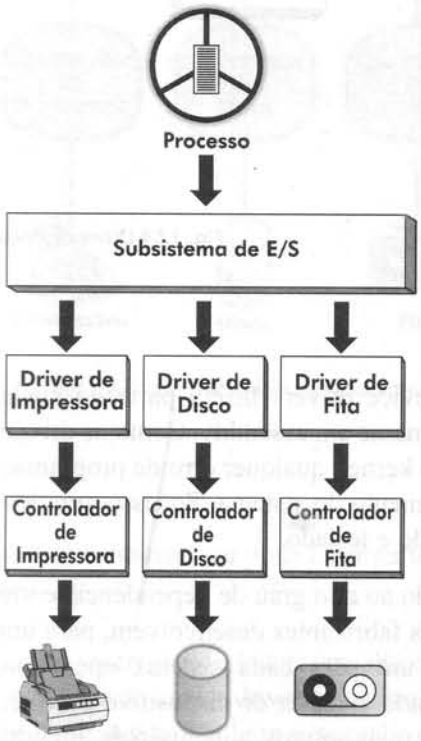

Fig. 12.3 Device drivers.

O driver está integrado diretamente às funções do controlador, sendo o componente do sistema que reconhece as características particulares do funcionamento de cada dispositivo de E/S, como número de registradores do controlador, funcionamento e comandos do dispositivo. Sua função principal é receber comandos abstratos do subsistema de E/S e traduzi-los para comandos que o controlador possa entender e executar. Além disso, o driver pode realizar outras funções, como a inicialização do dispositivo e seu gerenciamento.

Por exemplo, na leitura síncrona de um dado em disco, o driver recebe a solicitação de leitura de um determinado bloco e informa ao controlador o disco, cilindro, trilha e setor que o bloco se localiza, iniciando, dessa forma, a operação (Fig. 12.4). Enquanto se realiza a leitura, o processo que solicitou a operação é colocado no estado de espera até que o controlador avise a UCP do término da operação através de uma interrupção que, por sua vez, ativa novamente o device driver. Após verificar a inexistência de erros, o device driver transfere as informações para a camada superior. Com os dados disponíveis, o processo pode ser retirado do estado de espera e retornar ao estado de pronto para continuar seu processamento.

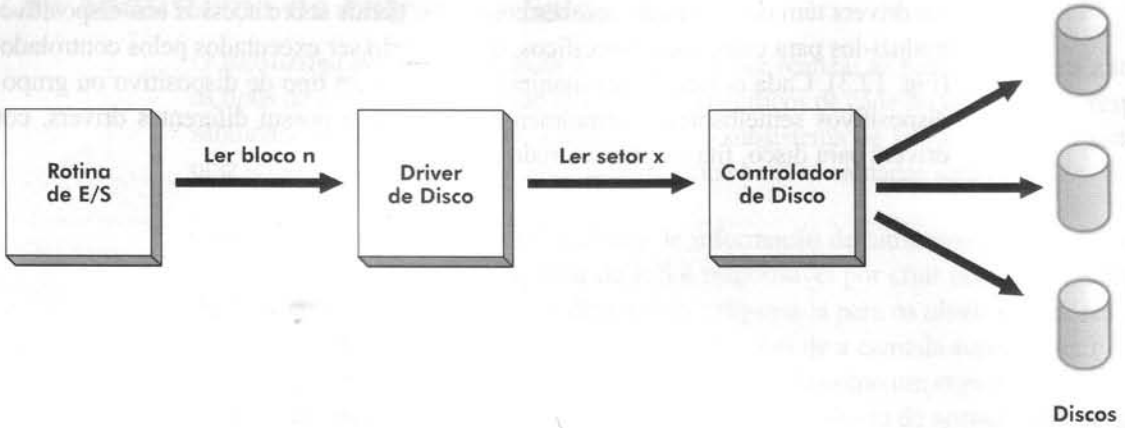

Fig. 12.4 Driver de disco.

Os device drivers fazem parte do núcleo do sistema operacional, sendo escritos geralmente em assembly. Como os drivers são códigos reentrantes que executam em modo kernel, qualquer erro de programação pode comprometer por completo o funcionamento do sistema. Por isso, um device driver deve ser cuidadosamente desenvolvido e testado.

Devido ao alto grau de dependência entre os drivers e o restante do núcleo do sistema, os fabricantes desenvolvem, para um mesmo dispositivo, diferentes device drivers, um para cada sistema operacional. Sempre que um novo dispositivo é instalado, o driver do dispositivo deve ser adicionado ao núcleo do sistema. Nos sistemas mais antigos, a inclusão de um novo driver significava a recompilação do kernel, uma operação complexa e que exigia a reinicialização do sistema. Atualmente, alguns sistemas permitem a fácil instalação de novos drivers sem a necessidade de reinicialização.

12.5 Controladores

Os *controladores* são componentes de hardware responsáveis por manipular diretamente os dispositivos de E/S. O sistema operacional, mais exatamente o device driver, comunica-se com os dispositivos através dos controladores (Fig. 12.5). Em geral, o controlador pode ser uma placa independente conectada a um slot do computador ou implementado na mesma placa do processador.

O controlador possui memória e registradores próprios utilizados na execução de instruções enviadas pelo device driver. Essas instruções de baixo nível são responsáveis pela comunicação entre o controlador e o dispositivo de E/S. Em operações de leitura, o controlador deve armazenar em seu buffer interno uma seqüência de bits proveniente do dispositivo até formar um bloco. Após verificar a ocorrência de erros, o bloco pode ser transferido para um buffer de E/S na memória principal.A transferência do bloco do buffer interno do controlador para o buffer de E/S da memória principal pode ser realizado pela UCP ou por um controlador de DMA. O uso da técnica de DMA evita que o processador fique ocupado com a transferência do bloco para a memória. O controlador

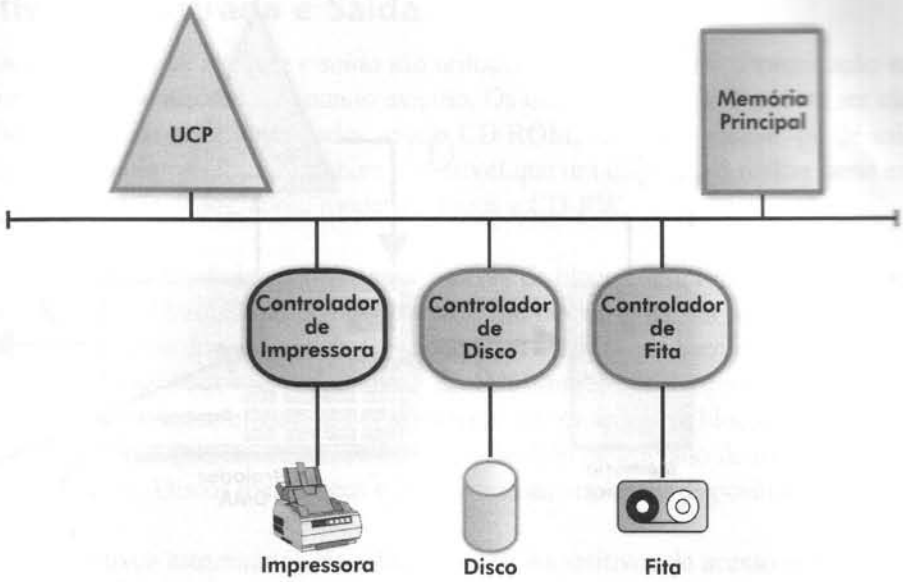

Fig. 12.5 UCP, memória e controladores.

de DMA é um dispositivo de hardware que pode fazer parte do controlador ou ser um dispositivo independente.

De forma simplificada, uma operação de leitura em disco utilizando DMA teria os seguintes passos. A UCP, através do device driver, inicializa os registradores do controlador de DMA e, a partir deste ponto, fica livre para realizar outras atividades. O controlador de DMA, por sua vez, solicita ao controlador de disco a transferência do bloco do disco para o seu buffer interno. Terminada a transferência, o controlador de disco verifica a existência de erros e, caso não haja erros, o controlador de DMA transfere o bloco para o buffer de E/S na memória principal. Ao término da transferência, o controlador de DMA gera uma interrupção avisando ao processador que o dado já se encontra na memória principal (Fig. 12.6).

Alguns controladores, particularmente os de discos, implementam técnicas de cache semelhantes às implementadas pelos sistemas de arquivos, na tentativa de melhorar o desempenho das operações de E/S. Normalmente, o controlador avisa ao sistema operacional do término de uma operação de gravação, quando os dados no buffer do controlador são gravados no disco (write-through caching). O controlador também pode ser configurado para avisar do término da gravação, mesmo quando os dados ainda se encontram no buffer do controlador e a operação de gravação no disco não foi realizada (write-back caching). Desta forma é possível obter ganhos consideráveis de desempenho.

O padrão mais popular para a conexão de dispositivos a um computador é o SCSI (Small Computer Systems Interface). Inicialmente utilizado em estações de trabalho RISC, o SCSI pode ser encontrado hoje em sistemas de computação de todos os portes, desde computadores pessoais até servidores de grande porte. O SCSI define padrões de hardware e software que permitem conectar ao sistema computacional dispositivos de

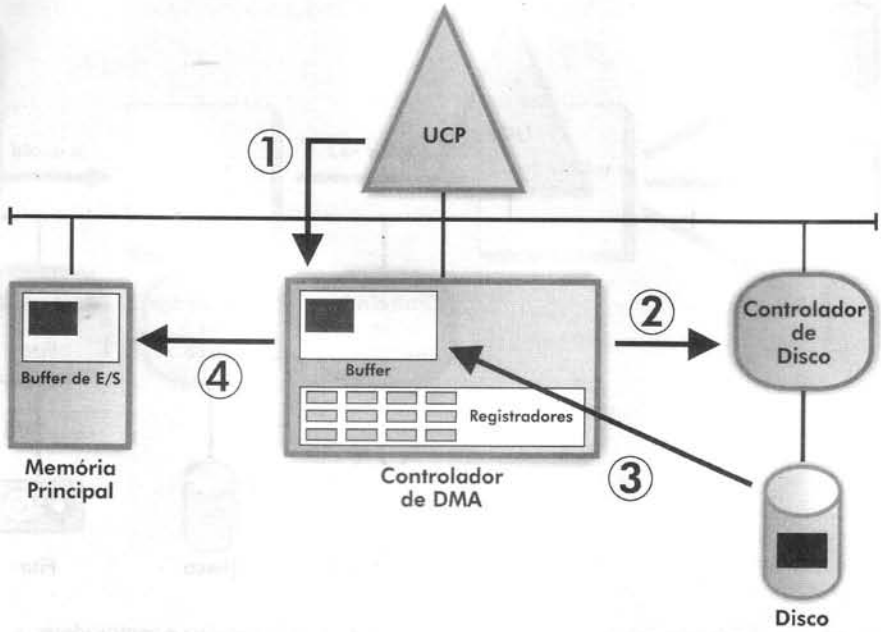

Fig. 12.6 Técnica de DMA.

fabricantes diferentes, como discos, CD-ROMs, scanners e unidades de fita, desde que sigam o padrão estabelecido. Para que isso seja possível, deve-se configurar o sistema operacional com um driver SCSI e o hardware com um controlador SCSI, onde os periféricos são conectados (Fig. 12.7).

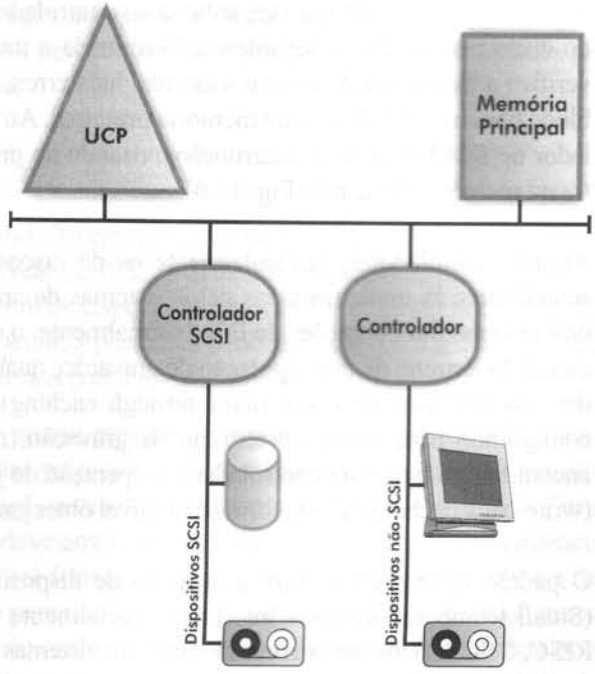

Fig. 12.7 Controlador SCSI.

12.6 Dispositivos de Entrada e Saída

Os *dispositivos de entrada e saída* são utilizados para permitir a comunicação entre o sistema computacional e o mundo externo. Os dispositivos de E/S podem ser classificados como de entrada de dados, como CD-ROM, teclado e mouse, ou de saída de dados, como impressoras. Também é possível que um dispositivo realize tanto entrada quanto saída de dados, como modems, discos e CD-RW.

A transferência de dados pode ocorrer através de blocos de informação ou caracteres, por meio dos controladores dos dispositivos. Em função da forma com que os dados são armazenados, os dispositivos de E/S podem ser classificados em duas categorias: dispositivos estruturados e dispositivos não-estruturados.Os *dispositivos estruturados* (block devices) caracterizam-se por armazenar informações em blocos de tamanho fixo, possuindo cada qual um endereço que pode ser lido ou gravado de forma independente dos demais. Discos magnéticos e ópticos são exemplos de dispositivos estruturados.

Os dispositivos estruturados classificam-se em dispositivos de acesso direto e seqüencial, em função da forma com que os blocos são acessados. Um dispositivo é classificado como de *acesso direto* quando um bloco pode ser recuperado diretamente através de um endereço. O disco magnético é o melhor exemplo para esse tipo de dispositivo. Um dispositivo é do tipo de *acesso seqüencial* quando, para se acessar um bloco, o dispositivo deve percorrer seqüencialmente os demais blocos até encontrá-lo. A fita magnética é exemplo deste tipo de acesso.

Os *dispositivos não-estruturados* (character devices) são aqueles que enviam ou recebem uma seqüência de caracteres sem estar estruturada no formato de um bloco. Desse modo, a seqüência de caracteres não é endereçável, não permitindo operações de acesso direto ao dado. Dispositivos como terminais, impressoras e interfaces de rede são exemplos de dispositivos não-estruturados.

12.7 Discos Magnéticos

Entre os diversos dispositivos de E/S, os discos magnéticos merecem atenção especial, por serem o principal repositório de dados utilizado pela maioria das aplicações e pelo próprio sistema operacional. Fatores como desempenho e segurança devem ser considerados na arquitetura de discos magnéticos.

Na realidade, um disco magnético é constituído por vários discos sobrepostos, unidos por um mesmo eixo vertical, girando a uma velocidade constante. Cada disco é composto por trilhas concêntricas, que por sua vez são divididas em setores. As trilhas dos diferentes discos que ocupam a mesma posição vertical formam um cilindro. Para a superfície de cada disco existe um mecanismo de leitura/gravação. Todos os mecanismos de leitura/gravação são conectados a um braço que se movimenta entre os vários cilindros dos discos no sentido radial (Fig. 12.8).

O tempo utilizado para leitura e gravação de um bloco de dados em um disco é função de três fatores: tempos de seek, de latência rotacional e de transferência. O tempo de seek é o tempo gasto no posicionamento do mecanismo de leitura e gravação até o cilindro onde o bloco se encontra. O tempo de latência rotacional é o tempo de espera até

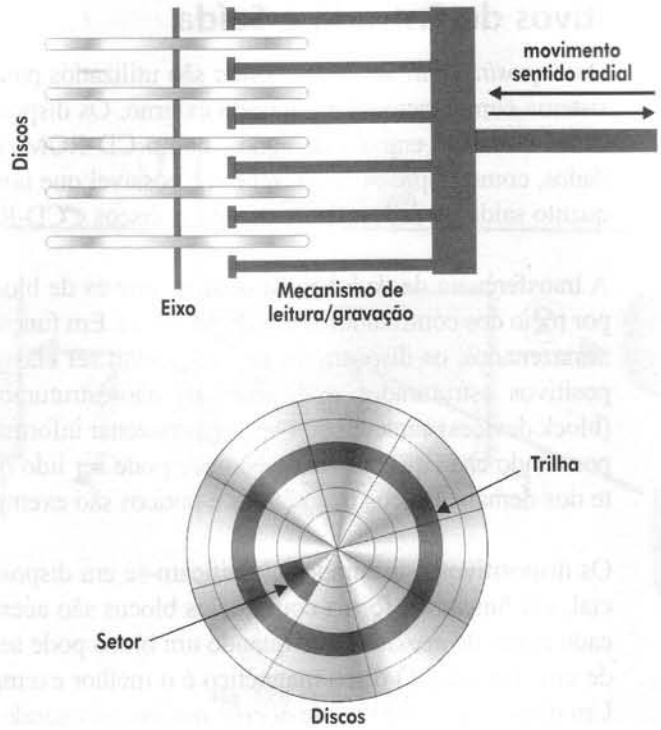

Fig. 12.8 Estrutura de um disco magnético.

que o setor desejado se posicione sob o mecanismo de leitura/gravação. O tempo de transferência corresponde ao tempo necessário para a transferência do bloco entre memória principal e o setor do disco (Fig. 12.9).

Como todos esses fatores envolvem aspectos mecânicos, o tempo total das operações de E/S é extremamente longo, se comparado ao número de instruções que o processa-

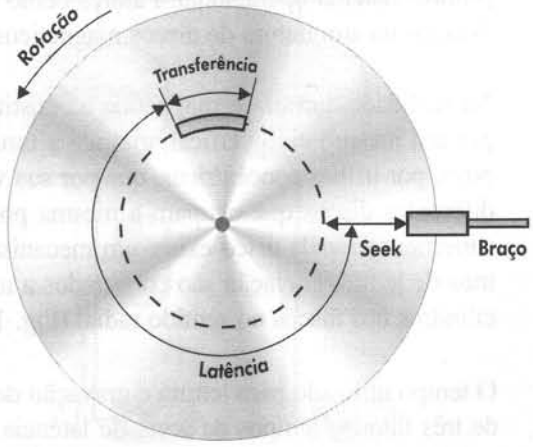

Fig. 12.9 Tempo de acesso.

dor pode executar no mesmo intervalo de tempo. Para a maioria dos discos magnéticos, o tempo de seek é o fator de maior impacto no acesso a seus dados.

Uma forma de eliminar parcialmente os tempos de seek e latência é copiar parte dos dados do disco para a memória principal, utilizando uma área conhecida como disco RAM. Alguns sistemas gerenciadores de banco de dados (SGBD) implementam essa técnica com vistas a aumentar o desempenho no acesso a grandes bases de dados.

12.7.1 Desempenho, Redundância e Proteção de Dados

No final da década de 1980, pesquisadores da Universidade da Califórnia em Berkeley desenvolveram técnicas de gerenciamento de discos que otimizavam as operações de E/S e implementavam redundância e proteção de dados conhecidas como *RAID* (Redundant Arrays of Inexpensive Disk). As diferentes técnicas, utilizando múltiplos discos, foram publicadas em seis níveis (RAID 1-6). Estas técnicas tiveram grande aceitação no mercado e, posteriormente, um novo nível foi introduzido e denominado RAID 0.

As técnicas de RAID podem ser implementadas diretamente nos controladores de discos, conhecido como *subsistema RAID externo*, ou por software através do sistema operacional ou um produto gerenciador de discos, denominado *subsistema JBOD* (just a bunch of disks). A Fig. 12.10 ilustra a diferença entre as duas possíveis formas de implantação das técnicas de RAID.

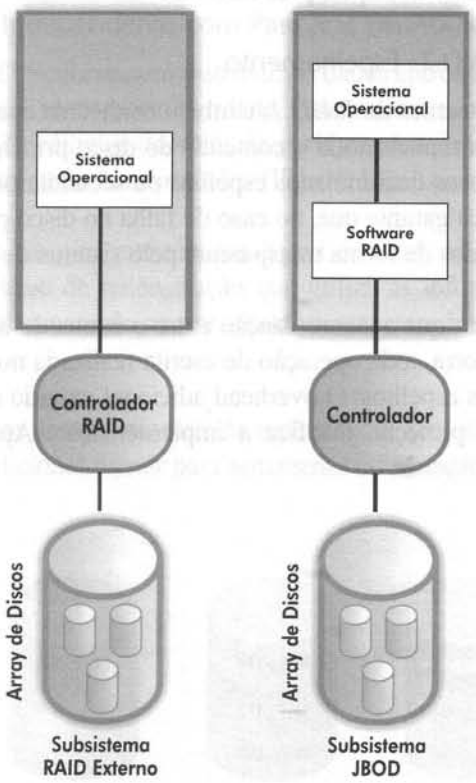

Fig. 12.10 Subsistema de discos.

Uma característica fundamental na técnica de RAID é a criação de um dispositivo virtual conhecido como *array de discos*. Este array consiste em um grupo de discos físicos que são tratados pelo sistema operacional como se fosse um único disco. Este disco tem como características uma grande capacidade de armazenamento, alto desempenho e confiabilidade nos dados armazenados. A seguir são apresentadas as técnicas de RAID 0, RAID 1 e RAID 5, por sua ampla utilização em diversos sistemas computacionais:

- RAID 0: Striping

  A técnica de *RAID 0*, também conhecida como *striping*, consiste na implementação do chamado disk striping, que é distribuir as operações de E/S entre os diversos discos físicos contidos no array com o intuito de otimizar o desempenho. Como os dados são divididos entre os diversos discos, as operações de E/S podem ser processadas paralelamente.

  Para poder implementar o striping é preciso formar um conjunto de discos chamado de *stripe set*, onde cada disco é dividido em pedaços (stripes). Sempre que um arquivo é gravado, seus dados são divididos em pedaços iguais e espalhados simultaneamente pelos stripes dos diversos discos (Fig. 12.11).

  Apesar da denominação RAID, esta técnica não implementa qualquer tipo de redundância, só sendo vantajosa no ganho de desempenho das operações de E/S. Caso um haja uma falha em qualquer disco do stripe set, os dados serão perdidos. Aplicações multimídia são beneficiadas com o uso desta técnica pois necessitam de alto desempenho nas operações com discos.

- RAID 1: Espelhamento

  A técnica de *RAID 1*, também conhecida como *espelhamento* ou *mirroring*, consiste em replicar todo o conteúdo do disco principal, chamado primário, em um ou mais discos denominados espelhos ou secundários. A redundância oferecida por essa técnica garante que, no caso de falha no disco principal, os discos espelhos sejam utilizados de forma transparente pelo sistema de arquivos (Fig. 12.12).

  Para que a sincronização entre o conteúdo do disco principal e dos discos espelhos ocorra, toda operação de escrita realizada no disco primário é replicada para os discos espelhos. O overhead adicional exigido nesta operação é pequeno e o benefício da proteção justifica a implementação. Apesar da vantagem proporcionada pela

Fig. 12.11 RAID 0.

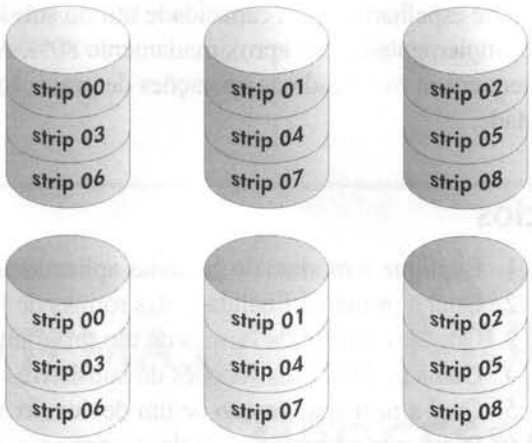

Fig. 12.12 RAID 1.

redundância oferecida por esta técnica, a capacidade útil do subsistema de discos com a implementação do RAID 1 é de apenas 50%.

A técnica de RAID 1 pode ser implementada por software em um subsistema JBOD ou por hardware diretamente pelo controlador de disco em um subsistema RAID externo. A implementação por software necessita que o sistema operacional ou algum produto gerenciador de discos ofereça esta facilidade.

- RAID 5: Acesso Independente com Paridade Distribuída

  A técnica de *RAID 5* consiste em distribuir os dados entre os discos do array e implementar redundância baseada em paridade. Este mecanismo de redundância é implementado através de cálculos do valor da paridade dos dados, que são armazenados nos discos do array junto com os dados (Fig. 12.13).

Caso haja uma falha em qualquer um dos discos do array, os dados podem ser recuperados por um algoritmo de reconstrução que utiliza as informações de paridade dos demais discos. Esta recuperação ocorre automaticamente e é transparente ao sistema de arquivos.

A principal vantagem de uma técnica de redundância que utiliza paridade é que esta requer um espaço adicional menor para armazenar informação de controle que a técni-

Fig. 12.13 RAID 5.

ca de espelhamento. A capacidade útil do subsistema de discos com a técnica de RAID 5 implementada é de aproximadamente 80%. Apesar disso, esta técnica de redundância requer um overhead nas operações de gravação no disco em função do cálculo da paridade.

12.8 Exercícios

1. Explique o modelo de camadas aplicado na gerência de dispositivos.
2. Qual a principal finalidade das rotinas de E/S?
3. Quais as diferentes formas de um programa chamar rotinas de E/S?
4. Quais as principais funções do subsistema de E/S?
5. Qual a principal função de um device driver?
6. Por que o sistema de E/S deve criar uma interface padronizada com os device drivers?
7. Explique o funcionamento da técnica de DMA e sua principal vantagem.
8. Diferencie os dispositivos de E/S estruturados dos não-estruturados.
9. Qual a principal razão de as operações de E/S em fitas e discos magnéticos serem tão lentas se comparadas a velocidade com que o processador executa instruções?
10. O que são técnicas de redundância em discos magnéticos?
11. Diferencie as técnicas RAID 0, RAID 1 e RAID 5 apresentando vantagens e desvantagens.

13

SISTEMAS COM MÚLTIPLOS PROCESSADORES

13.1 Introdução

Sistemas com múltiplos processadores são arquiteturas que possuem duas ou mais UCPs interligadas e que funcionam em conjunto na execução de tarefas independentes ou no processamento simultâneo de uma mesma tarefa. Inicialmente, os computadores eram vistos como máquinas seqüenciais, onde o processador executava as instruções de um programa uma de cada vez. Com a implementação de sistemas com múltiplos processadores, o conceito de paralelismo pôde ser expandido a um nível mais amplo.

A evolução desses sistemas se deve, em grande parte, ao elevado custo de desenvolvimento de processadores mais rápidos. Em função disso, passou-se a dar ênfase a computadores com múltiplos processadores em vez de arquiteturas com um único processador de alto desempenho. Outra motivação são aplicações que necessitam de grande poder computacional, como sistemas de previsão do tempo, dinâmica dos fluidos, genoma humano, modelagens e simulações. Com múltiplos processadores, é possível reduzir drasticamente o tempo de processamento destas aplicações. Inicialmente, as configurações limitavam-se a poucos processadores, mas atualmente existem sistemas com milhares de processadores.

Os primeiros sistemas com múltiplos processadores surgiram na década de 1960, com o objetivo principal de acelerar a execução de aplicações que lidavam com um grande volume de cálculos. Por muito tempo, esses sistemas foram utilizados quase que exclusivamente em ambientes acadêmicos e centros de pesquisas voltados para o processamento científico. O mercado corporativo começou realmente a utilizar os sistemas com múltiplos processadores na década de 1980, para melhorar o desempenho de suas aplicações comerciais e reduzir o tempo de resposta dos usuários interativos. Posteriormente, as empresas reconheceram também nesse tipo de sistema uma maneira de aumentar a confiabilidade, a escalabilidade, e a disponibilidade, além da possibilidade do balanceamento de carga de suas aplicações. Atualmente, a maioria dos servidores de banco de dados, servidores de arquivos e servidores Web, utiliza sistemas com múltiplos processadores. Além disso, sistemas com múltiplos

processadores estão sendo utilizados em estações de trabalho e, até mesmo, em computadores pessoais. Isso foi possível devido à redução de custo dessas arquiteturas e à evolução dos sistemas operacionais, que passaram a oferecer suporte a múltiplos processadores.

Este capítulo apresenta as vantagens e desvantagens de sistemas com múltiplos processadores, os tipos de sistemas, suas classificações e características.

13.2 Vantagens e Desvantagens

Existem inúmeras vantagens em sistemas com múltiplos processadores, como desempenho, escalabilidade, relação custo/benefício, tolerância a falhas, disponibilidade e balanceamento de carga. A seguir, são apresentadas as principais vantagens:

- Desempenho

A princípio, sempre que novos processadores são adicionados à arquitetura de uma máquina, melhor é o *desempenho* do sistema. Apesar de esta relação não ser linear, o aumento de desempenho pode ser observado pelo maior throughput do sistema, pela redução no tempo de resposta e pelo menor tempo de processamento das aplicações.

O desempenho pode ser formalmente medido utilizando os padrões especificados pelo consórcio Transaction Processing Performance Council (TPC), criado em 1988 e formado por inúmeras empresas. O TPC oferece três benchmarks (TPC-A, TPC-B e TPC-C) que podem ser aplicados para determinar o desempenho comparativo de diversos sistemas, além da relação custo/desempenho.

O ganho de desempenho com múltiplos processadores pode ser obtido em dois níveis. No primeiro nível, múltiplos processadores permitem a execução simultânea de diversas tarefas independentes, aumentando o throughput do sistema. Servidores de banco de dados e servidores Web são bons exemplos de ambientes onde o aumento do número de processadores permite atender um número maior de usuários simultaneamente.

No segundo nível, múltiplos processadores permitem a execução de uma mesma tarefa por vários processadores simultaneamente (processamento paralelo). Neste caso, o ganho de desempenho dependerá de diferentes fatores, como a organização dos processadores, a linguagem de programação utilizada e o grau de paralelismo possível na aplicação. O processamento paralelo é mais difícil de ser implementado, e apenas algumas aplicações oferecem ganhos reais com aumento do número de processadores (aplicação concorrente).

- Escalabilidade

Escalabilidade é a capacidade de adicionar novos processadores ao hardware do sistema. Em ambientes que permitam apenas um processador, para aumentar a capacidade computacional é necessário substituir a UCP por uma outra com maior poder de processamento. Com múltiplos processadores, é possível ampliar a capacidade de computação apenas adicionando-se novos processadores, com um custo inferior à aquisição de um outro sistema com maior desempenho.

- Relação custo/desempenho

Sistemas com um único processador, por mais poderosos que sejam, apresentam limitações de desempenho inerentes à sua arquitetura, devido às limitações existentes na comunicação da UCP com as demais unidades funcionais, principalmente a memória principal. Além disso, o custo do desenvolvimento de um processador que ofereça desempenho semelhante a um sistema com múltiplos processadores é muito elevado.

Sistemas com múltiplos processadores permitem utilizar UCPs convencionais de baixo custo, interligadas às unidades funcionais através de mecanismos de interconexão. Desta forma é possível oferecer sistemas de alto desempenho com custo aceitável.

- Tolerância a falhas e disponibilidade

Tolerância a falhas é a capacidade de manter o sistema em operação mesmo em casos de falha em algum componente. Nesta situação, se um dos processadores falhar, os demais podem assumir suas funções de maneira transparente aos usuários e suas aplicações, embora com menor capacidade computacional.

A *disponibilidade* é medida em número de minutos por ano que o sistema permanece em funcionamento de forma ininterrupta, incluindo possíveis falhas de hardware ou software, manutenções preventivas e corretivas. Na Tabela 13.1 são apresentados diversos níveis de disponibilidade em função do tempo de indisponibilidade do sistema (downtime), considerando uma operação de 24 horas por 7 dias.

Tabela 13.1 Níveis de disponibilidade

Disponibilidade	Downtime em Minutos	Impacto ao Usuário
90%	50.000	Mais de um mês
99%	5.000	Menos de 4 dias
99,9%	500	Menos de 9 horas
99,99%	50	Cerca de 1 hora
99,999%	5	Pouco mais de 5 minutos
99,9999%	0,5	Cerca de 30 segundos
99,99999%	0,05	Cerca de 3 segundos
100%	0	0

Uma alta disponibilidade é obtida com sistemas com maior tolerância a falhas. Sistema de alta disponibilidade são utilizados em aplicações de missão crítica, como sistemas de tráfego aéreo e de comércio eletrônico na Internet.

- Balanceamento de carga

Balanceamento de carga é a distribuição do processamento entre os diversos componentes da configuração, a partir da carga de cada processador, melhorando, assim, o desempenho do sistema como um todo. Servidores de banco de dados, que oferecem esse tipo de facilidade, permitem que as solicitações dos diversos usuários sejam distribuídas entre os vários processadores disponíveis.

Apesar das inúmeras vantagens, sistemas com múltiplos processadores também possuem desvantagens. Com múltiplos processadores, novos problemas de comunicação e sincronização são introduzidos, pois vários processadores podem estar acessando as mesmas posições de memória. Além disso, existe o problema de organizar os processadores, memórias e periféricos de uma forma eficiente, que permita uma relação custo/desempenho aceitável. Dependo do tipo de sistema, a tolerância contra falhas é dependente do sistema operacional e não apenas do hardware, sendo difícil de ser implementada.

13.3 Tipos de Sistemas Computacionais

Os sistemas computacionais podem ser classificados conforme o grau de paralelismo existente no processamento de suas instruções e dados. O modelo proposto por Flynn (1966) define quatro tipos de sistema e, apesar de antigo, continua sendo amplamente utilizado para comparar e compreender a evolução das arquiteturas de computadores.

- SISD (Single Instruction Single Data)

  Esta arquitetura engloba os sistemas que suportam uma única seqüência de instruções e apenas uma seqüência de dados. A grande maioria dos computadores com apenas um processador se enquadra nesta categoria, desde computadores pessoais até servidores de grande porte. Mesmo em sistemas com um único processador é possível encontrar algum nível de paralelismo, como na utilização da técnica de pipeline.

- SIMD (Single Instruction Multiple Data)

  O segundo tipo trata de sistemas com uma única seqüência de instruções e múltiplas seqüências de dados. Os computadores SISD trabalham com dados escalares e, portanto, processam vetores seqüencialmente, ou seja, um componente de cada vez. Computadores SIMD permitem a manipulação de vetores inteiros simultaneamente, possibilitando a execução de uma mesma instrução sobre diferentes elementos de um ou mais vetores.

Vejamos o exemplo da soma de dois vetores, A e B, onde o resultado é atribuído ao vetor C. Em uma linguagem de alto nível, a operação poderia ser implementada conforme o loop descrito no trecho de código a seguir. Em uma arquitetura SISD, a soma dos vetores A e B corresponderia ao ciclo de busca da instrução, ao cálculo dos endereços dos operandos e à execução das instruções de controle da repetição (FOR) para cada soma dos N elementos dos vetores. Para a mesma situação, um computador SIMD utiliza uma única instrução, onde o vetor A é somado ao vetor B e o resultado atribuído ao vetor C. A grande vantagem dessa implementação é que somente uma instrução é executada, ocorrendo apenas um ciclo de busca e execução.

```
FOR i := 1 TO N DO
    C[i] := A[i] + B[i];
```

Arquiteturas SIMD são vantajosas apenas quando as aplicações executadas têm um elevado grau de *paralelismo de dados*, como problemas numéricos, processamento

de imagens, estudos meteorológicos e de física nuclear. Para processar esses tipos de problemas, que realizam repetidas operações aritméticas de ponto flutuante em grandes vetores, foram desenvolvidos os chamados supercomputadores ou computadores vetoriais. Essas máquinas são capazes de processar, em segundos, o que um computador SISD levaria horas ou mesmo dias. O custo do seu alto desempenho é sua organização complexa e preços muito superiores aos dos computadores convencionais. Um exemplo de computador vetorial é o Cray T90, que possui oito registradores vetoriais, com 128 elementos por vetor, e máximo de 32 processadores.

- MISD (Multiple Instruction Single Data)

  A terceira categoria permite múltiplas seqüências de instruções e uma única seqüência de dados. Não existe, até o momento, nenhum computador desenvolvido com esta arquitetura.

- MIMD (Multiple Instruction Multiple Data)

  A quarta categoria trata múltiplas seqüências de instruções e múltiplas seqüências de dados, onde se enquadram os sistemas com múltiplos processadores.

13.4 Sistemas Fortemente e Fracamente Acoplados

As arquiteturas MIMD podem ser classificadas em função de diversos fatores, como compartilhamento da memória principal, distância física entre processadores, tempo de acesso à memória principal, mecanismos de comunicação e sincronização utilizados e velocidade de comunicação dos processadores. A partir desses fatores, é possível determinar o grau de acoplamento de um sistema, permitindo que arquiteturas MIMD sejam classificadas em sistemas fortemente acoplados ou fracamente acoplados.

Nos *sistemas fortemente acoplados,* os processadores compartilham uma única memória principal e são controlados por apenas um único sistema operacional. Os *sistemas fracamente acoplados* caracterizam-se por possuir dois ou mais sistemas computacionais independentes, conectados por uma rede de comunicação, tendo cada sistema seus próprios processadores, memória principal, dispositivos E/S e sistema operacional (Fig. 13.1).

A grande diferença entre os dois tipos de sistemas é que em sistemas fortemente acoplados existe apenas um espaço de endereçamento compartilhado por todos os processadores, também chamado de *memória compartilhada*. A comunicação entre os processadores é feita através de variáveis na memória principal, utilizando operações de leitura e escrita. Nos sistemas fracamente acoplados, cada sistema tem seu próprio espaço de endereçamento individual e a comunicação entre os sistemas é realizada através de mecanismos de troca de mensagens, utilizando operações de send e receive. A Tabela 13.2 apresenta diversas características encontradas em sistemas fortemente e fracamente acoplados e compara suas principais diferenças.

Uma outra maneira de subdividir as arquiteturas MIMD foi proposta por Bell (1985), considerando apenas o grau de acoplamento da memória principal. A subdivisão proposta separa arquiteturas que compartilham um único espaço de endereçamento,

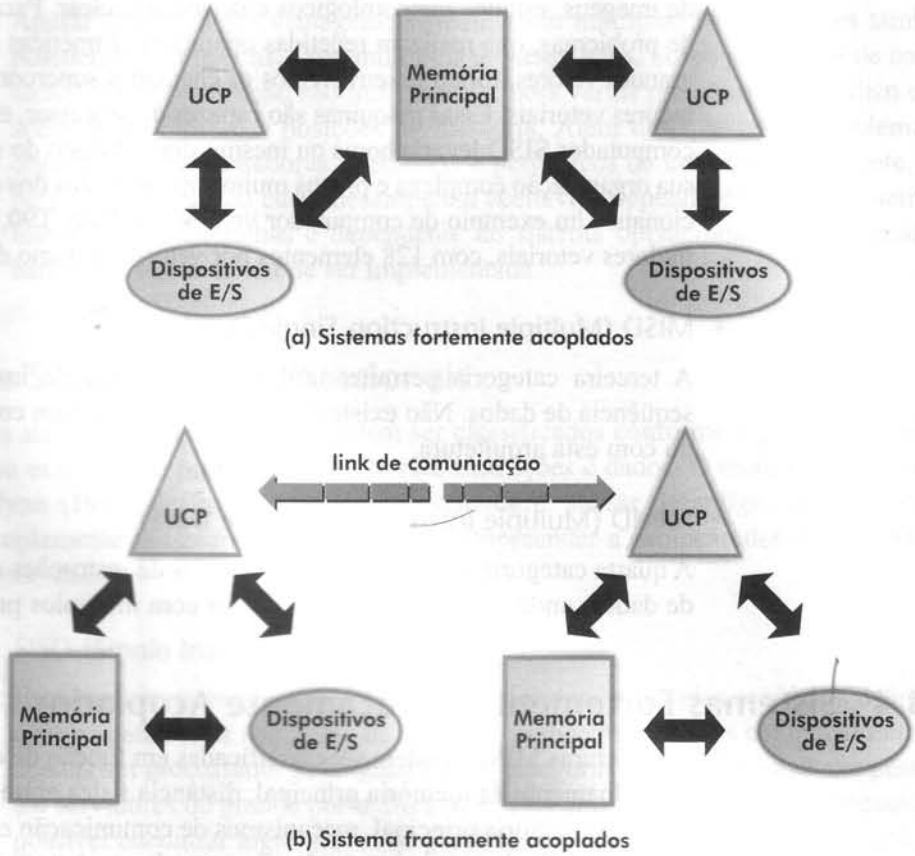

Fig. 13.1 Sistemas fortemente e fracamente acoplados.

chamadas *multiprocessadores*, das que possuem seu próprio espaço de endereçamento individual, chamadas *multicomputadores*. De certa forma, podemos relacionar os sistemas fortemente acoplados aos multiprocessadores e os sistemas fracamente acoplados aos multicomputadores.

Tabela 13.2 Sistemas fortemente acoplados × sistemas fracamente acoplados

Características	Sistemas Fortemente Acoplados	Sistemas Fracamente Acoplados
Espaço de endereçamento	Centralizado	Distribuído
Comunicação entre os processadores	Muito rápida	Lenta
Arquitetura de hardware	Complexa	Mais simples
Sistema operacional	Homogêneo	Geralmente heterogêneo
Cópias do sistema operacional	Existe apenas uma cópia	Existem várias cópias, uma para cada sistema
Programação paralela	Mais fácil	Mais difícil
Número de processadores	Centenas	Não existe limite
Escalabilidade	Baixa	Alta
Disponibilidade	Baixa/Média	Média/Alta
Administração	Simples	Complexa
Custo de software	Menor	Maior
Intercomunicação	Proprietária	Padronizada
Segurança	Centralizada	Distribuída

A Fig. 13.2 apresenta uma subdivisão para os sistemas fortemente acoplados e fracamente acoplados, para facilitar a identificação dos sistemas intermediários.

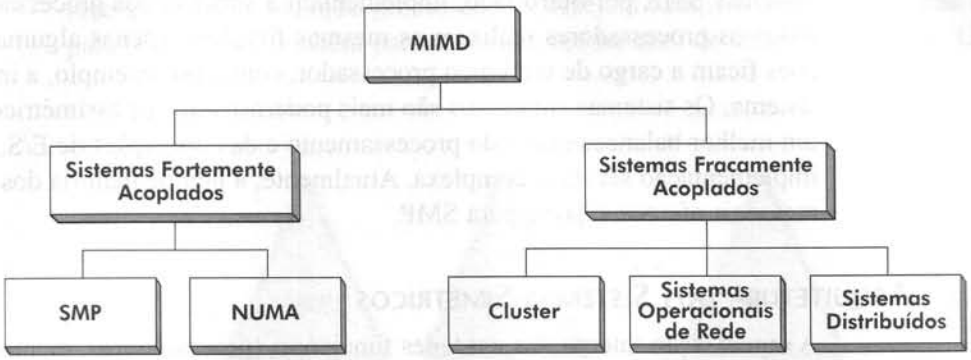

Fig. 13.2 Sistemas com múltiplos processadores.

13.5 Sistemas com Multiprocessadores Simétricos

Os *sistemas com multiprocessadores simétricos* (*Symmetric Multiprocessors* – SMP) possuem dois ou mais processadores compartilhando um único espaço de endereçamento e gerenciados por apenas um sistema operacional.

Uma característica importante nos sistemas SMP é que o tempo de acesso à memória principal pelos vários processadores é uniforme, independente da localização física do processador. Este tipo de arquitetura também é conhecido como *UMA* (*Uniform Memory Access*).

Inicialmente, os sistemas simétricos estavam limitados aos ambientes de grande porte, restritos aos centros de pesquisas e às grandes corporações. Com a evolução dos computadores pessoais e das estações de trabalho, os sistemas operacionais para esses tipos de ambiente passaram a suportar vários multiprocessadores simétricos.

13.5.1 Evolução dos Sistemas Simétricos

Os *sistemas SMP* são uma evolução dos sistemas com múltiplos processadores assimétricos. Na organização *assimétrica* ou *mestre/escravo*, somente um processador, denominado mestre, pode executar serviços do sistema operacional, como, por exemplo, operações de E/S. Sempre que um processador do tipo escravo precisa realizar uma operação de E/S, tem de requisitar o serviço ao processador mestre. Dependendo do volume de operações de E/S destinadas aos processadores escravos, o sistema pode se tornar ineficiente, devido ao elevado número de interrupções que deverão ser tratadas pelo mestre.

Outra conseqüência dessa organização é que, se o processador mestre falhar, todo o sistema ficará incapaz de continuar o processamento. Neste caso, o sistema deve ser

reconfigurado, fazendo um dos processadores escravos assumir o papel de mestre. Mesmo sendo uma organização simples de implementar e uma extensão dos sistemas multiprogramáveis, esse tipo de sistema não é eficiente devido à assimetria dos processadores, que não realizam as mesmas funções.

Sistemas SMP, por outro lado, implementam a simetria dos processadores, ou seja, todos os processadores realizam as mesmas funções. Apenas algumas poucas funções ficam a cargo de um único processador, como, por exemplo, a inicialização do sistema. Os sistemas simétricos são mais poderosos que os assimétricos, permitindo um melhor balanceamento do processamento e das operações de E/S, apesar de sua implementação ser mais complexa. Atualmente, a grande maioria dos sistemas operacionais oferece suporte para SMP.

13.5.2 Arquitetura dos Sistemas Simétricos

A organização interna das unidades funcionais (processadores, memória principal e dispositivos de E/S) é fundamental no projeto de sistemas SMP, pois determina quantos processadores o sistema poderá suportar e como será o mecanismo de acesso à memória principal.

A forma mais simples de comunicação entre múltiplos processadores e outras unidades funcionais é interligar todos os componentes a um *barramento único*. O maior problema dessa organização é que somente uma unidade funcional pode estar utilizando o barramento em determinado instante, o que pode produzir um gargalo quando várias unidades tentam acessá-lo simultaneamente. Além disso, caso ocorra algum problema no barramento, todo o sistema fica comprometido (Fig. 13.3).

Apesar de ser uma arquitetura simples, econômica e flexível, sistemas desse tipo estão limitados a poucos processadores, dependendo da velocidade de transmissão do barramento. A maioria das arquiteturas que implementa o barramento único utiliza o esquema de cache para reduzir a latência das operações de acesso à memória

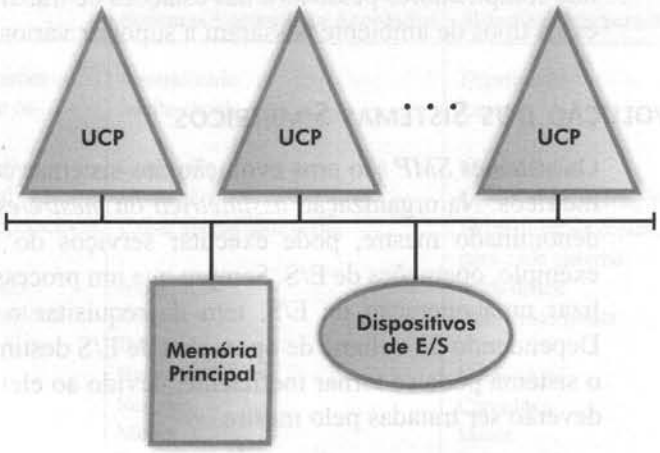

Fig. 13.3 Barramento único.

principal. Apesar de ser largamente utilizado, caches introduzem um novo problema, conhecido como *coerência de cache*. Nesse esquema, cada processador possui seu cache individual, para leitura e escrita de dados de maneira eficiente. Quando os dados são apenas para leitura, como instruções, não há problema que cada processador tenha sua própria cópia do dado, já que não haverá alteração. O problema aparece quando dois ou mais processadores desejam compartilhar um dado, não apenas para leitura, mas também para escrita, como no caso de uma variável (Fig. 13.4).

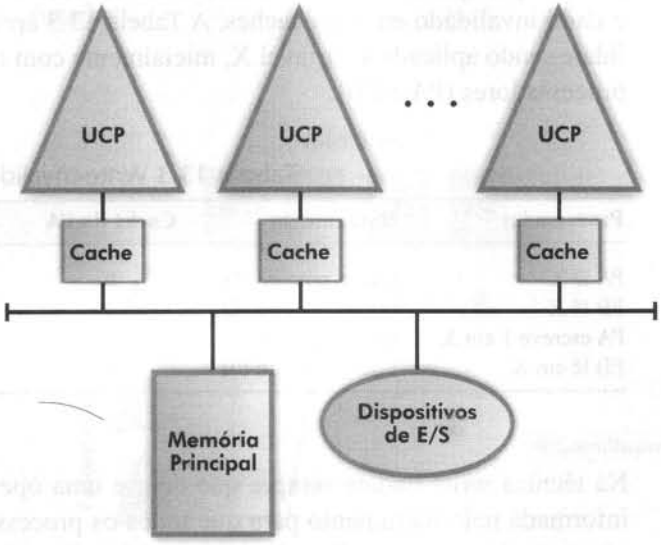

Fig. 13.4 Barramento único com cache.

Suponha que um processador PA leia uma variável X na memória e seu conteúdo seja copiado para o cache. Se o conteúdo da variável X for alterado, o cache terá um valor e a memória principal outro diferente, logo estarão inconsistentes. Caso um processador PB leia a mesma variável, PB terá no cache um valor que não é idêntico ao de PA. Uma solução simples para o problema apresentado é que, sempre que um dado no cache for alterado, a memória principal também seja atualizada. Este esquema é conhecido como *write-through* e, apesar de sua simplicidade, não oferece um bom desempenho, pois incorre em acesso à memória a cada operação de escrita, gerando, conseqüentemente, tráfego no barramento. Outro esquema amplamente empregado é conhecido como *write-back*, que permite alterar o dado no cache e não alterá-lo imediatamente na memória principal, oferecendo, assim, melhor desempenho, porém não resolvendo o problema da inconsistência.

A técnica mais utilizada para manter a coerência de cache é chamado de *snooping*, sendo implementada em hardware. Cada cache monitora o barramento, verificando se o endereço do dado que trafega no barramento está localmente armazenado. Caso o dado seja acessado apenas para leitura, não há problema de vários caches possuírem suas próprias cópias, mas caso seja um dado que possa ser alterado, a técnica de snooping deve garantir que os processadores obtenham a cópia mais recente.

Existem duas implementações para a técnica de snooping: *write-invalidate* (escreve-invalida) e *write-update* (escreve-atualiza). Na técnica write-invalidate, como o nome sugere, sempre que ocorre uma operação de escrita, todas as cópias do mesmo dado em outros caches são invalidadas e o novo valor é atualizado na memória principal. Nesse caso, apenas o processador que realizou a operação de escrita possuirá uma cópia válida do dado no cache. Os demais processadores, ao acessarem novamente o dado no cache, terão uma cópia inválida e o dado deverá ser transferido da memória principal paro o cache (*cache miss*). Se dois ou mais processadores tentarem realizar a escrita no dado ao mesmo tempo, deve existir um mecanismo que garanta que apenas um processador tenha sucesso na operação e os demais tenham o dado invalidado em seus caches. A Tabela 13.3 apresenta a técnica de write-invalidate sendo aplicada à variável X, inicialmente com o valor zero, e ao cache de dois processadores (PA e PB).

Tabela 13.3 Write-invalidate

Processador	Barramento	Cache do PA	Cache do PB	Memória
PA lê X	Cache miss do PA	0	–	0
PB lê X	Cache miss do PB	0	0	0
PA escreve 1 em X	Invalidação de X	1	–	1
PB lê em X	Cache miss do PB	1	1	1

Na técnica write-update sempre que ocorre uma operação de escrita, a alteração é informada pelo barramento para que todos os processadores que possuam a mesma cópia atualizem seu cache com o novo valor. Esta técnica oferece um desempenho inferior a técnica de write-invalidate, pois além do endereço do dado a ser atualizado deve também informar no barramento o seu novo valor. Por isso, a técnica de write-invalidate é empregada na grande maioria dos sistemas SMP. A Tabela 13.4 apresenta a técnica de write-update sendo aplicada à variável X, inicialmente com o valor zero, e ao cache de dois processadores (PA e PB).

Tabela 13.4 Write-update

Processador	Barramento	Cache do PA	Cache do PB	Memória
PA lê X	Cache miss do PA	0	–	0
PB lê X	Cache miss do PB	0	0	0
PA escreve 1 em X	Atualização de X	1	1	1
PB lê em X		1	1	1

A maioria dos sistemas comerciais com múltiplos processadores adota o esquema de write-back com a técnica de write-invalidate, a fim de reduzir o tráfego no barramento e permitir um número maior de processadores. Apesar de todas as técnicas apresentadas buscarem aumentar o número de processadores, a topologia de barramento único está limitada comercialmente a cerca de 64 UCPs.

Para evitar o problema do gargalo do barramento único, a memória principal pode ser dividida em módulos para permitir múltiplos acessos simultâneos, podendo assim ser compartilhada entre as várias unidades funcionais. As unidades funcionais podem ser conectadas entre si através de um *barramento cruzado comutado* (*cross-bar switch*), criando uma matriz de interconexão (Fig. 13.5). Nesse esquema, é possível a comunicação simultânea entre diferentes unidades funcionais, ficando a cargo do hardware e do sistema operacional a resolução dos possíveis conflitos de acesso a uma mesma unidade. Um exemplo de máquina que implementa esta arquitetura é o Sun Enterprise 10000, que pode suportar até 64 processadores UltraSPARC. As UCPs são agrupadas em nós de quatro processadores e interligadas através de 16 barramentos cruzados.

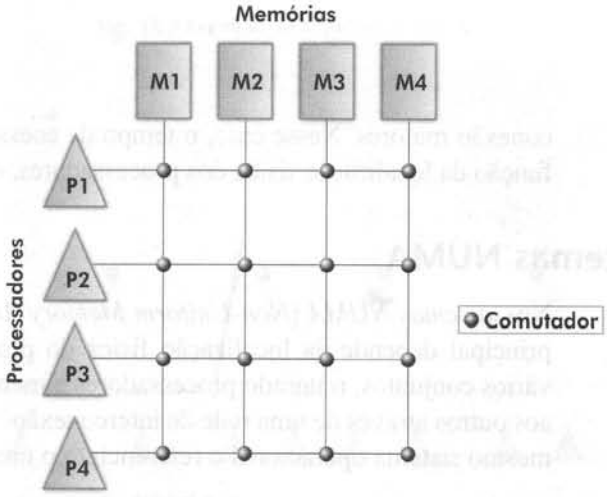

Fig. 13.5 Barramento cruzado comutado.

Em uma arquitetura de barramento cruzado, para cada n processadores e n módulos de memória são necessários n^2 comutadores para interligar todos os pontos. Em uma configuração onde n seja muito grande, o custo tende a ser muito alto.

Uma maneira de reduzir o número de comutadores é implementar uma *rede Ômega*. Nessa topologia, não existe uma ligação exclusiva entre cada processador e um módulo de memória; os caminhos são compartilhados entre as diversas unidades funcionais. Desta forma, é possível que um processador tenha que esperar para poder acessar um determinado módulo de memória devido à falta de um caminho disponível no momento. A grande vantagem dessa arquitetura é o seu menor custo, pois são necessários $(n \log_2 n)/2$ comutadores, número menor que o utilizado no barramento cruzado comutado (Fig. 13.6).

Apesar de a rede Ômega ser implementada com um número menor de comutadores, ainda é possível a qualquer processador acessar todos os módulos de memória utilizando a mesma técnica de comutação das redes de pacotes. Apesar do menor custo, redes Ômega podem introduzir o problema de latência, devido ao longo caminho percorrido entre o ponto de origem e o de destino, principalmente se considerarmos redes de inter-

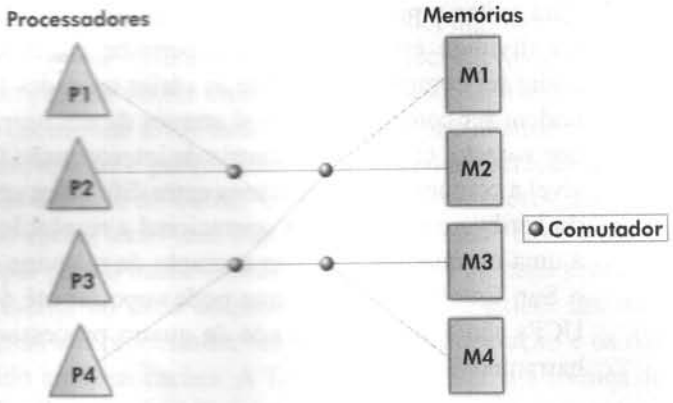

Fig. 13.6 Rede Ômega.

conexão maiores. Nesse caso, o tempo de acesso à memória poderá ser diferente em função da localização física dos processadores, originando os sistemas NUMA.

13.6 Sistemas NUMA

Nos *sistemas NUMA* (*Non-Uniform Memory Access*), o tempo de acesso à memória principal depende da localização física do processador. Nesta arquitetura, existem vários conjuntos, reunindo processadores e memória, sendo cada conjunto conectado aos outros através de uma rede de interconexão. Todos os conjuntos compartilham um mesmo sistema operacional e referenciam o mesmo espaço de endereçamento.

A diferença entre os sistemas NUMA e SMP está no desempenho das operações de acesso à memória. Na Fig. 13.7, é apresentado um exemplo de uma arquitetura NUMA, tendo cada conjunto três processadores e uma memória principal, conectados a um mesmo barramento interno. Os conjuntos são interligados através de um barramento interconjunto, criando um modelo hierárquico. Quando um processador faz um acesso local, ou seja, à memória dentro do mesmo conjunto, o tempo de acesso é muito menor que um acesso à memória remota em um outro conjunto. Para manter um nível de desempenho satisfatório, o sistema deve manter a maioria dos acessos locais, evitando acessos à memória remota.

O primeiro sistema NUMA, conhecido como Cm*, era formado por vários conjuntos de componentes, cada um com um processador, um módulo de memória principal e dispositivos de E/S opcionais, conectados por um barramento. Os conjuntos eram interconectados por um outro barramento único e cada conjunto possuía um controlador de memória que determinava se o endereço referenciado era local ou remoto. Se o endereço fosse local, o controlador simplesmente acessava o módulo de memória no mesmo barramento. Se o endereço fosse em um outro conjunto, o controlador local solicitava o acesso ao controlador do conjunto remoto, que, por sua vez, realizava a operação.

Existem diversas formas de interligar os vários conjuntos neste tipo de arquitetura, como as topologias em árvore tipo fat-tree, anel, grid 2D, torus 2D e hipercubo, tendo cada topologia um custo e um desempenho associados (Fig. 13.8).

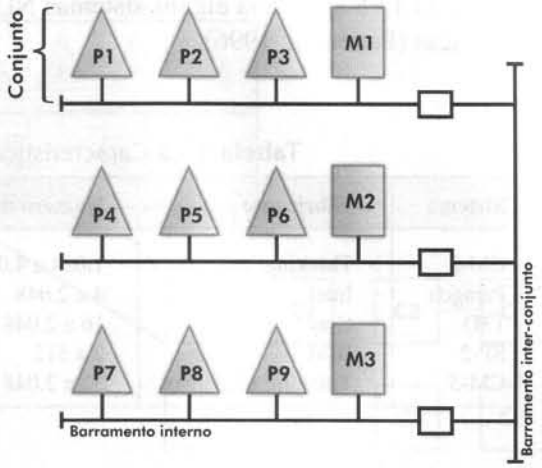

Fig. 13.7 Exemplo de arquitetura NUMA.

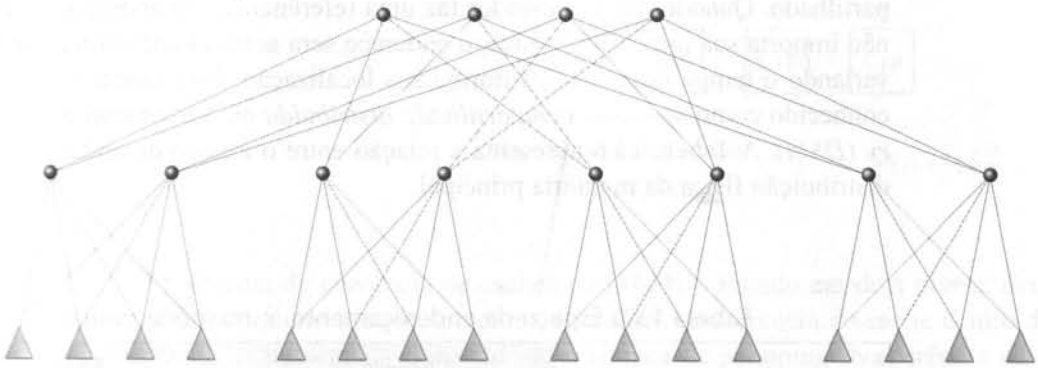

(a) Fat-tree

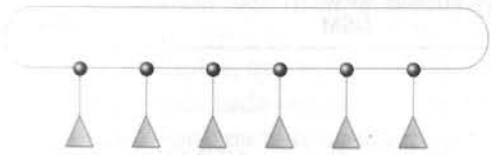

(b) Anel

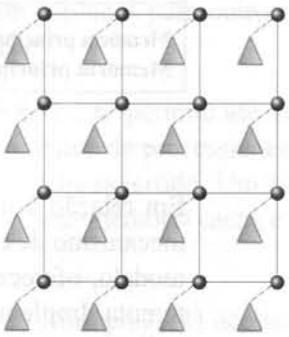

(c) Grid 2D

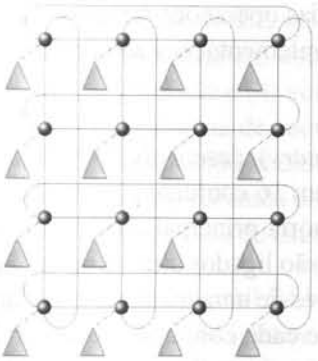

(d) Torus 2D

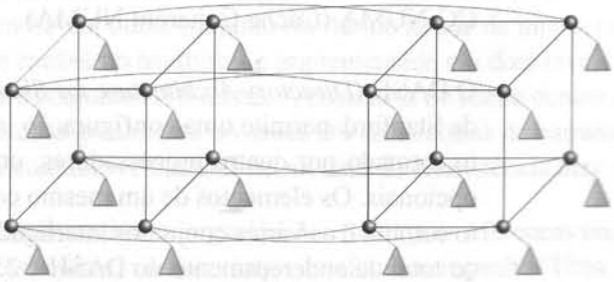

(e) Hipercubo

Fig. 13.8 Topologias NUMA.

A Tabela 13.5 apresenta alguns sistemas NUMA comerciais e suas principais características (Patterson, 1996).

Tabela 13.5 Características de sistemas NUMA

Sistema	Fabricante	Número de Processadores	Topologia
CM-2	Thinking Machines	1.024 a 4.096	Cubo
Paragon	Intel	4 a 2.048	Grid 2D
T3D	Cray	16 a 2.048	Torus 3D
SP-2	IBM	2 a 512	Árvore
CM-5	Thinking Machines	32 a 2.048	Árvore

Na arquitetura NUMA, a memória principal é fisicamente distribuída entre os vários processadores, porém existe apenas um único espaço de endereçamento sendo compartilhado. Quando um processador faz uma referência a um endereço de memória, não importa sua localização física, o endereço será acessado de forma transparente, variando o tempo de acesso conforme sua localização. Este modelo de memória é conhecido como *memória compartilhada distribuída* ou *Distributed Shared Memory* (*DSM*). A Tabela 13.6 apresenta a relação entre o espaço de endereçamento e a distribuição física da memória principal.

Tabela 13.6 Espaço de endereçamento × memória principal

	Espaço de Endereçamento Compartilhado	Espaço de Endereçamento Individual
Memória principal centralizada	SMP	N/A
Memória principal distribuída	DSM	Clusters e SOR

Em relação à memória, as primeiras arquiteturas NUMA não utilizavam qualquer mecanismo de cache. A ausência de cache, apesar de simplificar e reduzir o custo do modelo, oferece uma latência muito alta quando são realizados acessos à memória remota. Implementações mais recentes, como o DASH e o Multiplus (Aude, 1996), utilizam memória cache para reduzir a latência das operações remotas, mas introduzem o problema da coerência de cache. Estas implementações são conhecidas como CC-NUMA (Cache Coherent NUMA).

O DASH (*Directory Architecture for Shared Memory*), desenvolvido na Universidade de Stanford, permite uma configuração inicial com 16 conjuntos, sendo cada conjunto formado por quatro processadores, uma memória principal e dispositivos de E/S opcionais. Os elementos de um mesmo conjunto são ligados através de um barramento comum e os vários conjuntos interligados através de uma matriz retangular. O espaço total de endereçamento do DASH é 256 Mb, e cada conjunto possui um intervalo de 16 Mb desse espaço. A memória local de cada conjunto é dividida, por sua vez, em blocos de 16 bytes, produzindo um total de 1 Mb bloco por conjunto (Fig. 13.9).

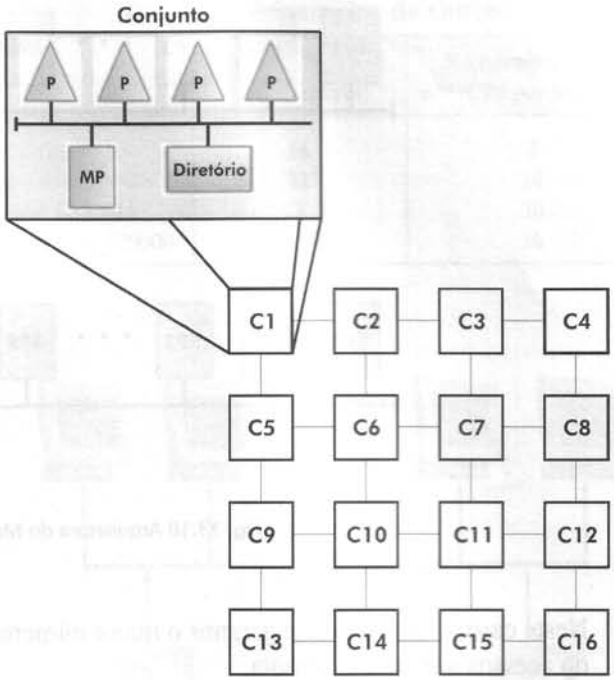

Fig. 13.9 Arquitetura DASH.

O problema de coerência de caches no DASH é tratado em dois níveis: dentro do mesmo conjunto e entre conjuntos diferentes. A coerência de cache dentro do conjunto é implementada utilizando-se a técnica de snooping. A coerência de caches entre conjuntos utiliza o esquema de diretórios. Para cada conjunto existe um diretório que mantém o controle dos blocos que foram copiados para outros conjuntos, permitindo identificar os blocos que estão em cache.

O Multiplus, que vem sendo desenvolvido na UFRJ/NCE, permite até 128 conjuntos, sendo cada conjunto formado por até oito elementos de processamento, conectados por uma rede de interconexão multiestágio n-cube invertido. Um elemento de processamento (EP) é formado por um processador, uma memória cache e um módulo de memória principal (Fig. 13.10).

Podem existir quatro tipos de acesso à memória no Multiplus: (1) acesso rápido ao cache do EP, (2) acesso à própria memória local do EP, (3) acesso a um módulo de memória em outro EP, porém dentro do mesmo conjunto sem o uso da rede de interconexão e (4) acesso a um EP em outro conjunto utilizando a rede de interconexão. O problema de coerência de caches no Multiplus é implementado em dois níveis: dentro do mesmo conjunto e entre conjuntos diferentes. A coerência de cache dentro do conjunto é tratada com as técnicas geralmente adotadas em arquiteturas de barramento. A coerência de caches entre conjuntos é baseada no modelo de consistência *lazy release*.

Sistemas NUMA são uma alternativa às organizações SMP, pois oferecem uma escalabilidade maior de processadores, menor custo e maior desempenho. Uma grande dificuldade em sistemas NUMA é manter um nível de desempenho satisfatório, devido a possibilidade de existirem tempos de acesso à memória principal bem diferentes.

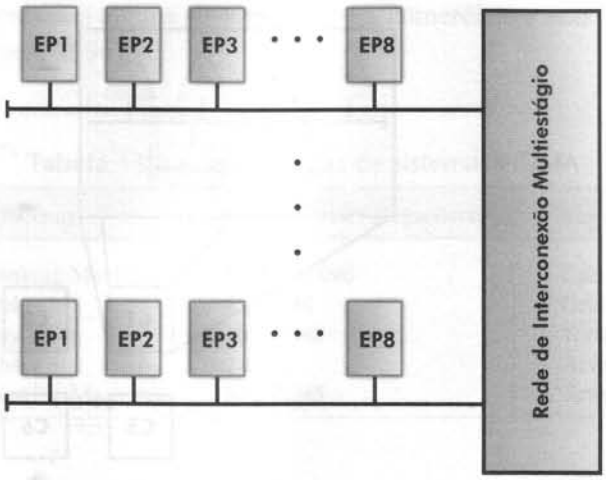

Fig. 13.10 Arquitetura do Multiplus.

Neste caso, o sistema deve garantir o maior número possível de acessos locais, evitando acessos à memória remota.

13.7 Clusters

Clusters são sistemas fracamente acoplados, formados por nós conectados por uma rede de interconexão de alto desempenho dedicada. Cada nó da rede é denominado membro do cluster, e possui seus próprios recursos, como processadores, memória, dispositivos de E/S e sistema operacional. Geralmente, os membros do cluster são de um mesmo fabricante, principalmente por questões de incompatibilidade dos sistemas operacionais.

O primeiro cluster comercial foi desenvolvido pela Digital Equipment Corporation (DEC) em 1983, com o nome de VAXcluster. A Tabela 13.7 apresenta alguns exemplos de clusters comerciais, com o número máximo de membros e processadores.

Cada membro do cluster possui seu próprio espaço de endereçamento individual, e a comunicação entre os membros se faz, na maioria das implementações, pelo mecanismo de troca de mensagens através da rede de interconexão. Inicialmente, os fabricantes utilizavam esquemas proprietários de interconexão, mas, atualmente, existem diversos padrões estabelecidos, como FDDI, Fibre Channel, ATM e Gigabit Ethernet.

Geralmente, a rede de interconexão é restrita aos membros do cluster, e o acesso aos serviços oferecidos é feito a partir de uma outra rede de acesso. A Fig. 13.11 apresenta um exemplo de cluster com dois membros (Membro 1 e Membro 2), conectados por uma rede de interconexão do tipo Gigabit Ethernet, enquanto a rede de acesso é uma rede local Ethernet 10/100. Os membros do cluster compartilham os dispositivos de armazenamento utilizando, por exemplo, o padrão SCSI ou alguma rede de armazenamento do tipo SAN (*Storage Area Network*).

A razão para o surgimento e a rápida aceitação de sistemas em cluster foi a maior necessidade de tolerância a falhas e a alta disponibilidade, de forma a reduzir o downtime. O downtime pode ser reduzido não apenas contornando problemas de hardware e software, mas também reduzindo o impacto de manutenções preventivas e

Tabela 13.7 Exemplos de clusters

Cluster	Número Máximo de Membros	Número Máximo de UCPs por Membro	Número Total de UCPs
HP 9000 EPS 21	16	4	64
IBM RS/6000 SP2	32	16	512
Sun Enterprise Cluster 6000 HA	2	30	60
Tandem NonStop Himalaya S70000	256	16	4096

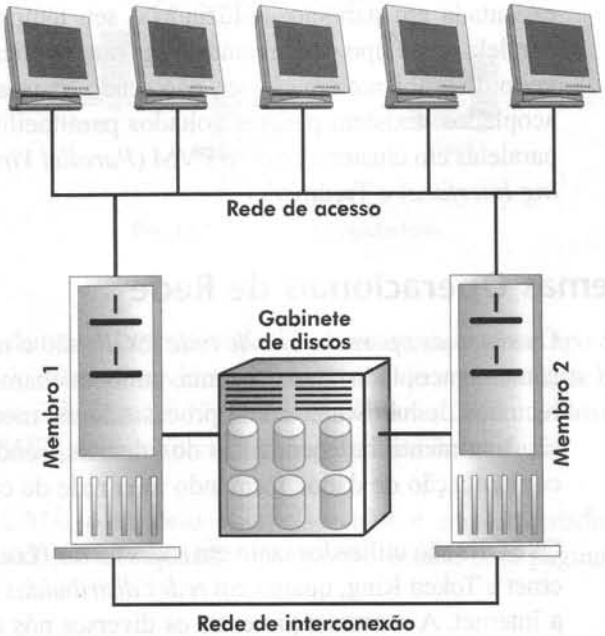

Fig. 13.11 Exemplo de cluster.

atualizações. Outras vantagens de um cluster são sua escalabilidade e o balanceamento de carga. Por essas razões, clusters são utilizados em servidores Web, sistemas de comércio eletrônico, servidores de banco de dados e soluções de firewall.

Quando um usuário tem acesso ao cluster, ele não tem conhecimento do número de membros que compõem o cluster e da identificação individual de cada membro. Para o usuário é como se ele estivesse acessando um único sistema fortemente acoplado. Esta característica, conhecida como imagem única do sistema, é implementada pelo sistema operacional juntamente com as aplicações que estão sendo processadas no ambiente. A maioria dos clusters implementa apenas parcialmente este conceito, principalmente quando o problema envolve o desenvolvimento de aplicações paralelas.

Quando ocorre uma falha em um dos membros do cluster, outro membro verifica o problema e assume as suas funções (*failover*). Após resolvido o problema, a situação inicial pode ser restaurada (*failback*). Para que o processo de failover seja efetivo, as aplicações processadas no ambiente devem ter sido desenvolvidas para utilizar os recursos oferecidos pelo cluster. Neste caso, se houver uma falha em um dos mem-

bros do cluster, o usuário não perceberá o problema, pois outro membro assumirá o processamento de forma transparente.

Sistemas em cluster permitem o compartilhamento de dispositivos de E/S, como impressoras, discos e fitas, independentemente do sistema que o usuário esteja conectado, o que permite melhor utilização dos recursos computacionais. Nesse tipo de configuração, se um dos membros falhar, o acesso aos dispositivos não será interrompido.

Além das vantagens apresentadas, clusters podem ser utilizados também para processamento paralelo. Neste ambiente, conhecido como *cluster farm*, uma aplicação pode ser dividida entre os vários membros do cluster, de forma que a aplicação possa ser executada em paralelo, reduzindo o seu tempo de processamento. A programação paralela nesse tipo de ambiente exige que a aplicação seja desenvolvida para tirar proveito do ambiente em cluster, não sendo transparente como nos sistemas fortemente acoplados. Existem pacotes voltados para facilitar o desenvolvimento de aplicações paralelas em clusters, como o PVM (*Parallel Virtual Machines*), MPI (*Message Passing Interface*) e Tredmarks.

13.8 Sistemas Operacionais de Rede

Os *sistemas operacionais de rede* (*SOR*) são o melhor exemplo de um ambiente fracamente acoplado. Cada sistema, também chamado host ou nó, possui seus próprios recursos de hardware, como processadores, memória e dispositivos de E/S. Os nós são totalmente independentes dos demais, sendo interconectados por uma rede de comunicação de dados formando uma rede de computadores (Fig. 13.12).

Os SORs são utilizados tanto em *redes locais* (*Local Area Network — LAN*), como Ethernet e Token Ring, quanto em *redes distribuídas* (*Wide Area Network — WAN*), como a Internet. A comunicação entre os diversos nós é feita por uma interface de rede que possibilita o acesso aos demais componentes da rede. A princípio, não existe um limite máximo para o número de nós que podem fazer parte de uma rede de computadores. A Fig. 13.13 apresenta as principais topologias utilizadas em redes de computadores.

Cada nó é totalmente independente dos demais, possuindo seu próprio sistema operacional e espaço de endereçamento. Os sistemas operacionais podem ser heterogêneos, bastando apenas que os nós comuniquem-se utilizando o mesmo protocolo de rede. Na Internet, cada host pode estar processando um sistema operacional diferente, mas todos estão se comunicando através do mesmo protocolo de rede, no caso, os protocolos da família TCP/IP (*Transmission Control Protocol/Internet Protocol*).

O usuário tem acesso aos recursos de outros computadores especificando o nome ou endereço do nó onde o recurso é oferecido. Nesse ambiente, cada estação pode compartilhar seus recursos com o restante da rede. Caso uma estação sofra qualquer problema, os demais componentes da rede podem continuar o processamento, apenas não dispondo dos recursos antes oferecidos. Não existe a idéia de imagem única do sistema, como também não existe a tolerência a falhas e a alta disponibilidade presente nos sistemas distribuídos.

A grande maioria dos SORs e seus protocolos de rede implementa o modelo *cliente/servidor*. Neste modelo, existem um ou mais servidores que oferecem serviços e respondem

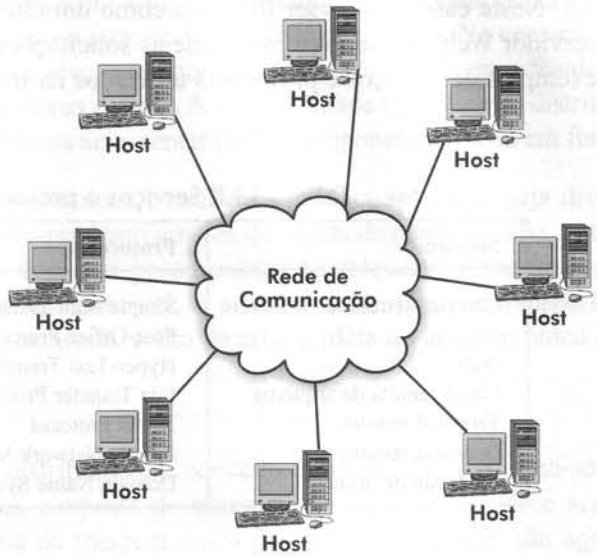

Fig. 13.12 Rede de computadores.

às solicitações dos demais clientes da rede. Um bom exemplo deste tipo de ambiente são as redes locais, onde existem servidores de arquivos, de impressão, de banco de dados, de correio eletrônico e de intranet. O Microsoft Windows 2000 e o Novell Netware são dois exemplos de SORs voltados para oferecer este tipo de serviço.

Não apenas em LANs o modelo cliente/servidor é implementado. Este tipo de ambiente pode ser observado quando um usuário acessa uma página Web na Inter-

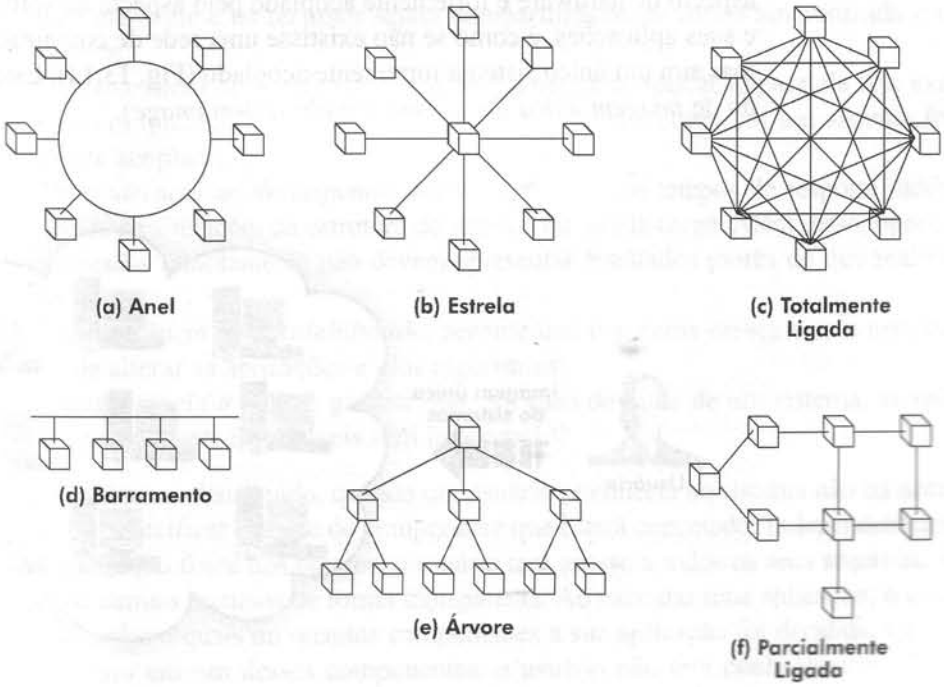

Fig. 13.13 Topologias de redes de computadores.

net. Neste caso, o browser funciona como um cliente que solicita informações, e o servidor Web, por sua vez, responde as solicitações. A Tabela 13.8 apresenta alguns exemplos de serviços e protocolos utilizados na Internet baseados neste modelo.

Tabela 13.8 Serviços e protocolos Internet

Serviços	Protocolos
Correio eletrônico	Simple Mail Transfer Protocol (SMTP) Post-Office Protocol (POP)
Web	Hyper-Text Transfer Protocol (HTTP)
Cópia remota de arquivos	File Transfer Protocol (FTP)
Terminal remoto	Telnet Protocol
Gerência remota	Simple Network Management Protocol (SNMP)
Tradução de nomes	Domain Name System (DNS)

13.9 Sistemas Distribuídos

Um *sistema distribuído* é um conjunto de sistemas autônomos, interconectados por uma rede de comunicação e que funciona como se fosse um sistema fortemente acoplado. Cada componente de um sistema distribuído possui seus próprios recursos, como processadores, memória principal, dispositivos de E/S, sistema operacional e espaço de endereçamento. Os tipos de sistemas operacionais que compõem um sistema distribuído não precisam ser necessariamente homogêneos.

O que diferencia um sistema distribuído dos demais sistemas fracamente acoplados é a existência de um relacionamento mais forte entre os seus componentes. Podemos definir um sistema distribuído como sendo um sistema fracamente acoplado pelo aspecto de hardware e fortemente acoplado pelo aspecto de software. Para o usuário e suas aplicações, é como se não existisse uma rede de computadores independente, mas sim um único sistema fortemente acoplado (Fig. 13.14). Este conceito é chamado de *imagem única do sistema* (*single system image*).

Fig. 13.14 Sistema distribuído.

Os componentes de um sistema distribuído podem estar conectados em um ambiente de uma rede local ou através de uma rede distribuída. Na verdade, a localização de um componente não deve constituir um fator a ser levado em consideração, bem como as características físicas da rede. A escalabilidade dos sistemas distribuídos é, a princípio, ilimitada, pois basta acrescentar novos componentes à rede em função da necessidade.

Os sistemas distribuídos permitem que uma aplicação seja dividida em diferentes partes, que se comunicam através de linhas de comunicação, podendo cada parte ser executada em qualquer processador de qualquer sistema (*aplicações distribuídas*). Para que isto seja possível, o sistema deve oferecer transparência e tolerância a falhas em vários níveis, a fim de criar a idéia de imagem única do sistema.

13.9.1 Transparência

Em sistemas distribuídos, o conceito de *transparência* torna-se fator-chave, pois, a partir dele, um conjunto de sistemas independentes parece ser um sistema único, criando a idéia da imagem única do sistema. A seguir, são apresentados os vários aspectos relativos à transparência em sistemas distribuídos:

- *Transparência de acesso*: é a possibilidade de acesso a objetos locais ou remotos de maneira uniforme;
- *Transparência de localização*: significa que o usuário não deve se preocupar onde estão os recursos de que necessita. Os recursos são acessados por nomes lógicos e não por nomes físicos, criando assim a independência da localização dos recursos;
- *Transparência de migração*: permite que os recursos sejam fisicamente movidos para outro sistema, sem que os usuários e suas aplicações seja afetados;
- *Transparência de replicação*: permite a duplicação de informações, com o objetivo de aumentar a disponibilidade e o desempenho do sistema, de forma sincronizada e consistente;
- *Transparência de concorrência*: permite que vários processos sejam executados paralelamente e os recursos sejam compartilhados de forma sincronizada e consistente;
- *Transparência de paralelismo*: possibilita que uma aplicação paralela seja executada em qualquer processador de qualquer sistema, como em um sistema fortemente acoplado;
- *Transparência no desempenho*: oferece aos usuários tempos de resposta independentes de alterações na estrutura do sistema ou na sua carga. Além disso, operações realizadas remotamente não devem apresentar resultados piores do que realizadas localmente;
- *Transparência de escalabilidade*: permite que o sistema cresça sem a necessidade de alterar as aplicações e seus algoritmos;
- *Transparência a falhas*: garante que, em caso de falha de um sistema, as aplicações continuem disponíveis sem interrupção.

Em um sistema distribuído, quando um usuário se conecta ao sistema não há necessidade de especificar o nome do componente que estará conectado. Independentemente da localização física dos objetos, o usuário terá acesso a todos os seus arquivos, diretórios e demais recursos de forma transparente. Ao executar uma aplicação, o usuário não saberá em quais ou quantos componentes a sua aplicação foi dividida. Caso um erro ocorra em um desses componentes, o usuário não terá conhecimento, ficando como responsabilidade do sistema operacional a resolução de todos os problemas.

13.9.2 Tolerância a Falhas

Para que um sistema distribuído possa oferecer transparência é preciso que o sistema implemente *tolerância a falhas* de hardware e, principalmente, de software. Neste caso, o sistema deve garantir que, em caso de problema em um de seus componentes, as aplicações continuem sendo processadas sem qualquer interrupção ou intervenção do usuário, de forma totalmente transparente.

A tolerância a falhas de hardware é facilmente oferecida utilizando-se componentes redundantes, como fontes duplicadas, vários processadores, memória com detecção e correção de erro e técnicas de RAID. Em sistemas distribuídos, a tolerância a falhas de hardware passa pela redundância dos meios de conexão entre os sistemas, como placas de rede, linhas de comunicação e dispositivos de rede.

A tolerância a falhas de software é bem mais complexa de implementar. Quando uma falha deste tipo ocorre, como uma falha no sistema operacional, a aplicação deve continuar sem que o usuário perceba qualquer problema. Enquanto em uma rede de computadores o usuário deverá se reconectar a um outro sistema em funcionamento e reiniciar sua tarefa, em um sistema distribuído o problema deve ser resolvido de forma transparente, mantendo a integridade e consistência dos dados.

Com a tolerância a falhas, é possível também oferecer alta disponibilidade e confiabilidade. Como existem sistemas autônomos, em caso de falha de um dos componentes um outro sistema poderá assumir suas funções, sem a interrupção do processamento. Como as aplicações estão distribuídas por diversos sistemas, caso ocorra algum problema com um dos componentes é possível que um deles assuma de forma transparente o papel do sistema defeituoso.

13.9.3 Imagem Única do Sistema

A maior dificuldade em implementar um sistema distribuído é a complexidade em criar para os usuários e suas aplicações uma imagem única do sistema a partir de um conjunto de sistemas autônomos. Para conseguir criar um ambiente fisicamente distribuído e logicamente centralizado é necessário um sistema operacional capaz de lidar com os diversos problemas de comunicação existentes em um ambiente fracamente acoplado. O sistema precisa oferecer tolerância a falhas de forma transparente, independente do tipo da rede de comunicação.

Um problema encontrado em sistemas fortemente acoplados é o compartilhamento de recursos de forma segura. Em sistemas distribuídos, a utilização de recursos concorrentemente exige mecanismos mais complexos e lentos para manter a integridade e a segurança dos dados.

Um dos grandes desafios para a adoção de sistemas distribuídos é a dificuldade no desenvolvimento de aplicações paralelas. Enquanto a programação em sistemas fortemente acoplados é relativamente transparente, em sistemas distribuídos o desenvolvimento não é tão simples. Apesar de algumas aplicações serem naturalmente paralelas, como ordenações e processamento de imagens, desenvolver aplicações distribuídas exige uma grande interação do programador com detalhes de codificação e escalonamento da aplicação.

13.10 Exercícios

1. Por que sistemas SMP que utilizam arquitetura em barramento único possuem sérias limitações quanto ao número de processadores?
2. Como o esquema de cache melhora o desempenho de sistemas SMP com topologia em barramento único?
3. Qual a diferença entre os mecanismos write-through e write-back para coerência de caches? Qual o mecanismo apresenta o melhor desempenho?
4. Qual a diferença entre os mecanismos write-invalidate e write-update para snoopping?
5. Um sistema com oito processadores precisaria de quantos comutadores em uma arquitetura de barramento cruzado? Este mesmo sistema precisaria de quantos comutadores em uma rede Ômega?
6. Quantos comutadores no máximo uma mensagem deve percorrer em um sistema com 256 processadores organizados em uma matriz 16 × 16?
7. Qual a diferença entre os sistemas SMP e NUMA?
8. Como os sistemas NUMA permitem um número maior de processadores?
9. O que são clusters e como são utilizados?
10. Defina o conceito de imagem única do sistema?
11. O que é transparência em sistemas distribuídos?
12. Considere um sistema com dois processadores (CPU1 e CPU2) e memória compartilhada. A fila de prontos é única e compartilhada entre os processadores. Neste sistema são criados 5 processos com as seguintes características:

Processo	Tempo de UCP	Prioridade	Tempo em que foi criado
P1	10	1	0
P2	6	7	2
P3	12	5	4
P4	11	2	6
P5	7	4	11

O tempo de escalonamento ou troca de contexto entre processos deve ser desconsiderado. No tempo 0, serão buscados processos na fila de prontos para execução nos processadores. A escolha da CPU1 sempre será prioritária sobre a CPU2 no momento do escalonamento. Desenhe um diagrama mostrando o que está acontecendo em cada um dos processadores até o término da execução dos cinco processos, calculando o tempo de turnaround dos processos e considerando os seguintes esquemas de escalonamento:

a) Circular com fatia de tempo igual a 5

b) Prioridade (número menor implica prioridade maior).

PARTE IV

ESTUDOS DE CASOS

"Quem abre uma escola, fecha uma prisão."

Victor Hugo

"A leitura faz o homem completo.

A história torna-o sábio e prudente;

A poesia, espiritual;

A matemática, sutil;

A filosofia, profundo;

A moral, grave;

A lógica e a retórica, apto para discutir.

Ler é conversar com os sábios."

Francis Bacon

14

WINDOWS 2000

14.1 Histórico

A Microsoft lançou em 1981 seu primeiro sistema operacional, o MS-DOS (Disk Operating System), para a linha de computadores pessoais IBM-PC, concebido para ser um sistema operacional de 16 bits, monoprogramável, monousuário e com uma interface de linha de comandos. O MS-DOS foi desenvolvido com base no sistema operacional CP/M e algumas idéias do Unix.

Em 1985, é lançada a primeira versão do MS-Windows, que introduz uma interface gráfica, porém mantém o MS-DOS como o sistema operacional. As versões posteriores do MS-Windows, como Windows 3.1, Windows 95/98 e Windows ME, apesar de várias melhorias e inovações, sempre estiveram associadas ao MS-DOS.

Devido as inúmeras limitações e deficiências do MS-DOS, a Microsoft começou a conceber no final da década de 1980 um novo sistema operacional, conhecido como Windows NT (New Technology). Este novo projeto foi conduzido por David Cutler, ex-projetista da Digital Equipment Corporation (DEC), que foi responsável pelo desenvolvimento de inúmeros sistemas operacionais, como o PDP/RSX e VAX/VMS. Além da grande influência do sistema operacional VMS, no projeto do Windows NT foram utilizados vários conceitos dos sistemas OS/2 e LAN Manager.

Em 1993, a Microsoft lança o Windows NT, sistema operacional de 32 bits, com multitarefa preemptiva, multithread, memória virtual e suporte a múltiplos processadores simétricos. O Windows NT não tem qualquer relação com a arquitetura do MS-DOS, mas oferece compatibilidade parcial com aplicações legadas. O Windows NT acompanhou a evolução da família DOS-Windows e incorporou algumas de suas características, como a interface gráfica. Com isso, passaram a existir duas linhas de sistemas operacionais da Microsoft com arquiteturas completamente distintas, porém com a mesma interface para o usuário (Fig. 14.1).

O Windows 2000 é uma evolução do Windows NT versão 4, pois mantém a mesma arquitetura interna. O Windows 2000 passou a incorporar alguns recursos da família DOS-Windows, como a função de plug-and-play. A grande novidade trazida pelo sistema é o Active Directory, que funciona como um serviço de diretórios e veio substituir o conceito de domínio existente no Windows NT.

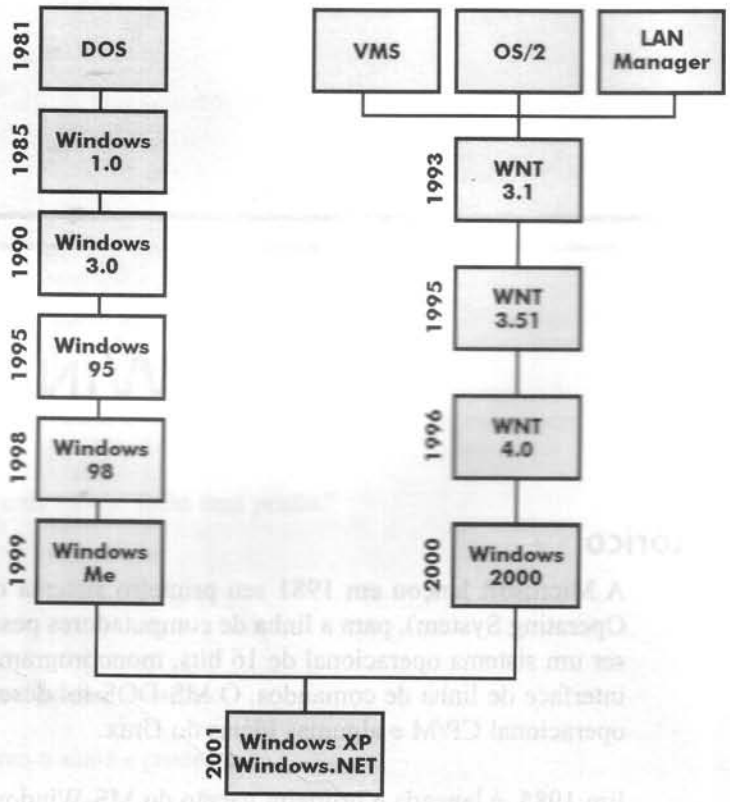

Fig. 14.1 Evolução do Windows.

O Windows XP, lançado em 2001, introduz uma nova interface gráfica e alguns poucos recursos adicionais, porém mantém a mesma arquitetura do Windows 2000. A partir do Windows XP, a intenção da Microsoft é descontinuar lentamente as famílias DOS-Windows e Windows NT/2000, integrando as duas linhas de sistemas operacionais.

14.2 Características

O Windows 2000 é um sistema operacional multiprogramável de 32 bits, que suporta escalonamento preemptivo, multithread, multiusuário, multiprocessamento simétrico (SMP) e memória virtual. Além dessas características, o sistema oferece:

- Serviços de diretórios, implementado através do Active Directory;
- Segurança baseada em Kerberos e nível de segurança C2;
- Suporte a aplicação MS-DOS, Win16, Win32, OS/2 e POSIX;
- Suporte aos protocolos NetBEUI, TCP/IP, NWLink e Apple Talk;
- Suporte a VPNs, NAT, OSPF e RIP;
- Suporte a plug-and-play;
- Suporte a RAID 0, 1 e 5;
- Suporte aos sistemas de arquivos FAT, FAT32 e NTFS;
- Compressão e criptografia de arquivos;
- Quotas em disco e desfragmentação.

O Windows 2000 foi lançado em duas versões: Windows 2000 Professional e Windows 2000 Server. O Windows 2000 Professional é direcionado ao mercado de estações de trabalho e computadores pessoais, enquanto o Windows 2000 Server é voltado para servidores de aplicações, arquivos, impressão e de banco de dados. A Microsoft criou três versões do Windows 2000 Server para atender diferentes tipos de aplicações: Server, Advanced Server e Datacenter Server.

As diferentes versões do Windows 2000 possuem a mesma arquitetura interna e interface gráfica. A diferença entre os sistemas está nos serviços oferecidos, escalabilidade e desempenho, em função dos diferentes segmentos de mercado em que cada um atua. A Tabela 14.1 apresenta uma comparação entre as principais características das diferentes versões do Windows 2000.

Tabela 14.1 Versões do Windows 2000

Versão	Máximo UCPs	Máximo Memória	Suporte a Cluster	Finalidade
Professional	2	4 GB	Não	Usuário final
Server	4	4 GB	Não	Pequenas aplicações
Advanced Server	8	8 GB	Sim	Aplicações médias
Datacenter Server	32	64 GB	Sim	Grandes aplicações

14.3 Estrutura do Sistema

O Windows 2000 possui mais de 29 milhões de linhas de código escritas, em sua maioria, em Linguagem C, porém com alguns módulos desenvolvidos em C++ e assembly. O sistema é estruturado combinando o modelo de camadas e o modelo cliente-servidor.

Embora não seja totalmente orientado a objetos, o Windows 2000 representa seus recursos internos como objetos. Essa abordagem diminui o impacto das mudanças que o sistema venha a sofrer no futuro, reduzindo o tempo e o custo de manutenção. Além disso, a criação, manipulação, proteção e compartilhamento de recursos pode ser feita de forma simples e uniforme. Quando um objeto é criado, um handle é associado ao objeto, permitindo o seu acesso e compartilhamento. A Tabela 14.2 apresenta alguns objetos implementados pelo sistema.

A arquitetura do Windows 2000 pode ser dividida em duas camadas: o subsistema protegido, que executa em modo usuário, e o núcleo do sistema propriamente dito, que executa em modo kernel. Na verdade, essas duas camadas podem ser subdivididas em outras camadas, como pode ser observado na Fig. 14.2.

Tabela 14.2 Objetos do Windows 2000

Objeto	Descrição
Processo	Ambiente para execução de um programa.
Thread	Unidade de execução em um processo.
Seção	Área compartilhada de memória.
Porta	Mecanismo para a troca de mensagens entre processos.
Token de acesso	Identificação de um objeto.
Evento	Mecanismo de sincronização entre processos.
Semáforo	Contador utilizado na sincronização entre processos.
Timer	Temporizador.

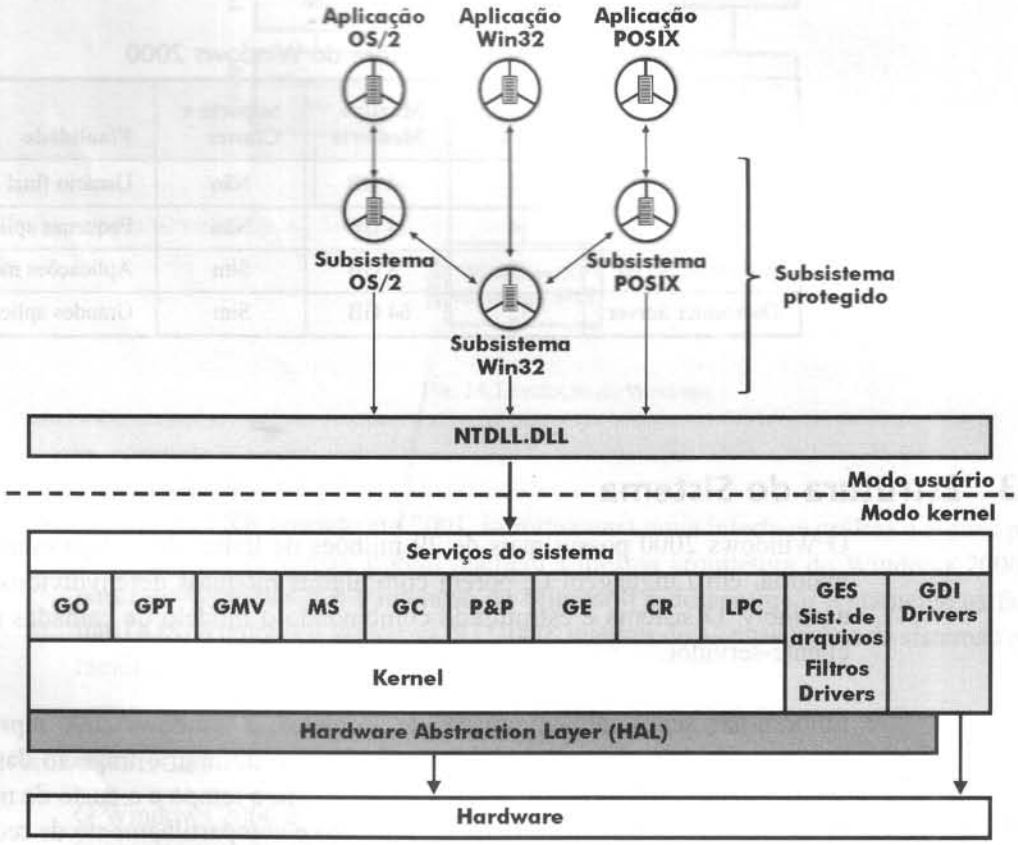

Fig. 14.2 Arquitetura do sistema.

- Hardware Abstraction Layer

O Hardware Abstraction Layer (HAL) é uma biblioteca que engloba a parte do código do sistema dependente do hardware, como acesso a registradores e endereçamento de dispositivos, identificação de interrupções, DMA, temporização, sincronização em ambientes com múltiplos processadores e interface com a BIOS e CMOS. Essa camada garante ao Windows 2000 uma facilidade muito grande de ser portado para diferentes plataformas de hardware.

- Kernel

O kernel é responsável por tornar o sistema operacional totalmente independente do hardware, implementando as demais funções não suportadas pelo HAL, como troca de contexto, escalonamento e dispatching, tratamento de interrupções e exceções, e suporte a objetos de uso interno do kernel, como DPC (Deferred Procedure Call), APC (Asynchronous Procedure Call) e dispatcher objects.

- Executivo

O executivo é a parte do núcleo totalmente independente do hardware. Suas rotinas podem ser agrupadas em categorias, em função do tipo de serviço que oferecem, como gerência de objetos (GO), gerência de processos e threads (GPT), gerência de memória virtual (GMV), monitor de segurança (MS), gerência de cache (GC), plug-and-play (P&P), gerenciamento de energia (GE), configuração do registry (CR), Local Procedure Call (LPC), gerência de E/S (GES) e Graphics Device Interface (GDI).

- Device Drivers

No Windows 2000, um device driver não manipula diretamente um dispositivo. Esta tarefa é função do HAL, que serve de interface entre o driver e o hardware. Esse modelo permite que a maioria dos device drivers sejam escritos em Linguagem C e, conseqüentemente, tenham grande portabilidade.

- Subsistema protegido

As aplicações que realizam chamadas às rotinas do sistema utilizam uma biblioteca, conhecida como Win32 Application Program Interface (API). Diferente da maioria dos sistemas operacionais, uma aplicação Windows não pode realizar uma chamada diretamente a uma rotina do sistema utilizando uma system call, mas sempre fazendo uso de uma Win32 API. As APIs funcionam como uma interface entre a aplicação e as system calls propriamente ditas, que por sua vez fazem as chamadas às rotinas do sistema operacional. Enquanto as APIs do Windows 2000 são amplamente documentadas, as system calls não são inteiramente conhecidas.

As APIs são implementadas utilizando DLLs (Dynamic Link Libraries) e o subsistema Win32. Uma DLL é uma biblioteca de procedimentos, geralmente relacionados, que são linkados à aplicação apenas em tempo de execução. Esse tipo de biblioteca compartilhada evita que aplicações que utilizem os mesmos procedimentos tenham sua própria cópia individual das rotinas na memória principal. Existem três formas de o sistema tratar as APIs: (a) a DLL pode tratar diretamente uma API não chamando rotinas do sistema; (b) a DLL pode chamar uma outra DLL, que realiza chamadas a rotinas do sistema; (c) a DLL pode chamar o subsistema Win32.

Até a versão do Windows NT 3.51, o subsistema Win32 concentrava um grande número de rotinas do sistema, principalmente as relacionadas com a parte gráfica, obrigando que as DLLs sempre chamassem o subsistema Win32. Como grande parte do código do sistema estava sendo executada no ambiente de um processo em modo usuário, o Windows NT chegou a ser considerado um exem-

plo de arquitetura microkernel. A partir do Windows NT 4.0, por questões de desempenho, a maioria dessas rotinas foram portadas para dentro do núcleo do sistema, formando o Graphics Device Interface (GDI). Com isso, apenas algumas poucas rotinas permaneceram no subsistema Win32, reduzindo a necessidade de chamadas a esse subsistema.

Além do Win32 API, que serve de interface para aplicações Windows, o subsistema protegido ainda oferece suporte para aplicações POSIX e OS/2, através do subsistema POSIX e subsistema OS/2, respectivamente. Na prática, o que esses dois subsistemas implementam são chamadas ao subsistema Win32, que serve de interface com o sistema operacional. Em função de suas limitações, poucas aplicações podem ser portadas utilizando os subsistemas POSIX e OS/2, tornando-os pouco úteis.

14.4 Processos e Threads

Processos no Windows 2000 são objetos criados e eliminados pelo gerente de objetos, representados internamente por uma estrutura chamada EPROCESS (Executive Process Block). Ao ser criado, um processo possui, dentre outros recursos do sistema, um espaço de endereçamento virtual, uma tabela de objetos, um token de acesso e pelo menos um thread (Fig. 14.3).

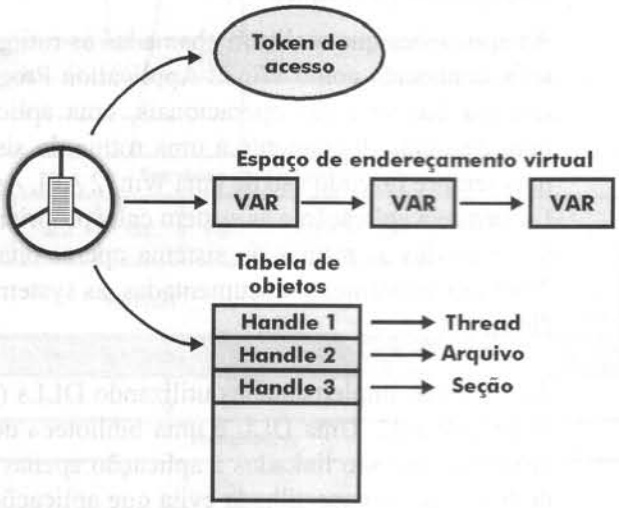

Fig. 14.3 Estrutura do processo.

O espaço de endereçamento virtual é formado por descritores, conhecidos como VARs (Virtual Address Descriptors), que permitem que a alocação do espaço de endereçamento seja feita dinamicamente, conforme as referências aos endereços virtuais. A tabela de objetos contém handles para cada objeto que o processo tem acesso. Um handle é criado quando o processo cria um novo objeto ou solicita acesso a um já existente. O token de acesso identifica o processo para o sistema operacional e sempre que o processo tem acesso a um recurso do sistema, o token é utilizado para

determinar se o acesso é permitido. Cada processo é criado com um único thread, mas threads adicionais podem ser criados e eliminados quando necessários.

Threads também são implementados como objetos, sendo criados e eliminados pelo gerenciador de objetos e representados por uma estrutura chamada ETHREAD (Executive Thread Block). Todos os threads de um processo compartilham o mesmo espaço de endereçamento virtual e todos os recursos do processo, incluindo o token de acesso, prioridade base, tabela de objetos e seus handles.

O Windows 2000 escalona apenas threads para execução e não processos. A Tabela 14.3 apresenta os diferentes estados possíveis de um thread, enquanto a Fig. 14.4 apresenta as mudanças de estado de um thread durante sua existência.

Tabela 14.3 Estados de um thread

Estado	Descrição
Criação	Criação e inicialização do thread.
Espera	O thread aguarda por algum evento, como uma operação de E/S.
Execução	O thread está sendo executado.
Pronto	O thread aguarda para ser executado.
Standby	O thread foi escalonado e aguarda pela troca de contexto para ser executado. Somente um thread pode estar no estado de standby para cada processador existente.
Terminado	Quando um thread termina sua execução, o sistema o coloca no estado de terminado, porém o objeto pode ou não ser eliminado.
Transição	O thread aguarda que suas páginas gravadas em disco sejam lidas para a memória principal.

Além de processos e threads, o Windows 2000 implementa os conceitos de job e fiber. Um job é uma coleção de processos que guardam alguma relação e devem ser gerenciados como uma unidade. Processos em um job compartilham quotas e privilégios, como o número máximo de processos que podem ser criados e o espaço máximo alocado na memória principal.

O Windows 2000 implementa threads em modos usuário e kernel. Threads em modo kernel, denominados simplesmente threads, apresentam problemas de desempenho devido à necessidade de troca de modo de acesso usuário-kernel-usuário. Threads em modo usuário, denominados fibers, eliminam as trocas de contexto e de modo de acesso e, conseqüentemente, oferecem melhor desempenho. Cada thread pode ter múltiplos fibers, da mesma forma que um processo pode ter múltiplos threads. O sistema operacional desconhece a existência dos fibers, ficando a cargo da própria aplicação o seu escalonamento.

A Tabela 14.4 apresenta algumas APIs utilizadas para a criação, eliminação, comunicação e sincronização de processos, threads e fibers.

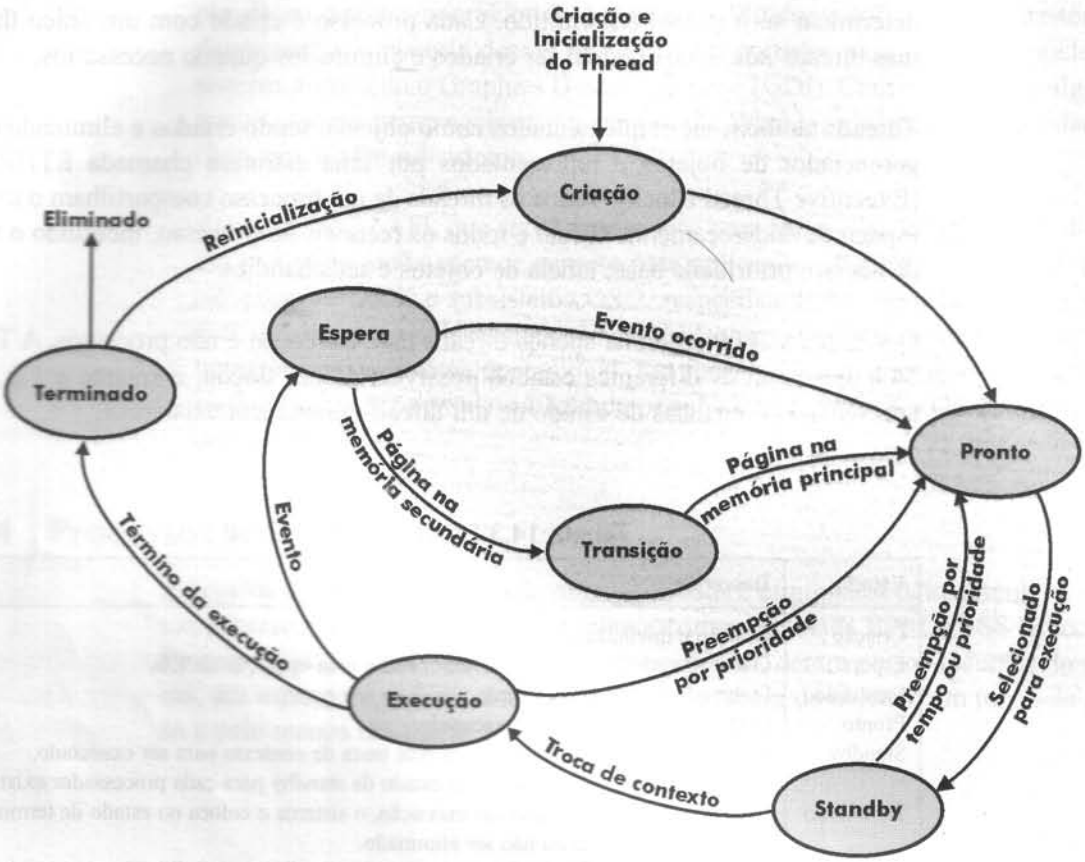

Fig. 14.4 Mudanças de estado de um thread.

Tabela 14.4 APIs para a gerência de processos, threads e fibers

API	Descrição
CreateProcess	Cria um processo.
CreateThread	Cria um thread no processo corrente.
CreateRemoteThread	Cria um thread em um outro processo.
CreateFiber	Cria um fiber no processo corrente.
OpenProcess	Retorna um handle para um determinado processo.
GetCurrentProcessID	Retorna a identificação do processo corrente.
ExitProcess	Finaliza o processo corrente e todos seus threads.
TerminateProcess	Termina um processo.
ExitThread	Finaliza o thread corrente.
TerminateThread	Termina um thread.
CreateSemaphore	Cria um semáforo.
OpenSemaphore	Retorna um handle para um determinado semáforo.
WaitForSingleObject	Espera que um único objeto, como um semáforo, seja sinalizado.
WaitForMultipleObjects	Espera que um conjunto de objetos sejam sinalizados.
EnterCriticalSection	Sinaliza que a região crítica está sendo executada.
LeaveCriticalSection	Sinaliza que a região crítica não está mais sendo executada.

14.5 Gerência do Processador

O Windows 2000 suporta dois tipos de política de escalonamento: escalonamento circular com prioridades e escalonamento por prioridades. O código de escalonamento é implementado no kernel do sistema. Não existe uma rotina única para o escalonador, pois seu código está espalhado pelo kernel. As rotinas que executam essas tarefas são chamadas genericamente de kernel dispatcher.

A política de escalonamento é implementada associando prioridades aos processos e threads. Inicialmente, o thread recebe a prioridade do processo ao qual pertence, podendo ser alterada posteriormente. O escalonamento é realizado considerando apenas os threads no estado de pronto, e os processos servem apenas como unidade de alocação de recursos.

O Windows 2000 implementa 32 níveis de prioridades, divididos em duas faixas: escalonamento de prioridade variável (1-15) e escalonamento de tempo real (16-31). A prioridade zero serve apenas para que um thread especial do sistema (zero page) seja executado quando não existirem threads prontos para execução. Threads com a mesma prioridade são organizados em filas no esquema FIFO, e o primeiro thread na fila de maior prioridade será sempre selecionado para execução. Caso um thread fique pronto com prioridade maior que o thread em execução, ocorrerá a preempção por prioridade (Fig. 14.5).

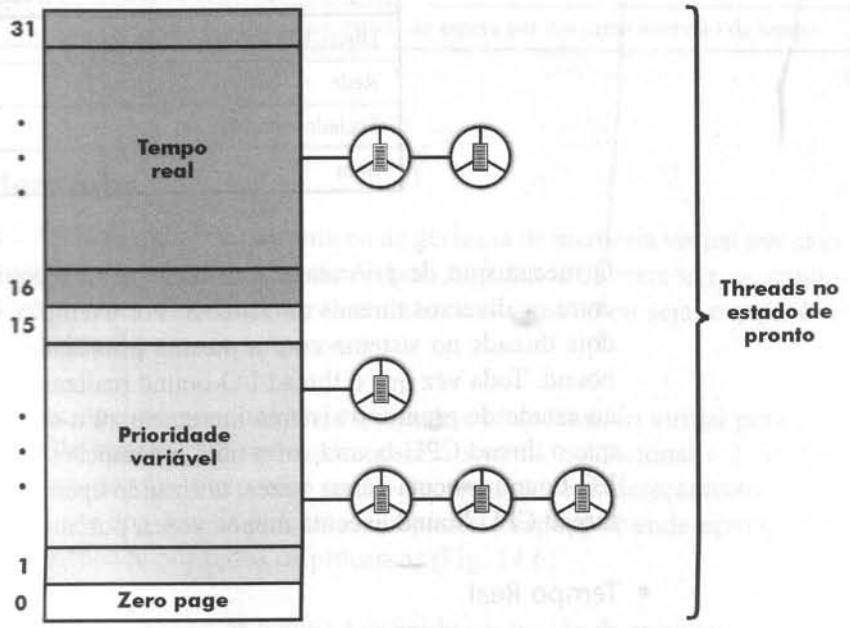

Fig. 14.5 Níveis de prioridade.

A seguir, são apresentados os dois esquemas de escalonamento implementados pelo Windows 2000:

- Prioridade Variável

No esquema de prioridade variável (1-15) é adotada a política de escalonamento circular com prioridades. O thread de maior prioridade é selecionado e recebe uma fatia de tempo para ser executado. Terminado este quantum, o thread sofre preempção por tempo e retorna para o estado de pronto no final da fila associada à sua prioridade.

O escalonamento de prioridade variável utiliza dois tipos de prioridades para cada thread: base e dinâmica. A prioridade base é normalmente igual à do processo e não sofre alteração durante a existência do thread. Por outro lado, a prioridade dinâmica é sempre igual ou maior que a prioridade base e varia de acordo com as características do thread, sendo controlada pelo sistema. O escalonamento é realizado em função da prioridade dinâmica dos threads.

A prioridade dinâmica é aplicada exclusivamente aos threads que passam pelo estado de espera. Por exemplo, sempre que um thread realiza uma operação de E/S, o sistema o coloca no estado de espera. No momento em que o thread é transferido para o estado de pronto, a prioridade base do thread é acrescida de um valor em função do tipo de operação realizada, ou seja, a prioridade dinâmica é resultado da soma da prioridade base mais um incremento (Tabela 14.5). O incremento não é cumulativo e a prioridade dinâmica nunca poderá ultrapassar o limite máximo da prioridade variável, ou seja, prioridade 15.

Tabela 14.5 Incremento na prioridade base

Tipo de Operação de E/S	Incremento
Disco, CD e vídeo	1
Rede	2
Teclado e mouse	6
Som	8

O mecanismo de prioridade dinâmica permite equilibrar o uso do processador entre os diversos threads no sistema. Por exemplo, suponha que existam apenas dois threads no sistema com a mesma prioridade, um CPU-bound e outro I/O-bound. Toda vez que o thread I/O-bound realizar uma operação de E/S e retornar ao estado de pronto, o sistema incrementará a sua prioridade base, fazendo com que o thread CPU-bound sofra uma preempção. Dessa forma, enquanto o thread I/O-bound executa várias vezes, utilizando apenas parte da sua fatia de tempo, o thread CPU-bound executa menos vezes, porém utilizando todo o seu quantum.

- Tempo Real

No esquema de tempo real (16-31), é adotada a política de escalonamento por prioridades. Existem duas grandes diferenças no esquema de tempo real se com-

parado ao de prioridade variável: o conceito de fatia de tempo e a prioridade dinâmica.

Os threads no estado de execução são processados o tempo que for necessário, não existindo fatia de tempo. Neste caso, um thread é interrompido apenas por processos mais prioritários, ou seja, quando sofre uma preempção por prioridade. Além disso, os threads não têm aumentos de prioridade, sendo as prioridades base e dinâmica sempre iguais.

Esta faixa de prioridade deve ser utilizada apenas por threads do sistema operacional por questões de segurança. Se qualquer thread com prioridade acima de 15 entrar em loop, todos os threads com prioridades entre 1 e 15 nunca serão executados.

Os dois níveis de escalonamento apresentados permitem ao Windows 2000 oferecer características de sistemas de tempo compartilhado e tempo real dentro do mesmo ambiente, tornado-o versátil e possibilitando sua utilização por diferentes tipos de aplicações. A Tabela 14.6 apresenta algumas APIs relacionadas ao escalonamento de threads.

Tabela 14.6 APIs de escalonamento

API	Descrição
SuspendThread	Coloca o thread no estado de espera.
ResumeThread	Permite que o thread volte para o estado de pronto.
SetPriorityClass	Permite alterar a prioridade base do processo.
SetThreadPriority	Permite alterar a prioridade base do thread.
SetThreadPriorityBoost	Permite oferecer um incremento de prioridade temporário ao thread.
Sleep	Coloca o thread em estado de espera por um certo intervalo de tempo.

14.6 Gerência de Memória

O Windows 2000 implementa o mecanismo de gerência de memória virtual por paginação, com espaço de endereçamento de 32 bits. A gerência de memória, ao contrário do escalonamento, lida com processos e não com threads, ou seja, o espaço de endereçamento virtual pertence ao processo.

O sistema operacional proporciona um espaço de endereçamento virtual para cada processo de 4 Gb, sendo 2 Gb reservados para o sistema operacional e 2 Gb para aplicações do usuário. Cada processo tem o seu espaço de endereçamento virtual único, independente dos demais processos, enquanto o espaço de endereçamento do sistema é compartilhado por todos os processos (Fig. 14.6).

No Windows 2000, o tamanho da página é definido em função da arquitetura do processador, possibilitando páginas entre 4 e 64 Kb. No processador Pentium da Intel, as páginas possuem 4 Kb. O mapeamento é realizado utilizando tabelas de páginas

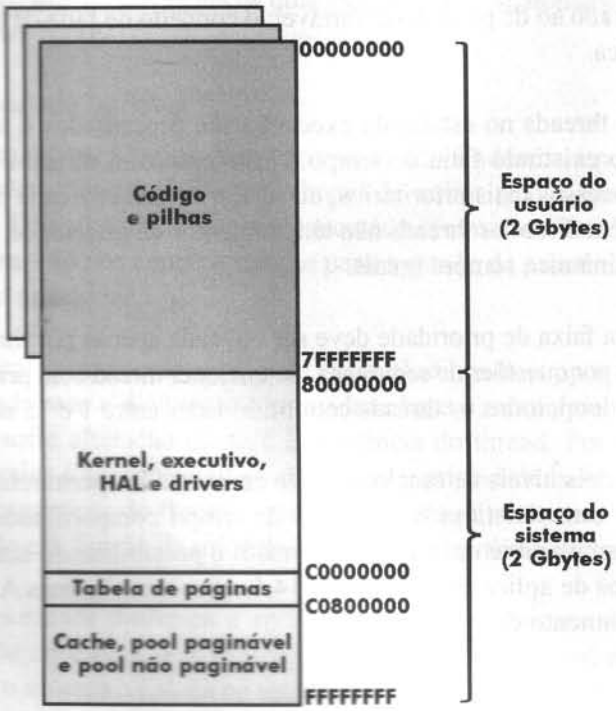

Fig. 14.6 Espaço de endereçamento virtual.

em dois níveis: a tabela de primeiro nível (page directory index) aponta para tabelas de segundo nível (page table index), que por sua vez apontam para os frames na memória principal (Fig. 14.7). O endereço real é obtido combinando-se o endereço do frame e o deslocamento (byte index).

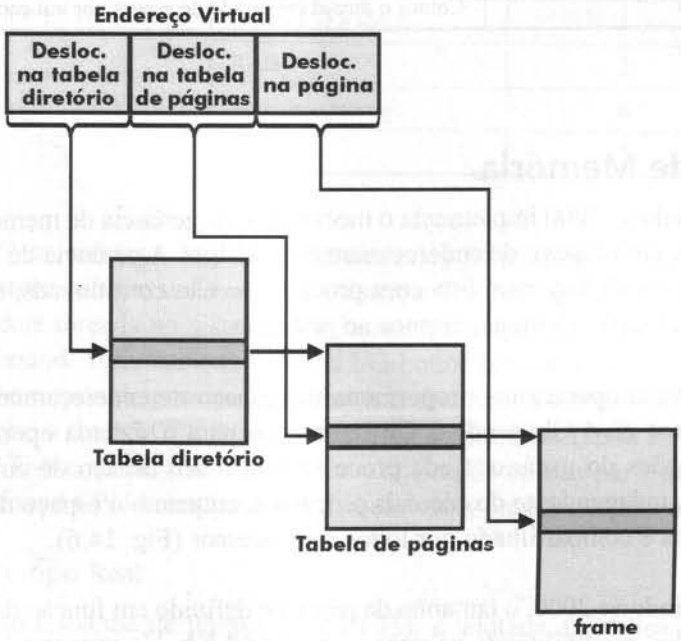

Fig. 14.7 Mapeamento.

Cada página da memória virtual gera uma entrada na tabela de páginas denominada *page table entry* (PTE). O PTE possui, entre outras informações, um bit que indica se a página associada está ou não na memória principal (*valid bit*), um bit que indica se a página foi alterada (*dirty bit*) e bits que permitem implementar a proteção da página.

A gerência de memória permite que dois ou mais processos compartilhem a mesma área de código ou dados na memória principal. Não existe nenhum mecanismo automático de controle de acesso a essa região, ficando como responsabilidade de cada processo a sincronização, para evitar conflitos. Além disso, é possível mapear um arquivo residente em disco na memória principal e compartilhá-lo entre diversos processos. As aplicações podem ler e gravar registros diretamente na memória principal, evitando operações de E/S em disco.

O Windows 2000 implementa o esquema de paginação por demanda como política de busca de páginas. Quando ocorre um *page fault*, o sistema carrega para a memória principal a página referenciada e um pequeno conjunto de páginas próximas (cluster de páginas), na tentativa de reduzir o número de operações de leitura em disco e melhorar o desempenho do sistema (Fig. 14.8a). O tamanho do cluster de páginas varia conforme o tamanho da memória principal e se a página lida for de código ou dados.

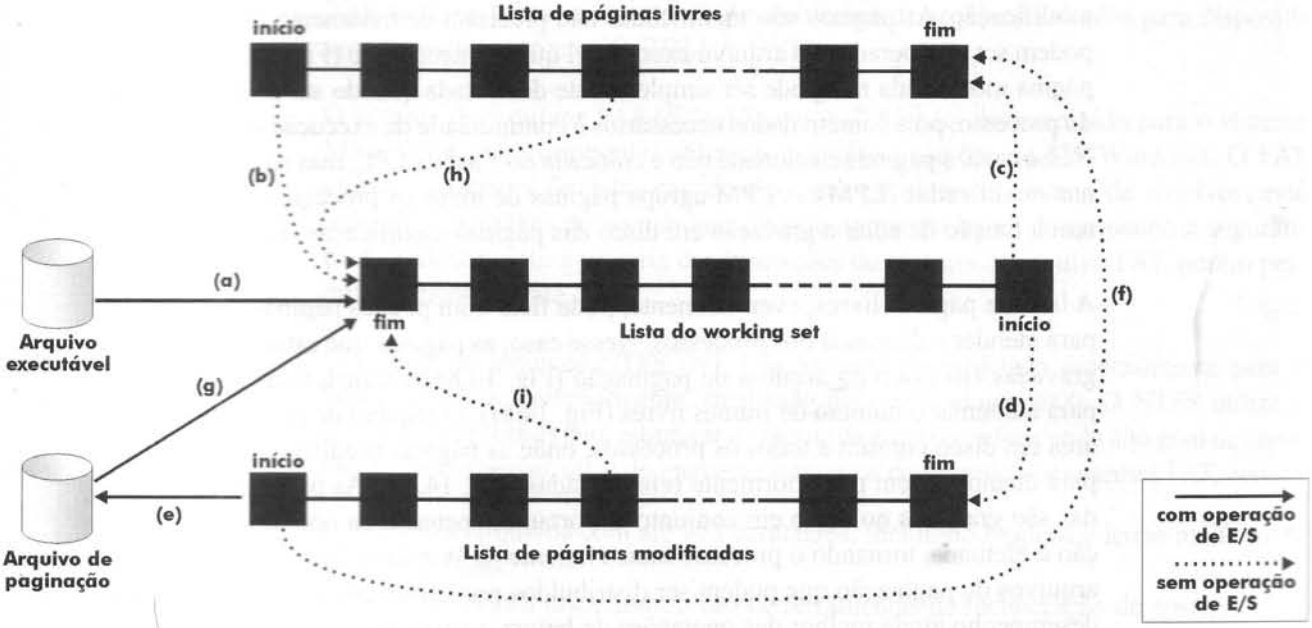

Fig. 14.8 Gerência de memória.

Quando um programa é executado, apenas parte de seu código e de seus dados está na memória principal. Segundo conceito definido pela Microsoft, o conjunto de frames que um processo possui na memória principal é denominado *working set*. As páginas pertencentes ao processo são mantidas em uma estrutura chamada lista do working set, organizada no esquema FIFO. O tamanho do working set varia confor-

me a taxa de paginação do processo e da disponibilidade de frames na memória principal. Os tamanhos mínimo e máximo do working set são definidos na criação do processo, mas podem ser alterados durante a sua existência. É importante ressaltar que o conceito de working set no Windows 2000 não é idêntico ao apresentado no Capítulo 10, Gerência de Memória Virtual.

O Windows 2000 implementa o esquema FIFO com buffer de páginas como política de substituição de páginas. De forma simplificada, o sistema possui duas listas que funcionam como buffers: a lista de páginas livres (*free page list*) e a lista de páginas modificadas (*modified page list*). As listas de páginas têm a função de reduzir a taxa de page faults dos processos e, principalmente, o número de operações de leitura e gravação em disco.

A lista de páginas livres (LPL) agrupa todos os frames disponíveis para uso na memória principal. Quando um processo necessita de uma nova página e seu working set não atingiu o seu limite máximo, o sistema retira a primeira página da LPL e adiciona ao final da lista do working set do processo (Fig. 14.8b). Por outro lado, quando o working set do processo alcança seu limite máximo, o processo deve ceder a página mais antiga no seu working set para a LPL, antes de receber uma nova página (Fig. 14.8c). Como pode ser observado, a política de substituição de páginas é local, afetando apenas o processo que gerou o page fault.

O destino da página selecionada para substituição vai depender de a página sofrer modificação. As páginas não modificadas não precisam de tratamento especial, pois podem ser recuperadas do arquivo executável quando necessário (Fig. 14.8a). Já uma página modificada não pode ser simplesmente descartada quando sai do working set do processo, pois contém dados necessários à continuidade da execução do programa. Nesse caso, a página selecionada não é colocada no final da LPL, mas na lista de páginas modificadas (LPM). A LPM agrupa páginas de todos os processos no sistema e tem a função de adiar a gravação em disco das páginas modificadas (Fig. 14.8d).

A lista de páginas livres, eventualmente, pode ficar com poucas páginas disponíveis para atender a demanda dos processos. Nesse caso, as páginas que estão na LPM são gravadas em disco no arquivo de paginação (Fig. 14.8e) e transferidas para a LPL para aumentar o número de frames livres (Fig. 14.8f). O arquivo de paginação é uma área em disco comum a todos os processos, onde as páginas modificadas são salvas para quando forem posteriormente referenciadas (Fig. 14.8g). As páginas modificadas são gravadas no disco em conjunto e, portanto, apenas uma operação de gravação é efetuada, tornando o processo mais eficiente. O Windows 2000 permite até 16 arquivos de paginação que podem ser distribuídos por vários discos, permitindo um desempenho ainda melhor das operações de leitura e gravação.

A LPL, além de agrupar os frames disponíveis da memória principal, permite também reduzir o impacto do algoritmo FIFO utilizado na política de substituição de páginas. Quando o sistema libera uma página do working set de um processo para a LPL, esta página não é imediatamente utilizada, pois o frame deverá percorrer a lista até chegar ao seu início. Desta forma, as páginas que saem do working set permanecem na memória por algum tempo, permitindo que essas mesmas páginas possam retornar ao working set do processo. Nesse caso, na ocorrência de um page fault, o

sistema poderá encontrar o frame requerido na LPL, gerando um page fault sem a necessidade de uma operação de leitura em disco (Fig. 14.8h). Por outro lado, quando o frame não é encontrado na LPL, o sistema é obrigado a realizar uma operação de leitura em disco para obter novamente a página referenciada (Fig. 14.8a). De forma semelhante, quando uma página modificada é referenciada, o frame pode estar na LPM, dispensando uma operação de leitura em disco (Fig. 14.8i). Caso contrário, o frame deverá ser lido do arquivo de paginação em disco (Fig. 14.8g).

Periodicamente, o sistema verifica o tamanho da LPL. Caso o número de páginas esteja abaixo de um limite mínimo, o tamanho do working set dos processos é reduzido de forma a liberar páginas para a LPL (*working set trimming*). Inicialmente, o sistema seleciona os processos com grandes working sets e que estão inativos por mais tempo ou que apresentem baixas taxas de paginação.

Para controlar todas as páginas e listas na memória principal, a gerência de memória mantém uma base de dados dos frames na memória (*page frame database*), com informações sobre todas as páginas livres e utilizadas.

14.7 Sistema de Arquivos

O Windows 2000 suporta três tipos de sistemas de arquivos: FAT, FAT32 e NTFS. Cada sistema determina como os arquivos e diretórios são organizados, o formato dos nomes dos arquivos, desempenho e segurança de acesso aos dados. O Windows 2000 também oferece suporte a outros sistemas de arquivos voltados para dispositivos específicos, como CD-ROMs e DVDs.

O sistema de arquivos FAT (*File Allocation Table*) foi desenvolvido para o sistema MS-DOS e, posteriormente, utilizado nas várias versões do MS-Windows. O FAT utiliza o esquema de listas encadeadas para estruturar o sistema de arquivos, está limitado a partições de no máximo 2 Gb, e apresenta baixo desempenho e segurança. O FAT32 possui a maioria das limitações do sistema de arquivo FAT, porém permite partições de até 2 Tb.

O sistema de arquivos NTFS (NT File System) foi projetado especialmente para o Windows NT e, posteriormente, atualizado para o Windows 2000. O NTFS utiliza o esquema de árvore-B para estruturar o sistema de arquivos, oferecendo alto grau de segurança e desempenho, além de inúmeras vantagens comparado aos sistemas FAT, como:

- nomes de arquivos com até 255 caracteres, incluindo brancos e letras maiúsculas e minúsculas;
- partições NTFS dispensam o uso de ferramentas de recuperação de erros;
- proteção de arquivos e diretórios por grupos e ACLs;
- criptografia e compressão de arquivos;
- suporte a volumes de até 2^{64} bytes;
- ferramentas de desfragmentação e gerência de quotas em disco;
- suporte a Unicode;
- suporte a RAID 0, RAID 1 e RAID 5.

O NTFS trabalha com volumes que são partições lógicas de um disco físico. Um volume pode representar todo o espaço de um disco ou apenas parte do disco físico.

Além disso, em um mesmo disco podem ser configurados vários volumes com diferentes sistemas de arquivos, como NTFS e FAT. Esse esquema de particionamento permite o boot de diferentes tipos e versões de sistemas operacionais a partir de um único disco físico.

Um disco, quando formatado, é dividido em setores que são agrupados em clusters. O cluster é uma unidade de alocação de espaço em disco e seu tamanho varia em função do volume, ou seja, quanto maior o volume, maior o tamanho cluster. O tamanho do cluster influencia na fragmentação interna do volume. Na Fig. 14.9, um volume NTFS pode ser visualizado como uma seqüência de clusters de quatro setores, identificados por um Logical Cluster Number (LCN).

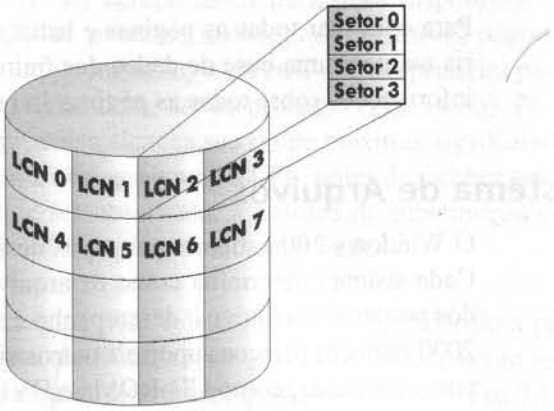

Fig. 14.9 Estrutura lógica do disco.

A estrutura de um volume NTFS é implementada a partir de um arquivo chamado Master File Table (MFT), formado por diversos registros de 1 Kb. A Fig. 14.10 apresenta a estrutura do MFT, onde os registros de 0 a 15 são utilizados para mapear os arquivos de controle do sistema de arquivos (arquivos de metadados) e os demais registros são utilizados para mapear arquivos e diretórios de usuários. O registro 0 do arquivo mapeia o próprio MFT.

Os registros no MFT, apesar de possuírem o mesmo tamanho, apresentam formatos diferentes. Um registro possui um header, que identifica o registro, seguido por um ou mais atributos. Cada atributo é formado por um par de cabeçalho e valor. O cabeçalho identifica o que o valor representa. O NTFS define 13 tipos diferentes de atributos que podem aparecer em um registro, como nome do arquivo, descritor de segurança e dados do arquivo. No caso de arquivos pequenos, todos os seus atributos, inclusive os dados, podem estar presentes no próprio registro no MFT (Fig. 14.11). No entanto, para a maioria dos arquivos, seus atributos podem ultrapassar facilmente o tamanho do registro, sendo colocados em clusters no disco (*nonresident attributes*).

Um arquivo em disco é formado por uma seqüência de clusters não necessariamente contíguos no disco. Por questões de desempenho, sempre que possível, o sistema tentará alocar todos os clusters que compõem o arquivo seqüencialmente no disco.

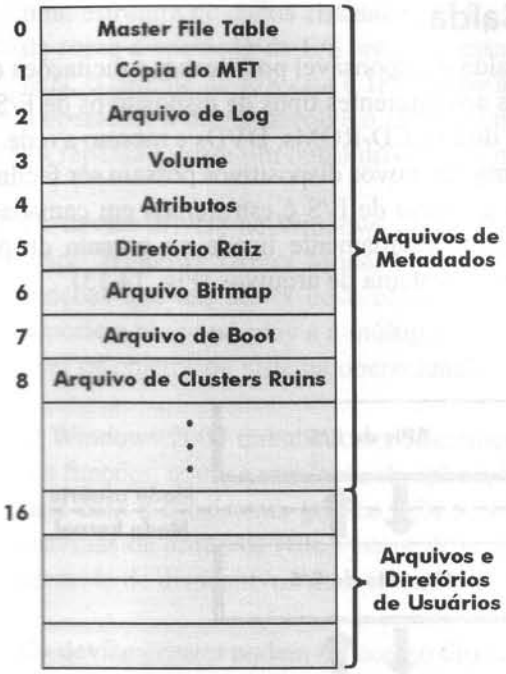

Fig. 14.10 Master File Table.

Fig. 14.11 Exemplo de registro para um pequeno arquivo.

Quando não for possível o arquivo será formado por vários conjuntos de clusters contíguos, sendo cada conjunto chamado de *extent*. O número de extents indica o grau de fragmentação do arquivo. Para mapear os extents de um arquivo, o NTFS registra no MFT a posição inicial do extent no disco, utilizando o LCN, e quantos clusters contíguos compõem o extent. A Fig. 14.12 ilustra o exemplo de um arquivo formado por três extents. Caso o número de extents do arquivo ultrapasse o tamanho do registro no MFT, um ou mais registros adicionais podem ser utilizados.

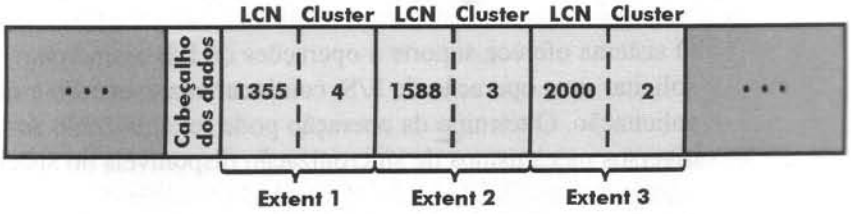

Fig. 14.12 Exemplo de registro de um arquivo.

14.8 Gerência de Entrada/Saída

A gerência de entrada/saída é responsável por receber solicitações de E/S dos diversos threads e repassá-las aos diferentes tipos de dispositivos de E/S, como teclados, impressoras, monitores, discos, CD-ROMs, DVDs e mesmo a rede. O subsistema de E/S foi projetado de forma que novos dispositivos possam ser facilmente conectados ao sistema. Para isso, a gerência de E/S é estruturada em camadas e interage com outros subsistemas, estando intimamente ligada ao gerente de plug-and-play, de energia e de cache, além do sistema de arquivos (Fig. 14.13).

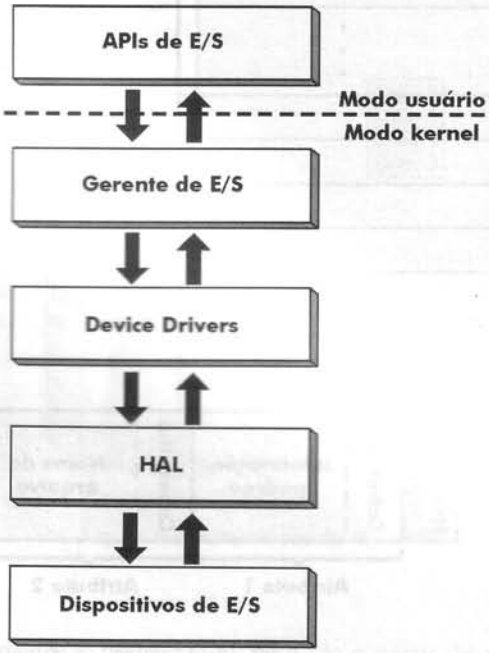

Fig. 14.13 Gerência de E/S.

O Windows 2000 oferece centenas de APIs relacionadas à gerência de E/S, sendo a maior parte ligadas ao subsistema gráfico, chamado Graphics Device Interface (GDI). O GDI é um conjunto de rotinas que permite a uma aplicação manipular dispositivos gráficos, como monitores e impressoras, independente do tipo do dispositivo físico, funcionando como uma interface entre a aplicação e os drivers dos dispositivos. O GDI oferece funções de gerenciamento de janelas, menus, caixas de diálogo, cores, desenhos, textos, bitmaps, ícones e clipboard.

O sistema oferece suporte a operações de E/S assíncronas, ou seja, um thread pode solicitar uma operação de E/S, continuar sua execução e depois tratar o término da solicitação. O término da operação pode ser sinalizado ao thread utilizando um dos diversos mecanismos de sincronização disponíveis no sistema.

O gerente de E/S (I/O Manager) é responsável por receber os pedidos de operações de E/S e repassá-los aos device drivers. Cada solicitação de E/S é representada por

uma estrutura de dados chamada I/O Request Packet (IRP), que permite o controle de como a operação de E/S será processada. Quando uma operação de E/S é solicitada, o gerente de E/S cria o IRP, passa a estrutura para o device driver. Terminada a operação, o driver devolve o IRP para o gerente de E/S para completar a operação ou repassá-lo para um outro driver para continuar o processamento.

Os device drivers no Windows 2000 são desenvolvidos a partir de um padrão chamado Windows Driver Model (WDM). O WDM define diversas características e funções que um driver deve oferecer para ser homologado pela Microsoft, como suporte a plug-and-play e a múltiplos processadores, gerência de energia e interface com os objetos do sistema operacional.

O Windows 2000 trabalha com diferentes tipos de drivers para implementar diversas funções, como a emulação de aplicações MS-DOS (virtual device drivers), interface com o subsistema gráfico GDI (display e printer drivers), implementação dos sistemas de arquivos (file system drivers), funções de filtragem (filter drivers) e o controle de dispositivos de E/S (hardware device drivers).

Os device drivers podem ter acesso diretamente ao dispositivo de E/S, como em um driver de disco, ou podem trabalhar em camadas, separando funções ou implementando funções complementares. Por exemplo, as operações de compressão, criptografia e tolerância a falhas de discos são implementadas através de drivers específicos (filter driver) acima dos drivers ligados aos dispositivos de E/S. Os sistemas de arquivos NTFS e FAT também são implementados através de drivers especiais que recebem solicitações do gerente de E/S e as repassam para os drivers de disco correspondentes.

15

UNIX

15.1 Histórico

Na década de 1960, inúmeros esforços foram direcionados para o desenvolvimento de um verdadeiro sistema operacional de tempo compartilhado que viesse a substituir os sistemas batch da época. Em 1965, o MIT (Massachusetts Institute of Technology), a Bell Labs e a General Electric se uniram para desenvolver o MULTICS (MULTiplexed Information and Computing Service). Em 1969, a Bell Labs retirou-se do projeto, porém um de seus pesquisadores envolvido no projeto, Ken Thompson, desenvolveu sua própria versão do sistema operacional, que veio a se chamar UNICS (UNiplexed Information and Computing Service) e, posteriormente, Unix.

O Unix foi inicialmente desenvolvido em assembly para um minicomputador PDP-7 da Digital. Para torná-lo mais fácil de ser portado para outras plataformas, Thompson desenvolveu uma linguagem de alto nível chamada B e reescreveu o código do sistema nessa nova linguagem. Em função das limitações da linguagem B, Thompson e Dennis Ritchie, também da Bell Labs, desenvolveram a linguagem C, na qual o Unix seria reescrito e, posteriormente, portado para um minicomputador PDP-11 em 1973.

No ano seguinte, Ritchie e Thompson publicaram o artigo "The Unix Timesharing System" (Ritchie e Thompson, 1974) que motivou a comunidade acadêmica a solicitar uma cópia do sistema. Na época, a Bell Labs era uma subsidiária da AT&T e, mesmo tendo criado e desenvolvido o Unix, não podia comercializá-lo devido às leis americanas antimonopólio, que impediam seu envolvimento no mercado de computadores. Apesar dessa limitação, as universidades poderiam licenciar o Unix, recebendo inclusive o código fonte do sistema. Como a grande maioria das universidades utilizava computadores da linha PDP-11, não existiam dificuldades para se adotar o sistema como plataforma padrão no meio acadêmico.

Uma das primeiras instituições de ensino a licenciar o Unix foi a Universidade de Berkeley na Califórnia. A Universidade desenvolveu sua própria versão do sistema, batizada de 1BSD (First Berkeley Software Distribution), seguida por outras versões, chegando até a 4.4BSD, quando o projeto acadêmico foi encerrado. O Unix de Berkeley introduziu inúmeros melhoramentos no sistema, merecendo destaque o

mecanismo de memória virtual, C shell, Fast File System, sockets e o protocolo TCP/IP. Em função dessas facilidades, vários fabricantes passaram a utilizar o BSD como base para seus próprios sistemas, como a Sun Microsystems e a Digital. Para dar continuidade ao desenvolvimento do Unix de Berkeley, foi criada a Berkeley Software Design que, posteriormente, lançaria o sistema FreeBSD.

Em 1982, a AT&T foi autorizada a comercializar o sistema que tinha desenvolvido. A primeira versão lançada foi a System III, logo seguida pela System V. Diversas versões foram posteriormente desenvolvidas, sendo a versão System V Release 4 (SVR4) a que merece maior importância. Vários fabricantes basearam seus sistemas no Unix da AT&T, como a IBM, a HP e a SCO. Em 1993, o Unix da AT&T é comercializado para a Novell, que, posteriormente, lança o UnixWare, com base nesse sistema. No mesmo ano, a Novell transfere os direitos sobre a marca Unix para o consórcio X/Open e, posteriormente, vende o UnixWare para a SCO.

Em 1991, o finlandês Linus Torvalds começou o desenvolvimento do Linux, com base em suas experiências com o sistema Minix. O Minix foi desenvolvido pelo professor Andrew Tanenbaum, da Universidade Vrije, na Holanda, com fins apenas educacionais e pode ser obtido livremente, incluindo o código fonte (Minix, 2002). O Linux evolui a partir da colaboração de vários programadores que ajudaram no desenvolvimento do kernel, utilitários e vários aplicativos. Atualmente, o Linux é utilizado para fins tanto acadêmicos como comerciais e pode ser obtido sem custos acompanhado do seu código fonte (Linux, 2002). No Brasil, existe o sistema Tropix, desenvolvido pelos pesquisadores Oswaldo Vernet e Pedro Salenbauch do Núcleo de Computação Eletrônico da Universidade Federal do Rio de Janeiro. O código fonte do Tropix está disponível na Internet gratuitamente (Tropix, 2002).

Várias tentativas foram feitas visando unificar as versões do Unix de Berkeley (BSD) e da AT&T (System V), além das inúmeras outras implementações oferecidas pelo mercado. A AT&T publicou um conjunto de especificações, conhecidas como System V Interface Definition. Fabricantes ligados à vertente do Unix da AT&T fundaram a Unix International, enquanto os ligados ao Unix de Berkeley criaram a Open Software Foundation (OSF). Nenhuma dessas iniciativas resultou na padronização de um único Unix.

A tentativa de unificação do Unix mais importante nesse sentido foi dada pelo IEEE (Institute of Electrical and Electronics Engineers) através do seu comitê POSIX (Portable Operating System Unix). Como resultado desse trabalho, surgiu o padrão IEEE 1003.1, publicado em 1990, estabelecendo uma biblioteca padrão de chamadas e um conjunto de utilitários que todo sistema Unix deveria oferecer. Em 1995, o X/Open cria o UNIX95, um programa para garantir uma especificação única do Unix. Posteriormente, o consórcio passa a chamar-se The Open Group e lança a terceira versão de sua especificação, incluindo o padrão POSIX e representantes da indústria.

A Fig. 15.1 apresenta a evolução das duas principais vertentes do Unix e alguns dos sistemas operacionais derivados das versões da AT&T e de Berkeley (Lévénez, 2002). Atualmente, diversas versões do Unix são encontradas não só no meio acadêmico, mas também sendo comercializadas por inúmeros fabricantes, como a Sun

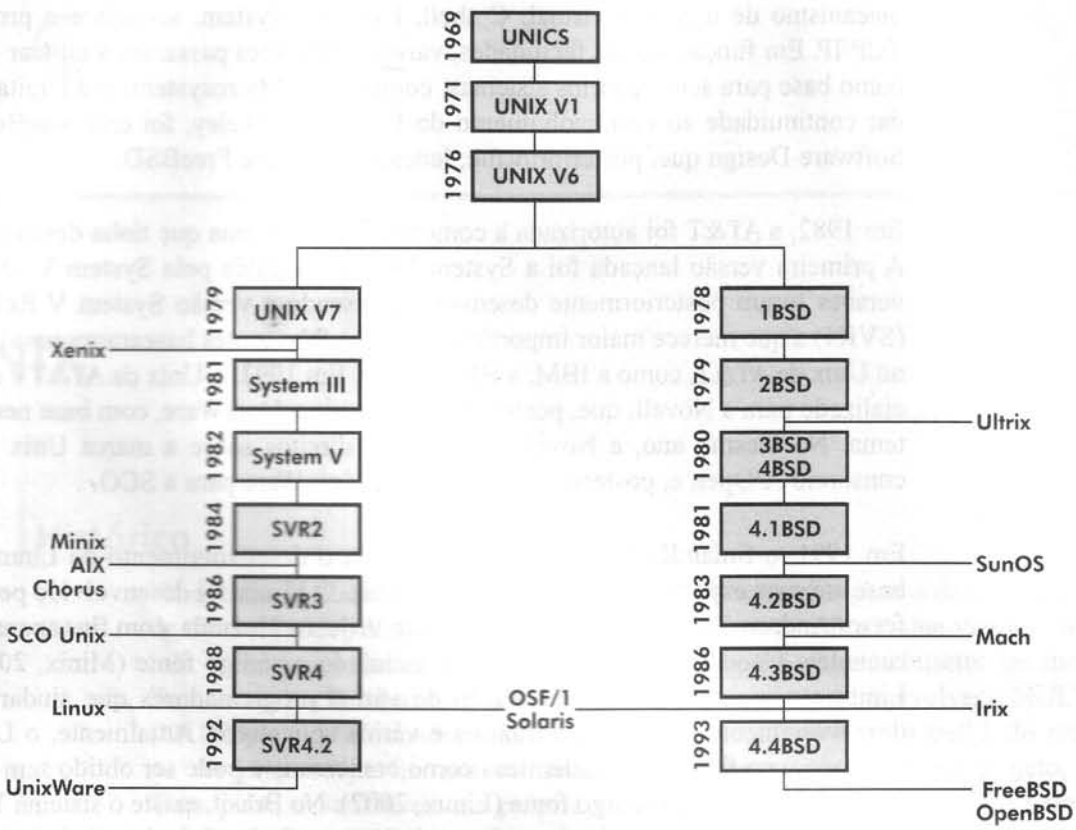

Fig. 15.1 Evolução do Unix.

Microsystems (SunOS e Solaris), HP (HP-UX), IBM (AIX) e Compaq (Compaq Unix).

As implementações do sistema Unix variam conforme suas versões, plataformas de hardware e fabricantes, principalmente se comparadas às versões originais de Berkeley e da AT&T. No decorrer deste capítulo, será apresentada uma visão geral do sistema, sem entrar em detalhes das diferentes versões.

15.2 Características

O sistema operacional Unix é um sistema multiprogramável, multiusuário, que suporta múltiplos processadores e implementa memória virtual. Entre as muitas razões para explicar o sucesso alcançado pelo Unix, incluem-se as características a seguir:

- Escrito em uma linguagem de alto nível, tornando fácil a compreensão e alteração do seu código e portabilidade para outras plataformas de hardware;
- Oferece um conjunto de system calls que permite que programas complexos sejam desenvolvidos a partir de uma interface simples;
- Flexibilidade, podendo ser utilizado como sistema operacional de computadores pessoais, estações de trabalho e servidores de todos os portes, voltados para banco de dados, Web, correio eletrônico e aplicação;

- Implementação de threads, em algumas versões, e diversos mecanismos de comunicação e sincronização, como memória compartilhada, pipes e semáforos;
- Suporte a um grande número de aplicativos disponíveis no mercado, sendo muitos gratuitos;
- Suporte a diversos protocolos de rede, como o TCP/IP, e interfaces de programação, como sockets, podendo ser utilizado como servidor de comunicação, roteador, firewall e proxy;
- Implementação de sistema de arquivos com uma estrutura bastante simples, onde os arquivos são representados apenas como uma seqüência de bytes. Além disso, existem diversas opções para sistemas de arquivos distribuídos, como NFS (Network File System), AFS (Andrew File System) e DFS (Distributed File System);
- Oferece uma interface simples e uniforme com os dispositivos de E/S.

15.3 Estrutura do Sistema

A maior parte do código que compõe o núcleo do Unix é escrita em Linguagem C e o restante, como os device drivers, em assembly, o que confere ao sistema uma grande portabilidade para diferentes plataformas de hardware.

O Unix utiliza o modelo de camadas para a estruturação do sistema, implementando dois níveis de modo de acesso: usuário e kernel. A Fig. 15.2 apresenta as camadas do sistema de forma simplificada, sem a preocupação de representar a estrutura interna real e abranger a maioria das implementações.

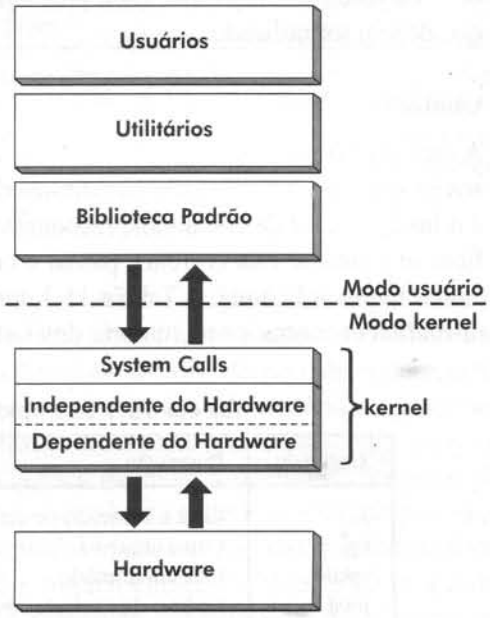

Fig. 15.2 Estrutura do Unix.

- Kernel

O kernel é responsável por controlar o hardware e fornecer as system calls para que os programas tenham acesso às rotinas do sistema, como criação e gerência de processos, gerência de memória virtual, sistema de arquivos e gerência de E/S.

O kernel pode ser dividido em duas partes: a parte dependente do hardware e a parte independente do hardware. A parte dependente do hardware consiste nas rotinas de tratamento de interrupções e exceções, device drivers, tratamento de sinais, ou seja, todo o código que deve ser reescrito quando se está portando um sistema Unix para uma nova plataforma. A parte independente do hardware não deve ter a princípio nenhum vínculo com a plataforma onde está sendo executada, e é responsável pelo tratamento das system calls, gerência de processos, gerência de memória, escalonamento, pipes, paginação, swapping e sistema de arquivos.

O kernel do Unix, comparado com o de outros sistemas operacionais, oferece um conjunto relativamente pequeno de system calls, a partir das quais podem ser construídas rotinas de maior complexidade. A estratégia de criar um sistema modular e simples foi muito importante no desenvolvimento do Unix, pois novos utilitários podem ser facilmente integrados ao sistema, sem que o kernel tenha que sofrer qualquer tipo de alteração.

- Biblioteca Padrão

Para cada rotina do sistema, existe um procedimento na biblioteca padrão do Unix que permite esconder os detalhes da mudança de modo de acesso usuário-kernel-usuário. A biblioteca implementa uma interface entre os programas e o sistema operacional, fazendo com que as system calls sejam chamadas. O POSIX define a biblioteca padrão e não as system calls, ou seja, quais procedimentos a biblioteca deve oferecer, as funções de cada procedimento e os parâmetros de entrada e saída que devem ser utilizados.

- Utilitários

A camada mais externa do sistema é a interface com o usuário, formada por diversos programas utilitários, como editores de textos, compiladores e o shell. O shell é o interpretador de comandos, responsável por ler os comandos do usuário, verificar se a sintaxe está correta e passar o controle para outros programas que realizam a tarefa solicitada. A Tabela 15.1 apresenta alguns exemplos de comandos e utilitários encontrados na maioria dos sistemas Unix.

Tabela 15.1 Exemplos de comandos e utilitários

Utilitário	Descrição
ls	Lista o conteúdo de diretórios.
cp	Copia arquivos.
mkdir	Cria um diretório.
pwd	Exibe o diretório corrente.
grep	Pesquisa por um determinado padrão dentro do arquivo.
sort	Ordena um arquivo.
cc	Executa o compilador C.
vi	Permite a criação e edição de arquivos textos, como programas e scripts.

Devido às várias implementações do Unix, três interpretadores de comandos se tornaram populares. O Bourne Shell (sh) foi o primeiro shell disponível e pode ser encontrado em todas as versões do Unix. O C Shell (csh) é o padrão para o BSD e o Korn Shell (ksh), padrão para o System V. Além das interfaces orientadas a caracter, existem também interfaces gráficas disponíveis, como o X Windows System.

15.4 Processos e Threads

O Unix, como um sistema multiprogramável, suporta inúmeros processos, que podem ser executados concorrentemente ou simultaneamente. O modelo de processo implementado pelo sistema é muito semelhante ao apresentado no Capítulo Processo. As primeiras versões do Unix não implementavam o conceito de threads, porém as versões mais recentes já oferecem algum tipo de suporte a aplicações multithread.

Um processo é criado através da system call fork. O processo que executa o fork é chamado de processo pai, enquanto que o novo processo é chamado processo filho ou subprocesso. Cada processo filho tem seu próprio espaço de endereçamento individual, independente do processo pai. Apesar de o espaço de endereçamento dos subprocessos ser independente, todos os arquivos abertos pelo pai são compartilhados com seus filhos. Sempre que um processo é criado, o sistema associa identificadores, que fazem parte do contexto de software, permitindo implementar mecanismos de segurança (Tabela 15.2).

Tabela 15.2 Identificadores

Identificador	Descrição
PID	O Process Identification identifica unicamente um processo para o sistema.
PPID	O Parent Process Identification identifica o processo pai.
UID	O User Identification identifica o usuário que criou o processo.
GID	O Group Identification identifica o grupo do usuário que criou o processo.

A system call fork, além de criar o subprocesso, copia o espaço de endereçamento do processo pai para o filho, incluindo o código executável e suas variáveis. Por ser apenas uma cópia, qualquer alteração no espaço de endereçamento do processo filho não implica modificação das posições de memória do processo pai. As versões mais recentes do Unix utilizam a técnica conhecida como copy-on-write para evitar a duplicação de todo o espaço de endereçamento do processo pai e o tempo gasto na tarefa. Nesse esquema, o espaço de endereçamento do processo pai é compartilhado com o filho, sendo copiadas apenas as páginas que foram alteradas pelo subprocesso. Uma outra solução, implementada no Unix BSD, é a utilização da system call vfork, que não copia o espaço de endereçmanto do processo pai.

Quando o sistema é ativado, o processo 0 é criado, o qual por sua vez cria o processo 1. Esse processo, conhecido como init, é o pai de todos os outros processos que

venham a ser criados no sistema. Sempre que um usuário inicia uma sessão, o processo init cria um novo processo para a execução do shell. Quando o usuário executa um comando, dois eventos podem ocorrer: o shell pode criar um subprocesso para a execução do comando ou o próprio shell pode executar o comando no seu próprio contexto.

No Unix é possível criar processos foreground e background. No primeiro caso, existe uma comunicação direta do usuário com o processo durante a sua execução. Processos background não podem ter interação com o usuário e são criados com o uso do símbolo &. O comando a seguir mostra a criação de um processo background para a execução de prog.

```
# pgm &
```

Processos do sistema operacional no Unix são chamados de daemons. Os daemons são responsáveis por tarefas administrativas no sistema, como, por exemplo, escalonamento de tarefas (cron), gerência de filas de impressão, suporte a serviços de rede, suporte à gerência de memória (swapper) e gerência de logs. Os daemons são criados automaticamente durante a inicialização do sistema.

Processos no Unix podem se comunicar através de um mecanismo de troca de mensagens, conhecido como pipe. O comando a seguir mostra o mecanismo de pipe entre dois processos. O primeiro processo é criado a partir da execução do comando ls, que lista os arquivos do diretório corrente. A saída desse processo é redirecionada para a entrada do segundo processo, criado para a execução do comando grep. O comando grep seleciona dentre a lista de arquivos as linhas que possuem o string pgm.

```
# ls | grep pgm
```

Outro mecanismo de comunicação entre processos muito importante no Unix é conhecido como sinal. Um sinal permite que um processo seja avisado da ocorrência de eventos síncronos ou assíncronos. Por exemplo, quando um programa executa uma divisão por zero, o sistema avisa ao processo do problema através de um sinal. O processo, por sua vez, pode aceitar o sinal ou simplesmente ignorá-lo. Caso o processo aceite o sinal, é possível especificar uma rotina de tratamento.

Sinais são definidos de diferentes maneiras em cada versão do Unix. O POSIX define um conjunto de sinais padrões que devem ser suportados pelo Unix, a fim de compatibilizar a utilização de sinais. A Tabela 15.3 apresenta alguns dos sinais definidos pelo POSIX.

Um processo no Unix é formado por duas estruturas de dados: a estrutura do processo (proc structure) e a área do usuário (user area ou u area). A estrutura do processo, que contém o seu contexto de software, deve ficar sempre residente na memória principal, enquanto a área do usuário pode ser retirada da memória, sendo necessária apenas quando o processo é executado. A Tabela 15.4 apresenta um resumo das informações contidas nessas duas estruturas.

Tabela 15.3 Sinais POSIX

Sinal	Descrição
SIGALRM	Sinaliza o término de um temporizador.
SIGFPE	Sinaliza um erro em uma operação de ponto flutuante.
SIGILL	Sinaliza que a tecla DEL ou CTRL-C foi digitada para interromper o processo em execução.
SIGKILL	Sinaliza que o processo deve ser eliminado.
SIGTERM	Sinaliza que o processo deve terminar.
SIGSEGV	Sinaliza que o processo fez acesso a um endereço inválido de memória.
SIGUSR1	Pode ser definido pela própria aplicação.
SIGUSR2	Pode ser definido pela própria aplicação.

Tabela 15.4 Processo no Unix

Estrutura do processo	Área do usuário
Identificação: PID, PPID, GID e UID	Registradores
Estado do processo e prioridade	Tabela de descritores de arquivos
Endereço da área do usuário	Contabilidade de recursos do sistema, como UCP, memória e disco
Máscara de sinais	Informações sobre a system call corrente
Ponteiros para as tabelas de páginas	Tratadores de sinais

Os processos existentes no sistema são organizados em um vetor, chamado tabela de processos, onde cada elemento representa uma estrutura do processo. O tamanho desse vetor é predefinido e limita o número máximo de processos no sistema. A estrutura do processo, por sua vez, possui um ponteiro para a área do usuário. Quando um processo executa um fork, o sistema procura por um elemento livre na tabela de processos, onde é criada a estrutura do processo filho, a partir das informações copiadas da estrutura do processo pai.

A Tabela 15.5 apresenta algumas system calls voltadas para a gerência de processos disponíveis na maioria dos sistemas Unix.

Tabela 15.5 Gerência de processos

System call	Descrição
fork	Cria um processo filho idêntico ao processo pai.
execve execv execl execle	Permite substituir o código executável do processo filho depois da sua criação.
waitpid	Aguarda até o término do processo filho.
exit	Termina o processo corrente.
kill	Envia um sinal para um processo.
sigaction	Define qual ação deve ser tomada ao receber um determinado sinal.
alarm	Permite definir um temporizador.

Em função do overhead gerado no mecanismo de criação e eliminação de processos, vários sistemas Unix implementaram o conceito de threads, porém sem qualquer preocupação com compatibilidade (Tabela 15.6). Em 1995, o padrão POSIX P1003.1c, também conhecido como Pthreads, foi aprovado, permitindo que aplicações multithread pudessem ser desenvolvidas de forma padronizada.

Tabela 15.6 Arquitetura de threads

Ambiente	Arquitetura
Compaq Unix 5	Modo híbrido
IBM-AIX 4.2	Modo kernel
HP-UX 10.1	Modo usuário
Linux 2	Modo kernel
Sun Solaris 8	Modo híbrido
SunOS 4	Modo usuário

O POSIX não define como os threads devem ser implementados no sistema, ou seja, o padrão pode ser implementado utilizando pacotes apenas em modo usuário, modo kernel ou uma combinação de ambos (modo híbrido). As vantagens e desvantagens de cada tipo de implementação podem ser consultadas no capítulo Thread. O padrão POSIX também define mecanismos de sincronização entre threads, como semáforos, mutexes e variáveis condicionais. A Tabela 15.7 apresenta as principais system calls definidas pelo Pthreads.

Tabela 15.7 Gerência de POSIX threads

System call	Descrição
pthread_create	Cria de um novo thread.
pthread_exit	Finaliza o thread corrente.
pthread_join	Aguarda pelo término de um thread.
pthread_mutex_init	Cria um mutex.
pthread_mutex_lock	Verifica o estado do mutex.
pthread_mutex_unlock	Libera o mutex.
pthread_mutex_destroy	Elimina o mutex.
pthread_cond_init	Cria uma variável condicional.
pthread_cond_wait	Aguarda por uma variável condicional.
pthread_cond_signal	Libera um thread.
pthread_cond_destroy	Elimina uma variável condicional.

15.5 Gerência do Processador

A gerência do processador no Unix utiliza dois tipos de política de escalonamento: escalonamento circular com prioridades e escalonamento por prioridades. A política de escalonamento tem o objetivo de permitir o compatilhamento da UCP por vários processos interativos e batch, além de oferecer baixos tempos de respostas para os usuários interativos.

Os processos no Unix podem ter prioridades entre 0 e 127, e quanto menor o valor, maior a prioridade. Processos executados no modo usuário têm valor de prioridade entre 50 a 127 (menor prioridade), enquanto processos no modo kernel têm valores de prioridade entre 0 e 49 (maior prioridade). Os processos no estado de pronto ficam aguardando para serem escalonados em diversas filas, cada fila associada a uma prioridade. O algoritmo de escalonamento seleciona para execução o processo de maior prioridade, ou seja, o primeiro processo da fila de menor valor (Fig. 15.3). O processo, depois de escalonado, poderá permanecer no processador no máximo uma fatia de tempo, que varia entre 10 e 100 milissegundos. Depois de terminado seu quantum, o processo retorna para o final da fila associada à sua prioridade.

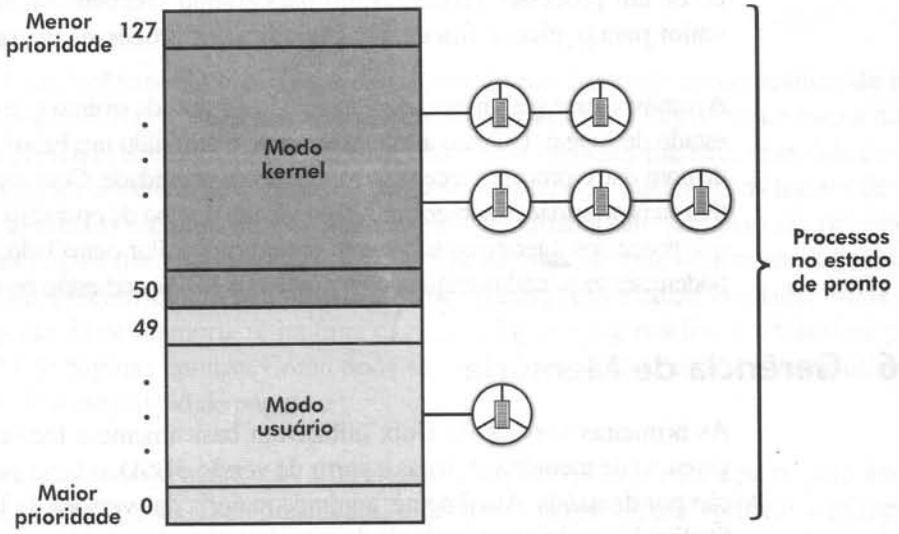

Fig. 15.3 Níveis de prioridade.

O escalonador recalcula a prioridade de todos os processos no estado de pronto periodicamente. Para realizar o cálculo da nova prioridade, é utilizada a fórmula a seguir com base em três variáveis: p_cpu, p_nice e base.

$$\text{Prioridade} = \text{p_cpu} + \text{p_nice} + \text{base}$$

A variável p_cpu pertence ao contexto de software do processo e permite contabilizar o tempo durante o qual o processo utilizou o processador. Quando o processo é criado, a variável é inicializada com zero. Sempre que o processo é executado, o valor de p_cpu é incrementado de uma unidade a cada tick do clock até o valor máximo de 127. Quanto maior o valor da variável, menor será sua prioridade. A variável p_cpu permite penalizar os processos CPU-bound e, dessa maneira, distribuir de forma mais igualitária o processador.

O escalonador, além de recalcular a prioridade dos processos, também reduz o valor de p_cpu periodicamente, com base no valor de decay. O cálculo de decay varia conforme a versão do Unix e tem a função de evitar o problema de starvation de processos de baixa prioridade. Quanto menos um processo utilizar o processador, menor será o valor de p_cpu e, logo, maior sua prioridade. Esse esquema também privilegia processos I/O-bound, pois mantém suas prioridades elevadas, permitindo que tenham maiores chances de serem executados quando saírem do estado de espera.

No BSD, a variável p_nice pode assumir valores entre 0 e 39, sendo o default 20. Quanto maior o valor atribuído à variável, menor a prioridade do processo. A variável permite alterar a prioridade de um processo de diferentes maneiras. A própria aplicação pode reduzir voluntariamente a sua prioridade a fim de não prejudicar os demais processos utilizando a system call nice. O administrador do sistema pode reduzir o valor da variável utilizando o comando nice, aumentando assim a prioridade de um processo. Processos em background recebem automaticamente um valor maior para p_nice, a fim de não prejudicar os processos interativos.

A variável base geralmente está associada ao tipo de evento que colocou o processo no estado de espera. Quando a espera termina, é atribuído um baixo valor à variável, fazendo com que o processo receba um aumento de prioridade. Com isso, processos I/O-bound têm suas prioridades aumentadas dependendo do tipo de operação realizada, fazendo com que processos interativos não sejam prejudicados. Por outro lado, processos CPU-bound podem ser executados enquanto os processos I/O-bound estão no estado de espera.

15.6 Gerência de Memória

As primeiras versões do Unix utilizavam basicamente a técnica de swapping para a gerência de memória. Apenas a partir da versão 3BSD, o Unix passou a utilizar paginação por demanda. Atualmente, a grande maioria das versões do Unix, tanto BSD como System V, implementa gerência de memória virtual por paginação com swapping. Neste item, será apresentada uma abordagem com base na versão 4BSD, mas grande parte dos conceitos e mecanismos apresentados também podem ser encontrados no System V.

No Unix, os conceitos de espaço de endereçamento virtual e mapeamento seguem as mesmas definições apresentadas no capítulo Gerência de Memória Virtual. Muitos detalhes de implementação, como tamanho de página, níveis de tabelas de páginas e TLBs, são dependentes da arquitetura de hardware, podendo variar conforme a versão de cada sistema.

O espaço de endereçamento dos processos no Unix é dividido em três segmentos: texto, dados e pilha (Fig. 15.4). O segmento de texto corresponde à área onde está o código executável dos programas, sendo uma área protegida contra gravação. O segmento de texto é estático e pode ser compartilhado por vários processos, utilizando o esquema de memória compartilhada. O segmento de dados corresponde às variáveis do programa, como tipos numéricos, vetores e strings. A área de dados é dinâmica, podendo aumentar ou diminuir durante a execução do programa. A pilha armazena informações de controle do ambiente do processo, como parâmetros passados a um procedimento ou system call. A área de pilha cresce dinamicamente do endereço virtual mais alto para o mais baixo.

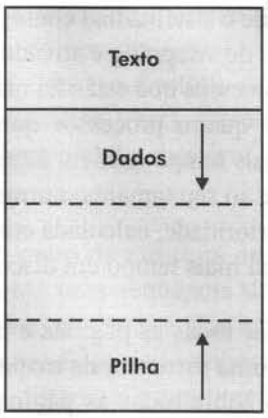

Fig. 15.4 Espaço de endereçamento.

O Unix implementa o esquema de paginação por demanda como política de busca de páginas. Nesse esquema, páginas do processo são trazidas do disco para a memória principal apenas quando são referenciadas. O sistema mantém uma lista de páginas livres com todos os frames disponíveis na memória e gerencia os frames de todos os processos em uma lista de páginas em uso. Quando um processo faz referência a uma página que não se encontra na lista de páginas em uso, ocorre um page fault. O sistema identifica se a página está na memória através do bit de validade. Nesse caso, a gerência de memória retira uma página da lista de páginas livres e transfere para a lista de páginas em uso. Como pode ser observado, o Unix utiliza uma política global de substituição de páginas.

O mecanismo de paginação é implementado parte pelo kernel e parte pelo daemon page (processo 2). Periodicamente, o daemon é ativado para verificar o número de páginas livres na memória. Se o número de páginas for insuficiente, o daemon page inicia o trabalho de liberação de páginas dos processos para recompor a lista de páginas livres. As páginas de texto podem ser transferidas sem problemas para a lista de páginas livres, pois podem ser recuperadas no arquivo executável. Por outro lado, para as páginas de dados, o sistema utiliza o bit de modificação para verificar se a página foi modificada. Nesse caso, antes de ser liberada para a lista de páginas livres, a página é gravada em disco.

O sistema implementa uma variação do algoritmo FIFO circular como política de substituição de páginas. Esse algoritmo, conhecido como two-handed clock, utiliza dois ponteiros, ao contrário do FIFO circular, que implementa apenas um. O primeiro ponteiro fica à frente do segundo um certo número de frames na lista de páginas em uso. Enquanto o primeiro ponteiro desliga o bit de referência das páginas, o segundo verifica o seu estado. Se o bit de referência continuar desligado, significa que a página não foi referenciada desde o momento em que o primeiro ponteiro desligou o bit, fazendo com que essa página seja selecionada. Apesar de estarem liberadas para outros processos, as páginas selecionadas permanecem um certo tempo intactas na lista de páginas livres. Dessa forma, é possível que as páginas retornem aos processos de onde foram retiradas, eliminando-se a necessidade de acesso a disco. O daemon page também é responsável por implementar a política de substituição de páginas.

Em casos onde o sistema não consegue manter um número suficiente de páginas livres, o mecanismo de swapping é ativado. Nesse caso, o daemon swapper seleciona, inicialmente, os processos que estão há mais tempo inativos. Em seguida, o swapper seleciona dentre os quatro processos que mais consomem memória principal aquele que estiver há mais tempo inativo. Esse mecanismo é repetido até que a lista de páginas livres retorne ao seu tamanho normal. Para cada processo transferido para disco é atribuída uma prioridade, calculada em função de vários parâmetros. Em geral, o processo que está há mais tempo em disco é selecionado para retornar a memória principal.

Para controlar todas as páginas e listas na memória principal, a gerência de memória mantém uma estrutura de mapeamento dos frames na memória (*core map*), com informações sobre todas as páginas livres e em uso. O core map fica residente na parte não paginável da memória principal, juntamente com o kernel do sistema.

15.7 Sistema de Arquivos

O sistema de arquivos foi o primeiro componente a ser desenvolvido no Unix, e as primeiras versões comerciais utilizavam o System V File System (S5FS). Devido às suas limitações, Berkeley desenvolveu o Fast File System (FFS) introduzido no 4.2BSD. Posteriormente, o SVR4 passou também a suportar o sistema de arquivos de Berkeley.

Um arquivo no Unix é simplesmente uma seqüência de bytes sem significado para o sistema operacional, que desconhece se o conteúdo do arquivo representa um texto ou um programa executável. O sistema tem apenas a função de prover o acesso seqüencial ou aleatório ao arquivo, ficando a cargo da aplicação a organização e outros métodos de acesso. O tamanho do nome de arquivos era, inicialmente, limitado a 14 caracteres, mas as versões mais recentes ampliam esse nome para 255 caracteres.

O sistema de arquivos do Unix tem como base uma estrutura de diretórios hierárquica, sendo o diretório raiz (root) representado pela barra (/). Os diretórios são implementados através de arquivos comuns, responsáveis pela manutenção da estrutura hierárquica do sistema de arquivos. Todo diretório contém os nomes de arquivos ponto (.) e dois pontos (..), que correspondem, respectivamente, ao próprio diretório e ao seu diretório pai (Fig. 15.5).

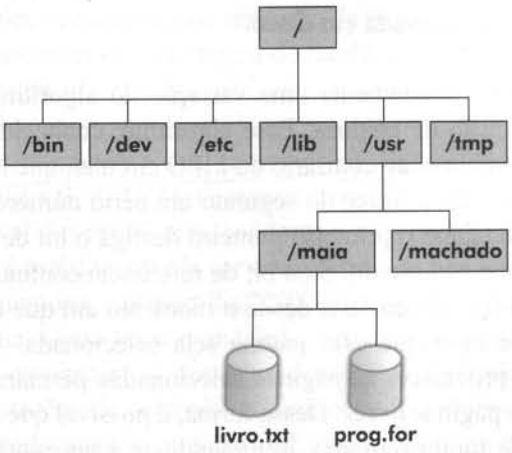

Fig. 15.5 Estrutura de diretórios.

Alguns nomes de diretório do sistema de arquivos são padronizados, como o diretório de programas executáveis do sistema (/bin), o diretório de arquivos especiais ligados aos dispositivos de E/S (/dev), o diretório de bibliotecas (/lib) e diretório que agrupa os subdiretórios dos usuários (/usr). Geralmente, cada usuário possui seu diretório default de login, denominado diretório home ou de trabalho (/maia e /machado).

A localização de um arquivo dentro da estrutura de diretórios é indicada utilizando-se um *pathname*, que representa uma seqüência de diretórios separados por barra. Existem dois tipos de pathname: absoluto e relativo. Um pathname absoluto indica a localização de um arquivo através de uma seqüência completa de diretórios e subdiretórios, a partir da raiz do sistema de arquivos. Um pathname relativo indica a localização de um arquivo a partir do diretório corrente. Por exemplo, na Fig. 15.5 o pathname /usr/maia/livro.txt representa o caminho absoluto para o arquivo livro.txt. Caso um usuário esteja posicionado no diretório /usr/machado, basta especificar o caminho relativo ../maia/livro.txt para ter acesso ao mesmo arquivo.

O sistema de arquivos proporciona um mecanismo para compartilhamento de arquivos conhecido como link simbólico. Um link é uma entrada em um diretório que faz referência a um arquivo em um outro diretório. Um arquivo pode possuir múltiplos links, de forma que diferentes nomes de arquivos podem ser utilizados por diversos usuários no acesso às informações de um único arquivo. O número de links de um arquivo é o número de diferentes nomes que ele possui. Existem diversas vantagens na utilização de links, como redução de utilização de espaço em disco, uma vez que existe uma única cópia dos dados, compartilhamento entre diversos usuários da última versão do arquivo e facilidade de acessso a arquivos em outros diretórios.

Cada arquivo no Unix pertence a uma ou mais dentre três categorias de usuários. Todo arquivo ou diretório tem um dono (user) e pertence a um grupo (group). Qualquer usuário que não seja o dono do arquivo e não pertença ao grupo enquadra-se na categoria outros (others). O administrador do sistema, utilizando a conta root, não pertence a nenhuma das categorias acima, tendo acesso irrestrito a todos os arquivos. Para cada categoria de usuário, podem ser concedidos três tipos de acesso: leitura (r), gravação (w) e execução (x). A Tabela 15.8 apresenta as permissões que podem ser aplicadas a arquivos e diretórios.

Tabela 15.8 Permissões para arquivos e diretórios

Arquivo	Descrição
r	Permissão para ler e copiar o arquivo.
w	Permissão para alterar e eliminar o arquivo.
x	Permissão para executar o arquivo.
Diretório	**Descrição**
r	Permissão para listar o conteúdo do diretório.
w	Permissão para criar, eliminar e renomear arquivos no diretório.
x	Permissão para que o usuário possa se posicionar no diretório e acessar os arquivos abaixo desse diretório.

A Tabela 15.9 apresenta algumas system calls relacionadas à gerência do sistema de arquivos, envolvendo operações com arquivos e diretórios.

Tabela 15.9 System calls do sistema de arquivos

System call	Descrição
creat	Cria um arquivo.
open	Abre um arquivo.
read	Lê um dado do arquivo para o buffer.
write	Grava um dado do buffer no arquivo.
position	Posiciona o ponteiro do arquivo.
close	Fecha um arquivo.
mkdir	Cria um diretório.
chdir	Altera o diretório default.
rmdir	Elimina um diretório.
link	Cria um link simbólico para um arquivo.
unlink	Elimina um link simbólico para um arquivo.

No Unix não existe uma dependência entre a estrutura lógica do sistema de arquivos e o local onde os arquivos estão fisicamente armazenados (Fig. 15.6). Dessa forma, é possível criar um sistema de arquivos onde os diretórios e arquivos estão fisicamente distribuídos em vários discos, porém para o usuário é como se existisse uma única estrutura lógica de diretórios. Esse modelo permite adicionar novos discos ao sistema de arquivos sempre que necessário, sem alterar sua estrutura lógica. Além disso, os diversos discos podem estar residentes em estações remotas. Nesse caso, existem padrões para a implementação de sistemas de arquivos remotos, como o Network File System (NFS), Remote File System (RFS) e Andrew File System (AFS).

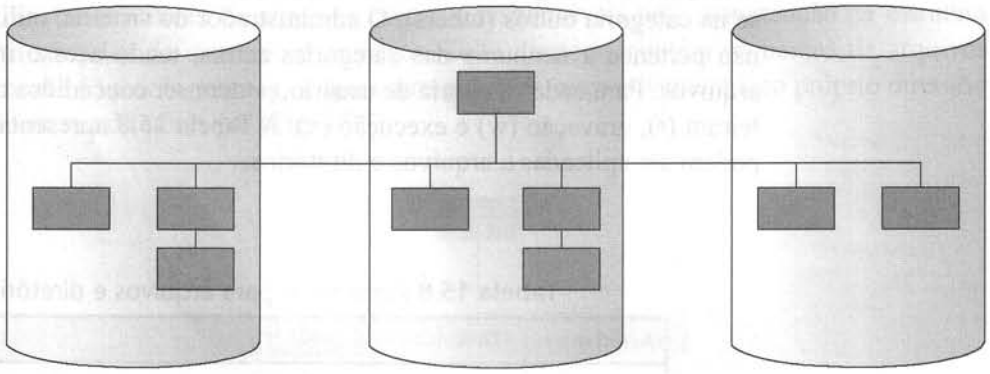

Fig. 15.6 Sistema de arquivos.

A estrutura do sistema de arquivos do Unix varia conforme a implementação. Em geral, qualquer disco deve ter a estrutura semelhante à descrita na Fig. 15.7. O boot block, quando utilizado, serve para realizar a carga do sistema. O super block possui informações sobre a estrutura do sistema de arquivos, incluindo o número de

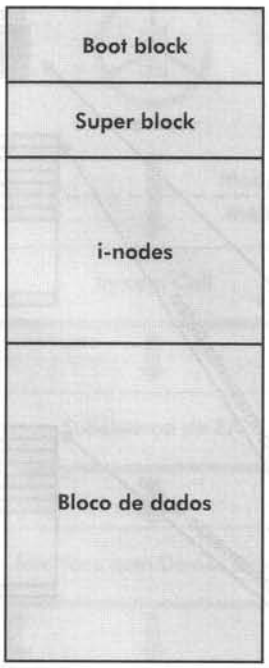

Fig. 15.7 Estrutura do sistema de arquivos.

i-nodes, o número de blocos do disco e o início da lista de blocos livres. Qualquer problema com o super block tornará inacessível o sistema de arquivos.

Os i-nodes (index-nodes) permitem identificar e mapear os arquivos no disco. Cada i-node possui 64 bytes e descreve um único arquivo, contendo seus atributos, como tamanho, datas de criação e modificação, seu dono, grupo, proteção, permissões de acesso, tipo do arquivo, além da localização dos blocos de dados no disco. Os blocos de dados contêm os dados propriamente ditos, ou seja, arquivos e diretórios. Um arquivo pode ser formado por um ou mais blocos, contíguos ou não no disco.

No caso de arquivos pequenos, todos os blocos que compõem o arquivo podem ser mapeados diretamente pelo i-node. No caso de arquivos grandes, o número de entradas para endereçamento no i-node não é suficiente para mapear todos os blocos do arquivo. Nesse caso, utilizam-se os redirecionamentos único, duplo e triplo. No redirecionamento único, uma das entradas no i-node aponta para uma outra estrutura, que por sua vez endereça os blocos do arquivo no disco. Os redirecionamentos duplo e triplo são apenas uma extensão do conceito apresentado (Fig. 15.8).

15.8 Gerência de Entrada/Saída

A gerência de entrada/saída no Unix foi desenvolvida de forma integrada ao sistema de arquivos. O acesso aos dispositivos de E/S, como terminais, discos, impressoras e a própria rede, é feito através de arquivos especiais. Cada dispositivo está associado a um ou mais arquivos especiais, localizados no diretório /dev. Por exemplo, uma impressora pode ser o arquivo /dev/1p; um terminal, /dev/tty1; e uma interface de rede, /dev/net.

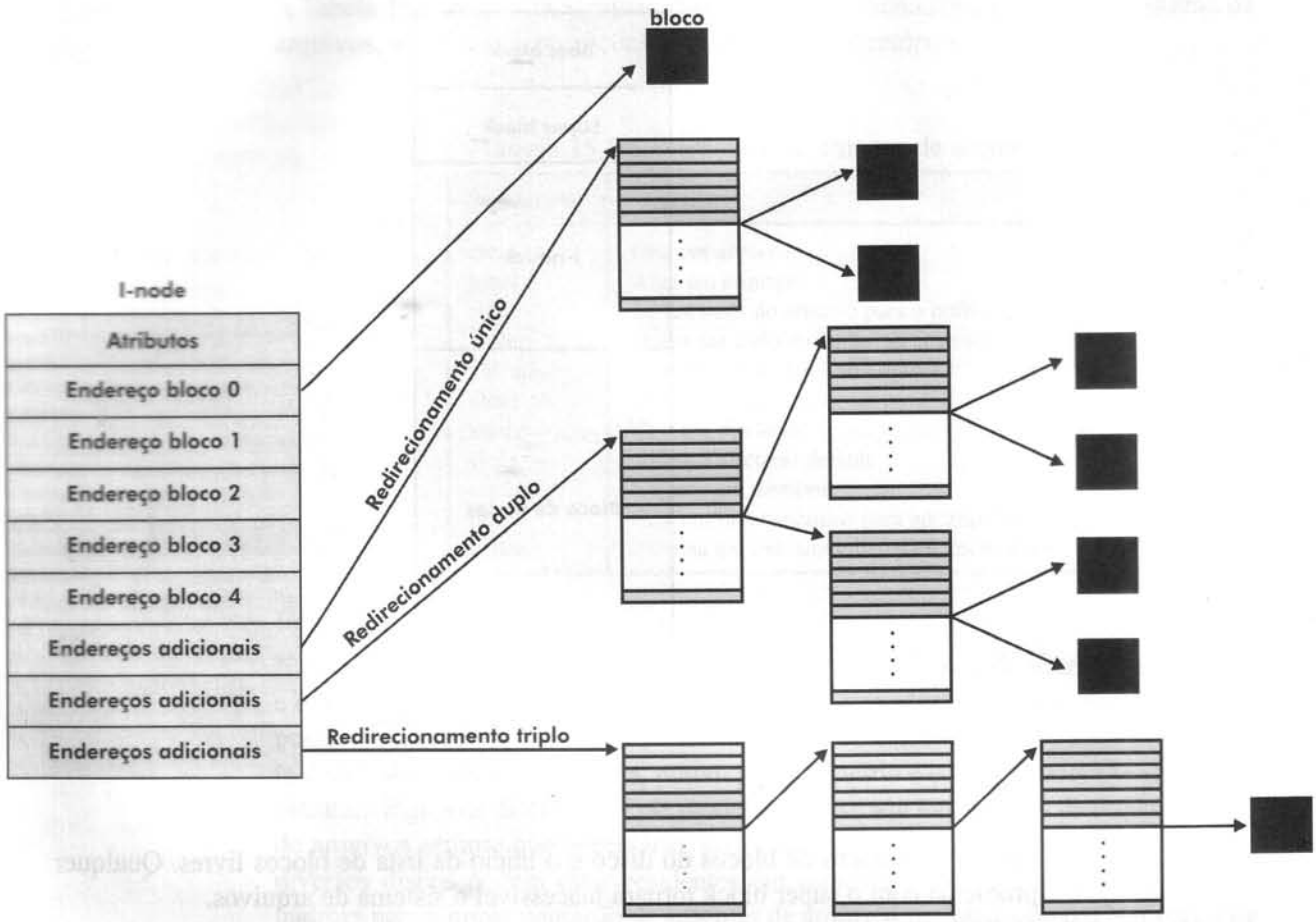

Fig. 15.8 Estrutura do i-node.

Os arquivos especiais podem ser acessados da mesma forma que qualquer outro arquivo, utilizando simplesmente as system calls de leitura e gravação. No Unix, todas as operações de E/S são realizadas como uma seqüência de bytes, não existindo o conceito de registro ou método de acesso. Isso permite enviar o mesmo dado para diferentes dispositivos de saída, como um arquivo em disco, terminal, impressora ou linha de comunicação. Dessa forma, as system calls de E/S podem manipular qualquer tipo de dispositivo de maneira uniforme.

A Fig. 15.9 apresenta as camadas que compõem a gerência de E/S no Unix. Os processos se comunicam com o subsistema de E/S através das system calls de E/S. O subsistema de E/S é a parte do kernel responsável por lidar com as funções entrada e saída independentes do dispositivo, como buffering e controle de acesso. Para permitir a comunicação entre o subsistema de E/S e os diferentes drivers de maneira uniforme, o sistema implementa uma interface com os device drivers, padronizada com base nas especificações Device Driver Interface (DDI) e Driver Kernel Interface (DKI).

Os device drivers têm a função de isolar os dispositivos de E/S do restante do kernel, tornando-o independente da arquitetura de hardware, e para cada dispositivo

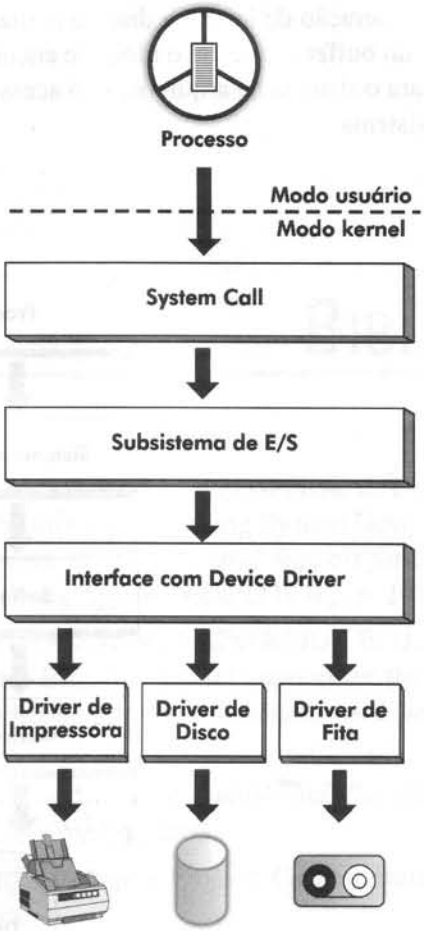

Fig. 15.9 Gerência de E/S.

existe um device driver associado. Os device drivers são acoplados ao sistema operacional quando o kernel é gerado, e sempre que um novo dispositivo é acrescentado ao sistema, o driver correspondente deve ser acoplado ao núcleo. A tarefa de geração do kernel não é simples e exige que o sistema seja reinicializado. As versões mais recentes do Unix, como o Linux, permitem que os device drivers possam ser acoplados ao núcleo com o sistema em funcionamento, sem a necessidade de uma nova geração do kernel e reinicialização do sistema.

Os device drivers podem ser divididos em dois tipos: orientados a bloco e orientados a caractere. Os device drivers orientados a bloco estão ligados a dispositivos como discos e CD-ROMs, que permitem a transferência de blocos de informações do mesmo tamanho. Os drivers orientados a caractere são voltados para atender dispositivos como terminais e impressoras que transferem informação de tamanho variável, geralmente caractere a caractere ou uma seqüência de caracteres.

No caso das operações orientadas a bloco, deve existir a preocupação em minimizar o número de transferências entre o dispositivo e a memória, utilizando o buffer cache (Fig. 15.10). O buffer cache é uma área na memória principal onde ficam armazenados temporariamente os blocos recentemente referenciados. Por exemplo, quando

uma operação de leitura a disco é realizada, o subsistema de E/S verifica se o bloco está no buffer cache. Se o bloco se encontra no cache, é possível passá-lo diretamente para o sistema de arquivos, sem acesso ao disco, melhorando assim o desempenho do sistema.

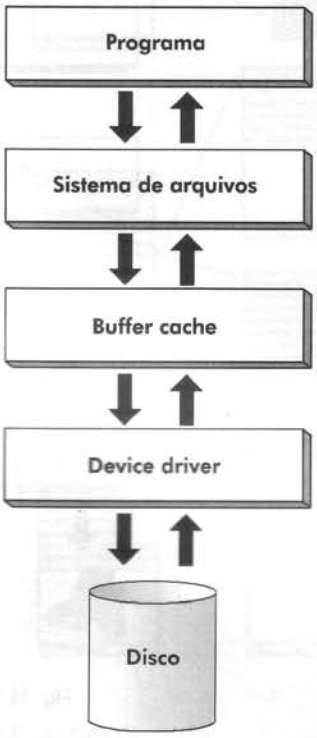

Fig. 15.10 Operação orientada a bloco.

BIBLIOGRAFIA

ANDERSON, T. E., BERSHAD, B. N., LAZOWSKA, E. D., LEVY, H. M. The Interaction of Architecture and Operating System Design. *Proc. Fourth International Conference on Architectural Support for Programming Languages and Operating Systems (ASPLOS IV)*, p. 108-120, April, 1991.

ANDERSON, T. E., BERSHAD, B. N., LAZOWSKA, E. D., LEVY, H. M. Scheduler Activations: Effective Kernel Support for the User-Level Management of Parallelism. *ACM Transactions on Computer Systems*, vol. 10, p. 53-79, Feb., 1992.

ANDREWS, Gregory R. *Foundations of Multithread, Parallel, and Distributed Programming*. Addison-Wesley, 2000.

AUDE, Júlio S. *The Multiplus/Mulplix Project: Current Status and Perspectives*. NCE/IM/UFRJ, 1996.

BACH, Maurice J. *The Design of the Unix Operating System*. Prentice-Hall, 1986.

BACON, Jean. *Concurrent Systems: Operating Systems, Database and Distributed Systems*. Addison-Wesley, 1997.

BEN-ARI, M. *Principles of Concurrent and Distributed Programming*. Prentice-Hall, 1990.

CHOW, Randy, JOHNSON, Theodore. *Distributed Operating Systems and Algorithms*. Addison-Wesley, 1997.

COFFMAN, E. G., ELPHICK, M. J., SHOSHANI, A. System Deadlocks. *Computing Surveys*, vol. 3, p. 67-78, 1971.

CONWAY, M. A Multiprocessor System Design. *Proceedings of the AFIPS. Fall Joint Computer Conference*, 1963.

CORBATÓ, F. J., DAGGETT, M. M., DALEY, R. C. An Experimental Time-Sharing System. *Proceedings AFIPS Spring Joint Computer Conference*, p. 334-335, 1962.

CORBATÓ, F. J., VYSSOTSKY, V. A. Introdution and Overview of the Multics System. *Proceedings AFIPS Fall Joint Computer Conference*, p. 185-196, 1965.

COULOURIS, George, DOLLIMORE, Jean, KINDBERG, Tim. *Distributed Systems: Concepts and Design*. Addison-Wesley, 1995.

ARQUITETURA DE SISTEMAS OPERACIONAIS

Este livro aborda a arquitetura e o funcionamento dos sistemas operacionais multiprogramáveis de forma atual, abrangente e didática. Seu conteúdo é direcionado a estudantes e a profissionais de informática de todas as áreas. Como pré-requisito básico para sua leitura, é necessário apenas algum conhecimento de organização de computadores e estrutura de dados. *Arquitetura de Sistemas Operacionais* pode ser utilizado integralmente em disciplinas universitárias de graduação ou parcialmente em cursos de extensão.

O livro aborda entre outros tópicos:

- Evolução dos sistemas operacionais;
- Tipos e características de sistemas multiprogramáveis;
- Mecanismos de interrupção e sinalização, técnicas de spooling, buffering e DMA;
- Estrutura do sistema operacional e modos de acesso;
- Processos e threads;
- Mecanismos e algoritmos de comunicação e sincronização entre processos;
- Semáforos, monitores e deadlock;
- Escalonamento de processos;
- Gerência de memória virtual por paginação e segmentação;
- Sistema de arquivos;
- Gerência de dispositivos de entrada/saída;
- Sistemas com múltiplos processadores;
- Estudos de caso: MS Windows e Unix.

O website **http://www.pobox.com/~aso** complementa a publicação com material disponível para professores e alunos, onde são encontrados:

- Plano de aulas para professores que queiram utilizar o livro como referência para cursos;
- Slides em MS PowerPoint para apoio nas aulas;
- Soluções dos exercícios propostos;
- Estudo de caso: OpenVMS;
- Links interessantes sobre sistemas operacionais;
- Atualizações;
- Novidades sobre o livro e assuntos ligados ao tema.

ISBN 978-85-216-1548-4

9 788521 615484

LTC LIVROS TÉCNICOS E CIENTÍFICOS EDITORA

www.ltceditora.com.br